AutoDex: 자동 실물 파지 데이터 수집 분석

arXiv:2606.23689v2 (2026-11-04) · CoRL 2026 채택(arXiv 댓글) · Seoul National University · 공식 코드 snuvclab/autodex-code (라이선스 없음, 커밋 448732d) · 분석일 2026-11-10 · 게시용 버전: 논문 그림과 원문 PDF는 뺐습니다(라이선스).

핵심 요약

1. **무엇을 하는가:** BODex가 만든 파지 후보를 20대 카메라 워크셀에서 Allegro 또는 Inspire 손으로 실행하고, 다시점 기록으로 성공·실패를 붙이고, 자세별 리셋으로 사람 없이 반복한다. 3,593회(성공 1,912) 수집이 주장이다(`01` §1-§3).
2. **구현 판정: 실물 재현은 불가능하다.** 공식 코드는 연구실 워크셀과 비공개 `paradex`가 필요하고, 이 맥에는 로봇도 CUDA도 없다. 라벨·리셋·검색 아이디어의 재구현은 중간 난이도다(`04` §4).
3. **처리량 주장이 바뀌었다:** v1은 "49.4 h 대 10.3 h, 4.8×"를 측정처럼 썼다. v2는 텔레옵 28.4 h를 "8시간 근무일 추정"으로 낮춰 2.8×로 쓴다. 사람 시간 0.2 h 대 9.3 h(46×)는 v2에서 추가됐고 추정치다(`02` §5, `03` §1).
4. **라벨 규칙이 세 가지이고 오차율은 없다:** 본문은 5 cm·3 s 유지, 실행 중 코드는 charuco 보드 가시성(들어 올린 직후 한 시점), 데이터셋 `success`는 GoTrack 높이 최댓값 > 50 mm다. 자동 라벨 오차 10%면 절대 성공률이 ±5 pp 움직인다(토이 A, `03` §3(c), §4).
5. **검증 효과 76% 대 34%는 p가 매우 작지만 독립성이 불명확하다:** 515회, 20물체, 팔당 횟수 없음. 분할을 바꿔도 $p < 10^{-14}$다. 문제는 물체 군집과 라벨 규칙이다(`03` §2.2).
6. **사람 개입 31/500(6.2%)은 정의가 없다:** 0.2 h를 31회로 나누면 회당 23 s다. 루프 밖 시간 3.6 h(35%)는 리셋과 개입이 섞여 있을 것이다. 리셋 실패율 6%면 개입 31회가 맞지만 개입 한 번이 600 s면 10.3 h와 맞지 않는다(`03` §3(e)-(f), §5).
7. **정책 학습 평가가 없다:** 검색(retrieval)으로만 평가했다. "AutoDex 데이터로 학습한 정책이 시뮬·텔레옵 데이터보다 낫나"라는 질문에 답하지 않는다(`01` §6).
8. **선택 편향 경로가 코드에 있다:** 판독 불가 시도는 버려진다. 자세 품질 게이트(`sil_loss > 0.003`)로 격리된 시도도 빠진다. 라벨 가능성이 난이도와 상관이면 DB 성공률이 최대 9.5 pp 과대 추정된다(토이 B, `04` D4, D7).
9. **저장소와 본문이 어긋난다:** 카메라 20대(본문) 대 24대(데이터·실험 코드), Inspire 1,367(본문) 대 384(데이터 설명서), 충돌 임계 값 3종(본문 없음, v1 30 N·m, 코드 20 N·m·70 N·m). `04` D8-D11, D6.

01. 논문 분석: AutoDex (arXiv:2606.23689v2)

대상: Choi, Kim, Kim, Kim, Ha, Lim, Joo, "AutoDex: An Automated Real-World System for Dexterous Grasping Data Collection", CoRL 2026 채택(arXiv 댓글 기준), v2 2026-11-04, 13쪽 본문·참고문헌. 인용은 절·그림·표 번호로 한다. 원문 텍스트는 `paper/paper.txt`(pdftotext -layout)다.

1. 한 문단 요약

공개된 시뮬레이션 기반 생성기(BODex)가 만든 손-물체 파지 후보를 실제 로봇으로 시험해, 들어 올리고 유지하는 성공·실패를 자동으로 붙여 데이터베이스를 만든다. 실험 장치는 20대 카메라 워크셀에 6-DoF xArm과 Allegro(16-DoF) 또는 Inspire(6-DoF) 손을 달고, 물체 6D 자세 추적, 잔차 토크 충돌 감지, 자세별 리셋으로 사람 개입 없이 돌리는 루프다. 100개 물체에서 3,593회를 수집했고(성공 1,912, 실패 1,681), 그중 손 방향(`approach`)·성공률·처리 시간을 텔레오퍼레이션과 비교했다. 저자의 핵심 주장은 두 가지다. 첫째, 500회 수집에 사람 주의 0.2 h가 든다(텔레오퍼레이션 9.3 h). 둘째, 검증된 DB에서 가져온 파지는 실제 성공률 76%이고, 시뮬레이션 필터만 거친 파지는 34%다(20개 물체, 515회). 정책을 학습해 평가하지는 않았다. 검색(retrieval)만 했다.

2. 문제 설정과 기여 (Sec. 1)

- **문제:** 다지(multi-finger) 파지는 기하 검증(IK, 충돌, 계획)을 통과해도 접촉 물리 때문에 실패한다(Sec. 1, p.1-2). 실물 검증은 사람 개입(자세 추정, 추적, 후보 선택, 안전, 라벨, 리셋)이 없어야 규모가 난다.
- **기여 3가지(Sec. 1, 3번째 단락):** (1) 생성 후보의 실물 실행·라벨을 자동화한 시스템, (2) 성공과 실패를 모두 담은 3,593회 DB, (3) 처리량·검증 효과·리셋·카메라 수에 대한 시스템 평가.
- **명시적 범위 제한(Sec. 5):** 들어 올리기(lift-and-hold) 기준은 파지 안정성만 본다. 도구 사용이나 건네주기에 충분한지는 보지 않는다. 후보 집합에 없는 파지는 수집되지 않는다. 20대 워크셀은 접근성이 낮다. 저자는 "2대 카메라로도 동작한다"고 쓴다(Sec. 5, 아래 §4.4 참조).

3. 방법 (Sec. 3, Fig. 1-4)

3.1 후보 생성 (Sec. 3.1)

- 생성기는 BODex [8]이다. 장면 제약은 벽(wall), 선반(shelf), 상자(box) 세 가지 평면 원형이다. 완전히 둘러싸여 손이 닿지 않는 배치는 제외한다.
- 물체의 안정 자세 집합 P를 정하고, 자세 Pi마다 후보 집합 Gcand(Pi)를 모은다. 자세가 바뀌면 그 자세의 후보만 본다. 본문은 생성 파라미터(간격, 시드 수, 사전 필터)를 적지 않는다. v1 부록에는 있었다(§5 v1→v2 차이).

3.2 워크셀 (Sec. 3.2, Fig. 2)

- 1.5×1.5×2.5 m LED 조명 셀, RGB 카메라 20대(2048×1536, 30 FPS, 하드웨어 동기 트리거, 서브 밀리초 동기). 캘리브레이션은 ChArUco 보드, COLMAP, 손-눈 캘리브레이션을 쓴다. 다중 시점 자세 자기일치는 "서브 밀리미터"라고 한다(수치 근거는 본문에 없다).
- 로봇 제어기 120 Hz, 관절 위치·속도·토크·모터 전류·명령값을 기록한다.
- 충돌 감지: 내장 충돌 감지기가 물체 하중과 손 관성 때문에 거짓 경보를 냈다고 쓴다. 그래서 자유 공간 토크를 MLP로 예측하고($\hat{\tau}\theta$ = MLPθ(q, $\dot{q}$)) 잔차 τres = $\hat{\tau}\theta$ – τmotor가 지속적으로 임계를 넘으면 접촉으로 본다. 접촉 구간(하강 등)에서만 켠다. 감지되면 실행을 멈추고 위로 물러나 홈 자세로 간다(Sec. 3.2 마지막 단락).

3.3 수집 루프와 라벨 (Sec. 3.3, Fig. 3 우측)

1. 여러 시점으로 6D 자세를 추정하고 현재 안정 자세 Pi를 정한다.
2. Gcand(Pi)를 로봇 좌표로 옮겨 IK가 없거나 충돌하는 후보를 뺀다. 남은 후보가 없으면 리셋(§3.4).
3. 선택한 후보를 계획하고, 열린 손 자세(clearance 최대화)에서 접근, 파지, 들어 올리기, 3 s 유지.
4. **라벨 규칙(본문):** 추적한 물체가 유지 구간 3 s 동안 초기 높이보다 5 cm 이상 떠 있으면 성공, 아니면 실패. v2 본문은 "영상 스트림 전체에 6D 추적을 돌린다"고만 쓴다. 실시간인지 사후인지는 v2에 없다(v1은 사후 적용이라고 명시했다, 02 §5).
5. 기록: 계획, 다시점 영상, 추적 자세, 카메라 보정, 시간 정보, 라벨. 물체를 내려놓고 후보를 "시도됨"으로 표시한다.

3.4 리셋 (Sec. 3.4, Fig. 3 좌측)

- 목표는 아직 시도할 후보가 남은 자세 중 가장 적게 본 자세 Pj다.
- 픽업 제약(Pi)과 배치 제약(Pj)을 하나의 충돌 장면으로 합쳐 두 끝점에서 모두 충돌하지 않는 리셋 파지를 찾는다.
- 직접 배치가 안 되면(평평한 물체) 높이 h에서 놓는다. h = 0부터 시작해 올린다. 낙하 후 가상 지지 기둥을 두어 손가락이 낙하 경로에 들어오지 않게 한다. 성공한 리셋 파지는 자세 쌍별로 캐시한다.

3.5 DB와 검색 실행 (Sec. 3.5, Fig. 4)

- DB는 실행된 시도만 저장한다. 성공 1,912, 실패 1,681. Allegro 2,226회(성공 39.4%), Inspire 1,367회(성공 75.7%). 물체 100개, 80% 이상이 IKEA 제품이고 플라스틱, 금속, 나무, 실리콘, 종이, 테이프, 세라믹을 포함한다.
- 배치 시 카메라 4대로 물체 자세와 장애물을 추정한다(SAM 3 [56], FoundationPose [57], Depth Anything 3 [58]로 마스크·초기 자세·깊이 재구성). 저장된 성공 파지를 현재 장면으로 옮기고, 팔 궤적이 장애물과 부딪히지 않는 첫 파지를 실행한다. 학습은 없다.

4. 결과 (Sec. 4, Fig. 5-6)

평가 집합은 100개 중 대표 20개 물체다(Sec. 4 첫 단락). 성공 기준은 "5 cm 들어 올리고 3 s 유지"로 적혀 있다.

4.1 처리량, 품질, 병목 (Sec. 4.1, Fig. 5 좌측, Fig. 3 우측)

항목	텔레오퍼레이션	AutoDex	본문 설명
500회 벽시계	28.4 h	10.3 h	"8시간 근무일" 가정 추정(텔레옵)
사람 시간	9.3 h(연속 8.3 + 준비 1.0)	0.2 h(추정)	배치와 회복
개입	always	31	정의 없음
성공률	71.7%	50.7%	"각 캠페인 기준"
관절 저크	13.7 rad/s³	10.7 rad/s³	속도 평활 후
접근각 다양성	60°	82°	공통 34개 물체

- 루프 시간 평균 48.2 s(500회 완전 실행). 실행 51.5%(24.8 s), 후퇴 24.6%(11.9 s), 인지 16.1%(7.8 s), 계획 7.8%(3.8 s).
- 리셋 시간과 개입 시간은 루프 구성에 없다. 500회 10.3 h에서 루프 6.7 h를 빼면 3.6 h(35%)가 남는데, 본문에 이름이 없다.

4.2 물리 검증의 효과 (Sec. 4.2, Fig. 5 우측)

- 20개 물체, 515회, 세 장면(탁자, 벽, 잡동사니), 무게 세 구간, 재질 일곱 구간.
- AutoDex 검증 DB 76%, 모델 선별 DB 34%.

- 범주별 막대 값은 본문에 없다. 저장소의 `rebuttal_fig.py`에 들어 있고 막대 높이와 맞는다(03 §1). 잡동사니 장면에서 격차가 가장 크다고 쓴다. 검증 DB는 80-90%라고 쓴다.
- 두 팔에 각각 몇 회씩 갔는지, 같은 물체와 자세를 반복했는지, 라벨 규칙이 두 팔에 같았는지는 본문에 없다.

4.3 리셋 전략 (Sec. 4.3, Fig. 6 좌측)

- 비교: Naive Drop(들어 올려 떨어뜨리기), Reorient + Passive Release, 제안 방식(Stable Reorient Placement).
- 리셋 성공을 수동적 전이 확률 P(Pj|Pi)의 함수로 그린다. Naive Drop은 y = x 위에 있다(구성상 그렇다).
- Reorient + Passive Release는 5.3%의 시도에서 물체를 작업 영역 밖으로 튕겨 사람이 복구해야 한다고 쓴다. 제안 방식은 이런 실패가 없다고 쓴다.
- 시도 수(분모)가 없다.

4.4 카메라 수와 자세 신뢰도 (Sec. 4.4, Fig. 6 우측)

- 20대 전체를 기준으로 k ∈ {2, 4, 8, 16} 대만 써서 다시 정제한 자세와의 평균 ADD-S: k=2에서 14.3 mm, k=16에서 0.5 mm. 큰 차이는 k=2에서 k=4 사이에 생긴다. 51회, 물체 5개.
- 분산이나 분위수가 없다. k=2의 큰 평균은 "텍스처가 없거나 얇은 물체의 가끔 생기는 큰 실패"가 이끈다고 쓴다.
- Sec. 5는 "수집 파이프라인은 카메라 2대로도 동작한다"고 쓴다. 본문에서 2대 결과는 14.3 mm 평균 오차다. 이 수치와 "2대로도 동작"이라는 주장은 같이 놓고 읽어야 한다(04 D9, 03 §6).

5. 한계와 저자가 밝힌 것 (Sec. 5)

- 사람은 물체를 놓는 일과 회복을 맡는다. 리셋과 수집은 자동이라고 쓴다.
- 파지 후보 집합은 입력으로 주어지고 수집은 그 집합에 제한된다.
- 들어 올리기 기준은 도구 사용과 건네주기에 충분한지 말해 주지 않는다.
- 20대 워크셀은 접근성을 떨어뜨린다.
- 검색 실험은 "데이터베이스에 있는 물체와 손의 범위" 안에서만 성립한다고 한정한다.

6. 읽으면서 본 빠진 정보

- **라벨 오차율.** 자동 라벨의 거짓 성공·거짓 실패 비율은 보고하지 않는다. 사람 라벨과의 대조도 없다.
- **정책 학습 평가가 없다.** 제목과 초록은 "데이터 수집"이지만, 수집 데이터로 정책을 학습해 시뮬레이션 데이터나 텔레오퍼레이션 데이터와 비교하는 실험은 없다. 검색 실험만 있다. 따라서 "AutoDex 데이터로 학습한 정책이 시뮬 생성 데이터나 텔레옵 데이터보다 낫다"는 질문에는 본문이 답하지 않는다.
- **텔레옵 비교의 조건.** 텔레옵 시도 수, 운영자 수, 사용한 워크셀과 손, 그리고 텔레옵 성공률을 낸 캠페인 크기가 없다.
- **개입 31회.** 무엇을 셌는지(물체 배치, 충돌 정지, 수동 재시도, 라벨 수정 등)가 없다.
- **리셋 시간과 실패 횟수.** 리셋 자세 쌍의 수, 리셋 시도 수, 리셋 실패율이 없다.
- **생성 파라미터.** 장면 간격, BODex 시드 수, 시뮬 사전 필터의 임계값이 v2 본문에 없다(v1 부록에는 있었다).
- **통계.** 신뢰 구간, 검정, 반복 수가 본문에 거의 없다. 저자는 "유의하다"고 쓰지 않지만, 큰 차이를 강조하는 문장들이 있다.
- **데이터 공개 범위.** 프로젝트 페이지에는 Hugging Face 갤러리 데이터셋 링크가 있다. 전체 3,593회가 공개되는지, 라이선스가 무엇인지는 확인하지 못했다(02 §4, 04 §5).

02. 선행연구, 가까운 대안, 저장소 대조

1. 계보

AutoDex가 놓인 자리는 세 줄기의 교차점이다.

1. **텔레오퍼레이션과 모션 캡처로 모은 다지 시연.** RealDex [1], DexCap [2], DexTransfer [3], AnyTeleop [6], DexPilot [14], Open-TeleVision [15]. 실제 접촉 결과를 주지만 운영자 주의가 계속 필요하다(논문 Sec. 1, Sec. 2).
2. **시뮬레이션 기반 파지 합성.** DexGraspNet [7], BODex [8](AutoDex의 생성기), Fast-Grasp'D [9], Grasp'D [27], Dexonomy [28], UniDexGrasp [29], FFHFlow [30]. 시뮬에서 맞는 파지가 실물에서 맞는다는 보장은 없다(Sec. 2, 두 번째 단락, Get a Grip [35], Horak & Trinkle [39], Rubert et al. [40]).
3. **자율 실물 수집과 리셋.** 자기지도 파지(Pinto & Gupta [42], Levine et al. [44], QT-Opt [45]), 자율 개선(Sharma et al. [47], Zhou et al. [48]), 사람 개입 학습(Liu et al. [49]), 플릿 수집(AutoRT [50]), 리셋 없는 RL(Gupta et al. [54]), 성공 탐지기로서 VLM(Du et al. [55]). 대부분 병렬 집게 팔이거나 정책 자체의 경험을 모은다(Sec. 2, 세 번째 단락).

AutoDex의 새로움은 "생성 후보를 실물에서 실행하고, 다시점 추적으로 라벨을 붙이고, 자세별 리셋으로 자율 반복한다"는 조합이다. 개별 부품(다시점 자세 추정, 충돌 감지, 파지 합성)은 선행 연구에 있다. 이 점은 논문 Sec. 2도 인정한다.

2. 가까운 대안 (이 저장소의 다른 분석과 연결)

분석 폴더	논문	AutoDex와의 관계
`lightning_grasp/`	접촉 장 BVH에서 초당 수백~수천 파지 생성	AutoDex의 생성기(BODex)를 바꿀 수 있는 후보. 후보 수와 물리 검증 비용의 균형을 바꾼다
`mana/`	절차적 keyframe + 강화학습 + 점군 정책, 도구 조작	시뮬 기반 데이터 생성의 다른 축. 실물 라벨 루프는 없다
`graspsense/`	물체 표면의 힘 지도로 파지 재정렬	모델 선별(시뮬 사전 필터)의 대안. AutoDex 라벨로 재정렬 성능을 검증할 수 있다
`reactive_grasp/`	접촉력 분배 QP로 실시간 파지 유지	AutoDex의 들어 올리기 라벨이 "유지 가능"을 보는지 검토할 때 참고가 된다
`flashdexretarget/`	사람 손 시연을 로봇 손으로 리타겟	텔레옵 대안 데이터원. 텔레옵 비교의 기준이 될 수 있다
`cross_embodiment_wm/`	손 종류가 달라도 쓰는 그래프 세계 모델	AutoDex 데이터(두 손, 3,593회)를 쓸 수 있는 후보 학습 대상
`eigendexplore/`, `dexpolicy/`	탐색 잡음, 행동 잡음 스케줄 (강화학습)	수집 정책을 개선하는 방법. AutoDex는 탐색 없이 후보 목록을 순서대로 시도한다

3. 구성 요소별 출처

구성 요소	논문 출처	비고
파지 생성	BODex [8]	장면 제약은 본문 Sec. 3.1, 생성 파라미터는 v1 부록에만 있었다
마스크	SAM 3 [56]	
초기 자세	FoundationPose [57], FoundPose(v1 부록)	v2 본문에는 FoundPose가 없다
깊이 재구성	Depth Anything 3 [58]	
다시점 추적	GoTrack(v1 부록에 명시), 본문에는 "6D tracking"	v2 본문에서 추적기 이름이 빠졌다

구성 요소	논문 출처	비고
자세 정확도 지표	ADD-S [59]	
자기 충돌 계획	cuRobo(v1 부록 [40])	
잔차 토크	본문 Sec. 3.2 (자체 설계)	학습 데이터와 임계는 v1 부록 C

4. GitHub와 관련 저장소 (2026-11-10 확인)

저장소	무엇인가	공식?	라이선스	별	최근 커밋
snuvclab/autodex-code	논문 공식 코드(파이프라인, 실행, 데이터 설명서, 리셋, 재현 스크립트)	**공식** (프로젝트 페이지 Code 링크)	**없음** (LICENSE 파일 없음, GitHub API license null)	3 (포크 1)	2026-09-30, `448732d` (커밋 1개로 합쳐짐)
BODex (JYChen18/BODex, 추정)	논문 [8] 생성기	의존(저자명 일치, 공식 여부 미확인)	NOASSERTION (LICENSE 확인 필요)	155	2026-04-21, `06b9a3c`
cuRobo (NVlabs/curobo)	모션 계획	의존	Apache-2.0	1,992	2026-11-09, `c301cb0`
FoundationPose (NVlabs/FoundationPose)	자세 추정	의존 (저장소에 사본 포함)	NOASSERTION (NVIDIA 라이선스)	3,694	2026-04-29, `a1b694b`
SAM 3 (facebookresearch/sam3)	마스크	의존 (저장소에 사본 포함)	NOASSERTION (SAM 라이선스)	12,258	2026-10-23, `f1647e8`
Depth Anything 3 (ByteDance-Seed)	깊이	의존 (저장소에 사본 포함)	Apache-2.0	6,664	2026-07-27, `3d835ec`
paradex	워크셀 제어·카메라·신호 라이브러리	**저장소에 없음**. 121개 파일이 import	확인 불가	—	—
GoTrack 계열 (object-6d-tracking, _object_6d_tracking)	다시점 6D 추적	서브모듈(얕은 클론에 내용 없음)	확인 불가	—	—

공식 저장소는 `repo/`에 얕게 클론했다(커밋 `448732d`, 2026-09-30 커밋 시각). 저장소 설명 문서는 `DATASET.md`, `README.md`, `docs/`다. 데이터 자체는 저장소에 없다(04 D11). 저장소 안의 `autodex-code` 항목은 다른 기기의 절대 경로를 가리키는 깨진 심볼릭 링크다. 이 경로는 여기 적지 않는다.

라이선스 함의: 공식 코드에 LICENSE가 없으므로 기본적으로 저작권이 유보된 상태다. 포크하거나 재배포하면 안 되고, 참고와 인용만 한다. 이 폴더는 코드를 복사하지 않는다(정적 대조는 읽기만 했다).

5. v1 → v2 차이 (텍스트 대조)

- **대상:** v1(2026-06-22, 16쪽)과 v2(2026-11-04, 13쪽, `paper/paper.pdf`). v2 댓글은 "9 pages + references, 6 figures. Accepted to CoRL 2026"이다. v1 댓글은 비어 있었다.
- **헤드라인 처리량이 바뀌었다.** v1 초록: "AutoDex 10.3 h 대 텔레옵 49.4 h, 4.8× 처리량 향상"으로 측정값처럼 썼다. v1 4.1절은 "같은 워크셀에서 누적 궤적 곡선"으로 비교했다(v1 Fig. 4 좌측). v2는 텔레옵 28.4 h를 "8시간 근무일 가정 추정"으로 바꿨고, 비교는 2.8×(28.4/10.3)로 낮아졌다. 사람 시간 0.2 h 대 9.3 h는 v2에서 새로 추가했다. v1에서 텔레옵 49.4 h의 근거는 없어졌다.

- **초록의 근거.** v1 초록은 "사람 개입 없이"라고 했다. v2는 "사람 주의 0.2 h(추정)"이라고 고쳤다.
- **라벨 규칙.** v1은 "사후에 다시점 추적(GoTrack)으로 라벨"이라고 명시했다(v1 부록 B). v2 본문은 "추적을 돌린다"고만 쓴다. v2에 GoTrack 이름과 부록이 없다.
- **충돌 감지.** v1 부록 C: 접촉 임계 30 N·m, 50 샘플(약 0.5 s), J1·J2, 하강 구간만. 접촉으로 멈춘 비율은 하강 2.7%, 배치 8.9%, 가시 접촉은 0.3%와 3.1%. 1,870회 시험에서 어댑터 손상 2건이 있었다는 사고 기록. v2에는 이 부록 전체가 없다.
- **부록 삭제.** v1에는 부록 A(생성 파라미터: 간격 {2,4,6,8} cm, 상자 상단 {5,8} cm, 시드 $N \in \{200, 1000\}$, MuJoCo 0.1 N 사전 필터, 열린 손 최적화, 스퀴즈 이득 $c = 6$과 2), B(교정, 자세 추정 파이프라인, 지각 시간 분포 Fig. 7), C(충돌 감지), D(물체 라이브러리 Fig. 9). v2는 모두 뺐다.
- **카메라.** v1 Fig. 7(c): 24대 후보 리그에서 최적 k대 표면 커버리지. v2 Fig. 6 우측은 ADD-S로 바뀌었다. 2-16대. 표본은 51회·5물체.
- **검증 효과 실험.** v1: "515회 / 20 물체"(Fig. 4 우측). v2: 같은 수치, 범주 막대는 Fig. 5 우측으로 이동. 범주 값 자체는 같다(03 §1).
- **인용·참고문헌.** v1은 참고문헌 38개(번호 기준), v2는 59개다. v2는 Get a Grip [35], RobustDexGrasp [34], Dex1B [36], Fast-Grasp'D [9], Horak & Trinkle [39] 등을 추가했다. 인용 번호 체계가 바뀌었다.
- **URL.** v1 초록: 프로젝트 페이지가 개인 계정 아래 있었다. v2는 `snuvclab` 조직 아래의 프로젝트 페이지와 공식 저장소를 가리킨다. v1은 "will be released", v2는 "are available"이다.
- **수치 일치.** 두 판의 공통 수치(3,593회, 76% 대 34%, 5 cm 들어 올리기, 3 s, 48.2 s 루프와 비율 51.5/24.6/16.1/7.8, 5.3% 튕김, ADD-S 14.3 → 0.5 mm)는 같다.

6. 우리 연구와의 관계

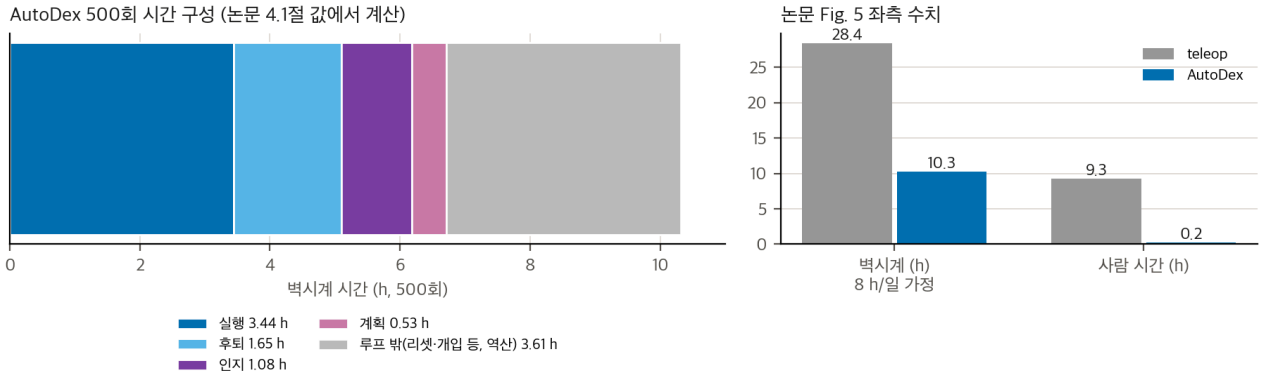
- 이 논문은 "데이터 수집 시스템"이다. 정책 성능 주장은 없다. 따라서 "정책이 AutoDex 데이터로 더 잘 되는가"를 묻는 우리 질문에는 직접 답하지 않는다.
- 라벨 품질(거짓 성공·실패 비율)과 선택 편향(라벨 불가 시도의 제외)은 독립적으로 검증할 수 있는 축이다. 03의 토이가 그 예다.
- 처리량 주장은 리셋 실패율과 개입 정의가 없으면 재계산할 수 없다. 03 §5의 모델이 필요한 입력을 보여 준다.

03. 재계산, 유의성, 유도, toy

재현 스크립트(모두 CPU, numpy/scipy 1스레드):

- `analysis/table_check.py` → `table_check_results.json` (1초 미만): 표 재계산, Fisher·Wilson·Newcombe, 민감도, 시간 예산, 라벨 오차 경계.
- `analysis/label_noise_toy.py` → `label_noise_toy_results.json` (약 0.3초): 토이 A.
- `analysis/collection_toy.py` → `collection_toy_results.json` (약 0.2초): 토이 B(처리량과 선택 편향).
- `analysis/plot_figures.py` → `report/figures/own_*.png`.

입력은 논문 본문·Fig. 5 표·공개 저장소의 수치뿐이다. 원자료(시도별 기록)는 없다. 따라서 아래 검정은 **논문이 적은 개수에서 역산한 값**이고, 독립성과 분산 구조는 확인할 수 없다.



그래프(우리 계산): 500회 시간 구성(루프 네 단계와 루프 밖 3.61 h)과 논문 Fig. 5 좌측 값의 비교. 텔레옵 벽시계 28.4 h는 8 h/일 추정이다.

1. 표 재계산

- **전체 DB.** 3,593회 중 성공 1,912, 실패 1,681(본문과 일치). 성공률 53.2%, Wilson 95% [51.6, 54.8].
- **손별 분해.** Allegro 2,226회 × 39.4% = 877.1 → 877, Inspire 1,367회 × 75.7% = 1,034.8 → 1,035. 합 1,912와 일치한다. 두 손의 횟수는 본문 수치와 정합한다. 두 손의 합 2,226 + 1,367 = 3,593도 맞는다.
- **Fig. 5 우측 범주 값.** 저장소 `rebuttal_fig.py`에 Fig. 5 우측 막대와 오차막대 값이 들어 있다. 막대 높이는 그림과 일치한다(예: 잡동사니 AutoDex 86.7, 모델 선별 6.7). 원자료는 없다.
  - 오차막대(7.9-17.2 pp)는 축별 한 팔 n(재질 약 64, 장면·무게 약 86)을 가정한 이항 SE(2.3-5.9 pp)보다 2-3배 크다. 따라서 이항 SE가 아니다. 물체 간 분산 등 다른 정의로 보인다. 정의는 논문에 없다.
  - 재질, 장면, 무게 세 축은 같은 515회를 나눈 것이다. 범주끼리 독립이 아니다.
- **텔레옵 대 AutoDex 성공률 (71.7%, 50.7%).** 캠페인 크기가 없다. 50.7%는 전체 DB 53.2%와도 다르다. 같은 "AutoDex"인데 정의가 다르다는 뜻이다(04 D13).
- **개입 31회 / 500회.** 6.2%, Wilson 95% [4.4, 8.7]. 0.2 h = 720 s를 31로 나누면 회당 23 s다. 개입 정의가 없으므로 이 값은 "사람이 짧게 만진 횟수"의 상한 해석만 가능하다.
- **시간 예산 (500회).** 루프 평균 48.2 s × 500 = 6.69 h. 벽시계 10.3 h − 6.69 h = **3.61 h(35%)**, 회당 26 s가 루프 밖이다. 본문 루프 구성 합 24.8 + 11.9 + 7.8 + 3.8 = 48.3 s(반올림 차이).
- **처리량.** AutoDex 500/10.3 = 48.5회/벽시계 h. 텔레옵(v2) 500/28.4 = 17.6회/h. 벽시계 비 2.76×(v2), 4.8×(v1, 49.4 h). 사람 시간 비 9.3/0.2 = 46.5×. 텔레옵 회당 사람 시간 67 s, AutoDex 1.44 s.

- **28.4 h 재현 시도.** "8시간 근무일"로 9.3 h 사람 시간을 환산하면 2일(16 h)이면 충분하다(9.3 h > 8 h/일이므로 최소 2일). 28.4 h는 3.55일이다. 9.3 h와 8 h/일 가정만으로는 28.4 h가 나오지 않는다. 다른 가정(휴식, 준비, 피로 손실 등)이 섞였을 것이다. 본문에 없다.
- **카메라 자세 오차 (Fig. 6 우측).** 평균만 있다. 51회·5물체. 분산이 없으므로 검정 불가.
- **리셋 튕김 5.3%.** 분모가 없다. 구간을 만들 수 없다.
- **데이터셋 설명서 대 본문.** 저장소 `DATASET.md`의 주요 세트 수: Allegro 1,656 + 574 = 2,230(본문 2,226), Inspire 384(본문 1,367). 합 2,614(본문 3,593). Inspire는 설명서의 수가 본문의 28%다. 품질 게이트로 격리된 시도를 빼면 설명되는지 확인할 수 없다(04 D12).

2. 유의성

2.1 손별 성공률 (Fisher, Newcombe)

대조	성공률	차이	Newcombe 95%	Fisher p
Inspire 1,035/1,367 대 Allegro 877/2,226	75.7% 대 39.4%	+36.3 pp	[33.3, 39.3]	6×10^{-103}

손의 차이는 통계적으로 명백하다. 하지만 **원인으로 읽으면 안 된다.** 두 손은 물체 집합, 세션, 기간, 운영 방식이 섞여 있다. 논문은 손을 바꾼 조건을 통제하지 않았다. 같은 물체에 두 손을 쓴 쌍(paired) 자료가 없다면 손 효과와 교란을 분리할 수 없다. CMH도 층(물체·세션) 정보가 있어야 한다.

2.2 검증 DB 대 모델 선별 DB (Fig. 5 우측, 515회)

한 팔당 시험 수가 없다. 분할을 바꾸며 민감도를 본다.

검증 DB n	모델 선별 n	76%·34% 각각 Wilson	차이 Newcombe 95%	Fisher p
100	415	[66.8, 83.3] 대 [29.6, 38.7]	[31.7, 50.5]	3×10^{-14}
200	315	[69.6, 81.4] 대 [29.0, 39.4]	[33.6, 49.4]	6×10^{-21}
257	258	[70.3, 80.7] 대 [28.6, 40.1]	[33.6, 49.1]	7×10^{-22}
300	215	[70.9, 80.5] 대 [28.0, 40.5]	[33.7, 49.5]	8×10^{-22}
400	115	[71.6, 79.9] 대 [25.9, 43.0]	[32.0, 51.0]	3×10^{-16}

어떤 분할에서도 p는 10^{-14} 이하다. **검정력 문제가 아니다.** 문제는 독립성이다.

- 같은 20개 물체, 같은 자세를 여러 번 시험했다면 유효 표본은 515보다 훨씬 작다. 물체 수준 군집(cluster) 검정이 필요하지만 물체별 결과가 없다.
- 두 팔의 라벨 규칙이 같은지 불분명하다. 논문 본문은 두 팔 모두 5 cm·3 s 규칙이라고 쓴다. 그러나 공식 코드의 실행 중 라벨은 charuco 보드 가시성 규칙이고, 3 s 유지를 보지 않는다(04 D1, D2). 두 규칙의 오차가 다르면 격차가 달라진다.
- 기준선은 "첫 번째 실행 가능한 파지"를 고른다. 검증 DB는 "첫 번째 성공 파지"를 고른다(본문 Sec. 3.5, 4.2). 순서가 BODex 점수와 관련되면 격차에 순서 효과가 들어간다.

2.3 텔레옵 대 AutoDex 성공률 (71.7% 대 50.7%)

캠페인 n이 없다. 민감도:

팔당 n	텔레옵 71.7% 대 AutoDex 50.7%, Newcombe 95%	Fisher p
50	[2.8, 39.0] pp	0.040

팔당 n	텔레옵 71.7% 대 AutoDex 50.7%, Newcombe 95%	Fisher p
100	[7.5, 33.5] pp	0.0035
200	[11.5, 30.0] pp	2×10^{-5}
500	[14.8, 26.6] pp	2×10^{-11}

n이 50 이상이면 차이는 유의하다. 그러나 텔레옵 성공률이 어떤 손과 어떤 물체에서 나왔는지, AutoDex 50.7%가 어느 집합인지(전체 53.2%와 다르다) 모르므로 해석은 제한된다. 텔레옵이 "AutoDex보다 성공률이 높다"는 결과는 방향이 중요하다. 논문도 이 결과를 "텔레옵 71.7%, AutoDex 50.7%"로 적고 있다. 논문은 성공률 차이를 한 문장으로 보고하고, 접근각 다양성(82° 대 60°)과 저크에 더 많은 설명을 쓴다.

2.4 여러 검정의 보정 (Holm)

CMH(층화 검정)는 층별 횟수가 필요하다. Fig. 5 우측은 범주별 비율만 있어서 CMH를 계산할 수 없다. 손 분해는 물체 층이 없다. 따라서 CMH는 **계산 불가**다.

Holm은 세 가지 대조를 묶어 보여 주는 예시로만 계산했다(횟수가 있는 것만).

대조	p (원)	p (Holm)
손: Inspire 대 Allegro	6×10^{-103}	2×10^{-102}
텔레옵 대 AutoDex (n=200)	2×10^{-5}	2×10^{-5}
검증 대 모델 선별 (n=257/258)	7×10^{-22}	1×10^{-21}

보정 후에도 모두 유의하다. 그러나 이 세 검정은 독립이 아니고, 실제 중요한 물음(물체 수준 차이)은 검정하지 못했다.

2.5 개입과 리셋

- 개입 31/500 = 6.2%, Wilson [4.4, 8.7].
- 리셋 튕김 5.3%는 분모가 없어 구간이 없다.
- 카메라 k=2 평균 14.3 mm, 분산 없음 → 검정 불가.

3. 파생 식과 유도

(a) Wilson 구간. 관측 비율 $\hat{p} = k/n$, $z = 1.96$. $\text{center} = (\hat{p} + z^2/2n) / (1 + z^2/n)$, $\text{half} = z\sqrt{(\hat{p}(1-\hat{p})/n + z^2/4n^2)} / (1 + z^2/n)$.

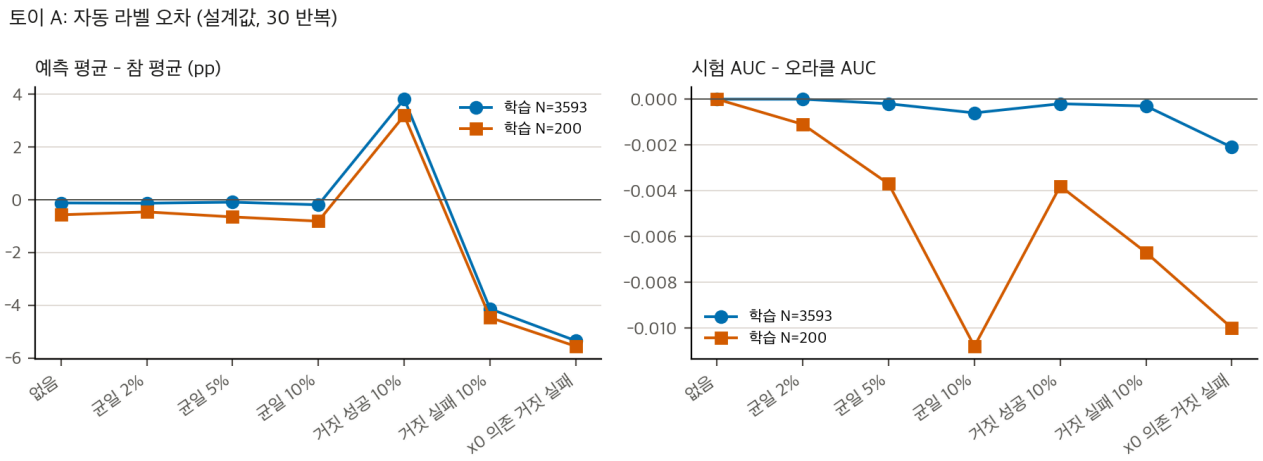
(b) Newcombe 차이 구간. 두 Wilson 구간 $[l1, u1]$, $[l2, u2]$에서 $d = \hat{p}1 - \hat{p}2$, $L = d - \sqrt{((\hat{p}1 - l1)^2 + (u2 - \hat{p}2)^2)}$, $U = d + \sqrt{((u1 - \hat{p}1)^2 + (\hat{p}2 - l2)^2)}$.

(c) 라벨 오차와 관측 성공률. 거짓 성공 비율 e0(참 실패를 성공으로), 거짓 실패 비율 e1(참 성공을 실패로)이면 관측 성공률은 $q = e0 + (1 - e0 - e1)\,p$, 따라서 참 성공률 $p = (q - e0) / (1 - e0 - e1)$. 관측 q = 53.2%일 때 (e0, e1) = (0.02, 0.02)이면 p = 53.3%, (0.10, 0.02)이면 49.1%, (0.02, 0.10)이면 58.2%다. 즉 **라벨 오차 10%면 참 성공률이 ±5 pp 움직인다.** 자동 라벨의 오차율을 보고하지 않은 상태에서 53.2%를 "생성기의 성공률"로 읽을 수 없다.

(d) 선택 편향. 라벨이 붙는 시도만 DB에 남을 때(라벨 지시자 L), 남는 집합의 성공률은 $E[y \mid L=1] = E[p \cdot L] / E[L]$이고, 차이는 $E[y \mid L=1] - E[p] = \text{Cov}(p, L) / E[L]$이다. 라벨 가능성이 난이도와 음의 상관이면 $\text{Cov}(p, L) > 0$이므로 DB 성공률이 과대 추정된다. 이것이 토이 B의 선택 편향이다. 논문 코드는 "사진이 없는 시도"를 버린다(04 D4). 그 조건이 난이도와 관련되면 $\text{Cov} \neq 0$이다.

(e) 처리량 모형. 벽시계 시간 T = Σ_i loop_i + N·o + Σ_{리셋 j} 1[실패_j]·T_int, 사람 시간 H = Σ_j 1[실패_j]·H_int. 논문 값으로 보정하면 N = 500, loop 평균 48.2 s, o = 26 s(10.3 h − 6.69 h를 500회로 나눈 값). 이 o는 리셋 시간과 개입을 모두 담는다고 가정한 값이다. 리셋 시간과 실패율이 따로 보고되지 않아서 분해할 수 없다. 개입 31회를 리셋 실패로 설명하려면, 리셋이 r회 시도마다 한 번이라면 q = 31 / (500/r). r=10이면 q = 6.2%, r=30이면 18.7%, r=100이면 62%다. 어떤 r이 맞는지는 본문에 없다.

(f) 개입 시간 예산. 사람 0.2 h = 720 s, 개입 31회면 회당 23 s다. 벽시계 예산 3.61 h가 모두 개입이라 해도 회당 419 s까지 가능하다. 그러나 개입 한 번이 600 s(토이 가정)라면 31회는 5.2 h가 된다. 그러면 전체 벽시계는 6.69 + 5.2 = 11.9 h가 되어 10.3 h와 맞지 않는다. 따라서 개입 한 번의 벽시계 비용은 최대 419 s(3.61 h ÷ 31, 루프 밖 시간 전부가 개입이라고 가정한 상한)보다 작아야 한다. 이 제약은 본문 수치들 사이의 내적 일관성 조건이다.



그래프(우리 계산): 토이 A. 라벨 오차 설정별 예측 편향(좌)과 시험 AUC의 오라클 차이(우), 학습 N = 3,593과 200, 30 반복.

4. 토이 A: 자동 라벨 오차와 성공 분류기 (`label_noise_toy.py`)

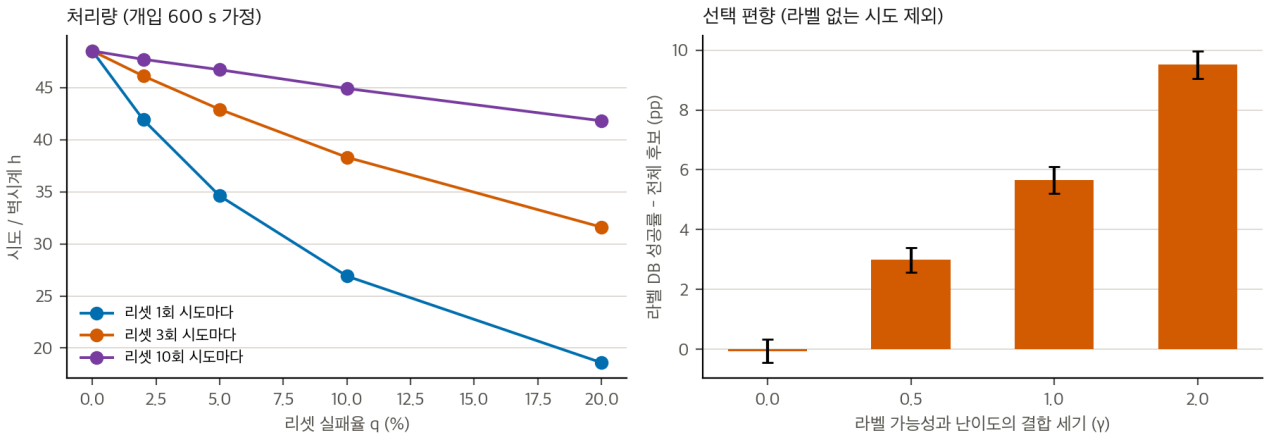
설계: 특징 d = 6, 참 로짓 x·W + 0.05, W = (1.2, −0.8, 0.5, 0, 0.3, −0.4). 학습 N = 3,593(논문 개수)과 N = 200(초기 수집 가정), 시험 2,000(깨끗한 라벨). 로지스틱 회귀를 뉴턴법으로 맞춘다(L2 = 10^{-3}). 반복 30회(seed 1000-1029). 참 성공률 약 0.5.

설정 (N=3,593)	관측 라벨 성공률	예측 평균 − 참 평균	기울기 감쇠	AUC (시험)	상위 20% 정밀도
오라클	0.506	−0.1 pp	1.02	0.823	0.897
균일 2% / 2%	0.506	−0.1 pp	0.94	0.823	0.897
균일 5% / 5%	0.507	−0.1 pp	0.84	0.823	0.897
균일 10% / 10%	0.506	−0.2 pp	0.69	0.822	0.898
거짓 성공 중심 10% / 2%	0.546	**+3.8 pp**	0.81	0.823	0.897
거짓 실패 중심 2% / 10%	0.466	**−4.1 pp**	0.81	0.823	0.897
x0 의존 거짓 실패 2% / 10%	0.454	**−5.3 pp**	0.70	0.821	0.895

설정 (N=200)	예측 − 참	기울기	AUC	상위 20% 정밀도
오라클	−0.6 pp	1.05	0.815	0.881
균일 10% / 10%	−0.8 pp	0.73	0.804	0.867
거짓 성공 중심	+3.2 pp	0.86	0.811	0.876
거짓 실패 중심	−4.5 pp	0.84	0.808	0.871
x0 의존 거짓 실패	−5.6 pp	0.73	0.805	0.869

해석:

- **순위는 대체로 견딘다.** 균일 오차 10%에서도 AUC는 0.001 미만(N=3,593), 0.011(N=200) 떨어진다. 상위 20% 정밀도는 거의 그대로다. 검색(ranking)으로 쓰는 경우 라벨 오차 자체는 큰 문제가 아니다.
- **절대 성공률은 편향된다.** 거짓 성공이나 거짓 실패가 한쪽으로 치우치면 예측 평균이 ±4-5 pp 움직인다. 논문 53.2%나 "생성기 성공률" 같은 절대값을 말할 때 문제가 된다.
- **특징 의존 오차는 더 나쁘다.** x0이 큰 시도(어렵다고 가정한 자세)에서 거짓 실패가 늘면 기울기가 0.70까지 줄고 편향이 −5.3 pp가 된다. 어려운 자세일수록 라벨이 나쁘면 "어려움"이 과소평가된다.
- **한계.** 토이의 신호는 강하다(AUC 0.82). 신호가 약하면 순위 손실이 커진다. 실제 파지 성공 신호는 이보다 약할 가능성이 높다. 결론은 방향만 쓴다.



그래프(우리 계산): 토이 B. 리셋 실패율별 처리량(좌, 개입 600 s 가정)과 라벨 가능성-난이도 결합 세기별 DB 편향(우).

5. 토이 B: 처리량과 리셋 실패, 선택 편향 (`collection_toy.py`)

가정(모두 설계값, 논문에 없음): 루프 48.2 ± 8 s, 루프 밖 26 s/회(보정), 리셋은 r회 시도마다 한 번, 리셋 실패 시 개입 600 s 벽시계와 120 s 사람 시간. 반복 400회.

처리량(벽시계 h, 500회, 시도/벽시계 h):

리셋 빈도	q = 0%	2%	5%	10%	20%
매 시도 (r=1)	10.3 h	11.9 h (41.9)	14.4 h (34.6)	18.6 h (26.9)	26.9 h (18.6)
3회마다 (r=3)	10.3 h	10.8 h (46.1)	11.7 h (42.9)	13.1 h (38.3)	15.8 h (31.6)
10회마다 (r=10)	10.3 h	10.5 h (47.7)	10.7 h (46.7)	11.1 h (44.9)	12.0 h (41.8)

개입 수는 r=1, q=6.2%일 때 약 31회다. 이때 벽시계는 10.3 h + 31 × 600 s ≈ 15.5 h로 10.3 h보다 크다. 그러므로 **본문 10.3 h와 31회 개입은 개입 한 번이 600 s가 아니어야 맞는다.** 리셋이 드물거나(r ≥ 10) 개입이 짧으면 두 값은 맞는다. 처리량의 민감도는 리셋 빈도와 개입 시간에 달려 있다.

선택 편향 (라벨 가능성이 난이도와 결합, 후보 20,000개, 40 반복):

γ (결합 세기)	라벨 가능 비율	라벨 DB 성공률 − 전체 후보	상관
0	69.0%	−0.06 pp (sd 0.39)	0.00
0.5	68.1%	+3.0 pp (sd 0.42)	0.21
1.0	66.1%	+5.7 pp (sd 0.45)	0.38

γ (결합 세기)	라벨 가능 비율	라벨 DB 성공률 – 전체 후보	상관
2.0	62.0%	+9.5 pp (sd 0.46)	0.58

전체 후보 성공률은 46.0%다. γ가 클수록 라벨 가능 비율이 줄고, DB 성공률이 최대 9.5 pp 과대 추정된다. 이 편향은 "DB 성공률"을 생성기의 성공률로 해석할 때 생긴다. 검색 실험의 42 pp 격차를 설명하지는 못한다. 격차는 검증 행위 자체에서 온다. 다만 기준선(모델 선별 집합)과 검증 DB가 같은 "라벨 가능" 필터를 거쳤는지 논문은 말하지 않는다. 기준선이 필터를 거치지 않았다면 격차는 필터 효과를 포함한다.

6. 가정과 한계

- 논문의 시도별 기록이 없으므로 모든 검정은 횟수 역산과 민감도 분석이다.
- 군집(물체, 세션) 구조를 알 수 없어서 독립성 가정이 가장 큰 위험이다.
- 토이의 계수, 잡음, 비용(600 s, 120 s, 26 s)은 설계값이다. 방향만 주장으로 쓴다.
- Fig. 5 우측 범주 값은 저장소 스크립트에서 가져왔다. 논문 본문 값과 같은지는 그림으로만 확인했다.

추가 검증 (2026-11-11)

스크립트: `analysis/extra_label_rules.py` → `analysis/extra_label_rules_results.json` (numpy 단일 스레드, 1초 미만).

추가 검증 1: 라벨 규칙 세 가지를 같은 합성 궤적에 적용

목적. 공식 코드에 있는 성공 라벨 규칙 세 가지가 같은 시도에 대해 얼마나 같은 판정을 내는지, 불일치는 어떤 행동에서 생기는지 본다. 세 규칙은 (1) 본문의 "5 cm 이상 3 s 유지", (2) 실행 중 charuco 보드 가시성, (3) 데이터셋의 "높이 최댓값 50 mm 이상"이다(`04` D1·D2 근거).

설정(가정).

- 궤적 20,000개, 10 Hz, 8 s. 행동 여섯 가지와 확률은 다음과 같다. 파지 유지 0.40, 유지 중 미끄럼 0.15(튕김 확률 0.3), 짧게 들었다 떨어뜨림 0.15, 손이 보드를 가린 유지 0.15, 기울어진 유지 0.05, 들리지 않음 0.10.
- 측정 높이 잡음 σ = 5 mm.
- Cc(charuco): 들어 올린 높이 ≥ 3 cm인 프레임 중 보드가 보이는 프레임이 하나라도 있으면 성공. 보드는 손에 가려지거나 기울기 ≥ 60°이면 보이지 않는다.
- Cz(최댓값): 측정 높이 최댓값 ≥ 50 mm이면 성공. 지속 시간 조건은 없다.
- C3(본문): 측정 높이 ≥ 50 mm가 3 s 이상 연속이면 성공.
- 참 값(GT): 실제 높이 ≥ 50 mm가 3 s 이상 연속(잡음과 가림 없음).

결과.

규칙	성공률
GT	38.4%
C3 (5 cm·3 s)	35.3%
Cc (charuco)	89.3%
Cz (최댓값 50 mm)	89.3%

일치율: C3와 GT 96.5%, Cc와 GT 48.4%, Cz와 GT 49.1%, Cc와 Cz 99.3%, C3와 Cc 45.4%.

GT 실패 중 성공으로 판정된 비율은 C3 0.4%, Cc 83.2%, Cz 82.6%다. GT 성공 중 실패로 판정된 비율은 C3 8.6%(경계 근처의 잡음), Cc 0.9%, Cz 0%다.

행동 유형별 성공률(GT / C3 / Cc / Cz)은 다음과 같다. 파지 유지 0.60 / 0.55 / 1.00 / 1.00, 미끄럼 0.18 / 0.16 / 1.00 / 0.98, 짧은 들어 올림 0 / 0 / 1.00 / 1.00, 가림 유지 0.60 / 0.55 / 0.98 / 1.00, 기울어진 유지 0.59 / 0.54 / 1.00 / 1.00, 들리지 않음 0 / 0 / 0 / 0.

결론.

- 짧은 들어 올림, 미끄럼, 튕김을 세는 두 규칙(Cc, Cz)은 서로 99%로 같지만 GT와는 절반만 맞는다. 둘 다 지속 시간을 보지 않기 때문이다.
- 본문 규칙(C3)은 GT와 96%로 맞는다. 불일치는 높이가 경계(5 cm) 근처인 시도에서 잡음 때문에 생긴다. 보드 가림은 C3에 영향을 주지 않는다.
- 규칙 선택만으로 같은 합성 혼합에서 성공률이 35%에서 89%까지 움직인다. §2.2에서 "두 팔의 라벨 규칙이 같은지 불분명하다"고 한 것은, 어떤 규칙이 DB를 만들었는지에 따라 53.2%의 해석 범위가 매우 넓어진다는 뜻으로 읽어야 한다. 이 크기는 행동 혼합에 달려 있으므로 방향으로만 읽는다.
- **한계.** 행동 혼합, 가림과 잡음의 확률은 설계값이다. 실제 DB의 행동 분포는 알 수 없다. 실제 charuco 판독은 다시 만들지 않았다(검증용 영상이 없음).

04. 코드 대조: 논문 ↔ snuvclab/autodex-code (448732d)

정적 읽기만 했다. 코드를 실행하지 않았고, 아무것도 설치하지 않았다. 의존 패키지와 서브모듈은 없어서 실행이 불가능하다. 줄 번호는 `repo/` 기준이다(얕은 클론, 커밋 `448732d`, 2026-09-30).

1. 확인한 파일

경로	역할
`README.md`, `DATASET.md`, `docs/*.md`	설치 절차, 데이터 구조, 파이프라인 설명
`src/execution/run_auto.py` (3,316줄)	자동 수집 루프: 계획, 실행, 라벨, 리셋, 재배치
`src/execution/label.py`	수동 라벨(`get_label`)과 자동 라벨(`auto_label_charuco`)
`src/dataset/exec_grasp/corl_exec.py`, `inspire_exec.py`	데이터셋의 `success` 필드를 쓰는 함수(`obj_success`)
`src/dataset/recompute_pose.py`, `fill_pose_from_runtime.py`	자세 품질 게이트(실루엣 손실)
`autodex/executor/real.py`	실물 실행기, 접촉 임계와 잔차 감지
`autodex/executor/tau_model.py`	토크 MLP 학습과 로드
`autodex/utils/path.py`	리셋 높이 `RESET_RELEASE_HEIGHTS_CM = (0, 4, 8, 12)`
`src/grasp_generation/sim_filter/run_sim_filter.py`	MuJoCo 시뮬 사전 필터(`TRANS_THRE = 0.05`, `ANGLE_THRE = 15`, 50 스텝)
`src/experiment/num_camera/*.py`	카메라 수 실험(24대 풀에서 k대 무작위 선택, `k` 기본값 2, 4, 8, 16)
`rebuttal_fig.py`	Fig. 5 우측 범주 값(상수로 들어 있음)
`pyproject.toml`	패키지 메타데이터만 있음(의존 목록 없음)

2. 논문 ↔ 코드 대조 (D-항목)

번호	논문 (v2)	코드	판단
D1	라벨은 6D 추적으로 물체 높이를 보고, 5 cm 이상 떠서 3 s 유지하면 성공(Sec. 3.3, Sec. 4).	**세 가지 규칙이 있다.** (a) 실행 중 자동 라벨: 들어 올린 직후 여러 카메라 영상에서 charuco 보드 11의 모든 코너가 보이면 성공(`run_auto.py` 2120-2145, `label.py` 42-95, 성공은 `trial_success = bool(auto_succ_lift)` 2578-2589). (b) 데이터셋 `success` 필드: 파지 시점 이후 GoTrack 높이의 **최댓값**이 파지 시점보다 50 mm 이상 높으면 성공(`corl_exec.py` 14-25). 유지 3 s는 보지 않는다. (c) 수동 라벨: `get_label()` y/n/c(`run_auto.py` 2655-2659).	**불일치.** 논문의 판정 규칙은 코드 어디에도 그대로 있지 않다. 논문이 주장하는 "3 s 유지"는 (a), (b) 어느 쪽도 보지 않는다. 논문의 라벨 오차율은 없다(03 §3(c)).
D2	(D1과 같음)	(a)의 charuco 규칙은 "보드가 가려지지 않았다 = 물체가 탁자에 없다 = 들어 올렸다"라는 간접 기준이다. 코너 누락이 한 개라도 있으면 실패, 허용 오차는 없다.	**오차 원인이 명확하다.** 물체가 보드 밖으로 밀려나 탁자 위에 남아도 보드가 보이면 성공이 될 수 있다. 반대로 팔이나 손이 보드를 가리면 성공이 실패로 찍힌다. 이 빈도는 확인할 수 없다. 논문은 자동 라벨 검증을 보고하지 않는다.

번호	논문 (v2)	코드	판단
D3	라벨은 자동이다(Sec. 3.3).	`--auto`가 아닌 수동 모드에서는 사람이 y/n/c(메모 포함)로 라벨을 붙인다(`label.py` 16-38, `run_auto.py` 2655-2659). "issue"(c) 라벨은 성공 판정에서 빠진다.	**논문에 수동 경로가 언급되지 않는다.** 어떤 시도가 수동인지 데이터셋 메타데이터로 알 수 있는지 확인하지 못했다.
D4	라벨 결과에 따라 시도를 기록한다(Sec. 3.3).	보드를 판독할 수 없으면(사진 없음, 보드 설정 없음) `label_unjudgeable`로 판정하고, 실패로 기록하지 않으며 시도를 **버린다**(`run_auto.py` 2160-2200).	**선택 편향 경로.** 판독 불가가 난이도와 상관이면 DB 성공률이 바뀐다(03 §3(d), §5). 논문은 이 처리를 말하지 않는다.
D5	"사람은 물체 배치와 복구만 한다"(Sec. 5, 4.1의 0.2 h).	물체 배치를 기다리는 루틴(`_wait_for_object_on_table`, `run_auto.py` 614-660)은 "Place obj then press Enter"를 출력하고 입력을 기다린다(`--auto`가 없을 때). `--auto`이면 기다리지 않고 종료한다. 재정렬 단계에서는 `reorient.py` 명령을 출력하고 "Press Enter to RUN integrated reorient now"를 묻는다(`run_auto.py` 1265-1280).	**사람 개입 지점이 여러 곳이다.** 0.2 h가 이 모든 개입을 포함하는지 본문은 말하지 않는다. 31회 개입의 정의와 대응해야 한다(03 §1).
D6	잔차 토크 감지: "예측 잔차가 미리 정한 임계를 지속해서 넘으면 접촉"(Sec. 3.2). 수치는 v2에 없다.	코드에 임계가 셋 있다. 배치 접촉 20 N·m, 6관절, 8틱 지속(`real.py` 77-78, 1803). 접근 감지 70 N·m(주석, 76). 토크 MLP는 클래스 기본값 은닉 64·2층, `train()` 기본값 은닉 128·3층이다(`tau_model.py` 54, 153). v1 부록 C의 30 N·m, J1·J2, 50 샘플은 코드와 맞지 않는다.	**값이 셋이다.** v2 본문에 수치가 없고, v1 값과 코드 값이 다르다. 어느 판본이 실험에 쓰였는지는 확인할 수 없다.
D7	자세 품질 게이트는 논문에 없다.	`DATASET.md`: 실루엣 손실 `sil_loss > 0.003`인 시도는 `{dataset}_pose_outlier/`로 격리된다. 주요 세트에 없는 시도는 논문 DB 수에 들어갈 수 없다.	**선택 편향 경로 2.** 자세 추정이 실패한 시도를 뺀 집합이 DB다. 논문은 이 게이트를 말하지 않는다. 격리 수는 공개되어 있지 않다.
D8	20대 카메라, 2048×1536, 30 FPS(Sec. 3.2).	`DATASET.md`: 에피소드당 **24**개 동기 FLIR 카메라 영상. `num_camera` 실험: 풀 24대에서 k대를 고른다(`num_camera/run_auto.py` 7, 170-183). 논문 Fig. 6 기준은 20대.	**카메라 수가 문서마다 다르다.** 20과 24 중 어느 것이 본 데이터인지 논문과 코드가 맞지 않는다.
D9	카메라 2대로도 동작한다(Sec. 5). 2-16대 ADD-S 14.3 → 0.5 mm(Sec. 4.4).	k대 실험 코드는 있다(`compute_adds.py` 70, 기본 `[2,4,8,16]`). 2대의 평균 오차 14.3 mm는 파지 기하에 비해 크다.	**주장과 수치가 긴장 관계다.** 2대로도 "동작한다"는 것은 실패율이 허용되는지의 문제이고, 평균 자세 오차로는 판단할 수 없다.
D10	시뮬 사전 필터는 "5 cm 이상 밀리면 기각, 0.1 N 외력, 50 스텝"(v1 부록 A; v2 본문은 Sec. 3.1에서 생략).	`run_sim_filter.py`: 외력 = `FORCE_SCALE × OBJ_MASS × 중력방향`, `OBJ_MASS = 0.1`(단위 명시 없음), 50 스텝, 기각 조건은 이동 > 5 cm **또는 회전 > 15°**(`ANGLE_THRE`).	**외력 단위와 회전 기준이 다르다.** 논문에 회전 기준이 없다. 0.1 N과 0.1 × 중력(약 1 N)은 다르다. 단위 확인이 필요하다.

번호	논문 (v2)	코드	판단
D11	데이터는 3,593회: Allegro 2,226, Inspire 1,367, 성공 1,912(Sec. 3.5).	`DATASET.md` : 주요 세트 `selected_100` 1,656 + `corl_selected_100` 574 = Allegro 2,230; `selected_100_inspire` 384. 합 2,614. 데이터 자체는 저장소에 없고 공유 저장소 경로를 가리킨다.	**Inspire 수가 맞지 않는다**(384 대 1,367). 시점 차이나 격리 때문일 수 있다. 논문은 이를 설명하지 않는다.
D12	리셋: 가장 적게 본 도달 가능 자세를 고르고, 높이 h = 0부터 올린다(Sec. 3.4).	`RESET_RELEASE_HEIGHTS_CM = (0, 4, 8, 12)` (`path.py` 56). 최대 12 cm. 리셋 캐시는 `reset_<height>/` 디렉터리 구조다(`run_auto.py` 196 주변). 목표 자세 선택은 `autodex/utils/coverage.py` 의 "남은 미커버 장면 수"(`load_coverage_map` 142-185)에 따른다. 논문의 "least-seen"과 같은 개념인지는 확인하지 못했다.	**대체로 일치.** 최대 높이 12 cm는 논문에 없다. 가상 지지 기둥은 시각화 색 상수 (`src/visualization/reset_figure.py`)에만 나오고, 계획 코드에서는 찾지 못했다.
D13	수동 낙하 대조군 튕김 5.3%(Sec. 4.3). 제안 방식은 튕김이 없다.	대조군 실험 스크립트는 `src/experiment/reset/naive_drop.py` , `reorient_drop.py` 에 있다. 튕김(작업 영역 이탈)을 세는 코드와 시도 수는 찾지 못했다.	**검증 불가**(분모와 집계 코드가 없다).
D14	재배치는 논문에 없다.	보드 11이 완전히 보이면 "reposition mode"로 들어가고 (`run_auto.py` 960-1000), 배치 전에 물체를 보드 11 중심으로 옮긴다(`run_auto.py` 2209 주변).	**논문에 없는 단계.** 재배치 시간과 실패율을 본문이 보고하지 않는다.
D15	6D 추적은 "스트림 전체"에 돈다(Sec. 3.3).	`gotrack_daemon.py` 와 `autodex/perception/gotrack_*.py` 가 있다. 그러나 추적기 소스인 서브모듈 `object-6d-tracking` 과 `_object_6d_tracking` 은 얕은 클론에서 비어 있다.	**추적 경로를 검증할 수 없다.** D1(b)는 추적 출력 파일을 읽을 뿐이다.
D16	텔레옵 비교: 9.3 h, 28.4 h, 71.7%(Sec. 4.1).	텔레옵 코드, 로그, 캠페인 목록을 찾지 못했다.	**검증 불가.**
D17	검색 실험: 76% 대 34%(Sec. 4.2, Fig. 5 우측).	범주 값은 `rebuttal_fig.py` 에 상수로 있다(그림과 일치). 검색 계산 코드, 시도 목록, 라벨을 찾지 못했다(키워드 검색).	**그림 상수만 확인됨.** 원자료는 없다.
D18	프로젝트 페이지와 저장소: "코드와 데이터를 제공한다"(v2 초록).	LICENSE 파일이 없다(GitHub API `license: null`). 데이터는 저장소에 없다. 프로젝트 페이지의 Hugging Face 갤러리 데이터셋 링크는 별도다.	**재사용 허가가 없다.** 04 §5 참조.
D19	(논문에 없음)	의존성 문제: (a) `paradex` 패키지를 121개 파일이 import한다. 저장소에 없다. (b) `chime` 등 외부 패키지. (c) `README.md` 와 코드에 작성자 기기의 절대 경로와 네트워크 공유 경로가 박혀 있다. (d) 저장소 안의 `autodex-code` 항목은 다른 기기 경로를 가리키는 깨진 심볼릭 링크다. 경로는 여기 적지 않는다. (e) 의존 목록 없음(`pyproject.toml` 은 메타데이터만 있다).	**자기완결적이지 않다.** 공식 코드를 그대로 실행하려면 작성자의 환경이 필요하다.

번호	논문 (v2)	코드	판단
D20	(논문에 없음)	설치 안내는 CUDA 빌드 torch를 여러 개의 conda 환경(sam3 torch 2.10 cu128, foundationpose torch 2.0 cu118, foundation_stereo torch 2.4.1 cu121, bodex torch 2.7 cu128)에 나눠 쓴다.	**GPU 전제.** 이 맥에서 실행할 수 없다.

3. 재현에 필요한데 논문에 없는 정보

- 시도별 기록(라벨 근거, 수동·자동 구분, 개입 여부, 판독 불가 여부, 자세 품질 게이트 통과 여부).
- 자동 라벨 오차율(사람 라벨과의 일치율, 샘플 수).
- 텔레옵 비교 조건(운영자, 시간, 손, 캠페인).
- 리셋 실패율과 리셋 시도 수.
- 충돌 감지 임계(어느 판본의 값인지)와 학습 데이터 크기.
- 장면 생성 파라미터(간격, 시드 수, 상자 상단 높이)와 BODex 설정.
- 시뮬 사전 필터의 외력 단위와 회전 기준.
- 카메라 수(20인지 24인지)와 배치 시 카메라 수(4대)의 근거.
- 검색 실험의 시도 목록: 어느 DB 항목이 어느 시험에 쓰였는지, 같은 물체·자세 반복 여부.

4. 구현할 수 있는지

4.1 공식 코드로 실물 재현 (하드웨어)

필요한 것: 6축 로봇 팔(코드는 xArm6와 FR3 설정을 함께 가진다), Allegro 16-DoF와 Inspire 6-DoF 손(장착 인터페이스 포함), 하드웨어 동기 RGB 카메라 20-24대와 ChArUco 보드, 조명 셀, Linux와 CUDA GPU 여러 대 또는 여러 환경(D20), 비공개 `paradex` 라이브러리(D19), 작성자 환경의 경로와 네트워크 공유(D19). **판정: 불가능하다(연구실 워크셀과 비공개 라이브러리 없이는 실행되지 않는다).** 하드웨어 규모는 "로봇 팔 1 + 다지 손 1 + 카메라 20 이상 + 동기 장치"다. 설치와 캘리브레이션, 코드 정리까지 포함하면 수 주에서 수 개월이다(추정).

4.2 이 맥 (Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치)

- **실물 재현: 불가능.** 로봇, 손, 카메라가 없다.
- **공식 소프트웨어 재현: 불가능.** SAM 3, FoundationPose, BODex, cuRobo가 CUDA를 쓴다(D20). `paradex`가 없다(D19). 서브모듈 GoTrack도 비어 있다(D15).
- **이 맥에서 할 수 있는 것(CPU):** 표 재계산과 통계(완료, `table_check.py`), 라벨 오차 토이(완료), 처리량과 선택 편향 모형(완료). charuco 판독 로직은 OpenCV ArUco로 다시 쓸 수 있으나(`paradex` 래퍼 없이), 검증용 영상이 없다.
- MPS는 작은 학습 토이(예: 라벨 노이즈 아래 분류기)에 쓸 수 있다. 이 폴더의 토이는 numpy로 충분했다.

4.3 아이디어만 다시 구현 (노력 추정)

구성 요소	난이도	근거	하드웨어 없이 가능한가
수집 루프(후보 필터, 시도 표시, 자세 전이)	중간	로직은 수백 줄. 상태 기계와 캐시	가능(시뮬 어댑터로 테스트)
자동 라벨(charuco 규칙)	쉬움	OpenCV ArUco 검출과 코너 집합	가능(사진이 있으면)
자동 라벨(5 cm·3 s 추적 규칙)	큼	6D 추적 모델과 다시점 자세 추정이 필요	부분 가능(추적기 자체가 큼)
잔차 토크 감지	중간	MLP는 쉽고, 학습 데이터(자유 공간 궤적)가 필요	학습 데이터가 있어야 함

구성 요소	난이도	근거	하드웨어 없이 가능한가
리셋 파지 생성	큼	BODex와 cuRobo 충돌 계획	어렵다(CUDA 의존)
검색 실행(DB 조회 + 팔 계획 + 충돌 확인)	쉬움	DB 조회와 계획 호출	가능

추정: 아이디어 수준의 재구현(루프 + 라벨 규칙 + 검색, 시뮬 기반)은 **2-4주**(1인, 하드웨어 없음). 실물 루프 재구현은 하드웨어 포함 **수 개월**. 이 값은 추정이다.

4.4 요약 표

항목	공식 코드	이 맥	재구현	하드웨어
실물 자율 수집	불가(연구실 워크셀)	불가	중간(수 개월)	로봇 팔 1, 다지 손 1, 카메라 20+
표 재계산·통계	해당 없음	완료(03)	—	없음
라벨 규칙 비교	코드 읽기만	토이 완료	쉬움(charuco) ~ 큼(추적)	충분한 사진
처리량 모형	해당 없음	토이 완료	—	없음
검색 실행 76% 대 34%	계산 코드 없음	불가	중간(충돌 계획은 CUDA 쪽)	로봇 팔과 손
정책 학습 비교	논문에 없음	—	데이터 수집 필요	데이터 자체가 필요

구현할 수 있는지 한 줄 판정: 실물 재현은 이 맥에서도, 공식 코드 그대로도 불가능하다. 라벨·리셋·검색 아이디어는 재구현할 수 있고(중간), CPU로 검증할 수 있는 것은 표 재계산, 라벨 오차 토이, 처리량·선택 편향 모형까지다.

5. 권리 표기 (license verdict)

- **논문:** arXiv 권리는 `nonexclusive-distrib 1.0` (arXiv abs 페이지 확인). CC BY가 아니다. 따라서 **논문 그림(Fig. 1-6)은 개인용 리포트와 PPT에만 넣는다.** 게시본에는 넣지 않는다. 게시본의 그림은 모두 이 폴더가 그린 그래프다.
- **PDF 1쪽 고지:** 저작권 문구는 없다(본문 텍스트에서 `©` · `Copyright` 0건). 있는 것은 arXiv 스탬프(`arXiv:2606.23689v2 [cs.RO] 4 Nov 2026`)와 학회 표기 "10th Conference on Robot Learning (CoRL 2026), Austin, Texas, USA"다. 재인쇄 허가 문구는 찾지 못했다.
- **프로젝트 페이지:** HTML에 라이선스 문구가 없다(`license` · `CC` 검색 0건). 페이지 자체의 사용 조건은 확인하지 못했다.
- **공식 코드:** LICENSE 파일이 없고, GitHub API의 license가 null이다. 기본적으로 저작권이 유보된다. 복사, 포크, 재배포는 하지 않고, 참고와 인용만 한다.
- **데이터:** 프로젝트 페이지의 Hugging Face 갤러리 데이터셋의 라이선스는 확인하지 못했다. 다운로드하지 않았다.
- **파일 크기:** 논문 PDF 7.8 MB, 25 MB 미만이므로 `.gitignore` 대상이 아니다. 원문 PDF는 저장소에 둔다.