ContactBench 1.0: 분석 리포트

arXiv:2610.24512v2 (2026-10-23; v1 2026-10-17) · 학회 표기 없음(프리프린트) · 저자 소속: University of Illinois Urbana-Champaign, Stanford University · 공식 시뮬 코드 Michaelwyx/contactbench-sim (MIT, 커밋 ccd8645) · 분석일 2026-11-10 · 게시용 버전: 논문 그림과 원문 PDF는 라이선스(arXiv 비독점 배포) 때문에 뺐습니다.

핵심 요약

1. **무엇을 하는가:** 접촉 기술 8개에 기반한 과제 36개, 인쇄 가능한 자산 40여 개, 시뮬레이션을 제시하고, 정책 6개 과제에서 DP, π0.5(시각 전용)와 RDP, FTP-1(촉각 추가)을 과제당 30회씩 비교한다(`01` §1, §5).
2. **표는 내부적으로 일치한다:** Table III의 22개 칸은 Fig. 11의 단계 퍼널 마지막 값과 모두 맞는다. 텍스트의 "56.7%"(17/30)와 "20%"(6/30)도 맞는다(`03` §1).
3. **촉각 효과는 "없다"보다 강하게 "해롭다"로 읽힌다:** 보정 후 유의한 촉각 차이는 두 건이고 둘 다 해롭다. RDP는 너트 나사 체결에서 0/30 대 8/30(Holm 0.018), FTP-1은 나사 조이기에서 3/30 대 17/30(Holm 0.001)이다. 4과제 층화 검정은 각각 p = 0.10과 0.0097이며, 효과는 과제 한 개에 기댄다(`03` §3).
4. **π0.5 우위도 과제에 따라 다르다:** 조이기와 수저에서만 보정 후 유의하고, 너트와 충전기는 차이가 검정력 밖이다(`03` §2).
5. **30회 설계는 큰 차이만 잡는다:** 방법당 30회로 80% 검정력을 얻으려면 차이가 약 36 pp 이상이어야 한다. 10 pp 차이의 검정력은 약 0.12다(`03` §5.7, §6).
6. **가정 문제:** 같은 초기 조건을 공유하는 것 자체는 거짓 양성을 늘리지 않는다. 학습 실행 분산이 있으면 시행을 늘릴수록 거짓 양성이 늘어난다(σ_s = 0.5, n = 150에서 0.45). 한 학습 실행만 보고한 자료로는 이 분산을 알 수 없다(`03` §7 토이 P2).
7. **코드 대조:** 공식 저장소는 시뮬 과제 22개(73행)를 자동 판정하지만, **정책 학습과 평가 파이프라인은 제외되어 있다**. 논문에 없는 수치 성공 기준이 추가되어 있고, 힘 지표 >40 N과 로봇 초기 자세의 가우시안 샘플링은 코드에 없다(`04` D1-D8).
8. **구현 가능성:** 이 맥(Apple M4 Pro, CUDA 없음)에서는 시뮬 채점과 정책 재현이 **불가능**하다. 실물 재현도 불가능하다. 할 수 있는 것은 표 재계산, 검정, toy, 과제 사양 읽기다(`04` §4).
9. **라이선스:** arXiv 비독점 배포(CC BY 아님). 논문 그림과 원문 PDF는 싣지 않았습니다(`04` §5).

ContactBench 1.0 (arXiv:2610.24512) 논문 분석

0. 메타

항목	내용
제목	ContactBench 1.0: A Benchmark for Everyday Contact-Rich Robotic Manipulation
저자	Jingyi Xiang, Yixuan Wang (University of Illinois Urbana-Champaign), Jeannette Bohg (Stanford University), Wenzhen Yuan (University of Illinois Urbana-Champaign)
arXiv	2610.24512. v1 2026-10-17, **v2 2026-10-23(최신, 이 분석의 대상)**. v1 → v2 차이는 `02` §2
학회	**표기 없음.** arXiv 초록 페이지의 Comments에는 프로젝트 사이트 주소만 있고, 본문과 프로젝트 페이지에도 학회 채택 문구가 없습니다. 프리프린트로 기록합니다
라이선스	arXiv nonexclusive-distrib 1.0(CC BY 아님). 판단과 근거는 `04` §5
원문	`paper/paper.pdf` (v2, 46 MB, 23쪽: 본문 1-17쪽, 참고문헌 16-17쪽, 부록 A-C 18-23쪽)
공식 자료	프로젝트 페이지 jingyi-xiang.github.io/contactbench, 시뮬레이션 코드 github.com/Michaelwyx/contactbench-sim(MIT)

1. 한 문단 요약

접촉이 많은 조작을 평가하려면 과제 정의와 성공 기준, 재현 가능한 물체가 필요하다는 문제의식에서 출발합니다. 사람의 일상 조작을 관찰해 **접촉 기술 8개**를 뽑고(Sec. III-A, Fig. 2), 이를 **36개 과제**(짧은 과제 31개와 긴 과제 5개, 부록 C)로 구체화합니다. 과제의 물체는 **3D 프린트(PLA)와 M3 나사로 만들며**, 인쇄된 압축·비틀림 스프링이 실제 물체와 비슷한 힘을 내도록 설계했습니다(Sec. III-D, Fig. 4-5). 같은 물체의 **시뮬레이션 모델**(Newton + MuJoCo Warp)도 공개합니다(Sec. IV). 정책 실험은 **6개 과제**에서 **Diffusion Policy(DP)와 π0.5(시각 전용), Reactive Diffusion Policy(RDP)와 Foundation Tactile Policy(FTP-1)(촉각 추가)**를 비교합니다. 각 방법은 과제당 **30회**씩 실행했고, 같은 30개 초기 조건을 모든 방법에 씁니다(Sec. V-A). 결론은 "시각 정책은 접촉 사건을 인지하고 반응하지 못하고, 촉각을 더해도 성능이 개선되지 않는다"입니다(Abstract, Sec. V-B/C).

2. 무엇이 "접촉이 많은" 과제인가

- **정의는 질적입니다.** 서론은 "접촉이 로봇이 목표를 이루는 수단"인 과제라고 씁니다(Sec. I). 접촉을 얼마나, 어떤 힘으로 쓰는지를 재는 양적 기준(힘 임계값, 접촉 시간 비율, 접촉 전환 횟수)은 없습니다.
- **8개 기술(Sec. III-A, Fig. 2)**: (1) 얇거나 작은 물체 잡기, (2) 여러 물체 한 번에 잡기, (3) 군집 속에서 잡기, (4) 환경 제약 아래 놓기, (5) 손안 재배치, (6) 외부 접촉 제어, (7) 관절 물체 조작, (8) 삽입과 정렬.
- **과제와 기술의 대응**은 부록 C 표(C1, C2)에 있습니다. 과제 하나에 기술 1-5개가 붙습니다.
- **접촉 "사건" 관점의 서술:** 각 기술 설명에 접촉의 역할이 들어 있습니다. 예를 들어 외부 접촉 제어는 "접촉이 미끄러지거나, 떨어지거나, 잘못된 힘을 전달할 수 있다"로 정의합니다(Sec. III-A). 이 정의는 검증 가능한 지표로 옮겨지지 않았습니다(`04` D4·D5).
- **정책 평가용 6개 과제의 선택 기준**은 "로봇 설정에서 가능한 것 중 가장 어려운 것"입니다(Sec. V-A). 선택 편향이 있습니다. 6개 과제는 8개 기술 중 **5개**를 덮고, **배치(placing)** 기술은 빠져 있습니다(Table II 기술 목록으로 확인).

3. 과제 목록과 난이도

짧은 과제 31개 + 긴 과제 5개 = 36개(Sec. III-B, 부록 C). 정책 평가에 쓴 6개는 아래와 같습니다(Table II, Table III, Table B2).

과제	기술	사람 시간(Table III)	시연 수(Table B2)	구성
Thread nut onto screw	삽입, 관절	17.5 s	100	손에 든 너트를 나사에 끝까지 맞물리게 돌림
Tighten screw with Allen key	외부 접촉, 삽입	19.7 s	100	육각렌치 끝을 나사 홈에 넣고 조임
Plug in charger	삽입	7.3 s	100	콘센트에 충전기 블록을 끝까지 꽂음
Turn doorknob to open door	관절	7.6 s	99(1개 제외)	손잡이를 돌려 잠금 해제 후 문 열기(5° 이상)
Retrieve single utensil from bin	군집, 얇음	11.8 s	100	통에서 수저 한 개만 꺼내 탁자에 놓기
Pick up thin card	얇음	7.5 s	100	받침대의 얇은 카드를 집어 들어 올리기

- **난이도의 근거:** 논문은 난이도를 수치로 정의하지 않습니다. 대신 최고 성공률로 드러냅니다. 최고 성공률은 너트 47%, 조이기 57%, 충전기 20%, 문 100%, 수저 53%, 카드 47%입니다(Table III). 충전기가 가장 어렵다고 쓴 것(Sec. V-B)과 맞습니다.
- **변이(Table I, Sec. III-C):** 행동 변이(회전량, 삽입력, 회전력)와 시각+행동 변이(물체 형상, 물체 수)를 Star-Gen 분류(Gao et al., 2026)로 나눴습니다. 행동 변이는 외관이 같고 필요한 행동만 다른 경우입니다.
- **과제별 사양(Table II, 부록 C)**은 성공 기준을 자연어로 씁니다. 예를 들어 문손잡이는 "문이 5° 이상 열리고 잠금 해제가 눈으로 분명해야 한다"입니다. 수치 임계값은 논문 본문에 더 없습니다(코드 쪽 수치는 `04` D4).

4. 시뮬레이션과 실물

시뮬레이션(Sec. IV, 부록 A)

- Newton 물리 엔진과 MuJoCo Warp 솔버 위에 구현했습니다(Sec. IV).
- 인쇄 스프링은 **스프링-댐퍼 관절**(강성 K, 예압 τ0)로 바꿉니다. 문손잡이 예: K와 τ0을 맞추면 인쇄본 세 종류의 힘 프로파일을 재현합니다(Fig. 7, 10 mm/s 회전).
- 접촉이 중요한 부분(나사산, 삽입 통로)은 메시 SDF로 모델링합니다. 카드는 두께 1.2 mm에 SDF 해상도 512 셀을 씁니다(Sec. IV-A).
- GelSight Mini 촉각 시뮬레이터는 hydroelastic 압력장 + Taxim 광학 렌더링입니다(Sec. IV-B, 부록 A-B, 식 A1-A3).
- 원격조작(키보드, 게임패드, SpaceMouse)과 스크립트 정책을 제공합니다(Sec. IV-C/D, Fig. 8-9).

인쇄 자산 검증(Sec. III-D, Fig. 5): 손목 F/T 센서로 미리 정한 동작(문손잡이 누르기, 충전기 꽂기)을 10회 반복 측정했습니다.

- 문손잡이: 인쇄본 5.01-9.54 N, 실물 5.45-9.53 N(누르는 힘).
- 콘센트: 인쇄본 8.04-29.26 N, 실물 5.24-37.18 N(삽입 힘).
- 같은 파일을 두 프린터(Bambu Lab P1S, Prusa XL)에서 뽑은 차이: 문 최대 0.5 N, 콘센트 최대 1.19 N.
- **범위의 한계:** 검증한 물체는 두 종류(문손잡이, 콘센트)뿐입니다. 정책 수준의 시뮬-실물 대응(같은 정책을 두 환경에서 돌린 결과)은 없습니다.

실물(Sec. V-A)

- UR5e + WSG50 평행 그리퍼 + 손목 RealSense D435i.
- 손가락: 3D 프린트 손가락에 GelSight Mini 4개 과제, Fin-Ray 손가락 2개 과제(수저, 카드). GelSight는 손끝 영역만 보기 때문에 이 두 과제에는 쓰지 않았습니다.
- 시연 수집: UMI 손잡이 그리퍼를 바꿔 쓰고(광각 카메라 → D435i, SLAM → HTC VIVE 추적), 사람 조작자는 손목 카메라와 자기 촉각에 의존하도록 제한했습니다(Sec. V-A).

5. 평가 프로토콜

항목	논문 기재	출처
정책	DP(처음부터 학습, commit 5ba07ac), RDP(처음부터, 8ed82a3), π0.5(pi05_base 미세조정, 과제마다 따로, openpi 15a9616), FTP-1(ftp1_v0426_50kstep 미세조정, 89fa681)	Sec. V-A, Table B1, 부록 B
학습 자원	DP 1×RTX 5090, RDP 1×RTX 5090, π0.5 2-4×GH200, FTP-1 2×GH200	Table B1
시연	과제당 100개(문손잡이 99개), 24 Hz, UMI 그리퍼	Table B2
시도	방법당 과제당 **30회**	Table III 설명, Sec. V-A
시간 제한	한 번의 롤아웃 1분	Sec. V-A
성공 판정	과제 성공 기준을 적용. **누가, 어떤 절차로 판정했는지는 없음**	Sec. V-A
초기 조건	물체 원점을 24×24 in 보드의 0.15 m × 0.15 m 안에서 균일 추출. 고정 난수 시드로 뽑고, 사람이 그 위치에 놓음. 렌더 오버레이(PyBullet)로 안내	Sec. V-A, Fig. 10
로봇 초기 자세	시연의 UMI 초기 자세에 맞춘 가우시안 분포에서 추출	Sec. V-A
방법 사이 짝짓기	같은 30개 물체와 로봇 초기 자세를 네 방법 모두에 씀	Sec. V-A
진행률	체크포인트 달성 비율(0-1)	Table III 설명

보고되지 않은 것(이 분석이 필요하다고 본 항목):

- 학습 시드 수(정책마다 학습 실행이 몇 번인지). 본문과 부록에 시드 언급이 없어 **1회로 보입니다**(추정).
- 시드 값과 초기 조건의 에피소드별 기록. 같은 30개 초기 조건을 썼다는 주장을 검증할 자료가 없습니다.
- 사람 조작자가 인쇄 위치를 맞춘 오차 허용치.
- 체크포인트 선택 규칙, 하이퍼파라미터 탐색 여부. 특히 π0.5와 FTP-1은 과제마다 미세조정했습니다(Sec. V-A). 평가 과제에서 조정을 했는지는 쓰지 않았습니다.
- 에피소드별 결과, 신뢰구간, 검정. 표 III는 집계값만 있습니다.

6. 결과

Table III 요약(30회 기준, 값은 SR = 성공 수 / 30)

과제	DP	RDP	π0.5	FTP-1
Thread nut	8	0	14	14
Tighten (Allen key)	0	0	17	3
Plug charger	2	4	6	4
Turn doorknob	30	29	30	29
Utensil from bin (DP, π0.5만)	0	—	16	—
Pick up card (DP, π0.5만)	14	—	2	—

- 최고 조합은 **π0.5의 조이기 17/30 = 56.7%**(Sec. V 첫 문단).
- 시각 전용 두 방법 중에서는 π0.5가 DP보다 높은 경우가 많지만, 카드는 DP가 높습니다.
- 촉각 변형(RDP, FTP-1)은 표 III에서 자기 기반 모델보다 낮거나 같은 경우가 많습니다(Sec. V-C). 통계 검정은 `03` §2-§3.

- 힘: 40 N을 넘는 에피소드 비율은 DP의 수저 과제 97%, 카드 57%, 충전기 80%로 높습니다(Table III, ">40 N" 열). 이 지표의 정의는 "손목 힘의 최댓값"이며, 측정 절차와 센서 위치는 본문에 자세히 없습니다(`04` D5).
- 진행률(Fig. 11)과 실패 유형(Fig. 12): 접촉 확립과 유지, 정렬, 불필요한 강한 접촉, 과제 상태 인식의 네 범주로 정리합니다(Sec. V-B). Fig. 11의 단계 퍼널 마지막 칸은 Table III의 성공 수와 모두 맞습니다(`03` §1).
- 촉각 실패의 원인(Sec. V-C): (a) 센서가 접촉을 보지 못함(손목·손가락 뒷면), (b) 정책이 시연에서 촉각으로 한 행동을 배우지 못함, (c) 과제와 무관한 촉각 신호에 반응함(나사 조이기에서 렌치가 미끄러지면 조기 종료, Fig. 13).
- 일반화(Sec. V-D, Fig. 14, Table IV): 문손잡이 회전량 60° → 72° → 80°에서 DP, π0.5, FTP-1은 72°에서 성공률이 절반으로 떨어지고 80°에서 거의 0입니다. RDP는 72°에서 80%(24/30), 80°에서 53.3%(16/30)를 유지합니다(본문 텍스트, Fig. 14 왼쪽). 손잡이 직경 5 mm 감소(55 mm, 10회)에서는 네 방법 모두 0%이며, 그리퍼 폭이 60 mm 설정과 같습니다(Table IV, 평균 58.7-59.2 mm).

7. 한계(Sec. VI)

- 강체와 관절 물체만 다룹니다. 변형체, 유체, 입자 물질은 범위 밖입니다.
- 인쇄 표면의 층 무늬는 촉각 센서에 다른 특징을 줄 수 있습니다. 마찰은 체계적으로 바꾸지 않았습니다.
- 촉각 센서의 시야(GelSight 손끝 영역)와 형상이 과제 선택을 좌우했습니다(Sec. V-C, 두 과제 제외).
- 논문은 "벤치마크 점수가 실물 성능을 얼마나 반영하는가"를 검증하지 않습니다. 정책 수준의 시뮬-실물 대응 증거가 없습니다.

8. 핵심 질문에 대한 답 (이 분석 기준)

질문	논문의 답	이 분석의 판단
무엇이 접촉이 많은 과제인가	8개 기술의 조합, 접촉이 목표 달성의 수단	질적 정의만 있음. 접촉량을 재는 지표 없음
과제 목록과 난이도	36개, 최고 성공률로 난이도를 드러냄	난이도 정의 없음. 6개 평가 과제는 선택 편향 있음(배치 기술 누락)
시뮬 대 실물	자산 힘은 두 종류에서 맞음, 정책은 실물만 평가	정책 수준의 대응 증거 없음
지표	성공, 진행률, >40 N 비율, 시간 배수	성공과 진행률은 검정 가능. 힘 지표와 시간은 정의·검정 정보 부족
평가 프로토콜	30회, 1분, 같은 초기 조건, 고정 시드	시드와 학습 실행 수 미보고. 에피소드별 자료 없음
기준선	DP, π0.5(시각), RDP, FTP-1(촉각)	힘/토크 입력 기준선 없음(F/T는 자산 검증에만 씀). 단일 학습 실행
통계	없음	`03`에서 재계산
벤치마크 점수가 실물 성능을 반영하는가	검증하지 않음	공개 코드에 정책 평가 파이프라인 없음(`04` D8)

ContactBench 1.0: 선행연구, GitHub 저장소, v1 → v2 차이

조사일 2026-11-10. GitHub 수치는 같은 날 `gh api`로 확인했습니다. 학회 정보는 논문 본문, arXiv 초록 페이지, 프로젝트 페이지에서만 확인했고, 학회 채택은 확인하지 못했습니다.

1. 선행연구 계보

논문 Sec. II의 분류를 따르고, 이 분석이 뽑은 가까운 대안을 덧붙였습니다.

(a) 재현 가능한 물리 벤치마크

- 표준 하드웨어: YCB(Calli et al., 2015), NIST 과제 보드(Kimble et al., 2020), ManipulationNet(Chen et al., 2026; 분산 실물 평가 인프라).
- 인쇄 설계: FurnitureBench(Heo et al., IJRR 2025), Fabrica(Tian et al., CoRL 2025), FMB(Luo et al., IJRR 2025), POMDAR(Liconti et al., RA-L 2026).
- 조건을 체계적으로 바꾸는 것: MatchMaker(Wang et al., 2025), **Peg-in-Bench**(Delgado et al., 2026, arXiv:2609.00906; 삽입 전용, 가장 가까운 대안), BusyBox(Fortier et al., 2026; 외형 일반화).
- ContactBench의 차별점은 논문 Sec. II-A의 주장대로 "기술 8개 범위"와 "인쇄 스프링이 힘을 정하는 설계"입니다.

(b) 시뮬레이션 벤치마크

- 과제 묶음: RLBench, MetaWorld, robosuite, ManiSkill2/3(GPU 병렬), CALVIN, LIBERO. 장기 과제와 언어 조건은 CALVIN과 LIBERO.
- 촉각 시뮬레이션: Taxim(렌더링), Tactile Gym 2.0(센서 비교), roto 2.0(Robot Tactile Olympiad, 2026), ManiFeel(2025), UniVTac(2026), OpenViTac(2026). 이들은 촉각 정책 평가 플랫폼이지만, 물리 자산과 접촉 행동을 연결하지는 않습니다(논문 Sec. II-B).

(c) 평가한 정책

- Diffusion Policy(Chi et al., IJRR 2025): 확산 정책의 표준 기준선.
- π0.5(Black et al., CoRL 2025): 비전-언어-행동 모델. 과제마다 미세조정(단일 과제 전문가로 씀).
- Reactive Diffusion Policy(Xue et al., 2025): 느린 시각 정책 + 빠른 촉각 반응 정책.
- Foundation Tactile Policy, FTP-1(Yuan et al., arXiv:2606.13102, 2026): π0.5 기반 범용 촉각 정책.
- 힘/접촉 정책 참고: ForceMimic(ICRA 2025), FoAR(RA-L 2025)(논문 참고문헌 [8], [9]). 힘 기반 기준선으로는 이 논문이 쓰지 않았습니다.

(d) 일반화 분류: Star-Gen(Gao et al., RA-L 2026)의 행동 변이와 시각+행동 변이 구분을 씁니다.

2. v1 → v2 차이

v1은 2026-10-17, v2는 2026-10-23입니다. 두 PDF(v1 16.99 MB 19쪽, v2 46.07 MB 23쪽)를 받아 본문 텍스트와 Table III 이미지를 대조했습니다.

수치는 같습니다. Table III(방법별 과제별 성공 수, 진행률, >40 N, 시간 배수)은 v1과 v2가 같습니다(이미지로 확인). Fig. 9(v1)과 Fig. 11(v2)의 단계 퍼널 수치도 같습니다. 캡션도 같습니다.

달라진 것

항목	v1	v2
용어	"vision-based", "vision-tactile" 8회·12회	"vision-only", "visual-tactile"로 통일(각각 1회·17회)
Table I	과제 예시(Examples of reference tasks)	변이 목록(Task variations)
Table II	변이 목록	정책 평가 6개 과제의 사양(성공 기준 포함)
부록	A(자산 모델링) 한 편	A 확장(Fig. A1, 촉각 시뮬 식 A1-A3, Fig. A2), **B 신설**(학습 커밋 해시, Table B1 학습 설정, Table B2 시연 통계와 언어 지시), **C 신설**(36개 과제 전체 사양, Table C1·C2)
초기 조건	"체계적으로 샘플링"	"**고정 난수 시드**로 물체 초기 자세를 뽑고, 사람이 그 위치에 둔다"는 문장 추가
초기 조건 그림	없음(PyBullet 렌더 오버레이를 본문에만 설명)	Fig. 10 신설(샘플링 위치의 렌더 오버레이와 벨크로 보드)
그림 번호	Fig. 8 "여섯 과제의 사람 시연 예"(v1)	삭제. Table II의 "실행 순서" 열로 대체
문손잡이 변이	Table IV(회전량·직경별 성공률)	성공률은 Fig. 14 왼쪽으로 옮김. v2의 Table IV는 그리퍼 폭(v1 Table V)
단위	"5.5 cm", "6 cm"	"55 mm", "60 mm"
롤아웃 시간	"at most one minute"	"has a one-minute time limit" (표현만 바뀜)
시뮬 그림	Fig. 4-7	Fig. 6-9 (번호만 바뀜)

해석: v2의 실질적 추가는 (1) 재현 정보(학습 커밋, 학습 설정, 과제 사양), (2) 초기 조건 샘플링의 시드, (3) 문손잡이 변이 결과의 이동입니다. 결과 수치는 바뀌지 않았습니다. v2는 "시드가 있다"는 점을 명시했지만, 시드 값과 에피소드별 기록은 여전히 없습니다(`01` §5).

3. 이 저장소의 다른 논문과의 관계

이 분석은 같은 저장소의 아래 분석들과 방법과 질문을 공유합니다. 각 항목은 해당 폴더의 README와 분석 문서 요약을 보고 적었습니다. 판단은 원문 재확인 없이 요약 수준입니다.

폴더	논문	관계	이 분석에 주는 것
`contact_disassembly/`	CONTACT, arXiv:2603.08560 (촉각 분해 정책)	같은 문제: 접촉 정책의 시뮬·실물 통계	같은 가정 문제. 그 분석은 "1500 독립 rollouts"(CMH p = 2.6e-9)와 "3 시드 × 초기 조건 50"(p = 0.062)의 차이를 보였습니다. 이 분석의 `03` §7(토이 P2)은 초기 조건 공유보다 **학습 실행 분산**이 거짓 양성을 키움을 보입니다
`restacvla/`	ResTacVLA, arXiv:2607.03387 (π0.5 + 촉각 잔차)	FTP-1과 같은 계열(π0.5 기반 촉각 확장)	같은 통계 틀(Fisher, Wilson, CMH)을 씁니다. 이 분석의 `03` §3에서 π0.5 → FTP-1 비교의 CMH 결과(p = 0.0097)와 비교할 수 있습니다
`insertion_wm/`	세계모델 삽입, arXiv:2609.28258	벤치마크 점수의 객체 간 분산	보고된 "56%" 대 "7%"는 같은 조건이 아니라는 점, 객체 분산을 넣으면 구간이 ±15-19 pp로 넓어진다는 점이 이 논문 표 III의 30회 칸(Wilson 구간 폭 11-34 pp)과 같은 문제입니다
`stiffness_copilot/`	Stiffness Copilot, arXiv:2603.14068	"안전" 주장의 힘 지표 검정	최대 접촉력 차이를 과제별로 검정하는 방식은 이 논문의 >40 N 지표를 검정할 때 참고가 됩니다. 이 논문은 힘 지표 검정을 하지 않았습니다

폴더	논문	관계	이 분석에 주는 것
`dexforce/`	DexForce, arXiv:2501.10356	촉각 힘을 **행동 목표**에 넣는 Diffusion Policy	이 논문의 기준선(촉각 입력을 관측에 넣는 RDP, FTP-1)에 없는 설계 축입니다. 힘을 목표로 바꾸는 방식은 벤치마크에 추가할 후보입니다
`beyond_implicit_force/`	Beyond Implicit Force, arXiv:2607.14578	힘 인지의 원천(관절각 편차 대 서보 전류)	이 논문은 F/T를 자산 검증에만 쓰고 정책 입력에는 넣지 않았습니다. 힘 입력 기준선이 없다는 점(`01` §8)의 대조군입니다
`pacevla/`	PaceVLA, arXiv:2610.25961	VLA 평가(공식 코드 없음)	과제별 단일 전문가 평가 설정과 비교할 수 있습니다
`thinkworld/`	ThinkWorld, arXiv:2610.37666	VLA 평가와 공식 리더보드 대조	벤치마크 점수와 실물 성능의 연결을 따지는 질문이 같습니다. 이 논문은 정책 수준의 연결 증거를 내지 않습니다

4. GitHub 저장소 표

저장소	무엇인가	공식?	라이선스	별	최근 push	고정 커밋
Michaelwyx/contactbench-sim	ContactBench 1.0 시뮬레이션. force-bench 패키지, 과제 22종(73행), 스크립트 정책, 원격조작, GelSight 시뮬, 자산 키트. **정책 학습과 평가 파이프라인은 제외**(README 명시)	**공식**(논문 Simulation code 링크, 프로젝트 페이지 링크)	MIT (LICENSE, 저작권 "2026 Yixuan Wang")	9	2026-11-05	`ccd864501275` (2026-11-04 커밋 "ContactBench 1.0 simulation"). 얕은 클론
Physical-Intelligence/openpi	π0.5 구현(논문 commit `15a9616`)	의존(논문: 공식 구현 사용)	Apache-2.0	14,604	2026-08-24	`15a9616` (2026-06-16) 존재 확인
real-stanford/diffusion_policy	Diffusion Policy 구현(논문 commit `5ba07ac`)	의존(공식 구현)	MIT	4,721	2024-12-24	`5ba07ac` (2024-12-24) 존재 확인
xiaoxiaoxh/reactive_diffusion_policy	RDP 구현(논문 commit `8ed82a3`)	의존(공식 구현)	GitHub 자동 판정 NOASSERTION(LICENSE 파일 미확인)	396	2026-04-12	`8ed82a3` (2025-12-12) 존재 확인
michaelyuancb/ftp1-policy	FTP-1 구현(논문 commit `89fa681`)	의존(공식 구현)	Apache-2.0	145	2026-07-15	`89fa681` (2026-07-15) 존재 확인
newton-physics/newton	시뮬 엔진. force-bench는 `newton==1.5.0`에 고정	의존	Apache-2.0	5,933	2026-11-10	버전 고정 1.5.0
google-deepmind/mujoco_warp	솔버. force-bench는 `mujoco-warp==3.11.0`에 고정	의존	Apache-2.0	1,626	2026-11-10	버전 고정 3.11.0

해석: 공식 시뮬 저장소는 별 9개이고 최근 push는 2026-11-05(5일 전)입니다. 커뮤니티 활동은 아직 작습니다. 정책 구현 네 개는 모두 논문이 고정한 커밋이 존재합니다. 그러나 **이 저장소에 정책 학습 스크립트, 데이터셋, 체크포인트, 평가 스크립트가 들어 있지 않아** Table III를 재생성할 수 없습니다(`04` D8).

5. 이 논문이 다른 벤치마크와 다른 점(요약)

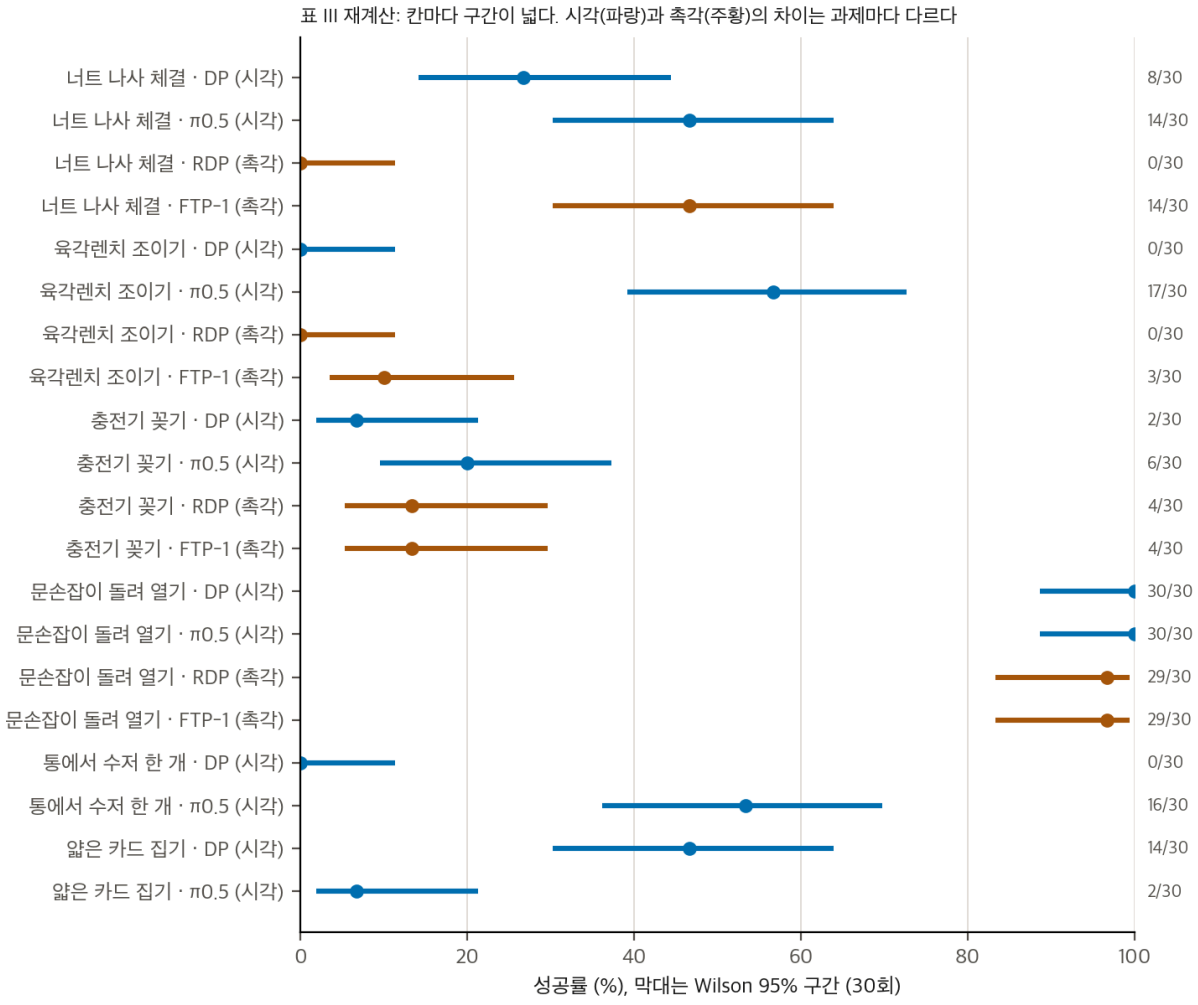
- 평가 대상: 정책 중심(DP, π0.5, RDP, FTP-1). 힘 입력은 기준선에 없습니다.
- 물체: 인쇄 가능한 물체(PLA + M3 나사)와 같은 물체의 시뮬 모델. 스프링의 힘을 K와 τ0로 맞춥니다(검증은 두 물체 종류).
- 과제: 36개를 정의하지만, 시뮬에서 채점 가능한 것은 22개 기본 과제(73행)와 과제 2의 장면입니다(`04` D1).
- 통계: 30회, 한 학습 실행, 집계 표만 공개(`03`).

ContactBench 1.0: 표 재계산, 유의성, 검정력, 토이 분석

재현 스크립트: `analysis/table_check.py` (→ `table_check_results.json`, 1초 미만), `analysis/power_toy.py` (→ `power_toy_results.json`, 약 20초, numpy 단일 스레드와 scipy의 Fisher 정확 검정). 그림은 `analysis/plot_figures.py`.

0. 데이터의 한계

- 공개된 자료는 **Table III의 집계값**(방법·과제별 성공 수 k/30, 진행률, >40 N 비율, 시간 배수)과 **Fig. 11의 단계 퍼널 퍼센트** 뿐입니다.
- 에피소드별 결과, 시드 값, 학습 실행 수, 초기 조건 번호는 없습니다. 따라서 **쌍 검정(McNemar)은 할 수 없고**, 독립 표본으로 보는 Fisher, CMH, Newcombe를 씁니다. 같은 30개 초기 조건을 쓴 쌍 설계라면 쌍 검정이 더 검정력이 높을 수 있습니다 (§7, 토이 P2의 McNemar 열).
- 모든 칸은 **30회**입니다. 한 과제의 한 방법은 학습 실행 1회로 보입니다(추정, `01` §5). 아래 추론은 "이 학습 실행과 이 30개 초기 조건"에 대한 것입니다. 학습 실행 사이의 변동은 포함하지 않습니다.
- 유의수준은 양측 0.05입니다. 다중 비교는 Holm으로 보정했고, 보정 가족을 표마다 밝혔습니다.



그래프: 표 III 칸별 성공률과 Wilson 95% 구간(30회). 파랑은 시각 정책, 주황은 촉각 정책.

1. 표 재계산과 일치 확인

(a) 셀별 성공률과 Wilson 95% 구간(n = 30)

과제	DP	RDP	π0.5	FTP-1
Thread nut	8/30 = 26.7% [14.2, 44.5]	0/30 = 0.0% [0.0, 11.3]	14/30 = 46.7% [30.2, 63.9]	14/30 = 46.7% [30.2, 63.9]
Tighten (Allen key)	0/30 = 0.0% [0.0, 11.3]	0/30 = 0.0% [0.0, 11.3]	17/30 = 56.7% [39.2, 72.6]	3/30 = 10.0% [3.5, 25.6]
Plug charger	2/30 = 6.7% [1.8, 21.3]	4/30 = 13.3% [5.3, 29.7]	6/30 = 20.0% [9.5, 37.3]	4/30 = 13.3% [5.3, 29.7]
Turn doorknob	30/30 = 100% [88.6, 100]	29/30 = 96.7% [83.3, 99.4]	30/30 = 100% [88.6, 100]	29/30 = 96.7% [83.3, 99.4]
Utensil from bin	0/30 = 0.0% [0.0, 11.3]	미평가	16/30 = 53.3% [36.1, 69.8]	미평가
Pick up card	14/30 = 46.7% [30.2, 63.9]	미평가	2/30 = 6.7% [1.8, 21.3]	미평가

- 칸의 구간 폭은 11-34 pp입니다. 가장 넓은 칸은 성공률이 0.5 근처인 π0.5 thread(33.7 pp)입니다.

(b) 표 내부 일치 점검

- Fig. 11의 퍼널 마지막 단계(task terminated correctly, door opened, card grasped)는 22개 칸 모두 Table III 성공 수 k/30을 반올림한 값과 같습니다. 퍼널의 다른 단계는 Fig. 9(v1)과도 같습니다(`02` §2).
- 텍스트 수치 점검: "최고 56.7%" = 17/30 ✓. "충전기에서 π0.5 20%" = 6/30 ✓. "RDP 72°에서 80%, 80°에서 53.3%" = 24/30, 16/30 ✓(§9).
- **시간 기준 불일치**: 표 III의 사람 시간(17.5, 19.7, 7.3, 7.6, 11.8, 7.5 s)과 표 B2의 시연 평균(19.6, 21.0, 8.4, 8.8, 12.9, 8.6 s)이 과제마다 1.1-2.1 s 다릅니다. 시간 배수가 어느 기준인지 정할 수 없습니다. 논문에 설명이 없습니다.

(c) 평균 성공률(같은 과제 집합에서만 비교)

집합	DP	RDP	π0.5	FTP-1
6과제	30.0%	—	47.2%	—
촉각 데이터가 있는 4과제(thread, tighten, plug, door)	33.3%	27.5%	55.8%	41.7%

6과제 평균을 촉각 방법과 비교하면 안 됩니다. 촉각 방법은 4과제만 평가했습니다. 4과제 기준으로 보면 촉각 변형이 시각 기반보다 낮습니다.

2. DP 대 π0.5: 과제별 비교 (6과제, Holm 보정 가족 = 6)

과제	DP	π0.5	차이 (pp)	Fisher p	Holm p
Thread nut	8	14	+20.0	0.180	0.540
Tighten	0	17	+56.7	< 1e-4	< 1e-4
Plug	2	6	+13.3	0.254	0.540
Door	30	30	0.0	1.000	1.000
Utensil	0	16	+53.3	< 1e-4	< 1e-4

과제	DP	π0.5	차이 (pp)	Fisher p	Holm p
Card	14	2	−40.0	0.0009	0.0036

- π0.5는 조이기와 수저에서 DP보다 **유의하게 높습니다**(보정 후 $p < 0.001$). DP는 카드에서 유의하게 높습니다(보정 후 0.0036).
- thread와 plug에서는 차이가 보정 후 유의하지 않습니다. 논문이 "π0.5가 DP보다 큰 폭으로 높다"고 쓴 문장(Sec. V-B)은 **6과제 중 2과제에서만** 검정과 맞습니다.

3. 촉각 효과: 시각 대 촉각 (각 4과제, 보정 가족 = 4)

(a) DP → RDP

과제	DP	RDP	차이(RDP − DP, pp)	Fisher p	Holm p
Thread nut	8	0	−26.7	0.0046	0.018
Tighten	0	0	0.0	1.000	1.000
Plug	2	4	+6.7	0.671	1.000
Door	30	29	−3.3	1.000	1.000

- 층화 CMH(4과제): χ^2 보정 2.66, **$p = 0.103$**, 공통 오즈비 2.9(DP 쪽).
- 과제를 하나씩 뺐을 때 CMH p: thread 뺌 → 1.00, tighten 뺌 → 0.103, plug 뺌 → 0.0048, door 뺌 → 0.158. **효과는 thread 한 과제에 기댑니다.** plug에서는 RDP가 더 높아 방향이 반대입니다.
- 합산 차이(층 무시): −5.8 pp, Newcombe 95% [−17.2, +5.8], Fisher p = 0.40.

(b) π0.5 → FTP-1

과제	π0.5	FTP-1	차이(FTP-1 − π0.5, pp)	Fisher p	Holm p
Thread nut	14	14	0.0	1.000	1.000
Tighten	17	3	−46.7	0.0003	0.001
Plug	6	4	−6.7	0.731	1.000
Door	30	29	−3.3	1.000	1.000

- 층화 CMH(4과제): χ^2 보정 6.70, **$p = 0.0097$**, 공통 오즈비 2.4(π0.5 쪽).
- 과제를 하나씩 뺐을 때 CMH p: thread 뺌 → 0.0009, **tighten 뺌 → 0.687**, plug 뺌 → 0.010, door 뺌 → 0.014. **효과는 조이기 한 과제에서 나옵니다.**
- 합산 차이: −14.2 pp, Newcombe 95% [−26.2, −1.5], Fisher p = 0.039(층 무시).

해석

- "촉각이 개선하지 않는다"는 논문 결론은 자료와 맞습니다. 하지만 자료는 한 걸음 더 나갑니다. **보정 후 유의한 효과 두 개는 모두 해롭다는 방향**입니다. RDP는 thread에서, FTP-1은 조이기에서 낮습니다(Holm 0.018, 0.001). 논문은 "종종 더 나빴다(oftentimes performed worse)"라고만 씁니다(Sec. V 도입).
- 조이기의 FTP-1 저하는 논문이 설명한 기제(렌치가 미끄러지면 촉각 신호가 조기 종료를 유발, Fig. 13)와 맞습니다. 이 기제는 로그가 없어서 검증하지 못했습니다.
- 두 CMH 검정은 한 과제에 기대므로, "촉각이 해롭다"는 과제별 보고로 말해야 합니다.

4. 40 N 칸(>40 N 비율)

Table III의 퍼센트에서 k를 역산했습니다(k/30을 반올림하면 표의 퍼센트가 나오는지 확인). 역산 가능한 칸은 모두 맞습니다.

칸	역산 k/30	Wilson 95%
DP: thread / plug / utensil / card	10 / 24 / 29 / 17	19-51 / 63-91 / 83-99 / 39-73 %
RDP: plug / door	25 / 19	66-93 / 46-78 %
π0.5: thread / plug / utensil / card	8 / 12 / 14 / 18	14-45 / 25-58 / 30-64 / 42-75 %
FTP-1: thread / plug / door	25 / 12 / 13	66-93 / 25-58 / 27-61 %

- 이 지표는 "접촉력이 크면 안전하지 않다"는 주장의 근거입니다(Sec. V-B). 검정은 하지 않았습니다. 정의가 모호합니다(`04` D5). 손목 힘의 최댓값이 어디서 재는지 본문에 없습니다. 같은 과제에서 DP와 π0.5 사이에 40 N 칸 차이가 있는지도 이 자료로는 말할 수 없습니다. 예: thread DP 10/30 대 π0.5 8/30은 차이가 작아 검정력 밖입니다.

5. 유도

5.1 Wilson 구간. 성공 수 k, 시도 n, $\hat{p} = k/n$, z = 1.96 일 때

center = $(\hat{p} + z^2/(2n)) / (1 + z^2/n)$, half = $z \cdot \sqrt{(\hat{p}(1-\hat{p})/n + z^2/(4n^2))} / (1 + z^2/n)$

구간은 [center − half, center + half]입니다. k = 0이면 하한이 0, k = n이면 상한이 1입니다.

5.2 Fisher 정확 검정(양측). 2×2 표 [[a, n_1-a], [b, n_2-b]]에서 주변합을 고정하면 a는 초기하분포를 따릅니다. 양측 p는 관측 확률 이하인 모든 표의 확률 합입니다. scipy의 `fisher_exact(alternative="two-sided")`가 이 값을 씁니다.

5.3 CMH(층화 Mantel-Haenszel, 연속성 보정). 과제 i마다 2×2 표 (a_i, b_i, c_i, d_i), 층 크기 $n_i = a_i+b_i+c_i+d_i$라 할 때

$E_i = (a_i+b_i)(a_i+c_i)/n_i$ $V_i = (a_i+b_i)(c_i+d_i)(a_i+c_i)(b_i+d_i) / (n_i^2(n_i-1))$ $\chi^2 = (|\Sigma(a_i - E_i)| - 0.5)^2 / \Sigma V_i$, $p = P(\chi^2_1 > \chi^2)$

공통 오즈비(Mantel-Haenszel)는 $OR = \Sigma(a_i\, d_i/n_i) / \Sigma(b_i\, c_i/n_i)$입니다. 어떤 층의 $b_i\, c_i$가 모두 0이면 정의되지 않습니다(이 경우 None으로 기록).

5.4 Holm 보정. 유의 p를 오름차순 $p_{(1)} \le \cdots \le p_{(m)}$로 정렬하면, 보정 $p_{(j)} = \max_{k \le j} \min(1, (m-k+1) \cdot p_{(k)})$입니다.

5.5 Newcombe 차이 구간. $p_1 - p_2$의 구간은 두 Wilson 구간 $[l_1, u_1]$, $[l_2, u_2]$로부터

lower = $d - \sqrt{((p_1 - l_1)^2 + (u_2 - p_2)^2)}$, upper = $d + \sqrt{((u_1 - p_1)^2 + (p_2 - l_2)^2)}$, $d = p_1 - p_2$

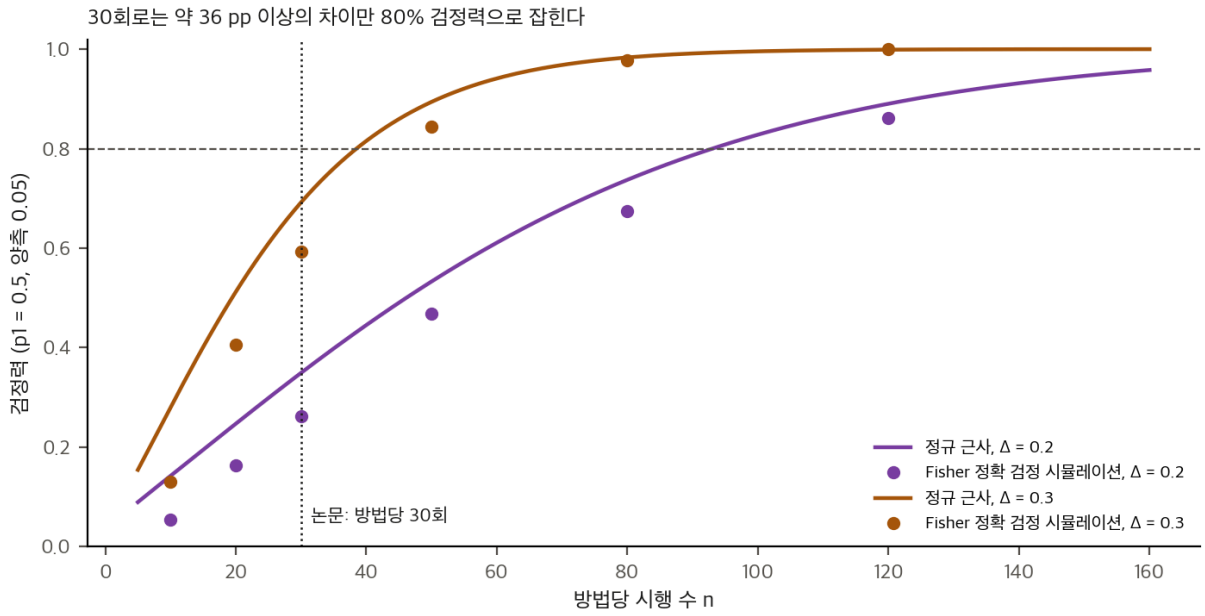
입니다.

5.6 쌍 설계일 때의 McNemar(이 자료에는 적용 못 함). 같은 초기 조건의 두 방법에서 불일치 쌍 수 b(A 성공, B 실패)와 c(A 실패, B 성공)가 있으면 $\chi^2 = (|b-c|-1)^2/(b+c)$, 자유도 1입니다. 에피소드별 기록이 공개되면 Fisher 대신 이 검정을 써야 합니다.

5.7 최소 검출 차이. 방법당 n, 기준 비율 $\bar{p}$(두 비율의 평균), 양측 α = 0.05, 검정력 1−β = 0.8일 때

$\Delta_{min} \approx (z_{\alpha/2} + z_\beta) \cdot \sqrt{(2\, \bar{p}(1-\bar{p}) / n)}$

n = 30이면 $\bar{p}$ = 0.5에서 $\Delta_{min} \approx 36.2$ pp, $\bar{p}$ = 0.2에서 28.9 pp입니다(`table_check_results.json`의 mde_80pct_n30).



그래프: 방법당 n에 따른 검정력(p1 = 0.5). 실선은 정규 근사, 점은 Fisher 정확 검정 시뮬레이션(2000회).

6. 검정력 (토이 P1)

(a) 80% 검정력에 필요한 방법당 n(정규 근사, p1 = 기준 성공률)

p1	Δ = 0.1	Δ = 0.2	Δ = 0.3
0.2	294	82	39
0.5	388	93	39
0.8	199	35	39

(b) Fisher 정확 검정 시뮬레이션(p1 = 0.5, 2000회 반복, 양측 0.05)

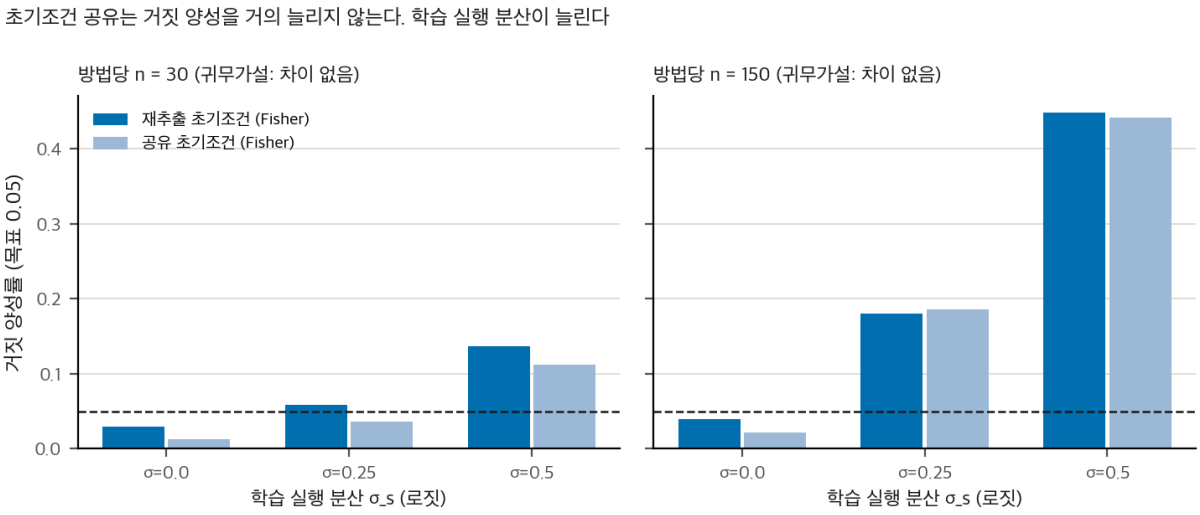
n	10	20	30	50	80	120
Δ = 0.2	0.05	0.16	0.26	0.47	0.67	0.86
Δ = 0.3	0.13	0.41	0.59	0.85	0.98	1.00

- 30회로 80% 검정력을 얻으려면 Δ ≈ 36 pp 이상이 필요합니다. 논문 표의 칸 차이 대부분(예: 0/30 대 17/30, 2/30 대 14/30)은 이 크기에 있습니다. 4-10 pp 차이는 이 설계로는 가릴 수 없습니다.

(c) 순위 신뢰도: 참 성공률 p_a > p_b일 때 관측 순서가 맞을 확률(동률 0.5점).

(p_a, p_b)	n=10	n=30	n=100	n=300
(0.5, 0.4)	0.67	0.79	0.92	0.99
(0.5, 0.3)	0.82	0.94	1.00	1.00
(0.9, 0.8)	0.73	0.86	0.98	1.00

- 순서가 맞을 확률 0.8 수준은 10 pp 차이에서 n ≈ 30, 0.9 수준은 n ≈ 100에서 얻습니다. 하지만 같은 n에서 그 차이를 **검정으로 잡는 힘**은 훨씬 낮습니다. 10 pp, n = 30의 검정력은 정규 근사로 약 0.12입니다. 순위 정확도와 검정력은 다른 질문입니다.



그래프: 토이 P2의 귀무 거짓 양성률. 공유 대 재추출 초기 조건, 학습 실행 분산 σ_s별. 점선은 0.05.

7. 토이 P2: 초기 조건 공유와 학습 실행 분산

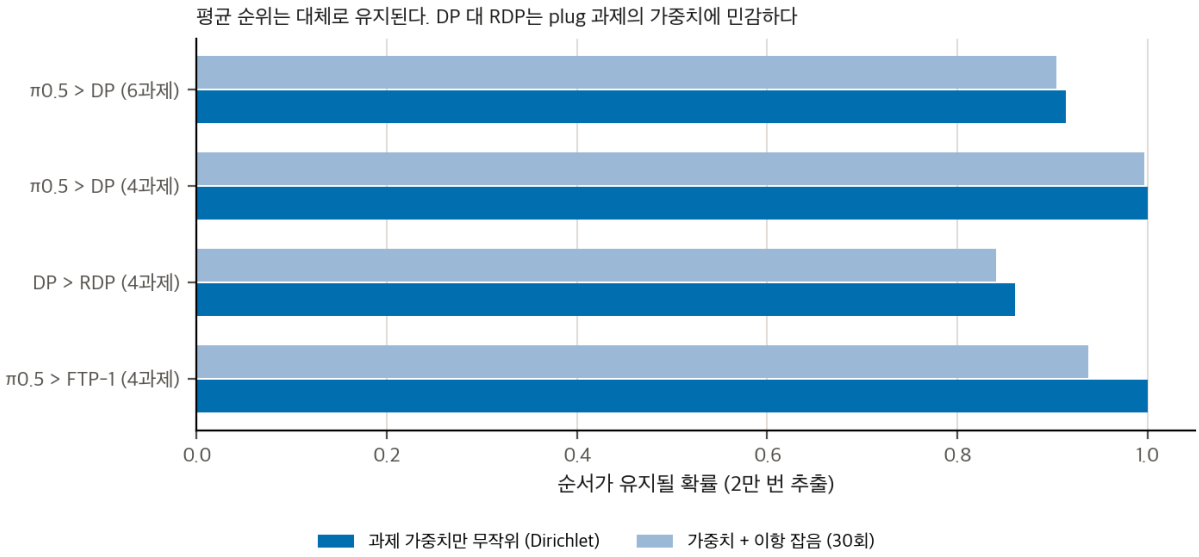
설정(가정). 로짓 모형 P(성공) = σ(μ_k + s_k + b_i). b_i ~ N(0, 1)은 초기 조건 난이도, s_k ~ N(0, σ_s^2)은 정책 k의 **학습 실행 효과**입니다. 정책당 학습 실행이 1회이면 s_k는 한 번 뽑힌 값이고 시행을 늘려도 평균되지 않습니다. 설계 R은 시행마다 새 초기 조건을 뽑고, 설계 S는 두 방법이 같은 n개 초기 조건을 씁니다. 귀무가설은 μ_A = μ_B입니다. 대립은 δ = 0.85 로짓 차이(기준 0.5 대 0.7)입니다. 2000회 반복, Fisher 정확 양측 0.05입니다.

설계	σ_s	n	거짓 양성률(귀무)	검정력(δ = 0.85)	McNemar 거짓 양성 / 검정력(설계 S만)
R	0	30	0.030	0.19	—
R	0	150	0.040	0.82	—
S	0	30	0.013	0.17	0.018 / 0.21
S	0	150	0.025	0.85	0.038 / 0.88
R	0.25	30	0.059	0.22	—
R	0.25	150	0.180	0.72	—
S	0.25	30	0.036	0.19	0.048 / 0.22
S	0.25	150	0.186	0.72	0.222 / 0.75
R	0.5	30	0.141	0.27	—
R	0.5	150	0.429	0.65	—
S	0.5	30	0.129	0.28	0.149 / 0.30
S	0.5	150	0.449	0.67	0.475 / 0.69

해석

1. **초기 조건을 공유하는 것 자체는 거짓 양성을 늘리지 않습니다.** σ_s = 0에서 S의 Fisher 검정은 오히려 보수적입니다(0.013, 0.025). 같은 초기 조건은 두 결과를 양의 상관으로 묶고, 독립을 가정한 검정은 그만큼 차이를 과소평가합니다.
2. **거짓 양성을 늘리는 것은 학습 실행 분산입니다.** σ_s = 0.25 또는 0.5에서 R과 S 모두 거짓 양성률이 n과 함께 커집니다(σ_s = 0.5, n = 150: 0.43-0.45). 시행을 많이 해도 학습 실행 차이는 평균되지 않으므로, 시행 수가 늘수록 "유의한" 차이가 더 자주 나옵니다.

3. 쌍 검정 McNemar는 S에서 검정력을 약간 높입니다(+0.02–0.04). 에피소드별 기록이 있다면 쓸 가치가 있습니다.
4. 이 결과는 **σ_s의 값에 달려 있습니다.** σ_s = 0.25 로짓은 p = 0.5 근처에서 약 ±6 pp의 학습 실행 차이입니다. 실제 값은 이 논문 자료로는 추정할 수 없습니다. 방향만 주장으로 씁니다.
5. contact_disassembly 분석의 결과(1500 독립 가정 대 3 시드 × 50 초기 조건)와 같은 구조입니다. 그 분석에서 큰 차이는 독립 가정으로 시행을 세었기 때문에 생겼습니다. 이 토이는 독립 가정이 틀렸을 때의 방향을 보여 줍니다.



그래프: 과제 가중치 민감도. 두 가지 무작위화(가중치만, 가중치 + 이항 잡음)에서 순서가 유지될 확률.

8. 토이 P3: 집계 점수의 과제 가중치 민감도

(a) 가중 평균의 순위. 과제 가중치를 Dirichlet(1,⋯,1)로 2만 번 뽑았습니다. 같은 순서가 유지되는 비율은 다음과 같습니다.

비교	가중치만 무작위	가중치 + 이항 잡음(30회)
π0.5 > DP (6과제)	0.91	0.90
π0.5 > DP (4과제)	1.00	1.00
DP > RDP (4과제)	0.87	0.84
π0.5 > FTP-1 (4과제)	1.00	0.94

- π0.5 > DP, π0.5 > FTP-1은 가중치에 강합니다. DP > RDP는 plug 과제의 가중치가 커지면 뒤집힙니다(plug에서 RDP 4/30 대 DP 2/30).

(b) 기술 수 가중(Table II 기준: thread 2, tighten 2, plug 1, door 1, utensil 2, card 1)을 쓰면 6과제 평균은 DP 23.0%, π0.5 48.9%이고 4과제에서는 DP 26.7%, RDP 18.3%, π0.5 54.4%, FTP-1 37.2%입니다. 순서는 바뀌지 않습니다. 그러나 RDP와 DP의 차이는 4과제 균등 가중(5.8 pp)보다 커집니다(8.3 pp).

(c) 과제 하나를 뺄 때 6과제 평균 차이(π0.5 − DP, pp)는 thread 뺌 16.7, tighten 뺌 9.3, plug 뺌 18.0, door 뺌 20.7, utensil 뺌 10.0, card 뺌 28.7입니다. 조이기에서 가장 큰 차이가 나므로, 이 과제를 빼면 차이가 가장 작아집니다(9.3 pp). 방향은 모든 경우에 같습니다.

해석: 집계 점수는 "과제 선택"에 민감합니다. 6과제 평균이 4과제 평균과 다르고, 촉각 방법은 4과제만 있으므로 6과제 평균을 쓰면 안 됩니다. 논문은 집계 점수를 쓰지 않았습니다(Table III는 과제별 표). 이 벤치마크에 집계 점수를 도입한다면, 가중치와 누락 과제를 먼저 정해야 합니다.

9. 논문 텍스트 주장 점검

주장(위치)	자료로 확인한 결과	판단
π0.5가 DP보다 "큰 폭으로" 높다(Sec. V-B)	6과제 중 조이기, 수저에서만 보정 후 유의	부분 맞음. thread와 plug는 차이가 검정력 밖
최고 조합 56.7%(Sec. V)	π0.5 조이기 17/30	맞음
충전기에서 π0.5 20%(Sec. V-B)	6/30	맞음
촉각 방법은 성능을 개선하지 않는다(Sec. V-C, Abstract)	촉각 쌍 중 보정 후 유의한 차이 2건, 모두 해로움(RDP thread, FTP-1 tighten)	맞음. 해롭다는 쪽이 더 강하다
촉각 방법은 "종종 더 나쁘다"(Sec. V 도입)	위 2건	맞음
RDP는 회전량 변화에 적응(Sec. V-D)	72° 80%, 80° 53.3%(24/30, 16/30). 다른 세 방법은 "절반", "거의 0"으로만 씀	수치 정보 부족. 다른 방법의 수치를 검정할 수 없음. 단일 과제, 단일 학습 실행
손잡이 5 mm 작아지면 네 방법 모두 0%(Sec. V-D)	10회, 전부 0	맞음(10회 기준). 그리퍼 폭은 기대 5 mm 대비 0.3 mm 이하 변화(Table IV)
시각 전용 정책은 접촉 사건을 인지하지 못한다(Sec. V-B)	정성 분석(Fig. 12). 정량 검정 없음	검정 불가
사람 시간이 표에 있다(Table III)	표 B2와 1.1-2.1 s 차이	불일치. 설명 필요

10. 한계

- 30회, 학습 실행 1회. 칸 구간 폭이 11-34 pp이고, 학습 분산은 포함하지 않습니다. 이 논문의 결론은 "이 학습 실행의 30회 시도에서" 관찰된 것입니다.
- 과제 6개는 선택 편향(가능한 것 중 가장 어려운 것)이 있습니다. 결과를 전체 벤치마크로 일반화할 수 없습니다.
- 초기 조건의 쌍 구조를 쓸 수 없습니다. 쌍 검정을 쓰면 검정력이 더 높을 수 있습니다.
- 토이의 σ_b = 1, σ_s 격자, δ = 0.85는 설계 가정입니다. 실제 값과 방향을 확인하려면 학습 실행을 여러 번 해야 합니다.

ContactBench 1.0: 논문 ↔ 공식 코드 대조 (정적 읽기)

0. 대상과 방법

- 저장소: github.com/Michaelwyx/contactbench-sim (MIT). 얕은 클론 `repo/contactbench-sim/` (gitignore). 커밋 `ccd864501275112e369a71c91880adf2da28b536` (2026-11-04 커밋, 2026-11-05 push, 제목 "ContactBench 1.0 simulation").
- **읽은 것**: README, docs/tasks.md(과제 표, "How a run is judged", "Tasks not included"), docs/variations.md(랜덤 시작), docs/data.md(수집과 에피소드 형식), docs/installation.md(요구 사항), docs/tactile.md 일부, `pyproject.toml`과 `packages/force-bench/pyproject.toml`(의존 고정), `qa.py`, `appendix_tasks/common.py`(판정 헬퍼), 과제 모듈 `plug_in_charger.py`, `pick_up_object_on_platform.py`, `screw_nut_onto_screw.py`, `turn_doorknob_open_door_flat.py`, `retrieve_utensil_from_bin.py`(일부), `_allen_key.py`(일부), `hang_wrench.py`, `hang_ruler.py`(시간 예산).
- **하지 않은 것**: 코드 실행, `pip install`, 자산·데이터·가중치 다운로드, GPU 사용. docs가 "`force-bench list`는 GPU가 필요 없는 순수 파이썬"이라고 쓰지만 실행하지 않았습니다.
- 표기: 논문 쪽은 절·표·그림 번호, 코드 쪽은 파일명과 줄 번호 또는 docs 절로 씁니다.

1. 과제 정의 대조

논문 36개 ↔ 코드 범위(docs/tasks.md)

- 기본 과제 31개 중 **22개에 스크립트 정책과 자동 판정**이 있고(73행), 과제 2(수저 통)는 **장면만**(판정 없음) 있습니다.
- 제외된 기본 과제 8개: 1(열쇠고리에서 열쇠 하나), 3(나사 통에서 한 개), 7·8(여러 물체 모으기), 10(통에 넣기), 11·12(손안 재배치), 21(열쇠 꽂기). 제외 이유는 docs에 과제별로 적혀 있습니다(예: 11·12는 "패드 마찰과 순응이 보정되지 않았다").
- 장기 과제 5개(부록 C, Table C2)는 **구현되지 않았습니다**. 몇몇 단계는 기본 과제로 존재합니다.

정책 평가 6과제 ↔ 코드 행(Table II 기준)

논문 과제	코드 행(예)	자동 판정	비고
Thread nut onto screw	`screw_nut_onto_screw`, `thread_nut_onto_screw_from_table`	있음	
Tighten screw with Allen key	`tighten_screw_with_allen_key_from_table`	있음	래퍼 31줄, 본체는 `_allen_key.py`
Plug in charger	`plug_in_charger`, `plug_in_charger_block1` … `4`, … `_spring_0.85mm`	있음	
Turn doorknob to open door	`turn_doorknob_open_door_flat`, `_unlock40`, `_unlock80`, `_knob1_55mm` (직경 55 mm)	있음	회전 40-80°, 스프링 5/7.5/10 mm 변형
Retrieve single utensil from bin	`retrieve_utensil_from_bin`	**없음 (장면만)**	docs/tasks.md 과제 2: 손가락 공간 때문에 스크립트 정책 불가
Pick up thin card	`pick_up_object_on_platform` (카드 행)	있음	

→ 논문의 6과제 정책 평가 중 **5개만 시뮬에서 채점할 수 있습니다**(D2).

2. 불일치와 일치 항목 (D-items)

판정 열: **불일치**(논문과 코드가 다름), **추가**(코드에만 있음), **일치**, **확인 불가**(코드에 근거 없음, 원자료 미공개).

ID	주제	논문	코드	판정	근거
D1	과제 범위	36개(31 + 5)	기본 22개 채점 + 과제 2 장면, 장기 과제 0개	불일치	docs/tasks.md, README
D2	정책 평가 과제	6개 중 실물 시연·평가	6개 중 5개 채점 가능. 수저 통은 장면만	불일치	docs/tasks.md 과제 2
D3	로봇	실물 UR5e + WSG50, 손가락 3D 프린트 + GelSight Mini 또는 Fin-Ray	시뮬 Franka FR3 + Franka Hand, Fin-Ray 어댑터(FR3용), 시뮬 GelSight	불일치(시뮬 대 실물)	docs/installation.md, docs/finray.md, Sec. V-A
D4	성공 기준	텍스트(예: 문 5° 이상, 충전기 완전 삽입)	텍스트 기준 + **논문에 없는 수치 기준** (아래 표)	추가	과제 모듈, `common.py`
D5	힘 지표	>40 N 비율(손목 힘 최댓값), 측정 위치·방법 미기재	손목 힘 40 N 판정 없음. 40 N은 **원격조작 가드의 위험 임계값**(robot→object, 경고 15 N). 접촉 해제는 0.05 N 미만	불일치(정의 불명)	docs/teleoperation.md 표, `common.py` `CONTACT_FREE_N = 0.05`
D6	물체 초기 조건	0.15 m × 0.15 m 균일, 고정 시드	`--seed N`으로 같은 사각형 안 균일 추출, 물체 겹침 회피	일치	docs/variations.md, `common.py` `sample_start`
D7	로봇 초기 자세	시연 UMI 초기 자세에서 가우시안 추출	로봇 시작 자세 랜덤화 **없음**(`appendix_tasks`에서 로봇 시작 랜덤 코드를 찾지 못함). 시드는 물체만	불일치	grep 결과, docs/variations.md("물체 위치 및 yaw")
D8	정책 학습과 평가	DP, RDP, π0.5, FTP-1을 과제당 학습·30회 평가	"Policy learning and evaluation pipelines are not part of this release." 스크립트 정책 수집과 원격조작 기록만 있음	**불일치(핵심)**	README 37행, docs/data.md

ID	주제	논문	코드	판정	근거
D9	롤아웃 시간	1분(실물)	과제마다 다름: `hang_wrench` 40 s, `hang_ruler` 50 s, 나사돌리개 120 s, Allen key 140 s, 렌치 150 s	불일치(목적이 다를 수 있음)	과제 모듈의 `T_BUDGET`
D10	판정	과제 성공 기준 적용, 판정 주체 미기재	자동 판정(`appendix_qa.json`), 기준 항목별 pass, 물리 무결성 검사 포함	추가(시뮬은 자동)	docs/tasks.md "How a run is judged"
D11	결정성	미기재	GPU 접촉 순서가 결정적이지 않음. 같은 시작에서도 힘이 조금 다름. 판정은 마진으로 흡수	추가(재현 한계)	docs/data.md, docs/installation.md, docs/tasks.md
D12	자산 힘 캘리브레이션	Fig. 5: 인쇄본 대 실물 F/T 힘, 10회 반복	`kit/mechanisms/outlet.py`: "28 kN/m fitted to measured insertion force (UR arm, wrist F/T, 10 trials)". docs/assets.md에 측정 힘 프로파일과 그것을 재현하는 파라미터가 있다고 적혀 있음(수치는 읽지 않음)	일치(상수), **원자료 확인 불가**	소스 주석, docs/assets.md
D13	시뮬 엔진	Newton + MuJoCo Warp(버전 없음)	`newton==1.5.0`, `warp-lang==1.16.0`, `mujoco-warp==3.11.0`, `mujoco==3.11.0`으로 고정	일치(버전 추가)	`packages/force-bench/pyproject.toml`
D14	촉각 시뮬	hydroelastic 압력장 + Taxim 렌더링, 선택 모듈	`hydrogel` 패키지(압력, 렌더, 센서 모듈), GS Mini 보정표는 HydroShear(MIT) 파생. `TB_GELSIGHT=1` 표시 과제만 지원	일치(범위는 과제 일부)	THIRD_PARTY_NOTICES, docs/tactile.md
D15	자산 수	40개 이상	자산 페이지 기준 49개 키트 자산	일치	README
D16	사람 시간	사람 시연 시간(Table III)	사람 시연 없음. 스크립트 정책은 "기준 시연이지 기준선이 아님"	확인 불가(시뮬에 대응 없음)	docs/tasks.md
D17	학습 설정	부록 B(DP 1×RTX 5090 등)	학습 설정 없음	불일치(없음)	저장소 전체

ID	주제	논문	코드	판정	근거
D18	라이선스	arXiv 비독점(논문), 자산 공개 예정	코드·자산 MIT, GS Mini 외장 CAD 제외(GPL-3.0)	추가	LICENSE, THIRD_PARTY_NOTICES
D19	공개일정	"will be open-sourced"	2026-11-05 push, 별 9개	일치	GitHub API
D20	과제목록	부록 C의 과제 이름	`docs/tasks.md` 의 과제 표가 같은 이름과 번호를 씀	일치	docs/tasks.md

D4 세부: 논문 텍스트에 없는 수치 기준(코드)

과제	코드의 추가 검사 (임계값)
문손잡이	잠금 해제 전 문 열림 < 1°, 마지막 시점 문 열림 ≥ 5°, 마지막 1초 손목 이동 < 3 mm, 마지막 1초 문 각도 범위 < 1° (`turn_doorknob_open_door_flat.py`)
충전기	밀기 시험에서 콘센트 반력 ≥ 8 N(`PUSH_F`), 추가 밀기 거리 ≤ 0.3 mm(`PUSH_MOVE_MAX`), 꽂은 뒤 정착 간격 ≤ 0.5 mm(`SEAT_GAP_MAX`), 놓은 뒤 정지 ≤ 0.5 mm(`STAY_MAX`) (`plug_in_charger.py`)
카드 집기	들어 올림 ≥ 30 mm(`LIFT_MIN`), 1.5 s 유지(`HOLD_S`) 동안 양쪽 패드 힘 > 0.5 N인 프레임 ≥ 95%, 미끄럼 < 2 mm (`pick_up_object_on_platform.py`)
너트 나사	최종 너트 중심 높이 `ENGAGED_Z`, 7회 스트로크 동안 평균 패드 힘 > 1 N, 마지막 z 변화 < 0.3 mm (`screw_nut_onto_screw.py`)
모든 "접촉 해제"	로봇-물체 접촉 합 < 0.05 N(`CONTACT_FREE_N`)

→ 논문 텍스트는 "stably grasped and lifted off the platform"처럼 질적으로 씁니다. 코드는 그것을 수치 규칙으로 바꿉니다. **이 임계값들은 논문에 없습니다.** 다른 연구자가 정책을 채점할 때 같은 결과를 내려면 이 값을 공유해야 합니다. 임계값을 바꾸면 Table III 같은 성공률은 달라질 수 있습니다. 정책 평가 재현에서 가장 중요한 설정 항목입니다.

3. "접촉이 많다"는 정의의 코드 쪽 대응

- 코드는 접촉을 **존재와 해제**로 채점합니다. 해제는 0.05 N 미만, 패드 힘은 1 N 이상이나 0.5 N 이상, 반력은 8 N 이상입니다.
- 접촉의 양이나 "얼마나 접촉에 의존하는가"를 재는 지표는 없습니다. 과제 목록의 기술 라벨(예: `extrinsic`, `insertion`)은 문서용 표시이고 채점 로직과 연결되지 않습니다.
- 따라서 "접촉이 많은 과제"의 조작적 정의는 논문과 코드 모두에 없습니다. 이 점은 `01` §8과 같습니다.

4. 구현 가능성 판정 (이 맥)

이 맥의 조건: Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, torch 미설치(메모리 기록). 설치는 하지 않았습니다.

시뮬레이터 요구 (docs/installation.md)

- Linux x86_64(Ubuntu 22.04에서 시험), **NVIDIA GPU**와 CUDA 12 드라이버(시험 장치 RTX 5090 32 GB), Python 3.10 이상(시험 3.12).
- 과제 프로세스당 GPU 메모리 1-2 GB(GelSight는 더 많음). Warp 커널 첫 컴파일에 수 분 걸립니다.
- 과제 실행 시간: 삽입·문·다이얼 2-6분, 손잡이 4-12분, 컵 6-20분, 공구 집기·사용·복귀는 30-60분(RTX 5090 기준, docs/tasks.md).
- Apple GPU(MPS)는 CUDA가 아니므로 이 저장소의 Warp 경로로는 쓸 수 없습니다(문서가 지원하지 않음). Warp의 CPU 백엔드로 돌릴 가능성은 문서에 없고 시도하지 않았습니다(미확인).

실물 요구 (논문 Sec. V-A, Table B1, B2)

- UR5e, WSG50, RealSense D435i(손목), GelSight Mini 여러 개(손가락 3D 프린트 부품), Fin-Ray 손가락, HTC VIVE 추적기와 OpenVR, 3D 프린터(PLA, 논문은 Bambu Lab P1S와 Prusa XL), M3 나사, 24×24 in 벨크로 보드, 렌더 오버레이용 PyBullet.
- 시연: 과제당 100회 × 6과제 = 약 600회(UMI 수집). 학습: DP와 RDP 각 RTX 5090 1장, π0.5 GH200 2-4장, FTP-1 GH200 2장(Table B1).

판정

항목	판정	이유
공식 시뮬 채점(force-bench) 실행	**불가**	CUDA GPU와 Linux가 필요. 이 맥에는 둘 다 없음
정책 평가(Table III) 재현	**불가**	실물 장비, GPU 학습, 시연 데이터, 그리고 평가·학습 코드가 공개되지 않음(D8)
실물 과제 재현	**불가**	하드웨어 7종 이상, 3D 프린트 자산, 사람 시연
시뮬 모델 읽기·사양 확인	가능	문서와 과제 모듈은 읽기만 하면 됨(이 분석에서 수행)
`force-bench list` 실행	조건부 가능	docs는 "GPU 불필요, 순수 파이썬"이라고 씀. 설치 승인 후 CPU에서 실행해 행 수 확인 가능(미실행)
아이디어 수준 재구현(DP 소형 학습)	조건부	DP 공개 구현(MIT, 2024)은 MPS에서 돌 수 있음. 그러나 학습 데이터가 필요하고, 데이터는 시뮬(GPU 필요)이나 실물(없음)에서만 나옴

노력 추정(추정이며 검증하지 않음): 시뮬 채점 재현은 Linux GPU 장비에서 한 주 정도(설치와 Warp 컴파일 포함). 정책 평가 재현은 시연 수집과 학습을 포함해 수 개월과 GPU 여러 장이 필요합니다. 실물 재현은 하드웨어 조달과 자산 인쇄까지 포함하면 더 깁니다.

결론(한 줄): 이 맥에서 ContactBench 1.0을 재현하는 것은 **불가능**합니다. 할 수 있는 것은 표 재계산, 통계 점검, toy, 과제 사양 읽기입니다. 정책 수준의 주장을 검증하려면 Linux GPU 장비와 실물, 그리고 저자의 평가 코드(D8)가 필요합니다.

5. 권리와 라이선스

대상	근거	판단
논문 PDF와 그림	arXiv 초록 페이지의 라이선스 링크: `nonexclusive-distrib/1.0`. PDF 본문 전체(pdftotext)에서 "©", "copyright", "license" 문구를 찾지 못함	**CC BY 아님.** 그림·표 이미지는 개인용 리포트와 PPT에만 넣음. 게시본에는 넣지 않음
프로젝트 페이지	HTML에 라이선스 문구 없음. 숨은 HTML 주석 안의 `[TODO]` 표시는 화면에 보이지 않음	라이선스 판단 근거 없음. 페이지 내용 인용은 짧게
수치(Table III)	사실 자료. 재계산은 저작권 보호 대상이 아님	게시본에 재계산값과 출처를 씀

대상	근거	판단
시뮬 코드와 자산	MIT(LICENSE). THIRD_PARTY_NOTICES: HydroShear 보정 MIT, GelSight GS Mini 외장 CAD 제외(GPL-3.0)	MIT 조건(저작권과 허가 문구 유지)을 지키면 사용 가능. 이 분석은 코드를 복사하지 않음
정책 구현	DP MIT(2024-12-24), openpi Apache-2.0, FTP-1 Apache-2.0, RDP는 GitHub 자동 판정 NOASSERTION(LICENSE 파일 미확인)	RDP는 라이선스를 확인하기 전까지 재배포하지 않음

저자 정보: 논문의 이메일 주소와 소속 연락처는 게시본과 요청문에 넣지 않았습니다. 소속은 대학 이름만 씁니다(인용에 필요한 경우).

6. 실행 안 한 것과 미확인 항목

- 시뮬레이터, 테스트, 예제를 실행하지 않았습니다. D11(결정성)과 힘 수치는 확인하지 못했습니다.
- 자산 STL과 키트의 `provenance.json`은 읽지 않았습니다.
- `packages/force-bench/tests`의 물리 계약 테스트를 읽지 않았습니다.
- 채택되어 있는 `repo/contactbench-sim` 커밋 이력 전체는 확인하지 않았습니다(얕은 클론). "2026-11-04 단일 커밋"으로 보이지만 확인하지 못했습니다.