Cross-Embodiment World Models: 분석 리포트

게시용 버전: 논문 그림·표는 CC BY-NC-SA 라이선스 때문에 뺐습니다. 원문 https://arxiv.org/abs/2511.01177 · arXiv:2511.01177v3 · IROS 2026 (채택, abs 페이지 기준) · Zihao He, Bo Ai 외 · 공식 코드 없음(2026-11-10 확인) · 분석일 2026-11-10 · 논문 그림은 개인 학습용(CC BY-NC-SA 4.0)

핵심 요약

1. **무엇을 하는가:** 손과 물체를 3차원 파티클로 보고, 행동을 말단 파티클 변위장으로 바꿉니다. 그래프 세계 모델(DPI-Net 계열)을 시뮬 로봇 손 6개의 무작위 상호작용과 사람 시연으로 학습하고, 샘플링 MPC로 제어합니다.
2. **시뮬 손 수 증가 효과는 있지만 통계와 대조군이 약합니다:** Fig. 2는 시각 판독으로만 보이고 수치 표와 검정이 없습니다. x = 5는 부분집합 하나뿐이고, Equal Data 점선이 여러 패널에서 공동학습보다 낮게 보입니다(`03` §4, `04` C1-C3).
3. **혼합 비율 "1:1 최적"은 그림과 맞지 않습니다:** 그림 5에서 가장 좋은 비율은 0.5이고 1.0이 가장 나쁩니다(`04` C9).
4. **실물 성공률 차이는 작은 표본에서 유의합니다:** 18/20 대 10/20(Fisher p = 0.014), 17/20 대 9/20(p = 0.019). Holm 보정 후에도 p < 0.05입니다. 글자별 검정은 유의하지 않습니다(`03` §2).
5. **실물 공동학습 모델은 미지 손이 아닙니다:** 공동학습에는 Ability Hand와 XHand의 시뮬 데이터가 들어 있습니다(Table I 캡션). "교차 손 제로샷"은 사람 전용 모델에만 해당합니다(`04` C13).
6. **구현 가능성:** 공식 재현은 불가합니다. 아이디어 재구현은 중간 난이도이고, 이 맥에서는 CPU toy까지만 가능합니다(`04` §4).

논문 분석: Scaling Cross-Embodiment World Models for Dexterous Manipulation

- 대상: arXiv:2511.01177 **v3** (arXiv 스탬프 2026-07-21). abs 페이지 댓글에 "Accepted to IROS 2026"이 있습니다. 본문 PDF에는 IROS 표기가 없습니다.
- 저자: Zihao He, Bo Ai (동등 기여), Tongzhou Mu, Yulin Liu, Weikang Wan, Jiawei Fu, Yilun Du, Henrik I. Christensen, Hao Su (대학 소속 UC San Diego, Shanghai Jiao Tong, Stanford, Harvard, 그리고 기업 소속 1곳)
- 프로젝트 페이지: https://alan-heoooh.github.io/dexwm.html (코드 링크는 `[your-repo]` 자리표시자 그대로입니다. 4절 참고)
- 권리: arXiv abs 페이지 라이선스는 **CC BY-NC-SA 4.0**입니다(CC BY 아님). PDF 1쪽에는 arXiv 스탬프만 있고 IEEE 같은 저작권 문구는 없습니다. 그래서 논문 그림은 개인용 리포트·PPT에만 넣고, 공개 산출물에는 넣지 않습니다.
- 원문: `paper/paper.pdf` (v3, 8쪽, 5.3 MB), `paper/paper.txt`. v1 비교용 PDF와 텍스트는 `.scratch/`에 있습니다 (gitignore).

0. 한눈에 보기

- **문제.** 손가락 수와 관절 공간이 다른 손(6축 Ability, 12축 XHand, 16·24축 시뮬 손)은 행동 공간이 달라서 데이터와 제어를 서로 옮기기 어렵습니다.
- **제안.** 손과 물체를 3차원 점(파티클) 집합으로 보고, 행동을 관절 명령이 아니라 **말단 파티클의 변위장** ΔX로 정의합니다. 한 그래프 월드 모델(DPI-Net 계열)을 시뮬 로봇 손의 무작위 상호작용과 사람 손의 실제 시연으로 함께 학습하고, 샘플링 MPC를 붙입니다. 배포할 때는 관절 명령을 순운동학(FK)으로 파티클 변위로 바꿉니다.
- **주장 세 가지.** (i) 학습에 넣는 시뮬 손이 많을수록 보지 않은 손에 대한 예측 오차가 줄어듭니다(Fig. 2). (ii) 실제 사람 데이터와 시뮬 데이터를 섞는 비율이 중요하고 적절히 섞으면 사람 데이터만 쓴 것보다 낫습니다(Fig. 5). (iii) 사람 데이터만으로 학습한 모델을 Ability Hand와 XHand에 MPC로 그대로 붙여 점토를 글자 모양으로 만들 수 있습니다(Table I).
- **실험 규모.** 시뮬 손 6개, 물체 두 과제(강체 밀기, 점토 성형), 실물은 점토 성형 한 과제, 손 2개, 글자 4개 × 5회 = 손당 20회입니다.

1. Abstract와 서론 요약

- Abstract(v3)는 v1과 같은 흐름입니다. "상호작용을 공유 기하 공간에서 모델링할 수 있다"는 가설과 세 가지 발견을 말합니다. v3 Abstract는 "same learned model enables effective control on robotic hands with distinct kinematics and degrees of freedom"으로 표현을 조금 바꿨습니다.
- 서론은 PointWorld [18]과 Particle-based 선행연구(Hong et al. [14], 사람-물체 상호작용에서 파티클 모델을 학습했지만 정책 탐색에만 씀)를 가까운 대안으로 둡니다. v3는 PointWorld와의 차이를 더 자세히 씁니다(II-B, III-A 뒤 설명).
- 주장의 범위는 "교차 손(cross-hand) 일반화"입니다. 교차 **작업**(task) 일반화나 물체 다양성은 평가하지 않습니다. 두 과제 모두 물체는 하나의 상자 또는 하나의 점토 덩어리입니다.

2. 방법 (III절)

2.1 상태·행동 표현 (III-A)

- 손 e의 말단은 N_e개의 파티클 X_t^(e) = {x_i,t} ⊂ R^3, 물체는 N_o개의 파티클 X_t^(o)입니다(III-A, 식 없음 문장).

- 행동은 **파티클 변위장** a_t^P = ΔX_t^(e) = X_{t+1}^(e) − X_t^(e) ∈ (R³)^{N_e}입니다. 로봇에서는 q_t, u_t로 계산한 FK로 X_t^(e) = Φ_e(q_t), X_{t+1}^(e) = Φ_e(q_t + u_t)를 얻습니다.
- 학습 목표는 식 (2) 최소제곱 형태입니다: θ* = argmin E[L(f_θ(X_t, a_t^P), X_{t+1})]. 식 (3)은 손실 ℓ(O_t, Ô_t)로, 시뮬(시간 대응이 있을 때)은 MSE, 실제 사람 데이터(대응이 없을 때)는 CD 또는 EMD를 씁니다.
- **핵심 가정(명시):** "배포 때 손의 FK만 알면 된다." 하지만 모델 입력인 손 파티클을 손 메시에서 어떻게 샘플링하는지(표면 샘플인지, 링크당 고정 점인지, 손마다 입자 수를 어떻게 맞추는지)는 본문에 없습니다. 9절 질문 Q1.

2.2 인식 (III-B)

- 여러 대 카메라. 사람 손은 POEM-v2로 메시를 복원한 뒤 FPS로 파티클을 뽑고, 물체는 다중 시점 점군을 합친 뒤 Poisson 재구성 후 FPS입니다. 강체 물체는 FoundationPose로 자세를 추정해 표면 점을 FPS로 뽑습니다(III-B).
- 배포에서 로봇 상태는 고유수용감각으로 얻고 물체만 인식합니다.

2.3 세계 모델 (III-C)

- DPI-Net [24]: 반경 그래프(radius graph)의 메시지 전달, 계층적 전역 전파. 파티클 속성 co = 그룹 정보(손/물체), 엣지 속성 d_k(길이).
- 메시지 전달 식(논문 III-C): ε_k^l = f_E(ce_k, h^{l−1}_u, h^{l−1}*v), h_i^l = f_O(co_i, Σ*{k∈N_i} ε_k^l, h^{l−1}*i), 출력 ô*{i,t+1} = f_O^dec(h_i^L).
- 대칭성: 상대 좌표와 공유 갱신 함수로 전역 평행이동·회전·파티클 순열에 불변입니다. 이 편향이 "교차 손 전이"의 근거라고 저자는 설명합니다.
- 구조 세부(층 수 L, 은닉 차원, 엣지 특징 차원, 학습률, 배치, 학습 스텝)는 본문에 없습니다. 재구현하려면 이 값이 필요합니다.
- 비교: Point Transformer [58] 어텐션 모형을 같은 입출력과 손실로 학습한 기준선(IV-A).

2.4 계획 (III-D)

- 목표를 점군 G로 주고 비용 J(X, G) = L_CD(X, G) + L_EMD(X, G)(두 항 같은 가중치). 식 (1)은 u**{0:H−1} = argmin J(T(s_0, u*{0:H−1}), s_g)입니다.
- 샘플링 기반 MPC. 행동 샘플은 손별 **모션 프리미티브**에서 뽑습니다. 점토: FingersPinch, PalmPress, ThumbPinch 세 가지. 밀기: 엔드이펙터 좌표에서 직선 궤적에 가우시안 잡음을 더하고, 접촉 손가락 수를 무작위로 고릅니다(III-D).
- 실행 설정(IV-A, Model implementation): 매 MPC 반복에서 후보 행동 열 500개, 계획 길이 H = 4, 최적화 반복 10회, 앞 2단계만 실행 후 재계획. RTX 4090에서 한 번의 계획 갱신에 약 60초.
- v1은 "cross-entropy method"라고 썼지만, v3는 "sampling-based"로만 씁니다. 알고리즘 세부(엘리트 수, 분산 갱신)는 둘 다 없습니다. 재계획 횟수와 한 번 시험 시간도 없습니다.

3. 실험 (IV절)

3.1 설정

- **시뮬 손 6개:** Ability(6축), Allegro(16), XHand(12), LEAP(16), Shadow(24), Shadow w/o forearm(24). 밀기는 SAPIEN, 점토는 Rewarped(미분 가능 다물리 시뮬).
- 데이터: 과제·손마다 무작위 행동 100 궤적(IV-A). 궤적 길이, 학습/평가 분할 비율, 시드 수는 없습니다.
- **과제:** 강체 밀기(상자의 방향 맞추기, 물체 100 파티클, 손 50 파티클, 반경 0.04 m), 점토 성형(물체 300 파티클, 손 200 파티클, 반경 0.025 m 안쪽·0.04 m 바깥, 목표는 점군).
- **실물:** UFACTORY XArm 7, Ability Hand와 XHand, RealSense 4대, RTX 4090. 사람 시연은 세 프리미티브 각각 30분.

3.2 Q1: 시뮬에서 손 수 증가 (Fig. 2)

- 방법: 목표 손 하나를 빼고, 나머지 5개 손의 부분집합 C(5, x)로 학습합니다(x = 1-5). 평가는 빠진 손의 MSE입니다. x = 6*은 목표 손을 포함한 전체 학습입니다.
- 결과(시각 판독, 수치 표 없음): 많은 패널에서 x가 커질수록 MSE가 내려갑니다. 특히 Shadow, LEAP, Allegro 쪽이 뚜렷합니다. 짧은 손(Ability)은 x=1-4에서 이미 평탄합니다. PT 기준선은 기울기가 약하고 들쭉날쭉합니다(논문도 같은 설명, IV-B).
- 주장: "x = 5(목표 데이터 없음)에서 목표 전용 학습과 비슷하거나 더 낫다"(zero-shot strength). 그림에서는 일부 패널(Ability의 두 과제, 밀기의 XHand 등)에서 x = 5 점이 목표 전용 점선보다 확실히 높고, Shadow 계열 밀기처럼 낮은 패널도 있습니다. 판독은 근사이며 03 §4에 정리했습니다.
- 점선 두 개: "Ours (Target Only)"는 목표 손 데이터 100 궤적, "Ours (Target Only, Equal Data)"는 source 손 5개의 합과 같은 샘플 수(500 궤적)입니다. v1에는 PT와 Equal Data 선이 없었고 v3에 추가되었습니다.

3.3 Q2: 시뮬과 사람 데이터 혼합 (Fig. 5)

- 평가: 실제 사람 데이터 보류분(held-out)에서 CD+EMD 오차. 실제 로봇 데이터에는 시간 대응이 없어서 MSE 대신 CD/EMD를 씁니다.
- 본문 주장: "1:1 비율이 과제 전반에서 가장 좋다"(IV-C), "시뮬만 쓰면 가장 나쁘다".
- 그림 5 막대(시각 판독): 밀기는 0 → 0.2 → 0.5 → 0.8 → 1.0이 약 2.85, 2.9, 2.65, 3.2, 5.0($\times 10^{-2}$), 점토는 약 0.71, 0.66, 0.57, 0.72, 1.20($\times 10^{-2}$)입니다. **가장 좋은 비율은 0.5이고, 1.0이 가장 나쁩니다.** 본문의 "1:1이 가장 좋다"와 맞지 않습니다. 범례의 "1:1"은 CD와 EMD의 가중치 1:1(캡션)을 뜻하고, 데이터 비율은 "0-1.0"입니다. 캡션과 본문이 "1:1"을 두 가지 뜻으로 씁니다. 또한 "시뮬만 쓰면 가장 나쁘다"를 보여 주는 막대가 그림에 없습니다. 03 §4에서 다시 씁니다.

3.4 Q3: 실물 제어 (Table I)

- 과제: 점토를 글자 X, R, T, A로 성형. 각 글자 5회, 손 2개, 두 방법(사람만 학습 vs 공동학습) → 총 80회 시도(손·방법당 20회).
- 성공 기준: CD + EMD < 0.0125(IV-D). 이 기준은 MPC 비용과 같은 양의 최종 상태에 대해 씁니다.
- 결과(Table I, 합계 행):
  - Ability: 공동학습 18/20, 사람만 10/20. CD 6.95 ± 0.10 대 7.15 ± 0.16, EMD 4.92 ± 0.13 대 5.23 ± 0.23 ($\times 10^{-3}$).
  - XHand: 공동학습 17/20, 사람만 9/20. CD 6.85 ± 0.12 대 7.22 ± 0.18, EMD 4.78 ± 0.14 대 5.18 ± 0.21.
- 검정 결과는 03 §2에 있습니다.

4. 한계 (논문 표시와 우리 판단)

논문이 직접 쓴 한계는 없습니다. v3에는 Limitations 절이 없고, 결론에서 한 줄("future direction")만 있습니다. 본문에서 저자가 스스로 제기한 점은 다음과 같습니다.

- 손의 그래프 밀도(반경 그래프 연결 수)에 따라 교차 손 이득이 달라집니다. 작은 손은 빨리 좋아지고 큰 손은 다양한 손이 더 필요합니다(IV-B "Embodiment-specific trends"). 저자는 "그래프 밀도에 덜 민감한 구조"를 미래 과제로 봅니다.
- 점토 과제에서 효과가 더 크고 밀기에서는 작습니다(IV-B "Task-specific differences").

우리가 본 한계:

- 실물 평가는 손 2개, 글자 4개, 시도 5회입니다. 평가 대상은 "사람 시연으로 학습한 모델이 로봇에 붙는가"이지 교차 손 확장 효과 자체는 아닙니다.
- 실물 비교는 학습 데이터 조합만 다르고 평가 손과 과제는 같습니다(정상적인 대조). 하지만 교차 손의 로봇 데이터가 **없으므로** 실물에서 "교차 손 일반화"를 직접 본 것은 아닙니다. 실물에서 본 것은 사람 데이터로 학습한 모델이 로봇에 붙는다는 점

입니다.

- 물체는 점토 하나와 상자 하나입니다. 다른 물체나 다른 기하 구조는 평가하지 않았습니다.

5. v1 → v3 차이

v1(2025-11-03)과 v3(2026-07-21)의 본문(둘 다 8쪽)을 텍스트로 대조했습니다(`.scratch/paper_v1.txt`, `paper/paper.txt`). 숫자는 PDF 표·캡션과 본문에서 확인했습니다.

항목	v1	v3	의미
상태·학회	학회 표기 없음	abs 댓글 "Accepted to IROS 2026"	채택 확인은 abs 페이지 기준, 본문에는 없음
저자 소속	대학 4곳과 기업 소속 1곳	대학 4곳과 기업 소속 1곳(기업 이름과 소속 인원 변경)	소속 목록 변경(이름은 공개본에서 뺌)
계획 알고리즘	cross-entropy method(MPC)	sampling-based MPC, 후보 500 · H=4 · 반복 10 · 실행 2 · 60 s	v3에서 수치가 생김
파티클 수·반경	없음	점토 300/200 (r 0.025/0.04), 밀기 100/50 (r 0.04)	v3에서 생김
비용 함수	CD 또는 EMD	J = L_CD + L_EMD(같은 가중치)	v3가 더 구체적
기준선	없음(목표 전용만)	PT [58] 기준선, Equal Data 점선	Fig. 2 캡션 변경
실물 결과	손당 CD/EMD 합계만	글자별 CD/EMD와 성공 횟수(18/20 대 10/20 등)	실물 성공률은 v3에서 처음 나옴
Table I 합계 CI	공동학습: Ability 6.95±0.10, 4.92±0.13; XHand 6.85±0.13, 4.78±0.15 / 사람만: Ability 7.15±0.12, 5.23±0.17; XHand 7.22±0.19, 5.18±0.22	공동학습: 6.95±0.10, 4.92±0.13; 6.85±0.12, 4.78±0.14 / 사람만: 7.15±0.16, 5.23±0.23; 7.22±0.18, 5.18±0.21	평균은 그대로이고 CI 일부가 바뀜. 이유는 적혀 있지 않음
실물 결과 문장	"We will further verify the benefits … through system deployment"	배포 결과(Table I, Fig. 4)	v1의 약속을 v3가 채움
사람 데이터 평가 caveat	"these evaluations are on human data only … approximations of the target domain"	해당 문장 없음	v3에서 caveat 삭제
참고문헌	2025년 이전 중심	π0.7(2026), EgoVerse(2026) 등 추가	인용 갱신
시간 대응	Fig. 5 설명에 CD/EMD 사용 이유	같음, 표현만 조금 다름	변화 없음

v1 → v3에서 **주장은 같고 근거가 늘었습니다.** 실물 성공률과 계획 설정이 추가되었고, 기준선 PT와 Equal Data가 추가되었습니다. 그러나 Fig. 5의 "1:1 최적" 문장은 두 판본 모두 그대로입니다(3.3절).

6. 읽으면서 생긴 질문 (가정·빠진 정보)

- Q1. **손 파티클 샘플링:** 손마다 입자 수와 배치를 어떻게 정하나요? 링크 길이에 따라 입자 수가 달라지는지, 같은 "관절 인덱스"가 서로 다른 손에서 같은 의미를 갖는지(대응) 설명이 없습니다. 손 사이의 파티클 대응이 없으면 식 (2)의 MSE(시간 대응)를 교차 손에 쓸 수 없습니다.
- Q2. **"미지의 손"의 뜻:** 보류 손의 운동학을 처음 보는지, 같은 운동학의 다른 인스턴스인지 문장으로 구분하지 않습니다. 실제로는 6개 손 모두 다른 운동학이므로 운동학 보류입니다. 실물에서는 로봇 데이터가 전혀 없으므로 "미지의 손"이 더 강합니다(사람 데이터만).

- Q3. **평가 분할:** 시뮬 MSE가 학습에 쓰지 않은 궤적에서 나온 것인지, x = 6*(목표 포함)일 때 평가 데이터가 학습과 겹치는지 분명하지 않습니다.
- Q4. **시드와 반복:** 시뮬 점의 오차 막대가 부분집합 분산인지 학습 시드 분산인지 모릅니다(03 §4에서 x = 5가 부분집합 1개뿐인 문제를 씁니다).
- Q5. **실물 시도:** 한 시도의 재계획 횟수, 시간 제한, 실패 판정, 시도 순서(무작위화 여부), 같은 목표를 두 방법에 같은 순서로 줬는지 모릅니다.
- Q6. **모델 구조 값:** DPI-Net의 L, 은닉 차원, 엣지 특징, 학습률, 옵티마이저, 배치, 스텝 수, PT 설정이 없습니다. 재구현에 필요합니다.
- Q7. **성공 기준:** 점토 성공 기준(0.0125)이 왜 이 값인지, 밀기 과제의 성공 기준은 무엇인지 없습니다. 시뮬 밀기는 MSE만 있고 최종 자세 오차나 성공률이 없습니다.

재계산·유의성·유도와 장난감 검증

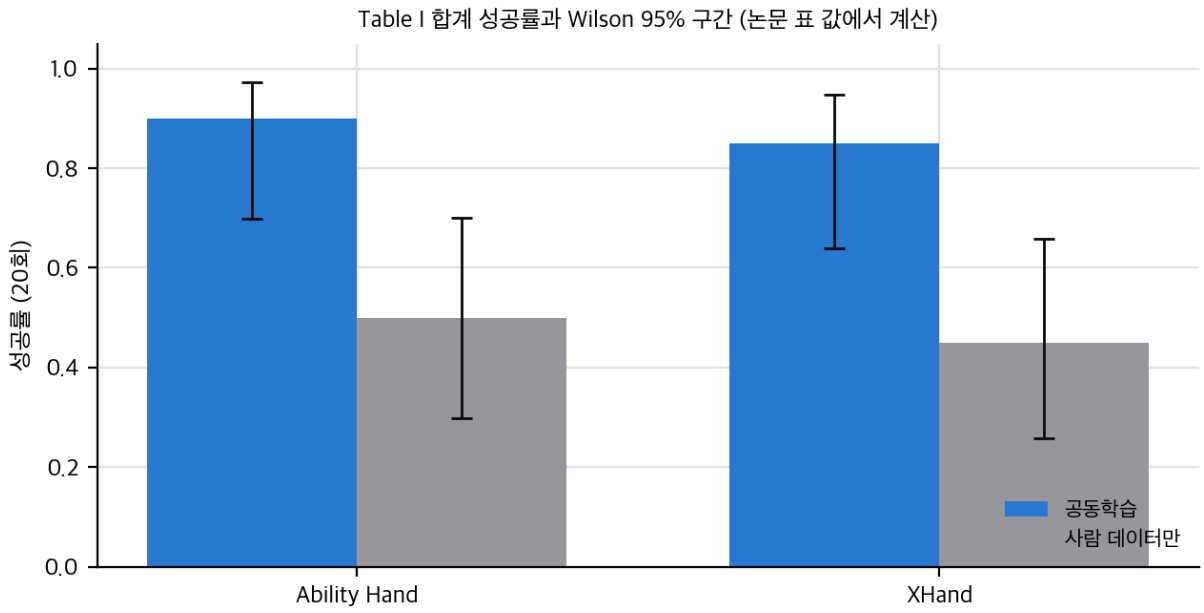
대상: arXiv:2511.01177 v3. 재계산 스크립트: `analysis/table_check.py` (→ `table_check_results.json`), `analysis/particle_toy.py` (→ `particle_toy_results.json`, 약 2분 30초, numpy 1스레드). 그림: `analysis/plot_figures.py`.

논문에는 Table I(실물)만 숫자 표로 있습니다. Fig. 2와 Fig. 5는 그림이고 원자료가 없어서, 그림에서 읽은 값은 **근사치**로만 씁니다.

1. 재계산 개요

대상	입력	한 일
Table I 성공 횟수	글자별 5회, 손·방법별 20회	Wilson 95%, Fisher 정확검정, Cochran-Mantel-Haenszel(글자 층)
Table I CD/EMD	합계 평균±95% CI(n = 20), 글자별 n = 5	CI에서 표준편차 역산, Welch t, Holm 보정
표본 크기	성공률 0.9 대 0.5, 0.85 대 0.5	두 비율 검정력 공식과 정규근사 검정력
Fig. 2 학습 실행 수	나머지 5손에서 부분집합 C(5, x)	개수 계산 (x = 1-5: 5, 10, 10, 5, 1)
장난감 실험 A, B	2차원 시뮬레이션	2절의 설계

2. Table I 유의성 (Plasticine Reshaping, 실물)



직접 계산: Table I 합계 성공률과 Wilson 95% 구간(논문 표 값에서 계산).

2.1 Table I 재계산

성공 횟수 (손별 합계 20회)

손	공동학습	사람만	Wilson 95% (공동 / 사람)	Fisher p	CMH OR (95% RBG)	CMH p	Holm (4개 검정)
Ability	18/20	10/20	0.70-0.97 / 0.30-0.70	0.0138	14.3 (1.06-194)	0.0053	0.028 (Fisher), 0.021 (CMH)
XHand	17/20	9/20	0.64-0.95 / 0.26-0.66	0.0187	11.0 (1.09-111)	0.0066	0.028, 0.021

- 4개 검정의 Holm 보정(Ability·XHand의 Fisher·CMH)은 모두 $p < 0.05$입니다.
- **글자별 Fisher는 전부 유의하지 않습니다.** 최소 $p = 0.17$(XHand 글자 R, 5/5 대 2/5). 글자당 5회라 검정력이 없습니다. 글자별 성공 횟수는 `table_check_results.json`에 있습니다.
- 차이의 크기: 위험 차이 0.40 (두 손 모두). 검정력 공식으로 20 대 20에서 0.9 대 0.5를 80% 검정력으로 찾으려면 손·방법당 20회가 필요합니다. 정규근사 검정력은 0.9 대 0.5에서 0.81, 0.85 대 0.5에서 0.67입니다. 즉 이 실험은 큰 차이만 잡습니다.

CD/EMD (합계 n = 20, Welch, 보정 전 p; 보정은 4개 검정)

손	지표	차이 (공동 − 사람, $\times 10^{-3}$)	t	p	Holm
Ability	CD	−0.20	−2.22	0.034	0.040
Ability	EMD	−0.31	−2.46	0.020	0.040
XHand	CD	−0.37	−3.58	0.0011	0.0043
XHand	EMD	−0.40	−3.32	0.0022	0.0066

- CI를 표준편차로 바꾸는 식은 `t(0.975, 19) · s/√20` 입니다. 논문이 CI를 어떻게 정의했는지(시도 단위인지 글자 단위인지)는 적혀 있지 않습니다. 이 가정이 틀리면 p 값이 달라집니다.
- 평균 합계는 글자 평균과 소수 둘째 자리까지 일치합니다(공동학습 CD 6.95, 사람 7.15 등).
- 시도 쌍 구조(같은 목표와 같은 순서를 쓰는지), 시도 간 독립성은 확인할 수 없습니다. 무작위 순서가 아니라면 결과가 과대평가될 수 있습니다.

3. 유도

(a) 계획 계산량. 한 번의 계획 갱신 = 후보 500 × 반복 10 × 계획 길이 H = 4 = 20,000 단계 예측. RTX 4090에서 60초이면 단계당 약 3 ms입니다. 재계획 횟수가 없어서 시도당 시간은 계산할 수 없습니다.

(b) 파티클 집계의 밀도 의존성. 물체 입자 i에 대해 접촉 가중 합 $S_i = \Sigma_j w_{ij} \delta_j$, 가중 평균 $M_i = S_i / \Sigma_j w_{ij}$입니다. 입자 간격이 $1/\sqrt{\rho}$ 배로 줄어 접촉 이웃 수가 ρ에 비례하면 $E[\Sigma_j w_{ij}] \propto \rho$이므로, S_i의 기대 크기는 ρ에 비례하고 M_i는 ρ에 무관합니다. 참 세계가 평균형이면 합 집계 모형은 학습한 게인 κ가 밀도에 묶입니다. 이 점은 논문의 그래프 밀도 가설(IV-B)과 연결되지만, 실제 DPI-Net은 학습된 MLP라 이 단순 계산이 그대로 적용되지는 않습니다.

(c) 학습 조건과 샘플 수. 목표 손 하나를 뺄 때 나머지는 5개입니다. x개를 고르는 부분집합은 C(5, x) = 5, 10, 10, 5, 1개입니다(합 31). x = 5는 부분집합이 하나뿐이므로 그 점의 오차 막대는 부분집합 분산이 아니라 **학습 시드 분산**이어야 합니다. 논문에 시드 수는 없습니다. 목표 손 하나당 학습 조건은 31 + 목표 전용 + Equal Data = 33개, 두 과제·두 방법(Ours, PT)을 합치면 약 264회 학습입니다(시드 제외).

(d) 데이터량 대조. 손당 100 궤적이라 x = 5의 총량은 500 궤적, 목표 전용 기준은 100, Equal Data 기준은 500입니다. 따라서 "x = 5 대 목표 전용(100)"은 데이터량이 다른 비교입니다. 데이터량을 맞춘 비교는 Equal Data 점선뿐입니다(4절).

4. Fig. 2와 Fig. 5 (그림에서 읽은 근사치)

Fig. 2 (로그 축, 시각 판독). 평평하다고 읽은 패널을 제외하고, 다음이 보입니다.

- 플라스틱 패널(b)에서 노란 "Equal Data" 점선은 여러 패널(Ability, LEAP, Shadow 계열 등)에서 x = 5와 x = 6*의 "Ours" 점보다 낮은 위치에 있습니다(약 10^{-6} 근처 대 x = 5의 10^{-6}–10^{-5}, 판독 근사). 즉 **같은 샘플 수의 목표 전용 학습이 교차 손 학습보다 낫게 보이는 패널이 많습니다.** 본문은 이 대조군을 설명하지 않습니다.

- 밀기 패널(a)에서는 Shadow와 Shadow w/o forearm의 x = 6* 점이 Equal Data보다 낮고, Ability는 반대입니다. 대조는 패널마다 다릅니다.
- 목표 전용 점선(red dashed)과 비교한 x = 5 점: 밀기는 Shadow 두 손에서만 낮고(약 0.9 대 2.5, 1.3 대 2.0 $\times 10^{-3}$), Ability·Allegro·LEAP·XHand에서는 높거나 비슷합니다. 점토는 Allegro, LEAP, Shadow, Shadow w/o forearm에서 x = 5가 낮고 Ability에서는 높습니다. 판독 오차는 로그 축에서 대략 ±30%입니다.
- 과제 간 비교("점토가 밀기보다 낮다")는 단위·파티클 수·목표 정의가 달라서 정량 비교가 되지 않습니다.

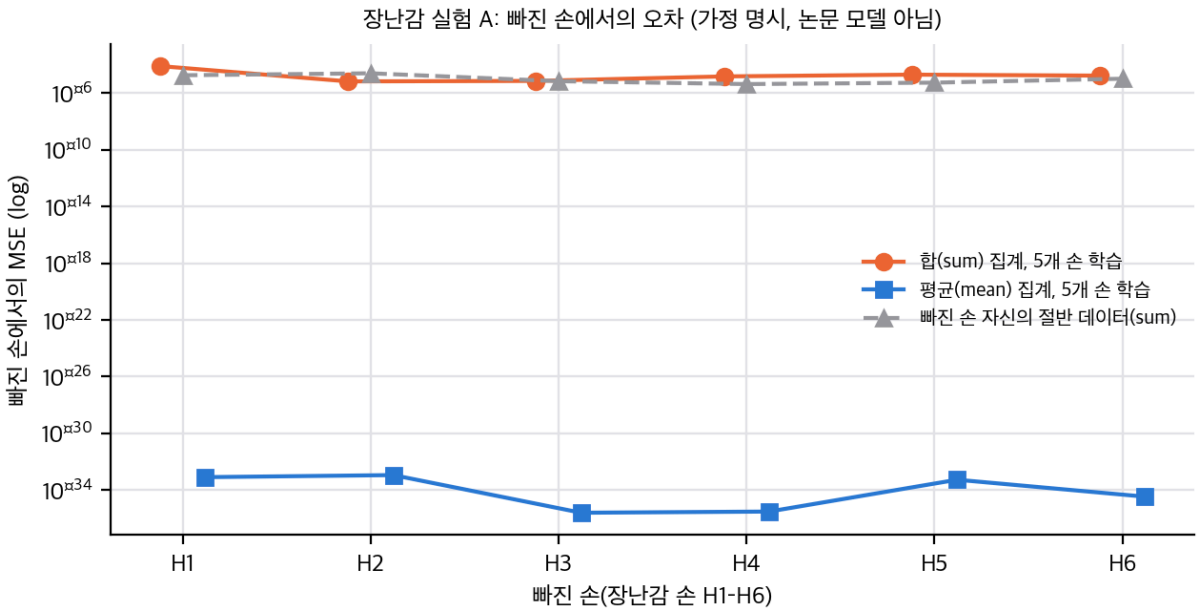
Fig. 5 (막대, $\times 10^{-2}$, 근사).

비율(범례)	0 (사람만)	0.2	0.5	0.8	1.0
밀기	≈2.85	≈2.9	≈2.65	≈3.2	≈5.0
점토	≈0.71	≈0.66	≈0.57	≈0.72	≈1.20

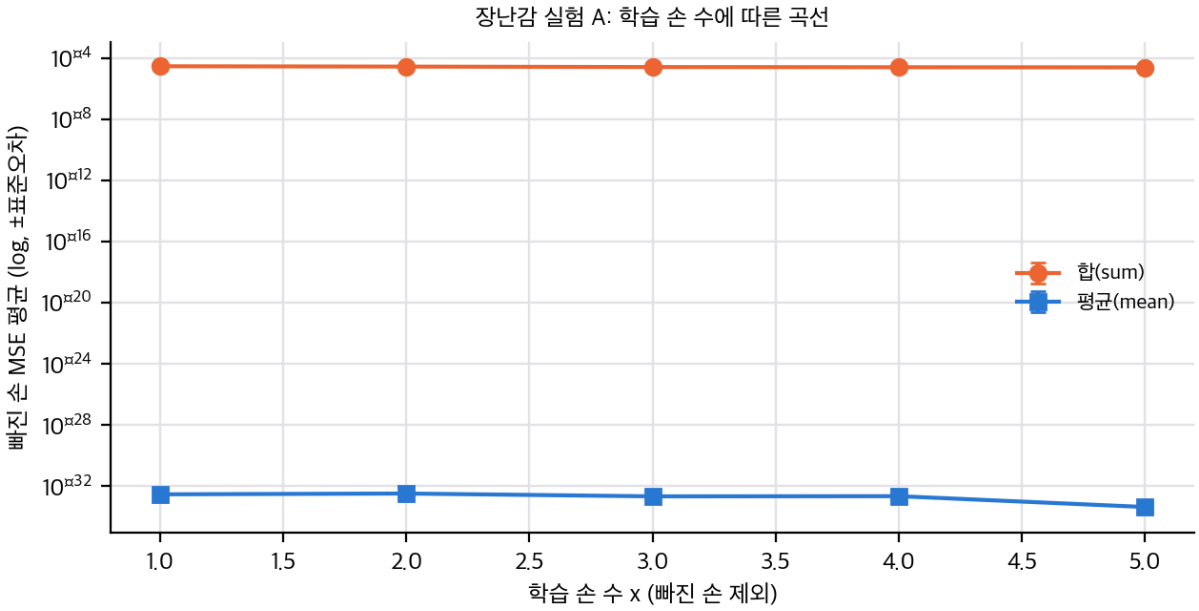
- 최적은 0.5 (두 과제 모두)입니다. 1.0이 가장 나쁩니다. **본문 "1:1 비율이 최적"과 맞지 않습니다.** 캡션의 "CD+EMD (1:1)"은 손실 가중치를 뜻하고, 데이터 비율과는 다른 말입니다.
- 본문의 "시뮬만 쓰면 가장 나쁘다"는 막대 목록에 없습니다. 범례 0이 사람 전용이라면 시뮬 전용 막대가 빠진 것입니다.
- 0 대 0.2 대 0.5 사이의 차이는 오차 막대 안에 있어 유의하지 않아 보입니다. 1.0 대 나머지의 차이는 큽니다.

5. 장난감 검증 (논문 모델이 아님)

장난감 세계: 2차원 평면, 2관절 팔 여섯 개(링크 길이와 입자 간격이 다름, 손 입자 수 9-19), 물체는 입자 30개. 참 세계의 물체 변위는 접촉 가중 평균 손 변위에 게이트를 곱한 평균형입니다(차수 불변). 이 설정 자체가 "평균 집계 모형이 맞다"를 보장하므로, 실험 A의 mean 결과는 **구조가 같아서 생긴 결과이지 교차 손 일반화의 증거가 아닙니다.** 이 점을 먼저 밝힙니다.



직접 계산(장난감): 빠진 손 MSE, 집계 방식(sum 대 mean) 비교. 논문 모델이 아님.

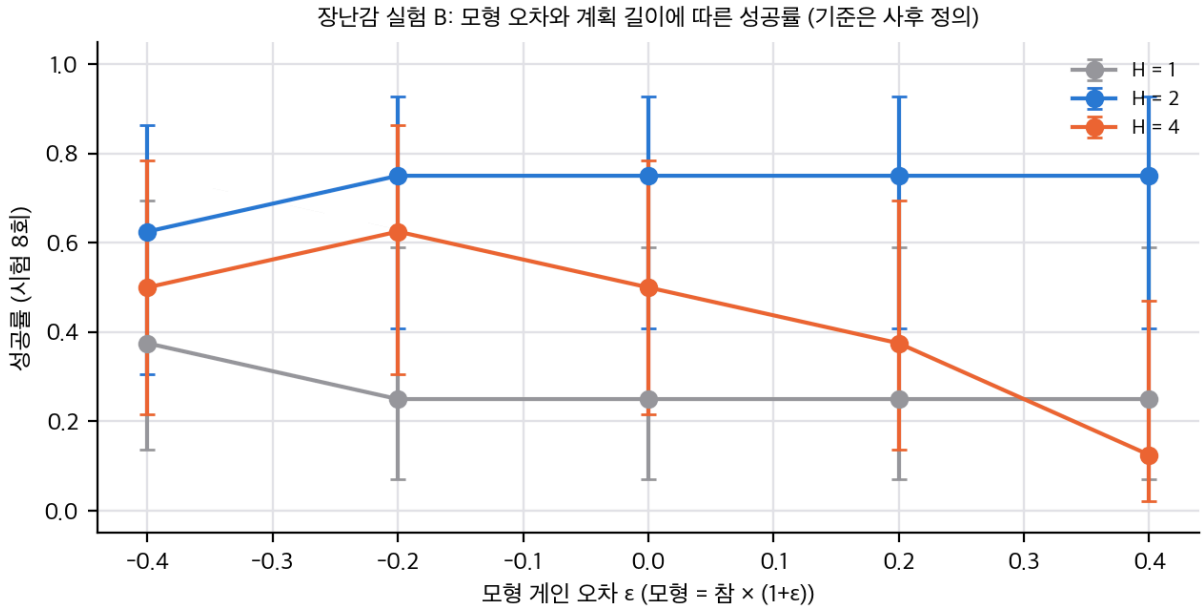


직접 계산(장난감): 학습 손 수 x에 따른 평균 MSE.

실험 A: 빠진 손 검증 (leave-one-hand-out, 손당 40 에피소드).

빠진 손	입자 수	입자 간격	반경 내 평균 이웃	합(sum) 5손 학습 MSE	평균(mean) 5손 학습 MSE	빠진 손 자체 학습 MSE (sum)
H1 짧은·촘촘	19	0.015	1.57	8.0×10^{-5}	8.2×10^{-34}	1.8×10^{-5}
H2 짧은·보통	11	0.025	0.36	6.7×10^{-6}	1.1×10^{-33}	2.5×10^{-5}
H3 중간·보통	13	0.030	0.41	7.2×10^{-6}	2.5×10^{-36}	6.9×10^{-6}
H4 중간·성김	9	0.045	1.38	1.5×10^{-5}	3.1×10^{-36}	4.3×10^{-6}
H5 긴·성김	11	0.050	0.96	2.0×10^{-5}	5.4×10^{-34}	5.5×10^{-6}
H6 긴·보통	15	0.035	0.61	1.7×10^{-5}	3.5×10^{-35}	1.0×10^{-5}

- 합 집계의 학습 게인 κ는 0.88-1.09로 손에 따라 다릅니다. 평균 집계는 게인 0.8로 정확히 맞춥니다(구조 일치).
- 합 집계의 pooled 오차가 빠진 손 자체 데이터(절반)로 학습한 손별 모형보다 큰 손은 H1, H4, H5, H6 네 개이고, H2는 반대(작음), H3는 비슷합니다. 절대값은 작고 손 6개라는 표본으로는 해석이 어렵습니다.
- Wilcoxon 부호 검정(손별 pooled sum 대 mean, 6쌍) p = 0.031. 6쌍 검정이라 크기 효과만 참고합니다.
- 학습 손 수 x별 평균(합 집계): x = 1: 2.9×10^{-5}, x = 2: 2.7×10^{-5}, x = 3: 2.6×10^{-5}, x = 4: 2.5×10^{-5}, x = 5: 2.4×10^{-5}. 부분집합은 최대 8개로 제한했습니다. 감소는 작고, 평균 집계의 곡선은 0 근처라 의미가 없습니다.



직접 계산(장난감): 모형 게인 오차와 계획 길이에 따른 성공률.

실험 B: 모형 오차와 계획 길이 (MPC, 시험 8회). 계획은 후보 500, 반복 10, 엘리트 50, 재계획 6회, 앞 2단계 실행, 모형 게인 = 참 게인 × (1+ε), 참 게인 0.8. 성공 기준은 **사후에 정했습니다**: 참 세계 ε = 0, H = 4의 최종 Chamfer 중앙값(0.0402)입니다. 기준 자체가 결과에 의존하므로 절대 성공률은 의미가 없습니다.

H	ε = −0.4	−0.2	0	+0.2	+0.4
1	3/8	2/8	2/8	2/8	2/8
2	5/8	6/8	6/8	6/8	6/8
4	4/8	5/8	4/8	3/8	1/8

- 8회 시험의 Wilson 구간은 대략 ±0.3입니다. ε에 따른 뚜렷한 경향은 없습니다. H = 4는 ε = 0.4에서 1/8로 떨어지는 경향이 있으나 노이즈와 구별되지 않습니다.
- H = 1이 H = 2보다 낮은 것은 짧은 계획이 밀기 자세를 못 잡는 것으로 해석할 수 있습니다. 시험 수가 적어 확정하지 못합니다.
- 결론: 이 장난감에서 **모형 게인 오차 ±40%는 성공률을 크게 바꾸지 않는 것으로 보이지만, 8회 시험으로는 결론을 내릴 수 없습니다.** 논문 규모(20회 이상, 여러 목표)가 필요합니다.

6. 한계

- 원자료가 없어 Fig. 2와 Fig. 5 값은 판독치입니다.
- Table I 검정은 가정(CI 정의, 시도 독립성, 시도 순서 무작위) 아래의 계산입니다.
- 장난감 실험 A의 mean 결과는 구조 일치 때문에 자명합니다. 합 집계 결과도 장난감 참 세계와 손 설정에 의존합니다.
- 장난감 실험 B는 시험 8회, 기준은 사후 정의이므로 확정 결론이 아닙니다.

추가 검증 (2026-11-11)

스크립트: `analysis/extra_density_sweep.py` → `analysis/extra_density_sweep_results.json` (numpy 단일 스레드, 1초 미만). `particle_toy.py`의 함수를 재사용한다.

추가 검증 1: 입자 밀도만 바꿨을 때 합 집계와 평균 집계의 교차 밀도 일반화

목적. §5의 실험 A는 손의 형상과 밀도가 함께 달라서 밀도 효과를 따로 보지 못했다. 팔 형상을 고정하고 입자 간격만 바꿔서, 밀도가 합 집계와 평균 집계의 일반화에 주는 영향을 분리한다. 참 세계가 평균형인지 합형인지에 따라 결론이 어떻게 뒤집히는지도 본다.

설정(가정).

- `particle_toy.py`의 2차원 2관절 팔(링크 0.14·0.12 m), 접촉 반경 0.05 m, 게이트 0.5, 물체 입자 30개를 그대로 쓴다.
- 입자 간격 $h \in \{0.010, 0.015, 0.025, 0.040, 0.060\}$ m. 입자 밀도가 6배 차이 난다. 팔 길이와 형상은 같다.
- 참 세계 두 가지: M(평균형, 기존 `true_step`), S(합형, $\kappa_s \Sigma_j w_{ij} \delta_j$). $\kappa_s = 1.166$으로, $h = 0.025$에서 두 집계 특징의 RMS 크기가 같도록 정했다.
- 예측기는 스칼라 κ 하나다(최소제곱). 집계는 합 또는 평균.
- 손마다 에피소드 20개, 길이 40 스텝. 지표는 상대 MSE $= \Sigma(\kappa f - t)^2 / \Sigma t^2$이다.

결과.

물체 입자당 접촉 이웃 수와 손당 입자 수는 다음과 같다.

간격 h (m)	0.010	0.015	0.025	0.040	0.060
손 입자 수	28	19	11	8	6
물체 입자당 접촉 이웃 수	3.10	2.07	1.71	0.47	0.14

참 세계가 평균형(M)인 경우:

- 합 집계 모형에서 손마다 맞춘 κ는 0.44($h = 0.010$), 0.58, 0.89, 1.18, 1.27($h = 0.060$)로, 약 2.9배 차이 난다.
- 학습 밀도와 시험 밀도의 상대 MSE 행렬에서 교차 밀도 중앙값은 같은 밀도 중앙값의 3.4배다. 가장 나쁜 쌍은 $h = 0.06$으로 학습하고 $h = 0.01$로 시험한 경우로 상대 MSE 2.94다(오차가 신호보다 크다).
- 전 밀도를 합쳐 학습한 합 집계 $\kappa = 0.62$는 밀도별 상대 MSE 0.16–0.36이다.
- 평균 집계 모형은 $\kappa = 0.80$으로 정확히 맞고 모든 밀도에서 0이다. 이 참 세계가 평균형으로 만들어졌으므로 구조가 같아서 생기는 결과다.

참 세계가 합형(S)인 경우:

- 합 집계 모형은 $\kappa = 1.166$으로 모든 밀도에서 0이다(구조 일치).
- 평균 집계 모형은 상대 MSE 0.04–0.21이고, 교차 밀도 중앙값 비는 2.1이다.

특징 크기의 밀도 기울기(로그-로그)는 합 집계 0.28, 평균 집계 0.08이다. 이론값은 합 1, 평균 0이다.

결론.

- 밀도가 바뀌면 합 집계의 최적 κ가 밀도를 따라 움직인다. 평균형 참 세계에서 약 3배다. §5의 "합 집계 모형의 κ가 밀도에 묶인다"는 정성 추론은 이 통제 실험에서 맞다.
- 같은 데이터에서 두 집계 방식은 반대 결론을 준다. 평균형 세계에서는 합이 틀리고, 합형 세계에서는 평균이 틀린다. toy로는 실제 세계가 어느 쪽인지 가릴 수 없다. 논문 모형의 집계 형태가 명시되어야 판단할 수 있다.
- 기울기가 이론값 1이 아니라 0.28이다. 접촉 반경(0.05 m)보다 간격이 큰 밀도에서는 많은 물체 입자가 이웃을 하나도 갖지 못해서, 이웃 수가 밀도에 비례하지 않는다. §3(b)의 "$E[\Sigma w] \propto \rho$"는 접촉 이웃이 충분할 때만 성립한다.

- **한계.** 2차원 팔 한 종류, 에피소드 20개, 참 세계 두 종류. 3차원 그래프 네트워크와 학습된 집계 함수는 포함하지 않았다. 논문 규모의 비교가 아니다.

추가 검증 2: 3차원 손 기하에서 입자 밀도와 집계 방식

목적. 추가 검증 1의 2차원 결과(밀도가 바뀌면 합 집계의 최적 κ가 밀도를 따라 움직인다)가 3차원 손 기하에서도 나타나는지 봅니다. 손 3종을 MuJoCo로 만들어 입자를 링크 축을 따라 배치했습니다. 결과는 `analysis/extra_particle_3d_results.json`에 있습니다.

설정. 스크립트는 `analysis/extra_particle_3d.py` 입니다.

- 손 3종(MJCF 문자열): 2관절 긴 팔(0.14·0.12 m), 3관절 팔(0.10·0.10·0.08 m), 2관절 짧은 팔(0.18·0.09 m). 힌지 축은 손마다 다릅니다. 관절 각은 에피소드마다 U(−1, 1) rad.
- 입자: 캡슐 축을 따라 간격 h ∈ {0.010, 0.025, 0.060} m. 입자 수는 링크 길이/h에 비례합니다(예: 0.01 m에서 손당 약 30-60개).
- 물체: 점 30개. 중심은 손 입자 근처 또는 작업 공간 무작위입니다.
- 참 세계(κ = 1, 가정): S는 $y = \Sigma_i \Sigma_j K$, M은 $y = \Sigma_i \text{mean}_j K$이며 $K = \max(0, 1 - |d|/0.05)$입니다.
- 학습기: 쌍 커널 $g_\theta((o_i - p_j)/0.05)$, 3 → 32 → 32 → 1, SiLU. 합 집계는 $\Sigma_i \Sigma_j g$, 평균 집계는 $\Sigma_i \text{mean}_j g$입니다.
- 학습: Adam 2e-3, 배치 64, 3000 스텝, 시드 0. 학습은 손 A, B, 시험은 손 C. 학습 자료는 밀도 3종을 섞은 것과 h = 0.025만 쓴 것 두 가지입니다. 시험 셀마다 에피소드 200개, 상대 MSE = $\Sigma(\hat{y} - y)^2/\Sigma y^2$.
- 장치: CPU, torch 2.15.0, MuJoCo 4.0.0, numpy 1.26.4, Python 3.12.7, 스레드 4. 전체 153 s.
- 첫 시도는 입력을 접촉 반경으로 나누지 않고 1500 스텝만 학습해서 맞는 집계에서도 오차가 0.3 안팎이었습니다. 커널 근사 오차가 밀도 효과를 가리므로, 입력 스케일을 맞추고 3000 스텝으로 바꾼 뒤 결과를 다시 얻었습니다. 아래는 다시 얻은 결과입니다.

결과. 시험 손 C의 상대 MSE, 시험 밀도 0.010 / 0.025 / 0.060 m 순서.

참 세계	학습 자료	학습기	상대 MSE
S (합형)	혼합 밀도	합 집계	0.039 / 0.042 / 0.048
S	혼합 밀도	평균 집계	0.228 / 0.048 / 1.377
S	h = 0.025	합 집계	0.032 / 0.033 / 0.037
S	h = 0.025	평균 집계	0.300 / 0.001 / 0.797
M (평균형)	혼합 밀도	합 집계	1.344 / 0.349 / 0.513
M	혼합 밀도	평균 집계	0.025 / 0.027 / 0.032
M	h = 0.025	합 집계	7.792 / 0.912 / 0.341
M	h = 0.025	평균 집계	0.030 / 0.032 / 0.036

결론.

- 집계가 참 세계와 맞으면 밀도가 바뀌어도 오차가 0.03-0.05 안에 머뭅니다. 맞지 않으면 밀도 이동에 따라 크게 틀립니다. 2차원 결과와 같은 방향입니다.
- 합 집계는 밀도가 높아질수록 이웃 수가 늘어 평균형 세계에서 과대 예측을 만듭니다(학습 밀도 0.025, 시험 0.010에서 상대 MSE 7.8). 평균 집계는 합형 세계에서 밀도 차이가 클 때 실패합니다(학습 0.025, 시험 0.060에서 0.80).
- 따라서 집계 형태를 모르면 밀도 일반화를 판단할 수 없습니다. 2차원의 "합 집계 κ가 밀도에 묶인다"는 정성 추론은 3차원 손 기하에서도 확인되었습니다.

한계.

- 쌍 커널을 학습하는 작은 MLP입니다. 그래프 신경망이나 학습된 집계 함수가 아닙니다. 따라서 3차원 그래프 네트워크 버전은 수행하지 않았습니다.
- 손 3종, 시드 1개, 셀당 에피소드 200개입니다. 참 세계 K는 설계한 거리 함수이며 로봇 접촉 모형이 아닙니다.
- 로봇 동역학과 정책 학습은 없습니다. 교차 손 학습이 실제 성공률을 바꾸는지는 이 실험으로 말할 수 없습니다.

주장 검증 (공식 코드 없음): C1-C16

대상: arXiv:2511.01177 v3. 공식 코드가 없어 **논문 ↔ 코드 대조(D항목)는 할 수 없었습니다.** 대신 논문의 표·그림·본문 수치를 다시 보고(표 재계산, 그림 판독), 주장별로 판정했습니다. 재계산 세부는 `03_analysis.md`, GitHub 확인은 `02_prior_work.md` §4에 있습니다.

판정 기호: **지지** (근거와 주장이 맞음), **부분** (일부 조건에서만 맞음), **모순** (근거가 주장과 반대), **비교 불가** (근거가 같은 척도가 아님), **확인 불가** (논문에 정보 없음).

1. 주장별 판정

ID	주장 (위치)	근거	판정	메모
C1	학습 손 수를 늘리면 보지 않은 손의 오차가 준다 (초록, IV-B, Fig. 2)	Fig. 2, 손 6개 × 두 과제	**부분**	많은 패널에서 하강 추세. 수치·표·통계 검정은 없음. 부분집합이 최대 5개, x=5는 1개뿐(03 §4)
C2	x = 5(목표 데이터 없음)에서 목표 전용 학습과 비슷하거나 더 낫다 (IV-B "Zero-shot strength")	Fig. 2 점선과 x=5 점	**부분**	밀기에서는 Shadow 두 손에서만 명확히 낮고 나머지는 높음. 점토는 대부분 낮음. 판독 근사. 프로젝트 페이지는 "surpass"로 더 세게 씀(02 §4)
C3	x = 6*(목표 포함)에서 공동학습이 목표 전용보다 낫다 (IV-B "Benefit of co-training")	Fig. 2	**확인 불가**	x = 6*는 목표 데이터를 학습에 넣은 설정이라 평가 대상이 학습 분포 안에 있을 수 있음. 평가 분할이 없음(01 Q3). 프로젝트 페이지 문장 "Training on all embodiments outperforms direct training on the target embodiment"도 같은 문제
C4	PT는 구현체 수에 덜 반응하고 GNN은 귀납 편향이 도움이 된다 (IV-B)	Fig. 2 PT 곡선	**부분**	PT 곡선은 대체로 평탄하지만 시드·부분집합 수가 없어 원인 주장은 검정 불가. 가설로 읽음
C5	점토 과제 오차가 밀기보다 낮다 (IV-B "Task-specific")	Fig. 2 두 축	**비교 불가**	두 과제의 MSE 단위와 크기(10^{-3} 대 10^{-5}-10^{-6}), 파티클 수(100/50 대 300/200), 목표 정의가 다름. 같은 척도가 아님
C6	점토에서 규모 효과가 더 크다 (IV-B)	Fig. 2 기울기	**부분**	점토 패널에서 x = 4-5 구간의 하강이 더 가파른 손이 많음. 그러나 척도 차이로 정량 비교 불가
C7	작은 손은 그래프가 촘촘해 적은 손으로도 좋아지고, 큰 손은 더 많은 손이 필요하다 (IV-B)	정성 설명	**확인 불가** (가설)	그래프 차수를 재지 않음. 03 §5의 장난감 실험은 "집계 방식과 밀도" 연결을 보여 주지만, 실제 DPI-Net에서는 확인되지 않음
C8	시뮬과 사람 데이터를 섞으면 사람 데이터만 쓴 것보다 낫다 (IV-C, Fig. 5)	Fig. 5 막대 (근사)	**부분**	0.2-0.5 혼합이 0 (사람만)보다 낮게 보이나 오차 막대가 겹침. 0.5가 최적으로 보임. 검정 없음
C9	"1:1 비율이 과제 전반에서 가장 좋다" (IV-C)	Fig. 5	**모순**	그림에서 최적은 0.5이고 1.0은 가장 나쁨(밀기 약 5.0, 점토 약 1.2, $\times 10^{-2}$). "1:1"은 CD:EMD 가중치를 뜻하는 캡션 문구와 섞여 있음
C10	시뮬만 쓰면 예측 오차가 가장 크다 (IV-C)	Fig. 5	**확인 불가**	막대 목록에 시뮬만(순수 시뮬) 항목이 없음. 범례 0 = 사람만이라면 본문이 가리키는 것이 없음

ID	주장 (위치)	근거	판정	메모
C11	사람 데이터만으로 학습한 모델이 로봇손에 zero-shot으로 붙는다 (IV-D, Table I)	Table I 사람만: 10/20, 9/20	**지지 (약함)**	로봇 데이터가 없는 설정이라 "미지 손" 조건은 맞음. 성공률은 50%(Ability) 이하
C12	공동학습이 사람 데이터만보다 실물 성공률이 높다 (IV-D, Table I)	18/20 대 10/20, 17/20 대 9/20	**지지 (작은 표본)**	Fisher p = 0.014(Ability), 0.019(XHand). Holm 보정 후 0.028, 0.021. CMH(글자 층화) p = 0.005, 0.007. 글자별 Fisher는 모두 p ≥ 0.17로 유의하지 않음(글자당 5회라 검정력이 없음). 03 §2
C13	같은 공동학습 모델이 서로 다른 운동학·자유도의 두 손에 제어를 가능하게 한다 (IV-D, 초록)	Table I 캡션	**부분**	**캡션에 공동학습은 "human + 6 simulated robot hands"로 적혀 있습니다.** 6개 시뮬 손에는 Ability Hand와 XHand가 들어 있으므로, 이 공동학습 모델은 두 실물 손의 시뮬 데이터를 이미 봤습니다. 즉 실물 공동학습 결과는 "미지 손"이 아닙니다. 사람 전용 모델만 미지 손 조건입니다. v3 본문은 "without fine-tuning"이라고 썼지만 미지 손 조건과 같다고 볼 수 없습니다
C14	파티클 변위 행동 덕분에 자유도와 무관하게 계획이 된다 (III-A, I절)	정의와 FK 설명	**부분**	행동 정의 자체는 그렇지만, 계획 샘플은 손별 모션 프리미티브에서 뽑음(III-D). 프리미티브가 손마다 어떻게 정의되는지 없음. 샘플 분포가 손에 따라 다르면 "무관"이 성립하지 않음
C15	계획 한 번에 약 60초 (IV-A)	RTX 4090, 500 × 10 × H = 4	**확인 불가 (수치는 맞음)**	계산량은 500 × 10 × 4 = 20,000 단계 예측. 60초는 손·물체 파티클 수와 구현에 따라 다름. 재계획 횟수와 시도당 시간 없음
C16	실물 점토 과제는 20회 시도다 (IV-D)	Table I	**지지**	글자 4개 × 5회 × 손 2개 × 방법 2개 = 80회 시도(손·방법당 20회). 시도 순서, 무작위화, 목표 공개 여부는 없음

2. 표·숫자 재계산 요약 (상세는 03)

- Table I 합계와 글자별 평균이 맞는지 확인했습니다(공동학습 CD 6.95 대 글자 평균 6.95, 사람 7.15 대 7.15 등). 평균 합계 행은 글자 평균과 소수 둘째 자리까지 일치합니다.
- 성공 기준 0.0125(CD + EMD)를 글자별 평균과 대조하면, 평균이 기준 아래(예: 공동학습 Ability 글자 A = 12.24×10^{-3})여도 성공 횟수는 5/5가 아닙니다. 기준은 시도마다 적용되므로 정상적인 분산입니다. 시도별 값이 없어 성공 판정을 검산할 수는 없습니다.
- 표본 크기: 20 대 20에서 성공률 0.9 대 0.5를 80% 검정력으로 찾으려면 손·방법당 20회가 필요합니다(정규근사). 0.85 대 0.5는 27회가 필요합니다. 이 실험은 큰 차이만 잡을 수 있습니다.

3. 빠진 정보 (재현과 판정에 필요)

- **데이터:** 시뮬 궤적의 길이, 학습/평가 분할, 손별 데이터 양(100 궤적 외). 실물 사람 시연의 수(30분 세 번) 외 프레임 수.
- **모델:** DPI-Net의 층 수 L, 은닉 차원, 엣지 특징, 옵티마이저, 학습률, 배치, 스텝, 손실 가중치, PT 설정.
- **파티클:** 손 파티클을 어떻게 샘플링하는지(FK의 대상 점 위치, 밀도, 손마다 개수). 교차 손 대응(어떤 파티클이 어떤 파티클과 같은지). Fig. 5는 CD/EMD를 쓰므로 대응이 없다고 명시하지만, 시뮬 MSE에서는 대응이 있어야 하는데 방법이 없음.
- **MPC:** 엘리트 수, 분산 갱신, 모션 프리미티브 파라미터, 손별 제약, 시도당 재계획 수, 시간 제한.
- **실물:** 시도 순서, 무작위화, 실패 판정 기준, 같은 목표를 두 방법에 같은 순서로 줬는지, 카메라 보정 오차.
- **통계:** 시드 수(부분집합 분산과 시드 분산을 구별하지 않음), 오차 막대의 정의(부분집합 대 시드), 유의성 검정.

4. 구현 가능성 판정

판정: 공식 재현은 불가능합니다. 아이디어를 작은 규모로 다시 만드는 것은 중간 난이도이고, 이 맥에서 학습 규모 재현은 불가능합니다.

항목	판정	근거
공식 재현 (코드·가중치·데이터)	**불가**	코드 없음(프로젝트 페이지 자리표시자, 저자 계정에 관련 저장소 없음). 같은 이름의 `facebookresearch/dexwm`은 다른 논문의 코드. 데이터셋·가중치 공개 없음
이 맥(Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치)에서 학습 재현	**불가** (규모 기준)	논문 학습은 RTX 4090급 GPU를 전제로 함. 이 맥에서는 MPS로 작은 GNN은 돌릴 수 있지만 Rewarped·SAPIEN 6개 손 데이터 생성과 대규모 학습은 설치와 승인이 필요 (설치 금지 조건)
실물 재현 (XArm 7, Ability Hand, XHand, RealSense 4대)	**불가**	하드웨어 없음. 사람 시연 수집 장치 없음
시뮬 Q1 (손 수 증가) 재현	**불가** (현 조건)	손 6개의 URDF·충돌 모델, 시뮬 설치, 데이터 수집이 필요. 이 맥에서 한 번에 못 함
아이디어 재구현 (파티클 변위 행동 + GNN + MPC)	**중간 난이도**	DPI-Net 류 GNN 구현 약 300-500줄(PyTorch), MPC 약 100-150줄. 손 파티클 샘플링과 교차 손 대응은 임의 선택이 필요하며 결과가 여기에 민감할 가능성이 큼
이 맥에서 CPU toy	**가능**	`analysis/particle_toy.py` (numpy 1스레드), 2차원 장난감 세계. 논문 모델은 아님
필요 자원 (재구현 규모)	GPU 1장(RTX급 이상) 학습 시간 수십 시간(추정), 시뮬 6종 설치, 실물 장비 2종	논문 MPC 1회 60초(RTX 4090) 근거. 학습 시간은 논문에 없어 추정치

한 줄 판정 (README용): 공식 재현 불가(코드·가중치 없음). 이 맥에서는 CPU toy까지만 가능하고, 학습·시뮬·실물 재현은 GPU·설치·장비가 필요해 보류.

5. 권리 표기

- arXiv abs 페이지 라이선스: **CC BY-NC-SA 4.0**(CC BY 아님). `paper/paper.pdf` 1쪽에는 arXiv 스탬프(v3, 2026-07-21)만 있고 IEEE 등 출판사 저작권 문구는 없음.
- 따라서 논문 그림(Fig. 2, Fig. 5)과 표(Table I)는 개인용 리포트와 PPT에만 넣고, 공개 산출물(`report_public.pdf`, `publish/`)에는 넣지 않습니다. 공개 그래프는 논문 표 값에서 직접 계산한 그래프와 장난감 실험 그래프만 씁니다.
- NC(비상업)와 SA(동일 조건 공유) 조건: 공개 게시본을 블로그나 저장소에 올릴 때 비상업 목적과 저작자 표시를 지켜야 합니다. 논문 본문을 인용하는 수준의 요약은 포함합니다(출처 명시).

선행연구와 관련 저장소

대상: arXiv:2511.01177 v3 (IROS 2026 채택, 4절 참고). 참고문헌 번호는 v3 본문의 번호입니다.

1. 계보: 어디서 왔나

줄기	v3 참고	이 논문이 가져온 것	이 논문과의 차이
교차 구현체 (embodiment) 학습	Ai et al. [3] 보행 스케일링 법칙, Bohlinger [5], Open X-Embodiment [27]	"구현체 수가 늘면 보지 않은 구현체 오차가 준다"는 실험 설계	보행에서 강화학습 기반. 여기서는 세계 모델 오차를 씀
파티클 기반 동역학	DPI-Net [24] (Li et al., CVPR 2020), RoboCook [40], RoboCraft [41], AdaptiGraph [56], RoboPack [2]	반경 그래프 GNN, 파티클 동역학, 다중 시점 파티클 인식 (FPS, 표면 재구성)	단일 구현체(평행 턱 그리퍼)로 학습한 것이 대부분. 여기서는 여러 손을 한 모델에 넣음
사람-물체 파티클 모델	Hong et al. [17] (2025)	사람-물체 상호작용으로 파티클 세계 모델 학습	정책 탐색에만 씀(v3 II-B). 교차 로봇 제어는 없음
파티클 기반 세계 모델의 대규모 학습	PointWorld [18] (Huang et al.)	3D 점 흐름 표현, 대규모 로봇 데이터	평행 턱 그리퍼의 점 흐름. 여기서는 손 파티클 변위장으로 바꿈
학습 기반 세계 모델 제어	Ai et al. [1] 리뷰, Tenenbaum [44]	세계 모델 + 샘플링 MPC	같음
점 네트워크 기준선	Point Transformer [58]	어텐션 기준선 PT(같은 입출력·손실)	기준선으로만 씀
손 인식	POEM-v2 [54] (사람 손 메시), FoundationPose [50] (강체 자세)	인식 파이프라인	인식 도구
시뮬레이터	SAPIEN [52] (강체), Rewarped [53] (미분 가능 다물리)	데이터 수집	시뮬레이터 두 종류 사용

읽는 순서 제안. [24] DPI-Net(구조), [2] RoboPack(같은 저자 계열의 실물 파티클 모델), [3] Embodiment Scaling(실험 설계), [18] PointWorld(가장 가까운 대안).

2. 가까운 대안과 차이

- **PointWorld [18].** 3D 점 흐름으로 대규모 데이터에서 학습합니다. 이 논문은 "사람과 여러 손을 같은 파티클 행동 공간에 넣는 것"을 차별점으로 씁니다(v3 II-B 마지막 문장). 두 논문은 같은 주제(점 기반 세계 모델)지만 행동 표현과 데이터가 다릅니다. 직접 비교 실험은 없습니다.
- **Hong et al. [17].** 사람-물체 파티클 모델을 정책 탐색에만 쓰고, 그 정확도가 직접 제어에는 부족했다고 v1에서 적었습니다(v1 II-B). v3는 같은 문장을 줄였습니다.
- **Ai et al. [3] 스케일링.** 이 논문 Q1의 설계 근거입니다. 다만 보행 정책 학습과 달리 여기서는 세계 모델의 **예측 오차**를 봅니다.
- **Point Transformer [58].** 같은 입출력을 쓰는 가장 가까운 대조군입니다. 이 논문에서 PT는 GNN보다 구현체 수 증가에 덜 반응하고, 저자는 그 이유를 GNN의 귀납 편향으로 봅니다(IV-B).

3. 이 저장소의 다른 논문과의 관계

이 논문의 핵심(교차 손 전이, 손 파티클 표현, 세계 모델 + MPC)과 같은 축에 있는 폴더입니다. 각 README 첫 단락을 기준으로 정리했습니다. 수치를 이 논문과 직접 비교한 것은 아닙니다.

폴더	무엇을 하나	이 논문과의 관계
`flashdexretarget/`	사람 손 시연 → 로봇손(XHand, Sharpa Wave) 궤적 리타겟팅(강화학습 정책)	교차 손 전이의 **다른 해법**: 리타겟팅 대 이 논문의 "행동을 파티클 변위로 바꿔 세계 모델에 그대로 넣기". 이 논문은 리타겟팅을 하지 않는다고 명시(v3 I절)
`gnr/`	리타겟팅 궤적을 기준으로 잔차를 flow matching으로 생성 (Tesollo DG-5F)	같은 문제(사람 → 로봇손)를 생성 모델로 풀이. 이 논문 입장에서는 "리타겟팅 + 정책" 기준선의 후보
`chord/`	사람 접촉점과 법선에서 마찰원뿔 기반 보상으로 다지 손 조작 RL	접촉 기하를 명시적으로 쓰는 방법. 이 논문의 "파티클이 접촉 기하를 담는다"와 대비
`lightning_grasp/`, `mana/`	손의 접촉 가능 집합(BVH), 절차적 파지 키프레임으로 파지·도구 조작 데이터 생성	파지 데이터 생성. 이 논문의 무작위 상호작용 데이터 수집과 대비되는 "구조화된 데이터"
`eigendexplore/`	리타겟된 PCA 방향을 행동이 아니라 탐색 잡음에 넣기	사람 동작의 저차원 구조를 쓴다는 점이 이 논문의 모션 프리미티브(III-D, [12])와 가까움
`openwam/`, `agentic_wam/`	영상·행동 결합 World-Action Model	세계 모델의 다른 표현(영상 대 파티클). 교차 구현체 주장은 없음
`dexpolicy/`	ViViDex 강화학습 탐색 잡음 스케줄	이 논문과 직접 관계는 약함. 사람 영상 기반 손 정책의 하위 기법

4. GitHub 저장소 (2026-11-10 확인)

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋
(이 논문 공식 코드)	**없음.** 프로젝트 페이지의 Code 링크는 `https://github.com/[your-repo]` 자리표시자 그대로입니다. 저자 계정 `Alan-Heoooh` 에는 이 논문용 저장소가 없습니다(공개 저장소 7개 중 관련 없음).	—	—	—	—
`facebookresearch/dexwm`	**다른 논문**의 공식 코드(DexWM: World Models for Learning Dexterous Hand-Object Interactions from Human Videos, arXiv:2512.13644, Meta-FAIR). 이름이 같아 혼동하기 쉽습니다.	다른 논문의 공식	확인 안 됨 (NOASSERTION)	110	`74ccc30` (2026-04-21)
`jiduster/DexWM`	위 DexWM에 교사 강요와 DexJoco 학습을 더한 개인 포크	비공식	확인 안 됨	0	`c9d46a9` (2026-09-23)
`kuangttu/dexwm_basdline`	이름만 보면 DexWM 기준선 실험	비공식(내용 확인 안 함)	확인 안 됨	0	`174bdbb` (2026-05-09)

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋
`YunzhuLi/DPI-Net`	DPI-Net 원 구현(Li et al., CVPR 2020)	이 논문이 쓴 GNN의 원 저자 공식	없음(license 필드 비어 있음)	141	`d20ee08` (2020-09-09)
`BoAi01/robopack`	RoboPack(같은 제1저자 계열, 촉각 파티클 동역학)	1저자 계열 저장소로 보임(저자 대조 안 함)	확인 안 함	11	2025-03-21 최종 push
`NVlabs/PointWorld`	PointWorld 후보(이름 일치, 저자 대조 안 함). 개인 저장소 `huangwl18/PointWorld` 도 있음	공식 여부 미확인	확인 안 함	571 (NVlabs), 421 (개인)	2026-05-17 (NVlabs) push
`Alan-Heoooh/FoAR`	제1저자 관련 연구(힘 인지 반응형 정책, RA-L 2025 & IROS 2025)	제1저자 공식 저장소	없음	70	`869abd3` (2026-08-07 push)
`NVlabs/FoundationPose`	강체 6D 자세 추정(이 논문의 강체 인식에 사용, [50])	원 저자 공식	NOASSERTION(NVIDIA 라이선스)	3,694	`a1b694b` (2026-04-29)
Rewarped, SAPIEN, POEM-v2, Point Transformer	검색 결과 없음(이름 검색으로는 찾지 못 함)	—	—	—	—

판단. 이 논문의 학습 코드, 세계 모델 가중치, 실험 설정 파일은 공개되지 않았습니다. `facebookresearch/dexwm`은 다른 논문이므로 이 논문의 구현으로 쓸 수 없습니다. 재현에 가장 가까운 공개 자원은 DPI-Net 원 구현(라이선스 없음, 2020년 이후 갱신 없음)과 RoboPack 계열 코드입니다. 두 저장소를 합쳐도 이 논문의 손 파티클 표현, 손 데이터 구성, MPC 설정은 복원되지 않습니다. 자세한 대조는 `04_claim_verification.md`를 보세요.

5. 가장 가까운 대안을 고르는 기준

- 교차 손 **행동 전이**: 리타겟팅 + 정책(`flashdexretarget/`, `gnr/`), 이 논문의 "파티클 세계 모델 + MPC". 같은 목적에 방법이 다릅니다.
- 세계 모델 **표현**: 파티클(이 논문, PointWorld, RoboPack), 영상(`openwam/`, `agentic_wam/`). 교차 구현체 전이를 주장하는 것은 파티클 쪽뿐입니다.
- 기준선을 고르려면 이 논문에 없는 항목(리타겟팅 + 정책, 손별 모델의 데이터 맞춤)을 직접 구성해야 합니다. 이 점은 `03_analysis.md`에서 다룹니다.