DDPG: 분석 리포트

게시용 버전: 논문 그림은 라이선스(arXiv 비독점 배포) 때문에 제외했습니다. 원문 https://arxiv.org/abs/1509.02971 · arXiv:1509.02971v6 · ICLR 2016 · Google DeepMind (Lillicrap, Hunt, Pritzel, Heess, Erez, Tassa, Silver, Wierstra) · 공식 코드 없음 · 분석일 2026-10-28 · 논문 그림은 개인 학습용으로만 사용(논문 라이선스가 CC BY 아님)

핵심 요약

1. **무엇을 했나:** DPG actor-critic에 DQN의 재생 버퍼와 soft 표적망(τ = 0.001), 배치 정규화, OU 탐색 잡음을 붙여 연속 행동을 신경망으로 학습했다. 같은 설정으로 MuJoCo 26개 과제와 Torcs를 저차원·픽셀 입력에서 풀었다고 보고한다.
2. **"계획기와 견줄 만하다"는 최고 시드 기준이다:** 저차원 평균 정규화 점수는 0.72(계획기의 약 72%)이고, 평균으로 계획기를 넘은 과제는 26개 중 2개다. 최고 시드 기준으로는 10개다.
3. **표적망 효과는 확실하고, BN 효과는 근거가 약하다:** DDPG가 DPG + BN보다 26개 중 25개 과제에서 높다($p = 6\times10^{-8}$). 반면 "표적망만" 변형은 표에 없고, Fig. 2에서는 BN 유무가 여러 과제에서 겹친다.
4. **공식 코드가 없고 재현 정보가 빠져 있다:** OU 잡음의 dt가 없어 구현마다 상관 시간이 100배(6 vs 666 step) 다르다. 픽셀 망은 커널·stride가 없어 "43만 파라미터"로 구조를 복원할 수 없다.
5. **주요 구현은 논문 설정과 다르다:** SB3·Spinning Up·TD3 저장소 모두 BN이 없고 τ·배치·잡음이 다르다. TD3 저장소의 "논문 재현" `DDPG.py` 도 `main.py` 로 돌리면 τ 0.005, 배치 256이 된다.
6. **numpy toy(진자, 5개 시드):** 표적망을 빼면 0/5, τ를 0.005로만 바꿔도 1/5만 풀었다. 잘 풀린 설정에서도 Q는 평균 +6.7% 과대추정되었다(Fig. 3의 "편향 없음"과 다름).
7. **구현 가능성:** 논문 표 재현은 불가능하다(과제·계획기 비공개). 알고리즘 재구현과 공개 구현 사용은 매우 쉽고, 저차원 MuJoCo 실험은 이 맥(CPU)에서 설치만 승인받으면 할 수 있다.

01. 논문 분석: DDPG (arXiv:1509.02971)

- 제목: *Continuous control with deep reinforcement learning*
- 저자: Timothy P. Lillicrap*, Jonathan J. Hunt*, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, Daan Wierstra (Google DeepMind)
- 공개: arXiv v1 2015-09-09 → v6 2019-07-05, ICLR 2016 학회 논문. **v6 기준으로 분석**했고 v1, v5와 대조했습니다.
  - v1 → v5: ICLR 형식으로 바뀌었고, Table 1에 원래 DPG(+ 재생 버퍼 + 배치 정규화) 비교 열 `cntrl`이 추가되었습니다. 하이퍼파라미터와 DDPG 수치는 같습니다.
  - v5 → v6: 오타 하나("chosen to chosen to")만 고쳤습니다.
- 코드: **공식 코드는 없습니다.** 실험 환경(MuJoCo 과제 32개, Torcs)과 iLQG 계획기도 공개되지 않았습니다. 주요 공개 구현은 `02` §4에 정리했습니다.
- 라이선스: arXiv 비독점 배포 라이선스 (**CC BY 아님**). 논문 그림은 개인용 리포트·PPT에만 넣습니다.
- 분석 범위: 본문 10쪽과 부록 4쪽(실험 설정, 계획기, 환경). 주요 구현 4종(Stable-Baselines3, Spinning Up, TD3 저장소, OpenAI baselines)과 rllab의 해당 파일.

---

1. Abstract (한 줄 요약과 주장)

한 줄 요약: DQN을 성공시킨 두 장치(재생 버퍼, 표적망)를 결정적 정책 경사(DPG) actor-critic에 옮기고 배치 정규화를 더해, 연속 행동 공간에서 신경망 정책을 안정적으로 학습했습니다. 하이퍼파라미터 하나로 20개 넘는 물리 과제를 저차원 관측과 픽셀 모두에서 풀었다고 보고합니다.

논문이 내세우는 주장은 네 가지입니다.

1. 모델 없는 off-policy actor-critic 알고리즘 **DDPG**를 제시합니다. 연속 행동을 이산화하지 않고 바로 다룹니다.
2. **같은 구조와 하이퍼파라미터**로 cartpole swing-up, 손 조작, 보행, 자동차 주행 등 20개 넘는 과제를 풉니다.
3. 동역학과 미분을 모두 아는 계획기(iLQG)와 **견줄 만한** 정책을 찾고, 일부 과제에서는 그보다 낫습니다.
4. 여러 과제에서 **픽셀 입력만으로** 끝까지(end-to-end) 학습합니다.

---

2. Method

2.1 배경: 결정적 정책과 Bellman 식 (Eq. 1-5)

정책이 결정적 μ(s)이면 Bellman 식의 다음 행동 기댓값이 사라집니다.

```
Q^μ(s_t, a_t) = E_{r_t, s_{t+1} ~ E} [ r(s_t, a_t) + γ Q^μ(s_{t+1}, μ(s_{t+1})) ]     (Eq. 3)
```

기댓값이 환경에만 걸리므로, 다른 행동 정책 β가 모은 전이로 Q^μ를 off-policy 학습할 수 있습니다. critic은 TD 손실 `L = E[(Q(s,a|θ^Q) − y)²]`, `y = r + γ Q(s', μ(s'))`로 학습합니다(Eq. 4-5).

2.2 actor 업데이트 (Eq. 6)

연속 공간에서는 매 step `argmax_a Q`를 풀 수 없으므로 actor μ(s|θ^μ)를 따로 둡니다. 시작 분포 기준 return J를 actor 파라미터로 미분하고 연쇄 법칙을 쓰면 다음과 같습니다.

```
∇_{θ^μ} J ≈ E_{s ~ ρ^β} [ ∇_a Q(s, a | θ^Q) |_{a = μ(s)} · ∇_{θ^μ} μ(s | θ^μ) ]     (Eq. 6)
```

Silver et al. (2014)은 이것이 정책 성능의 경사임을 증명했습니다(on-policy 분포 기준). 이 논문은 각주 2에서 상태 방문 분포의 할인을 무시했다고 밝힙니다. 행동 분포 ρ^β에서 기댓값을 취하는 점도 엄밀한 경사가 아닌 근사입니다(`03` §1).

2.3 DQN에서 가져온 두 장치와 배치 정규화 (Sec. 3, Algorithm 1)

장치	논문의 동기	방식
재생 버퍼	연속 탐색으로 모은 표본은 i.i.d.가 아니고, 하드웨어 효율에는 minibatch가 필요	크기 10^6, 가득 차면 오래된 것부터 버림, 매 step 균등 표본
soft 표적망	업데이트하는 Q가 표적 y 계산에도 쓰여 발산하기 쉬움	actor와 critic의 복사본을 두고 `θ' ← τθ + (1−τ)θ'`, τ = 0.001. **두 표적망이 모두 있어야** critic이 발산하지 않았다고 보고
배치 정규화	관측 성분마다 단위(위치, 속도)와 범위가 달라 과제 간 하이퍼파라미터 공유가 어려움	상태 입력, μ의 모든 층, 행동이 합류하기 전 Q의 모든 층에 적용
OU 탐색 잡음	관성이 있는 물리계에서 시간 상관 탐색이 효율적	`μ'(s) = μ(s) + N`, N은 Ornstein-Uhlenbeck 과정(θ = 0.15, σ = 0.2)

Algorithm 1은 매 환경 step마다 critic과 actor를 한 번씩 업데이트하고 두 표적망을 soft update합니다. 에피소드마다 탐색 과정 N을 새로 시작합니다.

2.4 실험 설정 (부록 7절)

항목	저차원 관측	픽셀 관측
구조	은닉 400 → 300, ReLU, actor 출력 tanh. **행동은 Q의 두 번째 은닉층에서 합류**	합성곱 3층(필터 32, pooling 없음) + 완전연결 200 × 2. 행동은 완전연결층에서 합류
파라미터 수	"약 13만"	"약 43만"
마지막 층 초기화	$U(-3\times10^{-3}, 3\times10^{-3})$	"$[3\times10^{-4}, 3\times10^{-4}]$" (음수 부호가 빠진 오타로 보임)
나머지 초기화	$U(-1/\sqrt{f}, 1/\sqrt{f})$, f = fan-in	같음
최적화	Adam, actor 10^{-4}, critic 10^{-3}, critic L2 weight decay 10^{-2}, γ = 0.99, τ = 0.001	같음
minibatch	64	16
재생 버퍼	10^6	10^6
입력	관절각, 위치 등	64 × 64 RGB, 행동 반복 3번 → 9채널, [0, 1] 정규화

빠진 정보도 있습니다. 합성곱의 커널 크기와 stride, OU 과정의 시간 간격 dt, 학습 시작 전 무작위 탐색 여부, 에피소드 길이와 시간 제한 처리, 평가 주기와 평가 에피소드 수가 없습니다(`04` §2).

---

3. Experiments

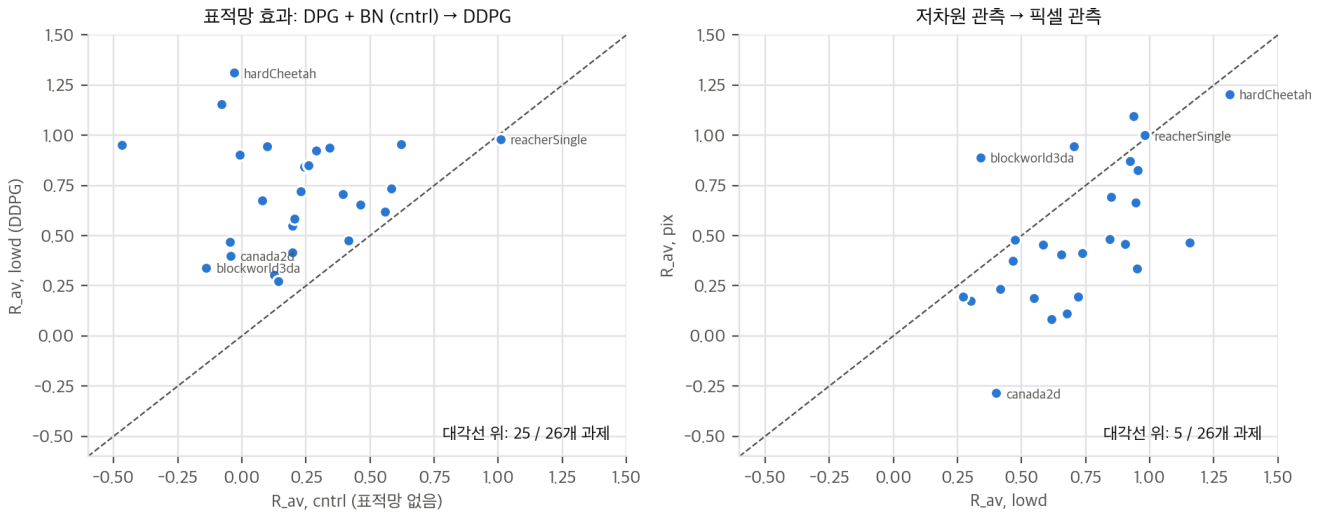
3.1 과제와 기준선 (Sec. 4, 부록 9절)

- MuJoCo로 만든 자체 과제입니다. 부록 Table 2에 32개 환경의 차원이 있고, Table 1에는 그중 26개와 Torcs가 실렸습니다. 빠진 6개는 cartpoleParallelTriple, hardCheetahNice, hyqKick, movingGripperRandom, reacherDouble, reacherObstacle입니다(`04` C5). cheetah를 빼면 행동은 관절 토크입니다.
- 점수는 두 기준으로 정규화합니다. 행동 공간에서 균등하게 뽑는 무작위 정책을 0, iLQG 모델 예측 제어기(진짜 동역학과 미분을 씀, 계획 구간 250-600 ms)를 1로 둡니다.
- 시드 5개입니다. "평균"과 "최고" 점수를 보고하고, 학습은 최대 250만 step입니다.

3.2 주 결과 (Table 1)

재계산은 `04` §3과 `analysis/table_check.py`에 있습니다.

열	26개 과제 평균	중앙값	최소-최대	계획기(1)를 넘은 과제 수
R_av, lowd (DDPG, 저차원)	0.718	0.712	0.272-1.311	2
R_best, lowd	1.078	0.992	0.705-1.990	10
R_av, pix (DDPG, 픽셀)	0.498	0.455	−0.285-1.204	2
R_best, pix	0.932	0.923	0.119-2.225	8
R_av, cntrl (원래 DPG + 버퍼 + BN)	0.217	0.201	−0.468-1.010	1



출처: 논문 Table 1(5개 시드 평균, 무작위 정책 0 · iLQG 계획기 1로 정규화). 점 하나가 과제 하나. 점선은 같은 점수.

우리 분석: Table 1을 과제 단위로 비교. 왼쪽 표적망 효과(cntrl → lowd), 오른쪽 저차원 → 픽셀.

해석:

- **"계획기와 견줄 만하다"는 최고 시드 기준입니다.** 평균으로 계획기를 넘은 과제는 26개 중 2개(blockworld1, hardCheetah)입니다. 최고 시드 기준으로는 10개입니다. 초록과 본문의 "some of the replicas"라는 표현은 정확하지만, 평균 성능은 계획기의 약 72%입니다.
- **표적망 효과는 분명합니다.** 표적망이 없는 DPG + BN(cntrl)보다 DDPG가 평균 기준으로 26개 중 25개 과제에서 높습니다(평균 차이 +0.50, Wilcoxon $p = 6\times10^{-8}$). 예외는 reacherSingle 하나입니다(1.010 vs 0.981).
- **픽셀은 대부분 저차원보다 나쁩니다.** 평균 기준으로 픽셀이 저차원 이상인 과제는 5개(blockworld3da, cart, movingGripper, reacherSingle, walker2d)뿐이고 평균 차이는 −0.22입니다. "단순한 과제에서는 픽셀도 저차원만큼 빠르다"는 본문 설명과 맞습니다.
- **시드 간 퍼짐이 큽니다.** R_best가 같은 5개 최종 점수의 최댓값이라면, R_best − R_av로부터 시드 표준편차의 하한을 구할 수 있습니다 (`03` §4). 예를 들어 canada는 0.80 이상, walker2d는 0.49 이상, hardCheetah는 0.38 이상입니다. "robustly solves"는 평균보다 최고 시드에 가까운 표현입니다. 다만 R_best가 학습 중 최고 체크포인트를 뜻한다면 이 하한은 성립하지 않으며, 논문만으로는 어느 쪽인지 알 수 없습니다.
- **Torcs는 평균이 음수입니다**(저차원 −393, 픽셀 −402). 최고 시드는 1,840과 1,876입니다. 본문도 "일부 시드만 트랙을 완주했다"고 적었습니다. 또 Torcs는 탐색 잡음을 바꿔서, "모든 과제에 같은 하이퍼파라미터"라는 주장의 예외입니다.

3.3 구성 요소 비교 (Fig. 2)

Fig. 2는 10개 과제에서 네 변형의 학습 곡선을 보입니다: DPG + BN(연회색), + 표적망(진회색), + 표적망 + BN(초록), + 표적망, 픽셀(파랑).

- 연회색(표적망 없음)은 대부분 과제에서 가장 나쁩니다. "표적망이 결정적"이라는 캡션과 맞습니다.
- 반면 **진회색(표적망만)과 초록(표적망 + BN)은 여러 과제에서 거의 겹칩니다**(Cart, Pendulum, Cheetah 등, 그림에서 읽은 판단). Table 1에는 "표적망만" 열이 없어서 배치 정규화의 기여는 수치로 보고되지 않았습니다. "두 장치가 모두 필요하다"(Sec. 4)는 주장에서 BN 쪽 근거는 약합니다.

3.4 Q 추정 정확도 (Fig. 3)

학습 후 Q 추정값과 테스트 에피소드의 실제 return을 비교했습니다. 진자와 cartpole은 대각선 근처이고, cheetah는 추정이 실제보다 크게 위에 있습니다(과대추정). 본문은 "단순 과제에서는 체계적 편향 없이 정확하다"고 해석합니다. 우리 진자 toy에서는 잘 풀린 설정의 시드 15개 중 13개가 과대추정이었고 평균 +6.7%였습니다(`03` §5). 단순 과제에서도 편향이 0은 아니라는 뜻입니다. 이후 TD3(Fujimoto et al., 2018)가 이 과대추정을 DDPG의 핵심 약점으로 지목했습니다.

---

4. Limitations

4.1 저자가 밝힌 한계

비선형 함수 근사 때문에 수렴 보장이 없습니다. 대부분의 모델 없는 방법처럼 학습 에피소드가 많이 필요합니다. 어려운 과제에서는 Q 추정이 부정확합니다.

4.2 분석하면서 추가로 발견한 한계와 의문점

1. **재현에 필요한 정보가 빠져 있습니다**(`04` §2). OU 잡음의 dt가 없어서 구현마다 상관 시간이 100배 다릅니다(rllab dt = 1 → 약 6 step, baselines·SB3 dt = 0.01 → 약 666 step). 픽셀 망은 커널과 stride가 없고, 세 층이 같은 설정이라고 가정하면 "43만 파라미터"를 7% 이내로 맞출 수 없습니다(`04` C7). 시간 제한 종료 처리, 무작위 시작 step, 평가 방식도 없습니다.
2. **과제, 정규화 기준, 계획기가 공개되지 않았습니다.** 정규화 점수의 0과 1이 모두 비공개 구현에 의존하므로 Table 1을 다른 환경에서 직접 재현할 수 없습니다.
3. **"하이퍼파라미터 하나로 모든 과제"는 보고 방식에 기댄 주장입니다.** 평균 점수의 범위가 0.27-1.31로 넓고, 시드 간 퍼짐도 큽니다. 같은 설정이 "돌아간다"는 것과 "안정적으로 잘 푼다"는 것은 다릅니다.
4. **배치 정규화의 기여가 수치로 분리되지 않았습니다**(§3.3). 이후 주요 구현(SB3, Spinning Up, TD3 저장소)은 모두 BN을 빼고도 잘 동작합니다.
5. **시드 5개, 신뢰구간 없음, 학습 곡선 일부만 공개**입니다. Table 1의 "최대 250만 step"도 과제마다 실제 학습 길이가 다를 수 있다는 뜻으로 읽힙니다.
6. **"DQN보다 20배 적은 step"은 단위가 섞인 비교입니다**(`04` C8). DQN의 5천만은 게임 프레임이고, DQN은 4프레임마다 행동하므로 행동 step으로는 1,250만입니다. 같은 단위로 비교하면 약 5배입니다(DQN 수치는 내 사전 지식이라 원문 확인이 필요합니다).

03. 핵심 식 해석과 toy 검증

스크립트는 세 개입니다.

- `analysis/table_check.py` : 표·부록 수치 재계산 → `table_check_results.json`
- `analysis/ddpg_toy.py` : numpy로 구현한 DDPG를 진자 swing-up에서 실행 → `ddpg_toy_results.json`
- `analysis/plot_figures.py` : 그림과 toy 통계 → `toy_stats_results.json`

toy의 수동 역전파는 중앙 차분과 비교해 최대 상대 오차 1×10^{-7}로 확인했습니다.

1. Eq. 6은 무엇의 경사인가

off-policy 목적함수를 행동 분포 ρ^β 위에서 정의하면 J_β(μ) = E_{s~ρ^β}[Q^μ(s, μ(s))]입니다. 이를 미분하면 두 항이 나옵니다.

```
∇_θ J_β = E_{s~ρ^β} [ ∇_θ μ(s) · ∇_a Q^μ(s, a)|_{a=μ(s)} ]  +  E_{s~ρ^β} [ ∇_θ Q^μ(s, a)|_{a=μ(s)} ]
                    └──── Eq. 6 ────┘                              └ 정책이 바뀌면 Q^μ 자체가 바뀌는 항 (버림)
┘
```

Eq. 6은 두 번째 항을 버린 근사입니다. Silver et al.(2014)의 off-policy 결정적 actor-critic도 같은 근사를 씁니다. 정리가 정확히 성립하는 것은 on-policy 할인 방문 분포 ρ^μ에서인데, DDPG는 재생 버퍼의 분포에서 기댓값을 취하고 각주 2처럼 할인도 무시합니다. 버퍼가 크고 정책이 빨리 바뀔수록 ρ^β와 ρ^μ의 차이가 커집니다. 따라서 "버퍼가 클수록 좋다"는 데이터 효율과, 경사의 편향 사이에 맞교환이 있습니다. 논문은 버퍼 크기를 10^6 하나만 씁니다.

해석하면 Eq. 6은 "현재 critic이 보기에 Q가 커지는 방향으로 행동을 민다"는 정책 개선 단계입니다. critic이 틀리면 actor도 그대로 따라갑니다. 과대추정(§5)이 정책 품질로 바로 이어지는 이유입니다.

2. soft 표적망 = 지수이동평균

`θ' ← τθ + (1−τ)θ'`을 펼치면 θ'*k* = *Σ_j τ(1−τ)^j θ*{k−j}이므로, 표적망은 최근 파라미터의 지수이동평균입니다. 반감기는 ln 0.5 / ln(1−τ) 업데이트입니다.

τ	반감기 (업데이트)	쓰는 곳
0.001	693	논문, rllab, TD3 저장소 `DDPG.py` 클래스 기본값
0.005	138	SB3, Spinning Up(polyak 0.995), TD3 저장소 `main.py`
0.01	69	OpenAI baselines `learn()`, FlashDexRetarget의 FlashSAC
1	0 (표적망 없음)	원래 DPG

환경 step마다 업데이트가 한 번이면, 논문 설정의 표적은 약 700 step 전 파라미터에 가장 큰 무게를 둡니다. 진자 3.5 에피소드 분량입니다. 업데이트-대-데이터 비율(UTD)을 바꾸면 같은 τ라도 환경 step 기준 지연이 달라집니다. FlashSAC는 환경 step당 업데이트 2번이라 τ = 0.01이 환경 step 기준 반감기 약 35입니다.

3. OU 잡음: dt가 빠지면 상관 시간이 100배 달라진다

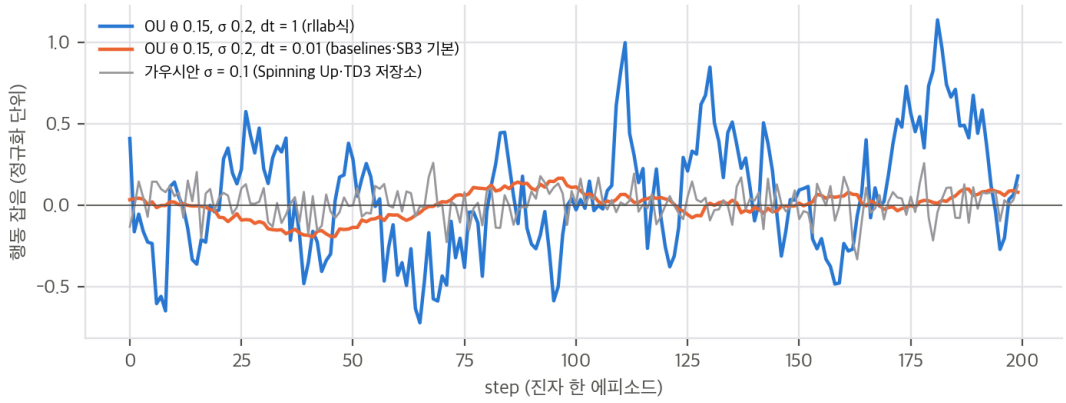
Euler 이산화 x' = x − θx·dt + σ√dt·ε의 성질은 다음과 같습니다(`table_check.py` C9).

```
lag−1 자기상관 ρ = 1 − θ·dt,   정상 분산 = σ²·dt / (1 − ρ²) = σ² / (2θ − θ²·dt)
```

dt	정상 표준편차	lag-1 자기상관	상관 시간 (1/e)	쓰는 곳
1	0.380	0.850	6 step	rllab (σ 0.3 기본)
0.1	0.367	0.985	66 step	—

dt	정상 표준편차	lag-1 자기상관	상관 시간 (1/e)	쓰는 곳
0.01	0.365	0.9985	666 step	OpenAI baselines, SB3 기본

정상 표준편차는 거의 같지만 상관 시간이 100배 다릅니다. 또 Algorithm 1처럼 에피소드마다 과정을 0에서 다시 시작하면, dt = 0.01에서는 200 step 안에 정상 상태에 닿지 못합니다. step t의 표준편차가 약 $\sigma\sqrt{(dt \cdot t)}$라서 t = 200에서도 0.28이고, 초반 수십 step은 거의 0입니다. 즉 "OU(0.15, 0.2)"라는 같은 이름으로 한쪽은 빠르게 흔들리는 잡음을, 다른 쪽은 천천히 떠도는 편향을 쓰게 됩니다(그림 `ou_noise.png`).



같은 θ, σ라도 dt에 따라 상관 시간이 6 step과 666 step으로 100배 다르다(table_check.py C9). 논문에는 dt가 없다.

4. 시드 퍼짐의 하한 (Table 1)

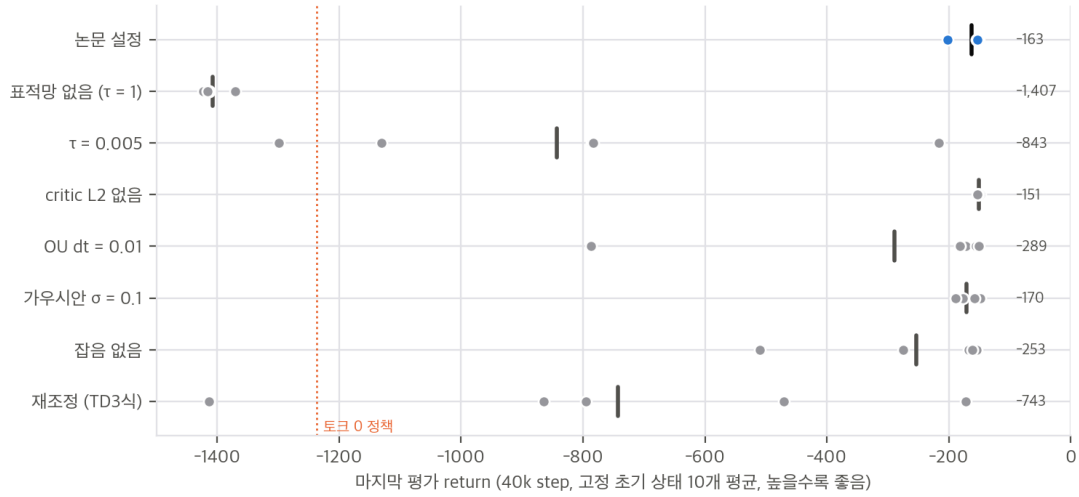
5개 값의 평균이 m이고 최댓값이 M이면, 표본 표준편차가 가장 작아지는 경우는 한 값이 M이고 나머지 넷이 m − (M−m)/4로 같을 때입니다. 이때 편차 제곱합은 $(M-m)^2 \cdot (1 + 4/16) = 1.25(M-m)^2$이므로 다음이 성립합니다.

```
s ≥ sqrt(1.25 / 4) · (M − m) ≈ 0.559 · (R_best − R_av)
```

저차원 DDPG에 적용하면 canada 0.80, walker2d 0.49, hardCheetah 0.38, canada2d 0.32 이상입니다. 26개 과제의 중앙값은 0.17입니다. 정규화 점수 범위(0-1)에 비하면 큰 퍼짐입니다. 단, 이 하한은 R_best가 R_av를 만든 같은 5개 최종 점수 중 최댓값일 때만 성립합니다. 논문의 "best observed"가 학습 중 최고 체크포인트라면 하한이 아닙니다.

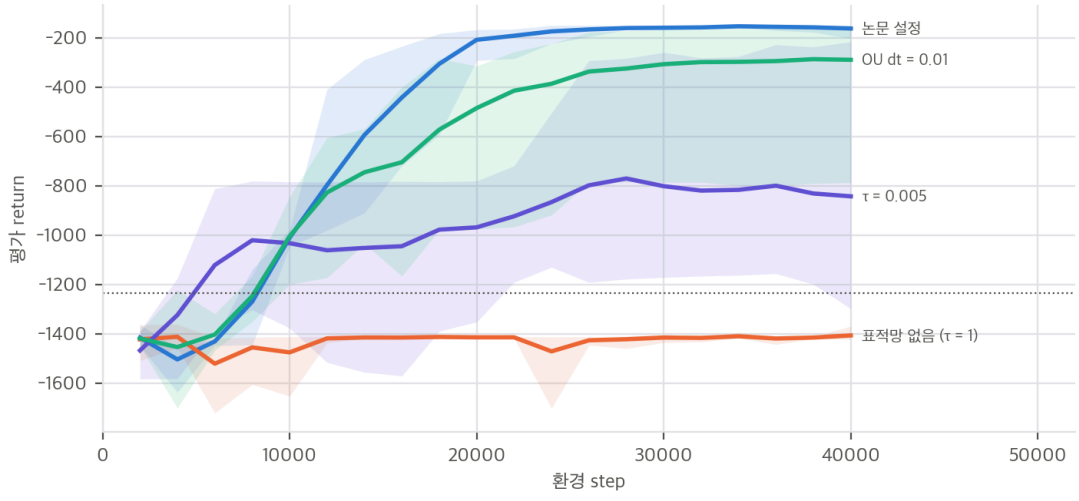
5. toy: numpy DDPG로 본 장치별 효과

설정: gym Pendulum-v1과 같은 동역학(200 step, 토크 ±2)에서 실행했습니다. 구조와 하이퍼파라미터는 논문 부록을 따랐습니다: ReLU, tanh 출력, 행동은 critic 두 번째 층에 합류, 마지막 층 U(±3e-3), Adam $10^{-4}/10^{-3}$, critic L2 10^{-2}, γ = 0.99, 배치 64. 다만 폭은 64-64로 줄였고 배치 정규화는 넣지 않았습니다. 40,000 step, 시드 5개이고, 논문 설정에서 한 항목씩만 바꿨습니다. 평가는 고정 초기 상태 10개에서 결정적 정책의 return 평균이고, 토크 0 정책은 −1,236입니다.



numpy DDPG(64-64), 진자 swing-up, 설정마다 5개 시드. 점 = 시드, 막대 = 평균. 논문 설정 대비 한 항목씩만 바꿈. analysis/ddpg_toy.py

설정	최종 return 평균	−250을 넘은 시드	논문 설정 대비 (Mann-Whitney p)
논문 설정 (τ 0.001, OU dt 1, L2 1e-2)	**−163**	5 / 5	—
표적망 없음 (τ = 1)	−1,407	0 / 5	0.008
τ = 0.005	−843	1 / 5	0.008
critic L2 없음	−151	5 / 5	0.14
OU dt = 0.01	−289	4 / 5	0.42
가우시안 σ = 0.1	−170	5 / 5	0.55
잡음 없음	−253	3 / 5	0.07
재조정 (lr 3e-4 둘 다, 배치 256, τ 0.005, 가우시안 0.1, L2 0)	−743	1 / 5	0.016



선 = 5개 시드 평균, 띠 = 최소-최대. 점선 = 토크 0 정책. analysis/ddpg_toy.py

해석:

- **표적망 없이는 전혀 배우지 못했습니다.** 다섯 시드 모두 토크 0 정책보다 나쁩니다. 수치 발산은 없었지만 정책이 개선되지 않았습니다. 논문의 "target networks are crucial"과 맞습니다.
- **τ는 다른 하이퍼파라미터와 묶여 있습니다.** 이 toy에서는 τ = 0.005가 논문 값 0.001보다 크게 나빴고, TD3 논문식 "재조정" 묶음도 5개 중 1개만 풀었습니다. 이것을 "τ = 0.005가 나쁘다"로 일반화하면 안 됩니다. SB3와 TD3 저장소는 τ = 0.005로 MuJoCo를 잘 풀고, 차이는 망 폭(400-300·256-256 vs 64-64), 할인율, 보상 크기에서 올 수 있습니다. 결론은 "τ만 따로 바꾸면 위험하다"입니다.
- **L2, 잡음 종류의 효과는 이 toy에서 구분되지 않습니다**(p > 0.1). L2를 빼도 오히려 약간 나았습니다(−151). 가우시안 0.1도 결국 풀지만 −400 기준을 넘는 시점이 늦었습니다(시드별 18-28k step, 논문 설정은 14-20k).

- **OU dt = 0.01은 한 시드가 실패했습니다**(−787). 나머지 넷은 풀었습니다. §3에서 본 대로 에피소드 초반 잡음이 거의 없어서 탐색이 약해진 결과로 보입니다. 시드 5개로는 유의하지 않습니다.
- **잡음이 없어도 5개 중 3개는 풀었습니다.** 진자는 초기 상태가 무작위라 탐색 부담이 작습니다. 잡음의 역할을 보기에는 약한 과제입니다.

Q 추정 편향 (Fig. 3 주장 확인): 학습 뒤 $Q(s_0, \mu(s_0))$를 같은 초기 상태에서 1,000 step 굴린 실제 할인 return과 비교했습니다.

- 논문 설정은 다섯 시드 모두 과대추정이었습니다(+1.4%, +7.4%, +22.3%, +4.0%, +11.7%. Wilcoxon p = 0.06, 5개라 검정력의 한계).
- 잘 풀린 세 설정(논문, L2 없음, 가우시안)을 합치면 15개 중 13개가 과대추정이고 평균 +6.7%입니다.
- 진자 같은 단순 과제에서도 체계적 과대추정이 있었습니다. "편향 없이 정확하다"는 Fig. 3의 해석은 이 toy에서는 재현되지 않았습니다. 그림의 축 단위가 "임의"라서 원 논문의 편향 크기를 직접 비교할 수는 없습니다.

toy의 한계: 망이 작고(64-64), BN이 없고, 과제가 하나이며, 시드가 5개입니다. 결론은 "이 설정에서의 경향"으로만 읽어야 합니다. 실행 시간은 다른 작업과 CPU를 나눠 써서 70분이 걸렸습니다. 단독으로 실행하면 몇 분 수준으로 추정합니다(3k step 실측 0.8초에서 환산하면 시드 하나 40k step에 약 15-20초).

6. 파라미터 수 확인 (부록 7절)

400-300 구조에 Table 2의 관측·행동 차원을 넣으면, actor는 122,201-164,209개, critic은 122,501-164,501개입니다(cheetah: actor 129,306, critic 129,601). "약 13만"은 두 망의 합이 아니라 **각 망의 크기**입니다.

픽셀 망은 커널과 stride가 적혀 있지 않습니다. 세 합성곱 층이 같은 커널·stride를 쓴다고 가정하고 k = 2-8, stride 1-4, valid/same padding을 모두 넣어 봤습니다. 가장 가까운 설정(k 2, stride 2)도 46만 개로 43만에서 7% 벗어납니다. 층마다 설정이 달랐을 것으로 보이며, 논문만으로는 픽셀 망을 복원할 수 없습니다.

추가 검증 (2026-11-11)

추가 검증 1: 배치 정규화 × 표적망, 선형-이차(LQR) 과제

목적. 논문의 "배치 정규화도 필요하다"(Sec. 4, 표 1에 "표적망만" 열이 없음)가 toy 수준에서 성립하는지 본다. 같은 과제에서 표적망 유무와 BN 위치를 함께 바꿔, BN의 효과가 표적망과 어떻게 얽히는지 확인한다. 과제 난이도가 낮아 결과가 한쪽으로 치우치지 않도록 최적 정책을 아는 LQR을 골랐다. 스크립트는 `analysis/extra_lqr_bn.py`, 결과는 `analysis/extra_lqr_bn_results.json`이다.

설정.

- 과제: 이산시간 선형 시스템 $x' = Ax + Bu$, $A = [[0.95, 0.1], [0, 0.9]]$, $B = [0.005, 0.1]^T$, 비용 $x^TQx + Ru^2$, $Q = \mathrm{diag}(1, 0.1)$, $R = 0.1$, $\gamma = 0.99$, 에피소드 100 step, 결정적 동역학. 최적 정책 $K = [1.76, 1.35]$를 할인 Riccati 반복으로 구했고, 행동은 ±5로 클리핑한다.
- 관측: $o = \mathrm{diag}(1, c) \cdot x$. c = 1은 척도가 같은 경우, c = 20은 속도 척도가 20배 큰 경우다. c = 20은 우리가 넣은 설정이라 BN 효과가 척도에 따라 달라질 수 있다.
- 망: ddpg_toy.py와 같이 64-64, ReLU, tanh 출력(×5), 행동은 두 번째 은닉층에 합류, Adam 1e-4(actor)·1e-3(critic), 배치 64, 환경 step마다 업데이트 1번, critic L2 없음. 탐색 잡음은 가우시안 $\sigma = 0.5$.
- BN 위치 세 가지: 없음, 입력만, 입력과 모든 은닉층 선형 출력(논문 부록식 "all"). 학습 때는 배치 통계, 평가 때는 이동 평균(momentum 0.05)을 쓴다. 표적망은 배치 통계로 계산한다.
- 표적망: $\tau = 0.001$ 또는 없음(목표를 온라인 망으로 계산).
- 시드 8개, 30,000 step. 평가는 고정 초기 상태 20개에서 결정적 정책의 할인 비용을 같은 100 step 기준으로 재고, 최적 정책 비용으로 나눈다(비용비, 1이 최적).
- 그래디언트 점검: BN 모드 "all"과 "input" 모두 파라미터별 중앙 차분과 비교했고, 최대 상대 오차는 각각 2.7×10^{-5}와 0이다.

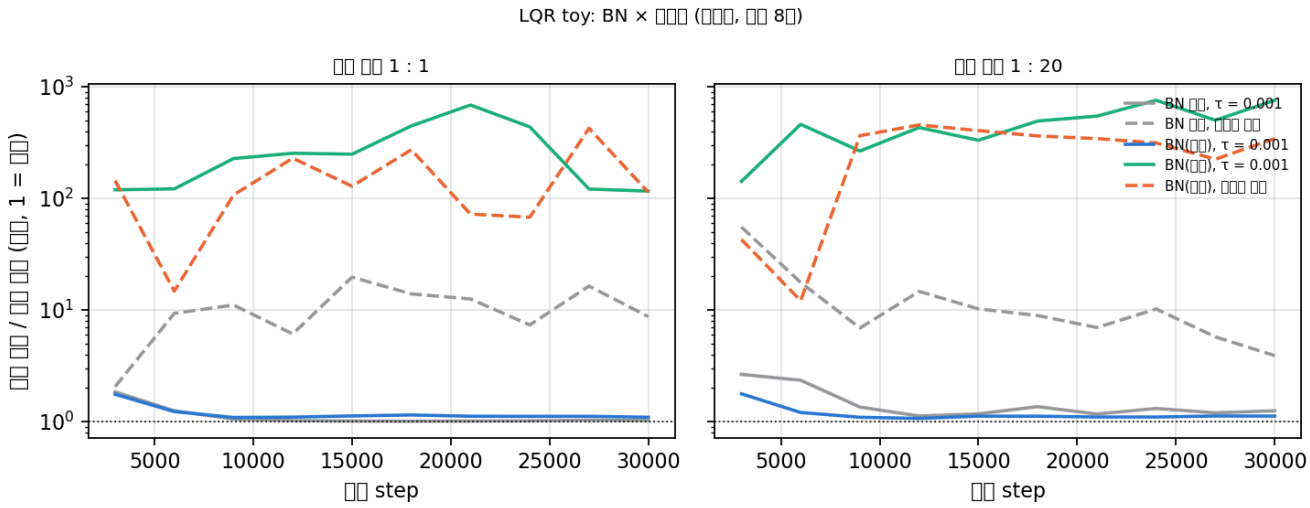
결과. 비용비의 중앙값과 평균(시드 8개), 1.5 미만을 기록한 시드 수는 다음과 같다.

관측 척도	BN	표적망	중앙값	평균	< 1.5인 시드
1	없음	$\tau = 0.001$	**1.02**	1.02	8/8
1	없음	없음	8.7	16.3	1/8

관측 척도	BN	표적망	중앙값	평균	< 1.5인 시드
1	입력	τ = 0.001	1.09	1.14	8/8
1	입력	없음	12.4	158.7	0/8
1	전체	τ = 0.001	116.0	361.7	0/8
1	전체	없음	113.5	344.1	0/8
20	없음	τ = 0.001	1.25	2.05	5/8
20	없음	없음	3.9	6.7	1/8
20	입력	τ = 0.001	**1.12**	1.14	8/8
20	입력	없음	2.5	28.0	1/8
20	전체	τ = 0.001	755.9	682.7	0/8
20	전체	없음	343.3	425.0	0/8

Mann-Whitney 검정(시드 단위, 8 대 8):

비교	관측 척도 1	관측 척도 20
전체 BN의 효과 (표적망 τ = 0.001)	p = 0.0002 (악화)	p = 0.0002 (악화)
전체 BN의 효과 (표적망 없음)	p = 0.002 (악화)	p = 0.0002 (악화)
입력 BN의 효과 (표적망 τ = 0.001)	p = 0.015 (1.02 → 1.09, 약간 악화)	p = 0.51 (1.25 → 1.12, 차이 없음)
표적망 효과 (BN 없음)	p = 0.0006 (8.7 → 1.02)	p = 0.038 (3.9 → 1.25)
표적망 효과 (전체 BN)	p = 0.65	p = 0.44



결론.

- 표적망은 BN이 없을 때 결과를 가른다. 표적망이 있으면 BN 없이 시드 8개 모두 최적의 1.5배 안에 들어간다. 표적망이 없으면 같은 설정에서 대부분 실패한다. 이는 §5의 진자 toy와 같은 방향이고, 논문의 "표적망이 결정적"과 맞는다.
- 논문의 "BN도 필요하다"는 이 toy에서 재현되지 않았다. 입력과 모든 은닉층에 BN을 넣으면(논문 부록식) 두 표적망 설정 모두에서 학습이 크게 나빠졌다. 입력에만 넣으면 차이가 작고 방향도 척도에 따라 다르다. 따라서 이 toy에서 BN은 "필요"하지 않고, 은닉층까지 넣으면 해롭다.
- 전체 BN이 해로운 원인은 검증하지 않았다. 가능성으로는 행동이 BN을 거친 두 번째 은닉층에 합류하여 배치 통계가 행동의 기여를 정규화하는 것이 있다. 이것은 가설이다. 구현이 틀렸을 가능성은 파라미터별 그래디언트 점검으로 줄였다.

한계.

- 이 과제는 판별력이 약하다. 토크 0 정책의 비용비가 2.13이라, 실패와 성공의 차이가 2배 수준에 머문다. 그래서 "실패"(비용비 1.5 이상)는 토크 0 정책보다 낮은 기준이다. 판별 범위가 좁다는 뜻이다.
- 개루프가 불안정한 설정(고유값 1.0)을 먼저 시도했을 때는 표적망이 있는 기준선도 상태가 발산하여 비교가 불가능했다. 그래서 개루프를 안정한 설정으로 바꿨고, 이 선택이 결과에 영향을 줬을 수 있다.
- 하이퍼파라미터는 논문 설정 하나만 썼고 BN 설정마다 튜닝하지 않았다. BN이 학습률에 민감하다면 결론이 달라질 수 있다.
- 시드 8개, 고정된 평가 상태 20개, 망 폭 64-64. 논문의 26개 과제나 픽셀 입력으로 옮길 수 없다.

04. 코드 검증: 논문 ↔ 주요 구현 대조, 수치 재계산, 구현 가능성

- **대상:** 공식 코드가 없어서 널리 쓰이는 구현 4종을 논문 부록 7절과 대조했습니다. 필요한 파일만 받았습니다(`code/` , `.gitignore`).
  - `DLR-RM/stable-baselines3` @ `0cdcd20` : `ddpg/ddpg.py` , `td3/td3.py` , `td3/policies.py` , `common/noise.py`
  - `openai/spinningup` @ `038665d` : `spinup/algos/pytorch/ddpg/{ddpg,core}.py`
  - `sfujim/TD3` @ `34770cc` : `DDPG.py` , `OurDDPG.py` , `main.py` , `utils.py`
  - `openai/baselines` @ `ea25b9e` : `baselines/ddpg/{ddpg,ddpg_learner,models,noise,memory}.py` , `common/models.py`
  - OU 잡음 비교용: `rll/rllab` @ `ba78e4c` 의 `exploration_strategies/ou_strategy.py` , `algos/ddpg.py`
- **범위:** 코드 읽기, 수치 재계산, numpy toy만 했습니다. 각 구현을 실행하지는 않았습니다(torch, gymnasium, MuJoCo 설치가 필요).

1. 하이퍼파라미터 대조

✅ 논문과 같음, ⚠️ 부분적으로 다름, ❌ 다름

항목	논문 (부록 7절)	sfujim/TD3 `DDPG.py`	SB3 `DDPG` 기본값	Spinning Up `ddpg` 기본값	OpenAI baselines `ddpg.learn` 기본값
은닉층	400-300 ReLU	✅ 400-300 ReLU	✅ 400-300 ReLU	❌ 256-256 ReLU	❌ `mlp` 빌더 기본 2×64 tanh
critic의 행동 합류 위치	두 번째 은닉층	✅ 두 번째 층	❌ 입력층	❌ 입력층	❌ 입력층
배치 정규화	상태 입력, μ 전 층, Q의 행동 합류 전 층	❌ 없음	❌ 없음	❌ 없음	⚠️ 없음. 대신 관측 running 정규화 (기본 켬), layer norm 선택
마지막 층 초기화	$U(\pm 3\times10^{-3})$	❌ PyTorch 기본	❌ PyTorch 기본	❌ PyTorch 기본	✅ $U(\pm 3\times10^{-3})$
actor / critic 학습률	10^{-4} / 10^{-3}	✅ 10^{-4} / 10^{-3}	❌ 10^{-3} / 10^{-3}	❌ 10^{-3} / 10^{-3}	✅ 10^{-4} / 10^{-3}
critic L2	10^{-2}	⚠️ Adam `weight_decay` 10^{-2} (bias 포함)	❌ 없음	❌ 없음	✅ 10^{-2} (은닉 가중치만)
τ	0.001	⚠️ 클래스 0.001, `main.py` 실행 시 0.005	❌ 0.005	❌ 0.005 (polyak 0.995)	❌ 0.01
minibatch	64	⚠️ 클래스 64, `main.py` 실행 시 256	❌ 256	❌ 100	✅ 64
재생 버퍼	10^6	✅	✅	✅	✅
γ	0.99	✅	✅	✅	✅
탐색 잡음	OU θ 0.15, σ 0.2 (dt 없음)	❌ 가우시안 0.1	❌ 기본 없음. OU를 주면 dt 0.01	❌ 가우시안 0.1	❌ 파라미터 공간 잡음 0.2. OU는 dt 0.01
학습 전 무작위 행동	언급 없음	25,000 step 균등 무작위	100 step 후 학습 시작	10,000 step 균등 무작위	없음
업데이트 비율	환경 step당 1번	1	1	50 step마다 50번 (= 1)	100 step 수집마다 50번 (= 0.5)
시간 제한 종료	언급 없음	시간 제한이면 bootstrap	버퍼 옵션	시간 제한이면 bootstrap	환경의 `done` 을 그대로 저장 (시간 제한도 종료로 취급)

2. 차이와 영향 (D1-D9)

#	내용	영향
D1	**배치 정규화가 주요 구현에서 모두 빠졌습니다.** 논문은 관측 단위 차이를 해결하는 핵심 장치로 소개했지만, SB3·Spinning Up·TD3 저장소에는 없고, baselines는 관측 running 정규화로 대신합니다.	논문 Fig. 2에서도 표적망만 쓴 변형과 BN까지 쓴 변형이 여러 과제에서 겹칩니다(`01` §3.3). 오늘날 DDPG는 사실상 "BN 없는 DDPG"입니다. 표적망 대신 정규화로 안정화하려는 CrossQ 계열이 이 질문을 다시 다룹니다.
D2	**critic의 행동 합류 위치가 다릅니다.** 논문은 두 번째 은닉층에서 합류하고, SB3·Spinning Up·baselines는 입력층에서 상태와 이어 붙입니다.	행동을 늦게 넣으면 첫 층이 상태 특징만 학습합니다. 논문에서는 BN을 행동 합류 전 층에만 적용하기 위한 구조이기도 합니다. 성능 차이는 보고된 적이 없고 이 분석에서도 측정하지 않았습니다.
D3	**TD3 저장소의 "논문 재현" `DDPG.py` 도 기본 실행에서는 논문 값이 아닙니다.** `main.py`가 `--tau`(기본 0.005)와 `--batch_size`(기본 256)를 모든 정책에 넘기므로, 클래스 기본값(τ 0.001, 배치 64)이 덮어써집니다. 탐색도 가우시안 0.1이고 처음 25,000 step은 무작위입니다.	이 저장소로 "원래 DDPG" 결과를 냈다면 실제 설정이 무엇이었는지 확인해야 합니다. 논문 설정을 원하면 `--tau 0.001 --batch_size 64`를 명시해야 합니다.
D4	**SB3 DDPG는 TD3의 특수 경우입니다**(`policy_delay=1`, `n_critics=1`, `target_noise_clip=0`). 표적 정책 평활화 잡음은 0.1로 두지만 clip이 0이라 실제로는 0이 됩니다. 기본 `action_noise=None`이라 사용자가 잡음을 주지 않으면 탐색 잡음 없이 학습합니다.	비교 실험이 쉬운 대신, 기본값만으로 돌리면 "잡음 없는 DDPG"가 됩니다. toy에서 잡음 없음은 5개 시드 중 2개가 실패했습니다(`03` §5).
D5	**OU 잡음의 dt가 구현마다 100배 다릅니다.** rllab은 dt = 1(dx = θ(μ−x) + σ·ε), baselines와 SB3는 dt = 0.01이 기본입니다. 논문은 θ, σ만 줍니다.	상관 시간이 6 step과 666 step으로 다르고, 에피소드마다 0에서 다시 시작하면 dt 0.01의 잡음은 초반에 거의 0입니다(`03` §3). "OU(0.15, 0.2)를 썼다"는 기술만으로는 탐색을 재현할 수 없습니다.
D6	**critic L2의 적용 범위가 다릅니다.** TD3 저장소는 Adam `weight_decay`로 bias까지 감쇠합니다. baselines는 출력층을 뺀 은닉 가중치에만 적용합니다. 논문은 "Q에 L2 10^{-2}"라고만 적었습니다.	toy에서는 L2를 빼도 성능이 비슷하거나 약간 나았습니다(−151 vs −163, p = 0.14). 영향은 작아 보이지만 과제와 보상 크기에 따라 다를 수 있습니다.
D7	**마지막 층 초기화(±3×10^{-3})를 PyTorch 구현들이 따르지 않습니다.** baselines만 논문과 같습니다.	초기 Q와 행동을 0 근처에 두려는 장치입니다. PyTorch 기본 초기화도 출력이 작은 편이라 영향은 크지 않을 것으로 보이지만 측정하지 않았습니다.
D8	**학습 전 무작위 탐색과 시간 제한 처리가 구현마다 다르고, 논문에는 없습니다.** TD3 저장소와 Spinning Up은 균등 무작위 행동으로 시작하고 시간 제한 종료에서 bootstrap합니다.	시간 제한을 종료로 취급하면 마지막 상태의 가치가 0으로 학습되어 편향이 생깁니다. 논문이 어느 쪽인지 알 수 없습니다.
D9	**논문 본문의 사소한 오류**: 배치 정규화가 "unit mean and variance"로 정규화한다고 썼습니다(실제로는 평균 0, 분산 1). 픽셀 마지막 층 초기화 범위 "[3×10^{-4}, 3×10^{-4}]"는 음수 부호가 빠졌습니다. μ : S ← A는 화살표 방향이 반대입니다.	재현에는 영향이 없습니다.

3. 수치 재계산 (`analysis/table_check.py`, `analysis/ddpg_toy.py`)

#	주장 (출처)	재계산	판정
C1	계획기와 견줄 만한 정책 (Abstract)	저차원 평균 0.718(중앙값 0.712). 최고 시드 평균 1.078	최고 시드 기준 ✅, 평균은 계획기의 약 72%
C2	일부 시드는 계획기보다 낫다 (Sec. 4)	평균 기준 2개 과제, 최고 시드 기준 10개(저차원). 픽셀은 2개, 8개	✅ ("some replicas"라는 표현과 일치)
C3	표적망이 결정적 (Fig. 2, Sec. 4)	DDPG > DPG + BN이 평균 기준 25/26 과제, 평균 차이 +0.50, Wilcoxon p = 6×10^{-8}. toy에서도 표적망 없이는 0/5	✅
C3b	배치 정규화도 필요 (Sec. 4)	Table 1에 "표적망만" 열이 없음. Fig. 2에서 진회색과 초록이 여러 과제에서 겹침	⚠️ 근거 약함
C3c	단순 과제는 픽셀도 저차원만큼 (Sec. 4)	평균 기준 픽셀 ≥ 저차원은 5/26 과제, 평균 차이 −0.22	✅ (일부 과제에 한정)
C4	같은 설정으로 강건하게 푼다 (Abstract, Sec. 6)	시드 표준편차 하한: canada ≥ 0.80, walker2d ≥ 0.49, 중앙값 0.17 (R_best 정의에 따라 조건부)	⚠️ 퍼짐이 큼

#	주장 (출처)	재계산	판정
C5	20개 넘는 과제 (Abstract)	Table 2는 32개, Table 1은 26개 + Torcs. 6개 환경은 결과 없음	✅ (목록 불일치는 있음)
C6	저차원 망 약 13만 파라미터 (부록 7절)	actor 122k-164k, critic 123k-165k (cheetah 129,306 / 129,601)	✅ 각 망 기준
C7	픽셀 망 약 43만 파라미터	세 층이 같은 커널·stride라고 가정하면 가장 가까운 설정이 46만(+7%)	⚠️ 구조 복원 불가
C8	DQN보다 20배 적은 step (Sec. 6)	5천만 / 250만 = 20은 프레임 대 행동 step. 행동 step끼리 비교하면 5배, 픽셀 과제의 시뮬레이션 프레임 기준 6.7배	⚠️ 단위 혼합 (DQN 수치는 사전 지식)
C9	단순 과제에서 Q 추정에 체계적 편향 없음 (Fig. 3)	toy 진자: 잘 풀린 설정 15개 시드 중 13개 과대추정, 평균 +6.7%	⚠️ toy에서는 재현 안 됨
C10	하나의 하이퍼파라미터 집합 (Sec. 1)	Torcs는 탐색 잡음을 바꿨다고 본문에 적혀 있음. 픽셀은 배치 16	⚠️ 예외 있음

4. 구현 가능성 판단

4.1 논문 결과를 그대로 재현하는 경우

불가능합니다. 공식 코드가 없고, 32개 MuJoCo 과제와 Torcs 설정, 정규화 기준인 iLQG 계획기도 공개되지 않았습니다. Table 1의 0과 1이 모두 비공개 구현에 묶여 있습니다. 픽셀 망 구조(커널, stride)와 OU dt도 빠져 있습니다.

4.2 알고리즘을 재구현하거나 공개 구현을 쓰는 경우

경로	판단	필요한 것
numpy toy (진자)	✅ 완료	추가 설치 없음. `ddpg_toy.py`
SB3 DDPG로 gymnasium Pendulum, MuJoCo 과제(HalfCheetah, Hopper, Walker2d 등)	이 맥에서 가능 (설치 승인 필요)	`torch`, `stable-baselines3`, `gymnasium[mujoco]`. MuJoCo와 소형 MLP는 macOS CPU에서 돌아갑니다. 100만 step이면 과제당 수 시간 예상(미측정)
논문 설정 그대로의 DDPG(BN, 두 번째 층 합류, OU, L2)	쉬움	약 150줄. TD3 저장소 `DDPG.py`에 BN과 OU를 더하는 정도
픽셀 입력 DDPG (dm_control 과제)	조건부	렌더링과 CNN 학습이 필요합니다. Apple GPU(MPS)를 쓸 수 있지만 macOS의 dm_control 오프스크린 렌더링은 확인하지 않았습니다
CUDA 전용 요소	해당 없음	DDPG 자체는 CUDA가 필요하지 않습니다

요약: 논문 표를 재현할 수는 없지만, 알고리즘은 짧고 공개 구현이 많아서 직접 쓰거나 재구현하기는 매우 쉽습니다. 실제로 쓸 때는 구현마다 BN, τ, 잡음, 배치, 행동 합류 위치가 논문과 다르다는 점(§1)을 알고 설정을 명시해야 합니다. 저차원 MuJoCo 실험은 이 맥(CPU)에서 할 수 있고, 패키지 설치만 승인받으면 됩니다.

02. 선행연구, 후속 계보, 공개 구현

논문 참고문헌은 저자-연도로 표기합니다(이 논문은 번호 인용을 쓰지 않습니다). 후속 연구의 arXiv ID는 TD3(`1802.09477`, FlashSAC 코드 주석에서 확인)만 확인했고, 나머지는 내 사전 지식이라 게시 전에 확인해야 합니다.

1. 계보도

```
[연속 행동 actor-critic]
  Prokhorov & Wunsch 1997 (adaptive critic designs)
  NFQCA (Hafner & Riedmiller 2011)     신경망 actor-critic, 배치 학습
  DPG (Silver et al. 2014)              결정적 정책 경사 정리, 선형·타일 코딩 근사
  SVG(0) (Heess et al. 2015)            Q-critic + 확률적 정책 (DPG는 그 결정적 극한)
        |
[DQN의 안정화 장치]  DQN (Mnih et al. 2013, 2015): 재생 버퍼 + 표적망
        |
  ★ DDPG (Lillicrap et al. 2016) = DPG + 재생 버퍼 + soft 표적망 + 배치 정규화 + OU 잡음
        |
  ├─ TD3 (Fujimoto et al. 2018, arXiv:1802.09477)   과대추정 대응: twin Q의 최솟값, 표적 정책 평활화, actor 지연 업데이트
  ├─ SAC (Haarnoja et al. 2018)                      확률적 정책 + 최대 엔트로피, 자동 온도 조절
  ├─ D4PG (Barth-Maron et al. 2018)                  분포형 critic, n-step, 분산 수집
  ├─ 파라미터 공간 잡음 (Plappert et al. 2018)        OpenAI baselines DDPG의 기본 탐색
  ├─ CrossQ (Bhatt et al. 2024)                      critic에 batch renorm, 표적망 제거 → DDPG의 BN 주장을 다시 꺼냄
  └─ 대규모 off-policy: FlashSAC (Kim et al. 2026)   범주형 critic, twin-Q 앙상블, 큰 버퍼·critic (이 저장소 flashdexretarget/)
```

DDPG의 위치: 알고리즘 자체(Eq. 6)는 DPG와 같습니다. 기여는 "신경망으로 키울 때 무엇이 필요한가"를 보인 공학적 조합과 대규모 평가입니다. 이후 계보는 대부분 DDPG의 약점을 고치는 방향입니다. TD3는 과대추정, SAC는 탐색과 민감도, D4PG는 분포와 규모, CrossQ는 표적망 대신 정규화를 다룹니다.

2. 구성 요소별 출처

구성 요소	출처	DDPG에서의 쓰임
결정적 정책 경사 (Eq. 6)	Silver et al. 2014	actor 업데이트
off-policy Q 학습 (Eq. 4-5)	Watkins & Dayan 1992	critic 업데이트
재생 버퍼, 표적망	Mnih et al. 2013, 2015 (DQN)	버퍼 10^6. 표적망은 hard copy 대신 soft update($\tau = 0.001$)
배치 정규화	Ioffe & Szegedy 2015	관측 단위 차이 해소
자기상관 탐색 잡음	Uhlenbeck & Ornstein 1930, Wawrzyński 2015	OU 과정 $\theta = 0.15$, $\sigma = 0.2$
Adam	Kingma & Ba 2014	actor 10^{-4}, critic 10^{-3}
ReLU	Glorot et al. 2011	은닉층
비교 기준 계획기	iLQG (Todorov & Li 2005), MPC (Tassa et al. 2012)	정규화 점수 1
재생 버퍼 actor-critic 선행	Wawrzyński 2009, Wawrzyński & Tanwani 2013	cheetah 환경 출처이기도 함

3. 이 저장소의 다른 논문과의 관계

논문	관계
FlashDexRetarget (`flashdexretarget/`)	FlashSAC 학습기는 DDPG 계보의 직계 후손입니다. 재생 버퍼, soft 표적망($\tau = 0.01$), 결정적 경사를 대신하는 재매개화 경사, TD3의 twin-Q(코드 주석에 arXiv:1802.09477 인용)를 씁니다. 그 논문의 Fig. 4(d)에서 버퍼(10M → 50M)와 critic 폭(256 → 1024)이 성능 차이의 대부분을 만든 결과는, DDPG가 처음 보인 "off-policy + 재생 버퍼"의 데이터 효율이 규모를 키워도 유지된다는 사례입니다.

논문	관계
DexScrew (`dexscrew/`)	PPO(on-policy)로 손가락 기술을 학습합니다. DDPG 논문은 TRPO 같은 on-policy 방법이 "데이터 효율이 상당히 낮아 보인다"고 했고(Sec. 5), FlashDexRetarget은 다중 레퍼런스 설정에서 같은 스텝 예산이면 PPO가 거의 0이라는 결과를 냈습니다. 한 과제만 학습하는 DexScrew 설정에 바로 적용되지는 않습니다.

4. 공개 구현 (GitHub)

DeepMind는 이 논문의 코드를 공개하지 않았습니다. 아래 표는 2026-10-28에 `gh api` 로 확인한 값입니다. "대조"는 이 분석의 `04` 에서 실제로 코드를 읽어 논문과 비교한 구현입니다.

저장소	공식 여부	프레임워크	라이선스	별	마지막 push	확인 커밋	DDPG 파일	대조
DLR-RM/stable-baselines3	비공식 (유지보수 활발)	PyTorch	MIT	13,940	2026-10-26	`0cdcd20`	`stable_baselines3/ddpg/ddpg.py` (TD3의 하위 클래스)	✅
openai/spinningup	비공식 (교육용)	PyTorch / TF1	MIT	12,019	2024-08-05	`038665d`	`spinup/algos/pytorch/ddpg/ddpg.py`	✅
sfujim/TD3	TD3 저자 공식, DDPG는 재구현	PyTorch	MIT	2,118	2023-07-14	`34770cc`	`DDPG.py` (논문 재현), `OurDDPG.py` (재조정)	✅
openai/baselines	비공식 (유지보수 중단)	TF1	MIT	16,773	2024-08-01	`ea25b9e`	`baselines/ddpg/`	✅
rll/rllab	비공식, 벤치마크 논문용 (유지보수 중단)	Theano	라이선스 파일 비표준	3,079	2023-06-10	`ba78e4c`	`rllab/algos/ddpg.py` , `exploration_strategies/ou_strategy.py`	OU·기본값만
vwxyzjn/cleanrl	비공식 (단일 파일)	PyTorch / JAX	비표준 표기	10,611	2026-04-20	`fe8d8a0`	`cleanrl/ddpg_continuous_action.py`	목록만
google-deepmind/acme	DeepMind 라이브러리 (이 논문 코드는 아님)	TF / JAX	Apache-2.0	4,082	2026-10-23	`2e09e3d`	`acme/agents/tf/ddpg/`	목록만
tensorflow/agents	Google 라이브러리	TF2	Apache-2.0	3,031	2026-01-16	`eb24cf5`	`tf_agents/agents/ddpg/`	목록만
thu-ml/tianshou	비공식	PyTorch	MIT	11,042	2026-04-03	`f240205`	`tianshou/algorithm/modelfree/ddpg.py`	목록만
rlworkgroup/garage	비공식, rllab 후속 (유지보수 중단)	TF / PyTorch	MIT	2,130	2023-05-04	`2d59480`	`src/garage/torch/algos/ddpg.py`	목록만
pfnet/pfrl	비공식	PyTorch	MIT	1,277	2026-03-02	`3578e33`	`pfrl/agents/ddpg.py`	목록만

저장소	공식 여부	프레임워크	라이선스	별	마지막 push	확인 커밋	DDPG 파일	대조
keras-rl/keras-rl	비공식 (유지보수 중단)	Keras	MIT	5,548	2023-09-17	`216c314`	`rl/agents/ddpg.py`	목록만

고르는 기준: 지금 실험에 쓸 기준선이라면 **SB3**입니다. 유지보수가 활발하고, DDPG가 TD3의 특수 경우로 구현되어 비교 실험이 쉽습니다. 논문 설정에 가장 가까운 코드를 보려면 **sfujim/TD3의 `DDPG.py`**입니다. 다만 저장소의 `main.py`로 실행하면 τ와 배치가 TD3 기본값으로 덮어써집니다(`04` D3). 알고리즘을 공부하려면 **Spinning Up** 문서와 코드가 가장 읽기 쉽습니다. OpenAI baselines와 rllab은 역사적 참고용입니다.

5. 논문이 다루지 않았지만 관련 있는 연구 (내 판단)

주제	관련성	근거 수준
결정적 정책 경사의 off-policy 편향 (Degris et al. 2012의 off-policy actor-critic 분석 등)	Eq. 6은 행동 분포 ρ^β에서 기댓값을 취하므로 엄밀한 경사가 아닙니다. 버퍼가 클수록 이 편향이 커질 수 있습니다(`03` §1).	내 해석, 서지 확인 필요
Pink noise 탐색 (Eberhard et al., ICLR 2023)	OU(빨간 잡음)와 백색 잡음 사이의 상관 구조를 고르는 문제를 정면으로 다룹니다. OU dt 모호성(`04` D5)과 바로 연결됩니다.	내 사전 지식, 서지 확인 필요
LQR을 이용한 actor-critic 단위 시험	선형-이차 문제는 최적 제어기를 알 수 있어서 구현 검증에 쓸 수 있습니다.	내 해석
HJB 잔차를 쓰는 연속 시간 가치 학습	critic이 만족해야 하는 Bellman 식의 연속 시간 극한(HJB 편미분방정식)을 PINN식 손실로 넣는 계열입니다. PINN 연구와 이어집니다.	내 사전 지식, 서지 확인 필요

한계: 1절과 5절의 후속 연구 서지는 TD3를 빼면 내 사전 지식에 근거합니다. 블로그나 git에 올리기 전에 원문을 직접 확인해야 합니다.