DexTouch-WM: 분석 리포트

arXiv:2609.20649 v2 · IROS 2026 워크숍(RoBoWoMo) 라이트닝 토크(본 트랙 아님) · 저자 Qin, Chen, Lin, Liu, Lyu, Su, Jin, Yu, Luo, Ding, Chen, Xu · 공식 코드 없음(GitHub·웹 조사) · 분석일 2026-11-10 · 게시용 버전: 논문 그림 없이 우리가 그린 그래프만 포함

핵심 요약

1. **무엇을 하는가:** 사람과 로봇 손에 같은 압전저항 촉각 배치를 달고, 사람 손 motion을 로봇 행동 공간으로 IK 리타게팅합니다. 사전학습 비디오 DiT(Wan2.2-TI2V-5B)에 촉각 전문가를 MoT로 붙여 RGB와 양손 촉각을 함께 예측합니다.
2. **스케일링 결과는 방향이 분명하다:** 로봇 5시간을 고정하고 사람 데이터를 0→100시간으로 늘리면 PSNR +3.6 dB, Contact-IoU 0.415→0.588입니다. 재계산은 본문과 맞습니다. 다만 한 번 학습한 결과이고 시드·분산이 없습니다.
3. **정책 평가 상관은 통계적으로 약하다:** 정책 3개로 계산한 Pearson은 $p<0.05$가 되려면 $|r|\geq 0.997$이 필요합니다. 본문 최댓값(0.972)도 $p\approx 0.15$입니다.
4. **시뮬레이터 점수는 실제보다 높게 나온다:** 같은 정책·과제 12셀에서 평균 +0.12(WM-Robot), +0.18(WM-Mix)입니다. 순위는 맞아도 성공률 절대값은 과대평가됩니다.
5. **합성 데이터의 이득은 정책마다 다르다:** 대조군이 실제 데이터를 두 배 씁니다. FTP-1은 거의 같고, π0.5(−0.131)와 X-VLA(−0.100)는 떨어집니다.
6. **사람 촉각 전이의 조건:** 토이에서 사람 데이터 이득은 도메인 격차와 리타게팅 오차가 작을 때만 양수입니다. 논문은 리타게팅 오차를 측정하지 않았습니다.
7. **희소 촉각 지표:** 접촉 3%에서 zero 예측은 MSE가 위치만 1칸 틀린 예측보다 낮습니다. 접촉 지표를 MSE와 함께 써야 합니다.
8. **구현 가능성:** 공식 재현은 불가(코드·가중치·데이터 없음). 이 맥(M4 Pro, CUDA 없음)에서 재현 불가, 토이와 소형 검증만 가능. 설계 아이디어는 중간에서 높은 노력으로 새로 구현할 수 있고, 병목은 촉각 장갑 두 벌과 사람 데이터 수집입니다.
9. **v1 → v2:** 본문 텍스트는 같고 저자 목록에 한 명이 추가되었습니다.

DexTouch-WM 논문 분석 (arXiv:2609.20649)

논문: DexTouch-WM: Learning Action-Conditioned Tactile World Models from Human Touch for Dexterous Robot Manipulation **저자:** Yan Qin, Yue Chen, Wenwei Lin, Shujia Liu, Chuqiao Lyu, Kailun Su, Weiyang Jin, Chenze Yu, Ping Luo, Wenbo Ding, Tianxing Chen, Renjing Xu (12명, 공동 제1저자 4명 *, 교신 3명 †) **arXiv:** 2609.20649 · 최신 v2 (2026-09-18) · cs.RO · 본문 8쪽, 부록 없음 **학회 위치:** arXiv 댓글 "Accept to IROS 2026 Workshop RoBoWoMo (Lightning Talk)". **IROS 2026 본 트랙 논문이 아니라 워크숍 논문(라이트닝 토크)입니다.** 실험 규모와 보고 깊이는 본 트랙 기준보다 얇게 읽어야 합니다. **라이선스:** arXiv 비독점 배포 1.0 (nonexclusive-distrib). CC BY가 아니므로 논문 그림은 개인용 리포트·PPT에만 쓰고 공개 산출물에는 넣지 않습니다(README 참고).

---

1. 한 문단 요약

사람 손에 건 압전저항 장갑(촉각 360 taxel/손, 그중 320개 사용)과 로봇 손(Wuji 20-DoF)에 같은 센서 배치를 달고, 사람 손 motion을 로봇 행동 공간으로 리타게팅(IK)합니다. 이렇게 하면 사람 데이터를 로봇용 행동조건 세계모델 학습에 그대로 쓸 수 있다는 것이 핵심 주장입니다. 모델은 사전학습 비디오 DiT(Wan2.2-TI2V-5B)에 경량 촉각 전문가(TactileDiT)를 Mixture-of-Transformers 방식으로 붙여 RGB와 양손 촉각을 함께 예측합니다. 실험의 핵심 질문은 "로봇 데이터를 5시간으로 고정하고 사람 데이터를 0→10→50→100시간으로 늘리면 로봇 도메인 예측이 좋아지는가"입니다(Table I). 결과는 좋아지는 방향이지만, 단일 실행·시드 미보고·검정 없음이라 "확실한 스케일링 법칙"이라고 하기는 어렵습니다. 정책 평가(Table II-III)와 데이터 생성(Table IV-V)은 정책 3개, 과제 4개 규모라 통계적으로 약합니다.

2. 문제 설정 (§III-A)

- 식 (1): $p_\theta(v_{1:T}, x_{1:T} \mid v_0, x_0, a_{1:T}, \ell)$. 초기 RGB v_0, 촉각 x_0, 언어 ℓ, 미래 자세 $a_{1:T}$를 받아 미래 RGB와 촉각을 예측.
- 행동은 두 도메인 모두 같은 67차원 표현: 양 손목 motion, 양 손 20-DoF, 머리 카메라 motion (식 (6)). 67차원 구성 요소별 차원 수는 본문에 없어 추정하지 않았습니다.
- 사람 데이터: 25-keypoint 손 골격 + 손목 6-DoF(VIVE tracker) + 손 관절(MANUS) + 머리·손목 카메라. 장갑은 Moxian 촉각 장갑을 MANUS MetaGloves 아래 착용.

3. 방법

3.1 구조 (§III-B, Fig. 2)

- **시각 전문가:** Wan2.2-TI2V-5B DiT와 frozen video VAE. 첫 프레임은 깨끗한 잠재(시간 index 0)로 유지하고 이후 잠재만 노이즈를 넣어 예측.
- **촉각 전문가 (TactileDiT):** 가벼운 DiT, frozen Split-Hands 인코더·디코더. 두 전문가는 bi-modal joint attention으로 정보를 교환하고, AdaLN과 FFN은 모달리티별로 따로 씀(MoT [10]).
- **조건:** 언어는 frozen text encoder, 자세는 AdaLN(식 (3)). 비디오는 4프레임 chunk, 촉각은 원래 프레임율로 조건을 넣음(dual-rate).

3.2 해부학적 촉각 토큰화 (§III-B "Anatomy-aware")

- 손당 320 taxel = 엄지~소지 손끝 5개 × 4×4(=80) + 손바닥 15×16(=240) (Fig. 3). 80+240=320으로 맞음.

- 조각 격자(Grid)는 손끝과 손바닥을 한 캔버스에 이어 붙임. 논문은 이것이 "인공적인 이웃"을 만든다고 보고, 손끝 공유 인코더 1개와 손바닥 공유 인코더 1개 + 패드 정체성 임베딩(Split-Hands)을 씀.
- Split-Hands는 contact 가중 재구성으로 사전학습 후 동결. 가중을 둔 이유는 비접촉 taxel이 대부분이라 표현을 지배하기 때문.
- 근거: Fig. 4 (Grid 대비 재구성 손실 낮고 Contact-IoU 수렴 빠름). **Fig. 4는 곡선만 있고 최종 수치가 없습니다.**

3.3 잔차 촉각 잠재 (식 (2))

- $z_t = E_x(x_t)$, $r_t = z_t - z_0$, $\hat{x}_t = D_x(z_0 + \hat{r}_t)$. 초기 촉각 배경 압력을 빼고 상호작용으로 생긴 변화만 예측.
- 손실 식 (4): $L = L_{video}^{FM} + \lambda_{tac} L_{tac}^{FM}$. 촉각 항은 "접촉 또는 시간에 따라 변하는 토큰"에서만 계산(마스크). **λ_{tac} 값과 마스크 기준(임계값)은 본문에 없습니다.**

3.4 사람→로봇 행동 정렬 (§III-D)

- 식 (5): $(e^h_t, J^h_t) \rightarrow (e^r_t, q^r_t)$, 사람 손목 자세와 손 기하를 캘리브레이션된 카메라-세계 정합 후 IK로 WujiHand2 (20-DoF) 자세에 매핑.
- 행동은 전부 첫 프레임 기준 상대 손목 motion (식 (6)).
- **리타게팅 오차를 정량화한 결과는 없습니다.** 키포인트 오차, 접촉 위치 불일치, 물체 자세 오차 등 어느 것도 보고하지 않습니다. "사람 촉각이 로봇에서 전이된다"는 주장이 이 단계에 기대고 있어서 가장 큰 빈칸입니다.

3.5 학습

- 조건부 flow matching [11]. 학습 스텝, 배치, 학습률, GPU 종류, 시드 수 모두 본문에 없음.

4. 실험

4.1 데이터 (§IV-A)

- 사람: 본문 두 곳이 어긋납니다. Introduction과 §IV-C는 "50 tasks", §IV-A 첫 문단은 "54 tasks". 같은 데이터인지 확인할 수 없어 상충으로 기록합니다. 총 약 100시간.
- 로봇: 10 과제, Tianji 팔 + Wuji 손. 6과제 5시간(사전학습), 나머지 4과제는 다운스트림. 6과제 held-out 로봇 에피소드 수는 본문에 없습니다.
- **모호한 점:** "Human and robot task sets are disjoint"라고 하는데, 평가하는 held-out 로봇 에피소드 6과제가 사전학습 6과제와 같은지 다른지 명시하지 않습니다. 같은 과제라면 "교차 과제 전이"보다는 "사람 데이터가 같은 로봇 과제의 예측을 돕는다"에 가깝습니다.

4.2 평가 지표 (§IV-A)

- 시각: PSNR, SSIM, LPIPS, Aesthetic/Image Quality(WorldArena [17]), JEPA similarity, Subject consistency, Semantic alignment, Trajectory accuracy, Geometry error. **Trajectory accuracy와 Geometry error의 정의는 본문에 없습니다.**
- 촉각: PSNR_taxel, SSIM_taxel, LPIPS_heatmap, MSE, MAE, Contact-MAE, Contact-IoU, Contact-F1. **접촉의 임계값, Contact-MAE가 접촉 칸만 보는지 여부 등 정의가 없습니다.**

4.3 Table I: 설계와 사람 데이터 스케일링 (§IV-B, §IV-C)

- 열: V-only, Cross-Attn, Robot-only(= Split-Hands + AdaLN), +10h, +50h, +100h(= DexTouch-WM). 모두 로봇 5시간 고정.

- 단일 값만 있고 분산·시드·신뢰구간이 없습니다. 재계산 결과(03 §1)는 본문 수치와 맞습니다(Table I의 소수 셋째 자리까지 재현).
- 핵심 수치: PSNR 23.47→27.10 (+3.62 dB), Trajectory Accuracy 0.891→0.962, Geometry 0.131→0.100, PSNR_taxel 24.81→29.18, Contact-IoU 0.415→0.588, Contact-F1 0.551→0.706.
- 주의할 점: Aesthetic 0.400→0.414, Subject Consistency 0.751→0.751(변화 없음), Semantic Alignment는 +50h(0.866)가 +100h(0.860)보다 높음. 본문 "visual metrics saturate between +50h and +100h"는 PSNR(+0.22 dB)·Trajectory(0)에서는 맞지만 JEPA는 +0.007 더 오르고 Semantic은 떨어져 "포화"로 한 줄 요약하기는 어렵습니다.

4.4 Table II-III: 정책 평가 (§IV-D)

- 4과제 × 정책 3개(FTP-1, π0.5, X-VLA). 과제당 롤아웃 10개, 각 롤아웃을 사람 평가자 5명이 채점, 평균.
- 세 환경: 실제 로봇, WM-Robot(200 로봇 궤적으로 적응), WM-Mix(로봇 100 + 사람 100).
- Table III: Pearson r과 MMRV. **Pearson은 정책 3개로 계산되므로 자유도가 1입니다.** $p<0.05$가 되려면 $|r|\geq 0.997$이 필요하고, 본문의 최댓값 0.972(Place Shoes, WM-Mix)도 양측 $p\approx 0.15$입니다(03 §2). 평균 Pearson 0.844(WM-Mix) 대 0.646(WM-Robot)의 차이는 검정할 수 없습니다.
- MMRV는 공식(식 (7))대로 재계산하면 본문과 맞습니다(03 §2).
- 시뮬레이터 편향: 12개 셀에서 WM-Robot 점수가 실제보다 평균 +0.12, WM-Mix는 +0.18 높습니다(03 §2.4). 순위는 맞출 수 있어도 절대 점수는 과대평가됩니다. 본문은 이 편향을 언급하지 않습니다.
- 이 평가에서 WM-Mix는 사람 데이터를 로봇 적응 데이터의 절반으로 바꿉니다. 로봇 적응 데이터가 WM-Robot보다 100개 적으므로, 이득의 원인이 사람 데이터인지 과제 데이터량 차이인지 분리되지 않습니다. 그래도 WM-Mix의 과제 데이터에 사람 시연이 "과제 특화"로 들어갔다는 점은 본문에 "task-specific human demonstrations, disjoint from HumanTouch"라고 되어 있어 사전학습 사람 데이터와는 다릅니다.

4.5 Table IV-V: 합성 데이터로 정책 학습 (§IV-E)

- 실제 200 궤적 vs (실제 100 + 합성 100). **대조군은 실제 데이터가 두 배입니다.** 실제 100 + 합성 0 대조가 없어서 합성 데이터의 순효과를 알 수 없습니다.
- 4과제 평균: FTP-1은 실제 0.731, +WM-Mix 0.694(−0.037). π0.5는 0.625 → 0.494(−0.131). X-VLA는 0.500 → 0.400(−0.100). +WM-Robot은 FTP 0.688, π0.5 0.563, X-VLA 0.506.
- 본문은 "Human-adapted world models can supply useful demonstrations"라고 씁니다. 표를 보면 π0.5와 X-VLA에서는 WM-Mix가 오히려 떨어집니다. 이 문장은 FTP-1에서만 근거가 있습니다.
- Table V(정책 Pearson·MMRV)는 본문에서 따로 논의하지 않습니다. WM-Mix의 Place Phone Pearson은 0.277로 낮은데 MMRV는 0.067입니다. 상관과 순위 지표가 엇갈립니다.

4.6 Figure 5 (생성 시연)

- 정성 비교만 있습니다(GT와 두 모델의 RGB·촉각 프레임). 접촉 타이밍이 맞는다는 주장은 시각 확인에 의존합니다.

5. 논문이 답하는 것과 답하지 않는 것

질문	논문의 답	근거 수준
촉각을 함께 예측하면 시각 예측도 나아지나?	Cross-Attn은 정책 지표를 낮추고 AdaLN(Robot-only)이 회복	단일 실행, 차이 0.04(Traj. Acc.)
사람 촉각 데이터가 로봇 예측을 돕나?	100시간에서 시각·촉각·기하 지표 개선	단일 실행, 시드 없음
사람 데이터를 정책 평가에 쓸 수 있나?	상관은 높아 보이나 정책 3개	자유도 1, 유의하지 않음

질문	논문의 답	근거 수준
합성 데이터로 정책을 학습할 수 있나?	정책마다 다름. FTP-1만 ≈, π0.5·X-VLA는 ↓	실제 데이터량이 다른 대조, 롤아웃 10개
리타게팅이 충분히 정확한가?	보고 없음	없음
두 장갑 센서가 같은 신호를 내나?	"같은 센서 배치"만 말함. 보정 방법과 도메인 격차 측정 없음	없음

6. 논문 스스로 밝히는 한계

- 본문에 한계(Limitations) 절이 없습니다. 결론은 "scalable human interaction is a complementary axis"라고만 씁니다.
- 공개 코드·가중치·데이터 공개 문장도 없습니다(arXiv 페이지에도 프로젝트 링크 없음).

7. 저자 주장 대비 읽을 때의 주의

1. 헤드라인 수치인 "100h 대 5h"는 한 번 실행한 결과입니다. 1-2% 차이가 아니라 PSNR +3.6 dB, Contact-IoU +0.17이라 방향은 강하지만, 시드 간 분산이 얼마나 되는지는 본문에 없습니다.
2. 사람 데이터는 "같은 센서 배치"이지만 장갑 위에서 손가락 압력이 달라질 수 있습니다. 로봇 손끝의 강성·형상과 사람 손끝의 차이도 접촉 분포를 바꿉니다. 이 차이를 측정하지 않았습니다.
3. 정책 평가 결과를 "evaluator consistency"라고 부르지만 측정 단위가 정책 3개입니다.

8. 재현 가능성 (요약, 상세는 04 §4)

- 코드, 가중치, 데이터셋 모두 공개되지 않은 것으로 확인했습니다(04 §1).
- 학습 세부(스텝, 배치, λ_tac, 마스크 기준, Contact 임계값)가 없어 같은 구조를 만들어도 같은 수치가 나오지 않을 가능성이 큽니다.

9. 이 저장소의 관련 논문과의 연결 (상세는 02 §3)

- 미래 촉각 예측 측면: contact_grounded_policy(접촉 기반 정책), restacvla(촉각 잔차 잠재).
- 사람→로봇 리타게팅: flashdexretarget, gnr.
- 사람 영상→로봇 학습: dreamx.
- 세계행동모델: openwam, agentic_wam (Wan 계열 백본 사용).
- 촉각 정책 대안: gpt6_astra_tactile.

DexTouch-WM 재계산, 유도, 토이 (03)

모든 수치는 `analysis/table_check.py` (→ `table_check_results.json`), `transfer_toy.py`, `sparse_metric_toy.py`로 다시 만들 수 있습니다. 모두 numpy, 1스레드, 수 초 안에 끝납니다. 그래프는 `plot_figures.py`.

1. Table I: 설계와 사람 데이터 스케일링

1.1 재계산 결과

- 본문 수치 전부를 표에서 다시 읽어 넣었고, 본문 텍스트의 인용(예: PSNR 23.47→27.10, Trajectory 0.89→0.96, Contact-IoU 0.42→0.59, Contact-F1 0.55→0.71, PSNR_taxel 24.81→29.18)과 모두 맞습니다.
- Robot-only → +100h 변화(절대·상대):

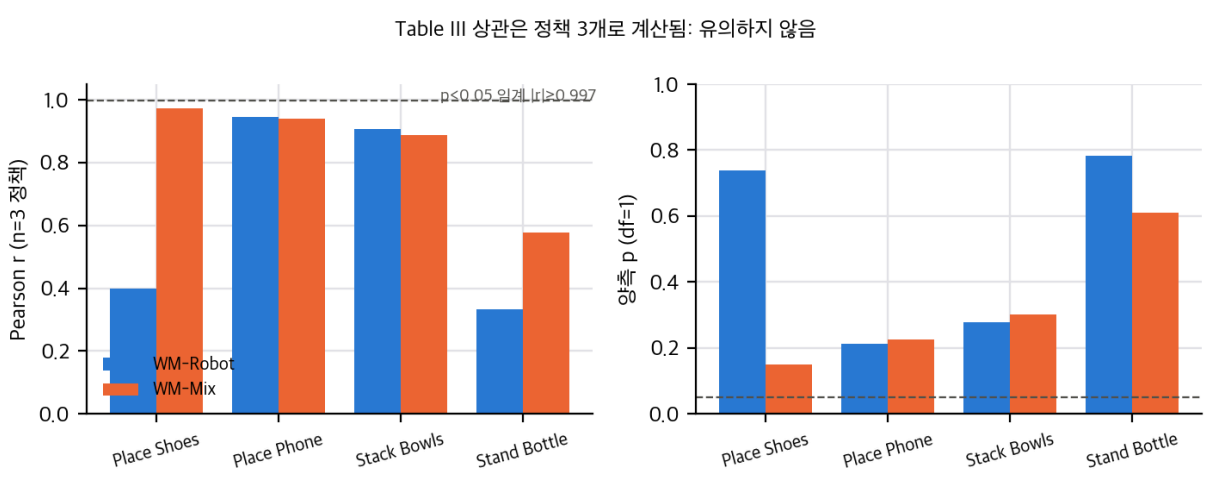
지표	Robot-only	+100h	변화	상대 변화
PSNR (dB)	23.473	27.096	+3.62	+15.4%
Trajectory accuracy	0.891	0.962	+0.071	+8.0%
Geometry error ↓	0.131	0.100	−0.031	−23.7%
PSNR_taxel (dB)	24.813	29.179	+4.37	+17.6%
Contact-MAE ↓	0.806	0.516	−0.290	−36.0%
Contact-IoU	0.415	0.588	+0.173	+41.7%
Contact-F1	0.551	0.706	+0.155	+28.1%
Aesthetic	0.400	0.414	+0.014	+3.5%
Subject consistency	0.751	0.751	0.000	0.0%

1.2 "포화"와 "+10h가 평평하다"의 확인

- +10h: PSNR_taxel은 24.813 → 24.349(−0.46 dB, 오히려 낮음), Contact-IoU는 0.415 → 0.417(+0.002), Contact-F1은 0.551 → 0.554(+0.003). **본문 "almost flat"은 맞습니다.**
- 포화: PSNR은 robot→+50h가 +3.40 dB, +50h→+100h가 +0.22 dB입니다. Contact-IoU는 +0.119 → +0.054로 줄어듭니다. 즉 시각 PSNR은 +50h에서 거의 꺾이지만, 접촉 지표는 +100h에서도 여전히 오릅니다. 본문의 "visual metrics saturate, contact continues"는 PSNR 기준으로 맞습니다. 다만 Trajectory는 +50h와 +100h가 0.962로 같고 Semantic alignment는 +50h(0.866)가 +100h(0.860)보다 높아 "포화"는 지표마다 다릅니다.
- Aesthetic 0.400 → 0.414(+3.5%)는 작지만 0이 아닙니다. 본문의 "nearly unchanged"는 주관적 표현입니다.

1.3 유의성

- 시드, 반복 실행, 분산이 보고되지 않았습니다. Table I의 차이가 학습 잡음보다 큰지 판단할 수 없습니다. 한 번만 학습한 PSNR 차이 3.6 dB는 클 가능성이 높지만, +10h→+100h의 Contact-IoU 차이(0.417→0.588)도 시드 분산과 비교해야 합니다.
- Cross-Attn → Robot-only의 Trajectory 차이(0.850 → 0.891)도 같은 문제입니다.



그래프: Table III의 과제별 Pearson(정책 3개)과 양측 p값. 점선은 p<0.05 임계(|r|≥0.997). 직접 계산.

2. Table II-III: 정책 평가 상관과 MMRV

2.1 Pearson r의 자유도

- 정책이 3개이므로 과제마다 상관은 점 3개로 계산됩니다(df = n − 2 = 1).
- 양측 검정: $t = r/\sqrt{(1-r^2)}$, df=1이므로 $p = 1 - (2/\pi)\cdot\arctan|t|$(Cauchy 분포).
- p < 0.05가 되려면 |r| ≥ 0.9967입니다. 이 값은 `table_check.py`의 임계값과 일치합니다.

2.2 재계산 결과 (본문 Table III 대비)

모델	과제	Pearson (재계산)	Pearson (본문)	양측 p	MMRV (재계산)	MMRV (본문)
WM-Robot	Place Shoes	0.400	0.400	0.738	0.0333	0.033
WM-Robot	Place Phone	0.945	0.945	0.212	0	0
WM-Robot	Stack Bowls	0.906	0.906	0.278	0	0
WM-Robot	Stand Bottle	0.334	0.334	0.783	0.0667	0.067
WM-Mix	Place Shoes	0.973	0.972	0.149	0	0
WM-Mix	Place Phone	0.939	0.939	0.224	0	0
WM-Mix	Stack Bowls	0.889	0.889	0.302	0	0
WM-Mix	Stand Bottle	0.577	0.577	0.609	0.0667	0.067

- 평균 Pearson: WM-Robot 0.646, WM-Mix 0.845(본문 0.844, 반올림 차이). 평균 MMRV: 0.025, 0.017. 모두 본문과 맞습니다.
- **결론:** 어떤 과제에서도 p < 0.05가 되지 않습니다. 본문이 Table III에서 "higher mean Pearson correlation"이라고 쓴 차이(0.646 vs 0.844)는 검정할 수 없고, 정책 3개로는 차이가 있다고 말하기 어렵습니다.
- MMRV는 정의대로 계산하면 쌍 하나의 실제 점수 차의 2/3가 됩니다(유도 §4.3). 그래서 0.033과 0.067 같은 작은 값이 나옵니다.

2.3 상관이 보여 주지 못하는 것: 시뮬레이터의 절대 편향

- 같은 정책·과제 12개 셀에서 시뮬레이터 점수 − 실제 점수:
  - WM-Robot: 평균 +0.123, 절대값 평균 0.223, 12개 중 9개에서 과대평가.

    - WM-Mix: 평균 +0.180, 절대값 평균 0.222, 12개 중 10개에서 과대평가.
- 예: π0.5 Place Shoes는 실제 0.450, WM-Robot 0.950(+0.50). 순위 상관은 높아도 절대 점수는 크게 틀립니다. Table II의 "WM ≈ real"로 읽으면 안 됩니다.

2.4 12쌍 pooled Pearson 0.925

- WM-Robot과 WM-Mix의 12쌍 점수 사이 상관은 0.925입니다(본문과 같음).
- 과제 평균을 빼고 다시 계산해도 0.925입니다. 따라서 이 값이 과제 간 차이 때문에 부풀려졌다고 볼 근거는 없습니다.
- 그래도 두 시뮬레이터 버전이 같은 정책 점수를 반복해서 쓰므로 독립 표본이 아닙니다. 두 적응 방식이 비슷하다는 뜻이지, 실제와 맞는다는 뜻이 아닙니다.

3. Table IV-V: 합성 데이터로 학습한 정책

3.1 평균과 비교 설계

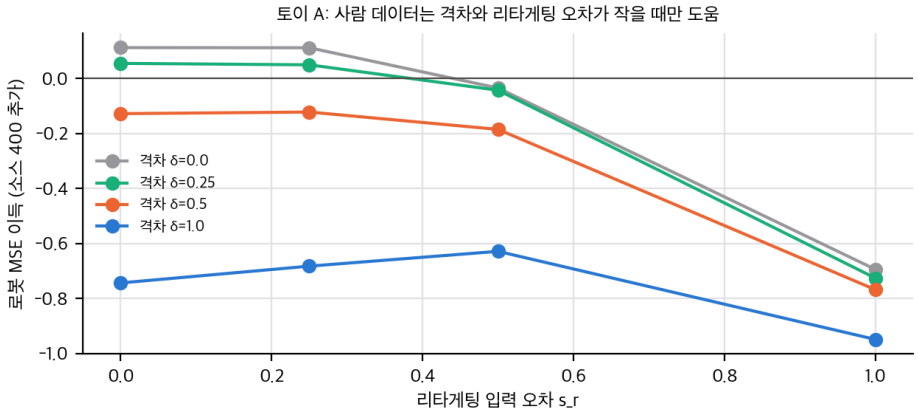
- 재계산 평균(4과제):
    - FTP-1: 실제 0.731, +WM-Robot 0.688, +WM-Mix 0.694
    - π0.5: 실제 0.625, +WM-Robot 0.562, +WM-Mix 0.494
    - X-VLA: 실제 0.500, +WM-Robot 0.506, +WM-Mix 0.400
- **설계 문제:** 실제 대조군은 실제 200 궤적, 합성 조건은 실제 100 + 합성 100입니다. 실제 데이터량이 절반으로 줄었으므로 합성 데이터의 순효과가 아닙니다. 올바른 대조는 "실제 100 + 합성 0"입니다.

3.2 불확실성 민감도

- 셀당 롤아웃 10개, 점수의 표준편차(SD)는 논문에 없습니다. 가정 SD에 따라 4과제 평균의 표준오차와 두 평균 차이의 표준오차를 계산했습니다.

가정 SD	4과제 평균 SE	두 평균 차이 SE
0.15	0.024	0.034
0.25	0.040	0.056
0.35	0.055	0.078

- 차이: FTP-1 실제 – WM-Mix = 0.037, π0.5 = 0.131, X-VLA = 0.100.
- 해석: FTP-1 차이는 SD 0.15에서도 1 SE 이내라 구분되지 않습니다. π0.5 차이는 SD 0.25에서 약 2.3 SE이고 0.35에서 약 1.7 SE입니다. 독립 표본 가정과 SD 가정에 크게 기대는 값이라 확정은 하지 못합니다.
- 결론: 본문 "usefulness depends on policy"는 맞습니다. 다만 "human-adapted world models can supply useful demonstrations"는 FTP-1에서만 근거가 있고, π0.5와 X-VLA에서는 오히려 떨어지는 방향입니다.



그래프: 토이 A. 소스 데이터 400개 추가의 로봇 MSE 이득을 격차 δ와 리타게팅 오차 s_r에 따라 나타냄. 직접 계산.

4. 토이 A: 사람 데이터는 언제 도움이 되는가

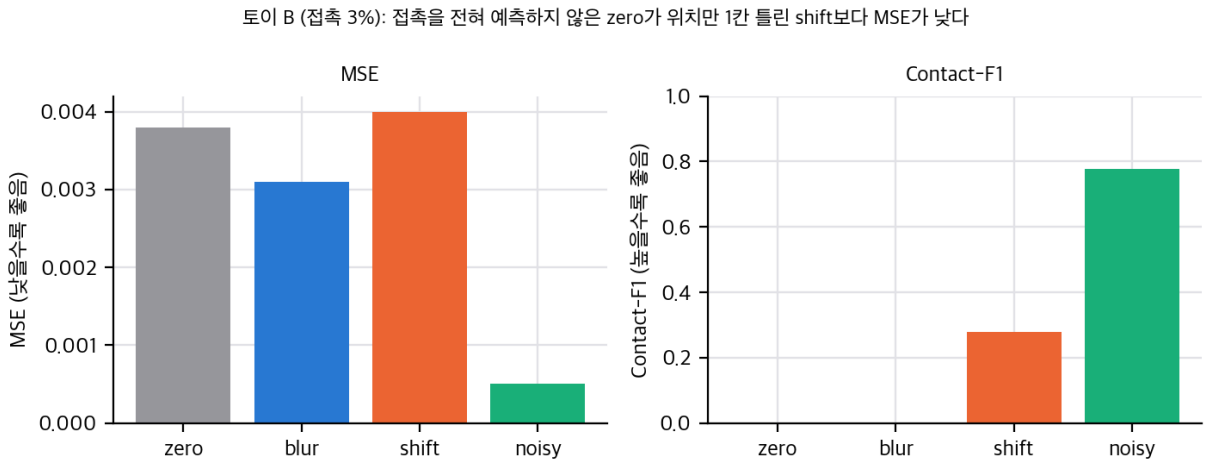
4.1 설정 (`analysis/transfer_toy.py`)

- 로봇 도메인: y = w_r^T x + ε, D = 8, 로봇 샘플 N_t = 25(5시간 고정의 소량 가정), σ = 0.5.
- 사람 도메인: 같은 입력 분포에서 y = (w_r + δ)^T x + ε. 격차 δ는 w 벡터에 1/√D 방향으로 더한 크기. 단위는 임의입니다.
- 리타게팅 오차: 사람 입력에 x + e, e ~ N(0, s_r^2 I). 입력 오차가 있는 회귀(errors-in-variables)입니다.
- 학습: 로봇 + 사람을 합친 최소제곱. 평가: 로봇 도메인 새 샘플 4000개의 MSE. 30회 반복 평균.
- 소스 샘플 N_s ∈ {0, 25, 50, 100, 200, 400}.

4.2 결과 (N_s = 400일 때 이득 = MSE(N_s=0) − MSE(N_s=400), 양수면 도움)

격차 δ \ 리타게팅 오차 s_r	0	0.25	0.5	1.0
0	+0.112	+0.111	−0.035	−0.694
0.25	+0.055	+0.049	−0.043	−0.726
0.5	−0.128	−0.122	−0.185	−0.768
1.0	−0.743	−0.682	−0.629	−0.949

- **도움이 되는 조건:** 격차가 작고(δ ≲ 0.25) 리타게팅 오차가 작을 때(s_r ≲ 0.25)입니다.
- **해가 되는 조건:** 격차가 δ ≥ 0.5 이거나, 격차가 0이어도 리타게팅 오차가 s_r ≥ 0.5이면 소스를 섞는 쪽이 손해입니다. s_r = 0.5에서 격차가 0이면 소스 섞기가 약간 손해(−0.035)인데, 입력 오차가 회귀 계수를 0 쪽으로 끌어당기기 때문입니다.
- **결론:** 사람 데이터의 이득은 도메인 격차와 리타게팅 오차에 따라 부호가 바뀝니다. 논문이 리타게팅 오차를 측정하지 않았으므로, 사람 데이터가 도움이 되는지는 논문으로 판단할 수 없습니다. 이 점은 04 C11, C12와 연결됩니다.
- 한계: 선형 모델, 입력 분포는 표준정규, 격차를 w 벡터에 한 방향으로만 줬습니다. 실제 촉각 맵은 비선형이고 접촉 희소성이 있어 결과를 그대로 옮길 수 없습니다.



그래프: 토이 B(접촉 3%). MSE는 zero가 shift보다 낮지만, 접촉 F1은 shift가 0.28로 높음. 직접 계산.

5. 토이 B: 희소 접촉 촉각 맵에서 MSE의 오해

5.1 설정 (`analysis/sparse_metric_toy.py`)

- 320 taxel을 20×16으로 근사. 접촉 taxel 비율 3%와 10%. 접촉 값은 0.4-1.0 균등, 정답은 가우시안으로 살짝 번짐.
- 후보 예측: zero(항상 0), blur(정답을 흐리고 0.6배), shift(정답을 1 taxel 옮김), noisy(정답 + 잡음 0.03).
- 접촉 지표: 임계값 0.1로 이진화한 IoU와 F1, 접촉 칸만 본 MAE. 200회 평균.
- **주의:** 임계값 0.1은 제가 고른 값입니다. blur는 최대값이 낮아 임계값 아래로 떨어지므로 F1이 0이 됩니다. 임계값을 바꾸면 blur 결과가 달라집니다.

5.2 결과 (접촉 3%)

후보	MSE	PSNR	Contact-IoU	Contact-F1	Contact-MAE
zero	0.0038	24.3	0.000	0.000	0.234
blur	0.0031	25.2	0.000	0.000	0.208
shift	0.0040	24.0	0.166	0.278	0.192
noisy	0.0005	32.9	0.639	0.776	0.024

- **오해가 생기는 지점:** shift는 접촉 위치 1칸만 틀렸지만 접촉 F1이 0.28입니다. MSE는 zero보다 나쁩니다(0.0040 대 0.0038). 아무것도 예측하지 않는 쪽이 MSE로는 더 낫게 보입니다.
- blur는 MSE가 zero보다 낫지만(0.0031) 접촉 F1은 0입니다. 흐린 예측이 평균 오차만 줄이고 접촉은 찾지 못합니다.
- 접촉 10%에서도 같은 방향입니다(zero MSE 0.0157 F1 0, shift MSE 0.0133 F1 0.48).
- **결론:** 희소 맵에서 MSE와 PSNR은 "배경을 0으로 맞추는" 능력을 크게 보상하고 접촉 위치의 정확성은 작게 반영합니다. 논문이 Contact-MAE·IoU·F1을 추가한 것은 이 문제를 인식했다는 뜻이고, 방향은 옳습니다. 다만 논문의 접촉 임계값과 Contact-MAE 정의가 없어서 이 설계가 실제로 얼마나 효과가 있는지 확인할 수 없습니다.

6. 유도

6.1 잔차 촉각 잠재(식 2)는 표현력을 늘리는가

- 디코더 D_x는 주어진 것이고 z_0는 깨끗한 문맥입니다. 예측값 $\hat{z}_t = z_0 + \hat{r}_t$이므로 잠재 오차는 $e_t = z_t - \hat{z}_t = r_t - \hat{r}_t$ 입니다.

- 따라서 잔차 예측의 잠재 오차는 절대 잠재 예측의 오차와 같습니다(z_0가 맞다는 조건에서). 정보가 늘지 않습니다.
- 차이는 **학습 동역학과 귀납 편향**에서만 생깁니다. 배경 압력이 큰 장면에서 학습 신호가 작은 변화에 집중하므로 실제 이득이 있을 수 있지만, 논문은 이 효과를 분리하지 않았습니다(잔차 대 절대 ablation 없음). 이 점은와 연결됩니다.
- 접촉 마스크 손실: 손실 값이 접촉 토큰에서만 계산되면 비접촉 토큰의 오차는 학습에 들어가지 않습니다. 평가 지표는 전체 taxel에서 계산되므로 학습과 평가가 다른 영역을 봅니다. 논문의 MSE 개선 중 일부가 이 불일치 때문일 수 있습니다. 마스크 정의가 없어 확인하지 못했습니다.

6.2 Pearson 자유도 1의 임계값

- 양측 검정에서 $t = r/\sqrt{(1-r^2)}$, 자유도 1의 t 분포는 Cauchy입니다.
- $P(|T| > t) = 1 - (2/\pi)\cdot\arctan(t)$. $p = 0.05$를 두면 $t = \tan(0.95\pi/2) \approx 12.71$이고 $r = t/\sqrt{(1+t^2)} \approx 0.9967$입니다.

6.3 MMRV의 닫힌 형식

- 정책 N = 3, 쌍 (i, j)에서 실제 순위가 뒤집힌 쌍이 하나뿐이고 실제 점수 차가 d이면 MMRV = (d + d)/3 = 2d/3입니다.
- 검산: Place Shoes WM-Robot d = 0.05 → 0.0333(본문 0.033). Stand Bottle d = 0.10 → 0.0667(본문 0.067). 두 값 모두 맞습니다.

6.4 Table IV 차이의 표준오차 (4.2절과 같은 가정)

- 셀 하나의 SE = SD/√10, 4과제 평균 SE = (SD/√10)/√4, 두 독립 평균의 차이 SE = √2 × 그 값.

7. 그래프

- `report/figures/table3_pearson_n3.png` : Table III의 Pearson과 n=3 p-value.
- `report/figures/transfer_toy.png` : 토이 A의 격차·리타게팅 오차에 따른 이득.
- `report/figures/sparse_metric.png` : 토이 B에서 MSE 순위와 접촉 F1 순위가 어긋나는 모습.

8. 재계산에서 찾은 본문과의 차이 요약

1. 사람 데이터 과제 수: 50(§I, §IV-C) 대 54(§IV-A). 같은 데이터인지 불명확.
2. "Aesthetic and image-quality scores stay nearly unchanged": Aesthetic +3.5%.
3. Table III의 Pearson 비교는 정책 3개 기반이라 통계적 비교가 성립하지 않음.
4. Table IV 대조군이 실제 데이터량을 다르게 함.
5. 시뮬레이터 점수의 절대 편향(+0.12~0.18)을 본문이 언급하지 않음.

추가 검증 (2026-11-11)

추가 검증 1. 사람 데이터 가중을 로봇 교차검증으로 고르면 해가 되는 영역을 피하는가

목적. 03 §4의 토이 A는 사람 데이터 가중을 고정했을 때 이득의 부호가 격차와 리타게팅 오차에 따라 바뀜을 보였습니다. 실제 연구에서는 가중을 데이터로 골라야 합니다. 이때 선택 절차가 해가 되는 영역을 피하는지 봅니다.

설정 (가정). 03 §4와 같은 선형 토이입니다(D = 8, 로봇 샘플 25, 사람 샘플 400, 잡음 0.5, 격차 δ는 1/√D 방향).

- 선택: 로봇 샘플만으로 5-fold 교차검증 MSE가 가장 낮은 가중 $\lambda \in \{0, 0.1, 0.3, 1.0\}$를 고릅니다. 사람 도메인 데이터는 쓰지 않습니다.

- 평가: 로봇 도메인 새 샘플 4000개의 MSE. 이득 G = MSE(λ = 0) − MSE(선택 λ). G < 0이면 해가 됩니다.
- 비교: λ = 1 고정(단순 합침), 시험 MSE로 고른 오라클(선택 불가능한 상한).
- 반복 200회. 실행 약 3초(`analysis/extra_src_weight_cv.py`, 결과 `analysis/extra_src_weight_cv_results.json`).

결과. 교차검증 선택의 평균 이득 G, 괄호 안은 G < 0인 반복의 비율.

격차 δ \ 리타게팅 오차 s_r	0	0.25	0.5	1.0
0	+0.111 (0%)	+0.083 (4.5%)	−0.019 (33%)	−0.003 (1%)
0.25	+0.065 (9.5%)	+0.049 (16.5%)	−0.020 (28%)	−0.003 (1%)
0.5	−0.014 (39%)	−0.012 (36%)	−0.030 (26%)	−0.001 (0.5%)
1.0	−0.023 (4.5%)	−0.024 (5.5%)	−0.021 (6.5%)	0.000 (0%)

같은 격자에서 λ = 1을 고정했을 때의 평균 이득은 δ = 0, s_r = 0에서 +0.12이지만, 나머지 셀의 대부분에서 음수입니다. 가장 나쁜 셀은 δ = 1, s_r = 1의 −2.00입니다. 시험 MSE 오라클(선택 불가능한 상한)은 δ = 0, s_r = 0에서 +0.12, δ 또는 s_r이 커지면 0-0.03 수준입니다.

결론.

- **큰 해는 피합니다.** 교차검증 선택의 최악 평균 이득은 −0.03입니다. 고정 λ = 1의 평균 이득이 −0.1에서 −2.0까지 떨어지는 영역에서 선택 절차는 손실을 0 근처로 줄입니다.
- **그래도 해가 남습니다.** 격차가 0.5 이상이거나 리타게팅 오차가 0.5 이상인 셀에서 평균 이득이 음수이고, 반복의 26-39%에서 해가 됩니다. 로봇 샘플 25개에서 5-fold 교차검증은 잡음이 커서, 이득이 작은 영역에서 λ를 잘못 고르는 경우가 많습니다.
- **정리.** "가중을 데이터로 고르면 안전하다"는 말은 이 toy에서 지지되지 않습니다. 선택 절차는 고정 가중보다 낫지만, 격차와 리타게팅 오차를 따로 재지 않으면 어느 쪽이 해가 되는지 알 수 없습니다.
- **한계.** 선형 모델, 격차 방향 하나, 교차검증 5-fold, 사람 샘플 400개 고정. 리타게팅 오차가 입력 잡음이라는 가정도 단순합니다.

추가 검증 2. 시뮬레이터 점수 편향 보정이 MMRV를 바꾸는가

목적. 03 §2.3은 시뮬레이터 점수가 실제보다 평균 +0.12~0.18 높다는 것을 보였습니다. 편향을 보정하면 MMRV가 줄어드는지, 정책 수(3과 10)에 따라 달라지는지 봅니다.

MMRV의 정의. 논문 식 (7): MMRV_k = (1/N) Σ_i max_j |R_ik − R_jk| v_ijk, v_ijk = 1[(R_ik − R_jk)(S_ik − S_jk) < 0]. 순위가 뒤집힌 쌍 중 실제 점수 차가 가장 큰 값을 정책마다 취해 평균합니다. N = 3이면 한 쌍이 뒤집힌 경우 2d/3이 됩니다(03 §6.3).

설정 (가정).

- 과제 4개, 반복 2000회. 정책 N개(3 또는 10)의 실제 점수 R ~ U(0.05, 0.95).
- 시뮬 점수 S = clip(R + μ + 0.05·η, 0, 1), μ ∈ {0.12, 0.15, 0.18}, η ~ N(0, 1). 편향의 정책별 변동 0.05는 가정입니다.
- 보정 자료: 실제 점수를 아는 독립 정책 k개(k = 3 또는 10)로 보정 계수를 맞추고, 평가 정책 N개에 적용합니다.
  - shift: S' = S − mean(S_cal − R_cal)(전 정책에 같은 값을 뺌, 단조).
  - linear: S' = a + bS(최소제곱). b < 0이면 순위가 뒤집힙니다.
- 실행 약 10초(`analysis/extra_sim_bias_mmrv.py`, 결과 `analysis/extra_sim_bias_mmrv_results.json`).

결과. μ = 0.15, 과제 평균.

평가 정책 N	보정 자료 k	MMRV 원시	MMRV shift	MMRV linear	linear의 기울기 < 0 비율	MAE 원시	MAE shift	MAE linear
3	3	0.0046	0.0046	0.0073	0.7%	0.143	0.046	0.076
3	10	0.0045	0.0045	0.0045	0%	0.143	0.042	0.045
10	3	0.0180	0.0180	0.0225	0.8%	0.143	0.046	0.080
10	10	0.0185	0.0185	0.0185	0%	0.143	0.043	0.045

μ = 0.12와 0.18에서도 같은 방향입니다. shift 보정은 모든 셀에서 MMRV를 **정확히** 0만큼 바꿨습니다(최대 변화 0.0).

결론.

- **단조 보정은 MMRV를 바꾸지 않습니다.** 모든 정책에 같은 단조 함수를 적용하면 v_ijk가 그대로이므로 MMRV는 수학적으로 불변입니다. 편향 보정은 MAE를 0.14에서 0.04 근처로 줄이지만, 순위 지표인 MMRV는 줄이지 못합니다. "보정하면 MMRV가 준다"는 기대는 맞지 않습니다.
- **MMRV가 변하는 경우는 보정이 순서를 뒤집을 때뿐입니다.** 보정 자료가 3개일 때 linear 보정의 기울기가 음수가 되는 경우(0.7-0.8%)가 있고, 그때 MMRV가 나빠집니다. 보정 자료가 10개면 이 현상이 사라집니다.
- **정책 수 3과 10의 차이.** MMRV 절대값은 N이 커지면 커집니다(0.005 → 0.018). 보정 방식의 차이는 N과 무관하게 같은 방향입니다. 이 toy의 정책 수 3은 MMRV에서 쌍이 적어 0에 가까운 값이 많이 나오므로, 논문의 0.033과 0.067은 한 쌍의 순위 뒤집힘에 해당합니다.
- **한계.** 편향의 정책별 변동(0.05)은 가정입니다. 실제 시뮬 편향이 정책 간에 순위를 바꿀 만큼 변하는지는 논문 데이터 없이 알 수 없습니다. 이 toy는 "보정으로 MMRV를 줄인다"는 주장이 보정 방식과 무관하게 성립하지 않는다는 것만 보입니다.

추가 검증 3. 접촉 임계값을 바꿨을 때 MSE와 접촉 지표의 순위 관계

목적. 03 §5의 토이 B는 접촉 임계값을 0.1로 고정했습니다. 임계값을 0.05-0.30으로 바꿨을 때 MSE와 접촉 지표가 주는 순위 관계가 달라지는지 봅니다.

설정 (가정). 토이 B와 같습니다(320 taxel, 접촉 3%와 10%, 후보 zero, blur, shift, noisy). 임계값 {0.05, 0.10, 0.15, 0.20, 0.25, 0.30}. 반복 200회, 시드 1. 실행 약 0.2초(`analysis/extra_contact_thr.py`, 결과 `analysis/extra_contact_thr_results.json`).

결과. 접촉 3%에서의 평균 Contact-F1(MSE는 임계값과 무관).

임계값	zero	blur	shift	noisy
0.05	0.000	0.013	0.447	0.745
0.10	0.000	0.000	0.278	0.776
0.15	0.000	0.000	0.099	0.942
0.20	0.000	0.000	0.039	0.948
0.30	0.000	0.000	0.033	0.917

MSE: zero 0.0038, blur 0.0031, shift 0.0040, noisy 0.0005. 접촉 10%에서도 같은 순서입니다. shift의 F1은 0.60(임계값 0.05)에서 0.11(0.30)으로 줄지만 zero보다 항상 높습니다.

결론.

- **"MSE 역설"의 방향은 임계값과 무관하게 유지됩니다.** shift는 F1에서 zero보다 항상 높고(모든 임계값, 두 접촉 비율), MSE에서는 zero보다 나쁩니다(0.0040 대 0.0038). 이 방향은 임계값 선택에 기대지 않습니다.
- **blur의 접촉 지표는 임계값에 민감합니다.** blur의 최댓값이 0.6배로 낮아서 임계값이 0.15 이상이면 blur는 접촉을 전혀 잡지 못합니다(F1 = 0). 0.05에서만 blur가 zero보다 약간 높습니다(F1 0.013 대 0). 즉 "blur가 접촉을 찾는다"는 결론은 낮은 임계값에서만 나오고, 그 차이는 작습니다.
- **임계값을 보고하지 않은 접촉 지표는 해석하기 어렵습니다.** 같은 예측이라도 임계값을 0.05에서 0.15로 올리면 blur의 Contact-F1이 0.013에서 0으로 바뀝니다. 논문은 임계값을 밝히지 않았으므로(`04` 참고), 접촉 지표의 절대값을 인용할 때는 임계값을 함께 적어야 합니다.
- **한계.** 가정 모델(작은 배열, 가우시안 접촉, 단순 후보). 실제 촉각 맵의 노이즈와 접촉 분포가 다르면 F1의 절대값은 달라집니다. 순위 관계의 방향만 봅니다.

DexTouch-WM 주장 검증 (04)

공식 코드가 없어서(02 §4) 코드 대조(`04_code_verification.md`)는 하지 않았습니다. 대신 논문 표·본문 수치를 재계산하고(03), 주장별로 판정했습니다.

판정 기준: **재현됨**(표 수치와 본문이 일치하고 계산이 맞음), **부분**(방향은 맞으나 근거가 약하거나 조건이 붙음), **확인 불가**(논문에 정보가 없음), **불일치**(본문과 표가 어긋남).

1. 주장 목록

ID	주장 (본문 위치)	확인한 것	판정	근거
C1	사람 데이터는 "50 tasks" (Intro, §IV-C) 대 "54 tasks" (§IV-A)	두 곳의 숫자 대조	**불일치**	§I, §IV-A
C2	Table I 전 셀의 값	표 수치와 본문 인용 값 대조	**재현됨**	03 §1.1
C3	사람 데이터 100h 추가 시 로봇 예측 개선 (PSNR 23.47→27.10, Traj 0.89→0.96, Geometry 0.13→0.10, Contact-IoU 0.42→0.59)	같은 표 값에서 변화량 계산	**부분**. 방향과 크기는 맞지만 단일 실행, 시드 미보고	03 §1.1, §1.3
C4	"+10h Human is almost flat on tactile metrics" (§IV-C)	+10h와 Robot-only 차이	**재현됨** (PSNR_taxel −0.46 dB, IoU +0.002, F1 +0.003)	03 §1.2
C5	"Visual metrics saturate between +50h and +100h" (§IV-C)	PSNR, Trajectory, JEPA, Semantic 변화	**부분**. PSNR(+0.22 dB)과 Trajectory(0)는 포화이나 JEPA는 +0.007 상승, Semantic은 +50h에서 최고	03 §1.2
C6	"Aesthetic and image-quality scores stay nearly unchanged" (§IV-C)	Aesthetic 0.400→0.414, Image Quality 0.718→0.724	**부분**. 절대값은 작지만 Aesthetic은 +3.5%	03 §1.1
C7	"Contact transfer is stronger": 촉각 지표가 시각보다 크게 개선	PSNR_taxel +17.6%, Contact-IoU +41.7%, Contact-F1 +28.1%	**부분**. 상대 변화는 크지만 Contact 임계값과 정의가 없어 크기 해석이 어려움	04 C19
C8	Table III 평균 Pearson: WM-Mix 0.844 > WM-Robot 0.646 (§IV-D)	정책 3개 기반 상관의 p값	**확인 불가** (유의하지 않음, 최소 p 0.15)	03 §2.2
C9	사람 촉각이 로봇 촉각 동역학을 공유한다 (Abstract, §I "shared contact dynamics")	사람 데이터만으로 촉각 예측, 사람·로봇 촉각 분포 비교, 전이 ablation을 찾음	**확인 불가**. 전이를 직접 측정한 실험이 없음. 개선은 "로봇 데이터 고정 + 사람 추가"의 결과뿐	01 §5
C10	같은 센서 배치라서 사람·로봇 촉각 관측이 호환된다 (§III-C, §IV-A)	센서 배치(320 taxel 배열) 비교	**부분**. 배치는 같으나 압력 보정, 감도, 장갑과 손가락 형상 차이를 다루지 않음	01 §3.2, §3.4
C11	리타게팅으로 사람 행동을 로봇 행동 공간에 옮긴다 (§III-D)	리타게팅 오차(키포인트, 접촉 위치, 물체 자세) 보고 여부	**확인 불가**. 정량 보고 없음	01 §3.4
C12	사람 데이터 효과가 리타게팅 오차에 강건하다 (암묵)	토이 A: 소스 이득이 격차·리타게팅 오차에 따라 부호가 바뀜	**확인 불가**(반증 가능성은 있음). 토이 결과는 논문 주장을 지지하지도 반박하지도 않음	03 §4.2
C13	Split-Hands가 Grid보다 재구성 손실이 낮고 Contact-IoU가 빨리 수렴 (Fig. 4)	Fig. 4 곡선	**확인 불가**. 그림만 있고 수치 없음	01 §3.2

ID	주장 (본문 위치)	확인한 것	판정	근거
C14	Cross-Attn은 정책 지표를 낮추고 AdaLN은 이를 회복 (Table I, §IV-B)	Trajectory 0.884 → 0.850 → 0.891	**부분**. 차이가 0.04 수준이고 시드 미보고	03 §1.3
C15	사람 데이터 0→100h로 Trajectory 정확도 0.89→0.96 (Table I)	표 값	**재현됨**(표 기준). 단일 실행	03 §1.1
C16	평가 상관 WM-Mix가 WM-Robot보다 평균적으로 높고 MMRV도 낮다 (Table III)	Pearson, MMRV 재계산	**재현됨**(값). 해석은 **부분**: MMRV 차이(0.025 대 0.017)는 Place Shoes 한 과제의 순위 교정(0.033→0)에서만 나오고, Stand Bottle의 0.067은 두 모델이 같음	03 §2.2
C17	12쌍 pooled Pearson 0.925로 두 적응 방식이 일관된다 (§IV-D)	12쌍 상관, 과제 평균 제거 후 상관	**재현됨**(0.925). 독립 표본이 아니고 정책 3개가 과제별로 반복되므로 "일관성"의 근거로는 약함	03 §2.4
C18	WM 점수는 실제 점수의 순위를 보존한다 (Table III, MMRV)	과제별 MMRV	**부분**. 순위 불일치는 Stand Bottle과 Place Shoes에서 생김. 절대 점수는 시뮬레이터 쪽이 평균 +0.12~0.18 높음(과대평가)	03 §2.3
C19	접촉 지표(Contact-MAE, IoU, F1)가 평균 MSE를 보완한다 (§IV-A)	토이 B: zero 예측이 shift 예측보다 MSE가 낮음	**재현됨**(토이 수준, 방향 맞음). 실제 맵에서 임계값에 따라 달라짐	03 §5.2
C20	평가 Contact-IoU·F1·Contact-MAE 정의	본문 정의 찾기	**확인 불가**. 임계값, 접촉 칸 정의, 마스크 기준 없음	01 §4.2
C21	합성 데이터로 정책을 학습할 수 있다 (Table IV, §IV-E)	실제 200 대 실제 100 + 합성 100	**부분**. FTP-1만 근접(−0.037), π0.5(−0.131)와 X-VLA(−0.100)는 하락. 대조군 설계 문제	03 §3
C22	사람 데이터로 과제 적응 데이터의 절반을 대체해도 된다 (§IV-D "Human-data substitution")	Table II, III, IV 종합	**부분**. 평가 상관은 유지되나 정책 학습에서는 두 정책이 떨어짐	03 §3.1
C23	로봇 held-out 평가는 사람 데이터와 과제가 다르다 (§IV-C)	사전학습 로봇 6과제와 held-out 6과제 대조	**확인 불가**. 같은 6과제인지 명시하지 않음. 같다면 "교차 과제 전이"라는 표현은 과장	01 §4.1
C24	WM-Robot은 5시간 로봇 데이터 고정 조건에서 적응 (§IV-C, 정책 평가)	Table II 설명: 적응에 로봇 200 궤적 사용	**불일치 가능성**. 5시간 사전학습 이후 200궤적을 추가로 쓰므로 "로봇 데이터 고정"의 예산이 다름	01 §4.4
C25	시뮬레이터 평가가 실제 정책 평가를 대신할 수 있다 (Table III 결론)	C16, C18, C8 종합	**부분**. 상관은 있으나 정책 3개, 절대 편향 있음	03 §2

2. 재현에 필요한 정보가 빠진 목록

- 학습 스텝, 배치 크기, 학습률, 옵티마이저, GPU 종류와 시간.
- 시드 수와 반복 실행 결과(분산).
- λ_tac 값, 접촉 마스크의 임계값.
- 67차원 행동의 구성 요소 차원 수(손목 pose 표현 방식 포함).
- 촉각 압력 단위와 정규화 방법, 두 도메인의 압력 보정.
- Trajectory accuracy, Geometry error, JEPA similarity, Subject consistency의 계산 정의와 사용 모델.
- Contact-IoU, F1, Contact-MAE의 임계값과 정의.
- 사람 데이터 에피소드 수, 로봇 held-out 에피소드 수, 시간당 프레임 수.
- 리타게팅 IK 솔버, 손 기하 정규화 방법.
- 정책 평가의 평가자 설정(블라인드 여부, 평가 기준 교육).

3. 검증 실행 목록 (이 저장소에서 한 것)

- `analysis/table_check.py` : Table I 변화량, 포화 점검, Table III 재계산(Pearson, p값, MMRV), 12쌍 pooled·과제 평균 제거 상관, 시뮬레이터 편향, Table IV 평균과 표준오차 민감도.
- `analysis/transfer_toy.py` : C12 관련 토이.
- `analysis/sparse_metric_toy.py` : C19 관련 토이.
- 재계산 결과는 모두 `table_check_results.json`, `transfer_toy_results.json`, `sparse_metric_results.json`에 있습니다.

4. 구현 가능성 판정

4.1 공식 재현: **불가**

- 코드, 가중치, 데이터셋 공개가 없고(02 §4), 학습 설정도 부족합니다(§2).
- 필요한 것: 촉각 장갑 두 벌(사람용·로봇용 동일 배치), 손 추적기(MANUS, VIVE), 20-DoF 로봇 손(Wuji)과 팔(Tianji), 사람 데이터 100시간, 로봇 데이터 5시간, 사전학습 비디오 백본(Wan2.2-TI2V-5B, 공개 가중치).
- 장비 목록 중 촉각 장갑과 Wuji 손은 구입 가능 여부가 불분명합니다. 공개 SDK 중 Wuji 손 제어 라이브러리(`wujihandpy`, MIT)는 있습니다.

4.2 이 맥(Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, torch 미설치)에서

항목	판정
논문 학습 재현 (100h 사람 + 5h 로봇 + 5B 백본 미세조정)	**불가**. CUDA 없음. 데이터도 없음. 학습 시간을 계산한 것은 아님
토이 수준 검증 (numpy, 이 저장소 완료)	**가능**
작은 촉각 인코더·잔차 잠재 학습 (합성 또는 공개 촉각 데이터)	**조건부**. torch 설치 승인 필요. MPS로 소형 모델은 가능할 것으로 추정(실행 안 함)
Wan2.2-5B 로드와 추론	**조건부**. 메모리는 24 GiB에서 빠듯할 수 있다는 추정(실행 안 함). 미세조정은 비현실적

4.3 같은 아이디어를 새로 구현하는 노력

- **중간에서 높음.** 구성 요소: (a) Wan2.2 DiT 위의 두 번째 경량 전문가와 joint attention(MoT 형태), (b) Split-Hands 촉각 토크나이저(공유 손끝 인코더 + 손바닥 인코더 + 패드 임베딩), (c) 초기 상태 기준 잔차 잠재와 접촉 마스크 손실, (d) dual-rate 조건, (e) 사람 자세 → 로봇 행동 리타게팅 파이프라인(IK 필요).
- 가장 값싼 부분은 (b)와 (c)입니다. 작은 촉각 맵 자동인코더 하나로 검증할 수 있습니다.
- 가장 비싼 부분은 (e)입니다. 사람 장갑 데이터 수집과 리타게팅 오차 측정이 없으면 DexTouch-WM의 핵심 주장을 확인할 수 없습니다.
- 줄 수 추정은 하지 않았습니다(근거 없음).

4.4 하드웨어 요구

- 학습: 대형 CUDA GPU 필요(근거: 5B 규모 비디오 DiT 미세조정은 보통 대형 GPU 메모리를 씀. 논문에 GPU 정보 없음, **추정**).
- 데이터 수집: 촉각 장갑 두 벌, 손 추적기, 로봇 손·팔.
- 공개 촉각 데이터(예: UniT 계열)로 촉각 인코더 부분만 검증하는 것은 하드웨어 없이도 가능합니다.

4.5 판정 요약

- **공식 재현: 불가.**
- **이 맥에서 재현: 불가. 토이와 소형 인코더 검증만 가능.**
- **새로 구현: 가능하나 중간에서 높은 노력. 데이터 수집이 병목.**
- **가치 판단:** 설계 아이디어(Split-Hands, 잔차 잠재, dual-rate)는 값싸게 검증할 수 있고 가치가 있습니다. 주장의 핵심인 "사람 데이터가 로봇 세계모델을 돕는다"는 리타게팅 오차와 도메인 격차를 재지 않으면 검증되지 않습니다.

5. 문제와 미확인 항목

- 논문 본문에 한계 절이 없음. 리뷰어가 볼 수 있는 질문(사람 촉각 전이, 리타게팅 오차, 시드 분산)이 본문에 답이 없습니다.
- 본문 밖의 자료(부록, 웹페이지, 보충 자료)를 확인하지 못했습니다. arXiv 페이지에 보충 자료 링크가 없었습니다.
- 워크숍 발표(라이트닝 토크) 여부와 발표 자료는 확인하지 못했습니다.
- 논문 그림 Fig. 4, Fig. 5, Fig. 6은 정성 결과라 재계산 대상이 아닙니다.

DexTouch-WM 선행연구와 관련 저장소 (02)

1. 논문이 놓은 계보

논문 §II(Related Work)를 기준으로 네 갈래로 정리합니다. 괄호 안은 논문의 참고문헌 번호입니다.

갈래	대표 연구	DexTouch-WM과의 차이
촉각을 제어 신호로 쓰는 정책	3D-ViTac [5], Reactive Diffusion Policy [26], ViTacFormer [3], Contact-grounded policy [25], FTP-1 [29], TactAlign [22]	촉각을 **예측 대상**으로 쓰지 않음. 논문은 이 점을 명시적으로 구분
사람이 모은 시각-촉각 데이터	Touch and Go [28], OpenTouch [18], DexUMI [24], FreeTacMan [23], DexViTac [1], Touch in the Wild [34]	모방·표현 학습이 목적. 논문은 같은 센서를 로봇에도 달아 **세계모델 학습 데이터로** 쓴다는 점이 다름
시각-촉각 세계모델	SPOTS [14], VT-WM [4], OmniVTA [32], FeelWorld [13], ViTacWorld [6], Dream-Tac [12], VT-WAM [19], TacForeSight [30], TouchWorld [33]	대부분 로봇 원격조작 데이터로 학습. 논문은 사람 촉각 데이터의 규모 효과를 **고정된 로봇 데이터**와 대비해 측정
세계모델 평가·생성	WorldGym [16], GigaWorld [2], Interactive world simulator [21], WorldSample [27], MMRV [9], [8]	평가 지표(MMRV)는 그대로 가져다 씀. 정책 3개로 계산하는 한계는 03 §2에서 다룸

논문의 중심 가설(§II 마지막 문단): "공유 접촉 동역학이 있으면 사람의 물리적 상호작용이 손 세계모델의 규모를 키운다." 이 가설을 검증하려면 촉각 전이 자체(사람 촉각 → 로봇 촉각)를 따로 떼어 보는 실험이 필요한데, 논문에는 그 실험이 없습니다(04 C9, C10).

2. 기반 기술

- **Wan2.2-TI2V-5B와 비디오 VAE [20]**: 시각 전문가의 초기화와 프레임 잠재. 공식 저장소 `Wan-Video/Wan2.2` (Apache-2.0).
- **Mixture-of-Transformers [10]**: 모달리티별 AdaLN·FFN을 두고 attention만 공유하는 구조.
- **Conditional flow matching [11]**: 식 (4)의 손실.
- **MMRV [9], [8]**: 식 (7). 정책 순위 불일치를 실제 점수 차로 가중.
- **WorldArena [17], GigaWorld [2]**: 시각 평가 지표 묶음(Aesthetic, Image Quality, JEPA similarity, Subject consistency, Trajectory accuracy). 논문은 이 프로토콜을 따른다고 하나 정의는 원 논문을 봐야 합니다.

3. 이 저장소의 다른 논문과의 관계

폴더	연구	DexTouch-WM과 맞닿는 지점	쓸 만한 것
`contact_grounded_policy/`	미래 촉각·상태 예측과 접촉 일관성	미래 촉각 예측	예측 대상을 접촉 상태로 둔 설계 비교
`restacvla/`	π0.5에 촉각 잔차를 VQ 토큰으로 주입	촉각을 "시각 예측과의 차이"로 표현	잔차 대 원시 ablation의 부재를 채우는 질문
`flashdexretarget/`	사람 손-물체 시연 → 로봇손 궤적 (RL)	사람→로봇 리타게팅	리타게팅 오차를 어떻게 재는지 (04 C12의 빈칸)

폴더	연구	DexTouch-WM과 맞닿는 지점	쓸 만한 것
`gnr/`	생성형 리타게팅 잔차(MPC 보정)	사람→로봇 행동 정렬	같은 IK 리타게팅 문제를 다른 방식으로 푼 비교 기준
`dreamx/`	사람 영상을 latent action으로 로봇 학습	사람 데이터를 로봇 행동 공간으로 옮김	사람 데이터 전이의 성공·실패 사례
`openwam/`	World Action Model 설계 부품 비교, Wan2.2 DiT 기반	같은 백본(Wan2.2-TI2V-5B) 계열	백본 선택과 학습 설정의 기준선
`agentic_wam/`	코드·영상·행동을 한 MoT로 생성	세계행동모델 구조	MoT 구조 비교
`gpt6_astra_tactile/`	고정된 대형 모델을 촉각 정책으로 씀	촉각 정책 대안	반사실 촉각 시험 설계

4. GitHub와 공개 자료 조사

조사 날짜 2026-11-10. `gh search repos` 는 검색 API 404로 실패해 `gh api repos/...` 로 확인했습니다. 웹 검색으로도 프로젝트 페이지를 찾지 못했습니다.

저장소	내용	공식?	라이선스	스타	마지막 커밋 (hash)
DexTouch-WM 코드	논문 공식 구현	**없음 (미확인)**. `DexTouch-WM`, `DexTouch`, `2609.20649` 로 저장소 검색 0건, 웹 검색에도 프로젝트 페이지 없음	-	-	-
`Wan-Video/Wan2.2`	백본 Wan2.2-TI2V-5B	공식(Wan 팀), 논문이 쓴 백본	Apache-2.0	18,481	2026-09-21 (`1ea34ff`)
`wuji-technology/wujihandpy`	Wuji Hand C++/Python SDK	공식(Wuji 팀), 논문의 Wuji 손 제어용으로 추정	MIT	40	2026-08-24 (`468e169`)
`wuji-technology/wujihandros2`	Wuji Hand ROS2 드라이버	공식(Wuji 팀)	명시 없음 (`none`)	16	2026-08-24 (`95000ed`)
`wuji-technology/wujihand-hmi`	Wuji Hand 모니터링·보정 GUI	공식(Wuji 팀)	MIT	2	2026-04-08 (`79d4f88`)
`Lee-Kangwon/dextouch`	DexTouch (LRA 2024, 촉각 전용 조작, arXiv:2401.12496)	**다른 연구**(이름만 같음)	-	0	2024-01-12

검토 메모:

- 논문의 촉각 장갑(Moxian)과 사람 손 추적(MANUS, VIVE)용 SDK는 GitHub에서 찾지 못했습니다. 장치 제조사 자료는 공개 저장소로 확인되지 않았습니다.
- Wuji SDK 두 개(wujihandpy, wujihandros2)는 논문의 WujiHand2와 같은 제품군이라는 점만 확인했습니다. 두 저장소 모두 WujiHand2 모델을 명시하는지는 확인하지 않았습니다.
- 논문 공개 자료 확인: 프로젝트 페이지 링크 없음(arXiv 초록 페이지와 PDF 본문 모두). 코드·데이터·가중치 공개 문장 없음.

- 논문 이름과 같은 외부 블로그 요약(예: 영문·중문 논문 요약 저장소)은 있으나, 원 저자가 올린 자료가 아니므로 근거로 쓰지 않았습니다.

5. 공개 자료 상태 (04와 연결)

- 공식 코드 없음 → 클론 없음 → `repo/` 없음 → 04는 `04_claim_verification.md` (주장 C1-C20 재계산·검증)로 씀.
- 리타게팅·데이터 수집 하드웨어 자료가 공개되지 않아, 04 §4의 재현 판정은 "논문만으로 구현하는 쪽"으로 봐야 합니다.