DexTouch-WM: 분석 리포트

arXiv:2609.20649 v2 · IROS 2026 워크숍(RoBoWoMo) 라이트닝 토크(본 트랙 아님) · 저자 Qin, Chen, Lin, Liu, Lyu, Su, Jin, Yu, Luo, Ding, Chen, Xu · 공식 코드 없음(GitHub·웹 조사) · 분석일 2026-11-10 · 게시용 버전: 논문 그림 없이 우리가 그린 그래프만 포함

핵심 요약

1. **무엇을 하는가:** 사람과 로봇 손에 같은 압전저항 촉각 배치를 달고, 사람 손 motion을 로봇 행동 공간으로 IK 리타게팅합니다. 사전학습 비디오 DiT(Wan2.2-TI2V-5B)에 촉각 전문가를 MoT로 붙여 RGB와 양손 촉각을 함께 예측합니다.
2. **스케일링 결과는 방향이 분명하다:** 로봇 5시간을 고정하고 사람 데이터를 0→100시간으로 늘리면 PSNR +3.6 dB, Contact-IoU 0.415→0.588입니다. 재계산은 본문과 맞습니다. 다만 한 번 학습한 결과이고 시드·분산이 없습니다.
3. **정책 평가 상관은 통계적으로 약하다:** 정책 3개로 계산한 Pearson은 $p<0.05$가 되려면 $|r|\geq 0.997$이 필요합니다. 본문 최댓값(0.972)도 $p\approx 0.15$입니다.
4. **시뮬레이터 점수는 실제보다 높게 나온다:** 같은 정책·과제 12셀에서 평균 +0.12(WM-Robot), +0.18(WM-Mix)입니다. 순위는 맞아도 성공률 절대값은 과대평가됩니다.
5. **합성 데이터의 이득은 정책마다 다르다:** 대조군이 실제 데이터를 두 배 씁니다. FTP-1은 거의 같고, π0.5(−0.131)와 X-VLA(−0.100)는 떨어집니다.
6. **사람 촉각 전이의 조건:** 토이에서 사람 데이터 이득은 도메인 격차와 리타게팅 오차가 작을 때만 양수입니다. 논문은 리타게팅 오차를 측정하지 않았습니다.
7. **희소 촉각 지표:** 접촉 3%에서 zero 예측은 MSE가 위치만 1칸 틀린 예측보다 낮습니다. 접촉 지표를 MSE와 함께 써야 합니다.
8. **구현 가능성:** 공식 재현은 불가(코드·가중치·데이터 없음). 이 맥(M4 Pro, CUDA 없음)에서 재현 불가, 토이와 소형 검증만 가능. 설계 아이디어는 중간에서 높은 노력으로 새로 구현할 수 있고, 병목은 촉각 장갑 두 벌과 사람 데이터 수집입니다.
9. **v1 → v2:** 본문 텍스트는 같고 저자 목록에 한 명이 추가되었습니다.

DexTouch-WM 논문 분석 (arXiv:2609.20649)

논문: DexTouch-WM: Learning Action-Conditioned Tactile World Models from Human Touch for Dexterous Robot Manipulation **저자:** Yan Qin, Yue Chen, Wenwei Lin, Shujia Liu, Chuqiao Lyu, Kailun Su, Weiyang Jin, Chenze Yu, Ping Luo, Wenbo Ding, Tianxing Chen, Renjing Xu (12명, 공동 제1저자 4명 *, 교신 3명 †) **arXiv:** 2609.20649 · 최신 v2 (2026-09-18) · cs.RO · 본문 8쪽, 부록 없음 **학회 위치:** arXiv 댓글 "Accept to IROS 2026 Workshop RoBoWoMo (Lightning Talk)". **IROS 2026 본 트랙 논문이 아니라 워크숍 논문(라이트닝 토크)입니다.** 실험 규모와 보고 깊이는 본 트랙 기준보다 얇게 읽어야 합니다. **라이선스:** arXiv 비독점 배포 1.0 (nonexclusive-distrib). CC BY가 아니므로 논문 그림은 개인용 리포트·PPT에만 쓰고 공개 산출물에는 넣지 않습니다(README 참고).

---

1. 한 문단 요약

사람 손에 건 압전저항 장갑(촉각 360 taxel/손, 그중 320개 사용)과 로봇 손(Wuji 20-DoF)에 같은 센서 배치를 달고, 사람 손 motion을 로봇 행동 공간으로 리타게팅(IK)합니다. 이렇게 하면 사람 데이터를 로봇용 행동조건 세계모델 학습에 그대로 쓸 수 있다는 것이 핵심 주장입니다. 모델은 사전학습 비디오 DiT(Wan2.2-TI2V-5B)에 경량 촉각 전문가(TactileDiT)를 Mixture-of-Transformers 방식으로 붙여 RGB와 양손 촉각을 함께 예측합니다. 실험의 핵심 질문은 "로봇 데이터를 5시간으로 고정하고 사람 데이터를 0→10→50→100시간으로 늘리면 로봇 도메인 예측이 좋아지는가"입니다(Table I). 결과는 좋아지는 방향이지만, 단일 실행·시드 미보고·검정 없음이라 "확실한 스케일링 법칙"이라고 하기는 어렵습니다. 정책 평가(Table II-III)와 데이터 생성(Table IV-V)은 정책 3개, 과제 4개 규모라 통계적으로 약합니다.

2. 문제 설정 (§III-A)

- 식 (1): $p_\theta(v_{1:T}, x_{1:T} \mid v_0, x_0, a_{1:T}, \ell)$. 초기 RGB v_0, 촉각 x_0, 언어 ℓ, 미래 자세 $a_{1:T}$를 받아 미래 RGB와 촉각을 예측.
- 행동은 두 도메인 모두 같은 67차원 표현: 양 손목 motion, 양 손 20-DoF, 머리 카메라 motion (식 (6)). 67차원 구성 요소별 차원 수는 본문에 없어 추정하지 않았습니다.
- 사람 데이터: 25-keypoint 손 골격 + 손목 6-DoF(VIVE tracker) + 손 관절(MANUS) + 머리·손목 카메라. 장갑은 Moxian 촉각 장갑을 MANUS MetaGloves 아래 착용.

3. 방법

3.1 구조 (§III-B, Fig. 2)

- **시각 전문가:** Wan2.2-TI2V-5B DiT와 frozen video VAE. 첫 프레임은 깨끗한 잠재(시간 index 0)로 유지하고 이후 잠재만 노이즈를 넣어 예측.
- **촉각 전문가 (TactileDiT):** 가벼운 DiT, frozen Split-Hands 인코더·디코더. 두 전문가는 bi-modal joint attention으로 정보를 교환하고, AdaLN과 FFN은 모달리티별로 따로 씀(MoT [10]).
- **조건:** 언어는 frozen text encoder, 자세는 AdaLN(식 (3)). 비디오는 4프레임 chunk, 촉각은 원래 프레임율로 조건을 넣음(dual-rate).

3.2 해부학적 촉각 토큰화 (§III-B "Anatomy-aware")

- 손당 320 taxel = 엄지~소지 손끝 5개 × 4×4(=80) + 손바닥 15×16(=240) (Fig. 3). 80+240=320으로 맞음.

- 조각 격자(Grid)는 손끝과 손바닥을 한 캔버스에 이어 붙임. 논문은 이것이 "인공적인 이웃"을 만든다고 보고, 손끝 공유 인코더 1개와 손바닥 공유 인코더 1개 + 패드 정체성 임베딩(Split-Hands)을 씀.
- Split-Hands는 contact 가중 재구성으로 사전학습 후 동결. 가중을 둔 이유는 비접촉 taxel이 대부분이라 표현을 지배하기 때문.
- 근거: Fig. 4 (Grid 대비 재구성 손실 낮고 Contact-IoU 수렴 빠름). **Fig. 4는 곡선만 있고 최종 수치가 없습니다.**

3.3 잔차 촉각 잠재 (식 (2))

- $z_t = E_x(x_t)$, $r_t = z_t - z_0$, $\hat{x}_t = D_x(z_0 + \hat{r}_t)$. 초기 촉각 배경 압력을 빼고 상호작용으로 생긴 변화만 예측.
- 손실 식 (4): $L = L_{video}^{FM} + \lambda_{tac} L_{tac}^{FM}$. 촉각 항은 "접촉 또는 시간에 따라 변하는 토큰"에서만 계산(마스크). **λ_{tac} 값과 마스크 기준(임계값)은 본문에 없습니다.**

3.4 사람→로봇 행동 정렬 (§III-D)

- 식 (5): $(e^h_t, J^h_t) \rightarrow (e^r_t, q^r_t)$, 사람 손목 자세와 손 기하를 캘리브레이션된 카메라-세계 정합 후 IK로 WujiHand2 (20-DoF) 자세에 매핑.
- 행동은 전부 첫 프레임 기준 상대 손목 motion (식 (6)).
- **리타게팅 오차를 정량화한 결과는 없습니다.** 키포인트 오차, 접촉 위치 불일치, 물체 자세 오차 등 어느 것도 보고하지 않습니다. "사람 촉각이 로봇에서 전이된다"는 주장이 이 단계에 기대고 있어서 가장 큰 빈칸입니다.

3.5 학습

- 조건부 flow matching [11]. 학습 스텝, 배치, 학습률, GPU 종류, 시드 수 모두 본문에 없음.

4. 실험

4.1 데이터 (§IV-A)

- 사람: 본문 두 곳이 어긋납니다. Introduction과 §IV-C는 "50 tasks", §IV-A 첫 문단은 "54 tasks". 같은 데이터인지 확인할 수 없어 상충으로 기록합니다. 총 약 100시간.
- 로봇: 10 과제, Tianji 팔 + Wuji 손. 6과제 5시간(사전학습), 나머지 4과제는 다운스트림. 6과제 held-out 로봇 에피소드 수는 본문에 없습니다.
- **모호한 점:** "Human and robot task sets are disjoint"라고 하는데, 평가하는 held-out 로봇 에피소드 6과제가 사전학습 6과제와 같은지 다른지 명시하지 않습니다. 같은 과제라면 "교차 과제 전이"보다는 "사람 데이터가 같은 로봇 과제의 예측을 돕는다"에 가깝습니다.

4.2 평가 지표 (§IV-A)

- 시각: PSNR, SSIM, LPIPS, Aesthetic/Image Quality(WorldArena [17]), JEPA similarity, Subject consistency, Semantic alignment, Trajectory accuracy, Geometry error. **Trajectory accuracy와 Geometry error의 정의는 본문에 없습니다.**
- 촉각: PSNR_taxel, SSIM_taxel, LPIPS_heatmap, MSE, MAE, Contact-MAE, Contact-IoU, Contact-F1. **접촉의 임계값, Contact-MAE가 접촉 칸만 보는지 여부 등 정의가 없습니다.**

4.3 Table I: 설계와 사람 데이터 스케일링 (§IV-B, §IV-C)

- 열: V-only, Cross-Attn, Robot-only(= Split-Hands + AdaLN), +10h, +50h, +100h(= DexTouch-WM). 모두 로봇 5시간 고정.

- 단일 값만 있고 분산·시드·신뢰구간이 없습니다. 재계산 결과(03 §1)는 본문 수치와 맞습니다(Table I의 소수 셋째 자리까지 재현).
- 핵심 수치: PSNR 23.47→27.10 (+3.62 dB), Trajectory Accuracy 0.891→0.962, Geometry 0.131→0.100, PSNR_taxel 24.81→29.18, Contact-IoU 0.415→0.588, Contact-F1 0.551→0.706.
- 주의할 점: Aesthetic 0.400→0.414, Subject Consistency 0.751→0.751(변화 없음), Semantic Alignment는 +50h(0.866)가 +100h(0.860)보다 높음. 본문 "visual metrics saturate between +50h and +100h"는 PSNR(+0.22 dB)·Trajectory(0)에서는 맞지만 JEPA는 +0.007 더 오르고 Semantic은 떨어져 "포화"로 한 줄 요약하기는 어렵습니다.

4.4 Table II-III: 정책 평가 (§IV-D)

- 4과제 × 정책 3개(FTP-1, π0.5, X-VLA). 과제당 롤아웃 10개, 각 롤아웃을 사람 평가자 5명이 채점, 평균.
- 세 환경: 실제 로봇, WM-Robot(200 로봇 궤적으로 적응), WM-Mix(로봇 100 + 사람 100).
- Table III: Pearson r과 MMRV. **Pearson은 정책 3개로 계산되므로 자유도가 1입니다.** $p<0.05$가 되려면 $|r|\geq 0.997$이 필요하고, 본문의 최댓값 0.972(Place Shoes, WM-Mix)도 양측 $p\approx 0.15$입니다(03 §2). 평균 Pearson 0.844(WM-Mix) 대 0.646(WM-Robot)의 차이는 검정할 수 없습니다.
- MMRV는 공식(식 (7))대로 재계산하면 본문과 맞습니다(03 §2).
- 시뮬레이터 편향: 12개 셀에서 WM-Robot 점수가 실제보다 평균 +0.12, WM-Mix는 +0.18 높습니다(03 §2.4). 순위는 맞출 수 있어도 절대 점수는 과대평가됩니다. 본문은 이 편향을 언급하지 않습니다.
- 이 평가에서 WM-Mix는 사람 데이터를 로봇 적응 데이터의 절반으로 바꿉니다. 로봇 적응 데이터가 WM-Robot보다 100개 적으므로, 이득의 원인이 사람 데이터인지 과제 데이터량 차이인지 분리되지 않습니다. 그래도 WM-Mix의 과제 데이터에 사람 시연이 "과제 특화"로 들어갔다는 점은 본문에 "task-specific human demonstrations, disjoint from HumanTouch"라고 되어 있어 사전학습 사람 데이터와는 다릅니다.

4.5 Table IV-V: 합성 데이터로 정책 학습 (§IV-E)

- 실제 200 궤적 vs (실제 100 + 합성 100). **대조군은 실제 데이터가 두 배입니다.** 실제 100 + 합성 0 대조가 없어서 합성 데이터의 순효과를 알 수 없습니다.
- 4과제 평균: FTP-1은 실제 0.731, +WM-Mix 0.694(−0.037). π0.5는 0.625 → 0.494(−0.131). X-VLA는 0.500 → 0.400(−0.100). +WM-Robot은 FTP 0.688, π0.5 0.563, X-VLA 0.506.
- 본문은 "Human-adapted world models can supply useful demonstrations"라고 씁니다. 표를 보면 π0.5와 X-VLA에서는 WM-Mix가 오히려 떨어집니다. 이 문장은 FTP-1에서만 근거가 있습니다.
- Table V(정책 Pearson·MMRV)는 본문에서 따로 논의하지 않습니다. WM-Mix의 Place Phone Pearson은 0.277로 낮은데 MMRV는 0.067입니다. 상관과 순위 지표가 엇갈립니다.

4.6 Figure 5 (생성 시연)

- 정성 비교만 있습니다(GT와 두 모델의 RGB·촉각 프레임). 접촉 타이밍이 맞는다는 주장은 시각 확인에 의존합니다.

5. 논문이 답하는 것과 답하지 않는 것

질문	논문의 답	근거 수준
촉각을 함께 예측하면 시각 예측도 나아지나?	Cross-Attn은 정책 지표를 낮추고 AdaLN(Robot-only)이 회복	단일 실행, 차이 0.04(Traj. Acc.)
사람 촉각 데이터가 로봇 예측을 돕나?	100시간에서 시각·촉각·기하 지표 개선	단일 실행, 시드 없음
사람 데이터를 정책 평가에 쓸 수 있나?	상관은 높아 보이나 정책 3개	자유도 1, 유의하지 않음

질문	논문의 답	근거 수준
합성 데이터로 정책을 학습할 수 있나?	정책마다 다름. FTP-1만 ≈, π0.5·X-VLA는 ↓	실제 데이터량이 다른 대조, 롤아웃 10개
리타게팅이 충분히 정확한가?	보고 없음	없음
두 장갑 센서가 같은 신호를 내나?	"같은 센서 배치"만 말함. 보정 방법과 도메인 격차 측정 없음	없음

6. 논문 스스로 밝히는 한계

- 본문에 한계(Limitations) 절이 없습니다. 결론은 "scalable human interaction is a complementary axis"라고만 씁니다.
- 공개 코드·가중치·데이터 공개 문장도 없습니다(arXiv 페이지에도 프로젝트 링크 없음).

7. 저자 주장 대비 읽을 때의 주의

1. 헤드라인 수치인 "100h 대 5h"는 한 번 실행한 결과입니다. 1-2% 차이가 아니라 PSNR +3.6 dB, Contact-IoU +0.17이라 방향은 강하지만, 시드 간 분산이 얼마나 되는지는 본문에 없습니다.
2. 사람 데이터는 "같은 센서 배치"이지만 장갑 위에서 손가락 압력이 달라질 수 있습니다. 로봇 손끝의 강성·형상과 사람 손끝의 차이도 접촉 분포를 바꿉니다. 이 차이를 측정하지 않았습니다.
3. 정책 평가 결과를 "evaluator consistency"라고 부르지만 측정 단위가 정책 3개입니다.

8. 재현 가능성 (요약, 상세는 04 §4)

- 코드, 가중치, 데이터셋 모두 공개되지 않은 것으로 확인했습니다(04 §1).
- 학습 세부(스텝, 배치, λ_tac, 마스크 기준, Contact 임계값)가 없어 같은 구조를 만들어도 같은 수치가 나오지 않을 가능성이 큽니다.

9. 이 저장소의 관련 논문과의 연결 (상세는 02 §3)

- 미래 촉각 예측 측면: contact_grounded_policy(접촉 기반 정책), restacvla(촉각 잔차 잠재).
- 사람→로봇 리타게팅: flashdexretarget, gnr.
- 사람 영상→로봇 학습: dreamx.
- 세계행동모델: openwam, agentic_wam (Wan 계열 백본 사용).
- 촉각 정책 대안: gpt6_astra_tactile.

DexTouch-WM 재계산, 유도, 토이 (03)

모든 수치는 `analysis/table_check.py` (→ `table_check_results.json`), `transfer_toy.py`, `sparse_metric_toy.py`로 다시 만들 수 있습니다. 모두 numpy, 1스레드, 수 초 안에 끝납니다. 그래프는 `plot_figures.py`.

1. Table I: 설계와 사람 데이터 스케일링

1.1 재계산 결과

- 본문 수치 전부를 표에서 다시 읽어 넣었고, 본문 텍스트의 인용(예: PSNR 23.47→27.10, Trajectory 0.89→0.96, Contact-IoU 0.42→0.59, Contact-F1 0.55→0.71, PSNR_taxel 24.81→29.18)과 모두 맞습니다.
- Robot-only → +100h 변화(절대·상대):

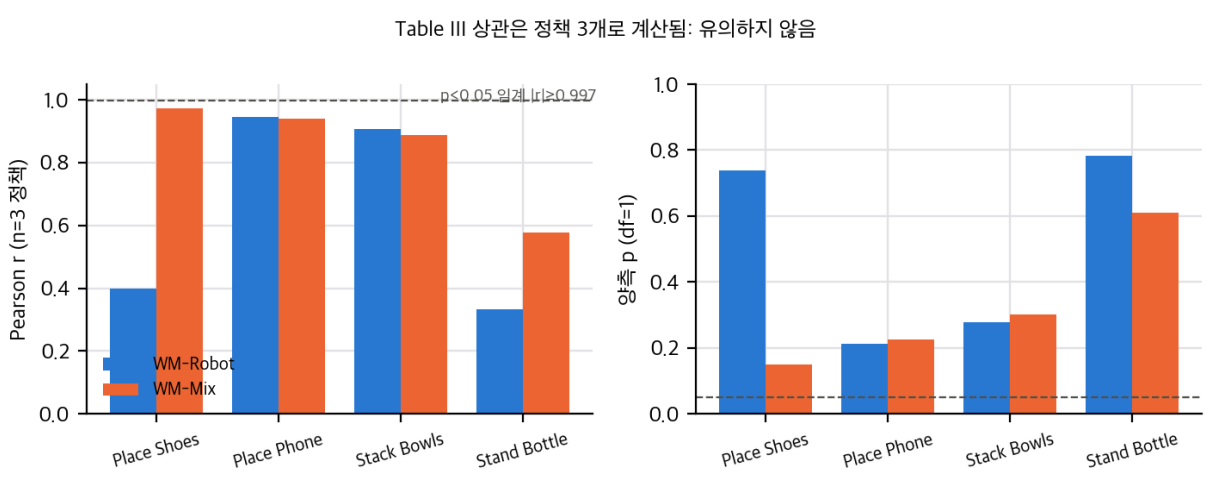
지표	Robot-only	+100h	변화	상대 변화
PSNR (dB)	23.473	27.096	+3.62	+15.4%
Trajectory accuracy	0.891	0.962	+0.071	+8.0%
Geometry error ↓	0.131	0.100	−0.031	−23.7%
PSNR_taxel (dB)	24.813	29.179	+4.37	+17.6%
Contact-MAE ↓	0.806	0.516	−0.290	−36.0%
Contact-IoU	0.415	0.588	+0.173	+41.7%
Contact-F1	0.551	0.706	+0.155	+28.1%
Aesthetic	0.400	0.414	+0.014	+3.5%
Subject consistency	0.751	0.751	0.000	0.0%

1.2 "포화"와 "+10h가 평평하다"의 확인

- +10h: PSNR_taxel은 24.813 → 24.349(−0.46 dB, 오히려 낮음), Contact-IoU는 0.415 → 0.417(+0.002), Contact-F1은 0.551 → 0.554(+0.003). **본문 "almost flat"은 맞습니다.**
- 포화: PSNR은 robot→+50h가 +3.40 dB, +50h→+100h가 +0.22 dB입니다. Contact-IoU는 +0.119 → +0.054로 줄어듭니다. 즉 시각 PSNR은 +50h에서 거의 꺾이지만, 접촉 지표는 +100h에서도 여전히 오릅니다. 본문의 "visual metrics saturate, contact continues"는 PSNR 기준으로 맞습니다. 다만 Trajectory는 +50h와 +100h가 0.962로 같고 Semantic alignment는 +50h(0.866)가 +100h(0.860)보다 높아 "포화"는 지표마다 다릅니다.
- Aesthetic 0.400 → 0.414(+3.5%)는 작지만 0이 아닙니다. 본문의 "nearly unchanged"는 주관적 표현입니다.

1.3 유의성

- 시드, 반복 실행, 분산이 보고되지 않았습니다. Table I의 차이가 학습 잡음보다 큰지 판단할 수 없습니다. 한 번만 학습한 PSNR 차이 3.6 dB는 클 가능성이 높지만, +10h→+100h의 Contact-IoU 차이(0.417→0.588)도 시드 분산과 비교해야 합니다.
- Cross-Attn → Robot-only의 Trajectory 차이(0.850 → 0.891)도 같은 문제입니다.



그래프: Table III의 과제별 Pearson(정책 3개)과 양측 p값. 점선은 p<0.05 임계(|r|≥0.997). 직접 계산.

2. Table II-III: 정책 평가 상관과 MMRV

2.1 Pearson r의 자유도

- 정책이 3개이므로 과제마다 상관은 점 3개로 계산됩니다(df = n − 2 = 1).
- 양측 검정: $t = r/\sqrt{(1-r^2)}$, df=1이므로 $p = 1 - (2/\pi)\cdot\arctan|t|$(Cauchy 분포).
- p < 0.05가 되려면 |r| ≥ 0.9967입니다. 이 값은 `table_check.py`의 임계값과 일치합니다.

2.2 재계산 결과 (본문 Table III 대비)

모델	과제	Pearson (재계산)	Pearson (본문)	양측 p	MMRV (재계산)	MMRV (본문)
WM-Robot	Place Shoes	0.400	0.400	0.738	0.0333	0.033
WM-Robot	Place Phone	0.945	0.945	0.212	0	0
WM-Robot	Stack Bowls	0.906	0.906	0.278	0	0
WM-Robot	Stand Bottle	0.334	0.334	0.783	0.0667	0.067
WM-Mix	Place Shoes	0.973	0.972	0.149	0	0
WM-Mix	Place Phone	0.939	0.939	0.224	0	0
WM-Mix	Stack Bowls	0.889	0.889	0.302	0	0
WM-Mix	Stand Bottle	0.577	0.577	0.609	0.0667	0.067

- 평균 Pearson: WM-Robot 0.646, WM-Mix 0.845(본문 0.844, 반올림 차이). 평균 MMRV: 0.025, 0.017. 모두 본문과 맞습니다.
- **결론:** 어떤 과제에서도 p < 0.05가 되지 않습니다. 본문이 Table III에서 "higher mean Pearson correlation"이라고 쓴 차이(0.646 vs 0.844)는 검정할 수 없고, 정책 3개로는 차이가 있다고 말하기 어렵습니다.
- MMRV는 정의대로 계산하면 쌍 하나의 실제 점수 차의 2/3가 됩니다(유도 §4.3). 그래서 0.033과 0.067 같은 작은 값이 나옵니다.

2.3 상관이 보여 주지 못하는 것: 시뮬레이터의 절대 편향

- 같은 정책·과제 12개 셀에서 시뮬레이터 점수 − 실제 점수:
  - WM-Robot: 평균 +0.123, 절대값 평균 0.223, 12개 중 9개에서 과대평가.

    - WM-Mix: 평균 +0.180, 절대값 평균 0.222, 12개 중 10개에서 과대평가.
- 예: π0.5 Place Shoes는 실제 0.450, WM-Robot 0.950(+0.50). 순위 상관은 높아도 절대 점수는 크게 틀립니다. Table II의 "WM ≈ real"로 읽으면 안 됩니다.

2.4 12쌍 pooled Pearson 0.925

- WM-Robot과 WM-Mix의 12쌍 점수 사이 상관은 0.925입니다(본문과 같음).
- 과제 평균을 빼고 다시 계산해도 0.925입니다. 따라서 이 값이 과제 간 차이 때문에 부풀려졌다고 볼 근거는 없습니다.
- 그래도 두 시뮬레이터 버전이 같은 정책 점수를 반복해서 쓰므로 독립 표본이 아닙니다. 두 적응 방식이 비슷하다는 뜻이지, 실제와 맞는다는 뜻이 아닙니다.

3. Table IV-V: 합성 데이터로 학습한 정책

3.1 평균과 비교 설계

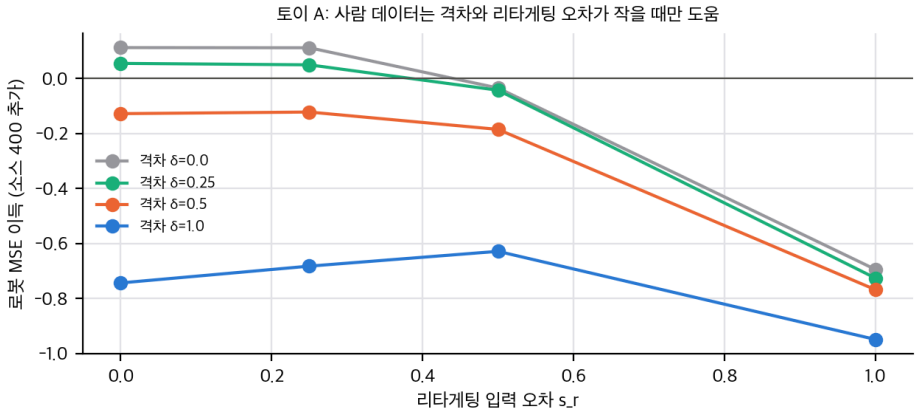
- 재계산 평균(4과제):
    - FTP-1: 실제 0.731, +WM-Robot 0.688, +WM-Mix 0.694
    - π0.5: 실제 0.625, +WM-Robot 0.562, +WM-Mix 0.494
    - X-VLA: 실제 0.500, +WM-Robot 0.506, +WM-Mix 0.400
- **설계 문제:** 실제 대조군은 실제 200 궤적, 합성 조건은 실제 100 + 합성 100입니다. 실제 데이터량이 절반으로 줄었으므로 합성 데이터의 순효과가 아닙니다. 올바른 대조는 "실제 100 + 합성 0"입니다.

3.2 불확실성 민감도

- 셀당 롤아웃 10개, 점수의 표준편차(SD)는 논문에 없습니다. 가정 SD에 따라 4과제 평균의 표준오차와 두 평균 차이의 표준오차를 계산했습니다.

가정 SD	4과제 평균 SE	두 평균 차이 SE
0.15	0.024	0.034
0.25	0.040	0.056
0.35	0.055	0.078

- 차이: FTP-1 실제 – WM-Mix = 0.037, π0.5 = 0.131, X-VLA = 0.100.
- 해석: FTP-1 차이는 SD 0.15에서도 1 SE 이내라 구분되지 않습니다. π0.5 차이는 SD 0.25에서 약 2.3 SE이고 0.35에서 약 1.7 SE입니다. 독립 표본 가정과 SD 가정에 크게 기대는 값이라 확정은 하지 못합니다.
- 결론: 본문 "usefulness depends on policy"는 맞습니다. 다만 "human-adapted world models can supply useful demonstrations"는 FTP-1에서만 근거가 있고, π0.5와 X-VLA에서는 오히려 떨어지는 방향입니다.



그래프: 토이 A. 소스 데이터 400개 추가의 로봇 MSE 이득을 격차 δ와 리타게팅 오차 s_r에 따라 나타냄. 직접 계산.

4. 토이 A: 사람 데이터는 언제 도움이 되는가

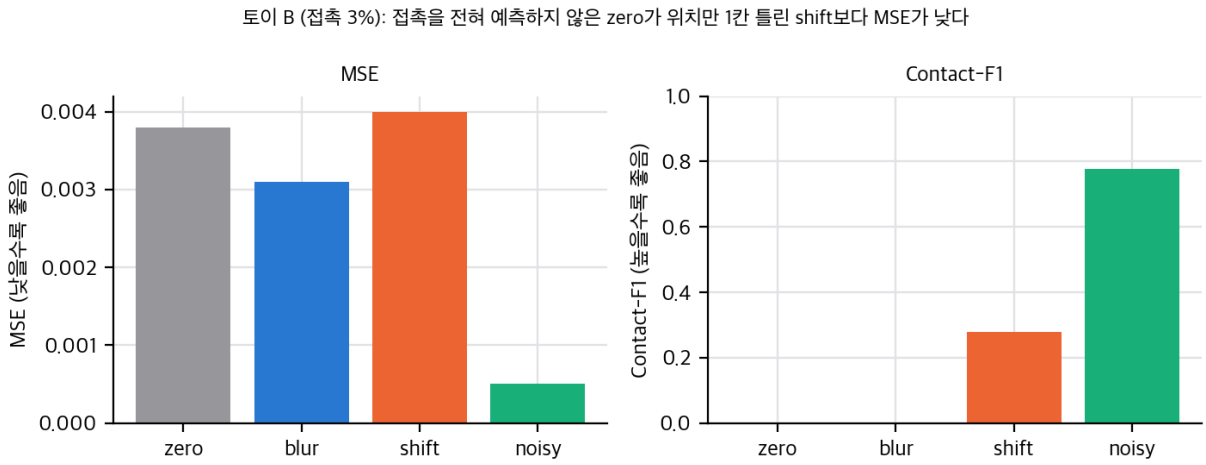
4.1 설정 (`analysis/transfer_toy.py`)

- 로봇 도메인: y = w_r^T x + ε, D = 8, 로봇 샘플 N_t = 25(5시간 고정의 소량 가정), σ = 0.5.
- 사람 도메인: 같은 입력 분포에서 y = (w_r + δ)^T x + ε. 격차 δ는 w 벡터에 1/√D 방향으로 더한 크기. 단위는 임의입니다.
- 리타게팅 오차: 사람 입력에 x + e, e ~ N(0, s_r^2 I). 입력 오차가 있는 회귀(errors-in-variables)입니다.
- 학습: 로봇 + 사람을 합친 최소제곱. 평가: 로봇 도메인 새 샘플 4000개의 MSE. 30회 반복 평균.
- 소스 샘플 N_s ∈ {0, 25, 50, 100, 200, 400}.

4.2 결과 (N_s = 400일 때 이득 = MSE(N_s=0) − MSE(N_s=400), 양수면 도움)

격차 δ \ 리타게팅 오차 s_r	0	0.25	0.5	1.0
0	+0.112	+0.111	−0.035	−0.694
0.25	+0.055	+0.049	−0.043	−0.726
0.5	−0.128	−0.122	−0.185	−0.768
1.0	−0.743	−0.682	−0.629	−0.949

- **도움이 되는 조건:** 격차가 작고(δ ≲ 0.25) 리타게팅 오차가 작을 때(s_r ≲ 0.25)입니다.
- **해가 되는 조건:** 격차가 δ ≥ 0.5 이거나, 격차가 0이어도 리타게팅 오차가 s_r ≥ 0.5이면 소스를 섞는 쪽이 손해입니다. s_r = 0.5에서 격차가 0이면 소스 섞기가 약간 손해(−0.035)인데, 입력 오차가 회귀 계수를 0 쪽으로 끌어당기기 때문입니다.
- **결론:** 사람 데이터의 이득은 도메인 격차와 리타게팅 오차에 따라 부호가 바뀝니다. 논문이 리타게팅 오차를 측정하지 않았으므로, 사람 데이터가 도움이 되는지는 논문으로 판단할 수 없습니다. 이 점은 04 C11, C12와 연결됩니다.
- 한계: 선형 모델, 입력 분포는 표준정규, 격차를 w 벡터에 한 방향으로만 줬습니다. 실제 촉각 맵은 비선형이고 접촉 희소성이 있어 결과를 그대로 옮길 수 없습니다.



그래프: 토이 B(접촉 3%). MSE는 zero가 shift보다 낮지만, 접촉 F1은 shift가 0.28로 높음. 직접 계산.

5. 토이 B: 희소 접촉 촉각 맵에서 MSE의 오해

5.1 설정 (`analysis/sparse_metric_toy.py`)

- 320 taxel을 20×16으로 근사. 접촉 taxel 비율 3%와 10%. 접촉 값은 0.4-1.0 균등, 정답은 가우시안으로 살짝 번짐.
- 후보 예측: zero(항상 0), blur(정답을 흐리고 0.6배), shift(정답을 1 taxel 옮김), noisy(정답 + 잡음 0.03).
- 접촉 지표: 임계값 0.1로 이진화한 IoU와 F1, 접촉 칸만 본 MAE. 200회 평균.
- **주의:** 임계값 0.1은 제가 고른 값입니다. blur는 최대값이 낮아 임계값 아래로 떨어지므로 F1이 0이 됩니다. 임계값을 바꾸면 blur 결과가 달라집니다.

5.2 결과 (접촉 3%)

후보	MSE	PSNR	Contact-IoU	Contact-F1	Contact-MAE
zero	0.0038	24.3	0.000	0.000	0.234
blur	0.0031	25.2	0.000	0.000	0.208
shift	0.0040	24.0	0.166	0.278	0.192
noisy	0.0005	32.9	0.639	0.776	0.024

- **오해가 생기는 지점:** shift는 접촉 위치 1칸만 틀렸지만 접촉 F1이 0.28입니다. MSE는 zero보다 나쁩니다(0.0040 대 0.0038). 아무것도 예측하지 않는 쪽이 MSE로는 더 낫게 보입니다.
- blur는 MSE가 zero보다 낫지만(0.0031) 접촉 F1은 0입니다. 흐린 예측이 평균 오차만 줄이고 접촉은 찾지 못합니다.
- 접촉 10%에서도 같은 방향입니다(zero MSE 0.0157 F1 0, shift MSE 0.0133 F1 0.48).
- **결론:** 희소 맵에서 MSE와 PSNR은 "배경을 0으로 맞추는" 능력을 크게 보상하고 접촉 위치의 정확성은 작게 반영합니다. 논문이 Contact-MAE·IoU·F1을 추가한 것은 이 문제를 인식했다는 뜻이고, 방향은 옳습니다. 다만 논문의 접촉 임계값과 Contact-MAE 정의가 없어서 이 설계가 실제로 얼마나 효과가 있는지 확인할 수 없습니다.

6. 유도

6.1 잔차 촉각 잠재(식 2)는 표현력을 늘리는가

- 디코더 D_x는 주어진 것이고 z_0는 깨끗한 문맥입니다. 예측값 $\hat{z}_t = z_0 + \hat{r}_t$이므로 잠재 오차는 $e_t = z_t - \hat{z}_t = r_t - \hat{r}_t$ 입니다.

- 따라서 잔차 예측의 잠재 오차는 절대 잠재 예측의 오차와 같습니다(z_0가 맞다는 조건에서). 정보가 늘지 않습니다.
- 차이는 **학습 동역학과 귀납 편향**에서만 생깁니다. 배경 압력이 큰 장면에서 학습 신호가 작은 변화에 집중하므로 실제 이득이 있을 수 있지만, 논문은 이 효과를 분리하지 않았습니다(잔차 대 절대 ablation 없음). 이 점은와 연결됩니다.
- 접촉 마스크 손실: 손실 값이 접촉 토큰에서만 계산되면 비접촉 토큰의 오차는 학습에 들어가지 않습니다. 평가 지표는 전체 taxel에서 계산되므로 학습과 평가가 다른 영역을 봅니다. 논문의 MSE 개선 중 일부가 이 불일치 때문일 수 있습니다. 마스크 정의가 없어 확인하지 못했습니다.

6.2 Pearson 자유도 1의 임계값

- 양측 검정에서 $t = r/\sqrt{(1-r^2)}$, 자유도 1의 t 분포는 Cauchy입니다.
- $P(|T| > t) = 1 - (2/\pi)\cdot\arctan(t)$. $p = 0.05$를 두면 $t = \tan(0.95\pi/2) \approx 12.71$이고 $r = t/\sqrt{(1+t^2)} \approx 0.9967$입니다.

6.3 MMRV의 닫힌 형식

- 정책 N = 3, 쌍 (i, j)에서 실제 순위가 뒤집힌 쌍이 하나뿐이고 실제 점수 차가 d이면 MMRV = (d + d)/3 = 2d/3입니다.
- 검산: Place Shoes WM-Robot d = 0.05 → 0.0333(본문 0.033). Stand Bottle d = 0.10 → 0.0667(본문 0.067). 두 값 모두 맞습니다.

6.4 Table IV 차이의 표준오차 (4.2절과 같은 가정)

- 셀 하나의 SE = SD/√10, 4과제 평균 SE = (SD/√10)/√4, 두 독립 평균의 차이 SE = √2 × 그 값.

7. 그래프

- `report/figures/table3_pearson_n3.png` : Table III의 Pearson과 n=3 p-value.
- `report/figures/transfer_toy.png` : 토이 A의 격차·리타게팅 오차에 따른 이득.
- `report/figures/sparse_metric.png` : 토이 B에서 MSE 순위와 접촉 F1 순위가 어긋나는 모습.

8. 재계산에서 찾은 본문과의 차이 요약

1. 사람 데이터 과제 수: 50(§I, §IV-C) 대 54(§IV-A). 같은 데이터인지 불명확.
2. "Aesthetic and image-quality scores stay nearly unchanged": Aesthetic +3.5%.
3. Table III의 Pearson 비교는 정책 3개 기반이라 통계적 비교가 성립하지 않음.
4. Table IV 대조군이 실제 데이터량을 다르게 함.
5. 시뮬레이터 점수의 절대 편향(+0.12~0.18)을 본문이 언급하지 않음.

DexTouch-WM 주장 검증 (04)

공식 코드가 없어서(02 §4) 코드 대조(`04_code_verification.md`)는 하지 않았습니다. 대신 논문 표·본문 수치를 재계산하고(03), 주장별로 판정했습니다.

판정 기준: **재현됨**(표 수치와 본문이 일치하고 계산이 맞음), **부분**(방향은 맞으나 근거가 약하거나 조건이 붙음), **확인 불가**(논문에 정보가 없음), **불일치**(본문과 표가 어긋남).

1. 주장 목록

ID	주장 (본문 위치)	확인한 것	판정	근거
C1	사람 데이터는 "50 tasks" (Intro, §IV-C) 대 "54 tasks" (§IV-A)	두 곳의 숫자 대조	**불일치**	§I, §IV-A
C2	Table I 전 셀의 값	표 수치와 본문 인용 값 대조	**재현됨**	03 §1.1
C3	사람 데이터 100h 추가 시 로봇 예측 개선 (PSNR 23.47→27.10, Traj 0.89→0.96, Geometry 0.13→0.10, Contact-IoU 0.42→0.59)	같은 표 값에서 변화량 계산	**부분**. 방향과 크기는 맞지만 단일 실행, 시드 미보고	03 §1.1, §1.3
C4	"+10h Human is almost flat on tactile metrics" (§IV-C)	+10h와 Robot-only 차이	**재현됨** (PSNR_taxel −0.46 dB, IoU +0.002, F1 +0.003)	03 §1.2
C5	"Visual metrics saturate between +50h and +100h" (§IV-C)	PSNR, Trajectory, JEPA, Semantic 변화	**부분**. PSNR(+0.22 dB)과 Trajectory(0)는 포화이나 JEPA는 +0.007 상승, Semantic은 +50h에서 최고	03 §1.2
C6	"Aesthetic and image-quality scores stay nearly unchanged" (§IV-C)	Aesthetic 0.400→0.414, Image Quality 0.718→0.724	**부분**. 절대값은 작지만 Aesthetic은 +3.5%	03 §1.1
C7	"Contact transfer is stronger": 촉각 지표가 시각보다 크게 개선	PSNR_taxel +17.6%, Contact-IoU +41.7%, Contact-F1 +28.1%	**부분**. 상대 변화는 크지만 Contact 임계값과 정의가 없어 크기 해석이 어려움	04 C19
C8	Table III 평균 Pearson: WM-Mix 0.844 > WM-Robot 0.646 (§IV-D)	정책 3개 기반 상관의 p값	**확인 불가** (유의하지 않음, 최소 p 0.15)	03 §2.2
C9	사람 촉각이 로봇 촉각 동역학을 공유한다 (Abstract, §I "shared contact dynamics")	사람 데이터만으로 촉각 예측, 사람·로봇 촉각 분포 비교, 전이 ablation을 찾음	**확인 불가**. 전이를 직접 측정한 실험이 없음. 개선은 "로봇 데이터 고정 + 사람 추가"의 결과뿐	01 §5
C10	같은 센서 배치라서 사람·로봇 촉각 관측이 호환된다 (§III-C, §IV-A)	센서 배치(320 taxel 배열) 비교	**부분**. 배치는 같으나 압력 보정, 감도, 장갑과 손가락 형상 차이를 다루지 않음	01 §3.2, §3.4
C11	리타게팅으로 사람 행동을 로봇 행동 공간에 옮긴다 (§III-D)	리타게팅 오차(키포인트, 접촉 위치, 물체 자세) 보고 여부	**확인 불가**. 정량 보고 없음	01 §3.4
C12	사람 데이터 효과가 리타게팅 오차에 강건하다 (암묵)	토이 A: 소스 이득이 격차·리타게팅 오차에 따라 부호가 바뀜	**확인 불가**(반증 가능성은 있음). 토이 결과는 논문 주장을 지지하지도 반박하지도 않음	03 §4.2
C13	Split-Hands가 Grid보다 재구성 손실이 낮고 Contact-IoU가 빨리 수렴 (Fig. 4)	Fig. 4 곡선	**확인 불가**. 그림만 있고 수치 없음	01 §3.2

ID	주장 (본문 위치)	확인한 것	판정	근거
C14	Cross-Attn은 정책 지표를 낮추고 AdaLN은 이를 회복 (Table I, §IV-B)	Trajectory 0.884 → 0.850 → 0.891	**부분**. 차이가 0.04 수준이고 시드 미보고	03 §1.3
C15	사람 데이터 0→100h로 Trajectory 정확도 0.89→0.96 (Table I)	표 값	**재현됨**(표 기준). 단일 실행	03 §1.1
C16	평가 상관 WM-Mix가 WM-Robot보다 평균적으로 높고 MMRV도 낮다 (Table III)	Pearson, MMRV 재계산	**재현됨**(값). 해석은 **부분**: MMRV 차이(0.025 대 0.017)는 Place Shoes 한 과제의 순위 교정(0.033→0)에서만 나오고, Stand Bottle의 0.067은 두 모델이 같음	03 §2.2
C17	12쌍 pooled Pearson 0.925로 두 적응 방식이 일관된다 (§IV-D)	12쌍 상관, 과제 평균 제거 후 상관	**재현됨**(0.925). 독립 표본이 아니고 정책 3개가 과제별로 반복되므로 "일관성"의 근거로는 약함	03 §2.4
C18	WM 점수는 실제 점수의 순위를 보존한다 (Table III, MMRV)	과제별 MMRV	**부분**. 순위 불일치는 Stand Bottle과 Place Shoes에서 생김. 절대 점수는 시뮬레이터 쪽이 평균 +0.12~0.18 높음(과대평가)	03 §2.3
C19	접촉 지표(Contact-MAE, IoU, F1)가 평균 MSE를 보완한다 (§IV-A)	토이 B: zero 예측이 shift 예측보다 MSE가 낮음	**재현됨**(토이 수준, 방향 맞음). 실제 맵에서 임계값에 따라 달라짐	03 §5.2
C20	평가 Contact-IoU·F1·Contact-MAE 정의	본문 정의 찾기	**확인 불가**. 임계값, 접촉 칸 정의, 마스크 기준 없음	01 §4.2
C21	합성 데이터로 정책을 학습할 수 있다 (Table IV, §IV-E)	실제 200 대 실제 100 + 합성 100	**부분**. FTP-1만 근접(−0.037), π0.5(−0.131)와 X-VLA(−0.100)는 하락. 대조군 설계 문제	03 §3
C22	사람 데이터로 과제 적응 데이터의 절반을 대체해도 된다 (§IV-D "Human-data substitution")	Table II, III, IV 종합	**부분**. 평가 상관은 유지되나 정책 학습에서는 두 정책이 떨어짐	03 §3.1
C23	로봇 held-out 평가는 사람 데이터와 과제가 다르다 (§IV-C)	사전학습 로봇 6과제와 held-out 6과제 대조	**확인 불가**. 같은 6과제인지 명시하지 않음. 같다면 "교차 과제 전이"라는 표현은 과장	01 §4.1
C24	WM-Robot은 5시간 로봇 데이터 고정 조건에서 적응 (§IV-C, 정책 평가)	Table II 설명: 적응에 로봇 200 궤적 사용	**불일치 가능성**. 5시간 사전학습 이후 200궤적을 추가로 쓰므로 "로봇 데이터 고정"의 예산이 다름	01 §4.4
C25	시뮬레이터 평가가 실제 정책 평가를 대신할 수 있다 (Table III 결론)	C16, C18, C8 종합	**부분**. 상관은 있으나 정책 3개, 절대 편향 있음	03 §2

2. 재현에 필요한 정보가 빠진 목록

- 학습 스텝, 배치 크기, 학습률, 옵티마이저, GPU 종류와 시간.
- 시드 수와 반복 실행 결과(분산).
- λ_tac 값, 접촉 마스크의 임계값.
- 67차원 행동의 구성 요소 차원 수(손목 pose 표현 방식 포함).
- 촉각 압력 단위와 정규화 방법, 두 도메인의 압력 보정.
- Trajectory accuracy, Geometry error, JEPA similarity, Subject consistency의 계산 정의와 사용 모델.
- Contact-IoU, F1, Contact-MAE의 임계값과 정의.
- 사람 데이터 에피소드 수, 로봇 held-out 에피소드 수, 시간당 프레임 수.
- 리타게팅 IK 솔버, 손 기하 정규화 방법.
- 정책 평가의 평가자 설정(블라인드 여부, 평가 기준 교육).

3. 검증 실행 목록 (이 저장소에서 한 것)

- `analysis/table_check.py` : Table I 변화량, 포화 점검, Table III 재계산(Pearson, p값, MMRV), 12쌍 pooled·과제 평균 제거 상관, 시뮬레이터 편향, Table IV 평균과 표준오차 민감도.
- `analysis/transfer_toy.py` : C12 관련 토이.
- `analysis/sparse_metric_toy.py` : C19 관련 토이.
- 재계산 결과는 모두 `table_check_results.json`, `transfer_toy_results.json`, `sparse_metric_results.json`에 있습니다.

4. 구현 가능성 판정

4.1 공식 재현: **불가**

- 코드, 가중치, 데이터셋 공개가 없고(02 §4), 학습 설정도 부족합니다(§2).
- 필요한 것: 촉각 장갑 두 벌(사람용·로봇용 동일 배치), 손 추적기(MANUS, VIVE), 20-DoF 로봇 손(Wuji)과 팔(Tianji), 사람 데이터 100시간, 로봇 데이터 5시간, 사전학습 비디오 백본(Wan2.2-TI2V-5B, 공개 가중치).
- 장비 목록 중 촉각 장갑과 Wuji 손은 구입 가능 여부가 불분명합니다. 공개 SDK 중 Wuji 손 제어 라이브러리(`wujihandpy`, MIT)는 있습니다.

4.2 이 맥(Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, torch 미설치)에서

항목	판정
논문 학습 재현 (100h 사람 + 5h 로봇 + 5B 백본 미세조정)	**불가**. CUDA 없음. 데이터도 없음. 학습 시간을 계산한 것은 아님
토이 수준 검증 (numpy, 이 저장소 완료)	**가능**
작은 촉각 인코더·잔차 잠재 학습 (합성 또는 공개 촉각 데이터)	**조건부**. torch 설치 승인 필요. MPS로 소형 모델은 가능할 것으로 추정(실행 안 함)
Wan2.2-5B 로드와 추론	**조건부**. 메모리는 24 GiB에서 빠듯할 수 있다는 추정(실행 안 함). 미세조정은 비현실적

4.3 같은 아이디어를 새로 구현하는 노력

- **중간에서 높음.** 구성 요소: (a) Wan2.2 DiT 위의 두 번째 경량 전문가와 joint attention(MoT 형태), (b) Split-Hands 촉각 토크나이저(공유 손끝 인코더 + 손바닥 인코더 + 패드 임베딩), (c) 초기 상태 기준 잔차 잠재와 접촉 마스크 손실, (d) dual-rate 조건, (e) 사람 자세 → 로봇 행동 리타게팅 파이프라인(IK 필요).
- 가장 값싼 부분은 (b)와 (c)입니다. 작은 촉각 맵 자동인코더 하나로 검증할 수 있습니다.
- 가장 비싼 부분은 (e)입니다. 사람 장갑 데이터 수집과 리타게팅 오차 측정이 없으면 DexTouch-WM의 핵심 주장을 확인할 수 없습니다.
- 줄 수 추정은 하지 않았습니다(근거 없음).

4.4 하드웨어 요구

- 학습: 대형 CUDA GPU 필요(근거: 5B 규모 비디오 DiT 미세조정은 보통 대형 GPU 메모리를 씀. 논문에 GPU 정보 없음, **추정**).
- 데이터 수집: 촉각 장갑 두 벌, 손 추적기, 로봇 손·팔.
- 공개 촉각 데이터(예: UniT 계열)로 촉각 인코더 부분만 검증하는 것은 하드웨어 없이도 가능합니다.

4.5 판정 요약

- **공식 재현: 불가.**
- **이 맥에서 재현: 불가. 토이와 소형 인코더 검증만 가능.**
- **새로 구현: 가능하나 중간에서 높은 노력. 데이터 수집이 병목.**
- **가치 판단:** 설계 아이디어(Split-Hands, 잔차 잠재, dual-rate)는 값싸게 검증할 수 있고 가치가 있습니다. 주장의 핵심인 "사람 데이터가 로봇 세계모델을 돕는다"는 리타게팅 오차와 도메인 격차를 재지 않으면 검증되지 않습니다.

5. 문제와 미확인 항목

- 논문 본문에 한계 절이 없음. 리뷰어가 볼 수 있는 질문(사람 촉각 전이, 리타게팅 오차, 시드 분산)이 본문에 답이 없습니다.
- 본문 밖의 자료(부록, 웹페이지, 보충 자료)를 확인하지 못했습니다. arXiv 페이지에 보충 자료 링크가 없었습니다.
- 워크숍 발표(라이트닝 토크) 여부와 발표 자료는 확인하지 못했습니다.
- 논문 그림 Fig. 4, Fig. 5, Fig. 6은 정성 결과라 재계산 대상이 아닙니다.

DexTouch-WM 선행연구와 관련 저장소 (02)

1. 논문이 놓은 계보

논문 §II(Related Work)를 기준으로 네 갈래로 정리합니다. 괄호 안은 논문의 참고문헌 번호입니다.

갈래	대표 연구	DexTouch-WM과의 차이
촉각을 제어 신호로 쓰는 정책	3D-ViTac [5], Reactive Diffusion Policy [26], ViTacFormer [3], Contact-grounded policy [25], FTP-1 [29], TactAlign [22]	촉각을 **예측 대상**으로 쓰지 않음. 논문은 이 점을 명시적으로 구분
사람이 모은 시각-촉각 데이터	Touch and Go [28], OpenTouch [18], DexUMI [24], FreeTacMan [23], DexViTac [1], Touch in the Wild [34]	모방·표현 학습이 목적. 논문은 같은 센서를 로봇에도 달아 **세계모델 학습 데이터로** 쓴다는 점이 다름
시각-촉각 세계모델	SPOTS [14], VT-WM [4], OmniVTA [32], FeelWorld [13], ViTacWorld [6], Dream-Tac [12], VT-WAM [19], TacForeSight [30], TouchWorld [33]	대부분 로봇 원격조작 데이터로 학습. 논문은 사람 촉각 데이터의 규모 효과를 **고정된 로봇 데이터**와 대비해 측정
세계모델 평가·생성	WorldGym [16], GigaWorld [2], Interactive world simulator [21], WorldSample [27], MMRV [9], [8]	평가 지표(MMRV)는 그대로 가져다 씀. 정책 3개로 계산하는 한계는 03 §2에서 다룸

논문의 중심 가설(§II 마지막 문단): "공유 접촉 동역학이 있으면 사람의 물리적 상호작용이 손 세계모델의 규모를 키운다." 이 가설을 검증하려면 촉각 전이 자체(사람 촉각 → 로봇 촉각)를 따로 떼어 보는 실험이 필요한데, 논문에는 그 실험이 없습니다(04 C9, C10).

2. 기반 기술

- **Wan2.2-TI2V-5B와 비디오 VAE [20]**: 시각 전문가의 초기화와 프레임 잠재. 공식 저장소 `Wan-Video/Wan2.2` (Apache-2.0).
- **Mixture-of-Transformers [10]**: 모달리티별 AdaLN·FFN을 두고 attention만 공유하는 구조.
- **Conditional flow matching [11]**: 식 (4)의 손실.
- **MMRV [9], [8]**: 식 (7). 정책 순위 불일치를 실제 점수 차로 가중.
- **WorldArena [17], GigaWorld [2]**: 시각 평가 지표 묶음(Aesthetic, Image Quality, JEPA similarity, Subject consistency, Trajectory accuracy). 논문은 이 프로토콜을 따른다고 하나 정의는 원 논문을 봐야 합니다.

3. 이 저장소의 다른 논문과의 관계

폴더	연구	DexTouch-WM과 맞닿는 지점	쓸 만한 것
`contact_grounded_policy/`	미래 촉각·상태 예측과 접촉 일관성	미래 촉각 예측	예측 대상을 접촉 상태로 둔 설계 비교
`restacvla/`	π0.5에 촉각 잔차를 VQ 토큰으로 주입	촉각을 "시각 예측과의 차이"로 표현	잔차 대 원시 ablation의 부재를 채우는 질문
`flashdexretarget/`	사람 손-물체 시연 → 로봇손 궤적 (RL)	사람→로봇 리타게팅	리타게팅 오차를 어떻게 재는지 (04 C12의 빈칸)

폴더	연구	DexTouch-WM과 맞닿는 지점	쓸 만한 것
`gnr/`	생성형 리타게팅 잔차(MPC 보정)	사람→로봇 행동 정렬	같은 IK 리타게팅 문제를 다른 방식으로 푼 비교 기준
`dreamx/`	사람 영상을 latent action으로 로봇 학습	사람 데이터를 로봇 행동 공간으로 옮김	사람 데이터 전이의 성공·실패 사례
`openwam/`	World Action Model 설계 부품 비교, Wan2.2 DiT 기반	같은 백본(Wan2.2-TI2V-5B) 계열	백본 선택과 학습 설정의 기준선
`agentic_wam/`	코드·영상·행동을 한 MoT로 생성	세계행동모델 구조	MoT 구조 비교
`gpt6_astra_tactile/`	고정된 대형 모델을 촉각 정책으로 씀	촉각 정책 대안	반사실 촉각 시험 설계

4. GitHub와 공개 자료 조사

조사 날짜 2026-11-10. `gh search repos` 는 검색 API 404로 실패해 `gh api repos/...` 로 확인했습니다. 웹 검색으로도 프로젝트 페이지를 찾지 못했습니다.

저장소	내용	공식?	라이선스	스타	마지막 커밋 (hash)
DexTouch-WM 코드	논문 공식 구현	**없음 (미확인)**. `DexTouch-WM`, `DexTouch`, `2609.20649` 로 저장소 검색 0건, 웹 검색에도 프로젝트 페이지 없음	-	-	-
`Wan-Video/Wan2.2`	백본 Wan2.2-TI2V-5B	공식(Wan 팀), 논문이 쓴 백본	Apache-2.0	18,481	2026-09-21 (`1ea34ff`)
`wuji-technology/wujihandpy`	Wuji Hand C++/Python SDK	공식(Wuji 팀), 논문의 Wuji 손 제어용으로 추정	MIT	40	2026-08-24 (`468e169`)
`wuji-technology/wujihandros2`	Wuji Hand ROS2 드라이버	공식(Wuji 팀)	명시 없음 (`none`)	16	2026-08-24 (`95000ed`)
`wuji-technology/wujihand-hmi`	Wuji Hand 모니터링·보정 GUI	공식(Wuji 팀)	MIT	2	2026-04-08 (`79d4f88`)
`Lee-Kangwon/dextouch`	DexTouch (LRA 2024, 촉각 전용 조작, arXiv:2401.12496)	**다른 연구**(이름만 같음)	-	0	2024-01-12

검토 메모:

- 논문의 촉각 장갑(Moxian)과 사람 손 추적(MANUS, VIVE)용 SDK는 GitHub에서 찾지 못했습니다. 장치 제조사 자료는 공개 저장소로 확인되지 않았습니다.
- Wuji SDK 두 개(wujihandpy, wujihandros2)는 논문의 WujiHand2와 같은 제품군이라는 점만 확인했습니다. 두 저장소 모두 WujiHand2 모델을 명시하는지는 확인하지 않았습니다.
- 논문 공개 자료 확인: 프로젝트 페이지 링크 없음(arXiv 초록 페이지와 PDF 본문 모두). 코드·데이터·가중치 공개 문장 없음.

- 논문 이름과 같은 외부 블로그 요약(예: 영문·중문 논문 요약 저장소)은 있으나, 원 저자가 올린 자료가 아니므로 근거로 쓰지 않았습니다.

5. 공개 자료 상태 (04와 연결)

- 공식 코드 없음 → 클론 없음 → `repo/` 없음 → 04는 `04_claim_verification.md` (주장 C1-C20 재계산·검증)로 씀.
- 리타게팅·데이터 수집 하드웨어 자료가 공개되지 않아, 04 §4의 재현 판정은 "논문만으로 구현하는 쪽"으로 봐야 합니다.