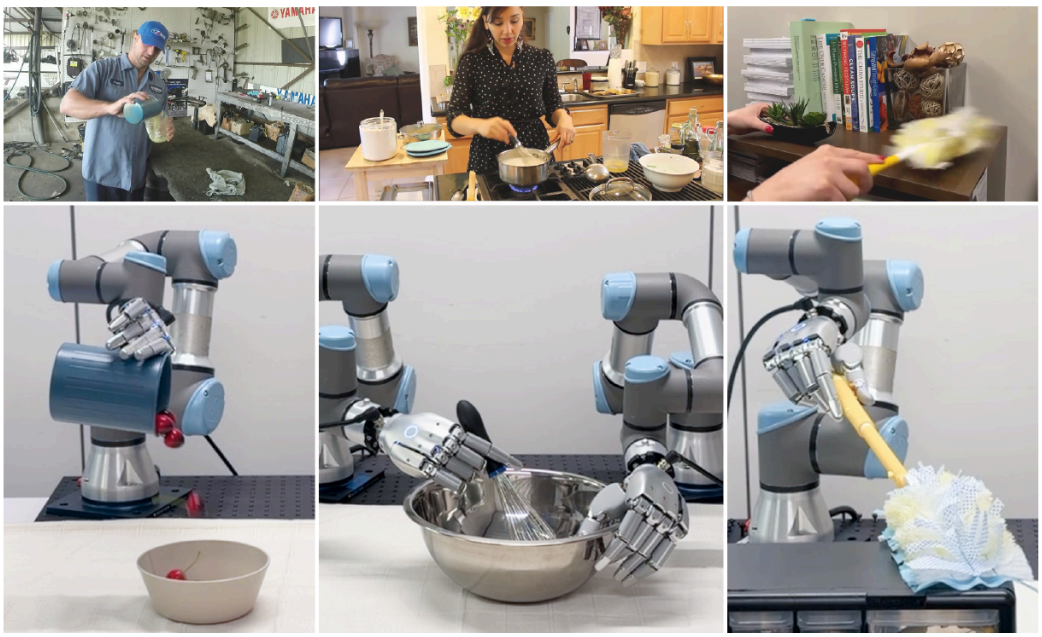
Do as I Do: 분석 리포트

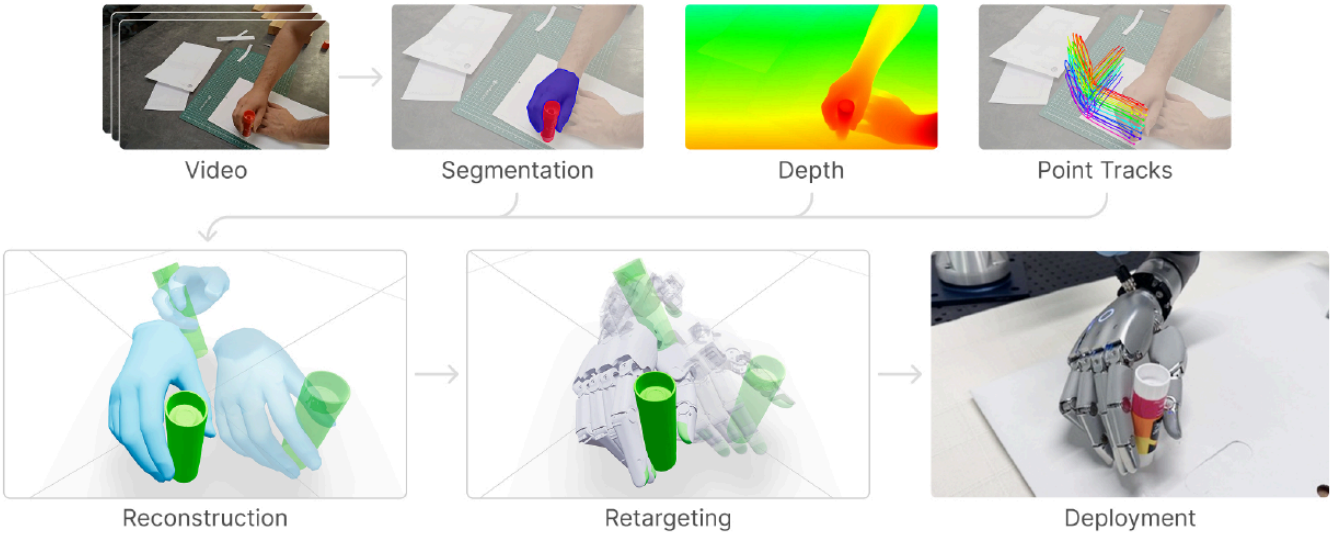
arXiv:2606.19333 · UC Berkeley (Paliwal, Etukuru, Liang, Abbeel, Shafiullah, Malik) · 코드 malik-group/do-as-i-do @ 824591b · 분석일 2026-10-28



논문 Fig. 1: 일상 영상(위)에서 로봇 실행 궤적(아래)을 얻는다.

핵심 요약

1. **무엇을 하는가:** 단안 RGB로 찍은 일상 영상(인터넷, egocentric, 생성 영상)에서 손과 강체 물체의 4D 궤적을 복원하고, MuJoCo Warp에서 sampling MPC로 22-DoF Sharpa 손 궤적으로 리타겟팅한다. 결과로 사람이 검증한 궤적 500개를 만들었고, 그중 10개 과제를 실제 로봇에서 시연했다.
2. **복원의 핵심:** SAM 3D 추론 루프에 Eq. 1 blending을 넣어, 학습 없이 비디오 추적기로 바꾸었다. 우리가 유도한 결과로는 **마지막 스텝 출력이 정확히 (1−α)·네트워크 예측 + α·이전 pose** 이므로, 이 방법은 프레임 단위 **EMA 필터**이고 적응형 α_p는 **One-Euro 필터**와 같은 발상이다(§2, toy 검증).
3. **리타겟팅의 핵심:** SPIDER 대비 성공률을 25%에서 71%로 올렸는데, **+46%p 중 +41%p가 Warmup** 하나에서 나왔다. Perturbation(+1%p)은 잡음 수준이다.
4. **수치를 읽을 때 주의할 점:** 같은 파이프라인 안에서 FoundationPose와 비교하면 추적기의 이득은 실험실 데이터에서 작다(HOI4D에서는 동률). 리타겟팅 성공 기준(평균 10 cm, 0.5 rad)은 느슨해서, 공개된 whisking 데모는 기준을 통과하지만 물체를 레퍼런스 높이의 약 1/3만 들어 올린다.
5. **코드 대조:** 핵심 식과 Table 4 하이퍼파라미터는 코드와 정확히 일치한다. 다만 본문에 없는 post-optimization, warmup 부가 장치, perturbation gate 등 10개 항목(D1–D10)이 결과에 기여했을 수 있다.



논문 Fig. 2: 파이프라인 개요. 영상 → 분할, 깊이, 점 추적 → 복원 → 리타겟팅 → 배포.

01. 논문 분석: Do as I Do (arXiv:2606.19333)

- 제목: *Do as I Do: Dexterous Manipulation Data from Everyday Human Videos*
- 저자: Bhawna Paliwal*, Haritheja Etukuru*, William Liang*, Pieter Abbeel, Nur Muhammad "Mahi" Shafiullah, Jitendra Malik (UC Berkeley)
- 공개: arXiv v1, 2026-06-17 · 코드 https://github.com/malik-group/do-as-i-do (확인 커밋 `824591b`, 2026-08-02) · 프로젝트 https://do-as-i-do.com
- 분석 범위: 본문 9쪽과 부록 A–D(총 20쪽), 공개 코드(메인 레포와 서브모듈 `Fast-SAM3D`, `sam-3d-objects`)

---

1. Abstract (한 줄 요약과 주장)

한 줄 요약: 단안 RGB로 찍은 일상 영상(인터넷, egocentric, 생성 영상) 한 편에서 손과 강체 물체의 4D 궤적을 복원하고, MuJoCo Warp 위에서 sampling 기반 MPC로 22-DoF 로봇손(Sharpa Wave) 궤적으로 리타겟팅한 뒤, 실제 UR3e 양팔 로봇에서 재생하는 파이프라인입니다.

논문이 내세우는 기여는 네 가지입니다.

1. 복원과 리타겟팅의 2단계 알고리즘을 제시합니다.
2. SAM 3D를 **학습 없이 추론 시점에만 손대서** 비디오 물체 추적기로 바꾸었고(guided flow matching), DexYCB·HOI4D에서 SOTA를 달성했다고 주장합니다.
3. 잡음이 많은 복원 레퍼런스에서도 리타겟팅이 동작하도록 Warmup, Random Force Perturbation, Transition Reward를 추가했습니다.
4. 저자들이 아는 범위에서 인터넷 영상부터 실제 다지(多指) 로봇손 롤아웃까지 이어지는 최초의 파이프라인이라고 주장합니다.

---

2. Method

2.1 전체 구조 (Fig. 2, 부록 Fig. 7)

```
비디오 ─┬─ SAM 3 분할(물체: 클릭, 손: 텍스트) ─┐
        ├─ MoGe-2 pointmap + intrinsics ──────┤
        ├─ HaWoR 손 메쉬(MANO) ──────────────┤
        ├─ GeoCalib 중력 방향 ──────────────┤
        └─ BootsTAPIR 2D point track → 회전 속도 ┤
                                              ▼
   기준 프레임에서 SAM 3D 메쉬 생성(x̄s 고정) → guided flow matching으로 프레임별 pose 추적
   → N=25 후보 클러스터링 → 손 기준 metric 정렬(최소제곱) → 4D hand-object 궤적
                                              ▼
   mink 운동학 IK(사람손 → Sharpa) → MPPI식 annealed sampling MPC (MuJoCo Warp, 1024 샘플)
   + Warmup / Perturbation / Transition Reward → 로봇 궤적 → UR3e+Sharpa IK → 실제 재생(50 Hz, 약 0.5배속)
```

2.2 복원: SAM 3D를 비디오 추적기로 바꾸는 방법

문제: SAM 3D[11]는 단일 이미지와 마스크를 받아 $p_\theta(x^s, x^p \mid c)$, 즉 형상(shape) latent와 자세(pose) latent의 결합분포에서 샘플을 뽑습니다. 프레임마다 독립적으로 돌리면 메쉬가 매번 달라지고 pose도 시간적으로 일관되지 않습

니다.

핵심 아이디어 (Eq. 1): shape와 pose가 같은 latent 공간에서 함께 생성된다는 점을 이용합니다. flow matching ODE를 Euler로 적분할 때 매 스텝마다 블록별로 다음 blending을 적용합니다.

```
x_t^s = (1-α_s)(x_{t-Δ}^s + Δ v_θ^s) + α_s · [(1-t) ε^s + t · x̄^s]        # shape: 기준 프레임 형상 쪽으로
x_t^p = (1-α_p)(x_{t-Δ}^p + Δ v_θ^p) + α_p · [(1-t) ε^p + t · x^p_{k-1}]   # pose: 이전 프레임 자세 쪽으로
```

- α_s = 1(코드 `--guidance_strength 1`)이면 shape 블록은 매 스텝 정확히 "x̄^s를 같은 노이즈로 보간한 점"으로 **치환**됩니다. RePaint[65]나 Song et al.[66]의 imputation과 같은 replacement 방식 조건부 생성입니다.
- pose 블록은 α_p만큼 이전 프레임 쪽으로 당겨집니다. 이 연산이 실제로 무엇을 하는지는 `03_derivations.md` §1에서 유도했습니다. 결론은 **마지막 스텝의 출력이 정확히 (1-α_p)·(네트워크 x1-예측) + α_p·(이전 pose)** 라는 것이고, 프레임 단위로 보면 지수이동평균(EMA) 필터입니다.

적응형 α_p (부록 A): 연속한 두 프레임에서 마스크 안 20개 점을 BootsTAPIR[67]로 추적하고, SVD로 2D 강체변환을 맞춰 평면 내 회전량 Δθ_k를 구합니다. 그다음 `α_p(k) = max(0.1, 0.7 − 0.09·|Δθ_k|)` 로 둡니다. 코드상 단위는 **deg/frame**이며 논문 본문에는 단위가 적혀 있지 않습니다. 따라서 6.7°/frame 이상에서 하한 0.1에 걸립니다.

후보 선택: 프레임마다 N=25개 pose를 샘플링하고 가중 SE(3) 거리 `w_t‖t_i−t_j‖ + w_r·geodesic(q_i,q_j)` 로 계층 군집화합니다. 작은 클러스터는 버리고 남은 후보를 마스크 IoU로 고릅니다. 정석은 pose 조건부 로그우도(Eq. 2, instantaneous change of variables)로 순위를 매기는 것이지만, 논문 계산으로는 프레임당 약 8.7k번의 forward+backward가 필요해(N·T·(1+D_p) = 25·25·14) 사용하지 않았습니다.

손-물체 정렬 (부록 A, Fig. 8): HaWoR 손 스케일을 near-metric 기준으로 삼습니다. 프레임마다 다음을 계산합니다.

- k = z^H_hand / z^M_hand
- obj_target = c^H_hand + k(c^M_obj − c^M_hand)

그다음 물체 회전은 고정한 채 카메라 광선 방향의 스칼라 s 하나를 1차원 최소제곱 `s* = tᵀ(obj_target − c_mesh)/tᵀt` 로 풉니다. 마지막으로 GeoCalib[68]로 중력 방향을 맞춥니다.

2.3 리타겟팅: 잡음 레퍼런스용 annealed sampling MPC

기반은 SPIDER[15]입니다. MPPI 계열 sampling 최적화에서 노이즈 커널을 반복(iteration)과 예측 구간(horizon) 양쪽으로 annealing합니다. 설정값은 부록 Table 4에 있습니다.

- 계획은 0.5 s(2 Hz)마다 하고 horizon은 3 s입니다.
- 1024개 샘플로 최대 32회 반복합니다.
- sim dt는 0.005 s(200 Hz)입니다.
- 보상은 물체(위치, 자세)와 손(위치, 자세, 관절) 추적 오차, 침투 페널티, 전이 페널티로 구성됩니다.

여기에 세 가지를 더했습니다.

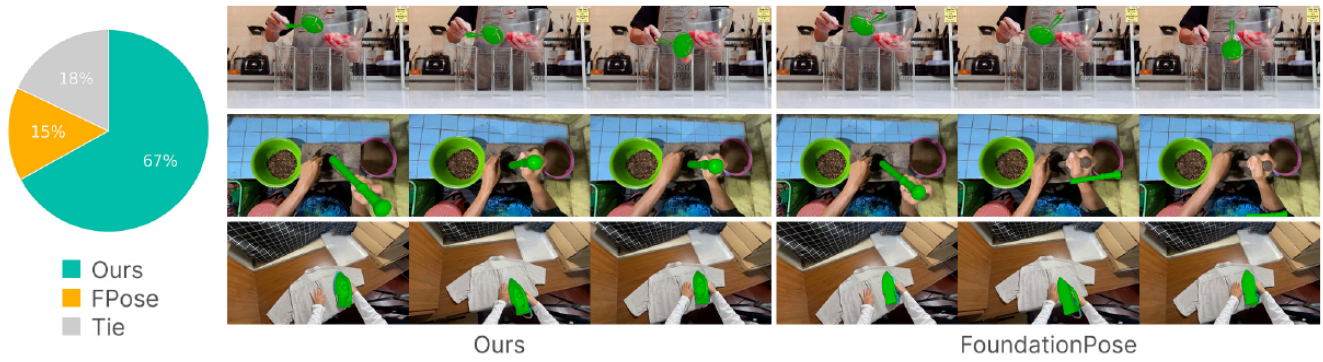
구성 요소	해결하려는 실패	방식
Warmup	잡음 낀 첫 프레임에서 시작하면 복구가 불가능하고, annealing 특성상 초반 H 스텝은 탐색이 덜 됨	레퍼런스 앞에 H(=3 s) 스텝을 덧붙이고, 이 동안 물체를 weld로 공중에 고정한 채 손만 자유롭게 움직임. warmup이 끝나면 weld를 해제함
Random Force Perturbation	손끝 위에 아슬아슬하게 올려두는 식의 불안정한 국소해	롤아웃 중 물체에 무작위 힘·토크를 가하고, 후보마다 K=4개 교란 시드에서 보상을 **평균**함 (기댓값 기준의 강건화)
Transition Reward	잡음이 낀 추적 보상만으로는 잡기와 놓기 같은 계단형 사건을 유도하기 어려움	레퍼런스상 in-hand 구간에서 손-물체 접촉이 없거나, rest 구간에서 물체-바닥 접촉이 없으면 상수 페널티를 줌

부록 B에는 본문에 없는 실무 요령도 적혀 있습니다. 이전 계획과 새 레퍼런스를 보간으로 이어 붙이는 reference blending, 운동학 IK를 여러 초기값으로 돌리는 방법, 비스듬히 놓인 물체용 바닥 "plate"(pedestal), 메쉬를 2 mm 두껍게 하고 팽창시키는 처리, CoACD 볼록 분해입니다.

---

3. Experiments

3.1 복원 (Table 2, Fig. 5, Table 5)

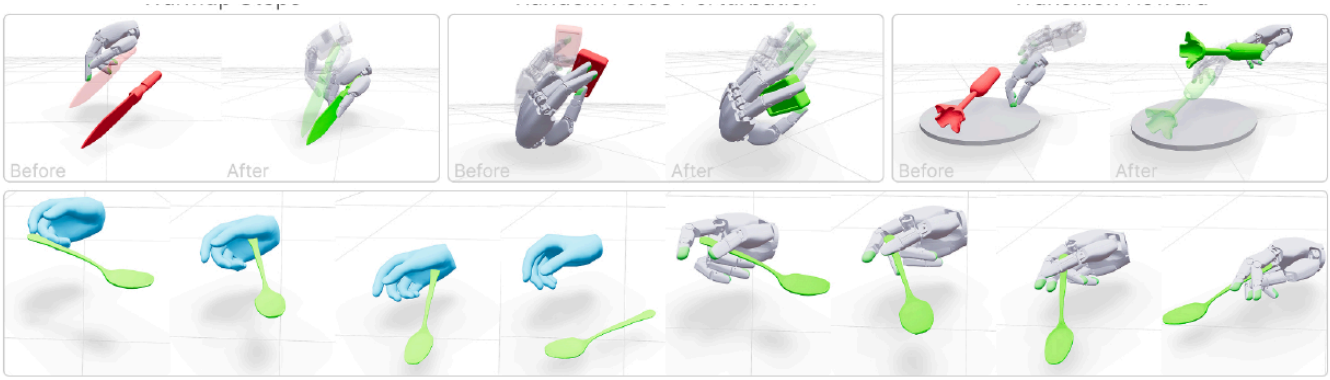


논문 Fig. 5: in-the-wild 150편에 대한 사람 선호도 평가(Ours 67%), FoundationPose와의 정성 비교.

	DexYCB F-5 / F-10 / CD	HOI4D F-5 / F-10 / CD
G-HOP	0.31 / 0.49 / 8.11	0.69 / 0.91 / 0.63
FoundationPose (같은 파이프라인에 끼워 넣음)	0.69 / 0.89 / 0.89	0.71 / 0.91 / 0.49
Any6D (같은 파이프라인에 끼워 넣음)	0.69 / 0.88 / 0.97	0.71 / 0.91 / 0.50
Ours	**0.71 / 0.93 / 0.66**	**0.72 / 0.91 / 0.49**

- **해석:** joint 방법(HO, IHOI, HORSE, MCC-HO, G-HOP) 대비 격차는 큽니다. 하지만 그 격차의 대부분은 "SAM 3D 메쉬 + 모듈식 파이프라인"이라는 구성 자체에서 나옵니다. 같은 파이프라인에 FoundationPose를 끼운 경우와 비교하면 **DexYCB에서 F-5 +0.02, CD 0.89→0.66이고, HOI4D에서는 사실상 동률(0.71 vs 0.72, CD 0.49 동일)**입니다. 즉 "추적기"만의 기여는 깨끗한 실험실 데이터에서 작습니다. 차이가 드러나는 곳은 in-the-wild 영상입니다.
- in-the-wild 150편을 사람이 선호도로 평가한 결과는 Ours 67%, FPose 18%, 동률 15%였습니다. 동률을 뺀 승률은 79%이고, Fleiss' κ=0.65, 만장일치는 75%였습니다. 다만 평가자 풀이 5명이고 영상당 3명이 평가했으며, 비교 대상은 FPose 하나뿐입니다(Any6D 제외). 정답 pose가 없으므로 "2D로 재투영했을 때 그럴듯해 보이는가"를 평가한 것이고, 3D 정확도를 잰 것은 아닙니다.

- **Ablation (Table 5):** 적응형 α_p는 고정 α_p 대비 DexYCB CD를 0.74→0.66으로 낮췄고, HOI4D F-5를 0.69→0.72로 올렸습니다. 클러스터링 선택은 로그우도 선택과 거의 같으면서(CD 0.66 vs 0.65) 최대 30배 빠릅니다. 무작위 선택은 HOI4D에서 크게 나빠집니다(F-5 0.62).



논문 Fig. 4: Warmup, Perturbation, Transition Reward가 해결하는 실패 유형.

3.2 리타겟팅 (Table 3)

방법	복원 레퍼런스 655개: 성공 / Pos / Rot	OakInk2 1,352개: 성공 / Pos / Rot
Annealed Sampling (SPIDER)	0.25 / 0.08 / 0.40	0.72 / 0.08 / 0.32
+ Warmup	**0.66** / 0.06 / 0.28	0.77 / 0.06 / 0.25
+ Perturbation	0.67 / 0.06 / 0.30	0.79 / 0.03 / 0.14
+ Transition Reward	**0.71** / 0.05 / 0.28	**0.81** / 0.03 / 0.15

성공 기준은 평균 위치 오차 < 0.1 m이고 평균 회전 오차 < 0.5 rad입니다(SPIDER, ManipTrans, DexMachina 관례).

- **해석:** 전체 향상 +46%p(0.25→0.71) 가운데 +41%p는 **Warmup** 하나에서 나옵니다. Perturbation은 복원 데이터에서 +1%p로 통계적으로 구분하기 어렵고, 저자들도 "정성적으로 자연스러운 grasp"를 근거로 들었습니다. Transition Reward는 +4%p입니다. 신뢰구간과 시드 반복은 보고되지 않았습니다. 655개 기준 이항 표준오차는 약 ±1.8%p이므로, 0.66→0.67 차이는 잡음 수준입니다.
- 성공 기준이 느슨한 편입니다. 평균 10 cm는 거품기나 숟가락 크기 물체에서 상당히 큰 오차이고, 성공이 "과제를 실제로 완수했다"는 뜻도 아닙니다. 예를 들어 우리가 공개 whisking 결과를 계산해 보면 기준은 통과하지만, 레퍼런스상 물체 높이 최대 0.228 m에 비해 시뮬레이션에서는 0.132 m까지만 올라갑니다(`04_code_verification.md` §3).

3.3 실제 배포와 데이터 필터링

- 사람이 검증한 궤적 500개를 만들었습니다. 출처 비율은 인터넷 53%, egocentric 31%, 생성 영상 16%입니다. 이 가운데 10개 동작을 실제 로봇에서 재생했습니다.
- 실제 로봇에서의 **성공률은 보고되지 않았습니다.** 영상 시연만 있습니다. 또한 초기 pose(x, y, z, yaw)는 사람이 직접 로봇 작업공간에 맞췄고, 재생은 약 0.5배속 open-loop입니다.
- **필터링 playbook:** 100DOH에서 뽑은 10초 클립 2,000개 중 실제로 손-물체 상호작용이 있는 것은 187개(9%)였습니다. 최종적으로 복원 단계를 통과한 것은 83개(4%)입니다. 결론은 인터넷 영상을 걸러내지 않고 쓰면 약 20배의 낭비가 생긴다는 것입니다.

---

4. Limitations

4.1 저자가 밝힌 한계

강체만 다룹니다. 단안 metric depth에 의존하고, 접촉과 가림을 구분하지 못합니다(깊이 모호성). 장면 전체가 아니라 손과 물체만 복원하므로 장애물이나 관절형 물체를 다루지 못합니다. 시뮬레이터와 실제 사이의 간극도 남아 있습니다.

4.2 분석하면서 추가로 발견한 한계와 의문점

1. **적응형 α_p가 2D 평면 내 회전만 봅니다.** 카메라 광축에 수직인 축으로 도는 회전(out-of-plane)은 Δθ≈0으로 측정되어 α_p가 높게 유지되고, 그 결과 과도한 평활화와 지연이 생길 수 있습니다. 숟가락을 뒤집는 동작이 그 예입니다.
2. **EMA 구조이므로 지연(lag)이 원리적으로 생깁니다.** α_p=0.7이면 실효 가중치가 0.7 이상입니다(`03` §1.2). 빠른 동작에서는 하한 0.1로 풀리지만, 회전 없이 빠르게 병진하는 동작에서는 Δθ≈0이라 강하게 평활화됩니다. translation 속도는 α_p에 반영되지 않습니다.
3. **Pose 블렌딩은 latent 공간에서 선형으로 이루어집니다.** 6D 회전 표현을 정규화한 latent를 선형 보간하므로 SO(3) 위의 측지 보간이 아닙니다. 회전 차이가 작을 때는 문제가 없지만, 큰 회전이나 플립 근처에서는 의미가 불분명합니다.
4. **복원 단계 하이퍼파라미터가 영상마다 다릅니다.** 예를 들어 데모 스크립트에는 기준 프레임, 물체 클릭, 시각화 `--scale 0.1808` 같은 수동 입력이 들어갑니다. SAM 3 물체 분할도 클릭 GUI로 합니다. 따라서 "scalable"이라는 표현이 아직 완전 자동화를 뜻하지는 않습니다.
5. **보고 방식에 통계 정보가 없습니다.** 리타겟팅 ablation에 시드 반복과 신뢰구간이 없습니다. 실제 로봇 성공률도 없습니다. in-the-wild 복원 655개 중 사람이 검증해서 남긴 500개와 Table 3의 성공 71%가 서로 어떤 관계인지도 설명되지 않습니다.
6. **결과물은 정책이 아니라 궤적입니다.** 생성된 데이터로 정책을 학습해서 일반화를 보인 실험이 없습니다. "데이터 생성기"로서의 효용, 예를 들어 이 데이터로 학습한 VLA나 diffusion policy의 성능은 검증되지 않았습니다.

03. 유도와 해석

논문에 명시되지 않았지만 코드와 수식에서 직접 따라 나오는 성질을 정리했습니다. 수치 확인은 `analysis/guidance_toy.py`로 했고(CPU, 약 1초), 결과는 `analysis/guidance_toy_results.json`에 있습니다.

---

1. Eq. 1의 guided flow matching은 사실상 "지수이동평균(EMA) 필터"다

1.1 마지막 스텝 항등식

- **표기:** flow matching 경로는 x_t = (1−t)ε + t·x_1이고, t=0이 노이즈, t=1이 데이터입니다. 코드의 `_prepare_t_and_d`는 `t_seq = linspace(0, 1, steps+1)`이고, `reversed_timestamp=False`가 기본값입니다(HF `pipeline.yaml` 값은 가중치 접근 권한이 필요해 직접 확인하지 못했지만, blending 식 자체가 t=1을 데이터로 가정하고 있습니다).
- **정의:** 어떤 velocity v든 "x1-예측" x̂_1 := x_t + (1−t)·v 로 다시 쓸 수 있습니다.
- **마지막 Euler 스텝:** t' = 1−Δ에서 t = 1로 가는 스텝을 보면 다음과 같습니다.

```
x̂_t   = x_{t'} + Δ·v(x_{t'}, t')
      = x_{t'} + (1−t')·v          (Δ = 1−t')
      = x̂_1(x_{t'})                 ← 네트워크의 x1-예측 그 자체

blending: z_ref(1) = (1−1)ε + 1·x_ref = x_ref
x_1 = (1−α)·x̂_1 + α·x_ref                                   (★)
```

결론: 노이즈 ε와 적분 경로, Taylor cache 근사(Fast-SAM3D)와 상관없이, 최종 pose latent는 **"마지막 스텝의 네트워크 예측"과 "이전 프레임 pose" 사이의 볼록결합**입니다. α_s = 1이면 shape는 정확히 x̂^s로 끝납니다.

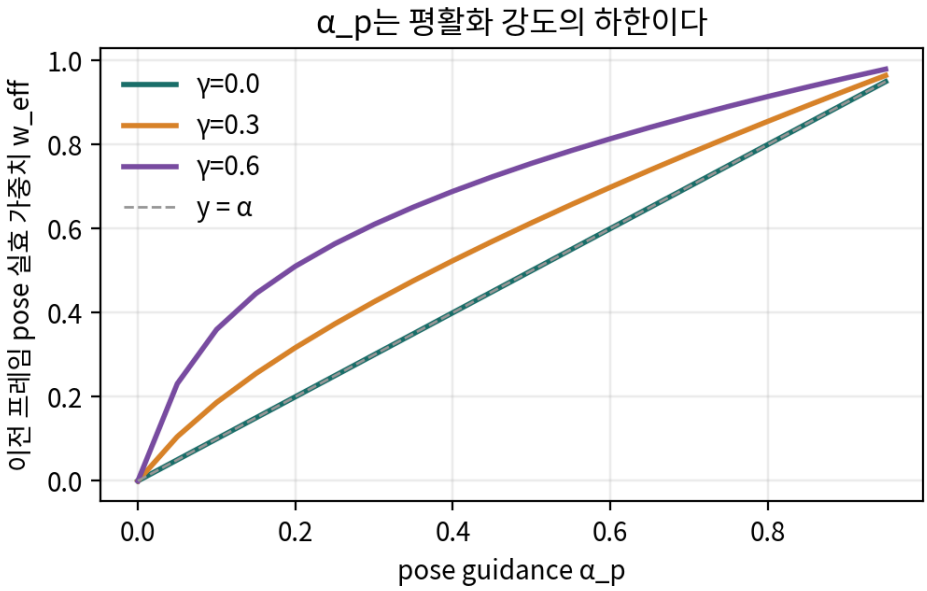
- **수치 확인:** 13차원(6D rot + t3 + s3 + translation_scale 1, 코드의 `_POSE_LATENT_KEYS`) 비선형·상태 의존 velocity를 200번 무작위로 뽑아 확인했습니다. 최대 절대오차는 **0.0**이었습니다.

1.2 α_p는 평활화 강도의 "하한"이다

(★)의 x̂_1 자체도 앞선 24번의 blending으로 x_ref 쪽으로 끌려간 상태 x_{t'}를 입력받아 계산됩니다. 그래서 네트워크 예측이 현재 상태에 의존하는 정도(γ)만큼 이전 pose의 실효 가중치 w_eff가 α보다 커집니다.

toy 모델은 x̂_1 = (1−γ)·y_obs + γ·(x_t에서 외삽한 x_1)이고, T=25입니다.

α_p	γ=0	γ=0.3	γ=0.6
0.1	0.10	0.19	0.36
0.5	0.50	0.61	0.76
0.7	0.70	0.78	0.87



함의: 논문 Table 5의 "고정 α_p"(코드 기본값 0.5)는 실제로는 그보다 강한 평활화입니다. SAM 3D 백본이 현재 latent에 얼마나 의존하는지(γ)는 모델 고유의 성질이므로, 같은 α_p라도 물체나 장면에 따라 평활화 강도가 달라집니다.

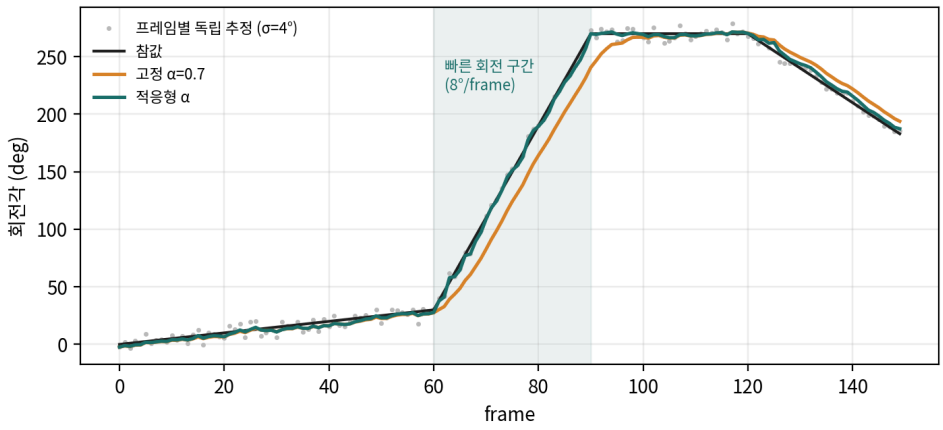
1.3 프레임 단위로 보면 EMA, 적응형 α는 One-Euro 필터와 같은 발상

프레임 k의 출력을 pose_k라 하면 pose_k ≈ (1−w_k)·obs_k + w_k·pose_{k−1}입니다. 1차 저역통과(EMA) 필터이고, 정상상태 지연은 약 w/(1−w) 프레임입니다. 예를 들어 w=0.78이면 약 3.5프레임입니다.

적응형 규칙 α_p = max(0.1, 0.7 − 0.09|Δθ|)는 "움직임이 빠르면 평활화를 줄인다"는 규칙입니다. HCI 분야의 One-Euro 필터(Casiez, Roussel, Vogel, CHI 2012, "1€ Filter")가 속도에 따라 차단 주파수를 올리는 것과 같은 구조입니다. **논문은 이 연결을 언급하지 않았습니다.**

toy 실험 조건은 1D 회전, 프레임별 독립 추정 잡음 σ=4°, 0.5→8→0→−3 °/frame 구간입니다.

방식	전체 RMSE (°)	빠른 구간 RMSE	빠른 구간 최대 지연	지터
가이던스 없음 (α=0)	3.99	3.65	7.8	5.98
고정 α=0.5	6.28	12.27	16.3	1.91
고정 α=0.7	12.75	25.13	30.5	1.50
적응형 α	**2.93**	3.73	7.5	2.04



해석: 고정 α는 지터를 줄이는 대가로 빠른 구간에서 큰 지연을 만듭니다. 적응형 α는 정지 구간에서는 평활화하고 빠른 구간에서는 풀어 주므로 두 장점을 함께 얻습니다. 이 결과는 Table 5에서 적응형이 고정보다 나았던 이유를 정성적으로 설명합니다.

주의: 이 toy 실험은 가우시안 잡음만 넣었고, SAM 3D 특유의 이상치(대칭 물체의 180° 플립)는 모델링하지 않았습니다. 플립은 N=25 클러스터링이 담당합니다.

1.4 이 관점에서 나오는 개선 아이디어 (검증되지 않은 가설)

- **(a) 속도 추정을 3D로 확장:** 2D Δθ 대신 이전 두 프레임 pose의 SE(3) 차분이나 3D point track을 쓰면 out-of-plane 회전과 병진 속도도 반영할 수 있습니다.
- **(b) EMA를 상수속도 예측(α-β 필터나 Kalman)으로 교체:** x_ref를 pose_{k−1} 대신 pose_{k−1} ⊕ (pose_{k−1} ⊖ pose_{k−2})로 바꾸면 정상상태 지연이 사라집니다. 코드에서는 `pose_target`만 바꾸면 되므로 구현 비용이 낮습니다.
- **(c) 블렌딩을 SO(3) 위에서 수행:** latent를 선형 보간하는 대신 회전 블록을 slerp으로 처리합니다.

---

2. Replacement 방식 조건부 생성의 편향

- α_s = 1의 shape 치환은 p(x^p | x^s = x̂^s, c)에서 정확히 샘플링하는 방법이 아닙니다. 매 스텝 shape 블록을 "같은 ε로 보간한 정답"으로 덮어쓰면, 네트워크가 보는 shape-pose 결합 상태는 학습 분포의 경로와 다를 수 있습니다.
- 이런 replacement 방식이 근사라는 점은 RePaint[65] 이후 inpainting 문헌에서 잘 알려져 있습니다. RePaint가 resampling을 도입한 이유도 이것입니다.
- 논문은 RePaint와 Song et al.[66]을 인용하면서도 이 편향은 논의하지 않습니다. 실무적으로는 N=25 샘플링과 클러스터링, 그리고 post-optimization(렌더 마스크 정렬, 본문에는 없음)이 이 편향을 덮어 주는 역할을 하는 것으로 보입니다.

---

3. 손-물체 정렬의 닫힌 해

- **목적함수:** min_s ‖ c_mesh + s·t − obj_target ‖ ²
- **미분해서 0으로 두면:** tᵀ(c_mesh + s·t − obj_target) = 0, 따라서 s* = tᵀ(obj_target − c_mesh) / tᵀt 입니다. 부록 식과 일치합니다.
- **기하학적 의미:** 물체를 카메라 원점에서 나가는 광선(방향 t)을 따라 미끄러뜨려, 손 기준으로 예측한 위치에 가장 가까운 깊이를 찾는 것입니다. 회전은 바뀌지 않습니다. 물체가 광선 방향과 직교하게 이동해야 할 오차(측면 오차)는 고칠 수 없습니다.
- **스케일:** k = z^H/z^M은 손 중심의 깊이 비율 하나만 씁니다. MoGe 깊이 오차가 손 주변에 국소적으로 몰려 있으면 그 오차가 물체 위치 전체에 비례해서 전파됩니다.

---

4. 리타겟팅 최적화기의 실제 형태 (코드 기준)

논문은 이 최적화기를 "MPPI-style, kernel annealed across iterations and horizon"이라고만 설명합니다. 코드(`retargeting/utils/sampling.py`)가 실제로 하는 일은 다음과 같습니다.

```
보상 R_i = −‖W ⊙ Δqpos‖₂ − 1e−4‖Δqvel‖ − 3000·max(pen − 5mm, 0)² − 0.5·𝟙[전이 불일치] (+
terminal ×10)
가중치: 상위 10% (elite 102개)만 남기고, 그 안에서 z-정규화 후 softmax(·/T), T = 1.0
업데이트: ctrl ← Σ w_i · ctrl_i
노이즈: 반복 i에서 global scale = β^i, β = 0.01^(1/32)  → 마지막 반복에 1% 수준
        horizon 방향으로는 첫 knot 1.0배에서 마지막 knot 4.0배까지 증가 (DIAL-MPC 계열 annealing)
조기 종료: 개선량 < 0.01 이 2회 연속이면 중단
교란: 후보 1개당 K=4개 교란 시드의 평균 보상 (worst-case가 아니라 기댓값)
```

- **순수 MPPI가 아닙니다.** 상위 10%만 남기고 순위를 정규화하는 방식은 MPPI보다 **CEM과 MPPI의 혼합**에 가깝습니다. 보상 스케일과 무관하게 동작하므로, 보상 항을 바꿔도 temperature를 다시 조정할 필요가 적다는 장점이 있습니다.
- **32회 반복은 상한일 뿐입니다.** 공개된 whisking 결과에서는 제어 스텝 16개 중 10개가 2회 반복으로 조기 종료됐습니다(`opt_steps = [2,13,2,8,2,2,6,2,9,2,6,2,2,2,2,2]`).
- **교란 보상을 평균하는 방식은 위험중립적(risk-neutral) 강건화입니다.** 평균 대신 CVaR이나 최소값을 쓰면 더 보수적인 grasp를 얻을 수 있을 것이라는 가설을 세울 수 있습니다(검증되지 않음).

04. 코드 검증: 논문 ↔ 구현 대조

- **대상:** `malik-group/do-as-i-do` @ `824591b`, 서브모듈 `malik-group/Fast-SAM3D` @ `823d478`, `malik-group/sam-3d-objects` (shallow clone)
- **범위:** GPU 실행 없이 코드 읽기와 레포에 포함된 결과 파일 분석만 했습니다. 재현 실험은 하지 않았습니다.

1. 모듈 매핑

논문	구현 위치	일치 여부
Eq. 1 shape/pose blending	`Fast-SAM3D/track_object.py:796-818` (`batched_guided_sample_sparse_structure`)	✅ 식과 정확히 일치합니다. `z_ref = (1-t)·noise + t·target`, `x = (1-α)·x_next + α·z_ref`
α_s ∈ [0.9, 1]	`run_pipeline.sh`: `--guidance_strength 1`	✅
적응형 α_p = max(0.1, 0.7 − 0.09|Δθ|)	`track_object.py:1676` lambda, `--pg_floor/--pg_ceil/--pg_slope`	✅ 단위는 **deg/frame**입니다 (논문에는 단위가 없음)
BootsTAPIR 20점 + SVD 2D 강체	`reconstruction/scripts/tapir_velocity_tracking.py` (`--num-points 20`, `np.linalg.svd`)	✅
D_p = 13	`_POSE_LATENT_KEYS` = 6drotation_normalized(6) + translation(3) + scale(3) + translation_scale(1)	✅ 논문 부록 수치와 일치합니다
N = 25 후보, T = 25 Euler	`--num_pose_samples 25 --euler_steps 25`	✅
가중 SE(3) 거리로 클러스터링	`_pose_distance`, `cluster_pose_candidates` (average linkage, `dist_thresh 0.3`, `min_size 3`, `w_rot 1.5`)	⚠️ 아래 D2 참조
로그우도 선택 (Eq. 2)	`pose_log_likelihood.py`, `--pose_selection pose_log_likelihood`	✅ 비교용으로 구현되어 있습니다
손-물체 정렬 최소제곱	`reconstruction/scripts/optimize_translation_scale.py`	✅ 구조 일치(세부 줄 단위 대조는 생략)
Warmup H 스텝 + weld	`retargeting/utils/io.py:101-120` (프레임 0 복제를 앞에 추가), `config.py` `warmup_*`, `mjwp.set_weld_active`	✅ 다만 본문에 없는 부가 장치가 있습니다(D4)
Random force perturbation	`sampling.py:make_rollout_fn` (N×K worlds, K = 4, 평균)	✅ 다만 gate가 있습니다(D5)
Transition reward	`mjwp._rest_surface_penalty` (in-hand 구간에 손 접촉 없음 / rest 구간에 표면 접촉 없음 → 상수 페널티)	✅ 의미는 같습니다. 다만 공개 설정은 **pedestal** 버전입니다(D6)
Table 4 하이퍼파라미터	`config/override/do_as_i_do.yaml`	✅ 수치가 전부 일치합니다 (num_samples 1024, sim_dt 0.005, ctrl_dt 0.5, horizon 3.0, knot_dt 0.2, 노이즈 스케일, 보상 스케일, 교란 파라미터)

2. 불일치와 논문에 적히지 않은 구현 요소

#	내용	영향
D1	**Post-optimization이 기본으로 켜져 있습니다** (`--post_optimize`). 최종 선택된 pose를 SAM 3D의 layout post-optimization(렌더 실루엣 정렬, shape ICP는 끔)으로 한 번 더 다듬습니다. 본문 Method에는 언급이 없습니다.	Table 2 수치에 이 단계가 포함됐는지 논문만 보고는 알 수 없습니다. 추적기 자체의 기여를 해석할 때 주의해야 합니다.
D2	**클러스터 순위 기준이 다릅니다.** 논문은 "작은 클러스터를 버리고 나머지를 silhouette IoU로 순위"라고 설명합니다. 코드는 (클러스터 크기, 평균 점수) 순으로 정렬해서 **가장 큰 클러스터**를 고르고, 그 안에서 render IoU가 가장 높은 후보를 고릅니다.	실질적으로는 "다수결 → IoU" 순서입니다. 모드를 찾는다는 논리와는 오히려 더 잘 맞습니다.
D3	회전 거리를 논문은 `2·arccos⟨q_i, q_j⟩`로 썼지만, 코드는 scipy `(r_a⁻¹ r_b).magnitude()`를 씁니다.	코드가 맞습니다. 논문 식은 절댓값이 빠져 있어서 q와 −q(같은 회전)를 2π만큼 떨어진 것으로 계산합니다. 논문 표기상의 실수입니다.
D4	Warmup에 본문에 없는 장치가 붙어 있습니다. 시작할 때 손가락을 펴고(finger qpos = 0), 손바닥 법선 방향으로 침투가 없어질 때까지 손목을 물린 뒤 10 cm 여유를 더합니다(`warmup_min_clearance 0.1`). 손목·물체와 손가락 레퍼런스를 3 s 동안 보간하고(`warmup_ref_*_interp_duration`), warmup 구간 보상에는 0.1을 곱합니다(`warmup_rew_multiplier`).	논문은 "grasp 휴리스틱을 쓰지 않는다"고 강조합니다. 그러나 "펼친 손으로 접근"하는 사전 설정은 약한 휴리스틱입니다. Warmup의 +41%p에 이 장치들이 얼마나 기여했는지는 분리되지 않았습니다.
D5	교란은 in-hand 구간에서만, 그리고 그 경계에서 0.5 s 안쪽으로 깎인(erode) 구간에서만 가해집니다(`perturb_gate_lag_duration`). warmup 중에는 꺼집니다.	본문에는 "rollout에 무작위 힘"이라고만 적혀 있습니다. gate가 없으면 잡기·놓기 순간에 교란이 들어가서 성능이 떨어질 수 있으므로, gate는 재현할 때 중요한 디테일입니다.
D6	공개 설정은 `pedestal_penalty_scale: 0.5`, `floor_penalty_scale: 0`입니다. 논문은 "object-floor contact"라고 설명하지만 실제로는 물체 밑에 붙인 pedestal(plate)과의 접촉을 봅니다.	의미는 같습니다(부록 B의 Object Base와 연결됩니다).
D7	최적화 temperature는 1.0이고, softmax는 **상위 10% 후보**에만 적용합니다(`_compute_weights_impl`). 논문은 "MPPI-style"이라고만 적었습니다.	`03_derivations.md` §4 참조
D8	IK 단계(`solve_ik`)는 기본값 `ref_dt=0.02`로 실행되어 `trajectory_kinematic.npz`의 `frequency=50`이 기록됩니다. 실제 레퍼런스는 HaWoR 약 30 FPS이고 물리 단계는 `ref_dt 0.0333`을 씁니다.	물리 단계 시간축은 맞습니다. IK 단계의 qvel 레퍼런스만 1.67배 크게 계산되지만, `vel_rew_scale = 1e-4`라서 영향은 미미합니다. 메타데이터 버그에 가깝습니다.
D9	Fast-SAM3D의 Taylor cache(`--enable_ss_cache`, stride 3)와 `torch_compile`로 속도를 높였습니다. 일부 Euler 스텝의 velocity는 네트워크로 계산하지 않고 외삽합니다.	논문은 Fast-SAM3D를 언급하지 않습니다. 정확도가 얼마나 떨어지는지 보고되지 않았습니다. 다만 §1.1의 항등식은 v의 출처와 무관하게 성립합니다.
D10	추적은 기준 프레임에서 **양방향**(backward, forward)으로 진행합니다. `--chain_on_diffusion`이 켜져 있어서, 다음 프레임 target으로는 post-opt 이전의 확산 출력 pose를 씁니다.	post-opt의 보정이 다음 프레임으로 전파되지 않습니다. 확산 latent 공간 안에서 일관성을 유지하려는 선택으로 보입니다.

3. 레포에 포함된 whisking 결과 수치 확인 (CPU, numpy)

`retargeting/outputs/sharpa/right/whisking/0/`의 `trajectory_mjwp.npz`(실행된 궤적)와 `trajectory_kinematic.npz`(레퍼런스)를 비교했습니다. 레퍼런스 시간축은 30 Hz이고 warmup 3 s만큼 이동시켰습니다. 스크립트는 `analysis/whisk_tracking_check.py`입니다.

지표	값	기준
평균 물체 위치 오차	**0.038 m** (최대 0.140)	< 0.1 ✅
평균 물체 회전 오차	**0.283 rad** (최대 1.387)	< 0.5 ✅
물체 높이(z) 범위	레퍼런스 0.087–0.228 m, 시뮬레이션 0.087–**0.132** m	성공 기준으로는 잡히지 않는 차이
반복 횟수	16개 제어 스텝 중 10개가 2회 반복에서 조기 종료	상한 32

해석: 데모는 논문의 성공 기준을 통과합니다. 그러나 레퍼런스에서 물체를 약 14 cm 들어 올리는 구간을, 시뮬레이션에서는 약 4.5 cm만 들어 올립니다. "평균 오차 < 10 cm"라는 기준은 이런 차이를 잡아내지 못합니다. 실제로 쓸 때는 구간별 최대 오차나 높이 같은 과제 특화 지표를 함께 봐야 합니다.

4. 재현할 때의 요구 사항 (코드 README 기준)

- **복원:** VRAM 32 GB 이상의 GPU, 4개 conda env(sam3, sam3d, hawor, tapnet), HF gated 가중치 (facebook/sam-3d-objects, facebook/sam3), MANO 라이선스, SAM 3 클릭 GUI용 X display
- **리타겟팅:** CUDA GPU(MuJoCo Warp), conda env 1개(python 3.12)
- **라이선스 주의:** HaWoR 포크는 CC BY-NC-ND 4.0이고 SAM 계열은 SAM License입니다. 연구용으로는 괜찮지만 상업적 사용과 수정본 재배포에는 제약이 있습니다.

02. 선행연구와 계보

번호 [n]은 논문의 참고문헌 번호입니다. arXiv ID는 논문 참고문헌 목록에 적힌 값을 그대로 옮겼습니다. 이 문서의 각 논문을 별도로 열어 내용을 검증하지는 않았습니다.

1. 계보도

```
[고전] MIT copy-demo(1970) [3] → Kang & Ikeuchi 1997 [4] → Efros et al. "Do as I do" 2003 [5]
        |
[RGB-D/3D 스캔 가정] DexMV 2022 [6] — 물체 3D 스캔, pick-place
        |
[특수 장비 가정] EgoZero [9], Dexterity from Smart Lenses [8] — 스마트글래스 depth, 손 keypoint
        |
[단안 RGB + 파운데이션 모델 + 물리 리타겟팅]  ← 2025–2026 주류
   H2Sim2Robot [16]  LiDAR 스캔 + FoundationPose → RL           (데이터: 직접 촬영)
   VideoManip [18]   MeshyAI + FoundationPose → DRO + DP3       (직접 촬영 + egocentric)
   DexMan [22]       TRELLIS + FPose + SpaTrack → RL             (직접 촬영 + 생성 영상)
   DexImit [7]       SAM 3D + FPose++ → motion planning          (직접 촬영 + 생성 영상)
   ★ Do as I Do      SAM 3D + guided diffusion 추적 → sampling 최적화 (직접 촬영 + 생성 +
egocentric + 인터넷)
```

차별점 요약: 다른 방법들은 모두 물체 추적에 **FoundationPose 계열**(모델 기반 6-DoF 추적기)을 씁니다. Do as I Do는 추적까지 **생성 모델(SAM 3D)** 로 처리하고, 리타겟팅은 RL이나 휴리스틱 대신 **RL 학습이 필요 없는 sampling 최적화**로 처리합니다.

2. 구성 요소별 핵심 선행연구

역할	논문	이 논문에서의 쓰임
이미지 → 3D 물체 (shape + pose 결합 생성)	SAM 3D [11], arXiv:2511.16624	메쉬 생성, 그리고 guided 추적의 백본
가속	Fast-SAM3D (wlfeng0509/Fast-SAM3D, 논문에는 미인용)	Taylor cache로 sparse-structure 단계 가속
분할	SAM 3 [64], arXiv:2511.16719	물체(클릭)와 손(텍스트) 비디오 분할
단안 기하	MoGe-2 [10], arXiv:2507.02546	pointmap과 intrinsics. SAM 3D가 MoGe pointmap으로 학습됐기 때문에 같은 것을 사용
손	HaWoR [45] (CVPR 2025)	world-space MANO 손 궤적. 스케일 기준으로 사용
점 추적	BootsTAP/BootsTAPIR [67], arXiv:2402.00847	회전 속도 → 적응형 α_p
중력	GeoCalib [68] (ECCV 2024)	궤적의 중력 정렬
6-DoF 추적 베이스라인	FoundationPose [17] arXiv:2312.08344, Any6D [47]	비교 대상(같은 파이프라인에 끼워 넣어 비교)
Flow matching 이론	Lipman et al. [77] arXiv:2210.02747	Eq. 2 로그우도(instantaneous change of variables)
Replacement 가이던스	RePaint [65] arXiv:2201.09865, Score SDE [66] arXiv:2011.13456	Eq. 1 blending의 근거
물리 리타겟팅	**SPIDER [15] arXiv:2511.09484**	바로 위 베이스라인. annealed sampling의 틀
RL 리타겟팅	ManipTrans [59] arXiv:2503.21860, DexMachina [60] arXiv:2505.24853, Dexplore [61]	성공 기준($E_{pos} < 0.1$, $E_{rot} < 0.5$) 관례
운동학 IK	mink [55]	사람손 → 로봇손 초기 레퍼런스, 로봇팔 IK
도메인 랜덤화	OpenAI Rubik's cube [69] arXiv:1910.07113, Rudin et al. [70] arXiv:2109.11978	교란(perturbation) 아이디어의 출처
데이터	DexYCB [71], HOI4D [72], OakInk2 [73] arXiv:2403.19417, 100DOH [76]	평가와 필터링 분석

3. 논문이 다루지 않았지만 관련 있는 연구 (내 판단)

주제	관련성	근거 수준
DIAL-MPC (Xue et al., 2024, "Full-Order Sampling-Based MPC for Torque-Level Locomotion Control via Diffusion-Style Annealing")	코드 주석에 "One DIAL-MPC optimization step"이라고 적혀 있습니다. 반복 방향과 horizon 방향으로 노이즈를 annealing 하는 방식이 DIAL-MPC 계열입니다. SPIDER를 거쳐 계승된 것으로 보입니다.	코드 주석으로 확인. 논문 본문에는 미인용
One-Euro filter (Casiez et al., CHI 2012)	적응형 α_p와 구조가 같습니다(`03` §1.3).	내 해석
Kalman / α-β 필터	EMA의 지연 문제를 상수속도 예측으로 없애는 고전적 해법입니다.	내 해석. 개선 아이디어 (b)
RePaint의 resampling, DPS 등 posterior 샘플링 계열	replacement 방식 조건부 생성의 편향을 줄이는 방법들입니다.	내 해석. `03` §2
EgoDex [75] arXiv:2505.11709	대규모 egocentric 손 데이터입니다. 논문은 필터링 동기 부분에서만 인용합니다. 이 파이프라인의 입력 소스로 바로 쓸 수 있습니다.	논문 인용

한계: 3절의 DIAL-MPC 서지 정보는 내 사전 지식에 근거합니다. 블로그나 git에 올리기 전에 arXiv ID를 직접 확인해야 합니다.