Foresight Residual RL: 분석 리포트

게시용 버전: 논문 그림과 표는 라이선스(arXiv 비독점 배포) 때문에 제외했습니다. 원문 https://arxiv.org/abs/2607.16506 · arXiv:2607.16506v1 · IROS 2026 (채택) · Yuhan Liu, Xinyu Zhang, Litao Liu, Abdeslam Boularias (Rutgers University) · 공식 코드 없음 (2026-11-10 확인) · 분석일 2026-11-10

핵심 요약

1. **무엇을 하는가:** 고정된 VLA(π0) 기반 잔차 RL에서, 단계(grasp, move-insert, rotate)의 희소 성공 보상에 "다음 단계가 성공할 확률"(foresight 예측기 p_φ)을 곱합니다(식 9). 예측기는 기준 정책의 종료 상태 이미지와 하류 롤아웃 성공 횟수($\kappa/K_{rep} = \kappa/5$)를 이항 NLL로 맞춘 것입니다. 학습은 뒤 단계부터 역순으로 합니다(Alg. 1).
2. **숫자는 시드 4개에서 유의하지만, 시드 정의와 예측기 검증이 빠져 있습니다:** 전체 과제 85.6 ± 3.9 대 54.5 ± 3.6(잔차 RL)은 Welch $p \approx 2\times10^{-5}$, 차이 31.1 %p(상대 57%)입니다. "+31.1%"는 %p라는 표기 문제가 있습니다. "512 에피소드"가 시드당인지 총인지 불명입니다(`03` §1).
3. **효과의 원인은 핸드오프 품질이라는 주장은 내부 일관성이 있습니다:** foresight의 연속 Grasp+Insert(87.3)는 단계 oracle 성공의 곱(87.5)과 맞고, 잔차 RL은 곱(90.7)보다 35 %p 낮습니다(`03` §3). 다만 oracle 초기화의 한계가 있습니다.
4. **곱셈 보상은 정확한 가치에서만 전역 목적과 같습니다:** 정확한 하류 가치에서는 foresight 기대 기울기가 전역 희소 보상의 기대 기울기와 같습니다(차이 3.5×10^{-17}, `03` §2.3). 가치가 틀리면 목적이 바뀝니다. 3단계 체인 toy에서 불안정한 잡기 행동의 가치만 0.99로 부풀리면 참 성공률이 0.507에서 0.129로 떨어졌습니다(`03` §4.2). PBRS 형태는 같은 오차에서도 최종 정책을 지켰습니다.
5. **예측기 검증이 약합니다:** Grasp→Insert 정확도 86.2%(다수 기준 73.9%)는 뚜렷하지만, 회전 단계의 Insert→Rotate 예측기는 93.9%(다수 기준 90.4%)로 검정 세트가 256이면 유의하지 않습니다(`03` §1.3). 보정, AUC, 독립 평가가 없고, Table III 점수는 학습에 쓴 같은 예측기로 잰 값입니다(순환, `04` C13-C14).
6. **빠진 대조군:** 상수 평균 가치, 섞인 가치, PBRS, 온라인 MC, 하류 critic, $\alpha{\cdot}N{\cdot}K_{rep}$ 민감도가 없습니다. toy에서 상수 평균 가치는 상수 기준선과 같은 결과(0.133)였으므로, 이득이 척도가 아니라 상태 의존성에서 온다는 점은 이 대조로만 확인할 수 있습니다(`03` §4.2).
7. **구현 판정:** 공식 코드가 없고(저장소는 템플릿), 프로젝트 페이지는 404입니다. 이 맥(CUDA 없음)에서는 Isaac Gym 재현과 π0 미세조정이 불가능합니다. 아이디어(곱셈 보상과 예측기)는 구현이 짧지만 시뮬레이션 자산과 전문가가 공개되지 않아 재구현 노력은 큽니다(`04` §4).

01. 논문 분석: Foresight Residual RL

- **대상:** arXiv:2607.16506v1 (2026-07-17 제출, 8쪽). 저자: Yuhan Liu, Xinyu Zhang, Litao Liu, Abdeslam Boularias (Rutgers University). 학회: IROS 2026 채택(abs 댓글 "Accepted at IROS2026").
- **원문:** `paper/paper.pdf`, 추출 텍스트 `paper/paper.txt`. 판본은 v1 하나뿐입니다.
- **한 줄 요지:** 고정된 VLA(π0) 기반 잔차 RL에서, 각 단계의 희소 성공 보상에 "다음 단계가 성공할 확률(foresight)"을 곱해 단계 경계의 핸드오프 품질을 높인다. 3단계 나사 조립(grasp, move-insert, rotate)에서 전체 성공률 54.5% → 85.6%.

1. 문제 설정 (Sec. III)

- **순차 준-MDP (III-A).** 과제를 K개 단계로 나누고, 단계 k의 종료 조건 β_k(s) ∈ {0,1}을 둔다. 단계 k+1은 단계 k의 종료 상태에서 시작한다. 목표는 최종 단계 성공 β_K의 기대 할인 합(식 1)이다. 단계들은 인과적으로 얽혀 있다. 예: 나사 돌릴 때 삽입 상태를 유지해야 한다(Sec. I).
- **단계별 학습 (III-B).** 기존 방식은 단계 k마다 π_k를 상수 보상 β_k(s_{t+1})로 따로 학습한다(식 2). 저자들은 이것이 종료 상태의 품질을 무시한다고 본다.

2. 방법 (Sec. IV-V)

- **foresight 가치 (Def. IV.1, 식 3).** V_{k+1:K}(s) = E[Σ γ^t β_K(s_{t+1}) | s는 단계 k+1 시작, 하류 정책 π_{k+1:K} 고정]. 단계 k의 종료 상태 s가 최종 성공에 기여하는 정도다.
- **국소 foresight 목적 (식 4).** V_k°(s) = E[Σ γ^t β_k(s_{t+1}) V_{k+1:K}(s_{t+1})]. 단계 k의 상수 보상 β_k를 V_{k+1:K}로 곱한 것이다. 저자들은 이것이 "국소적인 수정"이라고 쓴다(Sec. IV-B).
- **역방향 귀납 (Alg. 1).** k = K부터 거꾸로 학습한다. π_K는 β_K로 학습하고, π_k는 하류 π_{k+1:K}가 고정된 상태에서 V_{k+1:K}를 추정해 학습한다. 하류가 학습 중에 바뀌지 않으므로 추정값이 정적이라는 주장이다(Sec. IV-C).
- **잔차 정책 (Sec. V-A, 식 5).** a_t = π_k^0(o_t) + α π_k^res(o_t), α = 0.1. 잔차 최종층은 0으로 초기화된다.
- **1단계 근사 (식 6).** V_{k+1}(s) = Pr(단계 k+1 성공 | s) ≈ V_{k+1:K}(s). 정확한 경우는 (a) k = K−1, (b) 단계 k+2 이후의 성공률이 단계 k+1 성공에 조건부로 일정할 때다.
- **오프라인 예측기 (Alg. 2, Sec. V-B-C).** 기준 정책 π_k^0로 성공한 종료 상태 N개를 모으고, 각 상태에서 π_{k+1}을 K_rep = 5회 굴려 성공 횟수 κ_i를 센다. 예측기 p_φ(o)는 이항 음의 로그우도(식 8)로 학습한다. 입력은 두 카메라 이미지, 백본은 DINOv2-S/14, LoRA(rank 8), 시그모이드 출력이다.
- **보상 (식 9).** r_t = β_k(s_{t+1}) · p_φ(o_{t+1}). 저자들은 이 보상이 "유일한 보상이며 추가 shaping은 없다"고 쓴다.

3. 실험 설정 (Sec. VI)

- **환경.** Isaac Gym(GPU PhysX), 7자유도 Kuka IIWA + 11자유도 Robotiq 3지 그리퍼. 나사 렌치 5개 크기 변형(여유 2 mm 미만). 시각 입력 2대(3인칭, 손목) 256×256 RGB와 자세 8차원. 힘 센서와 물체 자세 정답은 없음. 제어 20 Hz, 단계 길이 160/200/200 스텝, 최대 560.
- **전문가 시연.** 단계마다 2,560개. 상태기계 전문가(물체 자세 정답 사용). 삽입 단계 전문가는 [28]의 상태 기반 RL 정책. 시연은 고정 전략이라 종료 상태 분포가 좁다(Sec. VI-B).
- **기준 정책.** π0를 단계별 시연으로 따로 미세조정해 3개 생성. 청크 H = 20.
- **잔차 RL.** 손목 카메라만 입력(DINOv2 고정, CNN, 2층 LSTM 256, MLP). PPO(rl_games), 병렬 환경 128개. 10회 비판단 워밍업 후 300회 공동 학습(Sec. VI-B). 총 환경 스텝 수와 horizon은 기재 없음.
- **평가.** 512 에피소드 × 4 random seeds, 평균 ± 표준편차 (Sec. VII-B). 예측기는 학습 중에만 쓰고 평가에서는 쓰지 않는다.

4. 결과 (Sec. VII)

- **예측기 품질 (Table I).** Grasp→Insert 86.2% (다수 기준 73.9%), Insert→Rotate 93.9% (다수 기준 90.4%). 임계 0.5, 검정 세트 크기는 기재 없음(80/10/10 분할이면 약 256).
- **주요 결과 (Table II).** 전체 과제: π0 end-to-end 54.9 ± 5.3, π0 chained 41.4 ± 3.3, π0 + Residual 54.5 ± 3.6, + Foresight 85.6 ± 3.9. 단계 oracle 초기화: Grasp 98.4 → 95.7, Insert 92.2 → 91.4, Rotate 99.2 → 99.8 (잔차 대 foresight). 연속 Grasp+Insert 55.5 → 87.3, Insert+Rotate 83.4 → 91.8.
- **종료 상태 품질 (Table III).** 예측기 점수 Grasp 종료: π0 0.64, 잔차 0.32, foresight 0.73. Insert 종료: 0.97, 0.86, 0.91. 같은 예측기로 측정한다(Sec. VII-C).
- **정성 분석 (Fig. 3).** 같은 시작 상태에서 두 방법 모두 단계 성공을 하지만, 잔차 방식의 종료 상태는 다음 단계에서 실패한다.
- **저자 주장의 숫자 표현.** 기여 3은 "+31.1%", 본문은 "over 30% improvement". 둘 다 절대 차이 31.1 %p이며 상대 증가율은 57%다(03 §1).

5. 한계와 저자가 적은 향후 과제 (Sec. VIII)

- 시뮬레이션만 함. 실물 RL 비용이 장애가 될 것이라 추정(근거 없음).
- 단일 과제, 단일 단계 분해, 대안 VLA 백본 미검증.
- 본문이 인정한 근사: 1단계 근사(식 6)의 조건 (b)와 분포 이동 "α가 작아 제한된다"는 주장(Sec. V-C).

6. 읽으면서 확인한 점 (논문 자체의 빈칸)

1. **보상 형태: 에피소드가 성공 뒤에도 계속되는가.** 식 4와 9는 β_k(s_{t+1})를 매 스텝 곱한다. 성공 상태가 여러 스텝 유지되면 p가 여러 번 더해진다(Sec. III-A의 "last for a number of time-steps"). 종료 조건이 명시되지 않았다.
2. **예측기의 레이블 분포.** Alg. 2는 기준 정책의 종료 상태에서 레이블을 만든다(Sec. V-B). Sec. VI-C는 레이블을 "base + trained residual" 하류 정책으로 만들었다고 쓴다. 하류는 잔차 적용 후 정책이므로 Alg. 2 입력과 다르다. 둘 중 무엇인지 분명하지 않다.
3. **판정 기준.** Table I의 정확도는 임계 0.5에서 계산한다. 예측기는 연속값으로 쓰이므로 이 지표는 보수적 대리값이라고 저자가 인정했다(Sec. VII-A). 보정(calibration)이나 AUC는 없다.
4. **평가와 학습에 같은 예측기.** Table III의 점수는 학습 목적함수와 같은 예측기로 잰 값이다. 예측기를 최적화하면 그 점수가 오르는 것이 당연하다. 독립 평가가 없다.
5. **"per-subtask success unchanged" (초록).** 단계 oracle 값이 잔차 대 foresight에서 Grasp 98.4 → 95.7로 낮아진다. 시드 표준편차(0.6, 3.3)로 보면 차이는 유의하지 않지만, "변하지 않았다"보다 "차이가 검출되지 않았다"가 정확하다.
6. **end-to-end π0의 학습 데이터.** 기준선 "π0 (end-to-end)"를 어떤 데이터로 학습했는지 기재 없음.
7. **시드와 에피소드.** "512 episodes across 4 random seeds"가 시드당 512인지 총 512인지 불명(03 §1).
8. **하이퍼파라미터.** PPO의 horizon, 에포크, 학습률, 엔트로피 계수, 보상 정규화, 예측기 학습률, N과 K_rep 값(N은 2,560으로 기재), 추가 시드 수에 따른 결과가 없음.

7. 요약 판단

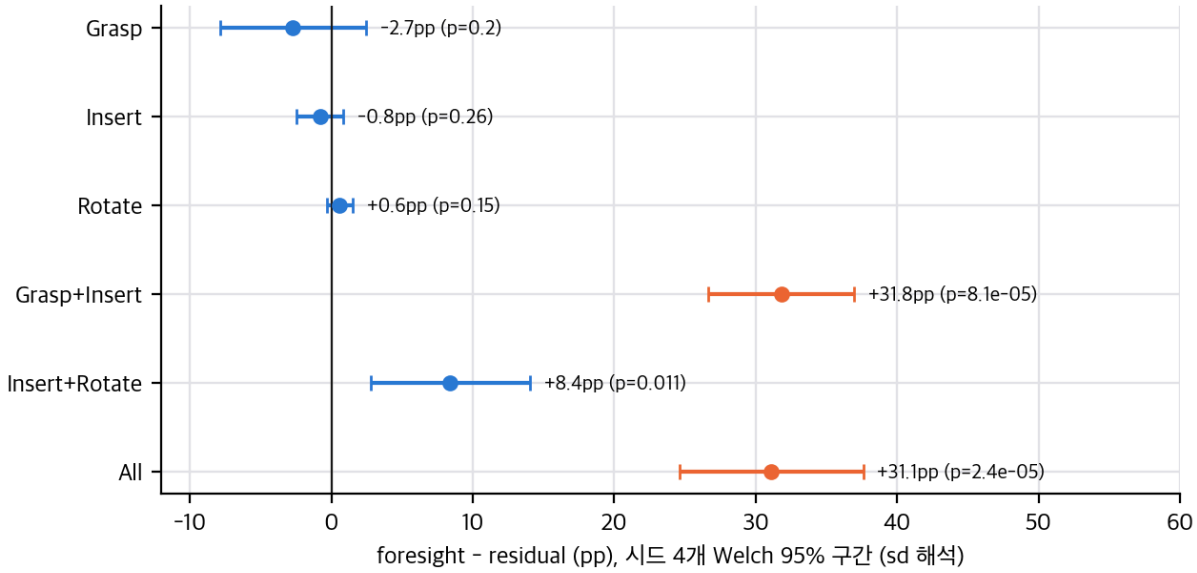
- 핵심 아이디어(종료 상태의 하류 가치를 보상에 넣기)는 명확하고, 계산 비용도 작은 편이다(예측기 학습 5분 미만, Sec. VI-C).
- 실험은 한 과제, 한 시뮬레이터, 시드 4개, 기준선 3개(π0 end-to-end, chained, 상수 잔차)에 한정된다. 예측기의 보정, 곱셈 형태의 대안(PBRS, 상수 평균 보상, 섞인 예측기), 하류 가치 추정의 대안(온라인 MC, critic 재사용)과의 직접 비교가 없다. 이 빈칸이 03의 toy 검증 주제가 된다.

- 논문은 "재현 가능하다"는 근거를 주지 못한다. 공식 코드가 없고, 프로젝트 페이지는 404다(04 §1).

03. 수치 재계산, 유도, toy 검증

재계산 코드: `analysis/table_check.py` → `table_check_results.json`. toy: `analysis/shaping_toy.py` → `shaping_toy_results.json`. 그래프: `analysis/plot_figures.py` → `report/figures/`. 모두 CPU, numpy 1스레드.

1. 표 재계산과 유의성



직접 계산: 열별 foresight – residual 차이와 Welch 95% 구간(시드 sd 해석).

1.1 Table II: 시드 4개 평균의 Welch 검정

논문은 "평균 ± 표준편차"를 쓰고 시드는 4개다. 표준편차가 시드 간 sd(ddof=1)인지 평균의 표준오차(SEM)인지 본문에 없어서 두 해석을 모두 계산했다.

열 (foresight 대 residual)	foresight	residual	차이 (pp)	Welch p (sd 해석)	95% 구간 (sd)	p (SEM 해석)	Holm (sd, 6열)
Grasp	95.7 ± 3.3	98.4 ± 0.6	–2.7	0.20	[–7.9, 2.5]	0.48	0.46
Insert	91.4 ± 0.6	92.2 ± 1.1	–0.8	0.26	[–2.5, 0.9]	0.55	0.46
Rotate	99.8 ± 0.4	99.2 ± 0.6	+0.6	0.15	[–0.3, 1.5]	0.44	0.46
Grasp+Insert	87.3 ± 1.3	55.5 ± 3.4	+31.8	8×10^{-5}	[26.7, 36.9]	0.001	4×10^{-4}
Insert+Rotate	91.8 ± 3.3	83.4 ± 3.2	+8.4	0.011	[2.8, 14.0]	0.12	0.043
All	85.6 ± 3.9	54.5 ± 3.6	+31.1	2×10^{-5}	[24.6, 37.6]	0.001	1×10^{-4}

- 해석: 전체 과제와 연속 Grasp+Insert의 차이는 sd 해석에서도 SEM 해석에서도 유의하다. 시드 4개라 검정력이 낮아서, SEM 해석에서 95% 구간의 하한은 18.1 pp다.
- 단계별 oracle 값은 차이가 검출되지 않는다. 초록의 "leaving per-subtask success unchanged"는 "검출되지 않았다"로 읽는 것이 맞다.

- 기준선끼리: π0 end-to-end 54.9 ± 5.3 대 잔차 54.5 ± 3.6은 차이가 없다(p = 0.91). 잔차 RL이 end-to-end 대비 이득이 없다는 뜻이다. chained(41.4)보다는 13.1 pp 높다(p = 0.002).
- **단위.** 기여 3의 "+31.1%"와 Sec. VII-B의 "over 30%"는 절대 차이 31.1 %p다. 상대 증가율은 57.1%다(85.6/54.5 − 1). 연속 Grasp+Insert는 31.8 %p, 상대 57.3%다.

1.2 이항 근거: Wilson, Fisher, CMH

- 512 에피소드를 시드 4개에 나눈 경우(시드당 128)와 시드당 512(총 2,048)를 나눠 보았다. 이항 표준편차의 기대치는 다음과 같다.

방법	시드당 128 기대 sd	시드당 512 기대 sd	관측 sd
foresight (85.6)	3.1	1.6	3.9
residual (54.5)	4.4	2.2	3.6
π0 end-to-end (54.9)	4.4	2.2	5.3

관측 sd는 "시드당 128"의 이항 기대와 비슷하다. 그렇지만 시드 간 변동이 더 있을 수 있으므로 어느 쪽인지 단정할 수 없다. 논문에 "512"의 의미를 물어야 한다.

- **Wilson 95%:** 시드당 128(총 512)일 때 foresight [82.2, 88.3], residual [50.2, 58.8]. 총 2,048이면 [84.0, 87.1], [52.3, 56.6].
- **Fisher(pooled):** 총 512로 세면 $p \approx 5\times10^{-28}$, 2,048로 세면 $p \approx 3\times10^{-108}$. 그러나 시드 구조를 무시한 의사복제(pseudo-replication)라 근거로 쓰면 안 된다. 시드 단위 Welch(1.1)가 맞는 검정이다.
- **CMH / Mantel-Haenszel:** 시드별 2×2 표(성공·실패 횟수)가 없어서 계산할 수 없다. 논문에 시드별 성공 횟수를 요청해야 한다.

1.3 Table I: 예측기 정확도

- 검정 세트 크기가 없다. 80/10/10 분할에서 10%는 2,560의 10% = 256이므로 이 값을 가정하고, 512를 민감도로 봤다.

경계	정확도 (Wilson 95%, n=256)	다수 기준 (Wilson 95%)	차이	근사 z, p (n=256)	근사 z, p (n=512)
Grasp→Insert	86.2 [81.6, 90.0]	73.9 [68.1, 78.8]	+12.3 pp	3.5, 4×10^{-4}	5.0, 6×10^{-7}
Insert→Rotate	93.9 [90.1, 96.1]	90.4 [86.0, 93.3]	+3.5 pp	1.5, 0.14	2.1, 0.037

- 두 비율은 같은 샘플을 쓰므로 독립 근사는 과대 추정일 수 있다. 그래도 방향은 분명하다. **Grasp→Insert 예측기는 다수 기준을 뚜렷이 넘고, Insert→Rotate 예측기(회전 단계 보상에 쓰이는 쪽)는 검정 세트가 256이면 유의하지 않다.** 논문이 "both predictors exceed their respective baselines"라고 쓴 것은 점 추정으로는 맞지만 두 번째는 약하다.
- 정확도는 임계 0.5의 지표다. 보정(ECE)이나 AUC, 로그우도 값은 없다. 보상은 연속값 p를 쓰므로 보정이 중요하다.

1.4 Table III

- 같은 예측기로 잰 점수라 독립 증거가 아니다(01 §6-4). 표준오차도 없다. 값 자체의 차이(0.32 → 0.73)는 크지만 시드 변동 정보가 없어서 유의성을 판단할 수 없다.

2. 유도

2.1 foresight 목적은 전역 성공 확률이다 (조건: 종료 시점에 한 번 보상)

단계 k가 처음 성공하는 시점을 τ, 그때의 상태를 s_τ라 하자. 하류 정책 $\pi_{k+1:K}$가 고정되어 있고 환경이 마르코프이면, 전역 성공 G의 조건부 기대는 다음과 같다.

$$E[G \mid F_\tau] = 1\{\tau < \infty\} \cdot V_{k+1:K}(s_\tau)$$

따라서 $E[G] = E[1\{\tau<\infty\} V_{k+1:K}(s_\tau)]$이다. 식 4가 이것과 같으려면 보상이 τ에서 한 번만 주어져야 한다(γ = 1). 식 4와 식 9는 $\beta_k(s_{t+1})$를 **매 스텝** 곱한다. 성공 상태가 여러 스텝 유지되면 V가 그만큼 여러 번 더해져 이 등식이 깨진다. 같은 문제가 상수 보상 기준선에도 있다(성공 유지 시간 보상). 논문은 종료 조건을 기재하지 않았다(01 §6-1).

2.2 곱셈 보상과 PBRS

- **PBRS (Ng, Harada, Russell 1999; 논문 미인용, 외부 지식):** 보상에 $F(s,s') = \gamma\Phi(s') - \Phi(s)$를 더하면, 모든 경로의 할인 합이 $R - \Phi(s_0)$ (종료 $\Phi = 0$)로 변한다. 정책 순위가 바뀌지 않는다. 이 성질은 Φ의 값이 정확하지 않아도 성립한다.
- **곱셈 보상:** $x_k \cdot \hat{V}(a_k)$는 그런 차분 형태가 아니다. 목적함수 자체를 바꾼다. 두 경우로 나눠 보면 다음과 같다.
  - $\hat{V} = V$ (정확): 단계 k의 목적이 $E[x_k V(a_k)] = E[1\{\tau<\infty\}V(s_\tau)]$ = 전역 성공 확률이 된다(2.1). 최적 정책 보존이 전역 목적 기준으로 성립한다.
  - $\hat{V} \neq V$: 단계 k의 최적이 $\text{argmax } E[x_k \hat{V}(a_k)]$로 옮겨 간다. 보존이 깨진다. 이것이 보상 해킹의 메커니즘이다(toy §5.1의 악용 행).
- 결론: 곱셈 보상은 "모양을 바꾸는 shaping"이 아니라 "전역 목적을 단계별로 분해하는 방식"이다. 보존 여부는 V의 정확도에 달려 있다. 논문은 이 조건을 쓰지 않았다.

2.3 foresight 곱셈 = 전역 희소 보상의 조건부 기대

2.1의 등식에서 단계 k의 기대 기울기는 다음과 같다. 하류가 고정되면

$$E[\nabla \log \pi_k(a_k) \cdot R] = E[\nabla \log \pi_k(a_k) \cdot x_k V(a_k)]$$

따라서 **정확한 V에서 곱셈 foresight 보상은 "하류까지 굴린 전역 희소 보상"의 기대 기울기와 같다.** 차이는 분산뿐이다. foresight는 V를 한 번에 주고, 전역 희소 보상은 하류 롤아웃 한 번으로 주므로 분산이 크다. 논문 Sec. V-B가 "온라인 MC는 불편하지만 분산이 크다"고 쓴 것과 맞는다. 예측기는 이 기대값을 학습된 함수로 바꾸는 장치로 볼 수 있다. toy에서 확인: 정확한 V로 단계 0의 기대 기울기 차이의 최댓값은 3.5×10^{-17}이다(`_check_foresight_equals_sparse_expected_grad`).

2.4 1단계 근사 (식 6)

$V_{k+1:K}(s) - V_{k+1}(s)$는 단계 k+1 성공 이후의 성공 확률이 상태 s에 따라 달라지는 정도다. 이것이 0이면 근사가 정확하다. 논문 조건 (b)는 "k+2 이후 성공률이 k+1 성공에 조건부로 일정"이다. Table II로 간접 점검하면, 잔차 정책의 연속 Insert+Rotate(83.4)는 단계 Insert oracle(92.2)보다 낮으므로 Insert 이후 Rotate 성공이 일정하지 않다는 신호다. 다만 oracle 초기화와 연속 실행은 초기 분포가 달라서 직접 비교는 불완전하다(§4). Grasp 경계 예측기는 이 근사에 기대므로, 이 오차가 큰 경계일수록 foresight 보상의 의미가 흐려진다. 논문은 이 근사 오차를 측정하지 않았다.

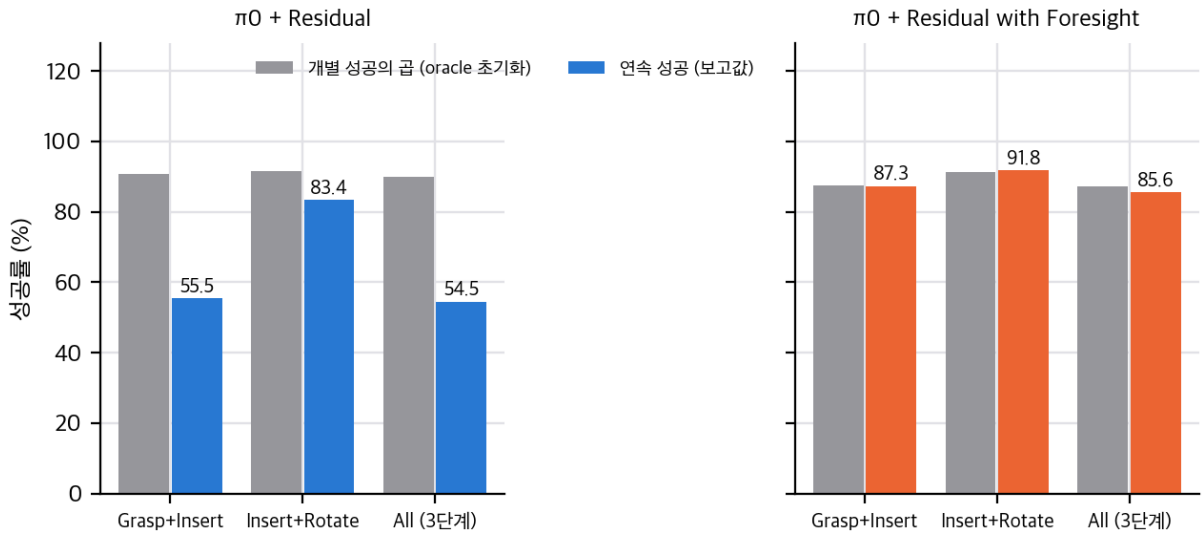
2.5 이항 NLL과 레이블 잡음 (식 8)

레이블 $y_i = \kappa_i/K_{rep}$에서 기울기는 $\Sigma_i (\kappa_i/K - p_\varphi(o_i)) \nabla\text{logit}$이며, 이는 soft-label 교차엔트로피와 같다. 레이블 분산은 $p(1-p)/K_{rep}$이다. $K_{rep} = 5$이면 $p = 0.5$에서 표준편차가 0.22다. 이 잡음은 N이 커지면 평균으로 줄지만, 상태마다 다른 p를

K_rep = 5로 추정하는 것이므로 **표본 N(2,560)보다 K_rep이 개별 상태의 정확도를 제한한다.** 논문은 K_rep 민감도를 보고하지 않았다.

2.6 계산 비용 (추정, 가정 명시)

레이블 하나에 하류 롤아웃 K_rep = 5, 최대 200스텝이므로 경계당 최대 약 2,560 × 5 × 200 ≈ 2.6×10^6 스텝이다. 시뮬레이션 스텝 수는 논문에 기재가 없어 실제 비용은 알 수 없다. 예측기 학습은 5분 미만(Sec. VI-C)이다.



직접 계산: 단계 oracle 성공의 곱과 연속 성공(보고값)의 비교. 세 방법.

3. 곱 검사 (Table II 내부 일관성)

독립 가정이면 연속 성공 ≈ 단계 oracle 성공의 곱이다. 논문의 oracle 값으로 계산했다.

방법	G×I 곱	G+I 보고	I×R 곱	I+R 보고	G×I×R 곱	All 보고
π0 chained	39.8	37.1	42.7	61.5	37.2	41.4
잔차	90.7	55.5	91.5	83.4	90.0	54.5
foresight	87.5	87.3	91.2	91.8	87.3	85.6

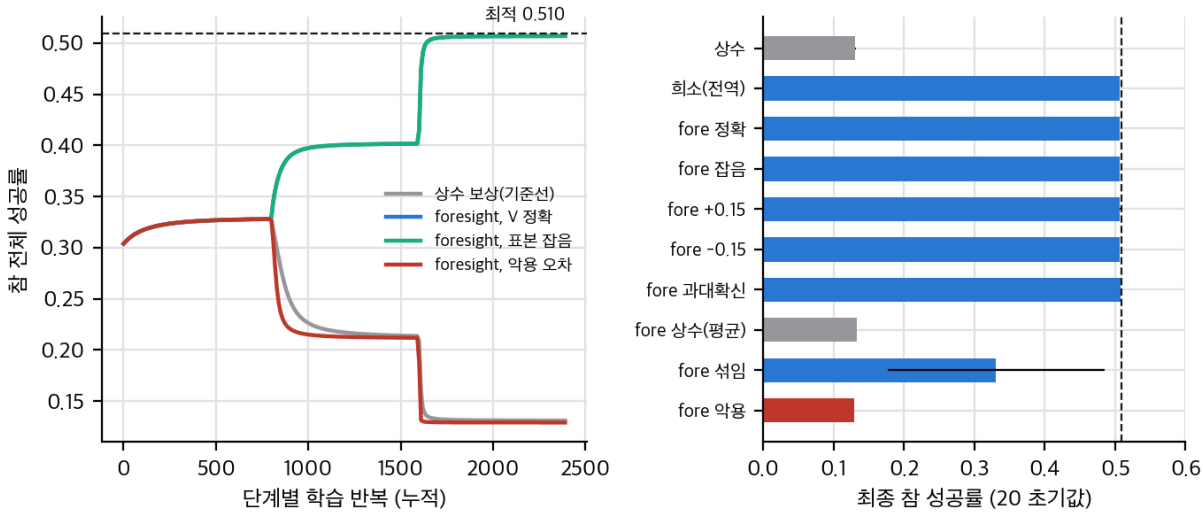
- **foresight는 곱과 거의 맞는다.** 핸드오프 실패가 사라지면 연속 성공이 단계 성공의 곱으로 수렴한다는 논문의 주장과 일치한다.
- **잔차는 곱보다 36 pp 낮다(All 54.5 대 90.0).** 단계 성공은 높지만 연결에서 손실이 난다는 뜻이다. 이것이 논문의 핵심 현상이다.
- **반례.** chained π0의 I+R은 곱(42.7)보다 크다(61.5). oracle 초기화 Insert 값(45.7)이 연속 실행의 실제 삽입 분포와 달라서 생긴 차이로 보인다. 즉 이 검사는 발견적 도구일 뿐 결정적 증거가 아니다.

4. toy 검증 (shaping_toy.py)

4.1 설정

- 3단계, 행동 4개, 정책은 단계별 softmax 표(상태 = 직전 행동).

- 기하 성공 SIG = [[0.98, 0.92, 0.85, 0.75], [0.95, 0.90, 0.85, 0.70], [0.99, 0.97, 0.90, 0.80]], 핸드오프 품질 Q = [[0.35, 0.60, 0.80, 0.95], [0.40, 0.65, 0.85, 0.97]]. 행동 0은 기하 성공이 가장 높고 핸드오프가 가장 나쁘다(논문 Fig. 3의 "그럴듯하지만 불안정한 잡기"에 대응).
- 단계 k+1의 성공 = SIG[k+1][b] × Q[k][h]. 실패하면 종료. 경로 열거 148개.
- 참 최적: 행동 (3, 2, 0), 전체 성공 **0.5096**. 상수 보상 기준선(각 단계 기하 성공 최대): 0.129.
- 단계별 학습(Alg. 1 형식): 기대 기울기를 열거로 정확히 계산(표본 잡음 없음), 20 초기값. 끝까지 학습(joint): 배치 32 에피소드 REINFORCE, 1000 업데이트, 20 초기값.
- 추정기 오차 모형: 표본 잡음(Binomial, n = 3,200), 편향 ±0.15, 과대확신(logit × 3), 악용(행동 0의 $\hat{V}$를 0.99로), 상수(평균), 섞임(무작위 순열).

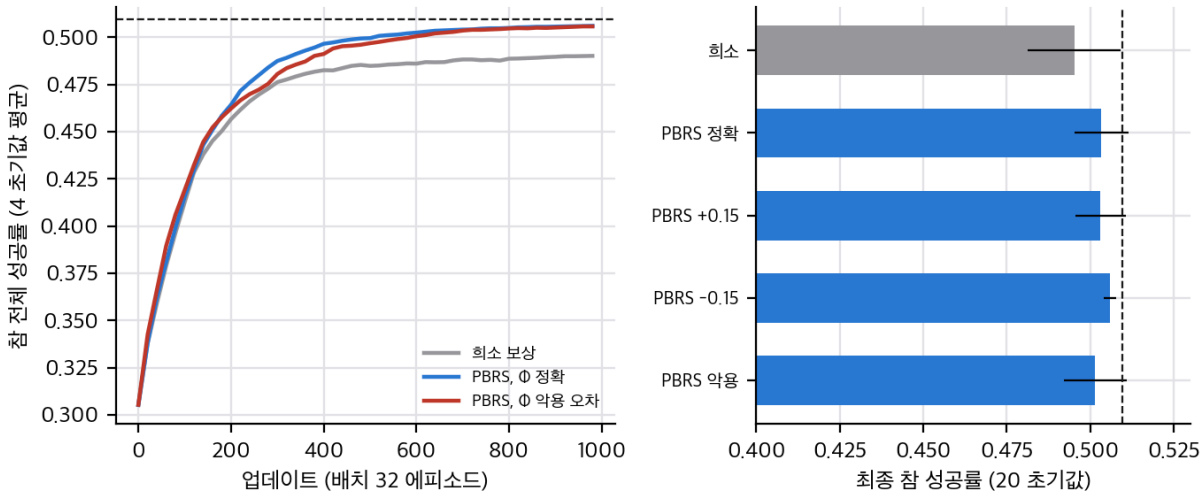


직접 계산(toy): 단계별 학습 곡선(왼쪽)과 추정기 오차별 최종 참 성공률(오른쪽). 점선은 최적 0.510.

4.2 결과 (최종 참 성공률, 20 초기값 평균 ± sd)

방법	최종	최적과의 차	최적의 95%에 도달
상수 보상 (단계별 기준선)	0.131 ± 0.000	−0.378	0/20
전역 희소 보상 (단계별, 하류 고정)	0.507 ± 0.000	−0.002	20/20
foresight, V 정확	0.507 ± 0.000	−0.002	20/20
foresight, 표본 잡음	0.507 ± 0.000	−0.002	20/20
foresight, 편향 +0.15 / −0.15	0.507 / 0.507	−0.002 / −0.003	20/20
foresight, 과대확신 ×3	0.507	−0.002	20/20
foresight, 상수(평균) 보상	0.133 ± 0.000	−0.376	0/20
foresight, 섞인 $\hat{V}$	0.331 ± 0.154	−0.179	5/20
foresight, 악용 오차	**0.129 ± 0.000**	**−0.381**	0/20
끝까지 희소 보상 (표본)	0.495 ± 0.014	−0.014	13/20 (중앙값 356 업데이트)
끝까지 PBRS, Φ 정확 (표본)	0.503 ± 0.008	−0.006	18/20 (중앙값 267)
끝까지 PBRS, Φ +0.15	0.503 ± 0.008	−0.007	18/20 (중앙값 277)
끝까지 PBRS, Φ −0.15	0.506 ± 0.002	−0.004	20/20 (중앙값 300)
끝까지 PBRS, Φ 악용	0.501 ± 0.009	−0.008	17/20 (중앙값 275)

- 단계별 학습 800 반복은 완전히 수렴하지 않는다(정확한 V에서 0.507 대 최적 0.510). 최적 정책은 같다.
- **검증 항목(모두 통과).**
  - 정확한 V에서 foresight와 전역 희소의 기대 기울기 차이: 3.5×10^{-17} (§2.3)
  - PBRS 반환 합이 모든 경로에서 R – Φ_0와 같음: 편차 0 (telescoping)
  - 정확한 기대 기울기에서 PBRS 항 추가가 기울기를 바꾸지 않음: 4.9×10^{-17}. 상태만의 함수는 기준선(baseline)과 같기 때문이다. 즉 **정확한 기대 기울기에서 PBRS는 아무것도 바꾸지 않는다.** 표본 기울기에서만 학습 속도가 달라진다(끝까지 학습 행: 중앙값 356 대 267).



직접 계산(toy): 끝까지 학습(희소 대 PBRS)의 곡선과 최종 성공률. PBRS는 Φ 오차에서도 최종 정책을 지킨다.

4.3 해석

1. **곱셈 foresight의 이득은 최적을 바꾸지 않는다.** 정확한 V에서 전역 희소 보상과 같은 해로 간다. 이 toy에서 이득은 "단계 분해로 얻는 분산 감소"뿐이다(§2.3). 상수 보상 기준선과의 차이는 V의 상태 의존성에서 온다. 평균 상수 $\hat{V}$(같은 척도)로는 상수 기준선과 같아진다(0.133). 척도 효과는 없다.
2. **보상 해킹이 실제로 일어난다.** 불안정한 잡기(행동 0)의 $\hat{V}$만 0.99로 올려도 단계 0 정책이 그쪽으로 몰리고, 참 성공률은 상수 기준선 수준(0.129)으로 떨어진다. 이 사례는 "예측기가 정책이 방문하는 상태에서 틀리면 정책이 그 오차를 찾아낸다"는 위험을 보여준다. 논문의 잔차 정책은 손목 카메라만 보고 예측기 입력은 두 카메라다. 정책이 예측기가 틀린 영역으로 밀리는지는 측정되지 않았다.
3. **무작위 섞임은 불안정하다.** 예측기가 상태를 잘못 연결하면(섞임) 결과가 0.33 ± 0.15로 흩어진다. Table III의 점수 변화가 예측기의 "국소적 정확도"에 의존한다는 논문 주장과 맞는 방향이다.
4. **PBRS(Φ 오차 포함)는 최종 정책을 바꾸지 않는다.** 악용 Φ에서도 최적 근처(0.501)로 간다. 속도만 달라진다. 이 toy에서 곱셈 방식과 PBRS 방식은 **오차가 있을 때 정반대로 행동한다.** 논문이 PBRS 대신 곱셈을 택한 이유는 기록되어 있지 않다. 이 비교는 논문에 없다.
5. toy는 표 형식(tabular)이고 이미지 예측기가 없다. 그래서 "예측기가 어디서 틀리는가"의 실제 분포는 알 수 없다. 이 결과는 메커니즘의 가능성을 보여줄 뿐 논문 수치를 재현하지 않는다.

5. 논문 수치와 toy의 연결

- 논문 Table II의 foresight 연속 성공(Grasp+Insert 87.3)은 toy의 "전역 희소 보상" 해에 가깝다(곱 검사 §3에서 foresight 곱 87.5). 즉 논문의 결과는 "예측기가 전역 희소 보상의 기대를 잘 근사했다"로 설명할 수 있다. 이는 예측기 오차가 작을 때의 결과다.

- 논문에 없는 대조군: (i) 상수 평균 $\hat{V}$, (ii) 섞인 $\hat{V}$, (iii) 악용 $\hat{V}$, (iv) PBRS, (v) 온라인 MC. 이 중 (i)-(iii)은 예측기가 실제로 "무엇을" 학습했는지 확인하는 최소 대조다.

6. 빈칸

- 논문에서 값을 얻을 수 없었던 것: 검정 세트 크기, 시드당 에피소드, 예측기의 정확도 대 보정, K_rep 민감도, N 민감도, α 민감도, PPO 설정, 시뮬레이션 스텝 수, 시드별 원자료.
- 이 세션에서 할 수 없었던 것: 원자료 획득(공개되지 않음), Isaac Gym 실행(CUDA GPU 필요, 이 맥 불가).

추가 검증 (2026-11-11)

추가 검증 1: 체인 길이와 핸드오프 격차를 바꾼 foresight 곱셈 이득

목적. §4의 toy(3단계)에서 곱셈 foresight의 이득을 두 축으로 확장한다. 첫째, 핸드오프 품질 격차 Δ에 이득이 비례하는지. 둘째, 예측기 표본 수 n이 줄 때 이득이 상수 기준선 쪽으로 떨어지는 지점이 있는지. 스크립트는 `analysis/extra_chain_sweep.py`, 결과는 `analysis/extra_chain_sweep_results.json`이다.

설정.

- 단계 수 L ∈ {3, 4, 5}, 행동 4개. 성공 확률은 P_k(s, a) = SIG_k(a) · Q_{k−1}(s)이다. SIG는 §4의 세 행을 순환해 쓰고, 핸드오프 품질 Q_k(a)는 §4의 두 행을 평균에서 Δ/0.6배로 줄인 것이다. Δ = 0.6이면 §4와 같고, Δ = 0이면 모든 행동의 핸드오프가 같다.
- 경로는 모두 열거하고(L = 5일 때 약 1,400개), 단계별 기대 기울기를 정확히 계산한다. 하류 정책은 고정하고 뒤에서부터 학습한다(Alg. 1 형식). 단계당 400 반복, 초기값 8개.
- 비교: 상수 기준선(단계 성공 지표), 전역 희소 보상, foresight 곱셈(V 정확), foresight 곱셈(예측기 표본 n).
- 예측기 오차 두 모형. 고정형은 학습 시작에 한 번 $N(0, (0.5/\sqrt{n})^2)$ 오차를 뽑아 끝까지 쓴다(p = 0.5 최악값, §2.5의 K_rep 잡음과 같은 식). 재표본형은 매 반복 Binomial(n, V)/n을 새로 뽑는다.
- 최적 성공률은 역방향 DP로 구했다.

결과. 표는 foresight 이득(foresight − 상수 기준선, 최종 참 성공률, 초기값 8개 평균)이다.

L	Δ	최적	상수 기준선	정확 V	n = 5	n = 20	n = 100	n = 1000
3	0	0.446	0.442	−0.001	−0.042	−0.035	−0.019	−0.003
3	0.15	0.381	0.347	+0.027	+0.015	+0.016	+0.017	+0.020
3	0.3	0.413	0.264	+0.144	+0.077	+0.086	+0.122	+0.140
3	0.6	0.510	0.135	+0.369	+0.285	+0.349	+0.355	+0.367
4	0	0.295	0.289	−0.004	−0.037	−0.032	−0.020	−0.007
4	0.15	0.240	0.204	+0.026	+0.013	+0.016	+0.019	+0.023
4	0.3	0.272	0.139	+0.123	+0.064	+0.078	+0.097	+0.119
4	0.6	0.383	0.057	+0.318	+0.175	+0.274	+0.299	+0.312
5	0	0.201	0.192	−0.007	−0.033	−0.027	−0.021	−0.011
5	0.15	0.150	0.122	+0.015	+0.007	+0.011	+0.012	+0.013
5	0.3	0.175	0.074	+0.085	+0.041	+0.050	+0.061	+0.081

L	Δ	최적	상수 기준선	정확 V	n = 5	n = 20	n = 100	n = 1000
5	0.6	0.270	0.024	+0.229	+0.117	+0.178	+0.217	+0.223

재표본형 예측기(매 반복 새 잡음)는 n = 5에서도 정확 V의 이득과 거의 같았다(예: L = 3, Δ = 0.6에서 0.369). 반복마다 잡음이 평균으로 사라지기 때문이다. 전역 희소 보상(하류 고정, 단계별 학습)은 최적보다 0.006-0.017 낮았다. 정확 V의 foresight보다도 약간 낮아서, 같은 해로 수렴하되 수렴 속도나 반복 수에 따라 차이가 날 수 있다.

결론.

- 이득은 격차에 따라 커졌다. 다만 비례하지 않는다. L = 3에서 Δ = 0.15, 0.3, 0.6의 이득은 0.027, 0.144, 0.369이다(Δ당 0.18, 0.48, 0.62). 격차가 0이면 이득이 없고 약간 음수다(−0.001에서 −0.007). 이는 §4에서 말한 "이득은 상태 의존성에서 온다"와 맞는다.
- 예측기 표본 수는 격차가 작을 때 중요하다. 고정형 예측기에서 n = 5이면 Δ = 0.15에서 이득이 절반 아래로 줄어 0.007-0.015가 되었다. 이 수준은 n = 1000의 이득(0.013-0.023)과 차이가 작아 상수 기준선과 구분하기 어렵다. Δ ≥ 0.3에서는 n = 5에서도 이득이 0.04 이상이었다. 상수 기준선 아래로 떨어진 경우는 격차가 0일 때뿐이다.
- 이 결과는 "예측기가 정확해야 한다"는 §2의 해석을 정량적으로 준다. 다만 n은 학습 표본 수 같은 것의 대리일 뿐이다. 실제 예측기의 오차가 독립적인 고정 오차인지, 상태에 따라 체계적인지는 이 toy로 알 수 없다. 그래서 §4.2의 악용 오차와 섞인 $\hat{V}$ 결과가 여전히 중요하다.
- 검산: L = 3, Δ = 0.6 설정은 §4의 설정과 같다. 여기서 정확 V 0.504, 상수 0.135, 최적 0.510은 §4의 0.507, 0.131, 0.510과 차이가 0.004 안쪽이다. 학습 반복 수(400 대 800)와 초기값 수(8 대 20)가 달라서 생긴 차이다.

한계.

- 단계 수 5와 행동 4는 여전히 작다. 논문의 3단계 조립과 실제 로봇의 연속 상태와 다르다.
- SIG와 Q는 §4의 값을 변형한 것이고, 격차 0-0.6 사이의 보간은 선형 가정이다.
- 예측기 오차는 상태와 무관한 상수 오차 하나로 모형화했다. 상태 의존 오차는 포함하지 않았다.
- 초기값 8개, 반복 400. 차이 0.01 이하는 구분하기 어렵다.

04. 주장 검증과 구현 가능성

- **대상:** arXiv:2607.16506v1. 원문 `paper/paper.pdf`.
- **코드:** 공식 코드를 찾지 못했습니다. 저자 계정 저장소 `JaySparrow/foresight-residual-rl`은 Academic Project Page Template 그대로이고 플레이스홀더만 남아 있습니다(코드, 학습 스크립트, 설정 없음). 그래서 논문 ↔ 코드 대조(D 항목) 대신 다음을 했습니다.
  - 표 재계산과 유의성, 곱 검사: `analysis/table_check.py` (`03` §1, §3)
  - 대조 toy(3단계 체인 MDP, 곱셈 대 PBRS 대 희소, 추정기 오차): `analysis/shaping_toy.py` (`03` §2-4)
  - 원문 텍스트·표·알고리즘 대조: `01`

1. 주장별 판정

판정 기호: ✅ 맞음(보고값·산술 일치), ⚠️ 맞지만 조건이나 표현에 문제, ❌ 틀리거나 근거 없음, ❓ 검증할 수 없음(정보 부족), ℹ️ 정보.

#	주장 (출처)	점검	판정
C1	3단계 나사 조립 전체 성공 85.6%, 잔차 RL 54.5% (초록, Table II)	보고값과 일치. 시드 4개, sd 3.9 / 3.6, Welch $p \approx 2\times10^{-5}$ (sd 해석)	✅ (시드 정의 `03` §1.2)
C2	"VLA baselines"보다 높다 (초록)	π_0 end-to-end 54.9 ± 5.3 대비 +30.7 pp, Welch $t \approx 9.3$(근사)	✅
C3	단계별 성공은 "변하지 않는다" (초록)	oracle 값 차이 Grasp −2.7, Insert −0.8, Rotate +0.6. 모두 $p > 0.15$	⚠️ "차이가 검출되지 않음"이 정확 (`03` §1.1)
C4	"+31.1%" 개선 (기여 3)	절대 차이 31.1 %p. 상대 증가 57%	⚠️ 단위 표기
C5	상수 보상 대비 "over 30%" (VII-B)	31.1 %p	⚠️ 같은 표기 문제
C6	잔차 RL은 end-to-end와 차이가 없다 (VII-B)	54.5 대 54.9, $p = 0.91$	✅
C7	단계 Insert 성공이 "두 배" (45.7 → 92.2)	2.02배	✅ 단, 같은 과제 oracle 값 비교
C8	Grasp→Insert 경계에서 연속 성공 55.5 → 87.3 (+31.8%) (VII-B)	값 일치. +31.8 %p, 상대 57%	✅ / ⚠️ 단위
C9	chained π_0(41.4)가 end-to-end(54.9)보다 낮다 (VII-B)	Welch $t \approx -4.3$, $p \approx 0.008$	✅
C10	예측기 정확도가 두 경계 모두 다수 기준을 넘는다 (Table I)	Grasp→Insert: 86.2 대 73.9 (n=256 가정 $z \approx 3.5$). Insert→Rotate: 93.9 대 90.4 ($z \approx 1.5$, $p \approx 0.14$)	⚠️ 두 번째 경계는 검정 세트가 256이면 유의하지 않음 (`03` §1.3)
C11	Grasp→Insert의 정확도 격차가 "종료 상태를 구분한다"는 증거 (VII-A)	정확도 격차는 구분 능력의 증거가 약함. AUC, 보정 없음	❌ 근거 부족
C12	예측기는 연속 곱셈기이고 임계 정확도는 보수적 대리값 (VII-A)	맞는 말이나 보정(ECE)·로그우도 없이 연속값의 품질을 말할 수 없음	⚠️
C13	상수 보상 잔차는 종료 상태 점수를 낮춘다 (0.64 → 0.32; 0.97 → 0.86) (Table III)	값 일치. 같은 예측기로 잰 점수라 독립 증거가 아님	⚠️ 순환 (`01` §6-4)

#	주장 (출처)	점검	판정
C14	foresight 정책이 Grasp 종료 점수를 가장 높인다(0.73) (Table III)	값 일치. 같은 조건의 순환	⚠️
C15	foresight 정책이 Insert 종료 품질을 잔차보다 더 보존(0.91 대 0.86) (VII-C)	값 일치. 기본 π0(0.97)보다는 낮음	✅ (잔차와의 비교만)
C16	잔차 정책이 종료 상태 분포를 학습 중에 크게 옮기지 않는다 (V-C, α = 0.1)	측정 없음. 분포 이동 지표 없음	❓
C17	예측기는 기준 정책 분포에서 학습하므로 잔차 정책의 방문 상태에 적용 가능 (V-C)	이동 측정 없음. toy §4에서 예측기 오차가 있을 때 보상 해킹이 생김	❓ (메커니즘 위험)
C18	온라인 MC 가치는 불편하지만 분산이 크다 (V-B)	정확한 V에서 foresight 보상의 기대 기울기 = 전역 희소 보상의 기대 기울기(차이 3.5×10^{-17}). 분산 주장은 이론상 맞음	✅ (`03` §2.3)
C19	곱셈 foresight 보상은 "국소 수정"이고 최적 정책을 바꾸지 않는다 (IV-B, 기여 1)	정확한 V에서만 전역 목적과 같다. V 오차가 있으면 목적이 바뀐다. toy 악용 행에서 0.507 → 0.129	❌ 일반적 보존은 성립하지 않음 (`03` §2.2, §4)
C20	식 6의 1단계 근사는 (a) 마지막 다음 단계 또는 (b) 상수 조건에서 정확 (V-B)	(a)는 Insert→Rotate 예측기에 해당. Grasp→Insert는 근사. (b) 확인 불가	⚠️ 근사 오차 측정 없음
C21	이항 NLL은 "보정된 확률"을 준다 (V-C)	적절한 점수규칙이라 표현력이 충분하면 맞음. 보정 검사 없음	⚠️
C22	예측기 학습은 5분 미만 (VI-C)	자료 크기(2,560×2 쌍)는 작음. 하드웨어 기재 없음	❓
C23	평가에서 예측기는 쓰지 않는다 (VII-B)	설계 진술. 평가 롤아웃은 보상과 독립	✅
C24	정성 사례(Fig. 3)는 두 방법의 차이를 보여준다	단일 사례. 통계 없음. 시작 상태와 과정은 맞음	⚠️ 일화
C25	기준 π0는 단계별 미세조정, end-to-end π0 학습 데이터는 기재 없음 (VI-B)	end-to-end 기준선이 같은 데이터를 쓰는지 알 수 없음	❓
C26	"512 episodes across 4 random seeds" (VII-B)	시드당 512인지 총 512인지 불명. 두 해석에 따라 검정력이 다름	❓ (`03` §1.2)
C27	단계 길이 160/200/200, 최대 560 스텝, 20 Hz (VI-A)	기재 값과 일치. 합 560은 맞음	✅
C28	예측기 학습 데이터 N = 2,560, K_rep = 5 (Alg. 2, VI-C)	기재 값 확인. K_rep 민감도 없음	✅ / ❓ (민감도)
C29	한계: 시뮬레이션만, 실물 비용이 장애 (VIII)	맞는 한계 진술. 실물 비용 추정 근거 없음	✅ / ℹ️
C30	방법이 "최적 정책에 의해 국소 학습과 전역 성공을 정렬한다" (기여 1)	C18-C19와 같은 조건. 전역 목적과의 정렬은 V 정확도에 달림	⚠️ 조건 생략

2. 재현에 필요한데 논문에 없는 정보

1. 공식 코드, 설정 파일, 학습 로그(없음. 저장소는 템플릿).
2. 시드 정의: 4개 시드 각각의 에피소드 수, 시드별 성공 횟수(CMH 계산용).
3. 에피소드 종료 조건: 단계 성공 시 종료하는지, 성공 상태가 유지되는 동안 보상이 계속 들어가는지(식 4, 9의 해석).
4. 예측기 레이블의 하류 정책: 기준 π_{k+1}인지, base + residual인지(Alg. 2와 VI-C가 다름).
5. 예측기 검정 세트 크기, 학습률, 에포크 외 설정, 입력 전처리, LoRA를 쓰는 백본 층 범위.

6. 예측기 보정(ECE, 신뢰도 도표), AUC, 로그우도.
7. N과 K_rep, α의 민감도 표.
8. PPO 설정: horizon, 학습률, 엔트로피, 보상 정규화, GAE, 미니배치, 환경 스텝 총수.
9. π0 미세조정 설정(학습률, 단계 수, 데이터 혼합)과 end-to-end 기준선의 학습 데이터.
10. 온라인 MC, PBRS, critic 재사용, 상수 평균 보상, 섞인 예측기 등 대조군 결과(없음).
11. 독립 평가: 정책이 만든 종료 상태에서 새로 굴린 롤아웃으로 측정한 전환 성공률(없음).
12. 시뮬레이션 자산: 나사·너트 5개 크기 메시, 전문가 상태기계 코드, [28] 삽입 전문가 가중치.
13. 실행 하드웨어와 시간(GPU 종류, 학습 시간, 샘플 수).

3. 권리 표기

- **arXiv 라이선스:** abs 페이지의 license 링크는 `arxiv.org/licenses/nonexclusive-distrib/1.0/` (CC BY 아님). 2026-11-10 확인.
- **PDF 1쪽:** 저작권 문구 없음. 1쪽 왼쪽 가장자리에 arXiv 스탬프("arXiv:2607.16506v1 [cs.RO] 17 Jul 2026")만 있다. 본문 전체에서 "©", "Copyright", "Personal use", "permission" 문구를 찾지 못했다(pdftotext 검색). 인용 문헌 목록의 "IEEE Robotics and Automation Letters"는 참고문헌 항목이다.
- **프로젝트 페이지:** 404라 라이선스 표기 없음.
- **결론:** 논문 비CC BY이므로 논문 그림과 표는 **개인용 리포트와 PPT에만** 넣는다. 게시본(`publish/` , `report_public.pdf`)은 우리가 직접 그린 그래프와 논문 수치 인용(출처 표기)만 쓴다. 논문에서 가져온 그림은 `report/figures/paper_*.png` (개인용)이며, 공개 산출물에 들어가면 안 된다.

4. 구현할 수 있는지

4.1 공식 재현

불가능합니다. 코드, 설정, 시뮬레이션 자산(나사·너트 메시, 전문가), 학습 스크립트가 모두 공개되지 않았습니다. 저장소에는 템플릿만 있습니다. 재현에 필요한 빈칸은 §2의 13개 항목이고, 그중 시드 정의와 종료 조건, 예측기 레이블 정책은 결과 해석을 바꿀 수 있습니다.

4.2 이 맥(Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치)에서

단계	판단
표 재계산, 유의성, 곱 검사	✅ 완료 (`table_check.py` , 수 초)
3단계 체인 toy (곱셈 대 PBRS 대 희소, 추정기 오차)	✅ 완료 (`shaping_toy.py` , 약 70초, 1스레드)
Isaac Gym 나사 조립 환경	❌ Isaac Gym은 NVIDIA CUDA GPU가 필요합니다(외부 지식, 이 세션에서 설치 여부 확인 안 함). 이 맥에서는 실행 불가
π0 미세조정(3개 단계 정책)	❌ torch 미설치. 3B급 모델 학습은 GPU 필요. MPS는 미확인
DINOv2 + LoRA 예측기 학습	❌ 레이블 데이터가 시뮬레이션에서 나와야 함. 공개 데이터 없음. 설치와 다운로드 금지 규칙
잔차 PPO	❌ 시뮬레이션 필요
소형 대체 실험(같은 구조의 과제를 CPU 시뮬레이터에서)	❌ 패키지 설치 필요(이번 작업 제약). toy 수준까지만 가능

4.3 아이디어만 다시 구현

노력은 중간에서 큽니다.

- 예측기와 곱셈 보상 자체(식 7-9): 짧습니다(수십에서 수백 줄). 어려운 부분은 레이블 생성과 하류 롤아웃 관리입니다.
- 필요한 큰 부품: (1) 나사 조립 시뮬레이션 환경(자산 제작, 2 mm 여유 맞추기), (2) 상태기계 전문가와 삽입 RL 전문가([28]), (3) π0 단계별 미세조정 3회(시연 2,560 × 3), (4) 잔차 PPO(128 환경 이상), (5) 예측기 레이블(경계당 2,560 × 5 롤아웃, 최대 200 스텝).
- 장벽: (a) 시뮬레이션 자산과 전문가가 공개되지 않음, (b) π0 미세조정의 GPU 비용, (c) 예측기 정확도와 보정을 재는 기준이 없음(논문 자체가 측정하지 않음), (d) 시드 4개에서의 검정력 부족.

4.4 하드웨어 요구 (추정)

- 시뮬레이션: NVIDIA GPU 1장 이상(CUDA). 128 병렬 환경 기준 메모리 여유가 필요합니다(추정, 논문에 기재 없음).
- 학습: π0 미세조정 3회와 PPO 여러 번. 대략 GPU 여러 장 또는 수일 단위 작업일 가능성이 큽니다(추정).
- 이 맥은 toy와 재계산까지만 씁니다.

4.5 판정 요약

- **공식 재현:** 불가능 (코드 없음).
- **이 맥에서 실측:** 불가 (CUDA 없음, GPU 재현 금지 규칙). toy까지만.
- **아이디어 재구현:** 가능하나 노력이 큼 (시뮬레이션과 π0가 주 장벽).
- **가장 싼 검증 (GPU 필요):** 예측기 보정과 AUC, 독립 평가, 상수 평균·섞인 예측기 대조. 이 셋이 논문의 핵심 주장(예측기가 쓸모 있다)을 직접 시험한다.

5. 구현 판정 한 줄

공식 코드가 없어 재현할 수 없고, 이 맥에서는 시뮬레이션과 π0 학습이 불가능하다. 아이디어(곱셈 보상과 예측기)는 구현이 짧지만, 시뮬레이션 자산과 예측기 검증 기준이 없어서 결과를 그대로 믿기는 어렵다.

02. 선행연구와 관계

1. 계보

- **계층 강화학습의 완성 함수:** Dietterich의 MAXQ [17]은 하위 과제 종료 후의 기대 반환(완성 함수)을 학습한다. 논문은 foresight 가치가 "선형 과제 그래프에 제한된 MAXQ 완성 함수"라고 말한다(Sec. II).
- **재보상 하위 과제:** Sutton 외 [18]은 하위 과제의 누적 신호에 부모 과제 보상과 종료 보너스를 넣는다. 논문은 이를 같은 계열로 본다.
- **보상 기계:** Toro Icarte 외 [19]는 단계 사이의 보상 구조를 명시한다.
- **스킬 연결과 초기 집합 정렬:** T-STAR [12](종료 상태 적대 정규화), SCaR [13](양방향 정규화), Sequential Dexterity [14](전이 가능성 함수), Bagaria 외 [15,16](초기 집합 분류기), Lee 외 [23](전이 정책), Meehan 외 [24](옵션 적응). 논문은 이들을 "분포 겹침이라는 대리 목적"으로 묶는다(Sec. II).
- **VLA 잔차 RL:** ResiP [7](확산 정책의 시점별 잔차), ResFiT [20](오프-정책 잔차 미세조정), PLD [21](π0에 probe-learn-distill). 논문은 이들이 개별 과제에만 작동한다고 본다.
- **옵션과 반-MDP:** Sutton 외 [25](옵션 경계의 V_Ω), option-critic [26].
- **시연 학습 기반 단계 연결:** MimicGen [10], Plan-SeqLearn [11].

2. 가까운 대안 (이 문서 작성자의 판단)

연구	관련 이유	이 논문과의 차이
MAXQ 완성 함수 [17]	같은 양(하류 기대 반환)을 다룸	TD로 함께 학습하므로 비정상성이 생기고, 고정 VLA 기반에서는 쓰기 어려움. 이 논문은 몬테카를로 오프라인 추정 후 예측기로 증류
전역 희소 보상으로 단계 학습 (온라인 MC)	저자들도 Sec. V-B에서 "불편 추정"이라고 씀	분산이 크고 시뮬레이션 비용이 큼. 이 논문의 곱셈 보상은 온라인 MC의 기대값을 예측기로 대체한 것으로 볼 수 있음(03 §3)
잠재 기반 보상 형성 (PBRS, Ng 외 1999)	단계 경계 가치를 보상에 넣는 가장 표준적인 방법. 논문은 인용하지 않음	덧셈 형태이며 최적 정책을 보존함. 곱셈 형태는 보존하지 않음(03 §2)
하류 critic 재사용	논문 Sec. V-B가 명시적으로 기각	하류 정책의 초기 상태 분포에서 학습된 값이라 상류 종료 상태에 맞지 않음 (논문 주장, 검증 안 함)
초기 집합 정렬 (T-STAR, SCaR 등)	같은 문제(핸드오프 품질)	분포 겹침 대리 목적. 성공 확률을 직접 보지 않음

3. 이 저장소의 다른 논문과의 관계

폴더	관계	비고
`thinkworld/` (arXiv:2610.37666)	세계 모델의 미래 예측 일치를 보상으로 GRPO 학습	보상이 모델 자신의 예측에 기대는 구조. 이 논문의 예측기 점수도 학습에 쓰인 같은 예측기로 평가된다는 점이 공통 위험(Goodhart). 그 연구에서는 RL 이득이 작고 설계에 민감하다는 결론을 얻었음
`dexpolicy/` (arXiv:2610.00360)	학습 중 행동 잡음 σ 스케줄(PPO, GRPO, FPO 적용)	잔차나 보상 형태보다는 RL 미세조정 설계. 학습 안정성 비교의 관점
`insertion_wm/` (arXiv:2609.28258, 분석 완료)	잠재 세계 모델로 삽입 과제. 미지 객체 제로샷 56%	삽입 과제의 다른 경로(모델 기반 계획). 이 논문은 모델 없이 단계 종료 상태의 가치만 예측

폴더	관계	비고
`pacevla/` (arXiv:2610.25961)	행동 청크의 실행 속도	보상이 아니라 실행 시간 축. 관련은 약함
`openwam/` (arXiv:2609.07398), `agentic_wam/` (arXiv:2610.30136)	세계 행동 모델(WAM)	예측 대상이 영상. 이 논문의 예측기는 단일 이미지에서 성공 확률을 본다
`chronospolicy/` (arXiv:2610.13929)	관측·행동 시각 조건	단계 경계 시간 정의와 연결될 수 있으나 직접 관계는 약함

4. 저자의 선행 연구 (참고문헌 [28])

- [28] Liu, Zhang, Chang, Boularias (2025), "Failure forecasting boosts robustness of sim2real rhythmic insertion policies." 같은 저자 그룹의 전작으로 보인다. 논문 본문은 [28]을 "상태 기반 RL 삽입 전문가"의 출처로 쓴다(Sec. VI-B). 이 논문에서 실패 예측의 역할은 확인하지 못했다. 원문은 이 세션에서 받지 않았다.

5. GitHub와 프로젝트 페이지 (2026-11-10 확인)

프로젝트 페이지 `jaysparrow.github.io/foresight-residual-rl`는 HTTP 404다(GitHub Pages 미활성).

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋
`JaySparrow/foresight-residual-rl`	저자 계정의 저장소. 설명에 논문 제목과 "(IROS 2026)". 내용은 **Academic Project Page Template 그대로**(README와 index.html의 PAPER_TITLE, BIBTEX_CITATION_HERE, YOUR_GITHUB_USERNAME 등 플레이스홀더가 남음). 코드·데이터·학습 스크립트 없음	저자 계정이지만 코드는 없음	없음(license null)	2	`f5f1345` (2026-07-17, "Initial commit", 단일 커밋)
`JaySparrow/IsaacGymScrew`	다른 저자 Azulay 외 (arXiv:2411.06408)의 IsaacGymInsertion 포크. Robotiq 3지 그리퍼로 교체. README는 "Visuotactile-Based Learning for Insertion"	이 논문의 코드 아님. 같은 Isaac Gym 삽입 환경의 선행 포크	LICENSE.txt(README는 Apache-2.0 표기, GitHub 자동 판별 실패)	0	`def15c9` (2024-12-28)
`osheraz/IsaacGymInsertion`	위 포크의 원저장소(Azulay 외)	공식(원 저자), 이 논문과 무관	자동 판별 NOASSERTION, README는 Apache-2.0	24	`b0e6b07` (2025-05-20)

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋
`JaySparrow/JaySparrow.github.io`	저자 개인 사이트 소스	무관	—	—	`c208a3a`

- `gh search repos "foresight residual"` : 위 첫 번째 저장소만 나옴. `"residual RL VLA foresight"` : 결과 없음. `"failure forecasting rhythmic insertion"` : 결과 없음([28] 공개 코드 없음).
- 공식 코드 clone 없음(공개된 코드가 없어 `repo/` 를 만들지 않음). 그래서 `04_code_verification.md` 가 아니라 `04_claim_verification.md` 를 씀.
- 프로젝트 페이지 HTML과 원저장소 README는 보관하지 않음(`.scratch/` 에만 임시 보관, 커밋 대상 아님).