Geometric Entropy: 분석 리포트

arXiv:2606.20871v1 · IROS 2026 (채택) · Qian Luo, Ruizhe Liu, Pei Zhou, Xunzhe Zhou, Yanchao Yang (University of Hong Kong) · 공식 코드 미공개(2026-11-10 확인) · 분석일 2026-11-10 · 게시용 버전: 논문 그림과 표는 라이선스(arXiv 비독점 배포)에 따라 뺐습니다. 원문: https://arxiv.org/abs/2606.20871

핵심 요약

1. **무엇을 주장하는가:** 시연 궤적의 모양 다양성을 H_G(호 길이 재표집, 끝점 고정, 목표 프레임 회전, 시작-끝 거리 정규화, 공분산 스펙트럼의 ln d_eff + ln Σλ)로 재고, 성공률이 H_G에 대해 역U라고 한다. 최적 H_G는 숙련도(데이터 양, 과제 난이도, 사전학습)에 따라 낮아지고, 사전학습 VLA에서는 단조 감소한다(`01` Abstract, §5).
2. **표 I의 방향은 재현된다:** k=0에서 r이 커지면 H가 단조 증가하고, k=1은 같은 r에서 H를 낮춘다. 합성 궤적의 toy도 같은 순서를 보인다. 절댓값은 논문에 없는 시작-목표 거리에 따라 달라진다(`03` §1.2, §3 T1b).
3. **H_G는 전략 수가 아니라 선형 차원을 잰다:** 반대 두 전략은 연속 분포보다 H가 약 0.93 낮다. 논문의 "모드 모호성" 해석과 반대 방향이다(`03` §3 T1c, `04` C6).
4. **역U는 DP의 N = 100, 200에서 유의하고, N = 1000에서는 근거가 없다:** 판독 값으로 2차항 p = 0.001(N = 100), 0.016(N = 200), 0.53(N = 1000). N = 500은 최고점이 동률이다(`03` §1.3, `04` C7, C8).
5. **사전학습 VLA는 단조이지만 범위가 좁다:** 4점, 오차막대 없음, 모두 k=0이다. 낮은 H 설정이 없어 최적점이 범위 밖인지 확인할 수 없다(`03` §1.4, `04` C10).
6. **실물 역U는 한 점에 의존한다:** StackCube 실물에서 왼쪽 끝 한 점(H ≈ 3.0)에서 피크로 오르는 기울기가 가장 강하다. 2차 검정은 p = 0.095다(`03` §1.5, `04` C12).
7. **커버리지는 재현되고, 평균화는 정책에 따라 다르다:** 2차원 toy에서 학습 시작점이 넓을수록 성공이 오른다. 모드 평균화(충돌 증가)는 단봉 최소제곱 정책에서만 나타나고, kNN은 나타나지 않는다(`03` §4).
8. **구현 가능성:** 공식 재현은 불가하다(코드 없음). H_G 계산과 toy는 이 맥에서 가능하다. 실험 재현(DP, ACT, π0.5)은 GPU와 하드웨어가 필요하다(`04` §4).

01 논문 분석: Geometric Entropy

메타

- 제목: *Geometric Entropy: When Trajectory Diversity Helps and Hurts in Imitation Learning*
- arXiv: 2606.20871, v1 (2026-06-18), cs.RO, 8쪽. 분석 대상은 v1이다.
- 저자: Qian Luo, Ruizhe Liu, Pei Zhou, Xunzhe Zhou, Yanchao Yang (University of Hong Kong, InfoBodied AI Lab)
- 학회: IROS 2026 (채택). arXiv 초록에 "Accepted to IROS 2026"이 있다. 카메라 레디 PDF는 프로젝트 페이지(`https://geometric-entropy.github.io/assets/paper/geometric_entropy_iros2026.pdf`)에 있다.
- 프로젝트 페이지: https://geometric-entropy.github.io/
- 라이선스: arXiv 비독점 배포(`arxiv.org/licenses/nonexclusive-distrib/1.0/`). CC BY가 아니다. 논문 그림과 표는 개인용 리포트와 PPT에만 쓴다.
- PDF 권리 문구: 1쪽 텍스트 층에서 저작권·IEEE 문구를 찾지 못했다(`©`, `Copyright`, `IEEE` 검색). arXiv 스탬프 "arXiv:2606.20871v1 [cs.RO] 18 Jun 2026"만 있다.

한 문단 요약

로봇 시연 데이터의 "궤적 모양 다양성"을 하나의 스칼라로 재는 H_G를 제안한다. 전이 구간을 목표 프레임에 정렬해 위치 차이를 없앤 뒤, 공분산 고유값 스펙트럼의 유효 차원과 총 분산의 로그를 더한다(식 1-2). 이 H_G에 대해 성공률이 역U를 그린다고 주장한다. 최적 H_G는 학습자의 "숙련도"(데이터 양, 과제 난이도, 사전학습)에 따라 낮아지고, 사전학습 VLA(π0.5)에서는 단조 감소한다. 시뮬(ManiSkill StackCube, PegInsertion; Diffusion Policy, π0.5)과 실물(ARX 팔; ACT, 3개 과제)에서 실험했다. 학습 전 데이터셋 감사 도구로 쓰자고 제안한다.

1. Abstract과 Introduction (Sec. I)

- 질문: 궤적 모양의 다양성은 얼마나 있어야 하는가(Sec. I, 1-2쪽). 기존 데이터 품질 연구는 관측 충실도, 라벨 정확도, 과제·장면 범위를 다뤘다.
- 주장: 다양성이 역할을 두 가지 한다. 낮은 범위에서는 경로 회랑을 넓혀 커버리지를 준다. 높은 범위에서는 같은 조건에 다른 전략이 섞여 모드 모호성을 만든다(Sec. I, 2쪽).
- 기여 세 가지: (1) 형식적 처리, (2) H_G, (3) 역U와 피크 이동의 실험 보고.
- 관찰: Sec. I의 "전략 모호성"은 H_G가 측정하는 것이 아니라 해석으로 붙은 것이다(`03` §3.2). 이는 이 논문의 핵심 쟁점이다.

2. 관련 연구 (Sec. II)

- A: 데이터 스케일링(RT-1, RT-2, OXE, DROID, Octo, OpenVLA, BC-Z, RoboCat, PaLM-E, VIMA, AW-Opt).
- B: 데이터 품질과 큐레이션(데이터 품질 분해 [12], DAgger [13], DART [14], 가중치·필터 [15-19], MimicGen [21], DemoGen [22], FieldGen [25], MOVE [26]).
- C: 궤적 기하, 다양성, 모드 커버리지(다중모드 GAIL [27], Behavior Transformer [28], IBC [30], 다양성 벤치마크 D3IL [33], 궤적 정렬 DTW [36]).
- 빠진 것: 사람 텔레옵 데이터의 품질·노력(`nestdex`, `dexforce` 등)을 H_G와 연결하는 논의가 없다. 또 다른 교란(시연 수, 학습 예산)을 다루는 연구(`contact_disassembly` D1-D2)와 연결하지 않았다.

3. 방법 (Sec. III)

3.1 문제 설정 (III-A, 2쪽)

궤적 $\tau_i = \{p_1..p_L\}$은 세 요인이 섞인 결과다. 외생 맥락 E(목표 자세, 작업 공간 크기), 기하 전략 G(접근 각, 곡률, 고도 프로파일, 우회), 실행 노이즈 ε. 목표는 G의 다양성을 E와 ε를 빼고 재는 것이다.

3.2 전이 구간 분할 (III-B, 2쪽)

- 전이(transit)와 정밀 조작(fine manipulation)을 나눈다. 그리퍼 닫힘이 접근→파지, 열림이 운반→놓기 경계다(예시). 정밀 구간은 제외한다.
- 구간마다 따로 점수를 매기고, 구간별 점수는 성공 궤적 수 n_p로 가중 평균한다(식 3).

3.3 정렬 (III-C, 2-3쪽)

1. 호 길이 재표집, T = 50 점(식 없음, 본문 "T=50").
2. 끝점 고정: $p'_k = \bar{p}_k - \bar{p}_T$ (목표 = 파지 자세).
3. 목표 프레임 회전: $p''_k = R_T^\top p'_k$. 시뮬은 환경 상태, 실물은 인지에서 R_T를 얻는다(각주 1).
4. 시작-끝 거리로 나눔: $\tilde{p}_k = p''_k / (\|\bar{p}_1 - \bar{p}_T\| + \varepsilon)$, $\varepsilon = 10^{-9}$.

디스크립터 $\xi \in R^{3T}$, D = 150.

3.4 H_G (III-D, 3쪽)

- 스펙트럼: X의 SVD에서 λ_j를 얻는다. "sample covariance"라고 쓰며, ÷(M−1)을 명시하지 않는다.
- $d_{eff} = \exp(-\Sigma\, p_j \ln p_j)$, $p_j = \lambda_j / \Sigma\lambda$(식 1).
- $H_G = \ln d_{eff} + \ln \Sigma_j \lambda_j$(식 2). 논문은 미분 엔트로피 근사라고 주장하지 않는다(3쪽 "spectral surrogate").
- 이유로 든 것: 대역폭이 없고, 한 번의 SVD로 계산되며, M ~ 10^2-10^3에서 안정적이다. 로그 행렬식 $\log\det(\Sigma+\alpha I)$은 $M \ll 3T$에서 조건이 나쁘고 정규화(α)가 필요하다고 한다.

3.5 관찰과 확인 사항

- H_G는 $\ln d_{eff}$(Shannon 형)와 $\ln \Sigma\lambda$(크기)의 합이다. 둘 다 2차 모멘트에 의존하므로 "모드 수"를 세지 않는다. `03` §2-3.
- ÷(M−1) 여부, T 의존성($\ln T$ 항), 시작-끝 거리의 역할은 논문에 없다.
- 정렬 후에도 시작점 방위 φ가 남는다. 이 변동은 "외생 변동"인데, 정렬이 이를 제거하지 못하면 H는 외생 변동을 센다(`03` T1).

4. 실험 설정 (Sec. IV, 3쪽)

- 질문 세 가지: (1) H_G가 안정하고 구별력 있는가(Fig. 1-2, Table I), (2) IL 성능이 H_G에 따라 어떻게 변하는가(Fig. 3-5), (3) 최적 H_G를 정하는 원리가 있는가(V-B).
- IV-A 시뮬: ManiSkill3의 PandaArmMotionPlanningSolver. 경유점 $w = g + [r\cos\theta, r\sin\theta, \Delta z]$(식 4). 모드 수 k(θ는 k개 등간격 값 중 하나, k=0이면 연속). 설정 7개(Table I).
- 과제: StackCube-v1(쌓기, 높은 난이도), PegInsertionSide-v1(정밀 삽입, 높은 숙련도).
- 데이터 크기: $N \in \{100, 200, 500, 1000\}$. 세 시드.
- 모델: Diffusion Policy(처음부터 학습), π0.5(StackCube에서 미세조정, Physical Intelligence).

- IV-B 실물: ARX 팔, 과제 3개(StackCube, PlacePanda, OpenDrawer), 다양성 5수준, 수집자 3명, N = 100, ACT 정책. 시험 40회 × 세 시드.
- 빠진 것: 시뮬 시험 횟수, 학습 예산, 시작점 분포, 시연 생성 실패 처리, 수집자와 수준의 대응.

5. 결과 (Sec. V, 4-6쪽)

5.1 H_G의 수렴과 기준선 (Fig. 2, Fig. 6, Table I)

- Fig. 2: StackCube에서 H_G가 "첫 50-100개 성공 궤적 안에서 안정"하다고 주장한다. 수치는 그림에만 있다.
- Table I: 설정 7개의 H^avg_G(2.901-3.667). 순서는 `03` §1.2에서 확인했다.
- Fig. 6: 기준선 네 가지(평균 분산, LogDet, 참여율, kNN KL)의 수렴 곡선. 그림만 있다. 주장: 평균 분산은 (0,0), (0.01,0), (0.03,0)을 구별하지 못하고, LogDet·참여율은 (0.10,1)을 (0.05,0) 근처에 둔다. kNN은 N ≤ 1000에서 표본 크기 drift가 크다.

5.2 DP, StackCube와 PegInsertion (Fig. 3, V-A-1, V-A-2)

- 주장 1(역U): 낮은 H_G에서는 성공이 오르고, 높은 H_G에서는 떨어진다. 과제와 모델에 따라 피크 H*가 있다.
- 주장 2(피크 이동): N이 커지면 H*가 왼쪽으로 옮겨진다. 이유로 "더 많은 데모가 초기 조건 범위를 넓게 덮어 추가 다양성의 한계 이득이 줄어든다"를 든다.
- 과제 비교: StackCube는 N이 커도 어렵고 H 증가가 커버리지로 도움이 된다. PegInsertion은 N이 커지면 포화하고 H 증가는 간섭이 된다.
- 판독 결과(`03` §1.3): StackCube N = 100, 200은 역U가 명확하다. N = 500은 최고점이 동률이다. N = 1000은 2차항이 유의하지 않다.
- PegInsertion은 H 축과 설정 목록이 없다. 판독 값은 H 약 1.8-2.5 범위다.

5.3 π0.5, 사전학습 VLA (Fig. 4, V-A "generalist foundation model")

- 주장: StackCube 미세조정에서 성공은 H_G에 대해 "approximately monotonically" 감소한다. 사전학습이 이미 커버리지를 가지므로 추가 다양성이 중복이고 간섭이 된다.
- 판독(`03` §1.4): 네 점(k=0, r = 0.01-0.10), 오차막대 없음. 감소는 0.08-0.22.
- 우려: 낮은 H 설정이 시험되지 않았다. 관찰 범위 안에서는 단조이지만, 최적점이 범위 밖인지 확인할 수 없다.

5.4 실물 (Fig. 5, V-B, V-C)

- StackCube(ACT): 피크 H ≈ 3.3(판독 3.27, 0.62). 왼쪽 끝(3.00, 0.30)과 오른쪽 감소. 역U.
- PlacePanda: 단조 감소(2.45 → 3.29, 0.87 → 0.20).
- OpenDrawer: 단조 감소(2.0 → 6.4, 0.93 → 0.23).
- 해석: 역U는 "어려운 과제", 단조는 "쉬운 과제"와 맞는다는 "sim-to-real consistency"를 주장한다.

5.5 숙련도 원리 (V-B, 6쪽)

- "최적 H*는 학습자의 숙련도에 따라 결정된다"는 원리. 숙련도는 N, 과제 난이도, 모델 사전지식 세 가지로 조작된다.
- 프록시: "저다양성 데이터셋에서의 성공률"을 숙련도로 본다. 높은 기준 성공률은 "이미 회랑을 배웠다"는 뜻이다.
- 비판: 프록시와 결과 변수가 같은 측정이고, 세 조작은 학습 예산과 설정 집합도 함께 바꾼다(`04` C16).

6. 논의와 한계 (Sec. VI, 6-7쪽)

- VI-A 실용적 진단: 파일럿 데이터셋에서 H_G를 재고, 목표 모델과 N에 맞는 예상 형태와 비교한다. H_G가 매우 낮으면 좁은 회랑, 매우 높으면 혼재 전략.
- VI-B 한계(저자 인정): 과제 범위(변형체, 도구, 덜 접촉적인 기술, 긴 조립), 전이 구간 분할이 이벤트 의존, 역U와 피크 이동은 경험적 규칙이며 용량·조건·커버리지와의 형식적 연결이 없다.
- 결론: "최대 다양성" 휴리스틱에 도전, 숙련도에 맞춘 캘리브레이션 원리 제안.

7. 공개된 자료와 프로젝트 페이지 차이

- 프로젝트 페이지의 요약문은 v1 초록보다 약하다. v1은 "consistent inverted-U", 프로젝트 페이지는 "inverted-U curves and, in higher-performing regimes, declining trends over the tested diversity range"라고 쓴다.
- 프로젝트 페이지의 StackCube 설명은 최고 H(3.183, 3.016, 2.917)를 N별로 알려 주며, 판독과 맞다.
- 카메라 레디 PDF와 v1의 핵심 문장·표·절 구성은 같다(키워드 대조). 분석은 v1 기준이다.

8. 분석자 관찰 (요약, 세부는 `03`, `04`)

1. 표 I의 방향은 맞다. 절댓값은 미공개 변수(시작-목표 거리, T, ÷(M−1))에 달려 있다(`03` §2.2).
2. H_G는 선형 차원과 크기를 잰다. 반대 두 전략은 연속 분포보다 H가 낮다(`03` T1c). 논문의 "모드 모호성" 해석과 반대 방향이다.
3. 역U는 DP N = 100, 200과 실물 StackCube에서만 유의하다. N = 1000에서는 단조 감소뿐이고, π0.5는 단조다. "일관된 역U"는 과장이다(`04` C15).
4. 평가 횟수와 학습 예산이 공개되지 않아 N 효과와 학습량 효과를 나눌 수 없다.
5. 커버리지 이득은 toy에서 재현되지만, 평균화 손실은 정책 클래스에 따라 달라진다(`03` §4).

03 재계산, 유도, toy 검증

이 문서는 논문의 수치를 다시 계산하고, H_G의 정의를 유도하고, 두 개의 CPU toy로 핵심 기전과 숨은 가정을 시험한 결과입니다. 코드는 `analysis/entropy_toy.py`, `analysis/bc_toy.py`, `analysis/stats_check.py`이고, 결과는 같은 이름의 `*_results.json`에 있습니다. 모든 계산은 numpy/scipy 1스레드로 한 번에 몇 초 안에 끝납니다.

읽는 법. 논문에는 표 I(StackCube의 H 값)만 숫자로 있습니다. 나머지 성공률은 그림 3·4·5에서 300 dpi로 판독한 근사값입니다(±0.01-0.02). 그래서 판독값으로 한 검정은 판단의 근거이지 확정값이 아닙니다. 시뮬 평가 횟수, 오차막대의 정의(SD 또는 SE), 시드별 값은 논문에 없어서 가정을 씁니다(§1.1).

1. 논문 수치의 재계산과 유의성

1.1 가정

항목	가정	이유
시뮬(DP, 그림 3a) 점 표준오차	0.015	3 시드, 오차막대 반폭 0.01-0.02 판독
실물(ACT, 그림 5) 점 표준오차	0.05	오차막대 반폭 0.04-0.06 판독
실물 이항 횟수	A: 40회 × 3 시드 = 120, B: 40회	논문은 "40 test episodes per configuration"과 "three seeds"만 씀. 두 해석을 모두 계산
π0.5(그림 4)	오차막대 없음	점 간 차이만 본다

1.2 표 I (StackCube, 정확한 값)

r/k	0/0	0.01/0	0.03/0	0.05/0	0.05/1	0.10/0	0.10/1
H^avg_G	2.901	2.917	3.016	3.183	2.909	3.667	2.997

- k=0에서 r이 커지면 H가 단조 증가합니다(2.901 → 2.917 → 3.016 → 3.183 → 3.667). 표 안에서 맞습니다.
- 같은 r에서 k=1은 k=0보다 H가 낮습니다(0.05: 2.909 < 3.183, 0.10: 2.997 < 3.667). 표 안에서 맞습니다.
- 표에는 평균 분산, LogDet, 참여율, kNN 값이 없습니다. 기준선 비교(Fig. 6)는 그림으로만 있고, 수치 재계산은 못 합니다.

1.3 그림 3a(DP, StackCube) 판독과 검정

판독 값(성공률), 열은 표 I의 설정 순서입니다.

N	0/0 (2.901)	0.05/1 (2.909)	0.01/0 (2.917)	0.10/1 (2.997)	0.03/0 (3.016)	0.05/0 (3.183)	0.10/0 (3.667)
100	0.06	0.065	0.12	0.215	0.22	**0.325**	0.24
200	0.16	0.26	0.285	0.36	0.375	**0.42**	0.27
500	0.395	0.42	0.48	0.575	**0.595**	0.58	0.355
1000	0.71	0.735	**0.76**	0.72	0.715	0.635	0.445

검정 결과(`analysis/stats_check_results.json` 섹션 B, C):

N	최고점	2등과 차이 z (p)	2차항 p (vs 1차)	꼭짓점 H*	판단
100	3.183	4.0 (0.0001)	0.001	3.36	역U 명확
200	3.183	2.1 (0.034; Holm 0.10)	0.016	3.30	역U 있음, 최고점은 약함
500	3.016	0.7 (0.48)	0.014	3.25	최고점 동률, 곡률은 있음
1000	2.917	1.2 (0.24)	0.53	식별 안 됨	역U 근거 없음

- N=1000 곡선은 왼쪽이 평평하고(0/0 → 0.01/0에서 0.71 → 0.76), 오른쪽만 감소합니다. 2차항이 유의하지 않고(p=0.53), 2.917 이후 감소는 단조입니다(Kendall τ = –1, p = 0.017). "역U"보다는 "2.92 근처에서 최고, 그 뒤 감소"가 정확합니다.
- 최고점 위치의 노이즈 시뮬레이션(점마다 SE 0.015를 20,000번 흔듦): N=500의 최고점 0.03/0은 67%, 0.05/0은 20%. N=1000의 0.01/0은 86%.
- 꼭짓점의 N 의존성(4점, 로그 N 회귀): 3.36 → 3.30 → 3.25(N = 100, 200, 500)으로 낮아지지만 기울기는 –1.5 per decade, SE 0.8, p = 0.21입니다. 피크가 왼쪽으로 옮겨 간다는 방향은 맞아 보이나, 통계적으로는 확정되지 않습니다.

1.4 그림 4(π0.5, StackCube) 판독

N	2.917	3.016	3.183	3.667	2.917 → 3.667 하락
100	0.905	0.88	0.875	0.685	0.22
200	0.932	0.92	0.93	0.85	0.08
500	0.97	0.953	0.947	0.845	0.125
1000	0.975	0.94	0.918	0.86	0.115

- 네 점, 오차막대 없음. 단조 감소는 τ = –1(N = 100, 500, 1000)이지만 정확 순열 p = 0.083으로 n=4에서는 유의하지 않습니다.
- 4개 점은 모두 k=0(r = 0.01, 0.03, 0.05, 0.10)입니다. 표 I 구조상 k=0에서 H는 r의 단조 함수이므로, 이 곡선은 "H 감소"가 아니라 "r 감소"와 같은 정보입니다. 0/0, 0.05/1, 0.10/1 같은 낮은 H 점은 시험하지 않았습니다. 그래서 "최적점이 왼쪽으로 밀려 관찰 범위 밖에 있다"는 주장은 확인할 수 없습니다.
- π0.5 곡선은 DP의 모든 점보다 위에 있습니다(같은 설정 3.183, N=1000에서 0.918 대 DP 0.635). 감소 추세와 사전학습 효과가 섞여 있어, 감소를 "다양성 간섭"으로만 해석하기 어렵습니다.

1.5 그림 5(ACT 실물) 판독과 검정

과제	H (판독)	성공률 (판독)	Wilson 95% (A, n=120)
StackCube	3.00	0.30	0.23-0.39
	3.27	0.62	0.53-0.70
	3.50	0.47	0.38-0.56
	3.70	0.37	0.29-0.46
	3.94	0.17	0.11-0.25
PlacePanda	2.45	0.87	0.80-0.92
	2.53	0.67	0.58-0.75
	2.79	0.47	0.38-0.56
	3.27	0.335	0.26-0.42
	3.29	0.20	0.14-0.28

과제	H (판독)	성공률 (판독)	Wilson 95% (A, n=120)
OpenDrawer	2.0	0.93	0.87-0.96
	4.0	0.73	0.64-0.80
	5.5	0.40	0.32-0.49
	5.9	0.37	0.29-0.46
	6.4	0.23	0.16-0.31

쌍 비교(Fisher 양측, Holm 보정은 가정 A 기준):

비교	가정 A (n=120)	가정 B (n=40)
StackCube 피크 3.27(0.62) 대 왼쪽 3.00(0.30)	$p = 1.3\times10^{-6}$	p = 0.007
StackCube 피크 3.27 대 오른쪽 3.50(0.47)	p = 0.027 (Holm 0.055)	p = 0.26
StackCube 피크 3.27 대 최고 H 3.94(0.17)	$p < 10^{-12}$	p = 0.0001
PlacePanda 3.27(0.335) 대 3.29(0.20)	p = 0.028 (Holm 0.055)	p = 0.31
OpenDrawer 4.0 대 5.5	$p < 10^{-6}$	p = 0.007

- StackCube의 "역U"는 왼쪽 끝 한 점(3.00)에서 피크로 올라가는 기울기가 가장 강한 근거입니다. 2차 검정은 p = 0.095(df 2)로 약합니다. 피크 오른쪽 이웃과의 차이는 가정 A에서만 유의합니다.
- PlacePanda에서 H가 0.02 다른 두 점(3.27, 3.29)의 성공률이 0.335와 0.20으로 다릅니다. H가 성공률을 정하지 않는다는 근거이지만, 판독 오차 범위입니다.
- OpenDrawer는 2차항 p = 0.12이고 꼭짓점이 관측 범위 밖(0.4)입니다. 단조 감소입니다.
- Mantel-Haenszel(과제 3개를 층으로, 최고 성공 쌍 대 최고 H 쌍): 합동 OR = 18.1(95% CI 12.3-26.8), CMH $\chi^2 = 268$. 다만 층 간 동질성 p = 0.0014이므로 하나의 OR로 요약하기 어렵습니다. 이 검정은 "가장 높은 H 설정이 과제마다 덜 성공한다"는 단순 요약이며, H가 원인이라는 뜻은 아닙니다.

1.6 H만으로 설명되는가, r과 k로 충분한가

N=1000 DP 곡선(7점, 가중 최소제곱, σ = 0.015)에서 H의 2차 모형(3 모수)은 가중 잔차제곱합 8.3, r의 2차항과 k 더미(4 모수)는 60.2입니다. H 모형이 더 잘 맞습니다. 다만 k=0에서 H는 r의 단조 함수이므로 차이는 k=1 두 점(0.05/1, 0.10/1)에서 나옵니다. 점이 7개이고 모수가 3-4개라서 "H가 r보다 낫다"는 결론은 약합니다.

2. 정의와 유도

2.1 식 1-2를 다시 쓰기

λ_j를 표본 공분산의 고유값, $p_j = \lambda_j/\Sigma\lambda$, $d_{eff} = \exp(-\Sigma p_j \ln p_j)$로 두면

- $\ln d_{eff} = H(p)$ (정규화된 스펙트럼의 Shannon 엔트로피, nats)
- $H_G = H(p) + \ln(\Sigma_j \lambda_j)$

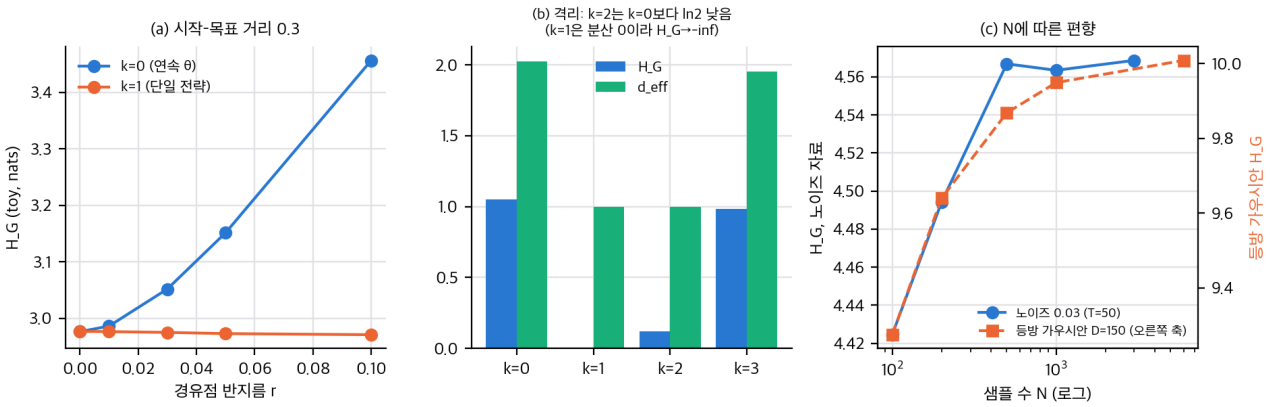
입니다. 즉 H_G는 "선형으로 퍼진 차원의 수(Shannon 형)"와 "전체 분산의 로그(크기)"를 더한 것입니다. 미분 엔트로피가 아닙니다. 논문도 이렇게 씁니다(Sec. III-D, "spectral surrogate").

2.2 세 가지 함정: 단위, 샘플 수, 재표집 점 수

1. **정규화 분모 ÷(M−1).** 논문 식만으로는 λ가 ÷(M−1)인지 불분명합니다. ÷(M−1)을 쓰면 Σλ = tr(표본 공분산)이고 M에 대해 기대값이 같습니다. ÷1(특이값² 그대로)을 쓰면 ln Σλ에 ln(M−1)이 더해집니다. Fig. 2가 "N=50-100 이후 안정"이라고 했으므로 ÷(M−1)이 맞을 것입니다(추론, 코드 없음). toy(T2): ÷(M−1)은 M=100에서 3.293, M=2000에서 3.296로 평평합니다. ÷1은 7.89에서 10.90으로 증가하며, 증가량은 ln(1999/99) ≈ 3.0과 같습니다.
2. **재표집 점 수 T.** 궤적 점 수를 T라 하면 D = 3T이고 trace(공분산)은 T에 비례합니다. 그래서 ln Σλ에 ln T가 더해집니다. toy(T3): T = 25, 50, 100에서 H_G = 2.62, 3.29, 3.98로, 두 배마다 약 0.69(= ln 2)씩 증가합니다. 논문은 T = 50만 씁니다. 다른 T나 다른 논문과 H의 절대 값을 비교하면 안 됩니다.
3. **거리 정규화와 시작-목표 거리.** 식은 시작-끝 거리로 나눕니다. 이 거리가 작으면 같은 반지름 r의 효과가 커집니다. 논문은 이 거리를 보고하지 않습니다. toy(T1 대 T1b): 거리 1.0에서는 r = 0.10인 경우에도 H가 3.26 → 3.30만 움직이지만, 거리 0.3에서는 2.98 → 3.46으로 움직입니다. 표 I의 크기는 이 숨은 값에 달려 있습니다.

2.3 0 분산 극한

완전히 같은 시연이면 λ = 0이 되고 ln Σλ → −∞입니다. toy에서 k=1이고 시작점을 고정한 경우 H = −58.5, 2차원 toy에서 s_tr = 0이면 −66입니다. 이것은 수치 하한(1e-12) 때문입니다. 실제 자료에서는 시작점, 노이즈가 조금이라도 있으면 유한한 값을 갖지만, 분산이 작을수록 H는 로그 스케일로 빠르게 내려갑니다. 저다양성 데이터에서 H가 "음수로 크게" 나오는 것은 정상이며 해석할 때 주의합니다.



직접 계산(toy): (a) 시작-목표 거리 0.3에서 r에 따른 H_G, (b) 시작점을 고정한 격리 검사, (c) 노이즈 자료와 등방 가우시안의 N 편향.

3. toy 1: H_G 정의를 합성 전이 궤적에 적용 (`analysis/entropy_toy.py`)

설정: 목표 g = 0, 시작점 방위 φ ~ U(0, 2π), 경유점 w = g + [r cos θ, r sin θ, 0.2], 궤적은 시작 → w → g의 두 직선을 호 길이로 재표집(T = 50). 목표 프레임은 z축 회전 yaw를 무작위로 주고 정렬 후 되돌립니다. 노이즈는 점마다 σ = 0.002입니다. 정렬(끝점 고정, R^T 회전, 시작-끝 거리 정규화)과 식 1-2는 논문 그대로입니다.

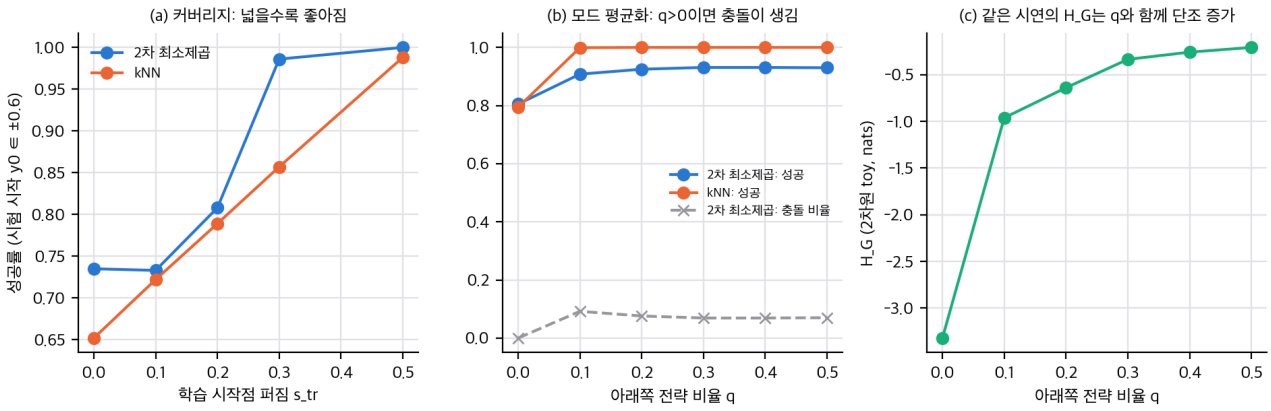
3.1 결과

검사	결과	의미
T1 (거리 1.0, N = 1000)	k=0: r = 0 → 0.10에서 3.256 → 3.297. k=1: 3.239	시작점의 외생 변동이 분산을 지배해 r 효과가 작음
T1b (거리 0.3)	k=0: 2.977 → 2.986 → 3.052 → 3.152 → 3.457 (r = 0, 0.01, 0.03, 0.05, 0.10). k=1: 2.971-2.977로 평평	표 I의 순서(k=0에서 r ↑ H ↑, k=1은 낮음)를 재현. 절댓값은 다름
T1c (시작 고정, yaw 없음, 노이즈 없음, N = 3000)	k=0: H = 1.053, d_eff = 2.03. k=2: H = 0.119, d_eff = 1.00. k=3: H = 0.986, d_eff = 1.95	**k=2(반대 두 전략)는 k=0보다 H가 0.93 낮음.** d_eff가 2에서 1로 줄어 ln 2 = 0.69가 빠지고, 나머지는 trace 차이

검사	결과	의미
T2 (N, ÷(M−1))	M = 100, 200, 500, 1000, 2000: 3.293, 3.288, 3.293, 3.294, 3.296 (모집단 3.296)	이 자료는 스펙트럼이 낮은 차원이라 편향이 작음
T2c (노이즈 0.03, 거리 0.3)	M = 100, 200, 500, 1000, 3000: 4.42, 4.49, 4.57, 4.56, 4.57	노이즈가 크면 N = 100에서 약 0.14 낮게 편향
T2d (등방 가우시안, D = 150)	M = 100, 200, 500, 1000, 6000: 9.27, 9.64, 9.87, 9.95, 10.01	참값 ≈ 10.02. N = 100에서 0.73 낮음
T3 (노이즈)	σ = 0, 0.002, 0.01, 0.03: 3.297, 3.298, 3.314, 3.427	노이즈는 차원을 늘려 H를 올림
T3 (T)	T = 25, 50, 100: 2.62, 3.29, 3.98	ln T 항. 비교 가능성을 깨뜨림
T4 (전역 회전)	원래 3.292979, 회전 후 3.292979	정렬 구현은 회전 불변 (검산)
T5 (kNN KL 기준선, D = 150)	k = 5: M = 100, 300, 1000에서 −207, −278, −362. H_G는 3.30, 3.30, 3.30	KL은 N에 따라 크게 드리프트. 이 기준선은 D = 150, M ≤ 1000에서 신뢰할 수 없음

3.2 해석

1. **H_G는 "전략 수"가 아니라 "선형 차원"을 센다.** T1c가 핵심입니다. 반대 방향 두 전략(k=2)은 공분산의 선형 차원이 1이라서, 연속 분포(k=0)보다 H가 낮습니다. 즉 논문에서 "모드 모호성"이라고 부르는 상황(서로 다른 전략이 같은 조건에 섞임)을 H_G는 "다양성 낮음"으로 읽습니다. 표 I에서 k=1이 H를 낮추는 결과는 이 성질과 맞습니다. 하지만 이는 "모호성을 측정한다"의 증거가 아니라 "2차 모멘트가 작다"의 증거입니다. 논문 Sec. V-D가 기준선(평균 분산, LogDet, 참여율)을 실패 사례로 든 이유와 같은 한계입니다. H_G도 2차 모멘트 기반입니다.
2. **k=3은 k=0과 같습니다**(T1c: 0.986 대 1.053). 정삼각 배치의 공분산은 등방이어서, 3개 이산 전략과 연속 분포를 구별하지 못합니다.
3. **N 편향은 자료의 스펙트럼에 달려 있습니다.** 낮은 차원 구조가 강하면 N = 100에서도 편향이 0.01 이하이고, 노이즈가 많거나 차원이 높으면 N = 100에서 0.14-0.7 낮게 나옵니다. 논문 Fig. 2의 "50-100개면 안정"은 이 차이에 따라 맞을 수도 틀릴 수도 있습니다. 이 논문에서는 N 곡선 수치가 없어 확인할 수 없습니다. 방향에 주의합니다. toy에서 편향은 작은 N의 H를 낮춥니다. 그러면 N = 100에서 관찰된 피크(3.18)는 편향을 보정하면 더 높아야 합니다. 즉 편향이 관찰된 "피크 왼쪽 이동"을 만든 것은 아니고, 오히려 그 이동을 줄이는 쪽입니다. 다만 편향은 설정(r, k)마다 다를 수 있으므로 검증 실험이 필요합니다.
4. **T(재표집 점 수)는 H의 절대 값을 옮깁니다.** 논문은 T = 50에 고정했으나, 다른 연구나 다른 로봇 데이터와 비교할 때 반드시 같은 T를 써야 합니다.



직접 계산(toy): (a) 학습 시작점 퍼짐과 성공률, (b) 아래쪽 전략 비율 q와 성공·충돌, (c) 같은 시연의 H_G.

4. toy 2: 커버리지 대 모드 평균화 (`analysis/bc_toy.py`)

설정: 2차원, 시작 (−1, y0), 목표 (1, 0), 원점에 반지름 0.2 장애물. 시연은 경유점 (0, h)을 지나며, h = +0.4(위쪽 전략)와 h = −0.4(아래쪽 전략)을 씁니다. 학습 시작점 y0 ~ U(−s_tr, s_tr), 시험 시작점은 y0 ∈ [−0.6, 0.6]의 400개 격자입니다. 정책은 두 가지입니다. (a) kNN(K=10): 이웃의 평균 속도. (b) 2차 다항식 최소제곱: 단봉(unimodal) MSE 회귀의 대리. 속도 크기는 1로 자릅니다. 5개 시드, 각 60개 시연.

4.1 결과

E1, 커버리지(단일 전략, 학습 시작점 퍼짐 s_tr):

s_tr	0.0	0.1	0.2	0.3	0.5
2차 최소제곱 성공률	0.735	0.733	0.808	0.986	1.000
kNN 성공률	0.652	0.722	0.789	0.857	0.988

시험 시작점이 학습 분포보다 넓으므로, 학습 시작점이 넓을수록 성공률이 올라갑니다. 이것이 논문의 "커버리지가 도움이 된다"와 맞습니다.

E2, 모드 평균화(학습 시작점 퍼짐 0.2, 아래쪽 전략 비율 q):

q	0.0	0.1	0.2	0.3	0.4	0.5
2차: 성공	0.805	0.908	0.925	0.931	0.931	0.930
2차: 충돌 비율	0.000	0.092	0.076	0.069	0.069	0.070
kNN: 성공	0.794	0.999	1.000	1.000	1.000	1.000
2차 H_G	−3.32	−0.96	−0.64	−0.34	−0.26	−0.21

- 2차 최소제곱 정책에서 q = 0의 실패는 전부 시간 초과입니다(커버리지 실패). q > 0에서는 실패가 충돌로 바뀝니다(모드 평균화의 특징적 실패). 실패 유형이 바뀌는 것은 전형적인 평균화 신호입니다.
- 그래도 이 toy에서 성공률은 q와 함께 올라갑니다. 커버리지 이득이 평균화 손실보다 큽니다. 논문이 말한 "역U"는 이 설정에서 나타나지 않았습니다.
- kNN 정책은 q가 커져도 충돌이 없습니다. 상태(위치)가 전략을 구별하므로 이웃이 같은 전략에서 옵니다. 평균화는 "조건 신호가 전략을 구별하지 못하는" 경우에만 생기며, 논문의 주장은 이 조건을 명시하지 않습니다.
- 연속 분포(양쪽, |h| ∈ [0.25, 0.45], s_tr = 0.2): 2차 정책 0.794(SD 0.12, 충돌 0.08), kNN 0.984(충돌 0.02). H_G = −0.47.

4.2 해석

- 같은 시연 데이터의 H_G는 q와 함께 **단조 증가**합니다(−3.3 → −0.2). 성공률은 q = 0.2 이후 거의 평평합니다. 즉 H_G는 "다양성이 많아졌다"를 알려 주지만, 최적점을 알려 주지는 않습니다. 최적점은 학습 방법(정책 클래스)에 따라 달라집니다. 논문의 결론("학습자에 따라 최적 H가 다르다")과 같은 방향입니다.
- 이 toy는 "다양성은 항상 해롭다"는 주장을 지지하지 않습니다. 해로움은 정책이 평균화하는 경우에만 나타나고, 그 크기는 성공률 차이로는 크지 않았습니다(충돌 7-9%, 성공률은 오히려 증가).
- 한계: 2차원, 장애물 하나, 시연 60개, 정책 두 종류. 실제 IL의 확산 정책이나 VLA와는 다릅니다. 이 toy는 기전(커버리지, 평균화, H의 단조성)을 보이는 용도입니다.

5. 민감도 요약

민감도	값	판단
샘플 수 N (낮은 차원 자료)	±0.01 이내 (N ≥ 100)	편향 작음
샘플 수 N (노이즈 0.03)	N = 100에서 −0.14	피크 위치 비교에 영향 가능
샘플 수 N (등방 D = 150)	N = 100에서 −0.73	고차원 자료에서는 큼
재표집 점 수 T	두 배마다 +0.69 (ln 2)	절댓값 비교 불가
시작-목표 거리	1.0 대 0.3에서 r 효과가 약 10배	논문 미보고, 표 I 크기를 결정
노이즈 σ	0.03에서 +0.13	노이즈가 차원을 늘림
정규화 ÷(M−1) 대 ÷1	M=100 → 2000에서 +3.0 (ln 20)	÷(M−1)이면 안정
kNN 엔트로피(D = 150)	k = 3 → 20에서 −210 nats (M = 100)	대역폭(k) 민감도가 매우 큼. 기준선으로 부적절

H_G에는 대역폭이 없다는 점은 맞습니다. 그러나 T, 거리 정규화, 편향이라는 다른 자유도가 있습니다.

6. 종합

1. 표 I의 방향(r ↑ → H ↑, k=1 → H ↓)은 이 정의로 재현됩니다(T1b). 절댓값은 미보고 변수(시작-목표 거리)에 달려 있어 재현되지 않습니다.
2. H_G는 선형 차원과 크기를 재므로, 두 전략이 반대로 나뉜 자료(k=2)를 "다양성이 낮은" 쪽으로 읽습니다(T1c). 모드 모호성을 직접 측정하지 못합니다.
3. N 편향은 자료의 스펙트럼에 따라 0.01-0.7 nats입니다. 논문의 피크 이동(0.1-0.3 nats)과 같은 크기이므로, N마다 같은 부분표본으로 비교하는 검증이 필요합니다.
4. 성공률 판독으로 보면 StackCube 시뮬의 역U는 N = 100, 200에서 명확하고, N = 1000에서는 "피크 뒤 감소"만 있습니다. 실물 StackCube는 왼쪽 점 한 개에 의존합니다.
5. toy 2에서 커버리지 이득은 재현되고, 평균화 손실은 정책 클래스에 따라 나타나거나 나타나지 않습니다. 논문의 기전은 조건 신호가 모호한 경우에만 성립합니다.

04 주장 검증과 구현 가능성

공식 코드가 없어서(§3) 코드 대조(`04_code_verification.md`) 대신 **주장 검증**으로 씁니다. 각 주장을 논문 절·표·그림에 붙이고, 우리 재계산(`03`), 판독 검정(`stats_check.py`), toy 결과로 판정했습니다. 판정 기준은 다음과 같습니다.

- **지지**: 논문 수치 또는 우리 재계산이 주장과 맞고, 유의하다.
- **부분**: 방향은 맞지만 범위, 유의성, 조건 중 하나가 빠졌다.
- **약함**: 방향은 맞아 보이나 통계적으로 확정되지 않는다(판독 오차 안).
- **반박**: 논문 수치 또는 toy가 주장과 반대다.
- **검증 불가**: 필요한 정보(코드, 평가 횟수, 시드별 값, 그림 수치)가 없다.

판독 기반 판정은 모두 근사입니다(`03` §1.1 가정).

1. 주장별 판정

ID	주장 (논문 위치)	근거	판정
C1	H_G는 과제에 무관(task-agnostic)하고 대역폭이 없다 (Abstract, Sec. III-D)	식은 대역폭이 없다. 그러나 전이 구간 분할은 그리퍼 이벤트에 의존하고(III-B), 목표 프레임 R_T는 시뮬에서는 환경 상태, 실물에서는 인지로 얻는다(III-B 각주 1). 재표집 점 수 T(`03` §2.2), 시작-목표 거리 정규화(§2.2)에 따라 H 값이 달라진다	부분. "대역폭 없음"은 맞고, "과제 무관"은 분할과 목표 프레임에 의존한다
C2	H_G = ln d_eff + ln Σλ, d_eff = exp(Shannon 엔트로피) (식 1-2)	식을 그대로 구현하면 toy에서 동작한다. ln d_eff = H(p)임을 유도했다(`03` §2.1)	지지 (구현 가능)
C3	표본 공분산 λ 사용, H는 "안정"하다. HG는 N ≈ 50-100 이후 수렴 (Fig. 2)	정규화를 ÷(M−1)로 가정하면 총 분산 항은 M에 무관하다(toy T2). 편향은 자료 스펙트럼에 따라 낮은 차원에서는 0.01 이하, 노이즈 0.03에서 N = 100에 −0.14, 등방 D = 150에서 −0.73(`03` §3.1). Fig. 2의 수치는 논문에 없다	약함. 자료가 낮은 차원일 때만 맞고, Fig. 2 수치 없이는 확인 불가
C4	표 I: r ↑에서 H ↑(k=0), k=1에서 H ↓	표 I 값 자체가 단조다(2.901 → 3.667; 0.05/1 = 2.909 < 0.05/0 = 3.183; 0.10/1 = 2.997 < 0.10/0 = 3.667)	지지 (표 안 일관성). 재현은 불가(C5)
C5	표 I 값이 재현된다	코드, 시연 생성 설정(시작점 분포, 거리, Δz, 최소 성공률), 평가 세부가 없다	검증 불가. toy는 방향만 재현(T1b), 절댓값은 시작-목표 거리(미보고)에 따라 달라진다
C6	식 4의 k=1은 "단일 전략", k=0은 "연속 전략"이라 H가 모드 모호성을 반영한다 (III-A, V-D)	toy(T1c): 반대 두 전략(k=2)은 연속 분포(k=0)보다 H가 0.93 낮다(d_eff 2.03 → 1.00). k=3과 k=0은 같다. 즉 H는 선형 차원을 센다	**반박 (해석 부분).** H는 전략 수가 아니라 2차 모멘트를 재므로, 모호성을 직접 재지 못한다. k=1이 H를 낮춘다는 표 I 결과는 맞다
C7	DP(StackCube)에서 성공률은 H에 대해 역U다 (Fig. 3a, V-A-1)	N = 100: 2차항 p = 0.001, 꼭짓점 3.36. N = 200: p = 0.016, 꼭짓점 3.30 (`03` §1.3)	지지 (N = 100, 200). 판독 근사 기준
C8	역U의 피크가 N이 늘수록 낮은 H로 이동한다 (Fig. 3a, V-A-2)	꼭짓점 3.36 → 3.30 → 3.25(N = 100, 200, 500). 기울기 −1.5/decade, p = 0.21. N = 500 최고점은 0.03/0과 0.05/0이 동률(p = 0.48). N = 1000의 피크 2.917은 2등(2.909)과 차이가 없고(p = 0.24), 2차항도 유의하지 않다(p = 0.53)	약함. 방향은 맞아 보이나 N = 1000에 역U가 없다
C9	쉬운 과제(PegInsertion)는 더 낮은 H에서 포화한다 (Fig. 3b, V-A-2)	Fig. 3b는 판독 가능하지만 H 축 값과 설정 목록이 없다. 판독 시 곡선은 낮은 H(약 1.8-2.5)에 있고, StackCube(2.9-3.7)와 축이 다르다	검증 불가 (H 축과 설정 미공개). 곡선 모양은 "더 빨리 포화"와 맞다

ID	주장 (논문 위치)	근거	판정
C10	π0.5(사전학습 VLA)에서 성공은 H에 대해 단조 감소한다. 최적점이 관찰 범위 밖으로 밀렸다 (Fig. 4, V-A)	4점, 오차막대 없음, 모두 k=0이라 H는 r과 같은 정보. $\tau = -1$이지만 정확 $p = 0.083$. 0/0, 0.05/1 등 낮은 H 설정은 시험하지 않았다 (`03` §1.4)	약함. "관찰 범위 밖에 최적점이 있다"는 확인되지 않았다. 최적점이 실제로 밀렸는지는 낮은 H 설정 없이 알 수 없다
C11	사전학습이 최적 H를 낮춘다 (V-B, Sec. I)	π0.5 곡선은 DP의 모든 점보다 높다(같은 설정 3.183, N=1000: π0.5 0.918, DP 0.635). 최적점 비교를 위한 공통 설정이 없다	부분. 사전학습이 성능을 전반적으로 올린다는 것은 맞다. "최적 H의 이동"은 같은 설정 비교로 확인되지 않았다
C12	실물 ACT StackCube에서 역U, 피크 H ≈ 3.3 (Fig. 5, V-C)	피크 3.27(0.62). 왼쪽 끝 3.00(0.30) 대 피크: $p = 1\times10^{-6}$(A), 0.007(B). 오른쪽 이웃 3.50과 차이: $p = 0.027$(A), 0.26(B). 2차항 $p = 0.095$ (`03` §1.5)	부분. 역U의 기울기는 왼쪽 한 점에 의존한다. 가정 B에서 피크 오른쪽 차이는 유의하지 않다
C13	실물 PlacePanda, OpenDrawer는 단조 감소 (Fig. 5, V-C)	두 과제 모두 Kendall $\tau = -1$(5점), 정확 $p = 0.017$. OpenDrawer의 2차항 꼭짓점은 범위 밖	지지 (판독 기준)
C14	시뮬과 실물의 정성적 일치 (V-C "sim-to-real consistency")	실물은 ACT, 시뮬은 DP다. 알고리즘이 다르므로 "같은 메커니즘"의 증거로는 약하다. 과제 H 축도 다르다(StackCube 시뮬 2.9-3.7, 실물 StackCube 3.0-3.9, PlacePanda 2.45-3.3, OpenDrawer 2.0-6.4)	약함
C15	"일관된(consistent)" 역U가 여러 IL 구조에서 나온다 (Abstract)	역U는 DP(시뮬, 특히 N = 100, 200)와 ACT(실물 StackCube)에서만 나온다. π0.5는 단조이고, 단조 과제가 2개이다. "일관된"은 과장이다. 논문 자신도 "effectively monotonic"을 인정한다	반박 (일관성 주장). 역U가 나오는 조건이 과제와 N에 의존함
C16	최적 H는 학습자의 숙련도(task mastery)에 따라 이동한다 (V-B)	숙련도의 독립 측정이 없다. 작업 프록시(저다양성 기준 성공률)는 결과 변수와 같은 측정이다. N, 과제, 사전학습은 숙련도 변수이지만 동시에 학습 예산, 과제 난이도, 설정 집합을 바꾼다	부분. 순환 정의와 교란이 있다. 원인 해석은 약하다
C17	H_G는 기준선(평균 분산, LogDet, 참여율, kNN)보다 낫다 (V-D, Fig. 6)	Fig. 6의 수치는 그림에만 있다. toy에서 H_G는 낮은 차원 구조에서 편향이 작고 kNN보다 N에 안정적이다(T2 대 T5). 그러나 kNN 기준선은 D = 150, M ≤ 1000에서 대역폭 민감도가 커서 공정한 비교가 아니다(§5). LogDet, 참여율은 toy에서 시험하지 않았다	검증 불가 (기준선 수치 없음). kNN 비교는 불공정
C18	H_G는 학습 전에 데이터셋을 감사하는 도구이다 (Abstract, VI-A)	예측 검증이 없다. 새 과제에서 H를 미리 재고 최적을 맞힌 사례가 없다. 시뮬 H 범위에서 최적은 과제마다 다르다(C9, C13). 최적 H의 절댓값을 과제 사이에 옮길 수 없다	검증 불가 (예측 검증 없음)
C19	한계: 과제 수가 적고, 전이 구간 분할이 이벤트 의존이며, 인과 효과는 실험에 기대고 있다 (VI-B)	저자가 스스로 인정한 한계이다. 우리 검토에서 추가 한계: 시연 평가 횟수 미공개, 학습 예산 통제 불명, 정책의 성공 시연만 H에 들어감 (Eq. 3의 n_p)	지지 (한계 목록은 충분하지 않음. 추가 항목은 §2)
C20	낮은 H는 좁은 회랑, 높은 H는 혼재 전략이라는 해석 (VI-A)	toy(T1c)에서 H가 높아도 혼재 전략의 구별 여부는 H에 나타나지 않는다. 반대 두 전략은 H를 낮춘다(C6). 해석의 진단 능력이 약하다	반박 (해석). 진단 규칙을 그대로 쓰면 오분류가 생긴다

2. 빠진 정보

논문 본문과 그림에서 확인되지 않는 항목입니다. 재현과 비교에 필요합니다.

1. 시뮬 평가 에피소드 수와 오차막대의 정의(SD 또는 SE), 시드별 값.
2. 학습 예산(에포크 또는 스텝)이 N에 따라 같은지. 같지 않으면 N 효과는 학습량 효과와 섞입니다(`contact_disassembly`의 D1-D2에서 같은 문제를 확인, 시뮬 데모 수 90과 30이 에포크 555와 1666으로 바뀜).
3. 시연 생성기의 시작점 분포, 목표 배치, 반지름 r의 단위, 경유점 높이 Δz, 플래너 실패 처리.
4. 시작-목표 거리(정규화 분모). 표 I 크기를 결정합니다(`03` §2.2).

5. T(재표집 점 수)를 T = 50으로 고정한 이유, 다른 T에서의 민감도.
6. ÷(M−1) 대 ÷M 여부(λ 정의). Fig. 2의 안정성은 ÷(M−1)을 전제합니다.
7. 실물에서 세 명의 수집자가 어떤 H 설정을 맡았는지. 수집자와 설정이 섞이면 H 효과가 수집자 효과와 교란됩니다.
8. Fig. 3b(PegInsertion)의 설정 목록과 H 값.
9. Fig. 4(π0.5)의 시드 수, 평가 횟수, 학습 설정, 낮은 H 설정(0/0, 0.05/1)을 포함하지 않은 이유.
10. Fig. 6의 기준선 수치, LogDet의 α, kNN의 k.
11. 전이 구간 분할의 세부(그리퍼 이벤트의 임계값, 최소 길이).
12. 성공하지 못한 시연을 어떻게 다뤘는지. Eq. 3은 성공 시연만 씁니다. 실패가 설정(r, k)에 따라 다르면 H는 선택 편향을 가집니다.

3. 재현 가능성 점검

항목	결과	근거
논문 공식 코드	없음	프로젝트 페이지는 `index.html`, `style.css`, 논문 PDF만 있음(`geometric-entropy/geometric-entropy.github.io`, 커밋 `d292168`, 2026-11-07, 라이선스 없음, 별 0). 저자 개인 저장소에 관련 코드 없음(`gh search repos`, `gh api`)
프로젝트 페이지 대 arXiv v1	주요 수치와 표는 같다	프로젝트 페이지의 StackCube 설명은 "최고 3.183(N=100, 200), 3.016(N=500), 2.917(N=1000)"이라고 쓰며 우리 판독과 맞다. 요약문 표현은 더 약하다("in higher-performing regimes, declining trends")
카메라 레디 PDF (`assets/paper/geometric_entropy_iros2026.pdf`)	v1과 같은 구성	키워드 대조(표 I, 3.3, 40 test episodes, three seeds, 절 제목)가 같다. v1을 기준으로 씀
우리 재계산	표 I 순서 재현, 역U 일부 재현	`03` §1, §3

4. 구현 가능성 판정

결론: 공식 재현은 불가능하고, 아이디어(H_G 계산과 역U 실험 설계)는 옮길 수 있습니다. 실험 재현에는 GPU와 시뮬레이터 설치가 필요합니다.

항목	판정	근거
공식 재현	**불가**	코드, 시연 생성기, 학습 설정이 없다. 프로젝트 페이지에는 코드 링크가 없다(§3)
H_G 계산 (식 1-3)	**가능** (이 맥, CPU numpy)	`entropy_toy.py`의 `align()`과 `h_g()`가 정렬과 식 1-2를 수십 줄로 구현. 이미 실행됨. 실제 궤적 입력만 있으면 된다
시연 생성기 (ManiSkill, 경유점 삽입)	**조건부**: 설치 승인 필요, 플래너 CPU 실행 여부 미확인	논문은 PandaArmMotionPlanningSolver를 쓴다. ManiSkill(Apache-2.0, 3504 별, 2026-08-04 최근 푸시)는 시뮬 설치가 필요하고 카메라 렌더링에 GPU가 필요할 수 있다. 상태 기반 플래너만 쓰면 CPU로 가능할 가능성이 있으나, 이 맥에서 실측하지 않았다

항목	판정	근거
DP 학습 (N 스윕, 그림 3)	**불가 (현재 환경)**	공개 DP 코드(MIT, 4721 별, 최근 푸시 2024-12-24, `5ba07ac`)는 사용 가능하다. 학습에는 CUDA GPU가 권장된다. 이 맥은 CUDA가 없고 torch가 없다. MPS로 소형 모델은 가능할 수 있으나 StackCube 성공률 평가는 시뮬이 필요하다
π0.5 미세조정(그림 4)	**불가**	openpi(Apache-2.0, 14603 별, `215abfb`)와 3B급 모델 미세조정에는 GPU가 여러 장 필요하다. 체크포인트 다운로드도 승인 대상
ACT 실물(그림 5)	**불가**	ARX 로봇 팔이 필요하다. 시뮬 재현도 없다. ACT 코드(tonyzhaozh/act, MIT, 2335 별, `742c753`)는 쓸 수 있다
판독 검정(`03` §1)	**가능** (완료)	이 맥에서 완료. 판독 오차의 영향은 `stats_check.py`에서 흔들기로 확인
재구현 노력	H_G 계산 0.5일, 시연 생성기와 평가 1-2주(GPU 포함), 실물 재현 별도	추정. 실제 노력은 ManiSkill 설치와 플래너 호환에 크게 좌우됨
필요한 하드웨어	GPU 1장 이상(CUDA, 소형 DP 학습 기준 수 GPU-시간), 실물 팔 1대	논문 설정 기준

이 맥(Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치)에서 할 수 있는 것: H_G 정의의 검산, 합성 궤적에서 N·T·정규화·노이즈 민감도, 2차원 BC toy, 판독 값 검정. 이것들은 모두 완료했습니다.

할 수 없는 것: 논문 수치 재현, DP·ACT·π0.5 학습과 평가, 실물 실험. 이들은 설치·다운로드·GPU 승인이 필요하며 현재 계획에 없습니다.

H_G를 실제 데이터 감사에 쓰려면: 시연 궤적(위치 시계열)과 목표 프레임(목표 자세)이 있으면 됩니다. 이 조건은 텔레옵 데이터셋에서 대부분 충족될 가능성이 있으나, 목표 자세 추정이 없으면 정렬이 불가능합니다(C1). 과제 분할 이벤트(그리퍼)도 필요합니다.

5. 기준선 공정성 메모

- kNN(Kozachenko-Leonenko) 엔트로피는 D = 150, M ≤ 1000에서 대역폭 k에 민감합니다(T5, k = 3 → 20에서 −210 nats). 같은 자료에서 H_G는 0.005만 움직입니다. 이 비교는 "H_G가 안정적"을 보이기는 하지만, 기준선이 약하게 설정된 것입니다. 공정한 기준선은 차원을 줄인 뒤의 가우시안 엔트로피나, 같은 PCA 차원에서의 H_G 변형일 것입니다.
- 평균 분산(σ^2_avg)은 임의의 순서를 무시합니다. 논문이 든 (0,0), (0.01,0), (0.03,0)의 붕괴는 이 기준선의 정의상 예상되는 결과이므로 증거로서 약합니다.

02 선행연구, 가까운 대안, 저장소 내 관계, GitHub

1. 선행연구 계보

계보	대표 연구 (논문 참고문헌 번호)	이 논문과의 관계
데이터 스케일링	RT-1 [1], RT-2 [2], OXE [3], DROID [4], Octo [5], OpenVLA [6]	다양성을 "태스크·객체·embodiment" 같은 거친 속성으로 다룸. H_G는 궤적 기하에 한정
데이터 품질	Belkhale et al. [12] (행동 발산과 전이 다양성), Mandlekar et al. [15]	품질 축은 관측, 라벨, 범위. 궤적 기하 축은 다루지 않음
수집과 큐레이션	DAgger [13], DART [14], 가중치·필터 [16], Scizor [17], CUPID [18], 온라인 경험 큐레이션 [19]	선택과 가중이 목적. H_G는 감사(진단) 용도
데이터 생성	MimicGen [21], DemoGen [22], ManiBox [23], FieldGen [25], MOVE [26]	생성으로 커버리지를 넓힘. H_G는 넓힌 결과의 측정 도구로 쓸 수 있음
다중모드 정책	GAIL [27], BeT [28], IBC [30], 잠재 행동 생성 [31], BAKU [32]	다중모드를 정책 쪽에서 모델링. 논문은 이 정책 클래스의 차이를 실험하지 않음
다양성 평가	D3IL [33], 점유 측도 매칭 [34], "다양성이 필요한가" [35]	[35]이 "다양성 효과가 변수에 따라 다르다"를 보임. 논문과 같은 질문
궤적 유사도	DTW [36]	쌍별 정렬. H_G는 집단 스펙트럼

가까운 선행 연구 중 이 논문이 비교하지 않은 것. [35] Shi et al. (`Is diversity all you need`)은 같은 질문에 다른 변수(장면·객체 다양성)로 답한다. 논문은 이 연구를 언급만 하고 H_G와 비교하지 않는다.

2. 가까운 대안 (기준선)

대안	정의	H_G와 차이	이 저장소 검증
평균 분산 σ^2_avg	시점별 분산의 평균	순서와 상관을 무시	논문 Fig. 6 (그림만)
LogDet	log det(Σ+αI)	정규화 α 필요, 낮은 차원에서 조건 나쁨	우리 toy 미실시
참여율 PR	$(\Sigma\lambda)^2/\Sigma\lambda^2$	스펙트럼 정보는 쓰지만 단일 요약	논문 Fig. 6
kNN KL	Kozachenko-Leonenko	대역폭 k, D = 150에서 표본 크기 drift	우리 toy T5 (k에 매우 민감)
공분산 유효 차원만	exp(H(p))	크기 항 없음	toy T1c에서 d_eff로 분해

3. 이 저장소의 다른 분석과의 관계

논문의 핵심 질문(데이터의 어떤 속성이 학습에 도움이 되는가)은 이 저장소의 여러 폴더와 맞닿아 있습니다. 아래는 이 논문을 읽을 때 참고할 연결점입니다.

- **`nestdex/` (NestDex, arXiv:2608.13362).** 텔레옵 시연을 수집하는 방식이다. 수집 성공률(Table II, Fisher 검정)과 수집자의 노력이 데이터 품질을 좌우한다. H_G는 수집 품질(성공률)을 재지 않으므로, H_G 감사와 수집 품질 감사는 따로 해야 한다. 논문 Eq. 3이 성공 궤적만 쓰는 것도 같은 선택 편향 문제다(`04` §2의 12번).
- **`chronospolicy/` (Chronos Policy, arXiv:2610.13929).** 공개 코드가 없다("Coming soon", 2026-10-28 확인). 이 논문과 같이 "공개 코드가 없는 IL 논문에서 수치만 재계산하는" 사례다. 교훈: 재계산과 toy로 검증할 수 있는 범위를 먼저 정한다.

- **`do_as_i_do/` (Do as I Do, arXiv:2606.19333).** 일상 영상에서 손 궤적을 복원해 로봇 손으로 리타겟한다. 시연이 사람 영상에서 오므로, H_G의 목표 프레임(R_T)과 전이 구간 분할을 영상에서 얻는 문제가 생긴다(`04` C1). 영상 유래 데이터의 감사 도구로 H_G를 쓸 때 가장 먼저 확인할 조건이다.
- **`beyond_implicit_force/` (Beyond Implicit Force, arXiv:2607.14578, IROS 2026).** ACT를 ALOHA식 원격조작 데이터로 학습한다. 이 논문의 실물 실험(ACT, N = 100, 3 수집자)과 같은 정책 계열이다. 데이터 양과 수집 조건의 통제 방법(`beyond_implicit_force/analysis/04_claim_verification.md`)을 참고할 수 있다.
- **`contact_disassembly/` (CONTACT, arXiv:2603.08560, IROS 2026).** 시뮬 데모 수가 과제마다 90, 30으로 달라졌고, 에포크는 `int(50000/n_demo)`로 자동 계산되어 학습량이 같이 바뀐다(`contact_disassembly/analysis/04_code_verification.md` D1-D2). 이 논문의 N 스윕(100-1000)도 학습 예산을 통제하지 않았다면 같은 교란이 있다(`04` §2의 2번). 이 패턴이 이 논문 검증의 가장 중요한 참고 사례다.
- **`dexforce/` (DexForce, arXiv:2501.10356).** 키네스테틱 시연에서 접촉력으로 행동 목표를 만든다. 데이터의 "품질"을 힘 정보로 정의한다는 점에서 H_G(기하 다양성)와 다른 축이다. 두 축을 같이 감사하면 데이터 큐레이션이 더 정확해질 것이다.

4. GitHub 조사 (2026-11-10 확인)

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋 (해시)
(논문 관련 코드)	`gh search repos "geometric entropy imitation learning"`, `"geometric-entropy"`, 저자 3명 계정(`qianqianlo`, `zrllrz`, `YanchaoYang`) 검색	—	—	—	**찾지 못함.** 관련 없는 "geometric entropy" 저장소만 검색됨
`geometric-entropy/geometric-entropy.github.io`	프로젝트 페이지(`index.html`, `style.css`, 논문 PDF). 코드 없음	공식(프로젝트 페이지)	없음	0	`d292168` (2026-11-07)
`qianqianlo/qianqianlo.github.io`	제1저자 개인 사이트	저자 개인	확인 안 함	—	2026-11-07 푸시. 코드 아님
`mani-skill/ManiSkill`	시뮬레이터(PandaArm 플래너, StackCube-v1, PegInsertionSide-v1)	논문이 사용	Apache-2.0	3504	`62ff3a5` (2026-08-02)
`real-stanford/diffusion_policy`	Diffusion Policy 구현	논문이 사용(정책)	MIT	4721	`5ba07ac` (2024-12-24)
`tonyzhaozh/act`	ACT 구현	논문이 사용(실물)	MIT	2335	`742c753` (2024-01-28)
`Physical-Intelligence/openpi`	π0.5 구현(미세조정 레시피)	논문이 사용(VLA)	Apache-2.0	14603	`215abfb` (2026-08-24)
`huggingface/lerobot`	SO-100 계열 및 π0.5 PyTorch 포트	참고용	Apache-2.0	28790	`81b8c5b` (2026-11-09)

판단: 이 논문의 H_G 계산 코드와 시연 생성기는 공개되지 않았습니다. 프로젝트 페이지 저장소는 웹사이트이고 코드가 없습니다. 실험 기반(ManiSkill, DP, ACT, openpi)은 모두 공개되어 있으므로, 실험 재현의 뼈대는 가능합니다. 다만 논문이 쓴 설정(경

유점 생성, 시연 수, 학습량)은 우리가 다시 정해야 합니다.

5. 저작권과 인용 메모

- 저자 소속은 대학(University of Hong Kong)만 인용합니다. 공개 문서에 기관명을 더 쓰지 않습니다.
- 인용 형식: Luo, Liu, Zhou, Zhou, Yang, "Geometric Entropy: When Trajectory Diversity Helps and Hurts in Imitation Learning", arXiv:2606.20871 (v1), IROS 2026.