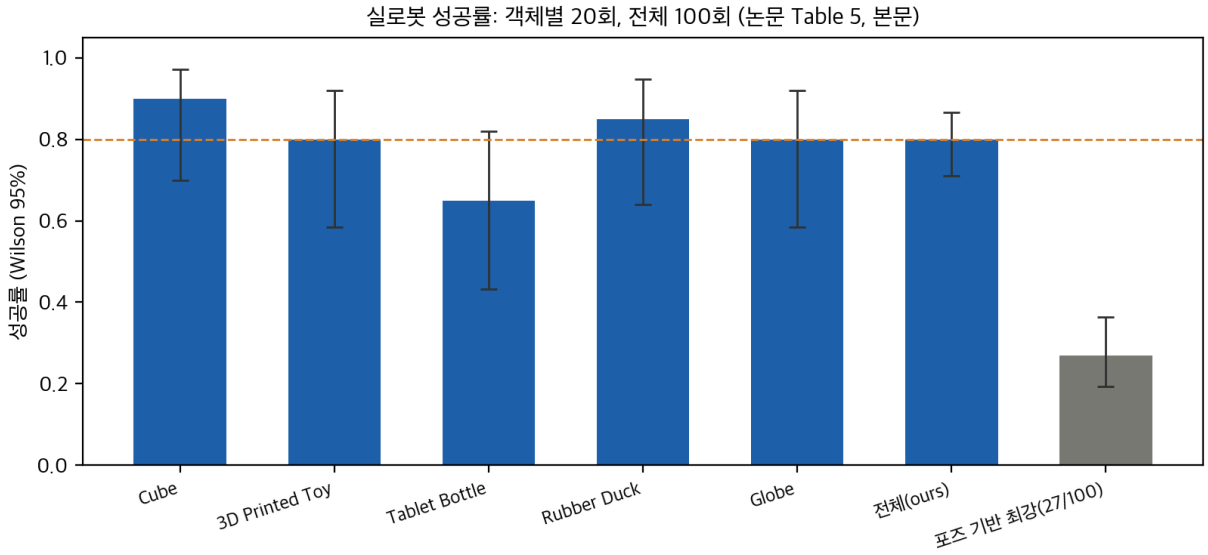
GoalDex: 분석 리포트

arXiv:2611.02171v1 (2026-11-01) · CoRL 2026 (원문 1쪽 표기) · 공식 코드 없음(프로젝트 페이지 "Code soon", 확인 2026-11-12) · 분석일 2026-11-12 · 논문 라이선스 CC BY-NC-ND 4.0 · 게시용 버전: 논문 그림과 원문 PDF는 뺐습니다(CC BY-NC-ND).

핵심 요약

1. **무엇을 하는가:** RGB 관찰, 고유감각, 목표 이미지를 받아 Allegro 손의 관절 목표를 내는 단일 정책을 학습한다. 교사(특권 상태)의 행동 복제, 숨은 상태 재구성, 목표 이미지와 자세 거리를 맞추는 연속 대조 손실을 함께 쓴다(`01` §2).
2. **이미지 목표의 이득은 CS와 TTS에 한정된다:** 같은 입력에서 포즈 목표 69.20 대 이미지 목표 77.30 (CS). 차이는 3 시드에서 유의하지 않다($p = 0.16$). 예측 실패율과 F1은 좋아지지 않는다(`03` §2.2, §3).
3. **실로봇 80/100은 확실하다:** Wilson 95% [71.1, 86.7]%. 포즈 기준선 27/100은 이항 검정에서 차이가 확실하다($p = 4 \times 10^{-14}$). 하지만 기준선의 시도 기록이 없다(`03` §2.1, §2.3).
4. **객체 간 차이는 검출되지 않는다:** χ^2 $p = 0.36$. Tablet Bottle이 가장 어렵다는 주장은 "원인은 대칭 기하"라는 설명과 함께 검증되지 않았다(`04` C8).
5. **대칭은 목표를 모호하게 만든다:** 정육면체 토이에서 이미지상 성공은 기하 성공의 23배다. 연속 대조 목표는 같은 이미지에 대해 서로 다른 값을 요구한다(`03` §5).
6. **허용오차 0.4 rad에서 예측 실패율은 모형 가정에 민감하다:** 최종 오차 척도 0.35 rad와 머리 잡음 0.19-0.30 rad가 필요하다. 허용오차를 0.2로 줄이면 예측 실패율이 두 배 이상이다(`03` §6).
7. **2x 환경 결과 표준편차 0.00이 이상하다:** 25개 물체 학생의 2x 행(CS 41.42 ± 0.00). 재집계를 확인해야 한다(`03` §1).
8. **공식 코드 없음:** 코드 대조는 만들 수 없다. 이 맥에서 재현은 불가능하다. 공식 재현은 NVIDIA GPU 리눅스와 ViserDex 자산이 있을 때 조건부다(`04` §4).
9. **라이선스:** CC BY-NC-ND 4.0. 논문 그림은 개인용 리포트와 PPT에만 넣었다(`04` §5).



그래프: 실로봇 성공률과 Wilson 95% 구간. 객체별 20회, 전체 100회, 포즈 기준선 27/100(본문 값). 우리가 그린 그래프다.

01. 논문 분석: GoalDex

메타

- 제목: *GoalDex: Learning Image-Goal-Conditioned Policies for Dexterous In-Hand Manipulation*
- arXiv: 2611.02171v1 (2026-11-01 제출), 분류 cs.RO
- 학회: **CoRL 2026** (10th Conference on Robot Learning, Austin, TX). 원문 1쪽 하단 "10th Conference on Robot Learning (CoRL 2026), Austin TX, USA." 표기로 확인했습니다. 채택 여부와 proceedings 게재 정보는 PDF에 없습니다.
- 저자: Bhardwaj, Mittal, Wilder-Smith, Patil, Hutter
- 원문: `paper/paper.pdf` (14.1 MB, 19쪽), 텍스트 `paper/paper.txt`, 프로젝트 페이지 HTML `paper/project_page.html`
- 프로젝트 페이지: https://rffr.leggedrobotics.com/works/goaldex/ (화면 확인 시점 "Code soon")
- 라이선스: arXiv abs 페이지의 라이선스 링크는 CC BY-NC-ND 4.0입니다. 1쪽에는 arXiv 스탬프와 CoRL 표기만 있고 "©"나 재인쇄 문구는 없습니다(`04` §5).

한 줄 요약

RGB 관찰, 고유감각, **목표 이미지**를 받아 Allegro 손의 관절 목표를 내는 단일 정책을, 특권 상태 교사의 행동 복제(온라인 DAgger)와 숨은 물체 상태 재구성 보조 손실로 학습합니다. 목표 이미지와 현재 이미지의 임베딩 거리를 두 자세의 측지 각에 맞추는 연속 대조 손실(α = 2.5)을 더합니다. 시뮬레이션 5개 물체에서 연속 성공 수(CS) 77.30 ± 3.25를 내고, 포즈 목표(같은 입력)는 69.20 ± 5.47입니다. 실로봇 5개 물체에서 100회 중 80회 성공하며, 같은 프로토콜의 포즈 기반 최강 기준선은 27회입니다(본문, 기준선 표는 없음).

구현 가능성 판정 (먼저 읽을 것)

- **공식 재현: 이 맥에서는 불가, NVIDIA GPU가 있는 리눅스에서는 노력이 큽니다(조건부).** 코드는 "Code soon" 상태라 아직 없습니다. 학습은 Isaac Lab, 3D Gaussian Splatting 렌더러(선행 연구 ViserDex [2]의 파이프라인), 객체 마스크용 SAM2 미세조정이 필요하고, 학생 한 정책이 H100 두 장에서 약 30시간입니다(부록 B.3). 실로봇은 Allegro 16-DOF 손과 손목 RealSense D435i가 필요합니다. 상세는 `04` §4.
- **이 맥(Apple M4 Pro, 약 24 GiB, MPS, CUDA 없음)**: Isaac Lab과 3DGS 학습은 불가입니다. 학습 방법의 핵심 손실(연속 대조, 재구성, DAgger 혼합)은 numpy와 CPU 토이로 옮겨 볼 수 있습니다. 이번에 했습니다(`03` §5-§6).
- **재구현 노력: 중간 이상.** 구조(ResNet-34 두 개, GRU 2층 512, 재구성 MLP)는 수백 줄이지만, 3DGS 렌더링과 물체 마스크, 학습 인프라가 실제 장벽입니다(추정).

1. 문제 설정 (§3.1)

- 목표는 SO(3)의 목표 방향을 **목표 이미지 I_g**로 지정하는 것입니다.
- 교사 MDP `M_priv = ⟨S, A, G, T, r, γ⟩`는 물체 기하, 질량, 마찰, 크기, 자세를 모두 봅니다. 배포 POMDP는 단안 RGB와 고유감각만 봅니다.
- 관찰은 "목표 중심(target-centric)" RGB 프레임 I_t라고 쓰지만, 실제로는 물체 마스크를 씌운 영상입니다(§3.3, 부록 B.3).
- 교사 상태에는 목표 상대 회전 q_rel과 물체 클래스 one-hot이 들어갑니다(§3.2).

2. 방법

구성 요소	내용	위치
교사	PPO, 여러 물체 하나의 정책, 목표 SO(3)를 월드 좌표로 줌	§3.2, 부록 B.1, 표 8·9
학생 시각	현재 영상 ResNet-34 → z_obj, 목표 영상 별도 ResNet-34(φ) → z_goal	§3.3-3.4, 부록 B.3
시간 통합	GRU 2층, 은닉 512 (x_t = [z_obj, z_goal, z_prop])	§3.3
재구성	은닉 상태에서 물체 위치, 자세, 속도, 크기, 질량 등을 MSE로 예측. 손가락 힘과 중력은 제외	§3.3, 표 8
연속 대조	$s^* = \exp(-\alpha\, d_\theta(q_{rel}))$, $L_{cont} = \mathrm{MSE}(s^*, \langle z_{obj}, z_{goal}\rangle)$, $\alpha = 2.5$	§3.4, 표 11
성공 예측	카메라 기준 상대 쿼터니언 $\hat{q}_{rel}$을 예측하고 각도가 0.4 rad 아래로 3 스텝 연속이면 성공 선언	§3.4, 부록 B.3
손실	$L_{total} = L_{BC} + 0.2\, L_{recon} + 0.1\, L_{cont}$	§3.4, 표 11
증류	온라인 DAgger, 교사 혼합 β = 0.9에서 0.995 감쇠	부록 B.3
렌더링	다물체 3DGS, 스케일은 카메라 뷰 행렬에 적용($\tilde{V} = VS$). 물체 스케일 U(0.5, 1.5)	§3.4, 부록 B.2

- 목표 이미지는 **물체 메시를 샘플된 자세로 렌더링한 영상**입니다(부록 B.5). 시뮬레이션에서는 3DGS로 렌더링합니다.
- 실로봇 배포는 30 Hz 정책, 300 Hz 관절 PD, 시각 인코더는 비동기 실행이며 임베딩은 zero-order hold로 씁니다. 목표 임베딩은 한 번 계산해 재사용합니다(부록 B.3).

3. 실험과 결과

3.1 설정

- 시뮬레이션: 3 시드, 환경 64개, 평가 에피소드 2회(환경당). 한 정책은 시드당 128 에피소드입니다(§4).
- 지표: 연속 성공 수 CS(↑), 성공까지 시간 TTS(↓), 성공 예측 F1(↑), 예측 실패율(↓), 재구성 오차.
- 성공 기준: 정책이 완료를 예측하고 **실제** 오차 < 0.4 rad. 예측 실패는 예측은 성공인데 실제 오차 ≥ 0.4인 경우이며, 그 목표를 버리고 새 목표를 뽑습니다(§4).
- 물체: 5개 세트(Cube, Globe, Tablet Bottle, 3D Printed Toy, Rubber Duck, 선행 연구 [2]와 같음), 25개 세트(확장).

3.2 표 1: 입력과 목표 표현 (3 시드)

방법 (JP / P / C / I / GP / GI)	CS ↑	TTS (s) ↓	F1 ↑	예측 실패율 (%) ↓
고유감각만 (✓ × × × ✓ ×)	1.05 ± 0.00	8.31	0.016	99.18
포즈 기반 (JP+P+GP)	8.64 ± 10.17	7.96	0.373	44.77
포즈 기반 (JP+P+C+GP)	11.23 ± 9.65	7.73	0.439	43.76
포즈 기반 (P+GP, 고유감각 없음)	1.81 ± 0.65	7.96	0.394	48.63
이미지 + 포즈 목표 (I+GP)	0.01 ± 0.01	6.80	0.000	100.00
이미지 + 고유감각 + 포즈 목표	69.20 ± 5.47	5.17	**0.923**	**8.33**
이미지 + 고유감각 + 이미지 목표 (ours)	**77.30 ± 3.25**	**4.35**	0.921	8.80

- 주의: 표의 "±"는 모집단 표준편차(ddof=0)로 보입니다. Table 5의 객체별 값으로 확인했습니다(`03` §1).
- 포즈 기반 기준선 네 줄(JP+P+GP, JP+P+C+GP, P+C+GP, P+GP)은 같은 표에서 포즈 목표를 씁니다. 포즈 추정기는 별도로 학습했습니다(부록 C, 표 12).

3.3 표 2: 시각 인코더와 재구성, 시간 메모리

변형	CS ↑	TTS (s)	F1	예측 실패율 (%)
동결 ImageNet ResNet	0.02	8.18	0.029	98.65
동결 DINOv2	0.00	-	0.000	100.00
동결 Depth Anything V2	0.12	8.46	0.036	96.72
포즈만 재구성	66.03 ± 9.34	5.55	0.912	9.70
시간 메모리 없음 (MLP)	38.64 ± 1.89	5.51	0.872	14.50
시각 메모리 없음	47.83 ± 9.07	5.93	0.913	11.80
전체 모델 (ours)	**77.30 ± 3.25**	**4.35**	0.921	8.80

- 본문은 "재구성 헤드를 뺀 변형은 완전히 실패"라고 쓰지만 수치는 표에 없습니다(§4.2).

3.4 표 3: 목표 정렬 방식

정렬	CS ↑	TTS ↓	F1 ↑	예측 실패율 ↓
분리 인코더	56.99 ± 1.89	4.50	0.913	10.50
EMA 목표 인코더	67.95 ± 6.80	5.65	0.857	10.30
공유 인코더	67.18 ± 4.43	4.69	**0.936**	9.32
InfoNCE (이진 임계)	63.01 ± 15.51	4.65	0.934	**8.11**
연속 대조 (ours)	**77.30 ± 3.25**	**4.35**	0.921	8.80

- 본문은 연속 대조가 CS와 TTS에서 최고라고 주장합니다. CS 차이의 유의성은 `03` §2에서 봅니다.
- InfoNCE는 F1과 예측 실패율에서 가장 좋습니다. 본문도 인정합니다.

3.5 표 4: 25개 물체

방법	CS ↑	TTS (s) ↓
특권 교사	110.84 ± 3.98	2.42
이미지 목표 (1x 환경 640)	10.11 ± 2.06	6.74
이미지 목표 (2x 환경 1280)	41.42 ± 0.00	5.30

- 1x에서 학생은 거의 실패합니다. 본문은 물체당 환경 수가 줄어 기울기 잡음이 커진다고 설명합니다(§4.4). 2x 표준편차가 정확히 0.00인 점은 `03` §1에서 확인합니다.
- 그림 5(c)의 평균선 41.42와 프로젝트 페이지의 "41.4" 표기는 표 4와 일치합니다.

3.6 실로봇 (표 5, §4.5)

물체	성공 (20회 중)	낙하	시간 초과	예측 실패
Cube	18	0	0	2
3D Printed Toy	16	1	2	1
Tablet Bottle	13	2	1	4
Rubber Duck	17	0	0	3

물체	성공 (20회 중)	낙하	시간 초과	예측 실패
Globe	16	1	1	2
합계 (100회)	**80**	4	4	12

- 같은 프로토콜의 포즈 기반 최강 기준선(클래스 인코딩 포함)은 100회 중 27회입니다. **이 27회의 표와 물체별 분해는 논문에 없습니다.**
- 본문: "Tablet Bottle은 대칭 기하, 낮은 마찰, 모호한 질감 때문에 가장 어렵다."

3.7 그림 5(부록 A.2): 물체별 시뮬레이션 값

- 5개 세트 CS(교사 대 ours): Globe 169 대 190, Tablet Bottle 141 대 90, 3D Printed Toy 130 대 59, Cube 145 대 47, Rubber Duck 25 대 9.0. 교사 평균은 122.96이고, ours 77.30은 교사의 63%입니다.
- 시뮬레이션에서 ours의 물체별 CS가 가장 낮은 것은 Rubber Duck(9.0)과 Cube(47)입니다. 실로봇에서 가장 어려운 것은 Tablet Bottle(13/20)입니다. **시뮬레이션과 실로봇의 어려운 물체 순위가 다릅니다.** 지표가 다르므로(연속 성공 수와 20회 성공률) 직접 비교는 할 수 없지만, 논문이 이를 한 줄로 넘긴 점은 짚을 가치가 있습니다.
- 그림 속 Cube는 면에 글자(T 등)가 인쇄된 물체이므로 `03` §5의 "무늬 없는 대칭 물체" 토이와 직접 같지 않습니다.

3.8 언어 지시 데모 (§4.6, 그림 4)

- GPT-4o(논문 본문은 VLM [9]로 표기)가 후보 시점 128개에서 목표 이미지 한 장 또는 순서열을 고릅니다(부록 B.4, 질의 형식은 JSON 출력).
- 세 과제: 유통기한 위치, 대륙 크기 비교, 글자 H-E-R-E 순서 제시. **정량 평가는 없습니다.** 성공 횟수가 보고되지 않았습니다.

3.9 부록 A.1 (표 6): 특권 및 오라클 포즈

- 표 6(부록 A.1)의 CS: 오라클 포즈 22.49 ± 6.77, 오라클 포즈 + 클래스 43.77 ± 7.06, 오라클 포즈 + 클래스 + 스케일 98.64, 특권 학생 120.38 ± 7.85, 교사 122.96 ± 2.38입니다.
- 본문은 오라클 포즈 정책이 RGB 정책보다 높지 않다고 씁니다. 수치로는 맞습니다(22.49 < 77.30). 하지만 오라클 포즈 + 클래스(43.77)도 RGB 정책보다 낮습니다. 학습된 포즈 기반 기준선(11.23)과 오라클 포즈 + 클래스(43.77) 사이의 약 32 CS 차이는 포즈 추정 오차 몫이며, 본문의 "포즈 추정 오차만으로 설명되지 않는다"와 양립합니다.
- 오라클 + 클래스 + 스케일(98.64)은 RGB 정책을 넘지만 스케일은 배포 때 관찰할 수 없는 값입니다(본문도 인정, 부록 A.1).

4. 저자가 인정한 한계 (Limitations 절)

1. 25개 물체 학습이며 **보지 못한 물체 범주에는 일반화하지 않는다**고 씁니다.
2. 목표 이미지 생성에 물체 기하(메시 렌더링)가 필요합니다. 해결책으로 유사 물체 검색이나 3D 생성 모델을 듭니다.
3. 물체 마스크가 필요합니다(SAM2 미세조정). 전체 프레임 학습으로 바꿀 계획입니다.
4. 실로봇은 palm-up 구성뿐입니다. 팔 움직임과 결합하면 일반 조작으로 확장할 수 있다고 씁니다.

5. 내가 보는 추가 한계 (본문에 없음)

- **허용오차 0.4 rad(약 23°)는 크고, 성공 판단은 예측 헤드에 의존합니다.** 실로봇 성공 수 자체가 "정책이 성공을 선언하고 오프라인 FoundationPose로 확인한 결과"입니다(부록 B.5). 평가가 포즈 추정에 기대므로, 포즈를 쓰지 않는다는 주장과 평가 절차가 맞물려 있습니다.
- **같은 이미지에 여러 자세가 대응할 수 있습니다.** 대칭 물체와 몸체가 회전체인 물체가 그렇습니다. 연속 대조 목표는 이 모호성을 반영하지 않습니다(`03` §5).

- **목표 이미지는 시뮬레이션 렌더링(3DGS)과 실로봇 메시 렌더링이 섞입니다.** 실로봇 목표 영상의 도메인이 학습 분포와 같은지 논문은 보이지 않습니다.
- **3 시드 통계.** 시드가 3개이므로 차이 검정력이 낮습니다(`03` §2).
- **실로봇 재현 데이터가 없습니다.** 표 5만 있고 시도별 기록, 목표 자세, 기준선 프로토콜이 없습니다.

6. 부록 요약

- **B.1 교사:** 관찰은 고유감각, 상태(교사만), 목표(위치와 쿼터니언 차이), 물체 클래스. 목표는 64차원, 상태는 128차원 잠재로 인코딩. PPO 액터와 크리틱 1024×4.
- **B.2 렌더링:** 3DGS 물체 가우시안, 스케일 증강을 뷰 행렬에 적용.
- **B.3 학생:** 학생 관찰은 고유감각 4스텝 행동 이력과 객체 마스크 RGB 두 장(현재, 목표). 640 환경, 45 스텝, 학습률 3e-4, 보조 손실 계수 0.2, 대조 계수 0.1, α = 2.5.
- **B.4 VLM:** 128 후보 뷰, JSON 질의 형식.
- **B.5 실로봇 라벨:** 각 예측 성공 프레임에서 FoundationPose(고해상도 RGB-D, 마스크, 메시, 반복 정제)로 자세를 구하고 메시 오버레이로 수작업 확인. 10초 시간 초과.
- **C 포즈 추정기:** ResNet-34(ImageNet 초기화), 아홉 개 키포인트(u, v, 깊이), Huber(δ = 0.05), AdamW.

7. 재현 시 필요한 정보 (논문에 없는 것)

- 물체 메시와 3DGS 자산, 도메인 무작위화 범위(본문은 질량과 마찰을 언급하지만 구체 범위는 확인되지 않음), 상태 재구성 대상 목록(표 8 기준)
- 교사의 학습 시간, 재구성 보조 손실 계수의 민감도
- 실로봇 시도별 기록과 기준선 프로토콜
- 시뮬레이션 CS의 정확한 정의(에피소드 안 연속 성공을 세는 방식과 시간 제한)

02. 선행 연구와 관련 저장소

1. 계보

- **포즈 기반 in-hand 재배향.** 정책 입력과 목표가 물체 포즈(또는 회전)입니다. 상태 추정기가 필요합니다. DextreMe [1], 촉각 재배향 [10, 11]이 여기에 속합니다. 6D 목표 자세 12는 외부 인지 모듈 [13]이 포즈를 추정해야 합니다.
- **같은 저자 선행 연구 ViserDex [2].** RGB 관찰로 물체별 정책 하나를 학습하는 sim-to-real 파이프라인(3D Gaussian Splatting 렌더링, 픽셀 증강, 포즈 키포인트 예측)입니다. GoalDex는 이 파이프라인을 다물체로 넓히고(부록 B.2), 포즈 대신 목표 이미지를 입력으로 바꿉니다. 포즈 기반 기준선은 ViserDex를 다물체로 확장한 것이라고 논문이 밝힙니다(표 1 제목 "extends [2] to multiple objects").
- **목표 표현 측면.** 픽셀 목표, 잠재 목표 임베딩 [14], 목표 분류기 [15], 깊이와 점군 기반 목표 [16]이 선행 연구로 인용됩니다. GoalDex는 "목표를 이미지 공간에서 직접 정의"하는 것이 차이라고 주장합니다(§2).
- **영상 입력 증류 정책.** DextrAH-G [17]는 깊이 기반 파지를 교사-학생으로 학습합니다. Lin 외 [18]는 양손 파지, HERMES [19]는 모바일 양손 조작에 깊이 증류를 씁니다. DextrAH-RGB [20]는 RGB 증류 파지이고, 이 논문의 재구성 기준선(포즈만 재구성)은 [20]의 방식으로 정의됩니다(§4.2).
- **교사-학생 증류의 원형.** 사족 보행의 지형 인지 정책 [23]을 인용합니다. 온라인 DAgger [30]를 혼합 비율 감쇠와 함께 씁니다.

2. 구성 요소별 출처

구성 요소	논문 설정	출처 (참고문헌 번호)	비고
교사 학습	PPO	[24]	액터와 크리틱 1024×4
학생 증류	온라인 DAgger, β 감쇠	[30]	부록 B.3
시각 백본	ResNet-34 (두 개: 현재, 목표)	[25]	512차원
순환 모듈	GRU 2층, 512	[31]	
재구성	은닉 상태에서 물체 상태 회귀	자체 설계 (근거: [20]의 포즈 재구성)	표 2 "포즈만 재구성" 비교
대조 목표	연속 대조 (코사인 대 exp(-α d_θ))	자체 설계	InfoNCE [27]와 비교(표 3)
렌더링	3DGS, 뷰 행렬 스케일	[2] 확장	부록 B.2
시뮬레이션	Isaac Lab	[6]	
물체 마스크	SAM2 미세조정	[32]	배포 시 로봇과 배경 분리
실로봇 라벨	FoundationPose	[13]	오프라인 자세 확인
동결 인코더 비교	ImageNet ResNet, DINOv2, Depth Anything V2	[26], [7], [8]	표 2
언어 선택	VLM (GPT-4o 표기)	[9]	128개 후보 뷰

3. 이 저장소의 다른 논문과의 관계

GoalDex의 주제는 "in-hand 재배향에서 목표를 어떻게 표현하는가"입니다. 이 저장소의 다음 분석과 비교할 수 있습니다.

폴더	논문	주제	GoalDex와의 관계
`kinefuse/`	KineFuse (arXiv:2607.14842)	in-hand 포즈 추적 (촉각과 자세 융합)	**가장 직접적인 대조.** GoalDex는 포즈 추적을 없애고 이미지 목표를 씁니다. 포즈 추적 정확도가 정책 성공으로 어떻게 이어지는지에 대한 대조 자료로 씁니다.
`nocontact_noworries/`	NoContactNoWorries (arXiv:2606.24450)	손목 RGB-D와 관절 자세로 손가락 접촉을 추정해 in-hand 회전 정책에 넣음	**같은 과제 공간.** 접촉 추정은 GoalDex의 재구성 보조 손실(접촉과 속도 상태)과 같은 정보를 다른 방식으로 얻습니다.
`chord/`	CHORD (arXiv:2607.00033)	사람 시연의 접촉 wrench로 보상을 만들어 다지 손 조작 학습	**목표 정의 방식의 대안.** GoalDex는 목표를 시각으로, CHORD는 접촉 지지 함수로 정의합니다.
`dexpolicy/`	DexPolicy (arXiv:2610.00360)	행동 잡음 σ 스케줄(PPO, GRPO, FPO)	목표 표현과 무관. 학습 스케줄 축에서만 비교 가능.
`eigendexplore/`	EigenDEXplore (arXiv:2610.07681)	사람 손 PCA 방향을 탐색 잡음에 넣음	목표 표현과 무관. 탐색 측면에서 GoalDex의 교사-학생 구조와 대비.
`cross_embodiment_wm/`	여러 손을 다루는 그래프 세계 모델 (arXiv:2511.01177)	입자 기반 세계 모델	목표 표현보다 표현 학습 방식(동역학 예측) 측면에서 간접 관련.
`motion_latent_action/`	Motion-Focused Latent Action (arXiv:2606.18955)	잠재 행동 표현으로 VLA 학습	"목표 표현을 잠재 공간에서 정렬" 측면에서 간접 관련.

- 과제 공간 전체(in-hand 재배향)를 공유하는 것은 `kinefuse/`와 `nocontact_noworries/`입니다.
- `tactilereflex/`와 `vnb_grasp/`는 파지와 촉각 제어 분석이라 직접 관계가 약합니다.

4. 버전

- 확인한 버전은 **v1**(2026-11-01 제출)입니다. arXiv abs 페이지의 버전 목록과 v2 존재 여부는 이번 분석에서 확인하지 않았습니다.
- 학회는 CoRL 2026입니다(원문 1쪽 표기). 프로젝트 페이지에도 "CoRL 2026"이 적혀 있습니다.

5. GitHub 확인 (2026-11-12, `gh search repos`와 `gh api`)

공식 코드는 아직 없습니다. 프로젝트 페이지의 "Code soon"이 확인 시점의 상태입니다. `leggedrobotics/goaldex`(조직 이름 기준)는 404입니다. 아래 표는 논문과 직접 관계된 저장소입니다.

저장소	무엇	라이선스 (GitHub 필드)	별	최근 푸시	비고
leggedrobotics/ViserDex	선행 연구 [2]의 공식 저장소	BSD-3-Clause	42	2026-09-16 (HEAD `937d533`)	같은 연구 그룹. GoalDex의 렌더링과 학습 기반으로 추정(논문에는 코드 공개 문구 없음)
isaac-sim/IsaacLab	시뮬레이션 프레임워크 [6]	NOASSERTION (LICENSE 파일 확인 필요)	8,626	2026-11-12 (HEAD `52ab68e`)	학습 필수
NVlabs/FoundationPose	자세 추정과 실로봇 라벨 [13]	Other (NVIDIA 자체 라이선스, 확인 필요)	3,698	2026-04-29	실로봇 평가 절차에 사용

저장소	무엇	라이선스 (GitHub 필드)	별	최근 푸시	비고
facebookresearch/sam2	마스크 미세 조정 [32]	Apache-2.0	20,138	2026-05-30	학습과 배포 마스크
facebookresearch/dinov2	동결 인코더 비교 [7]	Apache-2.0	13,526	2026-11-05	
DepthAnything/Depth-Anything-V2	동결 인코더 비교 [8]	Apache-2.0	9,141	2026-03-24	

이름 충돌 (무관한 저장소, 공식 아님):

- `yashashvialva/GoalDex` : OKR과 성과 관리 웹앱(README 확인).
- `SurajSingh90810/GoalDex` : Vite와 React 템플릿(README 확인).
- `goaldexorg01/goaldexAsset` : 로고 이미지 파일만 있음(내용 확인).

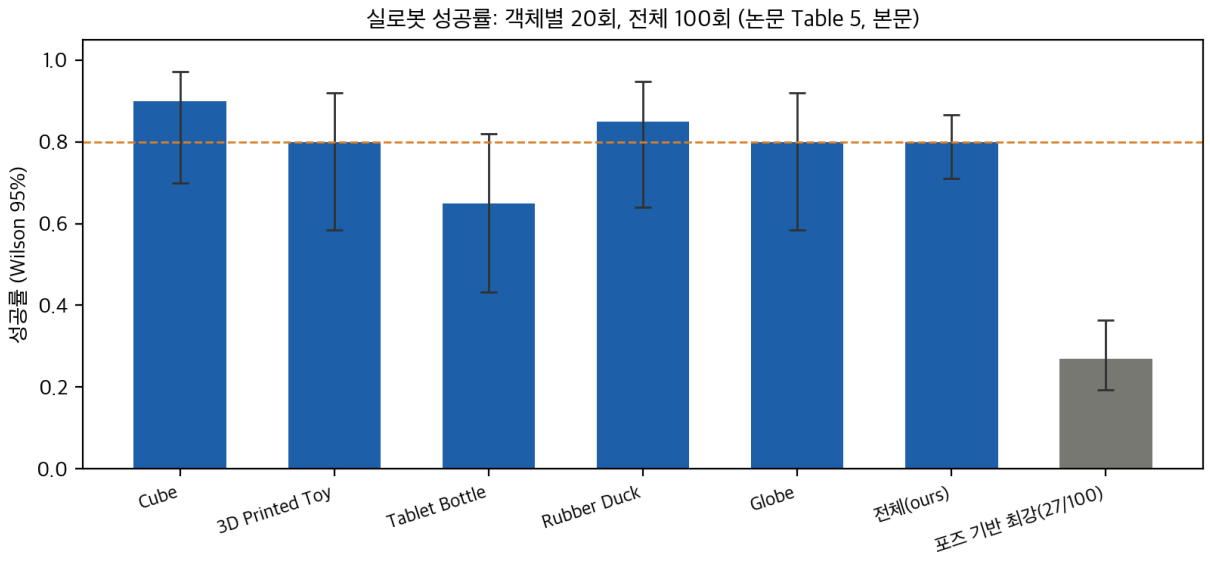
결론: 공식 코드 대조(`04_code_verification.md`)는 만들 수 없습니다. 코드가 나오면 그때 다시 확인합니다. 저장소는 clone하지 않았습니다.

03. 수치 재계산, 통계 검정, 토이 검증

재계산은 `analysis/table_check.py` → `table_check_results.json`, 토이는 `toy_symmetry.py` → `toy_symmetry_results.json`, `toy_tolerance.py` → `toy_tolerance_results.json` 입니다. 모두 numpy와 scipy로 CPU에서 수 초 안에 끝납니다. 토이의 파라미터는 설계 가정이며 논문 값에 맞추지 않았습니다.

1. 표 재계산과 일관성

확인	결과
"±" 규칙	Table 5 객체별 20회 값에서 모집단 표준편차(ddof=0)가 논문 값과 맞습니다. 성공 16.0 ± 1.67, 낙하 0.8 ± 0.75, 시간 초과 0.8 ± 0.75, 예측 실패 2.4 ± 1.02 모두 재현됩니다. 표본 표준편차(ddof=1)는 1.87 등으로 다릅니다. Table 1-4의 "±"도 같은 규칙으로 읽었습니다(가정).
Table 5 합계	객체별 성공 18, 16, 13, 17, 16 → 합계 80. 실패 합계 낙하 4, 시간 초과 4, 예측 실패 12. 80 + 4 + 4 + 12 = 100으로 맞습니다. 본문의 "80.0%"와 일치합니다.
동일 행 일치	이미지 목표 행(77.30 ± 3.25, TTS 4.35 ± 0.24, F1 0.921, 예측 실패율 8.80)이 Table 1, 2, 3에서 같습니다.
교사 수치	5개 물체 교사 CS 122.96(그림 5a, 표 6 122.96 ± 2.38), 25개 교사 110.84(표 4), 25개 2x 학생 41.42(표 4, 그림 5c 평균선, 프로젝트 페이지 "41.4")가 서로 맞습니다.
표 4 표준편차 0.00	2x 학생의 CS 41.42 ± 0.00과 TTS 5.30 ± 0.00은 3 시드 평균과 표준편차가 0이라는 뜻입니다. 세 시드가 정확히 같은 값을 낼 가능성은 낮습니다. 한 시드만 돌렸거나 표준편차가 반올림 또는 빠짐으로 0이 된 것으로 보입니다. **확인 필요.** 같은 표의 1x 행은 표준편차가 0이 아니므로 2x만 이상합니다.
표 6 오라클 포즈 행	오라클 포즈 + 스케일(37.05 ± 0.00), 오라클 포즈 + 클래스 + 스케일 98.64 ± 0.00 등 여러 행이 표준편차 0.00입니다. 표 4와 같은 문제입니다.
표 5 대 본문	본문 "포즈 기반 최강 기준선은 100회 중 27회"는 표 5에 없습니다. 기준선의 시도 기록과 프로토콜이 없어 검증할 수 없습니다(§2.3).



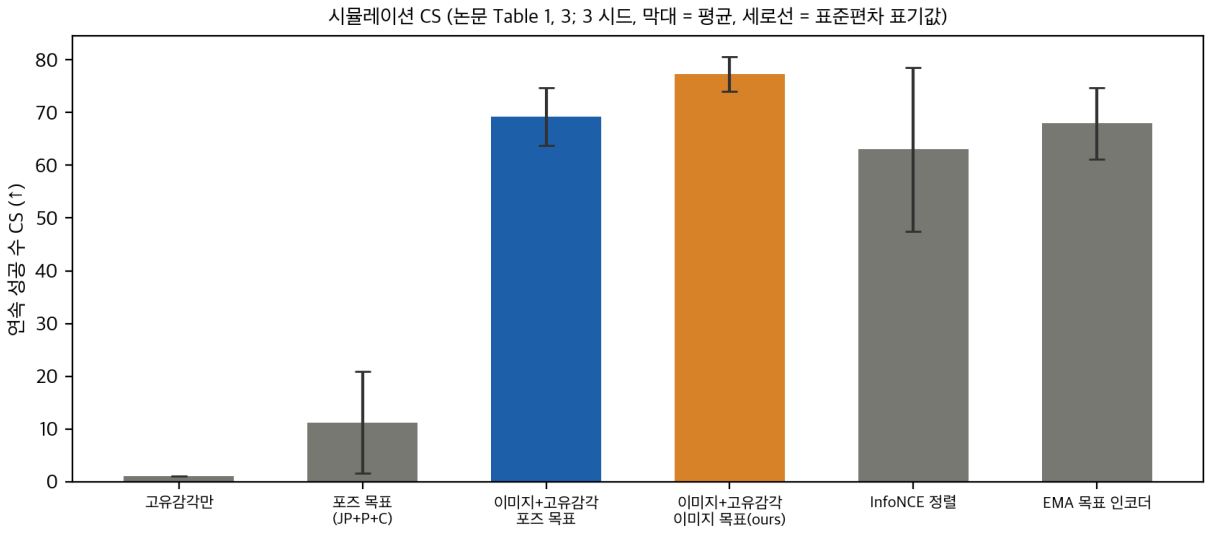
그래프: 실로봇 성공률과 Wilson 95% 구간. 우리가 그린 그래프다.

2. 유의성 검정

방법: 실로봇은 이항 자료라서 Fisher 정확 검정과 Wilson 95% 구간을 씁니다. 시뮬레이션은 시드 3개의 평균과 표준편차이므로 Welch t 검정(표본 표준편차 = 표기값 × √(3/2))을 쓰고, 여러 비교는 Holm으로 보정합니다. 3개 시드는 분산 추정이 불안정하므로 p값은 참고용입니다.

2.1 실로봇 (표 5)

- 이미지 목표 성공 80/100, Wilson 95% **[71.1, 86.7]%**.
- 포즈 기반 기준선 27/100(본문), Wilson 95% [19.3, 36.4]%. 두 비율의 Fisher 검정 $p = 4 \times 10^{-14}$.
- 객체별 성공 수의 이질성: $\chi^2(4) = 4.38$, $p = 0.36$. **객체 간 차이는 n = 20에서 검출되지 않습니다.** 객체별 Wilson 구간은 가장 낮은 Tablet Bottle [43.3, 81.9]%부터 Cube [69.9, 97.2]%까지 겹칩니다. 객체 간 "가장 어렵다"는 주장은 통계적으로 약합니다(Tablet Bottle 대 나머지 Fisher p = 0.11, Holm 0.57).
- 해석: 기준선과의 차이는 확실합니다. 단, 기준선의 프로토콜(목표 분포, 시도 수, 판정 기준)이 같다는 보장은 본문 진술에만 있습니다.



그래프: 논문 표 1, 3의 CS 평균과 표준편차 표기값. 우리가 그린 그래프이며 논문 수치만 쓴다.

2.2 시뮬레이션 (3 시드)

비교	차이 (CS)	Welch t	p (양측)	비고
이미지 목표 대 이미지+고유감각+포즈 목표	**+8.10**	1.80	**0.16**	가장 중요한 비교. 같은 입력이고 목표 표현만 다름. 유의하지 않음
이미지 목표 대 최강 포즈 기준선 (JP+P+C+GP, 11.23)	+66.07	9.18	0.006	포즈 기반 기준선 대비 차이는 큼
연속 대조 대 분리 인코더	+20.31	7.64	0.0036 (Holm 0.015)	유의
연속 대조 대 EMA	+9.35	1.75	0.18 (Holm 0.36)	유의하지 않음
연속 대조 대 공유 인코더	+10.12	2.60	0.065 (Holm 0.20)	유의하지 않음
연속 대조 대 InfoNCE	+14.29	1.28	0.32 (Holm 0.36)	유의하지 않음, InfoNCE의 표준편차 15.51이 큼

- **검정력:** 3 시드에서 차이 8.1 CS를 검출할 확률은 약 0.23입니다(표준편차를 3.25와 5.47로 둔 몬테카를로, `table_check_results.json`의 `power_3seed_CS`). 검정력 0.8에 필요한 차이는 약 20 CS입니다. **본문이 "가장 높은 CS"라고 쓴 이미지 목표 대 포즈 목표의 차이는 이 실험으로는 구별되지 않습니다.**
- 본문의 주장 중 "연속 대조가 CS와 TTS에서 최고"는 분리 인코더에 대해서만 유의합니다. 나머지 대안에 대해서는 방향만 맞습니다.
- 표 2의 동결 인코더와 "시간 메모리 없음"은 차이가 커서 검정이 필요 없습니다. 다만 동결 인코더는 CS 0.00-0.12로 사실상 0입니다.
- 표 4 1x 대 2x: 2x 표준편차가 0이라서 Welch 검정을 쓸 수 없습니다. 차이 31.3 CS는 1x의 표준편차 2.06을 감안하면 방향은 분명합니다.

2.3 실로봇 기준선 판정 불가

- 포즈 기반 기준선 27/100의 시도 기록이 없습니다. 같은 물체 집합에서 목표 분포가 같은지, 판정 시간이 같은지 확인할 수 없습니다. 이 값은 "논문 주장"으로만 씁니다.

3. 목표 표현 비교: 이미지 목표가 실제로 개선한 것

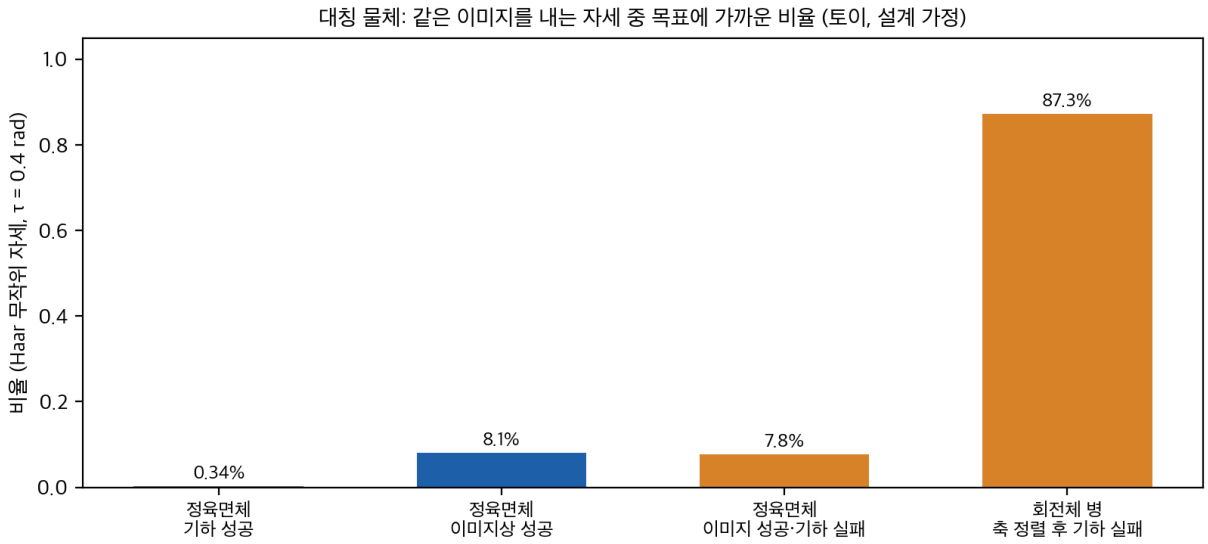
같은 입력(JP+I)에서 목표만 바꾼 비교(표 1, 마지막 두 행):

지표	포즈 목표	이미지 목표	방향
CS ↑	69.20	77.30	개선 (p = 0.16)
TTS (s) ↓	5.17	4.35	개선
F1 ↑	0.923	0.921	차이 없음 (포즈 목표가 조금 높음)
예측 실패율 (%) ↓	8.33	8.80	**이미지 목표가 나쁨**
물체 위치 재구성 오차 (mm) ↓	4.70	4.50	비슷
상대 방향 재구성 오차 (rad) ↓	0.152	0.136	개선

- 이미지 목표의 이득은 **연속 성공 수와 시간**에 한정되고, 성공 판단 품질(F1, 예측 실패율)은 좋아지지 않습니다. 저자는 이 점을 그렇게 강조하지 않습니다.
- 이미지 목표는 "포즈를 주지 않아도 된다"는 장점을 가집니다. 이 장점은 실로봇에서 쓰였지만(§4.5), 시뮬레이션 비교에서 성능 우위는 약합니다.

4. 실로봇 성공 판정 방식이 주는 제약

- 성공은 정책이 성공을 선언하고 오프라인 FoundationPose로 확인한 값으로 정합니다(부록 B.5). 따라서 평가는 포즈 추정기에 기댑니다. 포즈 추정 오차가 크면 "예측 실패"로 잘못 분류될 수 있습니다. 논문은 이 가능성을 다루지 않습니다.
- 예측 실패 12/100은 가장 흔한 실패입니다. 이 실패가 "진짜로 목표에 도달하지 않음"인지 "목표 판정 오류"인지 분리되지 않습니다.



그래프: 대칭 물체 토이. Haar 무작위 자세 40만 개에서 기하 성공과 이미지상 성공을 비교한다. 설계 가정이다.

5. 토이 A: 대칭 물체에서 이미지 목표의 모호성

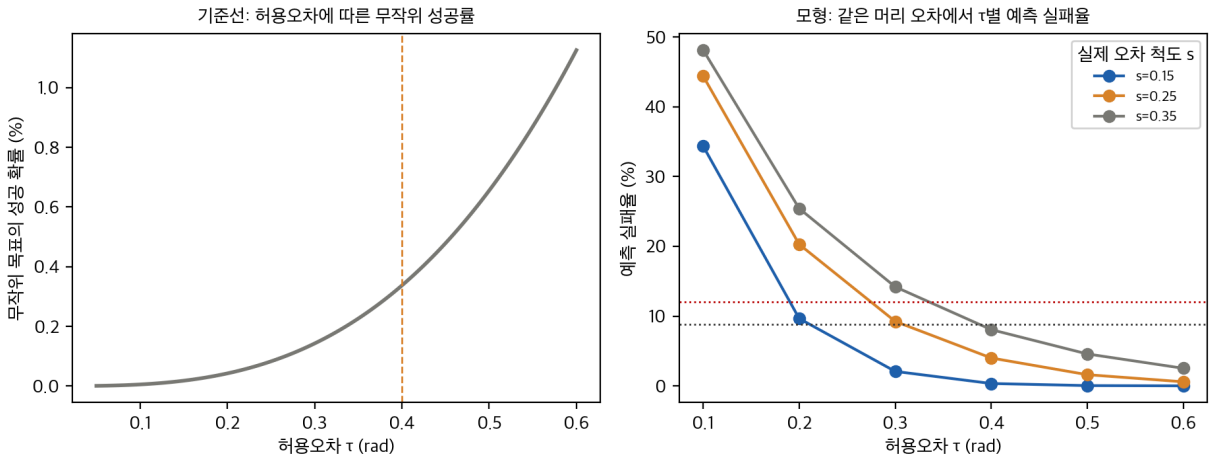
설정(설계 가정): 목표는 항등 자세, 허용오차 τ = 0.4 rad, α = 2.5(부록 표 11). 외형이 대칭군 G에 대해 불변이면 q와 qg(g ∈ G)는 같은 이미지를 낸다. 연속 대조 목표는 기하 거리만 보므로, 같은 이미지에 대한 목표 값이 여러 개 생깁니다. 학습의 최적해는 같은 등가류 안 목표의 평균이고, 평균에서 벗어난 분산이 최소 잡음입니다.

지표 (Haar 무작위 자세, 40만 표본)	값
정육면체(회전군 24) 기하 성공률 P(θ < 0.4)	0.34% (공식 (τ − sin τ)/π = 0.337%와 일치)
정육면체 이미지상 성공률 P(min_g θ(qg) < 0.4)	**8.1%** (기하의 약 23.5배)
정육면체: 이미지로는 성공이지만 기하로는 실패	**7.8%**
정육면체: 등가류 안 s* 분산 / 전체 s* 분산	0.99978 (거의 전부)
회전체 병(z축 대칭): 축 정렬 후 기하 실패율	**87.3%** (스핀 φ가
회전체 병: 등가류 안 s* 분산 / 전체 s* 분산	0.73

해석:

- 대칭이 있으면 이미지 목표는 목표 자세를 정확히 고정하지 못합니다. 정육면체에서 "이미지상 성공"은 "기하 성공"보다 20배 넓습니다. 연속 대조 손실은 이 차이를 학습 목표에 그대로 넣으므로, 정책과 인코더는 이미지만으로는 맞출 수 없는 목표를 받습니다.
- 병처럼 몸체가 회전체이면 이미지는 축 방향만 알려 줍니다. 축이 맞아도 스핀이 0.4 rad보다 크면 평가에서 실패합니다. 무늬가 있으면 스핀이 보일 수 있어 이 한계는 줄어듭니다.
- **주의:** 정육면체 토이는 무늬가 없는 경우의 상한입니다. 논문 그림 5의 Cube는 면에 글자가 있어 대칭 모호성이 작습니다. 그러므로 토이는 "논문이 Tablet Bottle의 어려움을 대칭 기하로 설명하는 방식"을 정량화한 것이며, 실제 물체의 무늬와 대칭은 논문에 없습니다.
- 논문은 Tablet Bottle이 "symmetric geometry"와 "visually ambiguous texture" 때문에 가장 어렵다고 씁니다(§4.5). 토이 결과는 이 설명과 방향이 맞습니다. 하지만 검증은 아닙니다. 물체별 무늬 유무와 대칭 분류가 있어야 확인할 수 있습니다.

그림: `report/figures/own_symmetry.png`.



그래프: 왼쪽은 허용오차별 무작위 성공률, 오른쪽은 가정한 오차 척도에서 허용오차별 예측 실패율이다. 설계 가정이다.

6. 토이 B: 허용오차와 보고된 예측 실패율

1. **무작위 기준선.** Haar 측도에서 $P(\theta < \tau) = (\tau - \sin\tau)/\pi$입니다. $\tau = 0.4$에서 0.34%이고 몬테카를로 0.33%와 맞습니다. 따라서 80% 성공은 기준선보다 약 240배입니다. 다만 "성공"의 의미는 목표 근처에 도달했는지에 달려 있으므로 이 비율 자체는 정책 품질을 말해 주지 않습니다.
2. **예측 실패율 모형.** 실제 최종 오차 $e \sim |N(0, s^2)|$, 예측 머리 $\hat{e} = e + N(0, \sigma_h^2)$. 선언 성공은 $\hat{e} < \tau$, 예측 실패는 $e \geq \tau$인 선언입니다.
   - 논문 PFR을 $\tau = 0.4$에서 재현하려면, $s = 0.15$는 두 값 모두 도달 불가(상한 0.8%)입니다. $s = 0.25$는 시뮬레이션 8.8%에 $\sigma_h > 1$ rad가 필요하고(사실상 무작위 머리), 실로봇 12%는 도달 불가(상한 11.0%)입니다.
   - $s = 0.35$일 때 머리 오차는 $\sigma_h \approx 0.19$ rad(시뮬레이션 8.8%), $\sigma_h \approx 0.30$ rad(실로봇 12%)입니다.
   - **결론(모형 의존):** 논문의 예측 실패율은 머리 잡음만으로는 설명하기 어렵습니다. 최종 오차 분포에 0.4 rad 근처 꼬리가 있어야 합니다. 이는 "허용오차가 여유 있다"는 가정과 어긋날 수 있습니다.
3. **τ에 따른 변화($\sigma_h = 0.17$ rad, 상대 방향 재구성 오차 0.136 rad의 평균 절대 오차를 가우스로 환산):**

s (rad)	τ = 0.2 (선언률 / 예측 실패율)	τ = 0.3	τ = 0.4	τ = 0.5
0.15	0.667 / 9.7%	0.826 / 2.1%	0.924 / 0.3%	0.973 / 0.0%
0.25	0.521 / 20.3%	0.687 / 9.2%	0.815 / 4.0%	0.901 / 1.6%
0.35	0.414 / 25.4%	0.565 / 14.2%	0.697 / 8.1%	0.801 / 4.6%

(표의 각 칸은 τ 열에서 선언률 / 예측 실패율이다. 0.3, 0.4, 0.5 열은 같은 형식.)

- 허용오차를 0.4에서 0.2로 줄이면 예측 실패율이 두 배 이상 뛉니다. 허용오차를 0.5로 늘리면 실패율은 떨어지지만 "성공"의 의미가 약해집니다.
- 따라서 **서로 다른 허용오차(0.4, 0.2, 0.1 등)를 쓴 논문끼리 성공률을 직접 비교할 수 없습니다.** 이 논문도 0.4만 씁니다.

그림: `report/figures/own_tolerance.png`.

7. 주장별 판정 요약 (자세한 표는 `04_claim_verification.md`)

주장	판정
이미지 목표가 포즈 목표보다 CS가 높다 (77.30 대 69.20)	방향은 맞지만 3 시드에서 유의하지 않음 (p = 0.16)

주장	판정
연속 대조가 분리 인코더보다 CS가 높다	유의 (Holm 0.015)
연속 대조가 CS와 TTS에서 최고다	분리 인코더에 대해서만 유의, 나머지는 방향만 맞음
실로봇 80% 대 기준선 27%	이항 검정상 확실. 기준선의 프로토콜은 검증 불가
물체 간 실로봇 차이	통계적으로 검출되지 않음 (p = 0.36)
25개 물체에서 2x 환경이 복구한다	방향은 맞음. 2x 표준편차 0.00은 확인 필요
포즈 추정 오차만으로 격차를 설명할 수 없다	맞음 (오라클 포즈 + 클래스 43.77 < RGB 77.30)
언어 지시 데모	정량 평가 없음, 판정 보류

8. 이 분석의 한계

- 논문 수치는 PDF 렌더링 이미지에서 옮겼습니다. 소수점 자리가 잘못 읽혔을 가능성은 있으나, 행 합계와 교차 표의 일치로 확인했습니다.
- 시뮬레이션 표준편차는 3 시드입니다. 시드 간 변동을 충분히 보지 못합니다.
- 토이는 무늬와 조명을 무시한 설계 가정입니다. 실제 물체의 외형과 판정은 다를 수 있습니다.

추가 검증 (2026-11-13): 목표 정렬 손실 비교 (연속 대조, InfoNCE, 없음)

재현 승인 범위 안에서 한 실험입니다. 자체 작성한 torch와 MuJoCo 코드만 썼습니다. 공식 코드(공개되지 않음), 패키지 설치, GPU, API는 쓰지 않았습니다. 스크립트는 `analysis/extra_goal_alignment.py`, 결과 요약은 `analysis/extra_goal_alignment_results.json`(집계만)입니다. 목표 정렬 보조 손실의 종류만 바꾸고, 같은 데이터, 같은 시드, 같은 학습 예산으로 비교합니다.

가. 설정과 논문과의 차이

- **손 모델(별도 다운로드).** `google-deepmind/mujoco_menagerie`의 `wonik_allegro`(Allegro Hand v3 MJCF)를 씁니다. commit `370c43965323c0944b433b202aac5058b5f907a9`, 라이선스 BSD-3-Clause(SimLab, 폴더의 `LICENSE`), 폴더 크기 2.5 MB입니다. 저장소에는 넣지 않았고, 아래 명령으로 `goaldex/data/menagerie/`에 받습니다(`data/`는 `.gitignore`에 있음).

  ```
  git clone --depth 1 --filter=blob:none --sparse https://github.com/google-
  deepmind/mujoco_menagerie.git goaldex/data/menagerie
  git -C goaldex/data/menagerie sparse-checkout set wonik_allegro
  ```

- **렌더링.** 32×32 RGB, `mujoco.Renderer`(이 세션에서 OpenGL 정상 동작, 대체 렌더러 불필요). 손은 고정된 배경입니다. 손가락 제어와 접촉은 없고, 손가락은 관찰에도 들어가지 않습니다.
- **물체.** 두 종류입니다. (1) 정육면체, 단색, 한 변 0.06 m, 외형이 회전 대칭군 24개에 불변. (2) 비대칭 상자, 0.08×0.05×0.03 m, 면마다 다른 색. 자세는 기구학적으로 설정합니다(`mj_forward`만 호출, 물리 적분 없음).
- **교사(특권).** 진짜 자세 오차를 아는 비례 제어기입니다. 명령은 세계 좌표 회전 벡터이며 이득 0.25, 최대 0.06 rad/스텝이고, 스텝마다 0.01 rad 소음이 더해집니다. 자세는 명령으로 갱신됩니다.
- **학생.** 현재 영상과 목표 영상을 각각 독립 CNN(4층, 16-32-32-32 채널, 128차원)으로 인코딩합니다(분리 인코더). 정책 헤드는 MLP 256-256-3(tanh)이며 교사 명령을 행동 복제합니다(MSE, 명령을 MAXSTEP로 정규화). 재구성 헤드, GRU, 성공 예측 헤드는 없습니다.

- **보조 손실(세 팔, 계수 모두 0.1).** 없음. 연속 대조 `MSE(s*, cos)`, `s* = exp(−2.5 θ)` (논문 Table 11의 α와 λ). InfoNCE: 같은 배치 안에서 (현재, 목표) 쌍의 측지 각이 0.4 rad 아래이면 양성, 온도 0.1. **논문은 InfoNCE의 온도를 주지 않습니다. 0.1은 이 비교의 선택값입니다.**
- **데이터.** 교사 궤적 400개(시작과 목표 무작위, 60 스텝), 고정 시드 0입니다. 두 물체가 같은 자세 집합을 씁니다. 학습 쌍은 같은 궤적의 미래 상태(40%), 에피소드 목표(30%), 무작위 상태(30%)에서 뽑습니다. 학습은 2000 스텝, 배치 128, Adam 학습률 1e-3입니다. DAgger는 쓰지 않았습니다.
- **평가.** 학습에 쓰지 않은 무작위 목표 16 에피소드, 에피소드당 200 스텝입니다. 모든 팔이 같은 평가 에피소드와 소음을 씁니다. 도달은 측지 각 < 0.4 rad가 3스텝 연속일 때이며, 도달하면 새 목표를 뽑습니다. CS는 에피소드당 도달 횟수이고, TTS는 첫 도달 스텝입니다(도달한 에피소드의 평균).
- **시드.** 5개입니다. 시드는 가중치 초기화와 배치 추출만 바꿉니다. 통계는 표본 표준편차(ddof = 1)이며, 검정은 Welch t와 쌍체 t, 세 비교에 Holm 보정을 씁니다.
- **논문과 직접 비교할 수 없는 점.** 물리와 접촉이 없고, 고유감각, GRU, 재구성, DAgger, 3DGS 렌더링이 없습니다. 목표 이미지는 같은 렌더러로 만든 무작위 자세입니다. CS 척도도 다릅니다. 교사 CS는 5.5(논문 교사 122.96), 명령 0인 정책은 0.0입니다. 절대 수준이 아니라 팔 사이 차이만 읽어야 합니다.

나. 결과: CS (에피소드당 도달 횟수), 5 시드

물체	손실	CS 평균 ± sd	시드별 CS	TTS (스텝, 도달 에피소드 평균)
비대칭 상자	없음	0.39 ± 0.25	0.8, 0.4, 0.2, 0.2, 0.3	84.4
비대칭 상자	InfoNCE	**3.10 ± 0.45**	3.6, 2.9, 3.5, 2.9, 2.6	57.5
비대칭 상자	연속 대조	1.71 ± 0.61	1.9, 1.4, 2.3, 2.1, 0.8	73.1
정육면체	없음	0.00 ± 0.00	0, 0, 0, 0, 0	-
정육면체	InfoNCE	0.03 ± 0.03	0.1, 0, 0, 0.1, 0	89.5 (도달 1-2개 에피소드)
정육면체	연속 대조	0.01 ± 0.03	0, 0, 0.1, 0, 0	116.0 (도달 1개 에피소드)

참조: 교사 CS 5.5, 명령 0 CS 0.0(두 물체 모두).

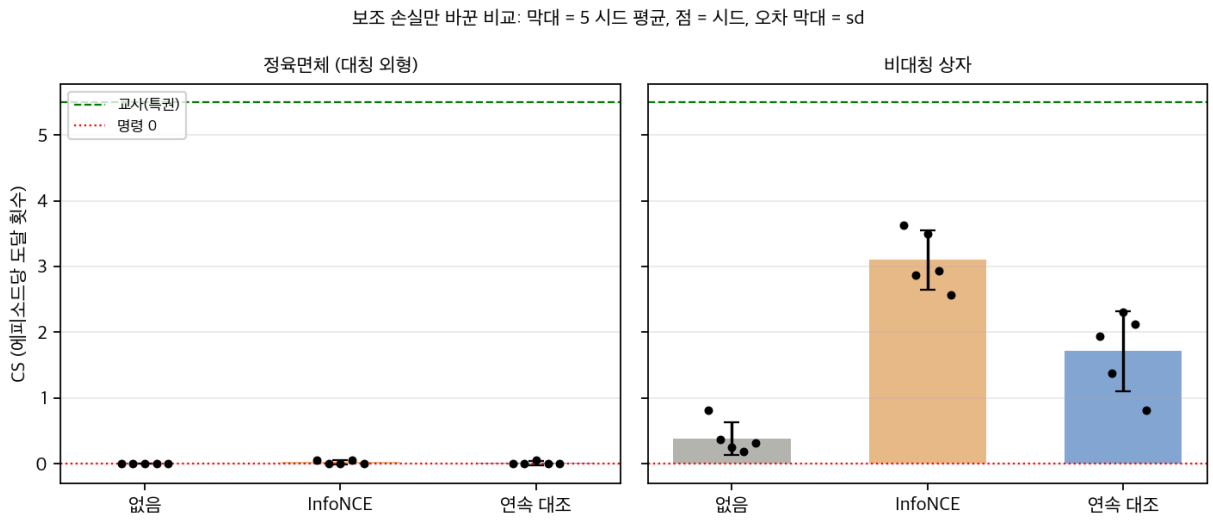
검정(CS):

- **비대칭 상자.** 연속 대조 − InfoNCE = −1.39 (Welch t = −4.09, p = 0.004, Holm 0.009; 쌍체 t = −7.98, p = 0.001). 연속 대조 − 없음 = +1.33 (Welch p = 0.006, Holm 0.009; 쌍체 p = 0.011). InfoNCE − 없음 = +2.71 (Welch p < 0.001).
- **정육면체.** 세 쌍 모두 Welch p ≥ 0.18(Holm ≥ 0.53)입니다. 전 팔이 바닥 근처라서 차이를 판정할 수 없습니다.
- **검출력.** 5 시드, 80%, 합동 sd 기준 검출 가능한 차이는 비대칭 약 0.9 CS입니다. 논문 Table 3의 차이(+14.29)보다 작습니다.

임베딩 진단(무작위 자세 쌍 400개, 5 시드 평균과 sd는 `results.json`):

물체	손실	r(cos, θ)	Spearman ρ	r(cos, s*)	평균 |cos − s*|	등가 상태의 정지 비율	등가 상태의 평균 cos
비대칭	없음	-0.01	-0.01	0.00	0.079	0.04	-0.01
비대칭	InfoNCE	-0.66	-0.58	0.61	0.167	0.03	0.01
비대칭	연속 대조	-0.71	-0.65	0.55	0.151	0.04	0.06
정육면체	없음	-0.01	-0.01	-0.01	0.075	0.49	0.02
정육면체	InfoNCE	0.00	-0.01	0.05	0.213	0.67	0.88
정육면체	연속 대조	-0.03	-0.03	0.08	0.173	0.63	0.71

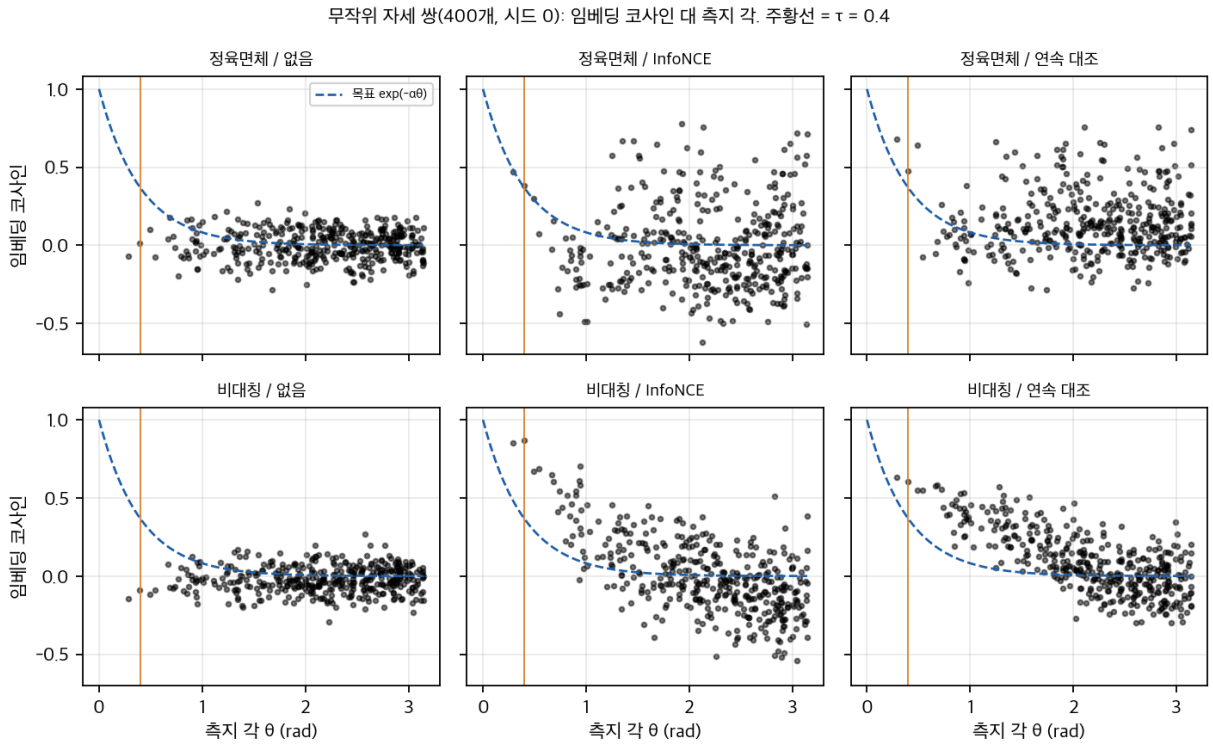
"등가 상태"는 `q_goal ⊗ g` (g는 정육면체 회전군의 원소, 목표와의 각도 > 0.4 rad)입니다. 정육면체에서는 영상이 거의 같습니다(평균 픽셀 차 0.04/255, 33%는 완전히 같음). 비대칭 상자에서는 영상이 다릅니다(평균 픽셀 차 41/255). "정지 비율"은 학생 명령 크기가 0.2 × MAXSTEP보다 작은 상태의 비율입니다.



그래프: 손실 종류별 CS. 비대칭 상자와 정육면체, 5 시드. 막대는 평균, 점은 시드, 오차 막대는 표본 표준편차. 설계 가정의 소규모 실험이다.

다. 임베딩 진단

- 비대칭 상자에서 임베딩 코사인은 각도와 음의 상관을 가집니다. 보조 손실이 있으면 상관이 -0.6--0.7로 강해지고, 없으면 0입니다. 연속 대조 쪽이 각도 상관이 더 강하고 s*와의 평균 오차도 작습니다(0.151 대 0.167).
- 정육면체에서는 상관이 어느 팔에서도 생기지 않았습니다. 학습이 자세 정보를 잡지 못했습니다.
- 정육면체의 등가 상태에서 보조 손실을 쓴 팔은 코사인이 0.7-0.9인데 목표 s*는 0.007입니다. 같은 영상 쌍에 서로 다른 목표가 주어지면 임베딩이 평균을 취한다는 03 §5의 예측과 방향이 맞습니다. 다만 없음 팔도 정지 비율이 0.49로 높아서, 이 수치만으로 대칭 모호성의 효과를 분리하지 못합니다.



그래프: 무작위 자세 쌍 400개(시드 0)에서 임베딩 코사인과 측지 각. 파란 곡선은 목표 exp(−2.5θ), 주황 선은 τ = 0.4. 설계 가정의 소규모 실험이다.

라. 해석: 표 3과 비교

- **표 3의 방향은 이 설정에서 재현되지 않았습니다.** 논문은 연속 대조가 InfoNCE보다 CS가 +14.29 높다고 씁니다($p = 0.32$). 비대칭 상자에서는 반대 방향입니다. InfoNCE가 1.39 CS 높고, Holm 보정 후에도 $p = 0.009$입니다.
- **하지만 이것이 "InfoNCE가 더 낫다"는 뜻은 아닙니다.** 두 손실의 기울기 크기를 맞추지 않았습니다. InfoNCE 손실은 log-sum-exp 값이라 배치 128에서 수 단위인 반면, MSE 손실은 0-1입니다. 같은 계수 0.1이라도 두 팔의 실제 강도가 다릅니다. 온도 0.1과 계수 0.1을 바꾸는 민감도 실험은 하지 않았습니다. 따라서 이 결과는 "손실 강도와 InfoNCE 정의에 따라 순위가 바뀐다"는 것까지만 말합니다.
- **두 보조 손실은 모두 없음보다 낫습니다**(비대칭, 두 쌍 모두 Holm $p \le 0.009$). 정렬이 도움이 된다는 방향은 논문과 같습니다. 크기는 다릅니다.
- **임베딩 기하와 제어가 어긋납니다.** 연속 대조는 기하 진단에서 더 나은데 CS는 더 낮습니다. 임베딩이 자세 각도에 맞춰지는 것만으로는 제어가 좋아지지 않았습니다.
- **정육면체는 판정할 수 없습니다.** 세 팔 모두 바닥($CS \le 0.03$)이라 대칭 외형이 학습을 막는지 보여 주지 못합니다. 32 px 해상도와 짧은 학습(2000 스텝)이 원인일 수 있습니다. 확인하지 않았습니다.

마. 한계

- 물리와 접촉이 없습니다. 목표 정렬이 이미지만으로 자세를 맞추는지를 보는 것이며, 접촉 제어 성능은 보지 않았습니다.
- 손실 계수, InfoNCE 온도, 학습 길이, 인코더 크기의 민감도를 확인하지 않았습니다.
- 시드 5개, 평가 16 에피소드입니다. 검출 가능한 차이가 0.9 CS라서 작은 차이는 가려집니다.
- CS 척도가 낮은 구간(1-3)에 있어서, 상대 차이(예: 3.1 대 1.7)는 과장되기 쉽습니다.
- 교사와 학생의 구조, 관찰, 목표 생성이 논문과 다릅니다(위 가 절). 따라서 논문 수치의 재현이 아니라 손실 비교의 소규모 점검입니다.

04. 주장 검증과 구현 가능성 (공식 코드 없음)

공식 코드가 아직 공개되지 않아 `04_code_verification.md` 는 만들지 않았습니다. 대신 논문의 주장을 표와 재계산, 토이로 검증합니다. 코드가 나오면 그때 대조합니다(§0).

0. 코드 상태

- 프로젝트 페이지(확인 2026-11-12): 버튼 "Code soon". 공식 저장소 링크는 없습니다.
- GitHub: `leggedrobotics` 조직에 goaldex 저장소가 없습니다(404). 이름이 같은 세 저장소는 무관합니다(`02` §5).
- 따라서 저장소를 clone하지 않았고, 코드를 실행하지 않았습니다.

1. 주장별 판정

판정: **지지**(수치로 확인), **부분**(방향만 맞거나 일부만 확인), **유의 없음**(방향은 맞으나 통계적 근거 부족), **미검증**(논문에 수치나 절차가 없음), **의심**(수치 내부 불일치 또는 설명이 부족).

ID	주장	위치	판정	근거
C1	이미지 목표 정책은 포즈 기반 방법과 사전 학습 인코더 정책보다 시뮬레이션에서 일관되게 낫다	초록, §4.1-4.2	**지지** (크기는 큼)	표 1: CS 77.30 대 포즈 기준선 최고 11.23, 동결 인코더 0.00-0.12 (`03` §1-§2)
C2	같은 입력에서 이미지 목표가 포즈 목표보다 CS가 높다	§4.1	**유의 없음**	77.30 대 69.20, Welch p = 0.16, 3 시드 검정력 0.23 (`03` §2.2)
C3	이미지 목표는 성공 판단 품질을 높인다	암시	**의심**	예측 실패율 8.80 대 8.33(이미지 목표가 나쁨), F1 0.921 대 0.923 (`03` §3)
C4	연속 대조가 CS와 TTS에서 최고다	§4.3	**부분**	분리 인코더에 대해서만 유의(Holm 0.015). EMA, 공유, InfoNCE 대비는 유의 없음 (`03` §2.2). (2026-11-13 추가) 손 모델 소규모 실험(비대칭 상자, 5 시드)에서는 연속 대조가 InfoNCE보다 CS가 낮음(–1.39, Holm 0.009), 방향이 반대. 손실 강도를 맞추지 않은 설정이라 순위 판정은 아님 (`03` 추가 검증)
C5	연속 대조 목표는 "기하 연속성"으로 진행 신호를 준다 (설명)	§3.4, §4.3	**미검증**	설명만 있음. 대칭 물체에서는 목표가 이미지와 맞지 않는다는 점이 토이에서 확인됨 (`03` §5)
C6	실로봇 5개 물체에서 100회 중 80회 성공	§4.5, 표 5	**지지**	표 5 합계 80, 객체별 합 일치. Wilson 95% [71.1, 86.7]
C7	같은 프로토콜의 포즈 기반 최강 기준선은 100회 중 27회	§4.5	**미검증**	표와 기록 없음. 프로토콜 동일성 확인 불가 (`03` §2.3)
C8	실로봇 성능은 물체에 따라 다르며, Tablet Bottle이 가장 어렵다	§4.5	**부분**	13/20이 최저이나 객체 간 차이는 χ^2 p = 0.36. 대칭 기하, 낮은 마찰, 모호한 질감은 원인으로 제시만 됨
C9	실패의 주된 원인은 예측 실패다	§4.5	**지지**	12 대 낙하 4, 시간 초과 4
C10	포즈 추정 오차만으로는 격차를 설명할 수 없다 (오라클 포즈가 RGB 정책보다 낮음)	§4.1, 부록 A.1	**지지 (부분)**	오라클 포즈 22.49, 오라클 포즈 + 클래스 43.77 < 77.30. 하지만 학습된 포즈 + 클래스(11.23)와 오라클 + 클래스(43.77) 사이 약 32 CS 차이는 추정 오차 몫입니다 (`01` §3.9)
C11	포즈 추정기는 6.8 mm, 0.25 rad 수준으로 정확하다	§4.1, 부록 A.3	**지지**	표 7: 6.76 mm, 0.245 rad (교사 롤아웃)

ID	주장	위치	판정	근거
C12	표 1의 포즈 재구성 오차는 추정기 실패가 아니라 정책 재구성 헤드의 오차다	§4.1	**의심**	포즈 기반 정책의 재구성 방향 오차 1.17 rad(JP+P+GP)이 추정기 입력 오차 0.25 rad보다 훨씬 큼. 헤드가 입력과 다른 신념을 만든다는 설명은 가능하나, 검증 실험이 없음
C13	재구성 보조 손실을 빼면 정책이 완전히 실패한다	§4.2	**미검증**	본문에만 있음. 표 2에 해당 행 없음
C14	시간 메모리와 시각 메모리가 모두 필요하다	§4.2	**지지**	시간 메모리 없음 38.64, 시각 메모리 없음 47.83 대 77.30 (시드 간 표준편차 1.9–9.1, 방향 확실)
C15	동결 사전 학습 인코더(ImageNet, DINOv2, Depth Anything V2)는 상호작용 정보를 담지 못한다	§4.2	**지지**	CS 0.00–0.12, 예측 실패율 97–100%
C16	25개 물체에서 학생은 2x 병렬 환경으로 성능을 회복한다	§4.4	**부분**	1x 10.11 대 2x 41.42 (교사 110.84). 2x 표준편차 0.00은 이상 (`03` §1)
C17	학생은 시뮬레이션에서 교사 성능의 약 63%에 도달한다 (5개 물체)	부록 A.1	**지지**	77.30 / 122.96 = 0.629
C18	목표 이미지로 VLM이 고른 목표를 실행할 수 있다	§4.6, 그림 4	**미검증**	정성 그림 세 장. 시도 수와 성공 수가 없음
C19	한 정책이 다섯 실물 물체에 zero-shot으로 전이된다	초록, §4.5	**지지 (범위 한정)**	표 5. 다만 목표 이미지가 메시 렌더링이고(부록 B.5), 물체 마스크를 쓰며, 시도 기록이 없음
C20	목표 이미지는 물체 메시를 샘플된 자세로 렌더링한 것이다	부록 B.5	**지지 (한계)**	실로봇 목표 영상의 도메인이 학습 렌더링과 같은지 보이지 않음
C21	성공은 정책이 예측한 성공이 실제 오차 0.4 rad 이하일 때 맞다 (실로봇은 FoundationPose 오프라인 확인)	§4, 부록 B.5	**지지 (절차 확인)**	판정이 포즈 추정에 의존함을 확인 (`01` §5)
C22	객체 스케일은 U(0.5, 1.5)로 넓혔다 (ViserDex의 0.95–1.05 대비)	§3.4	**지지 (설정 기술)**	설정 기술이며 효과는 분리되지 않음
C23	학생 한 정책은 H100 두 장에서 약 30시간	부록 B.3	**미검증**	설정 기술. 재현 시 예산 추정용

2. 수치 재계산 요약

- 표준편차 규칙(ddof=0)은 Table 5로 확인했습니다. 나머지 표는 같은 규칙으로 읽었습니다(가정).
- 같은 행이 Table 1, 2, 3에서 일치합니다.
- 교사 값은 그림 5, 표 4, 표 6이 서로 맞습니다(122.96, 110.84).
- 자세한 결과와 검정은 `03_analysis.md` 를 봅니다.

3. 저자에게 확인할 점

재현에 필요하고 논문에 없는 정보입니다. 발송은 하지 않습니다(사용자 결정 사항).

1. 표 4 2x 행과 표 6의 몇몇 행에서 표준편차가 0.00입니다. 시드 수와 집계 방식을 확인합니다.

2. 포즈 기반 기준선 27/100의 시도 기록, 목표 자세 분포, 판정 시간 제한이 같은지 확인합니다.
3. "CS"의 정확한 정의: 에피소드 안 연속 성공을 세는지, 시간 제한이 있는지, 128 에피소드를 어떻게 평균하는지.
4. 표 1의 포즈 기반 재구성 방향 오차(1.17 rad)와 추정기 입력 오차(0.25 rad)의 차이를 설명할 자료.
5. 대칭 물체(Tablet Bottle, Cube)의 외형 무늬와 대칭 분류. 목표 이미지가 같은 외형에서 여러 자세를 낼 때 학습 목표를 어떻게 처리하는지.
6. 실로봇 목표 이미지 생성(메시 렌더링의 조명, 질감, 마스크)과 학습 영상(3DGS)의 도메인 차이를 줄였는지.
7. 허용오차 0.4 rad를 고른 이유와, 다른 허용오차에서의 예측 실패율.

4. 구현 가능성 판정

경로	판정	근거와 필요 자원
공식 재현 (코드 공개 후)	**이 맥에서는 불가.** NVIDIA GPU가 있는 리눅스에서는 노력이 크고 조건부	코드가 "Code soon"이라 아직 없음. Isaac Sim과 Isaac Lab은 NVIDIA GPU가 필요하고 맥에서 돌지 않음. 학습은 H100 두 장에서 한 정책 약 30시간(부록 B.3), 25개 물체는 GPU 네 장(부록 B.3). 3DGS 렌더링은 ViserDex [2] 파이프라인과 자산이 필요. 마스크는 SAM2 미세조정이 필요. 실로봇은 Allegro 16-DOF 손, RealSense D435i, 30 Hz 정책, 300 Hz PD 제어
재구현 (아이디어만)	**조건부.** 구조 자체는 중간 노력	구조(ResNet 두 개, GRU, 재구성 MLP, 연속 대조)는 수백 줄. 병목은 (a) 다물체 3DGS 렌더링 (b) 교사 학습 (c) 학생 증류. 이 맥(MPS)은 CUDA가 아니므로 대규모 학습은 제외
CPU 토이 (이번 분석)	**가능, 완료**	대칭 모호성, 허용오차, 손실 잡음을 numpy로 검증(`03` §5-§6)
실로봇 재현	**불가 (이 저장소 범위 밖)**	Allegro, RealSense, 실험실 설정 필요

한 줄: 이 맥에서 GoalDex를 재현하는 것은 불가능합니다. 공식 코드가 나오고 NVIDIA GPU 리눅스 환경이 준비되면, 시뮬레이션 5개 물체 실험은 "중간 이상의 노력, 수일에서 수주"로 추정합니다(추정, 근거 부족).

5. 라이선스와 공개 범위

- **arXiv abs 페이지 라이선스: CC BY-NC-ND 4.0** (확인 2026-11-12). CC BY가 아니므로 논문 그림은 개인용 리포트와 PPT에만 넣고, 공개본에는 넣지 않습니다.
- **PDF 1쪽 고지:** arXiv 스탬프(`arXiv:2611.02171v1 [cs.RO] 1 Nov 2026`)와 CoRL 2026 표기만 있습니다. "©"나 재인쇄 허락 문구는 없습니다. 원문 PDF 자체에는 "IEEE" 같은 문구도 없습니다.
- 공개 문서(01-04)는 논문의 수치를 인용하고 해석합니다. 그림과 문장을 옮기지 않았습니다.
- 원문 PDF는 14.1 MB라 25 MB 기준 미만입니다. `.gitignore`에 넣지 않습니다. 재다운로드 명령은 README에 적습니다.