GR00T 2 백서 (NVIDIA, 2026-11): 분석 리포트

게시용 버전: 백서 원문(https://research.nvidia.com/labs/gear/gr00t-2/assets/gr00t2_whitepaper.pdf, 프로젝트 https://research.nvidia.com/labs/gear/gr00t-2/)과 백서 그림은 저작권 표기 때문에 싣지 않았습니다. NVIDIA 기술 백서(2026년 11월, arXiv 없음, 135쪽, 동료 심사 없음) · 원문 확인일 2026-11-12 · 프로젝트 페이지 상태: "Code Available in December" · 저작권 "© 2026 NVIDIA. All rights reserved."이므로 백서 그림은 싣지 않음

핵심 요약

1. **무엇인가:** GR00T 2는 Cosmos-Predict2.5-2B 비디오 확산 트랜스포머로 미래 영상과 로봇 행동을 한 시퀀스에서 함께 flow matching으로 예측하는 세계-행동 모델(WAM)이다. 사람 영상 402k 시간, UMI 10k 시간, 원격조작 23.5k 시간을 섞어 1,024장의 GB300에서 사전학습했다(Sec. 2, 4.1, 4.2).
2. **숫자는 대부분 맞다:** 표 1, 3, 11, 12, 27의 평균·합계·배율을 모두 다시 계산해 일치했다. 다만 Dexter 트럭 과제의 쉬운 장면 값(65%, 원래 장면은 35%)이 평균을 4.3%p 올린다(`03` §1).
3. **작은 차이는 근거가 약하다:** 과제당 20회로는 20%p 차이를 4번 중 3번 놓친다. Turbo와 GR00T 2의 YAM 차이(6.7%p)는 구분되지 않는다. 시뮬레이션 데이터 실험(H.3)은 p = 0.12다(`03` §2.2, §2.4, §4.1).
4. **"80% 승률"은 동점을 뺀 값:** π0.5 대비 Elo +236의 기대 승률 80%는 동점 35%를 뺀 승부 기준이다. 엄격한 승률은 약 52%다(`03` §2.6).
5. **계산 자원은 빠져 있다:** 스텝 수, 총 GPU 시간, MFU를 보고하지 않는다. 1,024장과 데이터 시간으로 본 계산량은 가정에 따라 크게 달라진다(`03` §3).
6. **공개 상태:** 가중치와 코드가 없다(HF에 GR00T 2 저장소 없음, 프로젝트 페이지 "Code Available in December"). 표 13 주석의 "released checkpoint"와 맞지 않는다(`02` §4, `04` C21).
7. **이 맥에서 구현할 수 있나: 지금은 불가**(가중치·코드 미공개). 공개 후에도 추론은 조건부(메모리는 되지만 CUDA 전용 최적화 경로, 추정 지연 1.5-4 s), 미세조정은 비추천, 사전학습과 아레나 재현은 불가다(`04` §4).

구현 판정 상세: 04 §4. 재계산 상세: 03.

01. GROOT 2 백서 분석: 초록에서 실험까지

GROOT 2: Scaling Robot Foundation Models for Generalization, Dexterity, and Adaptation (NVIDIA, 2026년 11월, arXiv 없음, 135쪽). 원문은 `paper/paper.pdf` (23.5 MB, 저작권 표기 "© 2026 NVIDIA. All rights reserved.")이고, 인용은 백서의 절(Sec.), 표(Tab.), 그림(Fig.) 번호로 합니다. 백서 본문은 `paper/paper.txt` 에서 확인했습니다.

1. 한 문장 요약

GROOT 2는 **비디오 확산 트랜스포머(Cosmos-Predict2.5-2B)를 그대로 가져와, 미래 영상과 로봇 행동을 한 시퀀스에서 함께 flow matching으로 예측하는 세계-행동 모델(world-action model, WAM)**입니다. 사람 영상(Human-1M 402k 시간), UMI 기구 시연(10k 시간), 원격조작 데이터(23.5k 시간)를 한 모델에 섞어 사전학습하고, 실물 강화학습과 프론티어 에이전트 연동을 더했습니다(Sec. 1, Sec. 2).

2. 초록(서론)의 주장 네 가지

백서의 서론(Sec. 1)은 네 가지 진전을 내세웁니다.

1. **초기 성능:** 여러 조작 과제에서 바로 쓸 만하다. 근거는 Tab. 1(YAM 장기 과제 6개, Dexter 장기 과제 7개)과 Tab. 2-3(제로샷 평가).
2. **빠른 적응:** 처음 보는 과제를 몇 번의 시연으로 익힌다. 근거는 Fig. 2(Dexter-50 제로샷 40%, 1회 시연 71%, 5회 95%)와 Sec. 3.1.
3. **X-적응(교차 적응):** 사람 영상, UMI, 글러브 시연으로 로봇 원격조작 없이 새 기술을 배운다. 근거는 Sec. 3.2와 App. B.
4. **에이전트 제어:** 추론 모델(프론티어 에이전트)이 GROOT 2를 도구처럼 호출해 긴 과제를 조합하고 복구한다. 근거는 Sec. 3.4, App. G.

추가로 **GROOT 2 Turbo**(더 작은 시각 잠재 표현을 쓰는 변형)를 소개하고, 휴머노이드 전신 제어에 쓴다(Sec. 2, Sec. 3.5).

3. 방법

3.1 구조 (Sec. 2 "Architecture")

구성 요소	백서의 설명	비고
백본	Cosmos-Predict2.5-2B, "video diffusion transformer", 2B 파라미터 한 개	시각·행동·상태 토큰을 한 시퀀스에 넣음
영상 인코더	Wan 2.1 VAE, 동결. 시간 4배, 공간 8배 압축	카메라 한 대 224×320, 프레임당 280 토큰
언어	Cosmos-Reason1 VLM, 동결. 교차 주의로 읽음	크기는 백서에 없음
상태·행동	임베디드먼트별 작은 MLP 입출력	행동은 "노이즈가 섞인 행동 청크"로 입력
학습 목표	flow matching, 영상과 행동에 각각 손실	사람 영상은 손 자세 궤적을 행동 감독으로 씀(Sec. 4.1)
추론	영상 1-2 단계, 행동 2-4 단계 데노이징	"2v4a" 같은 표기(Tab. 27 주석)
입력	0.8초 이력, 5 fps, 카메라 최대 4대	머리 1대 + 손목 2대가 전형 (Sec. 2)

Turbo는 같은 2B 트랜스포머에 Wan 2.2 VAE(공간 16배)를 써서 시각 토큰을 줄인 변형입니다(Sec. 2). 백서가 밝힌 Turbo 구조 차이는 VAE 하나와 입출력 투영뿐입니다.

3.2 학습 단계 (Sec. 4.1)

- **1단계 단일 시점 영상 사전학습:** 한 카메라 시점만으로 미래 영상을 예측해 물리 동역학 사전 지식을 얻습니다.
- **2단계 다시점 영상-행동 공동 학습:** 임베디드먼트별 상태·행동 모듈을 붙이고, 사람 영상은 손 자세를 행동 대리 감독으로 씁니다.
- **3단계 로봇 가중 공동 학습:** YAM과 손 로봇 데이터의 비중을 높입니다.
- **사후학습:** SFT 뒤 실물 GRPO 변형(CPS 샘플링, 자기 모방)과 잔차 RL을 적용합니다(Sec. 3.3). 시뮬레이션 RL은 DreamDojo 세계 모델을 씁니다(Sec. F.5).
- 레시피 기저는 "AutoRL"이라는 연구 에이전트가 시뮬레이션에서 약 35일 동안 찾았다고 합니다(Sec. 4.1, F.2).

3.3 데이터 (Sec. 4.2, App. C)

출처	규모 (백서)	역할
Human-1M 필터 사람 영상	402,730 시간, 약 1,375만 에피소드	행동 없는 영상 학습 + 손 자세 감독
스튜디오 사람 영상	3,000 시간	로봇과 맞춘 시점, 같은 속도
UMI-10K (손에 든 그리퍼)	10,184 시간, 94.2만 에피소드	로봇 행동 표현으로 바뀐 시연
원격조작	23.5k 시간, 116만 에피소드	YAM 18.7k, Sharpa 2.9k, Wuji 1.3k, G1 275 시간, DROID 350 시간 (Tab. 11)

Tab. 11의 샘플 비중은 YAM 51.2%, ABC-130k 10.4%, Sharpa 20.6%, Wuji 14.0%, G1 1.3%, DROID 2.5%로 시간 비중과 다릅니다. 즉 샘플링 가중치로 균형을 맞춘 것입니다. 주석은 Flora(자체 데이터 엔진)가 달았고, WGO-Bench 시간 분할 F1 50.3으로 GPT-6 Astra(46.0)보다 높다고 보고합니다(Sec. 4.2.4).

3.4 학습 인프라 (Sec. 4.7, App. K)

- 사전학습은 **GB300 NVL72 1,024장**에서 했습니다. 전체 클러스터는 2,016장입니다(Sec. 4.7.1, K.2.1).
- DeepSpeed ZeRO-2, BF16, GPU당 배치 16. 총 학습 스텝, 소요 시간, 총 GPU 시간은 **보고하지 않습니다.** MFU·OFU 수치도 없습니다.
- 데이터 로더는 LanceDS 형식으로 25개 저장소, 1,560만 에피소드, 462억 시간 단계를 읽고, 1,024장에서 약 12,000 샘플 창/초를 공급했다고 합니다(Tab. 35).

4. 실험과 평가

4.1 실물 평가 설계

백서는 두 종류의 평가를 씁니다.

- **고정 과제 표(Tab. 1-6):** 과제마다 시도를 적게(대개 10-20회) 하고 성공률과 진행률을 보고합니다. Tab. 1a(YAM 장기 6개, 과제당 최대 20회), Tab. 1b(Dexter 장기 7개, 시도 수 미기재), Tab. 2(YAM V2 제로샷, 시도 수가 과제·모델마다 다름), Tab. 3(Dexter 제로샷 71과제 × 3회).
- **블라인드 A/B 아레나(Sec. 4.3, App. D):** 같은 장면에서 체크포인트 2-4개를 무작위 순서로 돌리고, 작업자가 순위를 매깁니다. Bradley-Terry Elo를 쌍 부트스트랩(과제 단위 재표본)으로 구간 추정합니다. 공개 데이터는 없고 표 12와 13의 집계만 있습니다.

4.2 주요 결과 (백서 수치)

주장	백서 수치	근거
YAM 장기 6과제 평균 성공률	GR00T 2 71.7%, Turbo 65.0%, π0.5 12.5%, GR00T 1.7 8.3%	Tab. 1a
Dexter 장기 7과제 평균 성공률	GR00T 2 68.6%, Turbo 34.3%, GR00T 1.7 0.7%, π0.5 0.0%	Tab. 1b
Dexter 제로샷 71과제	GR00T 2 49.8%, Turbo 36.6%, π0.5 26.3%, GR00T 1.7 18.3%	Tab. 3
사람 영상 사전학습 비율(0→100%)	Dexter 실물 성공률 18%→41%	Fig. 10
블라인드 Elo	대 π0.5 +236 [171, 325], 대 GR00T 1.7 +95 [50, 148]	Tab. 13
시뮬레이션 벤치마크	RoboCasa365 67.2%(VLA·WAM 중 최고), 에이전트 포함 88.0%; RoboDojo 에이전트 포함 75.8%	Tab. 19, Tab. 30
추론 지연	Dexter 153 ms(RTX 5090), G1 Turbo 38 ms(RTX 5090) / 124 ms(Jetson Thor)	Tab. 27, Fig. 19

4.3 시뮬레이션과 실물의 관계

- 25개 YAM 과제에서 14개 체크포인트의 시뮬레이션 성능과 실물 성능의 Pearson 상관은 진행률 0.93, 성공률 0.92, Elo 0.93입니다(Sec. 4.5.2).
- 사람 영상 데이터 비율을 바꾼 실험(Fig. 10)은 실물 72과제(과제당 3회)에서 측정했습니다.

4.4 에이전트 실험 (Sec. 3.4, App. G)

- 에이전트(System 2)가 계획과 검증을 맡고, GR00T 2를 도구로 호출합니다.
- 실물 장기 조립 3개는 "사람이 부품을 무작위로 쏟은" 시작 상태에서 100회씩 평가했습니다(Fig. 7). 사람이 도운 시도는 실패로 셉니다.
- 시뮬레이션 리더보드에서는 개발 시드(15-30)로 실행기를 고르고 시험 시드(50)로 보고합니다(App. G.1).

5. 한계 (백서가 스스로 밝힌 것)

백서 결론(Sec. 5)은 다음 열린 문제를 적습니다.

- **예측 대상:** 미래 영상의 어떤 부분을 예측해야 하는지 모릅니다. Turbo는 잠재 격자가 4배 작은데 Dexter 장기 과제 성공률이 68.6%에서 34.3%로 떨어졌습니다(Sec. 5).
- **확장 법칙:** 모델 크기, 데이터, 계산량에 따른 WAM의 확장 법칙을 모른다고 합니다.
- **평가:** 실물 성공률은 이항 추정이라 "95%와 99%를 가르려면 과제당 약 285회"가 필요하다고 씁니다(Sec. 5, 각주 1). 백서의 과제당 20회로는 큰 차이만 잡힙니다.
- **재현성:** 상시 평가는 "블라인드 A/B"로 바꿨다고 하지만, 원자료와 학습 설정(스텝 수, 학습률 등 상당 부분)은 공개되지 않았습니다.

6. 읽을 때 주의할 점

- **백서는 동료 심사를 거치지 않았습니다.** NVIDIA 연구 페이지에 올라온 기술 보고서입니다(2026-11-09 생성, 2026-11 날짜 표기).
- **비교 대상의 버전:** 주요 비교 대상은 GR00T 1.7(VLA)입니다. N1, N1.5, N1.6은 주 비교에 없습니다. 아키텍처 변화는 공개된 N1.7 config와 대조해 `02`와 `04`에서 다룹니다.
- **Tab. 2-3의 GR00T 1.7은 "예비 결과"**(Tab. 2 주석)이고, 시뮬레이션에서 GR00T 1.7은 **저자들이 직접 다시 학습**했습니다(Sec. 4.5.4).
- **"released checkpoint" 표현:** Tab. 13 주석은 "GR00T 2는 공개된 체크포인트"라고 하지만, 프로젝트 페이지 버튼은 "Code Available in December"입니다. 2026-11-12 기준 공개 가중치가 없습니다(`02` §4).

02. 선행연구, 구성 요소의 출처, 공개 자료

1. GR00T 계보

세대	공개 시점 (확인)	구조 (공개 자료 기준)	GR00T 2와의 차이
GR00T N1	2025-06 (코드 태그 `n1-release`, 2025-06-11; arXiv 2503.14734)	VLM + 확산 행동 헤드 (VLA)	영상 예측 없음
GR00T N1.5	2025-12-15 (`n1.5-release`)	같은 계열, 동결 VLM 개선	영상 예측 없음
GR00T N1.6	2026-04-15 (`n1.6-release`), HF `GR00T-N1.6-3B`	같은 계열	영상 예측 없음
GR00T N1.7	2026-04-18 (`n1.7-release`), HF `GR00T-N1.7-3B` (2026-11-10 갱신)	VLM(`Cosmos-Reason2-2B`) + 32층 DiT 행동 헤드, 행동 호라이즌 40 (config)	백서 주 비교 대상 "GR00T 1.7(VLA)"
GR00T 2	백서 2026-11 (코드 "12월 공개 예정")	Cosmos-Predict2.5-2B 기반 WAM, 영상과 행동 공동 flow matching	아래 §3

백서는 GR00T 1.7을 "VLA", GR00T 2를 "WAM"으로 나눕니다(Sec. 2, Tab. 1). 두 모델은 같은 사후학습 레시피와 같은 데이터로 학습했다고 하며(Sec. 3.2, Tab. 4의 "모델 형식만 다름"), 이 대조가 백서의 핵심 비교입니다.

2. 구성 요소별 출처

구성	백서의 인용	확인 방법
백본 비디오 DiT	Cosmos-Predict2.5-2B (NVIDIA et al., 2025a)	HF `nvidia/Cosmos-Predict2.5-2B` 존재 확인 (메타데이터만)
영상 VAE	Wan 2.1 (Wan Team, 2025); Turbo는 Wan 2.2	백서 인용만 확인
언어 VLM	Cosmos-Reason1 (NVIDIA et al., 2025b)	N1.7 config는 `Cosmos-Reason2-2B`를 씀 (차이)
사후학습 RL	GRPO (Shao et al., 2024), CPS 샘플링 (Wang and Yu, 2025), RTC (Black et al., 2025)	인용만 확인
세계 모델 RL	DreamDojo (Gao et al., 2026)	인용만 확인 (공개 여부 미확인)
데이터 엔진	Flora (Leng et al., 2026), WGO-Bench (Macrodata Labs, 2026)	미공개
사람 데이터	Human-1M, HF `nvidia/PhysicalAI-Human-1M-100K` (CC-BY-4.0)	공개 100k 시간 부분집합만 (§4)
원격조작 데이터	ABC-130k (XDOF, 2026, HF `XDOF/ABC-130k`), DROID (Khazatsky et al., 2024)	외부 공개 데이터
시뮬레이터	Isaac Sim (Apache-2.0), IsaacLab-Arena, Newton, MuJoCo Warp	공개 소프트웨어
기준 모델	π0.5 (PI 2025), GR00T 1.7, FastWAM (Yuan 2026), MolmoAct2 (Fang 2026), FLUX 3 Action (Black Forest Labs 2026), LingBot-VA (Li 2026)	Tab. 1-3, 19

3. 가까운 대안 (이 저장소 안의 분석과 연결)

폴더	논문	관계
`openwam/`	OpenWAM (arXiv 2609.07398): 영상 생성 prior + ActionDiT	WAM 설계 선택을 부품 단위로 비교한 같은 계열. GR00T 2의 "영상 공동 예측"과 직접 비교 가능
`agentic_wam/`	AW-0 (arXiv 2610.30136): 영상과 행동을 한 Transformer에서 함께 denoise	공동 생성 WAM의 다른 구현
`thinkworld/`	ThinkWorld (arXiv 2610.37666): 미래 예측 보조 손실	미래 예측을 보조 손실로만 쓰는 경우. GR00T 2는 생성 자체를 쓴다는 점이 다름
`dreamx/`	DreamX (arXiv 2611.05377)	세계 모델과 정책 결합
`pacevla/`	PaceVLA (arXiv 2610.25961): GR00T N1.5 action expert 위에 decoder 4개	GR00T 계열 VLA 확장
`imle_vla/`, `adavla/`, `motion_latent_action/`, `uvt_visuomotor/`	행동 생성기·잠재 행동 VLA	행동 헤드 대안. GR00T 2는 행동 헤드를 영상 토큰과 같은 트랜스포머에 둠
`ultra_humanoid/`	ULTRA (arXiv 2603.03279): 휴머노이드 전신 제어	GR00T 2 Turbo + SONIC 조합과 비교할 대상
`restacvla/`	ResTacVLA (arXiv 2607.03387)	촉각 VLA. GR00T 2에는 촉각이 없음

4. GitHub, Hugging Face, 웹 자료 (확인일 2026-11-12, 메타데이터만)

자료	라이선스	별·좋아요	마지막 갱신	상태
백서 PDF (`research.nvidia.com/labs/gear/gr00t-2/assets/gr00t2_whitepaper.pdf`)	© 2026 NVIDIA, All rights reserved (표지 쪽 하단)	—	2026-11 (PDF 생성 2026-11-09)	원문 135쪽, 23.5 MB
프로젝트 페이지 `research.nvidia.com/labs/gear/gr00t-2/`	페이지 라이선스 표기 없음	—	2026-11	버튼: "Code Available in December" (코드 12월 공개 예정)
NVIDIA/Isaac-GR00T	Apache-2.0	★8,355, 포크 1,534	커밋 `3b49067` 2026-11-10	설명은 "N1.7". GR00T 2 코드·태그 없음. 최신 릴리스 `n1.6.1-release` (2026-04-23)
HF `nvidia/GR00T-N1.7-3B`	nvidia-open-model-license (`other`)	♥188, 다운로드 58,508	2026-11-10 (sha `373d34e`)	공개 중. config는 `analysis/meta/gr00t_n1d7_config.json`
HF `nvidia/GR00T-N1.6-3B`	라이선스 미기재	♥93	2025-12-15	공개 중
HF `nvidia/PhysicalAI-Human-1M-100K`	CC-BY-4.0	♥40, 다운로드 5,447	2026-11-07 (sha `7e312e6`)	100,000 시간 공개 부분집합, 3,405,573 에피소드
HF GR00T 2 모델 (`nvidia/GR00T-2*`, `nvidia/GR00T-N2*`)	—	—	검색 결과 없음	**공식 가중치 없음** (커뮤니티 `GR00T-2` 이름 저장소는 모두 비공식)
arXiv 제목 검색 "GR00T 2"	—	—	—	0건 (2026-11-12)

메타데이터 수집: `analysis/fetch_meta.py` → `analysis/meta/gr00t2_meta.json`.

공개 상태 판정: 2026-11-12 기준으로 GR00T 2의 가중치, 학습·추론 코드, 데이터 레시피는 공개되지 않았습니다. 프로젝트 페이지의 "Code Available in December"가 가장 최근 공식 일정입니다. 백서 Tab. 13 주석의 "released checkpoint"는 이 상태와 맞지 않아 `04`에서 불일치로 적었습니다.

5. GR00T N1.7 공개 config와 GR00T 2 백서의 구조 대조 (정적 비교)

`analysis/meta/gr00t_n1d7_config.json` (2 KB)에서 가져온 값과 백서 값을 나란히 놓았습니다. 두 모델은 다른 아키텍처이며, 같은 축에서 비교만 합니다. 어느 쪽도 실행하지 않았습니다.

항목	GR00T N1.7 (공개 config)	GR00T 2 (백서)
모델 이름	`Gr00tN1d7`	(이름 미정, 백서 본문은 "GR00T 2")
언어·시각 백본	`model_name: nvidia/Cosmos-Reason2-2B`, `tune_llm: true`, `tune_visual: true` (미세조정)	Cosmos-Reason1(동결), 영상 DiT는 학습
중간층	`select_layer: 16`, `use_vl_self_attention` 4층	영상과 행동 토큰이 한 시퀀스
행동 헤드	DiT 32층, 헤드 32개 × 48차원, `output_dim` 1024	같은 트랜스포머의 행동 토큰(출력 디코더는 임베디드먼트별)
행동 호라이즌	`action_horizon: 40`	백서에 일반값 없음. 설정마다 다름 (UMI 직접 학습은 48스텝 중 30 실행, App. E.2; DexUMI 후처리는 40스텝 stride 2, App. E.5)
추론 단계	`num_inference_timesteps: 4`	영상 1-2, 행동 2-4
입력 해상도	`image_target_size: [256, 256]` (잘라내기 230)	224×320, 카메라 최대 4대
임베디드먼트 수	`max_num_embodiments: 32`, `max_action_dim: 132`	임베디드먼트별 MLP(Sec. 2), 수는 백서 미기재
정밀도	`dtype: bfloat16`, `use_flash_attention: true`	BF16 학습, 서빙은 TensorRT·FP8 (Sec. 4.6.1)
학습 목표	행동 flow matching	영상 + 행동 flow matching
파라미터 수	이름에 3B	백서는 "2B-parameter transformer"

읽는 법: GR00T 2는 N1.7의 "VLM + 행동 헤드" 구조를 버리고, 영상 생성 백본 하나로 행동까지 생성합니다. 그래서 N1.7 config의 `tune_llm`, `select_layer` 같은 항목은 GR00T 2에 대응하는 값이 없습니다.

6. 데이터 공개 범위

데이터	백서 규모	공개 상태
Human-1M 사전학습 필터본	402,730 시간	미공개 (필터 기준과 목록은 App. C.1)
Human-1M 100K 공개 부분집합	100,000 시간 (HF, CC-BY-4.0)	공개
스튜디오 사람 데이터 3,000 시간	—	미공개
UMI-10K	10,184 시간	미공개 (백서 App. C.2에 통계만)
원격조작 (YAM, Sharpa, Wuji, G1)	23.5k 시간	대부분 미공개. ABC-130k(XDOF)는 HF 공개
평가 원자료 (A/B 아레나, 실물 시도 로그)	16,044 롤아웃	미공개 (집계 표만)

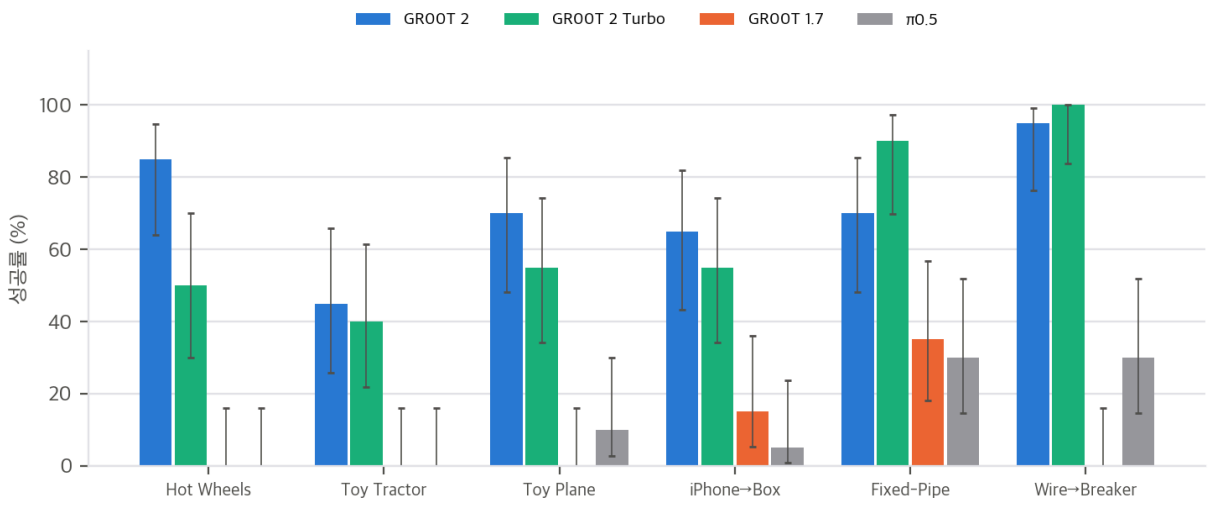
7. 이 저장소의 다른 WAM·VLA와 비교할 때 쓸 기준

- **같은 정도의 공개성:** GR00T 2는 가중치와 코드가 없습니다. 같은 계열인 OpenWAM과 AW-0는 공식 코드를 공개했습니다(각 폴더 README 기준). GR00T 2는 코드가 아직 없어 재현 가능성이 크게 낮습니다(`openwam/`, `agentic_wam/`의 분석 참조).
- **공동 예측의 증거:** Fig. 10의 사람 영상 비율 실험은 **영상 목표가 있는 모델**의 실험이라 WAM 효과만 따로 떼어 보기는 어렵습니다. GR00T 2 Turbo의 H.3 실험(시뮬레이션 데이터, WAM 대 VLA)이 가장 직접적인 대조인데, 시도 수가 30회라 결론이 약합니다(`03` §4).

03. 수치 재계산, 통계 검정, 산술 점검

이 문서의 수치는 백서 표·본문에 적힌 값을 그대로 가져와 다시 계산한 결과입니다. 원자료가 없으므로 **백서가 보고한 집계를 검산**하는 수준이고, 개별 시도 결과를 재현한 것은 아닙니다. 계산 스크립트는 `analysis/paper_checks.py` (→ `paper_checks_results.json`), `analysis/toy_power_fit.py` (→ `toy_power_fit_results.json`)입니다. 그래프는 `report/figures/` 에 있습니다.

1. 표 재계산



백서 표 1a(YAM 장기 과제, 값은 표 그대로). 막대 오차는 과제당 시도 20을 가정한 Wilson 95% 구간.

직접 그린 그래프: 표 1a의 과제별 성공률과 Wilson 95% 구간(과제당 시도 20 가정). 막대 값은 백서 표 그대로.

1.1 표 1a, 1b (실물 장기 과제 평균)

YAM 6과제, Dexter 7과제 평균을 다시 계산했습니다. **모든 평균이 보고값과 소수 첫째 자리까지 일치합니다.**

모델	YAM 진행률 (계산/보고)	YAM 성공률 (계산/보고)	Dexter 진행률 (계산/보고)	Dexter 성공률 (계산/보고)
GR00T 2	81.28 / 81.3	71.67 / 71.7	86.57 / 86.6	68.57 / 68.6
GR00T 2 Turbo	77.93 / 77.9	65.00 / 65.0	62.00 / 62.0	34.29 / 34.3
GR00T 1.7	22.60 / 22.6	8.33 / 8.3	22.00 / 22.0	0.71 / 0.7
π0.5	28.83 / 28.8	12.50 / 12.5	21.29 / 21.3	0.00 / 0.0

민감도: Dexter 트럭 조립(Truck Assembly)에서 GR00T 2의 65%는 "더 쉬운 새 시작 장면"의 값입니다. 원래 장면에서는 20회 중 7회(35%)였다고 본문이 밝힙니다(Tab. 1 주석). 원래 장면 값을 넣으면 Dexter 평균 성공률은 68.6%에서 **64.3%**로 내려갑니다(-4.3%p). 표의 평균이 쉬운 장면 값에 기대고 있다는 뜻입니다.

1.2 표 3 (Dexter 제로샷, 71과제 × 3회)

- 시도 수 213은 정수 성공 횟수와 맞습니다. GR00T 2 106/213 = 49.8%, Turbo 78/213 = 36.6%, GR00T 1.7 39/213 = 18.3%, π0.5 56/213 = 26.3%.
- 쉬운 점검: 표의 "71과제"는 Sec. 3.1의 49과제 + OOD 22과제와 맞지만, App. A.2는 "50과제 + OOD 22과제 = 72과제, 864 에피소드 (4모델 × 72 × 3)"라고 씁니다. **과제 수가 71인지 72인지 본문 안에서 엇갈립니다.** 어느 쪽이든 결론은 같지만, 과제 목록을 공개하지 않아 확인할 수 없습니다.

1.3 표 12 (아레나 집계)

항목	계산	본문
YAM 캠페인	78 + 122 − 5 (두 리그에 걸친 5개) = 195	195 ✓
YAM 롤아웃	6,373 + 9,671 = 16,044	16,044 ✓
YAM 시도	2,167 + 3,403 = 5,570	5,570 ✓
YAM 쌍 비교	5,732 + 6,035 = 11,767	11,767 ✓
YAM 체크포인트	45 + 26 = 71	71 ✓
동점 비율	5,732 × 30% = 1,720; 6,035 × 35% = 2,112	표 12의 30%, 35%

집계는 모두 맞습니다. 다만 **V1과 V2는 서로 다른 리그**라고 백서가 밝혔는데(표 12 주석), 본문 4.3은 두 리그를 합쳐 "71개 체크포인트"라고 씁니다. 합계의 의미는 "두 리그의 독립 집계를 더한 것"입니다.

1.4 표 11 (원격조작 혼합)

- 샘플 비중 합 100.0% ✓, 시간 합 23,508시간(본문 23.5k) ✓, 에피소드 합 1,158.6천(본문 1.16M) ✓.
- 샘플 비중과 시간 비중이 다릅니다. YAM은 시간의 64.4%지만 샘플의 51.2%이고, Sharpa는 시간의 12.3%지만 샘플의 20.6%입니다. 샘플링 가중치로 균형을 맞춘 것이므로 "샘플 비중"이 학습 분포를 정합니다.

1.5 표 27 (지연 시간 배율)

행	기준 (ms)	최적화 (ms)	계산 배율	보고 배율
Dexter GR00T 2, RTX 5090	449.20	152.78	2.94	2.94
Dexter GR00T 2, GB300	219.02	48.47	4.52	4.52
G1 Turbo, RTX 5090	224.73	38.40	5.85	5.85
G1 Turbo, Jetson Thor	720.41	123.97	5.81	5.81
YAM GR00T 2, RTX 5090	550.96	179.79	3.06	3.06
YAM GR00T 2, GB300	386.06	54.00	7.15	7.15

모든 배율이 맞고, 본문의 "2.9배에서 7.2배"도 맞습니다. 다만 **기준은 BF16 eager PyTorch, 최적화는 TensorRT·CUDA graph·FP8**이라서, 배율은 소프트웨어 경로 차이를 함께 담고 있습니다. 맥에서 얻을 수 있는 값은 아닙니다(§4).

2. 통계 검정과 신뢰구간

2.1 과제당 20회의 불확실성

Wilson 95% 구간 예시: 20회 중 17회 성공 → [64.0%, 94.8%], 10회 → [29.9%, 70.1%], 14회 → [48.1%, 85.5%]. 과제당 20회에서는 **±20%p가 흔한 불확실성**입니다.

2.2 Turbo와 GR00T 2의 차이 (표 1)

- YAM 6과제 평균 성공률 차이는 -6.7%p. 과제당 n=20을 가정한 표준오차는 약 5.5%p라서 95% 구간은 대략 [-17, +4]입니다. **통계적으로 구분되지 않습니다.** 백서 결론의 "6.7점 손실"은 점 추정으로만 맞습니다.
- Dexter 7과제 평균 차이 -34.3%p, 표준오차 약 5.2%p(같은 가정). 구간이 0에서 멀리 떨어져 있어 **차이 자체는 뚜렷합니다.** 다만 Dexter의 과제당 시도 수가 본문에 없어 n=20은 가정입니다.

2.3 Dexter 제로샷 두 모델 비교 (표 3)

- GROOT 2 대 GROOT 1.7: 106/213 대 39/213, 비쌍 두 비율 검정 z = 6.85. 같은 과제를 같은 세션에서 돌렸으므로 쌍 검정(McNemar 또는 과제 군집 부트스트랩)이 맞지만, 쌍 데이터가 공개되지 않아 비쌍 근사로만 씁니다. 차이가 워낙 커서 결론은 바뀌지 않을 가능성이 높습니다.
- 시도가 과제에 묶여 있어 실제 독립 단위는 과제 71개입니다. 과제 단위로 줄여 봐야 정확한 값이 나옵니다.

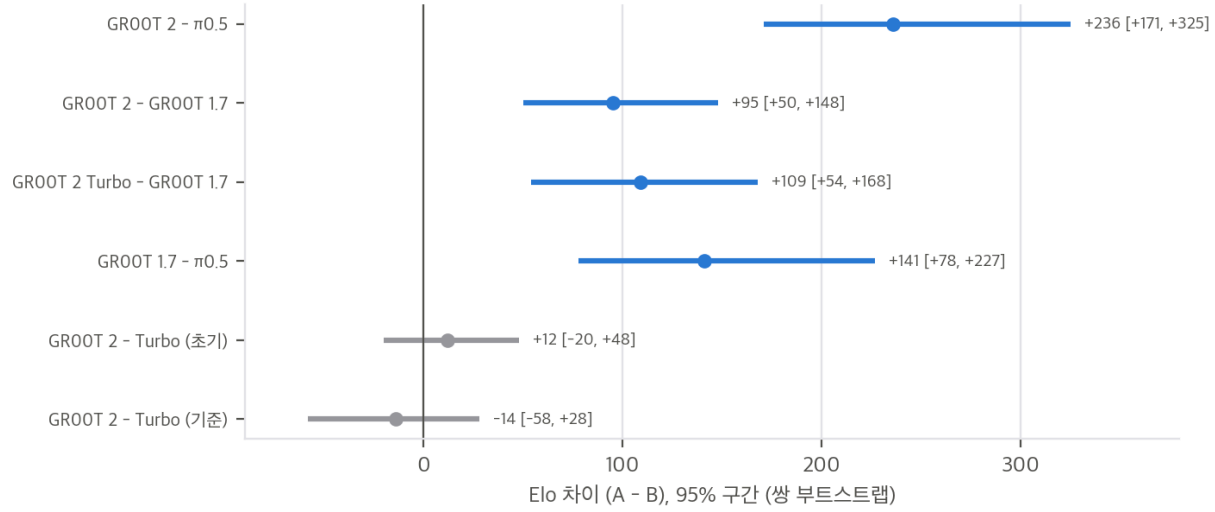
2.4 H.3 "WAM이 시뮬레이션 데이터를 더 잘 쓴다"

- 공동 학습 후 성공 19/30 (GROOT 2 Turbo, 63.3%) 대 12/30 (GROOT 1.7, 40.0%). 양측 Fisher 정확검정 **p = 0.12**(백서 본문 p ≈ 0.12와 일치).
- 백서는 이를 "suggestive rather than conclusive"라고 씁니다. 이 표현이 맞습니다. 이 근거만으로 "WAM이 더 잘 쓴다"고 결론 내리면 안 됩니다.

2.5 백서가 말한 표본 크기 (Sec. 5, 각주 1)

두 비율 검정, 양측 α = 0.05, 검출력 0.8 기준으로 계산했습니다.

비교	계산 (쪽당 표본)	백서	판정
95% 대 99%	284.3	"약 285"	✓
99% 대 99.9%	1,058.9	"1,000 이상"	✓ (1,059)



백서 표 13. 파란색은 구간이 0 위, 회색은 0을 포함. 기대 승률은 동점을 뺀 승부 기준이다.

직접 그린 그래프: 표 13의 쌍별 Elo 차이와 95% 구간. 회색은 0을 포함하는 비교.

2.6 아레나 Elo (표 13)

- 기대 승률: Elo 차이 236 → 79.6% (백서 80%), 95 → 63.3% (63%), 109 → 65.2% (65%), 141 → 69.2% (69%). **모두 맞습니다.**
- 다만 Elo 승률은 **동점을 뺀 승부**에 대한 값입니다. π0.5 대 GROOT 2에서 동점이 35%이므로, 전체 매치에서 GROOT 2가 엄격히 이기는 비율은 약 **51.7%**, π0.5가 이기는 비율은 13.3%, 동점 35.0%입니다. 본문의 "80% 승률"은 승부가 난 경우에 한한 값이라는 점을 밝혀야 합니다.
- 표 13의 Turbo 대 GROOT 2 차이(+12, [-20, +48]; -14, [-58, +28])는 0을 포함해서 **같다고 볼 수 있습니다.** 백서도 "statistically indistinguishable"이라고 씁니다.
- 구간 표기가 엇갈립니다. 표 13 주석과 App. D는 95% 구간, Fig. 11 주석은 "paired 90% bootstrap intervals"입니다. 어떤 구간을 쓰는지 한 가지로 정리되지 않았습니다.

2.7 사람 영상 비율 실험 (Fig. 10)

- 실물 기준 72과제 × 3회 = 216회 per arm. 0%는 39/216 = 18%, 100%는 89/216 = 41%.
- 과제를 무시한 비쌍 검정 z ≈ -5.3. 과제 군집을 넣으면 유효 표본이 줄어 p값은 크게 달라질 수 있습니다. 시드 반복이 없으므로 학습 자체의 무작위성(한 번의 학습)은 검정에 들어가지 않았습니다. 즉 **0%와 100%의 차이는 크지만, 학습 시드 변동은 측정되지 않았습니다.**
- "more than doubles"는 41/18 = 2.3배로 맞습니다. "포화되지 않았다"는 0, 1, 10, 100% 네 점으로 판단하므로 곡선 모양은 약합니다.

2.8 시뮬레이션-실물 상관 (Sec. 4.5.2)

- r = 0.93, n = 14 (체크포인트). Fisher z 변환 95% 구간은 **[0.79, 0.98]**입니다. 점 추정은 높지만 구간이 넓습니다.
- "완벽한 시뮬레이터의 상관의 95-99%"라는 상한은 공개된 자료로 계산할 수 없습니다.

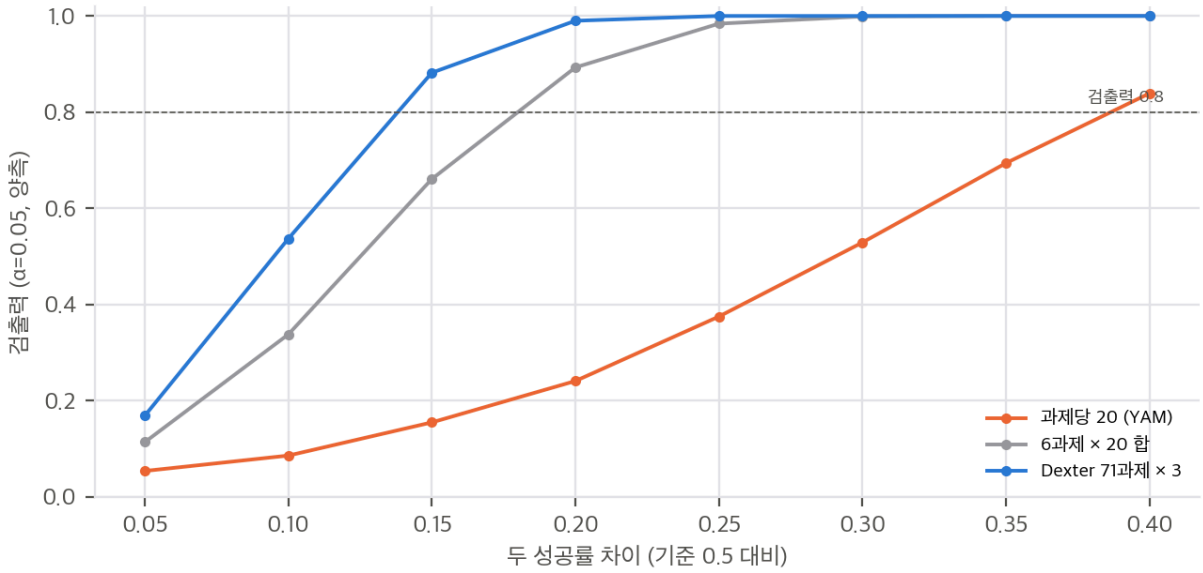
2.9 벤치마크 평균 (표 30, 표 19)

- RoboCasa365(표 30): GR00T 2 세 열(Atomic-Seen 87.4, Comp.-Seen 73.6, Comp.-Unseen 38.2)의 단순 평균은 66.4인데 보고된 Average는 67.2입니다. 과제 수 가중치를 쓴 것으로 보이지만 과제 수가 공개되지 않아 재계산할 수 없습니다. π0.5(15.97 대 16.9), GR00T 1.7(21.27 대 22.1)도 같은 방향으로 어긋납니다.
- RoboDojo(표 19): SFT 행의 다섯 차원 단순 평균은 35.22이고 보고값 35.2와 맞습니다. 백서 주석의 "official mean over the five capability dimensions"와 일치합니다.

3. 산술 점검 (기타)

항목	계산	결과
사람 데이터 시간	402,730 h / 13.75M 에피소드 = 1.76 분/에피소드	HF 공개 부분집합 100,000 h / 3,405,573 = 1.76 분 ✓ 같은 종류의 데이터로 보임
시간 단계	(402,730 + 10,184 + 23,500) h × 3600 × 30 Hz = 47.1×10^9	백서 462억(46.2×10^9), 2% 차이. 필터 전후 차이로 설명 가능 ✓
전역 배치	1,024 GPU × 16 = 16,384 창	백서는 GPU당 배치 16 (Sec. 4.7.1)
스텝 시간 (가정)	16,384 / 12,000 창/초 ≈ 1.37 s	데이터 대기가 0.049%라서 로더 전달율 ≈ 소비율이라는 가정
계산량 (가정)	학습 FLOP ≈ 6 × 2×10^9 × 16,384 × T (창당 토큰 T)	T = 1,000 / 2,000 / 4,000이면 스텝당 1.97 / 3.93 / 7.86 × 10^{17} FLOP, 1,024장 피크 2.5 PF 기준 MFU 5.6% / 11.3% / 22.5%
가중치 메모리	2B 파라미터 DiT: BF16 3.73 GiB, FP8 1.86, FP4 0.93	가중치만. 동결 VAE·VLM 크기는 백서에 없음

계산량 줄은 **가정치의 범위**입니다. 백서는 토큰 수, 스텝 수, MFU를 보고하지 않으므로, 총 GPU 시간은 여기서 확정할 수 없습니다. 스텝 수가 없으면 학습 기간과 총 GPU 시간은 계산되지 않습니다. 위 범위는 스텝당 계산량의 크기만 보여 줍니다. 이 추정은 확정 주장으로 쓰지 않습니다.



몬테카를로 20,000회, 과제 군집 효과는 넣지 않음. 과제 간 차이를 고려하면 실제 검출력은 더 낮다.

직접 그린 그래프: 시도 수별 두 비율 검정 검출력(몬테카를로, 과제 군집 미포함).

4. 토이 실험

4.1 시도 수와 검출력 (`analysis/toy_power_fit.py`, 몬테카를로 20,000회, 시드 0, 1스레드 0.1초)

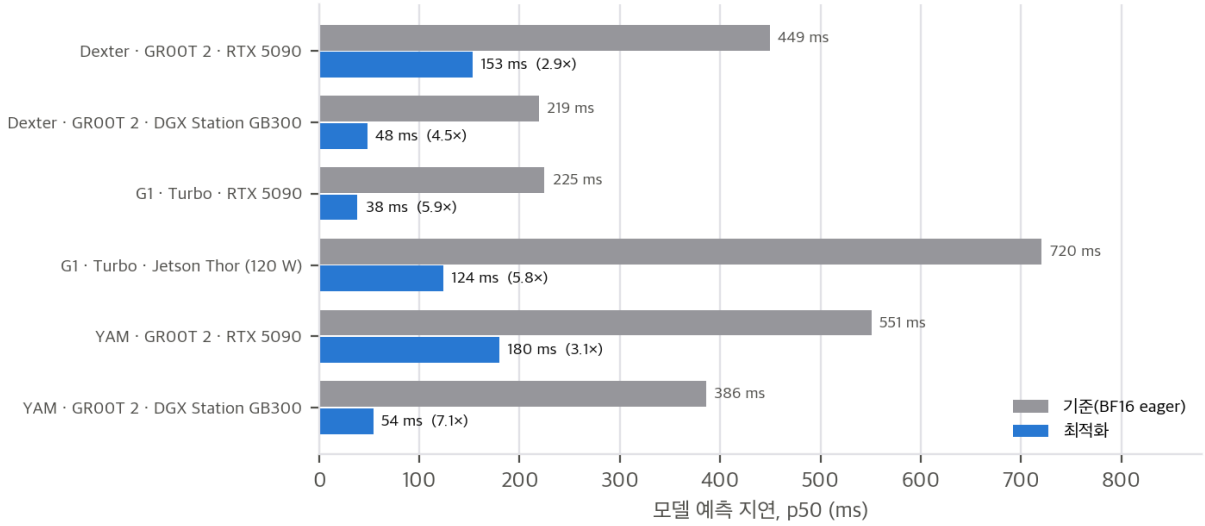
기준 성공률 0.5, 두 비율 양측 검정 α = 0.05.

시도 수 (쪽당)	차이 10%p	차이 20%p	차이 30%p
20 (과제당, YAM)	0.09	0.25	0.53
120 (6과제 × 20 합)	0.33	0.89	1.00
213 (Dexter 제로샷)	0.54	0.99	1.00
216 (사람 영상 비율 실험, 실물)	0.55	0.99	1.00

- 과제당 20회로는 **20%p 차이도 4번 중 3번은 놓칩니다.** 백서가 고른 큰 차이(예: GR00T 2 대 π0.5, 평균 59%p)만 잡힙니다.
- 과제 군집 효과를 넣지 않았으므로 실제 검출력은 이보다 낮습니다.
- Wilson 구간의 실제 포함률: n=20에서 p = 0.5일 때 96.1%, p = 0.85일 때 97.9%, p = 0.95일 때 92.5%. 명목 95%에 대체로 맞지만 p가 극단에 가까우면 약간 낮습니다.

4.2 메모리와 계산 (`analysis/toy_power_fit.py`의 둘째 부분)

- 2B DiT 가중치: BF16 3.73 GiB, FP8 1.86 GiB, FP4 0.93 GiB(블록 scale 제외).
- 24 GiB 맥은 GPU가 쓸 수 있는 작업 메모리를 보통 전체의 3/4 정도로 본다는 가정(추정)을 쓰면 약 18 GiB입니다. 가중치만 보면 **여유가 충분**합니다. VLM(Cosmos-Reason1)과 VAE 크기는 백서에 없으므로, 그 둘이 각각 2B 규모라면 BF16 합계는 약 8-9 GiB입니다. 이 값도 맥 한도 안입니다.
- 지연은 메모리가 아니라 연산이 문제입니다. 아래 §5에서 다룹니다.



백서 표 27의 중앙값. 최적화는 TensorRT·CUDA graph·FP8 등 CUDA 경로이므로 맥에서는 같은 값이 나오지 않는다.

직접 그린 그래프: 표 27의 지연 시간 중앙값과 배율. 최적화 경로는 CUDA 전용이다.

5. 맥(M4 Pro)에서의 지연 추정 (측정 아님)

백서 값(RTX 5090)에서 출발한 **자릿수 추정**입니다. 정확한 값은 공개 가중치로 측정해야 합니다.

- 피크 연산 비: RTX 5090 BF16 밀집 약 209 TFLOPS(NVIDIA 공개 사양 기준 추정) 대 M4 Pro GPU 약 9 TFLOPS(FP32 기준, Apple 사양 추정). 약 20배.
- 메모리 대역폭 비: 약 1.8 TB/s 대 273 GB/s, 약 6.6배.
- 추론은 연산 제약이 크므로 실효 차이는 대략 **10-25배**로 가정합니다. 그러면 Dexter GR00T 2의 153 ms(5090)는 맥에서 **약 1.5-4 s**, G1 Turbo의 38 ms는 **약 0.4-1 s**입니다.
- 원래 LoRA 미세조정은 RTX 5090에서 약 30분(Sec. 3.1)입니다. 같은 비율을 적용하면 맥에서 **대략 5-12시간**입니다(순전파와 역전파를 같은 비율로 본 거친 추정).

이 수치들은 `04` §4의 판정에 쓰지만, 측정 결과처럼 인용하지 않습니다.

6. 요약

점검	결과
표 1·3·11·12·27 재계산	모든 평균·합계·배율 일치. 표 1b는 트럭 과제의 쉬운 장면 값을 감안해 읽어야 함
통계 주장	Fisher p = 0.12 ✓, 95 대 99% 표본 285 ✓, Elo 기대 승률 ✓. Turbo의 YAM 차이는 구분 안 됨
주장 해석	"80% 승률"은 동점 제외. 엄격한 승률은 약 52%
시도 수	과제당 20회 → 20%p 차이 검출력 0.25. 백서의 결론 중 작은 차이를 말하는 부분은 근거가 약함
공개 수치의 불일치	과제 수 71 대 72, RoboCasa 평균 가중치 미공개, 구간 90% 대 95%
계산 자원	총 GPU 시간·스텝 수·MFU 미보고. 추정치만 가능

04. 주장 검증과 구현 가능성

GR00T 2의 공식 코드와 가중치는 **2026-11-12 기준 공개되지 않았습니다**(`02` §4). 그래서 코드 대조(논문 ↔ 코드)는 할 수 없고, 이 문서는 (1) 백서 주장을 백서 자체 수치로 다시 계산하고 (2) 공개된 N1.7 config와의 정적 대조만 합니다. 어떤 코드도 실행하지 않았고, 가중치는 받지 않았습니다.

판정 기호: **재현됨**(산술·집계가 맞음) / **부분**(일부만 맞거나 해석이 넓음) / **불일치**(본문과 표·다른 부분이 어긋남) / **검증 불가**(원자료·코드·가중치 없음).

1. 주장 검증 (C1-C16)

#	주장 (백서 위치)	검증 방법	판정	근거
C1	구조: Cosmos-Predict2.5-2B 백본, 2B 파라미터 트랜스포머, 영상 VAE·VLM 동결 (Sec. 2)	공개 코드·가중치 없음. 공개 N1.7 config와 대조	검증 불가	`02` §5. N1.7은 다른 구조(VLM + DiT 헤드)
C2	Dexter 제로샷 성공률 49.8% (71과제, 3회) (Tab. 3)	213 정수 횟수 확인	재현됨 (산술)	`03` §1.2. 과제 수 71과 72 불일치(App. A.2)
C3	본문의 제로샷 "40%, 50과제, 1회 시연 71%, 5회 95%" (Sec. 3.1, Fig. 2)	과제당 시도 수가 없음	검증 불가	Fig. 2 주석 "per task" 없음. 5회 95%는 "과제 중 80% 이상 학습된 50과제"로 고른 값이라 선택 편향 (Sec. 3.1 본문이 인정)
C4	YAM 장기 평균 GR00T 2 71.7%, Turbo 65.0%, 차이 6.7점 (Tab. 1a, Sec. 5)	평균 재계산	재현됨 (평균). 차이는 **부분**	평균 일치. 차이 6.7%p의 표준오차 약 5.5%p → 구분 안 됨 (`03` §2.2)
C5	Dexter 장기 GR00T 2 68.6%, Turbo 34.3% (Tab. 1b)	평균 재계산	재현됨, 해석 **부분**	트럭 과제 쉬운 장면 값 감안 시 64.3% (`03` §1.1)
C6	사람 영상을 0→100% 늘리면 실물 성공률 18→41%, "두 배 이상" (Sec. 4.2.1, Fig. 10)	216 per arm 계산, 비율	재현됨 (산술). 일반화는 **부분**	2.3배 맞음. 학습 시드 반복과 과제 군집 효과 없음 (`03` §2.7)
C7	0·1·10·100% 전 구간에서 "positive scaling", "포화되지 않음" (Fig. 10)	중간 점 값 확인	부분	4개 점만. 곡선 모양을 말하기 약함
C8	π0.5 대비 Elo +236 [171, 325], "80% 승률" (Tab. 13, Sec. 4.3)	Elo → 승률 계산	재현됨 (Elo식). "승률"은 **부분**	79.6%는 동점 제외. 동점 35%를 포함한 엄격한 승률은 약 52% (`03` §2.6)
C9	GR00T 1.7 대비 Turbo 대 GR00T 2는 "statistically indistinguishable" (Sec. 4.3)	Elo 구간 확인	재현됨	구간 [-20, +48]이 0을 포함
C10	아레나 규모: 195 캠페인, 16,044 롤아웃, 11,767 쌍 비교, 71 체크포인트 (Sec. 4.3, Tab. 12)	표 12 집계 합산	재현됨	`03` §1.3
C11	시뮬레이션과 실물 상관 r = 0.93 (14 체크포인트), "95-99% of a perfect simulator" (Sec. 4.5.2)	Fisher 구간 계산	부분	구간 [0.79, 0.98]. 완벽한 시뮬레이터 상한은 계산 불가
C12	추론 지연 153 ms (Dexter, RTX 5090), 124 ms (Turbo, Jetson Thor), 2.9-7.2배 가속 (Sec. 2, 4.6.1, Tab. 27, Fig. 19)	표 27 배율과 Fig. 19 비율 계산	재현됨 (배율)	기준 BF16 eager vs TensorRT·FP8(CUDA 경로). 맥의 값이 아님 (`03` §1.5)
C13	RoboCasa365 67.2%가 VLA·WAM 중 최고, 에이전트 포함 88.0%가 리더보드 1위 (Sec. 4.5.4, Tab. 19)	표 19 행 비교	부분	표 안에서는 1위(88.0 대 HexaShell 1.5의 85.6). 그러나 HexaShell은 에이전트이고 GR00T 2 행은 저자 실행. 평균이 과제 가중치라 재계산 불가(`03` §2.9)
C14	RoboDojo 75.8% (에이전트 + RL)가 최고 (Sec. 3.4, Tab. 19)	표 19 행 비교	부분	Q0-Preview 68.9 대비 1위. 공식 3개 레이아웃 뱅크 중 bank 0만 사용. 공식 SFT 35.5%에서 SFT 35.2(bank 0)
C15	사전학습 사람 데이터 402,730 h, 원격조작 23.5k h, UMI 10,184 h (Sec. 4.2)	표 11 합계, 시간 단위 계산	재현됨 (합계). 원자료 **검증 불가**	1.76분/에피소드, 30 Hz 프레임 수 2% 차이 (`03` §3)

#	주장 (백서 위치)	검증 방법	판정	근거
C16	사전학습은 GB300 1,024장 (Sec. 4.7.1)	데이터 로더 수치 (Tab. 35)와 계산량 가정	부분	장 수는 명시. **총 스텝, 기간, GPU 시간, MFU 미보고** (`03` §3)
C17	실물 장기 조립 97% 이상 (에이전트, Fig. 7)	100회 시도 표기 확인	부분	100회 표기는 맞음. 사람이 도운 시도는 실패로 셈(좋은 설계). 시도 로그는 공개 안 됨
C18	블라인드 A/B 프로토콜: 체크포인트 순서 무작위, 작업자 블라인드 (Sec. 4.3, App. D)	설명 확인	검증 불가	작업자 블라인드 여부는 원자료 없이 확인 불가
C19	Elo 재적합이 발표된 값을 0.1 이내로 재현 (App. D, Tab. 13 주변)	—	검증 불가	원자료 없음
C20	H.3: WAM이 시뮬레이션 데이터를 더 잘 쓴다 (63.3% 대 40.0%)	Fisher 검정	부분 (백서도 "suggestive")	p = 0.12. 결론은 약함 (`03` §2.4)
C21	"GR00T 2 is the released checkpoint" (Tab. 13 주석)	HF·GitHub·프로젝트 페이지 확인	**불일치**	2026-11-12 기준 HF GR00T 2 저장소 없음. 프로젝트 페이지는 "Code Available in December"
C22	백서 PDF 라이선스	표지 쪽 하단	—	"© 2026 NVIDIA. All rights reserved." (`README` 라이선스 절)

2. 본문 안의 불일치와 표기 문제 (요약)

1. **과제 수:** Tab. 3과 Sec. 3.1은 71과제(49 + 22). App. A.2는 72과제(50 + 22, 864 에피소드). (C2)
2. **구간 수준:** Tab. 13과 App. D는 95% 구간, Fig. 11은 90% 구간.
3. **"released checkpoint":** Tab. 13은 GR00T 2를 "공개된 체크포인트"라고 씀. 실제로는 아직 공개되지 않았음. (C21)
4. **쉬운 장면 값:** Tab. 1b의 트럭 조립은 원래 장면 7/20 대신 쉬운 장면 값 65%를 씀. 주석에 밝혔지만 평균에는 반영됨. (C5)
5. **평균의 정의:** 표 30(RoboCasa365)의 Average는 세 열의 단순 평균이 아님. 가중치를 밝혀야 재계산 가능. (C13)
6. **승률 표현:** "80% 승률"은 동점을 뺀 Elo 기대값. (C8)
7. **지연의 정의:** 본문 "per served call 171 ms"(Sec. 4.3)와 Tab. 27의 "model prediction 179.79 ms"(YAM, RTX 5090)는 측정 범위가 다르다. 같은 대상의 다른 측정으로 보임. 정의를 밝혀야 비교 가능.

3. 이 백서가 주장하지 않는 것 (범위 확인)

- 총 학습 비용(GPU 시간)과 스텝 수는 주장하지 않습니다.
- 맥이나 소비자 GPU에서의 학습·추론은 다루지 않습니다. 평가 하드웨어는 RTX 5090, DGX Station GB300, Jetson Thor, 그리고 L40/L40S(시뮬레이션)입니다(App. K.2, Sec. 4.6.1).
- 공개 재현 계획은 없습니다. "12월 코드 공개"만 있습니다.

4. 구현 가능성 판정 (맥 M4 Pro 24 GiB, CUDA 없음, MPS)

4.1 판정

이 맥에서 GR00T 2를 "공개 가중치로" 구현하는 것은 지금 불가능합니다. 가중치와 코드가 없습니다. 공개 예정일(12월) 이후에도 아래 조건을 충족해야 합니다.

작업	이 맥에서	필요한 것 (백서·공개 자료 기준)	판정
공개 가중치 다운로드 후 추론 (제로샷)	메모리는 충분(가중치 DiT 약 3.7 GiB BF16, VLM·VAE 포함해도 약 8-9 GiB 추정). 지연이 문제: 153 ms(5090)에서 맥은 수 초 단위로 추정	공식 서빙은 TensorRT·FP8·CUDA graph 경로라 맥에서 같은 경로는 없음. eager BF16 PyTorch 경로가 MPS에서 도는지 미확인	**조건부** (공개 후, 지연 측정 필요). 실시간 제어는 부적합, 오프라인 평가·라벨링 정도

작업	이 맥에서	필요한 것 (백서·공개 자료 기준)	판정
이미지·영상 입력 처리 (Wan VAE, Cosmos 토크나이저)	메모리 가능	CUDA 커널 의존 여부 미확인	미확인
LoRA 미세조정 (백서: 과제당 약 30분, RTX 5090)	맥에서 BF16 학습은 MPS 지원 범위 확인 필요. 같은 비율을 적용하면 약 5-12시간 (추정)	RTX 5090급 CUDA GPU 1장이 백서의 설정	**비추천** (시간과 안정성). 이 맥에서 하면 시험용 소규모만
실물 로봇 수준 데이터로 전체 사후학습	불가	대규모 원격조작과 실물	**불가**
사전학습 재현	불가	GB300 1,024장, 원자료 미공개	**불가**
아레나·시뮬레이션 평가 재현	불가	L40급 GPU, 시뮬레이터(IsaacLab 등)	**불가** (GPU 재현 금지 규칙)

4.2 하드웨어 요약

- **추론(제로샷, 공개 후):** 맥 M4 Pro 24 GiB로 메모리는 됨. 속도는 추정 1.5-4 s(Dexter), 0.4-1 s(G1 Turbo)로 실시간 조작에는 부족. 측정 전 확정할 수 없음.
- **미세조정:** 논문 설정은 RTX 5090(32 GB). 맥은 메모리는 되지만 시간이 길고 커널 호환이 불확실.
- **학습·RL:** CUDA GPU 여러 장 필요(백서는 GB300 1,024장, H100 풀, L40 시뮬레이션 클러스터).

4.3 대안 (이 맥에서 실제로 해 볼 수 있는 것)

- **GR00T N1.7-3B (공개 가중치, nvidia-open-model-license, 코드 Apache-2.0):** 같은 계열 공개 모델이라 맥에서 추론 구조를 익히는 데 쓸 수 있습니다. 다만 맥에서 실행되는지는 확인하지 않았습니다. 다운로드와 설치는 사용자 승인이 필요합니다.
- **Cosmos-Predict2.5-2B (HF 공개):** GR00T 2의 백본이므로 영상 예측 부분만 맥에서 시험할 수 있습니다. 행동 출력은 없습니다.
- **사람 데이터 공개 부분집합 (Human-1M 100K, CC-BY-4.0):** 데이터 통계와 전처리 연습에 쓸 수 있습니다. 전체 용량은 다운로드 전에 확인해야 합니다.

4.4 최종 판정 문장

> 이 맥에서 GR00T 2는 **지금은 구현할 수 없습니다**(가중치·코드 미공개). 12월 공개 후에도 추론은 **조건부**(메모리는 되지만 CUDA 전용 최적화 경로가 없고 지연이 수 초로 추정), 미세조정은 **비추천**(RTX 5090급 GPU 권장), 사전학습과 RL·아레나 재현은 **불가**입니다.

5. 정적 대조 요약 (공개된 것만)

항목	백서	공개 자료	판정
가중치	언급 없음 (Tab. 13 주석만 "released")	HF GR00T 2 없음	불일치 (C21)
코드	프로젝트 페이지 "Code Available in December"	Isaac-GR00T는 N1.7까지	미공개
라이선스	백서 표지 "All rights reserved"	Isaac-GR00T Apache-2.0, N1.7 가중치 nvidia-open-model-license	확인 불가 (GR00T 2 해당 없음)
사람 데이터	Human-1M 402k h 사전학습	HF 100k h 공개(CC-BY-4.0)	부분 공개
평가 데이터	아레나 16,044 롤아웃	없음	검증 불가