HolidayFactory 1.0: 분석 리포트

arXiv:2611.11789v1 (제출 2026-11-09) · 학회 표기 없음(프리프린트) · 공식 코드·자산 공개 없음 · 분석일 2026-11-12 · 게시용 버전: 논문 그림과 원문 PDF는 라이선스(arXiv 비독점 배포) 때문에 뺐습니다.

핵심 요약

1. **무엇을 하는가:** 접촉(수압 패치, CDMM 솔버)과 상태를 가진 액추에이터를 갖춘 산업 시뮬레이터 HOLIDAY-SIM, 자산·장면·평가를 생성하는 에이전트 파이프라인(ERIS, ISG), 작업을 리셋 없이 반복하는 벤치마크 24/7-BENCH(7개 작업)를 제시합니다(`01` §0-§4).
2. **정책 결과가 없습니다.** 저자들이 결론에서 "정책을 persistent run으로 비교한 적이 없다"고 인정합니다. 24/7-BENCH의 정책 순위, 기준선, 유의성은 본문에 없습니다(`04` C20).
3. **표 사이의 수치는 모두 맞습니다.** 탈락률, 회복률, 백본별 Δ, 비용 비율을 재계산했습니다. 문제는 표본입니다. 대부분 3-40단위입니다(`03` §1).
4. **헤드라인 차이의 유의성은 약합니다.** 측정 피드백의 "100% 대 84%"(표 13)는 쌍 McNemar p = 0.0625로 유의하지 않습니다. 1차 실패 회복률 11/12 대 4/12(Fisher p = 0.009)와 백본 다섯 개의 +25-35 pp 차이(쌍 $p \le 0.035$)가 더 강한 근거입니다(`03` §2).
5. **작업을 독립으로 세면 안 됩니다.** 토이에서 실행 효과가 있을 때 작업 독립 검정의 1종 오류는 0.13-0.32로 부풀고, 실행 단위 검정은 0.05를 지킵니다. 정책 간 10 pp 차이를 80% 검정력으로 보려면 정책당 실행 20-40회가 필요합니다(`03` §4).
6. **실물 검증과 시뮬레이터 파라미터의 실물 근거가 없습니다.** 배터리 들기 비교(CDMM 20/20 대 MuJoCo 1/20)는 파지 자세와 목표값을 CDMM으로 튜닝한 상태라 솔버 효과를 분리하지 못합니다(`01` §2.1, `04` C1).
7. **공개 자료가 없습니다.** GitHub 조직 Holiday-Robotics의 공개 저장소는 0개이고, 프로젝트 사이트에도 코드 링크가 없습니다. 논문의 "오픈소스 생태계 기여" 문장과 공개 상태가 맞지 않습니다(`02` §4, `04` §0).
8. **구현 가능성:** 공식 재현은 불가능합니다(코드·자산·LLM 파이프라인 없음). 이 맥(CUDA 없음)에서는 평가 프로토콜(작업 이벤트, 실행 단위 검정)만 CPU로 구현할 수 있습니다(`04` §4).
9. **이 저장소와의 연결:** 검정력 계산은 `contactbench/`와 같은 질문이고, 산업 삽입은 `insertion_wm/`, 촉각 평가는 `contact_disassembly/`, Newton 기반 시뮬 도구는 `robosimstudio/`와 연결됩니다(`02` §3).

그래프 세 장은 우리가 표 집계와 토이로 그렸습니다(`03` §7).

HolidayFactory 1.0: Simulating, Generating, and Evaluating Industrial Robot Tasks (arXiv:2611.11789v1) 논문 분석

- 저자: Holiday Robotics 명의, 14명(Jeongmin Lee 외). 프로젝트 리드는 Jeongmin Lee, Taehyeon Kim
- 버전: arXiv v1, 제출 2026-11-09. 본문 PDF 첫 쪽 날짜는 November 7, 2026. 72쪽, 본문 37쪽 + 부록 A-F
- 학회: 표기 없음. arXiv Comments 필드가 비어 있고 PDF에도 학회명이 없다(프리프린트)
- 원문: arXiv:2611.11789v1 PDF(23.4 MB). 게시본에는 넣지 않으며 `curl -L -o paper/paper.pdf https://arxiv.org/pdf/2611.11789v1`로 받습니다.
- 표기: 논문 본문의 그림·표 번호와 식 번호를 그대로 쓴다. 모델 이름(claude-opus-5-5, gpt-6.1-sol 등)도 논문 표기 그대로 다.

0. 한눈에 보기

이 논문은 **시뮬레이터, 자동 월드 생성기, 반복 작업 벤치마크를 하나의 기술 보고서로 묶은 프레임워크**입니다. 세 기여는 다음과 같습니다.

1. **HOLIDAY-SIM**(§3): Newton의 희소 SDF 기반 수압 탄성(hydroelastic) 접촉에 압력 법칙 확장, 원시-쌍대 반복 솔버(CDMM), 상태를 가진 액추에이터, 자기 촉각 센서를 더했습니다.
2. **에이전트 월드 구축**(§4): 자산 생성기 ERIS(§4.1), 역방향 장면 생성 ISG(§4.2), 사람이 확인하는 평가 생성(§4.3).
3. **24/7-BENCH**(§5): 장면을 리셋하지 않고 작업(job)을 반복하는 산업 작업 7개와 그 지표(처리량, 지연, 실패, 미완료, 모터 에너지).

논문이 **보여주지 않은 것**도 분명합니다. 저자들은 결론(§7)과 §5.3, §6.6에서 "정책을 persistent run으로 비교한 적이 없다"고 적었습니다. 따라서 24/7-BENCH의 정책 순위, 기준선(baseline), 유의성 검정 결과는 **본문에 없습니다.** 실물 로봇과의 비교도 없습니다(§6.1: "No result has been compared with measurements from a physical robot").

1. 문제 설정 (§1, §2)

- 동기: 로봇 평가는 보통 리셋에서 시작하는 에피소드로 이뤄지지만, 산업 작업은 이전 작업이 다음 작업의 상태를 바꾸는 연속 작업입니다. 독립 성공률 95%면 20개 연속 작업 성공 확률은 36%, 99%면 82%라는 계산을 서론에서 듭니다(0.95^20 = 0.359, 0.99^20 = 0.818로 재계산 일치, `analysis/04_claim_verification.md` C10).
- 세 연구 질문: RQ1 접촉·구동·감지 시뮬레이션, RQ2 과제 조건 월드 구성, RQ3 지속 상태에서의 반복 작업 측정(§1.1).
- 형식 정의(§2.1, 표 1-2): 작업장 W, 과제 T, 월드 $\xi = (S, E)$. 시나리오 S = (scene variants s_1..s_Ns, 공정 논리 ℓ), 평가 E = (job j, 지표 m_1..m_Nm, 루브릭 c). 식 (2): $S \sim G(T, W)$, $E \sim A(T, S)$. 여기서 G는 장면 생성, A는 평가 생성(사람 확인 포함)이고 V_scen, V_eval은 각각 검사입니다.
- 로봇: FRIDAY 휠형 휴머노이드, 75개 관절(활성 64, 수동 11), 머리·손목 카메라, IMU, LiDAR, 촉각 피부(표 46). 기본 시간 설정은 제어 주기 1/60 s, 물리 하위 단계 4개(1/240 s)(표 47).

2. HOLIDAY-SIM (§3, 부록 A·B)

2.1 접촉 (§3.1)

- 동기: 볼록 분해와 점 접촉(표 4의 대부분 벤치마크)은 분포 하중을 몇 점으로 모읍니다. 수압 탄성(Elandt 2019; Drake 구현)은 사면체 메쉬가 필요합니다. Newton은 메쉬 없이 희소 SDF에서 같은 원리를 씁니다(식 (3): 두 물체의 압력이 같은 면).

- 압력 법칙 식 (4): p = k_h [−φ]+ *(기본 선형). 식 (5): p = k_h x (1 + β (x/ℓ)²), β ≥ 0, x = [−φ]+*. β = 0이면 선형으로 돌아갑니다. 깊이에 따른 강성 증가를 넣은 확장입니다. 소성, 크리프, 측면 팽창은 모델에 없습니다(§A.2).
- 지면 접촉 식 (6): 무한 평면에는 SDF를 두지 않고 패치를 2차원 구적으로 적분합니다. 바퀴의 미끄럼 속도가 바퀴 폭 방향으로 달라지므로 패치 압력이 필요하다고 설명합니다.
- 힘과 모멘트 식 (7). 마찰 식 (8): $\mu(v) = \mu_s [r + (1 - r) e^{-v/v_c}]$. 정지 마찰은 μ_s, 빠른 미끄럼에서는 $r \mu_s$로 줄어듭니다. 이 식은 r = 1이면 쿨롱 마찰로 돌아갑니다.
- 감쇠: Hunt-Crossley 형태 f_n = K δ [1 − α v_n]_+(α는 s/m, v_n > 0은 분리). 접촉이 깊을수록 같은 접근 속도에서 감쇠가 커지고, 힘은 음수가 되지 않습니다.
- 솔버: CDMM(Constrained Dynamics via Method of Multipliers)의 원시(운동)-쌍대(접촉 반력) 반복. 접촉 블록 전처리, 충돌 간격 재샘플링에 따른 임펄스 웜스타트, 하위 단계 분할을 씁니다(§3.1.2, §A.2).
- 검증 근거: (a) 손가락 끝 패치 마찰 반경은 같은 법칙의 수치 구적과 비교(그림 5a, d), (b) 손가락 하중·제하 루프에서 감쇠가 침입 깊이에 따라 커지는지(그림 5b, e), (c) β에 따른 힘 곡선(그림 5c, f), (d) 바퀴 폭에 따른 요(yaw) 이득 감소(그림 6). 모두 **수치 기준과의 비교**이며 하드웨어 측정이 아닙니다(§6.1).
- 배터리 들기 비교(표 5): CDMM 20/20 성공, MuJoCo 반복 15회 1/20, 100회 0/20. 시간 간격 4개 × 5회씩이라 방법당 20회입니다. **단서:** 파지 자세와 목표값을 CDMM으로 튜닝했다고 적혀 있습니다(§3.1.2 본문). 이 비교는 솔버만의 효과를 분리하지 못합니다.

2.2 촉각 (§3.1.3, §A.4)

- 피부 안의 자석이 접촉 압력으로 옮겨지고(식 (9)의 Green 함수 형태 중첩), 홀 센서 값은 쌍극자 장(식 (10))으로 계산합니다.
- 접촉 패치에서 나온 하중 분포를 쓰므로 같은 순 하중이라도 패치 모양이 다르면 다른 판독이 나옵니다(그림 8, 그림 9). 그림 9는 같은 1 N 하중의 세 프로브가 다른 판독을 낸다는 **정성 예시**입니다. 측정과 비교하지 않았습니다.
- 결합은 한 방향입니다. 복원된 변형은 충돌 기하나 동역학으로 되돌아가지 않습니다.

2.3 상태를 가진 액추에이터 (§3.2, 부록 B)

- 모터 전기식 식 (11): L di/dt = V − R(T) i − k_e ω_m, τ = k_t i. 전류와 전압 한계, 열 상태(구리 손실, 권선 온도) 포함.
- 전달 기구는 기하 변환 식 (12): θ_m = φ(q), r(q) = dφ/dq, I_ref = I_r r(q)². 오프셋 슬라이더-크랭크 예시로 관절 위치에 따라 토크와 반사 관성이 달라짐을 보입니다.
- 마찰은 LuGre 모델(bristle 상태)입니다. 저속 미끄럼 전·미끄럼 중 전환과 반전을 설명하려고 추가했습니다.
- 암묵(implicit) 결합 식 (13): M_aug = M + diag(I_ref) + h D_act + h² K_act. 제어기 이득, 수동 스프링, LuGre 강성 근사가 관절 임피던스로 들어갑니다.
- 단일 작용 유압 손가락의 예(그림 10): 구동은 한쪽 방향으로만 힘을 냅니다. 모델은 chamber 힘 상태를 씁니다.
- 텔레메트리 식 (14): $\hat{\tau} = a_\tau \eta r(q) k_t \hat{\imath} + b_\tau + \varepsilon_\tau$. 전류 기반 추정은 내부 마찰 때문에 실제 관절 토크와 다릅니다. 보정 오차와 Ornstein-Uhlenbeck 잡음도 넣었습니다.
- 비교(표 6): LIBERO, RoboCasa365, ManiSkill3는 "이상적 토크 또는 PD 구동, 내부 상태 없음"입니다. 이 점이 HOLIDAY-SIM의 차별점입니다. 다만 **모델 파라미터가 어떤 실물 장치에 맞춰졌는지 논문에 없습니다.**

3. 에이전트 월드 (§4)

3.1 자산 생성 ERIS (§4.1)

- 과제 지시에서 LLM이 타입 있는 제약 집합을 뽑고, 결정론적 식 (15)로 세 분기 중 하나를 고릅니다. 메쉬(MESH: 텍스트→이미지→3D 메쉬), 코드 강체(CODE-RIGID: Blender 프로그램), 코드 관절(CODE-ARTICULATED: 관절 선언 포함).

- 검증 단계(표 7): 적합성(conformance), 충돌체(collider: SDF 해상도, 충실도, 배치 보존), 관절(articulation), 상호작용(interaction: 삽입, 굴림, 운반, 보유). 단계 적용 여부는 분기에 따라 다릅니다(표 8). 한 라운드 안에서 모든 단계를 끝까지 돌려 위반을 한꺼번에 피드백합니다.
- 충돌체 목적 식 (16): min M_SDF(Π, Δ_vox) 제약은 FSDF. 라운드 중 SDF를 구운 뒤 22% 콜라이더가 재작성되었습니다(표 12).
- 수정 식 (17): X_{t+1} = F_b(X_t, R, C⁻, C⁺). 성공한 제약 C⁺를 함께 주어 후퇴를 막습니다.

실험(§4.1.5, 부록 C):

- 분기 선택(표 10): 시각 충실도는 메쉬가 VLM 판정 80%(60건), 코드는 0%. 치수·구조 항목은 코드가 100%, 메쉬는 0-37.5%. 다만 60건은 **자산 30개를 두 번씩 판정한 것**이라 독립 표본이 30개입니다. 판정자는 claude-fable-5-1입니다.
- 첫 라운드 검증 실패(표 11): 72개 중 34개(47%) 탈락. 적합성이 주원인(28개, 고유 실패 24개).
- 수정 피드백(표 13, 32개, 같은 1차 자산): 1차 실패 12개 중 E RIS는 11개를 한 번에 고쳤고 나머지 1개도 두 번째 라운드에서 고쳐 Success@3 = 32/32. 독립 재생성 27/32(84%), 거친 피드백 26/32(81%).
- 백본 5종(표 14): 20과제 × 2회, 40쌍. E RIS가 독립 재생성보다 Success@4를 25-35 pp 높임. 예: opus 26/40 → 40/40.
- 생성 효율(표 15): 해결당 라운드 3.81(독립) → 1.70(E RIS), 해결당 비용 $5.00 → $2.48. 라운드당 비용은 오히려 늘었습니다.

3.2 장면 생성 ISG와 배경 (§4.2, 부록 D)

- 알고리즘 1: 과제 계획 Γ(예측 상태 그래프, 1차 검사 + 계획 비평가, 점수 ≥ 0.8 필요)와 장면 명세 Ŝ(자산 선택, 변형 해석, 정적 검사, 장면 비평가)를 순서대로 검증합니다. 정적 기준: 겹침 5 mm 이하, 지지 여유 1 cm 이하. 계획 검사는 술어 상태 10^4개까지만 탐색하므로 식 (18)의 전칭 조건을 **완전히 보장하지 못합니다**(논문도 인정).
- 피드백 효과(그림 14 우): 시도 5회 안의 성공이 gpt-6-astra 3/9 → 9/9, gpt-6.1-sol 2/9 → 7/9. 합치면 5/18 대 16/18입니다. 계획 검사 생략(그림 14 좌): 전체 검사를 통과한 후보가 1/10 대 5/10.
- 비평가 의존성(표 17, 그림 15): 같은 후보를 다른 비평가로 평가하면 장면 수용률이 달라집니다. 공통 비평가 opus에서 gpt-6.1-sol과 sonnet 모두 3/10으로 같습니다.
- 병목(표 19): 예산을 두 배로 늘려도 자산 부족이 대부분 실패의 원인입니다. 어포던스를 프롬프트에 적은 것만 수용 2/10을 늘렸습니다.
- 배경(§4.2.2, 부록 D.2): 파노라마 → 가우시안 스플랫. 독점 서비스(World Labs 계열)와 공개 체인 두 경로. 블라인드 VLM 판정은 독점 배경을 18번 비교에서 모두 선택, 평균 2.85 대 1.78(5점). 논문은 "두 배경 모두 사용 가능 수준은 아니다"라고 적었습니다. 배경은 관측 모델 O_s에만 들어가고 물리 F_{s,ℓ}은 바뀌지 않습니다(그림 17의 아홉 장).
- 공정 논리(§4.2.3): 효과, 이벤트, 큐, 유휴 목표의 네 종류. 스키마 검증만 하고 **의도한 공정을 구현했는지는 확인하지 않습니다.**

3.3 평가 생성 (§4.3, 부록 E)

- 에이전트가 과제·장면에 대해 모호한 점을 질문하고, 사람이 확인한 제안(작업, 지표, 루브릭)을 결정론적 컴파일러가 실행 가능한 평가로 바꿉니다. 모델 호출 없이 이뤄집니다.
- 세 가지 검사(표 21): 정적, 리셋(4 s 자유 물리), 유휴(로봇 제어 없이 실행). 이 검사로는 **과제 의도**를 판정할 수 없습니다(논문도 인정).
- 실험(그림 19, 표 43): 단일 tote 이송 한 과제, 모델 4종 × 3시행, 기록 15개(성공 4, 실패 11) 대조. 직접 생성 수용 6/12 → 검증 피드백 후 12/12. 질문 유도 생성은 10/12, 피드백 후 11/12. **질문 유도 생성은 15개 기록과 모두 일치**했지만, 시뮬레이션 사용자가 고정된 과제 의도 명세로 답합니다. 즉 의도 명세가 사용자 쪽에 들어 있어 순환성이 있습니다.
- 검증 피드백은 판정을 한 번도 바꾸지 못했습니다("does not correct any of the 21 misclassified recording pairs").

4. 24/7-BENCH (§5, 부록 F)

4.1 과제 (§5.1, 표 22-23)

과제	작업(job) 한 번	이전 작업이 남기는 상태	공정 논리(§4.2.3, §5.1)
컨베이어 적재	팔레트의 tote를 집어 벨트에 세우고 X선 입구 진입까지	스캔 후 tote가 팔레트로 돌아감	벨트 1, 큐 1
플로우랙 적재	스택의 용기를 통로를 거쳐 레인에 세움	레인 채움	벨트 3, 큐 1
카트 밀기	적재 카트를 도크 상차 데크까지 밂	카트와 도크 상태	없음(고정된 초기 집합에서 시작)
지그 적재	트레이의 지그를 벤치 지그에 끼우고 빈 지그를 보관	보관된 지그	없음(고정된 초기 집합)
프레스 작업	2손 제어로 프레스를 가동하고 찍힌 부품을 배출	출력 부품	이벤트 5
밸브 조작	입구 쪽에서 비커를 채우고 출구 쪽 밸브를 잠금	채워진 비커	없음(고정된 초기 집합)
바코드 분류	바코드를 스캔해 벨트 끝에서 목적지 tote로	목적지 tote	벨트 1, 이벤트 2

- 평가 구조: 작업 정의는 특권 시뮬레이터 상태에 대한 이벤트 집합입니다(표 23). 이벤트는 술어가 K_hold 스텝 연속 참일 때 발생(식 (19): r_t = b_t (r_{t−1} + 1), e_t = 1[r_t = K_hold]). 작업이 끝나면 완료, 실패 이벤트, 시간 초과, 실행 종료에 의한 검열 중 하나입니다.
- 장면 변형(scene variant)이 평가 단위이고, 배경만 다른 변형은 F_{s,ℓ}을 공유합니다(§5.3).

4.2 지표와 루브릭 (§5.2-5.3)

- 처리량: 3600 N_done / T_run(작업/시간, T_run은 초). 지연은 완료 작업만 보고하면 쉬운 작업 쪽으로 편향될 수 있어, 미완료는 Kaplan-Meier형 검열, 실패는 경쟁 위험(Fine-Gray)으로 다루겠다고 합니다. 논문은 이 추정량을 **실제로 계산하지는 않았습니다.**
- 모터 에너지: 모터 단자 전력의 인출·회생 에너지와 작업당 인출 에너지(실패 시도 포함). 계산과 센서 부하는 제외.
- 루브릭: 목표 작업 수 N_goal 도달, 시간 한계, 비활동 한계. 통과(식 (45))는 실패·시간 초과·정지·위반이 없을 때만.
- 검증(§5.2.3): 과제 6개(컨베이어 적재 제외)에 대해 영역 검사 185개, 시작 상태 탐침 20개, 스크립트 궤적 32개. 모두 기대 결과와 맞았다고 보고합니다. 이는 **이 평가 정의가 테스트한 사례에 맞는다**는 뜻이지 정책 성능이나 과제 완전 포괄을 뜻하지 않습니다(논문도 명시).
- 비교 원칙(§5.3): 같은 변형, 같은 초기 조건 분포에서 여러 정책을 비교하고, **실행(run)을 통계 단위**로 씁니다. 작업들이 상태를 물려받기 때문입니다(§6.6도 같은 말을 합니다).

4.3 결과

- **정책 결과 없음.** 표 21(검사)과 그림 21(채점표 모양, 개략도)만 있습니다. 그림 21 왼쪽의 프레스 주기 기록도 "개략도"로 표시된 예시입니다.
- 평가 실행의 반복 횟수, 시드 수, 신뢰구간은 제시되지 않았습니다.

5. 논의와 한계 (§6, §7)

저자들이 스스로 든 한계를 그대로 옮기면 다음과 같습니다.

1. **물리 모델의 실물 검증 없음**(§6.1): 접촉·액추에이터·센서 모델은 "명시된 동작"과만 비교했습니다. 물리 세부 사항이 정책 순위를 바꾸는지는 **측정되지 않았습니다**.
2. **자동 검증의 한계**(§6.2): 장면 수용은 비평가에 따라 달라지고, 평가 검사는 의도를 보지 못합니다. 라벨 없이는 검증 피드백이 판정을 고치지 못했습니다.

3. **장면 다양성 미측정**(§6.3): 생성 장면이 다양한지는 정의만 있고 정량화하지 않았습니다.
4. **코딩 에이전트 의존**(§6.4): 파이프라인 구성 요소의 필요성은 에이전트 버전마다 다시 검증해야 합니다. 생성 세계는 에이전트와 하니스 버전에 묶입니다.
5. **학습된 평가자 감독**(§6.5): 물리가 준 작업 기록을 진행률 감독으로 쓸 수 있다고 제안하지만 실험은 없습니다.
6. **통계적 신뢰성**(§6.6): "정책 두 개를 구별하려면 실행을 몇 번 해야 하는지는 알 수 없다"고 적었습니다. 이 분석의 토이(`analysis/power_toy.py`)가 이 질문을 조금 채웁니다(`03` §4).

추가로 분석에서 확인한 한계:

- 생성 실험은 대부분 **작은 표본**입니다(n = 3-40). 많은 비교가 쌍 설계인데 쌍 정보를 공개하지 않았습니다.
- 여러 실험이 같은 과제·같은 모델 기반이라 일반화 범위가 좁습니다. 평가 생성은 과제 1개, 기록 15개입니다.
- 로봇은 FRIDAY 하나입니다.
- 공식 코드, 자산, 장면 파일이 공개되지 않았다는 근거는 §6의 "open-source ecosystem" 문장뿐이고 **공개 링크는 없습니다**(`02` §4).

6. 부록에서 확인한 세부 사항

- 부록 A.3: 손가락 패치 마찰 설정(k_h = 10^8 N/m³, μ = 0.6, SDF 복셀 0.5 mm, 반복 128회, $\alpha = 10^{-6}$ s/m). 기준 반경 4.71, 5.07, 5.57 mm.
- 부록 E.3: 생성 실험의 "반복"은 **무작위 시드가 아니라 반복 모델 호출**이라고 명시합니다. 평가 생성 1회 실패 시 입력 토큰 247,042개.
- 부록 F.1: 노동 관련 수치(표 45)는 국가별 통계를 합친 것이며 **가중치를 두지 않았다**고 적었습니다.
- 부록 D.1.2 & 표 31: ISG 실험은 작업 계획 없이 장면 명세만 평가하는 설정과 전체 ISG를 구분합니다.

7. 출처 표기

- 본문 인용 문헌은 논문 참고문헌을 따릅니다. 이 분석에서 외부 문헌은 확인하지 않았습니다.
- 논문 그림은 Fig. 1 한 장만 개인 리포트에 넣었습니다(arXiv 비독점 배포 라이선스, `04` §5).

HolidayFactory 1.0: 선행연구, 대안, 이 저장소와의 관계

확인 날짜: 2026-11-12. 논문 인용은 arXiv:2611.11789v1의 참고문헌 목록과 본문에 따랐습니다. 인용된 논문은 이 분석에서 따로 읽지 않았습니다.

1. 선행연구 계보

논문이 자기 위치를 정하는 축은 세 가지입니다.

(a) 시뮬레이션 벤치마크: 가정이 가정

- 가정 환경: BEHAVIOR-1K(가정, 50개 과제), RoboCasa365(주방, 365개), LIBERO(탁상, 130개), ManiSkill3(탁상·실내), RoboTwin 2.0(양손 탁상, 50개), HumanoidBench(휴머노이드). 모두 **에피소드가 리셋에서 시작**합니다(논문 표 3).
- 산업 쪽: Factory(Narang 2022)가 유일하게 조립 셀을 다룹니다. 그러나 점 접촉이고 압력 패치가 없습니다(§3.1.1).
- 물리 쪽: 표 4의 대부분은 볼록 분해 + 점 접촉입니다. 표 4에서 LIBERO·RoboCasa365·HumanoidBench는 MuJoCo의 Newton 솔버(엔진 Newton과 무관)를 쓰며 "컴플라이언트 점 접촉"입니다.

(b) 접촉 물리: 수압 탄성과 촉각 시뮬레이션

- Elandt 2019(수압 탄성 원리), Drake 구현(Tedrake 2019, Masterjohn 2022): 사면체 메쉬 기반.
- Newton(The Newton Contributors 2025): 희소 SDF에서 같은 원리. 논문은 Newton을 "오픈소스 GPU 물리 엔진, NVIDIA Warp 기반"이라고 씁니다.
- 촉각: HydroShear(Dang 2026, RSS 2026): 접촉 패치 기반 전단 시뮬레이션. HOLIDAY-SIM의 자기 촉각 모델은 그 식(Hall 센서 중첩)을 따른다고 씁니다(§3.1.3).
- 액추에이터: 표 6 비교에서 "내부 상태 없음"이 일반입니다. 논문은 이 점을 자기 기여로 둡니다.

(c) 리셋 없는 학습과 반복 평가

- Sharma 2022, 2023; Wu 2026(리셋 없는 강화학습). Hao 2026(재시도 실패). Mahler 2019(Dex-Net 4.0 처리량 300 picks/h). 논문은 이들을 "연속 작업 문제"의 선행으로 씁니다.
- 실제 로봇 평가 대안: real-to-sim 재구성(Torne 2024; Han 2026; Jiang 2026; Wang 2026b). 논문은 이 방법이 **현장 접근과 촬영 세션을 요구한다**고 봅니다.
- 통계: 평가 구간 권고(Agarwal 2021), 군집 강건 추론(Cameron & Miller 2015), 순차 검정(Snyder 2025, 2026). 실행을 단위로 쓰라는 내용은 이 분석의 토이와 같은 방향입니다(`03` §4).

(d) 절차적·에이전트 장면 생성

- 절차적 생성(Deitke 2022; Raistrick 2024), LLM 레이아웃(Feng 2023; Yang 2024b), 에이전트 생성 장면과 물리 검사(Xia 2026 SAGE, CVPR 2026; Pfaff 2026; Wang 2026a). 논문은 이들 대비 **검증을 생성 루프 안에 넣는다**는 점을 차별점으로 둡니다(§4.1.3, §4.2.1).
- 생성 피드백 루프(Madaan 2023; Li 2026): 자가 개선 방식.
- 평가 보상 생성(Ma 2024; Xie 2024b; Yu 2023): 생성 보상이 **실제 성능 지표와 다를 수 있다**는 지적을 논문도 인용합니다(§4.3).

2. 가까운 대안과 차이 (논문 표 3-4 기준, 요약)

축	대표 벤치마크	이 논문의 주장	확인된 차이
실행 형식	에피소드(리셋)	작업 반복, 장면 상태 유지	실제 정책 비교 없음
접촉	볼록 분해 + 점 접촉	수압 패치, CDMM 솔버	측정 대비 검증 없음
액추에이터	이상적 토크·PD	전기·열·마찰 상태	파라미터의 실물 근거 없음
과제 생성	사람이 작성	에이전트가 자산·장면·평가 생성, 사람 확인	생성 가능한 작업장 중 벤치마크에 든 것은 7개뿐(§5.1)
평가	성공률	처리량, 지연, 실패·미완료, 에너지	추정량 계산 결과 없음

3. 이 저장소의 다른 분석과의 연결

이 논문을 읽을 때 참고할 다른 폴더입니다. 각 폴더의 결론은 해당 `README.md`에서 가져왔습니다(확인: 2026-11-12, 읽기만 함).

- **`contactbench/`** (ContactBench 1.0, arXiv:2610.24512): 접촉 과제 벤치마크, 정책 6과제 × 30회 설계. 본 분석 `03` §4의 검정력 토이와 같은 질문("벤치마크가 얼마나 많은 시행을 있어야 차이를 구별하나")을 다룹니다. 그 분석에서 30회 설계는 36 pp 이상 차이만 잡았습니다. HolidayFactory의 24/7-BENCH는 시행 수 자체를 정하지 않아서 이 계산이 직접 쓰입니다.
- **`insertion_wm/`** (Generalizable Robotic Insertion with World Models, arXiv:2609.28258): 조립 삽입. 이 논문의 "끼워 맞춤 정밀도" 요구(표 7의 상호작용 단계, 삽입 검사: 최종 자세가 공차 안에 드는지)와 맞닿습니다. 그 분석은 객체 단위 분산을 반영한 검정과 CPU toy를 했습니다.
- **`contact_disassembly/`** (CONTACT, arXiv:2603.08560): 촉각 분해 정책. 촉각 영상 대 촉각 힘장 비교. HolidayFactory의 촉각 피부 모델(§3.1.3)은 **시뮬레이션에서 촉각 판독을 만드는 방식**이라 그 분석의 "촉각 입력 비교"와 다른 축입니다. 실물 촉각 검증이 없다는 점은 같습니다.
- **`robosimstudio/`** (RoboSimStudio, arXiv:2610.18835): Newton 기반 도구에서 사람과 코딩 에이전트가 솔버, 접촉 모델, 물성을 함께 고쳐 Real2Sim을 하는 방식. HolidayFactory의 에이전트 장면·자산 생성과 같은 엔진 생태계(Newton)를 씁니다. 두 논문 모두 "에이전트가 시뮬레이션 설정을 바꾼다"를 다루지만, RoboSimStudio는 사람이 상호작용하는 도구이고 HolidayFactory는 검증 루프를 자동화한 파이프라인입니다.
- **`openwam/`** (OpenWAM, arXiv:2609.07398) 과 **`agentic_wam/`** (AW-0, arXiv:2610.30136): 세계-행동 모델. 평가 쪽에서 RoboDojo나 RoboTwin 같은 시뮬 벤치마크를 씁니다. 이 논문과는 "시뮬 평가를 믿을 수 있는가"라는 공통 질문이 있습니다. 직접 비교 대상은 아닙니다.

4. GitHub, 프로젝트 사이트, 자산 확인 (2026-11-12)

대상	무엇인가	라이선스	상태
github.com/Holiday-Robotics (조직)	조직 계정	—	**공개 저장소 0개** (`gh api orgs/Holiday-Robotics`, public_repos = 0).
holiday-robotics.com (프로젝트 사이트)	논문 바닥글의 사이트	—	코드·자산·데이터 링크 없음. 보고서 링크는 arXiv abs뿐
newton-physics/newton	상류 물리 엔진(SDF 접촉의 기반)	Apache-2.0	★5,944, 최근 push 2026-11-11
NVIDIA/warp	Newton의 기반 라이브러리	Apache-2.0	★7,302, 최근 push 2026-11-11

대상	무엇인가	라이선스	상태
`gh search repos "HolidayFactory"`, `"24/7-B"`, `"HOLIDAY-SIM"`	검색 결과 없음	—	2026-11-12

- 논문 본문의 URL은 holiday-robotics.com(바닥글), Newton, Warp, 표준 기관 자료뿐입니다. 공식 코드 링크는 없습니다.
- 따라서 **클론한 공식 코드는 없습니다.** `repo/`는 만들지 않았습니다. 정적 대조도 하지 않았습니다(`04`는 주장 검증 문서입니다).

5. 이 분석에서 쓰지 않은 것

- 논문 참고문헌 목록의 개별 논문(코드·결과를 재확인하지 않음).
- IFR 통계(논문 표 45 인용), Eurostat·BLS 등 노동 통계.
- 논문 TeX 원본(arXiv 소스). PDF로 충분했습니다.

HolidayFactory 1.0: 수치 재계산, 유의성, 유도, 토이

재현 스크립트: `analysis/table_check.py` → `table_check_results.json` (1초 미만), `analysis/power_toy.py` → `power_toy_results.json` (약 1초, numpy·scipy 단일 스레드), `analysis/plot_figures.py` → `report/figures/hf_*.png`. 모두 CPU에서 돌렸습니다(`.venv` Python, `-I`).

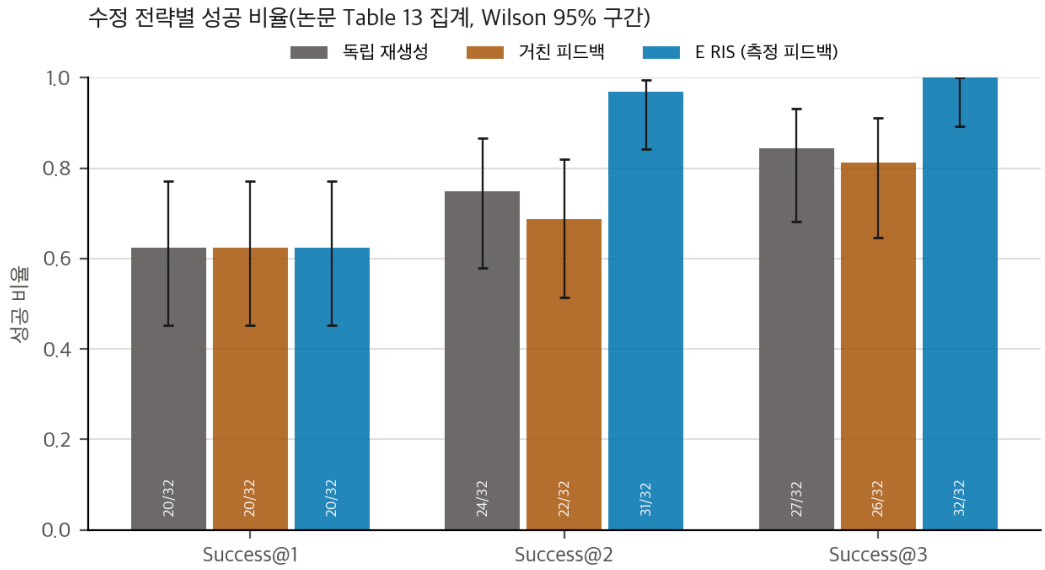
0. 분석 가능한 범위

- 논문은 **집계 값만** 보고합니다. 작업별 결과, 실행별 결과, 쌍(paired) 구조의 불일치 수는 없습니다. 쌍 검정은 불일치 수를 알아야 하는데 일부만 구할 수 있습니다. 그래서 실현 가능한 모든 분할에 대한 정확 McNemar p의 **최솟값과 최댓값**을 구간으로 보고합니다(§2).
- 표본은 대부분 작습니다. 표 13은 32개, 표 14는 40쌍, 그림 19는 12건(모델 4 × 3시행), 표 5는 방법당 20회.
- 정책 결과가 없으므로 **24/7-BENCH의 정책 순위나 차이에 대한 검정은 불가능합니다.** 대신 §4의 토이로 "실행 수를 얼마나 잡아야 하는가"를 물을 수 있습니다.

1. 표·본문 수치 재계산: 내부 일치 확인

점검	논문 값	재계산	판정
표 11 탈락률	34/72(47%), 28/72(39%), 10/72(14%)	47.2%, 38.9%, 13.9%	일치
표 11 고유 실패	24 + 4 = 28	탈락 34 중 6개는 여러 단계	일치(모순 없음)
표 12 콜라이더 재작성	346/1597(22%), 39/72(54%)	21.7%, 54.2%	일치
표 13 Success@2·@3	0.75, 0.84 / 0.69, 0.81 / 0.97, 1.00	1차 20/32 + 회복 분자로 24/32, 27/32 / 22/32, 26/32 / 31/32, 32/32	일치
표 13 회복	4/12, 2/12, 11/12, 3/8, 4/10, 1/1	분모가 1차 실패 수와 맞음	일치
표 14 Δ	+0.35, +0.25, +0.30, +0.35, +0.33	(E − R)/40 = 0.35, 0.25, 0.30, 0.35, 0.325	일치(반올림)
표 10 시각 판정	80%(60건 중 48)	48/60 = 80%	일치. 단 자산 30개의 중복 판정
표 15 시도 수	1회 시도 2.22 × 18해결	39.96 ≈ 40 라운드	일치
표 15 해결당 비용	$5.00 → $2.48	0.496배	일치. 라운드당 비용은 $1.31 → $1.46로 증가
서론 독립 연속 성공	95% → 36%, 99% → 82%	0.3585, 0.8179	일치
표 5 시행 수	4개 간격 × 5회	20회	일치
표 45 합계	5개 지역 합 519,100	서론의 "2025년 600,000대 이상"과 비교 가능한 정의가 아님	주석만

판정: **표 사이 수치는 모두 맞습니다.** 빠진 것은 원자료뿐입니다.



그래프: 표 13 집계. 수정 전략별 Success@t와 Wilson 95% 구간(n = 32, 같은 1차 자산). 2라운드와 3라운드 차이는 쌍 설계라 구간만으로 판단하지 않는다(§2).

2. 유의성 검정 (집계 값, 쌍 구조는 범위 제한)

비교	자료	검정	결과	해석
표 5: CDMM 대 MuJoCo(15회)	20/20 대 1/20	Fisher 양측	$p = 3 \times 10^{-10}$	차이는 크지만 튜닝 교란(파지·목표가 CDMM 기준). 솔버 효과로 읽으면 안 됨
표 5: CDMM 대 MuJoCo(100회)	20/20 대 0/20	Fisher 양측	$p = 1 \times 10^{-11}$	같은 단서
표 13: E RIS 대 독립, Success@3	32/32 대 27/32, 쌍	정확 McNemar	p = 0.0625 (b = 5, c = 0 **고정**)	불일치 수가 5/0으로 정해짐. 유의수준 0.05에서 **유의하지 않음**. 헤드라인 "100% 대 84%"는 작은 표본
표 13: E RIS 대 거친 피드백	32/32 대 26/32, 쌍	정확 McNemar	p = 0.031 (b = 6, c = 0 고정)	유의
표 13: 회복률 1차	11/12 대 4/12	Fisher	p = 0.0094	1차 실패 12건만의 비교. 가장 강한 증거
표 13: 독립 대 거친 피드백	27/32 대 26/32	쌍 McNemar	p 범위 1.0	차이 없음
표 14: 백본별 E RIS 대 독립	40쌍	정확 McNemar, 가능한 분할 전체	opus p = 0.00012(고정); fable 0.0020-0.013; astra 0.0005-0.004; sol 0.0001-0.0026; luna 0.0002-0.035	과제 20개가 군집. 쌍을 독립으로 본 p는 과장될 수 있음
그림 19: 직접 생성 수용 대 피드백	6/12 대 12/12	Fisher	p = 0.014	시행을 독립으로 본 근사. 모델과 시행이 3회씩
그림 19: 직접 대 질문(피드백 없음)	6/12 대 10/12	Fisher	p = 0.19	질문 유도 효과는 이 자료로 유의하지 않음
그림 14: 생성-검증 대 피드백	5/18 대 16/18	Fisher	p = 0.0005	시도 5회 성공. 모델 두 개(각 9시행)의 합

비교	자료	검정	결과	해석
그림 14 좌: 계획 검사 생략 대 전체	1/10 대 5/10	Fisher	p = 0.14	방향은 맞지만 유의하지 않음
표 17: 장면 수용, 각자 비평가	sol 1/10 대 sonnet 7/10	Fisher	p = 0.020	계획자와 비평가가 한 모델군 → 교란 가능
표 17: 공통 비평가 opus	sol 3/10 대 sonnet 3/10	—	같음	비평가가 수용률을 정하는 쪽의 근거

요약: 강한 결과는 **표 13의 회복률(1차 실패 12건)**, **표 14의 백본별 쌍 차이**, **그림 14의 피드백 효과**, **표 5의 튜닝 대비 차이**입니다. 표 13의 Success@3 차이와 그림 14 좌, 그림 19의 질문 유도 효과는 유의하지 않습니다. 논문 본문도 "더 많은 과제와 실행이 필요하다"는 식으로 말하지만, 헤드라인 문장(예: "100%")에는 불확실성이 빠져 있습니다.

3. 유도와 점검

3.1 압력 법칙과 감쇠 (식 (4), (5), (8))

- 식 (5)를 $p(x) = k\,x\,(1 + \beta\,x^2/\ell^2)$로 쓰면 $p(0) = 0$, $p'(0) = k$(초기 기울기), $p'(x) = k(1 + 3\beta\,x^2/\ell^2) \geq 0$입니다. 따라서 $\beta \geq 0$이면 압력은 깊이에 따라 단조 증가하고, $\beta = 0$이면 식 (4)의 선형 법칙으로 돌아갑니다. 논문 식과 일치합니다.
- 식 (8): $\mu(0) = \mu_s[r + (1 - r)] = \mu_s$, $\mu(v \to \infty) = r\,\mu_s$. $0 \leq r \leq 1$이면 μ는 v에 대해 감소하지 않습니다. 논문 설명(r = 1이면 쿨롱)과 일치합니다.
- Hunt-Crossley 형태 $f = K\,\delta\,[1 - \alpha\,v_n]_+$: *$v_n > 0$(분리)이면 힘이 줄고, $v_n < 0$(접근)이면 힘이 늘어납니다. $[\cdot]_+$* 때문에 힘은 음수가 되지 않습니다(인장이 없는 접촉). 논문의 "분리 속도가 빠르면 감쇠가 크다"는 설명과 부호가 맞습니다.

3.2 작업 이벤트 재귀 (식 (19))

- 논문 추출 텍스트는 $r_t = b_t\,r_{t-1} + 1$로 읽히지만, **페이지 이미지(33쪽)에서 $r_t = b_t\,(r_{t-1} + 1)$**가 맞습니다.
- 해석: 술어가 참인 연속 스텝 수를 세고 거짓이 되면 0으로 돌아갑니다. $e_t = 1[r_t = K_{hold}]$는 연속 K_{hold} 스텝마다 **한 번** 발생합니다(K_{hold}보다 길게 참이어도 정확히 한 번). 접촉 잡음이 이벤트를 만들지 않게 하는 장치입니다.

3.3 처리량과 검열

- 처리량 = $3600\,N_{done} / T_{run}$ (작업/시간, T_{run} 초). 예: 600 s에 10개 완료 = 60 작업/시간.
- 완료하지 못한 작업의 지연은 검열입니다. 완료 지연만 평균하면 쉬운 작업으로 편향됩니다(논문 §5.2.2). 이 편향의 크기는 자료가 없어서 측정할 수 없습니다.

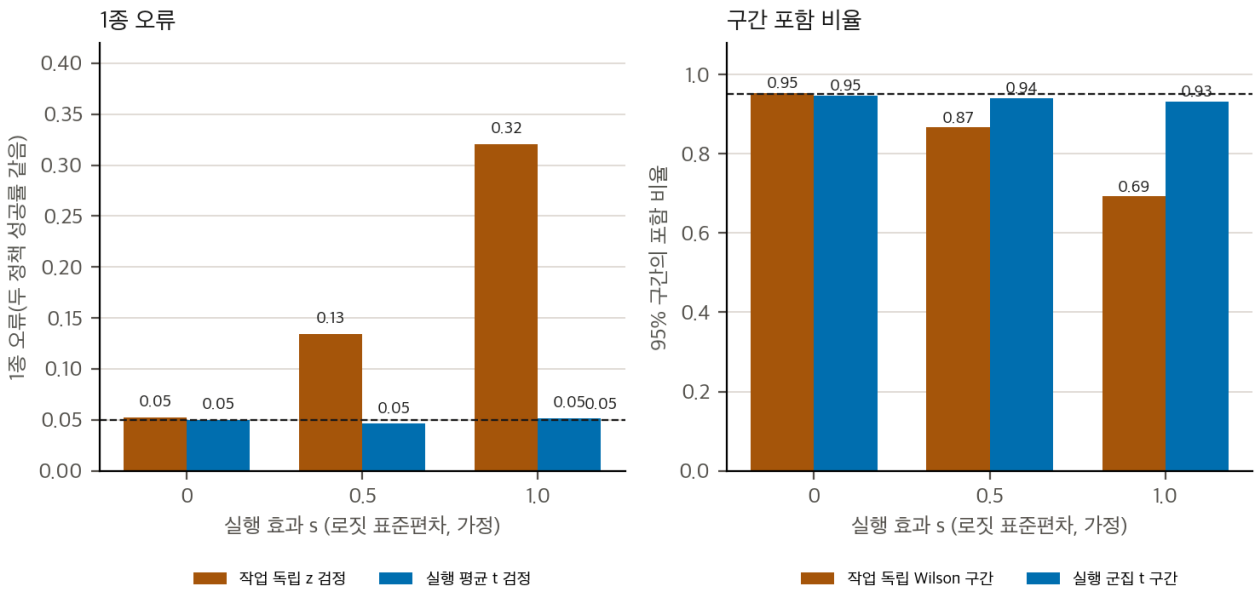
3.4 쌍 McNemar의 실현 가능 범위

- 쌍 n개에서 A가 x번, B가 y번 성공하면 $b = \#(\text{B 성공, A 실패})$, $c = \#(\text{A 성공, B 실패})$에 대해 $b - c = y - x$입니다.
- 가능한 c는 $\max(0, x - y)$에서 시작해 $b \leq n - x$, $c \leq n - y$를 만족하는 값이고, 각각의 정확 McNemar p를 계산해 범위를 냅니다. `table_check.py`의 `mcnemar_range`가 이를 구현합니다. 표 13 E RIS 대 독립은 가능한 분할이 1개뿐이라 p가 고정됩니다.

4. 토이: 작업 의존성에서의 검정 설계 (`analysis/power_toy.py`)

4.1 설정과 가정

- 실행 r의 작업 성공 확률: logit p_r = logit p_0 + s u_r, u_r ~ N(0, 1). 작업은 Bernoulli(p_r)입니다(실행 안에서는 독립, 실행 사이에 의존).
- 가정: 실행당 작업 수 M = 20, 기준 성공률 p_0 = 0.80, 실행 효과 s ∈ {0, 0.5, 1.0}, 차이 Δ ∈ {0, 0.05, 0.10}, 정책당 실행 수 R ∈ {3, 5, 10, 20, 40, 80}, 시뮬레이션 4000회, α = 0.05, 양측.
- 논문에 **없는** 값입니다. 목적은 설계 원리를 보여 주는 것입니다. 실제 설계에는 파일럿 실행으로 s를 추정해야 합니다.
- 두 검정:
  - **작업 독립 검정(naive):** 작업 전체를 독립 표본으로 보는 합동 비율 z 검정.
  - **실행 검정(run):** 실행별 성공률 평균에 대한 Welch t 검정.



그래프: 토이. 작업 독립 검정 대 실행 검정의 1종 오류(왼쪽)와 95% 구간 포함 비율(오른쪽). 정책당 실행 10회, 실행당 작업 20개, 모든 값은 가정.

4.2 결과 1: 1종 오류 (Δ = 0, R = 10)

s	작업 독립 검정	실행 검정	설계 효과 1 + (M−1)ICC
0	0.053	0.050	1.00
0.5	0.135	0.046	1.75
1.0	0.321	0.052	3.73

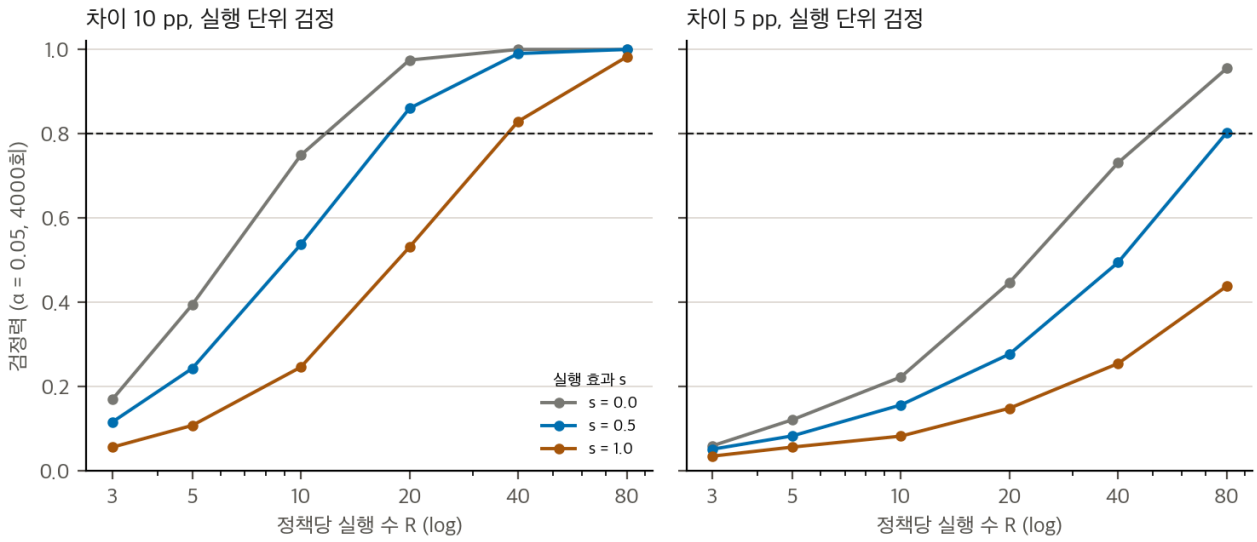
(ICC = 실행 확률의 분산 / (θ(1−θ)), θ는 주변 성공률. 설계 효과는 `ci_coverage_R10`의 값입니다.)

해석: 실행 효과가 있으면 작업을 독립으로 보는 검정은 **명목 5%의 2.7배(s = 0.5)에서 6.4배(s = 1.0)**까지 기각합니다. 실행 검정은 R = 10에서도 명목 수준을 지킵니다. 이는 논문이 "실행을 통계 단위로 써야 한다"고 한 권고(§5.3, §6.6)를 수치로 뒷받침합니다.

4.3 결과 2: 포함 확률 (R = 10, 95% 구간)

s	참값(주변 성공률)	작업 독립 Wilson 포함	실행 군집 t 포함
0	0.800	0.953	0.947
0.5	0.789	0.866	0.941
1.0	0.761	0.692	0.933

해석: 작업 독립 구간은 실행 효과가 클수록 덜 덮습니다(s = 1에서 0.69). 실행 군집 구간은 R = 10에서도 0.93 이상을 유지합니다.



그래프: 토이. 실행 검정의 검정력을 정책당 실행 수에 따라 그림. 차이 10 pp(왼쪽)와 5 pp(오른쪽). 점선은 0.8.

4.4 결과 3: 검정력과 필요한 실행 수 (실행 검정)

s	Δ = 0.10에 필요한 R (검정력 0.8)	Δ = 0.05에 필요한 R
0	20	80
0.5	20	80
1.0	40	80 초과 (R = 80에서 0.44)

R = 10에서 검정력: Δ = 0.10이면 s = 0에서 0.75, s = 0.5에서 0.54, s = 1.0에서 0.25입니다.

해석:

- 정책 간 차이가 10 pp 정도면 정책당 실행 20-40회가 필요합니다. 실행당 작업 20개(=총 400-800 작업)입니다.
- 5 pp 차이를 80%로 잡으려면 실행 80회 이상이 필요할 수 있고 s가 크면 실행 수를 늘려도 부족합니다.
- 작업 독립 검정의 높은 "검정력"(예: s = 1, R = 10에서 0.65)은 1종 오류가 0.32로 부풀려진 결과이므로 믿으면 안 됩니다.
- 이 수치는 M = 20과 p_0 = 0.8 가정에 민감합니다. 실제 설계에는 파일럿 실행으로 s를 추정한 뒤 다시 계산해야 합니다.

4.5 토이의 한계

- 실행 효과를 로짓 정규로 둔 한 가지 모형입니다. 작업 사이 자기상관(예: 같은 물체가 계속 실패)과 과제 간 이질성은 넣지 않았습니다.

- 정책 차이를 확률 차이로 넣었는데, s > 0에서 주변 성공률은 P_0 + Δ와 정확히 같지 않습니다(표의 참값 열이 이 차이를 보여 줍니다).
- 과제 7개의 순위 안정성은 계산하지 않았습니다. 논문에 정책 결과가 없어 입력이 없기 때문입니다.

5. 해석: 이 논문에 대한 평가 설계 시사점

1. **실행을 단위로**: 24/7-BENCH의 신뢰구간은 작업이 아니라 실행 단위로 잡아야 합니다(§4.4, §4.3). 작업을 독립으로 세면 구간이 좁아지고 1종 오류가 커집니다.
2. **실행 수의 요구량**: 10 pp 차이를 보려면 정책당 실행 20-40회가 필요합니다(s = 0.5-1). 논문에 실행 수가 없으므로 **지금 보고된 결과로는 차이를 판단할 수 없습니다.**
3. **쌍 설계를 쓸 것**: 같은 초기 장면과 같은 작업 공급으로 정책을 돌리면 장면 분산이 상쇄되어 필요 실행 수가 줄 수 있습니다. 논문은 "같은 분포에서 초기 조건을 뽑는다"는 원칙만 말하고 쌍 설계는 쓰지 않습니다(§5.3).
4. **생성 실험의 작은 표본**: 표 13, 14, 그림 14, 19의 대부분은 표본이 작고 쌍 구조를 알 수 없습니다. 헤드라인 수치는 구간과 함께 읽어야 합니다.

6. 추가로 필요한 자료

- 정책 결과: 같은 장면·같은 작업 공급에서 정책 2-3개의 작업별 기록(완료, 실패, 시간 초과, 지연, 에너지). 그래야 run 단위 검정과 ICC를 추정할 수 있습니다.
- 생성 실험: 시행별 결과(쌍 표). 모델 × 과제 × 시드 구조.
- 물리 모델의 실물 측정(예: 배터리 들기, 손가락 하중·제하 루프). 현재는 수치 기준과의 비교뿐입니다.

7. 그림

- `report/figures/hf_generation_revision.png` : 표 13의 수정 전략별 Success@t와 Wilson 95% 구간(n = 32).
- `report/figures/hf_dependence_error.png` : 작업 독립 대 실행 검정의 1종 오류와 구간 포함 비율(R = 10).
- `report/figures/hf_power_runs.png` : 실행 수에 따른 실행 검정 검정력(Δ = 0.10, 0.05).

HolidayFactory 1.0: 주장 검증, 공개 증거, 구현 가능성

공식 코드가 없어서 **코드 대조 문서는 만들지 않았습니다.** 대신 논문의 주장(C1-C21)을 표·본문 재계산(`analysis/table_check.py`), 내부 수식 점검, 공개 증거 확인으로 검증했습니다. 판정 기호: **확인**(수치와 해석이 맞음), **부분**(수치는 맞으나 해석이 과하거나 표본이 작음), **확인 불가**(자료가 없음), **반증**(자료와 충돌).

0. 공개 증거 확인 (2026-11-12)

항목	확인 방법	결과
공식 코드	arXiv 본문과 abs의 URL, 바닥글	GitHub 링크 없음. 논문 URL은 holiday-robotics.com과 Newton·Warp뿐
GitHub 조직	`gh api orgs/Holiday-Robotics`, `users/Holiday-Robotics`	공개 저장소 0개
GitHub 검색	`gh search repos "HolidayFactory"`, `"24/7-B"`, `"HOLIDAY-SIM"`	관련 결과 없음
프로젝트 사이트	holiday-robotics.com HTML과 JS 번들	기술 보고서 링크는 arXiv뿐. 코드, 자산, 데이터 링크 없음.
데이터·자산	본문과 부록	장면, USD, 자산, 평가 정의 파일 공개 언급 없음
라이선스	arXiv abs의 license 링크, PDF 본문	abs: **arXiv nonexclusive-distrib 1.0**. PDF 첫 쪽에 arXiv 스탬프(`arXiv:2611.11789v1 [cs.RO] 9 Nov 2026`)만 있고 저작권 문구, ©, 재인쇄 허용 문구는 전문에 없음
학회	abs의 Comments, PDF 전문 grep	없음. 프리프린트

1. 주장 검증

번호	주장(논문 위치)	근거와 재계산	판정
C1	배터리 들기에서 CDMM이 MuJoCo보다 많이 든다(표 5)	20/20 대 1/20, 0/20. Fisher $p < 10^{-9}$	**부분**. 파지 자세와 목표값을 CDMM으로 튜닝했다고 본문이 명시. 솔버 효과로 읽으면 과장
C2	수압 패치는 점 접촉이 놓치는 마찰 반경과 부드러운 감쇠를 보인다(그림 5)	수치 구적(quadrature)과 비교만 함	**확인 불가**(실물 없음). 내부 수치 기준에서는 일관
C3	바퀴 폭에 따른 요 이득 감소가 패치 접촉에서 나온다(그림 6)	그림과 기준 모델만	**확인 불가**(실물 없음)
C4	자기 촉각 판독은 같은 순 하중이라도 패치 모양에 따라 다르다(그림 9)	모델 출력의 정성 예시	**부분**. 논문 스스로 "모델 출력이며 실물과 맞는지는 보지 않음"
C5	메쉬는 시각 충실도가 높고(VLM 80%), 코드는 치수 조건을 100% 맞춘다(표 10)	48/60 = 80%(Wilson 68-88%); 0/60; 코드 100%	**부분**. 자산 30개를 두 번씩 판정(독립 30). 판정자는 claude-fable-5-1로 단일 모델
C6	측정 피드백(E RIS)이 Success@3에서 100%, 독립 84%, 거친 피드백 81%(표 13)	32/32 대 27/32 대 26/32. 쌍 McNemar 정확 $p = 0.0625$(독립), 0.031(거친)	**부분**. 헤드라인 차이는 유의수준 0.05에서 독립 대비 **유의하지 않음**. 회복률(1차 실패 12건, 11/12 대 4/12, Fisher $p = 0.009$)이 더 강한 근거
C7	측정 피드백이 다섯 백본 모두에서 독립 재생성보다 25-35 pp 높다(표 14)	쌍 40개, 차이 +25에서 +35 pp. McNemar p 범위 0.0001-0.035	**확인**(쌍 방향 일관). 과제 20개의 군집은 미반영

번호	주장(논문 위치)	근거와 재계산	판정
C8	측정 피드백은 해결당 라운드와 비용을 줄인다(표 15)	라운드 3.81 → 1.70, 비용 $5.00 → $2.48. 라운드당 비용은 증가	**확인**. 절감은 라운드 수에서 나오며 단가는 오히려 높음
C9	검증이 1차 자산의 47%를 탈락시키고, 적합성이 주원인이며, 콜라이더 22%를 재작성(표 11-12)	34/72, 28/72(고유 24), 346/1597, 39/72	**확인**
C10	피드백이 장면 명세 생성을 개선한다(그림 14 우, 표 18)	5/18 대 16/18. Fisher p = 0.0005(시행 독립 근사). 모델 두 개 각 9시행	**확인**(약함): 표본이 작고 시도 횟수를 5로 제한
C11	계획 검사를 빼면 검사를 통과한 후보가 줄어든다(그림 14 좌)	1/10 대 5/10. Fisher p = 0.14	**부분**. 방향은 맞지만 유의하지 않음. 그래서 "계획 검사가 필수"는 근거 부족
C12	장면 수용은 비평가 선택에 따라 달라진다(그림 15, 표 17)	각자 비평가 1/10 대 7/10(p = 0.020). 공통 비평가에서는 3/10 대 3/10	**부분**. 계획자와 비평가가 같은 모델군이라 교란
C13	검증 피드백은 직접 생성 수용을 6/12에서 12/12로 올리지만 판정을 한 번도 고치지 못했다(그림 19, 본문)	6/12 → 12/12, Fisher p = 0.014. 판정 개선 없음은 본문과 표 43(opus 행)에서 확인	**확인**(표본 작음: 기록 15개, 과제 1개)
C14	질문 유도 생성은 15개 기록 모두와 일치한다(§4.3.3)	표 43의 opus 행에서 FN = 0, FP = 0. 다른 모델 행은 그림 19 패널로만 확인	**확인**(부분 파싱). 시뮬레이션 사용자가 의도 명세로 답하므로 순환
C15	24/7-BENCH의 평가 정의는 테스트 사례에서 기대 결과와 맞는다(§5.2.3)	영역 검사 185, 시작 탐침 20, 스크립트 궤적 32	**확인 불가**(테스트 코드·자산 없음). 본문도 "테스트한 사례에 맞을 뿐 정책 성능이나 과제 포괄은 아님"이라 적음
C16	처리량 = 3600 N_done / T_run	식 그대로	**확인**(정의)
C17	작업 이벤트는 K_hold 연속 스텝의 참을 요구해 접촉 잡음을 거른다(식 (19))	페이지 이미지에서 식을 읽음: r_t = b_t(r_{t−1}+1). 연속 K_hold마다 한 번 발생	**확인**(식 정확)
C18	서론의 독립 연속 성공률 계산: 95%에서 36%, 99%에서 82%	0.3585, 0.8179	**확인**
C19	시뮬레이션 신뢰성은 실물 측정과 비교되지 않았다(§6.1)	본문 grep, 표 전체	**확인**(본문 인정). sim-to-real 증거 없음
C20	정책은 persistent run에서 아직 비교하지 않았다(초록, §7)	본문 grep	**확인**(본문 인정). 24/7-BENCH의 정책 결과 없음
C21	배경 생성: 독점 배경이 18/18 쌍에서 선호되고 평균 2.85 대 1.78(§4.2.2)	9 프레임 × 2 순서 = 18 산술 일치. 참조 이미지 1장, 판정 모델 1개	**부분**. 논문도 "사용 가능하지 않다"고 씀

2. 본문 내부의 모호하거나 어긋나는 부분

1. **"시드"와 "반복 호출"의 혼용**: 표 14는 "두 시드(two seeds)"라 쓰지만 부록 E.3은 생성 실험의 반복이 "무작위 시드가 아니라 반복 모델 호출"이라고 씁니다. 같은 용어를 다르게 씁니다.
2. **헤드라인 대 검정력**: 표 13의 "100%"와 "84%"가 본문 강조인데, 쌍 n = 32에서 p = 0.06입니다.
3. **튜닝과 비교의 교란**: 표 5 파지 자세와 목표값은 CDMM 기준으로 튜닝했다고 본문 §3.1.2에만 있습니다. 그림 7 설명과 초록에서는 빠집니다.
4. **자산 판정의 중복**: 표 10의 60건은 자산 30개의 두 번 판정입니다(본문 "60 judgments per generator").
5. **날짜**: PDF 첫 쪽 날짜는 November 7, 2026이고 arXiv 제출은 9 Nov 2026입니다. 사소하지만 문서 날짜는 PDF 날짜를 따랐습니다.

6. **Newton의 이름 충돌**: 표 4의 "Newton"은 MuJoCo의 솔버 이름입니다. 엔진 Newton과 다릅니다(본문 각주에 있음). 독자가 헷갈리기 쉽습니다.
7. **표 3-4의 다른 벤치마크 수치**: "기재되지 않은 값은 공개 코드와 문서를 따랐다"고 씁니다. 이 분석에서 확인하지 않았습니다.
8. **모델 이름**: claude-opus-5-5, gpt-6.1-sol 등 논문 표기를 그대로 씁니다. 이 분석에서는 이 모델을 확인하거나 호출하지 않았습니다.

3. 판정 요약

- 헤드라인 주장 중 **정책 비교, 실물 검증, 공개 코드**에 해당하는 것은 모두 본문이 "아직"이라고 인정한 부분입니다. 주장과 증거가 맞습니다.
- 생성 파이프라인의 **내부 수치**는 대부분 맞습니다. 다만 표본이 작아서 "측정 피드백이 낫다"는 방향은 지지되고 크기는 불확실합니다.
- 주장은 크게 세 부분입니다. (1) 시뮬레이터 설계(근거: 수식과 수치 기준 비교), (2) 자동 생성(근거: 작은 표본 실험), (3) 평가 프로토콜(근거: 설계 원칙, 정책 결과 없음). (3)은 이 분석의 토이로 실행 단위 검정이 필요하다는 점을 수치로 보였습니다 (`03` §4).

4. 구현 가능성 판정

결론: 공식 재현은 불가능합니다. 아이디어의 일부(평가 프로토콜)는 이 맥에서 구현할 수 있고, 물리 엔진과 자동 생성 파이프라인은 이 맥에서 현실적이지 않습니다.

구성 요소	공식 재현	이 맥(Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, `.venv` 에 torch·mujoco)	노력(추정, 검증 안 함)	필요한 자원
HOLIDAY-SIM 접촉(수압 패치, CDMM 솔버)	**불가**: 코드 없음	새로 짜는 것은 CPU로 가능하나 Newton 수준의 SDF 충돌과 솔버를 맞추는 일이 큼	수개월(추정)	Warp/Newton 지식, GPU 권장
상태 액추에이터(전기·열·LuGre·기하 전달)	**불가**: 코드 없음	CPU 가능. 식 (11)-(14)은 단순한 상미분 방정식	1-2주(추정) 기초 모형	없음
자기 촉각 센서 모델	**불가**	식 (9)-(10)은 CPU 가능	수일(추정)	없음
에이전트 자산 생성 ERIS	**불가**: 코드·프롬프트 없음, LLM 호출 필요	**불가**: API 호출 금지 조건(사용자 승인 없음)	—	LLM API
장면·계획 생성 ISG	**불가**	**불가**: 같은 이유	—	LLM API, 자산 카탈로그
배경 생성(Gaussian splat)	**불가**: 독점 서비스 사용	불가	—	외부 서비스, GPU
FRIDAY 로봇 모델(USD)	**불가**: 미공개	불가	—	제조사 자료
24/7-BENCH 7개 과제 장면과 평가	**불가**: 장면·평가 파일 미공개	평가 정의를 직접 쓰는 것은 가능(작업 이벤트, 처리량, 실행 단위 검정)	수일(추정)	과제 장면 제작
평가 프로토콜 토이(작업 의존, 실행 검정)	— (논문에 없음)	**가능**: `analysis/power_toy.py` 가 1초 내 실행	완료	numpy, scipy
실물 검증	**불가**	**불가**: FRIDAY 없음	—	휴머노이드 하드웨어

- 맥 특이 사항: 논문 엔진은 GPU 병렬 인스턴스(Nenv)를 전제합니다. 이 맥은 CUDA가 없어 Warp GPU 경로를 쓸 수 없습니다. Warp의 CPU 경로가 macOS에서 되는지는 **확인하지 않았습니다**(설치 승인 전).
- 상류 Newton(Apache-2.0, ★5,944, 2026-11-11 push)이 SDF 기반 hydroelastic 접촉을 제공하는지, 이 논문의 확장(β 법칙, CDMM)과 얼마나 같은지는 확인하지 않았습니다.
- 노력 추정은 검증하지 않은 추정입니다. 설치와 실행은 하지 않았습니다(설치 전 승인 필요).

5. 권리와 게시 판단

- **arXiv 권리: nonexclusive-distrib 1.0. CC BY가 아닙니다.** 논문 그림(Fig. 1 한 장)은 개인용 리포트·PPT에만 넣었습니다.
- PDF 본문에는 저작권 문구, ©, 재인쇄 문구가 없습니다. arXiv 스탬프만 있습니다.
- 공개 게시본에는 논문 그림도, 원문 PDF도, 논문 그림을 재사용한 그림도 넣지 않았습니다. 우리가 그린 그래프 세 장(`report/figures/hf_*.png`)만 씁니다.
- 원문 PDF 크기는 23.4 MB입니다. 25 MB 기준 미만이라 `.gitignore`에 넣지 않았습니다(README의 큰 파일 규칙 확인).