Hydra-0: 분석 리포트

게시용 버전: 논문 그림은 저작권(© NVIDIA) 때문에 제외했습니다. 원문 https://arxiv.org/abs/2608.18077 · arXiv:2608.18077v1 · NVIDIA, Brown, Columbia, Harvard (Li, Wen, Zhu, Wang, Du, Li, Konidaris, Birchfield, Pouya, Li, Chang) · 코드 미공개 · 분석일 2026-10-28 · 논문 그림은 개인 학습용으로만 사용(논문 라이선스가 CC BY 아님)

핵심 요약

1. **무엇을 하는가:** 로봇 행동을 이미지 평면의 점 궤적(action flow)으로 표현하고, 이를 조건으로 하는 비디오 world model을 여러 embodiment의 영상 2,202시간으로 학습한다. 배포할 때는 Isaac Lab이 로봇을 움직이고 비디오 모델이 환경 반응을 예측하는 **하이브리드 시뮬레이터**가 된다.
2. **수치는 정확히 맞는다:** 논문 Table 2와 웹페이지 수치표(42행 × 7지표), 평균 행과 SE, 헤드라인 90.4%/60.2%, RoboLab 혼동행렬(κ 0.82)까지 모두 재계산으로 일치한다.
3. **해석은 걸러야 한다:** 헤드라인 −90.4%의 기준선(Cosmos 2.5 + 6D 행동)은 제로샷 ATI보다 그리퍼 오차가 7.4배 나쁘다. 같은 백본 통제 비교는 그리퍼 −59.7%, 물체 −52.6%다. **진짜 이득은 물체 움직임 예측**(제로샷 궤적 모델 대비 −77%)에 있다.
4. **"Hydra-0"은 결과마다 다른 모델이다:** 최고 품질은 LightX2V 4-step 체크포인트 기반, 16배 속도는 자체 증류 학생, WAM은 50-step 교사, RoboLab 모델은 명시되지 않았다.
5. **정책 평가 r = 0.96의 의미 범위가 좁다:** 30쌍 집계 상관이고, 기준은 시뮬레이터이며, 실행된 궤적을 재생하는 open-loop라 결과 누설을 통제하지 않았다.

01. 논문 분석: Hydra-0 (arXiv:2608.18077)

- 제목: *Hydra-0: Action Flow for Generalist World Modeling and Control*
- 저자: Hongyu Li, Bowen Wen, Xinghao Zhu, Yixuan Wang, Yilun Du, Yunzhu Li, George Konidaris, Stan Birchfield, Soha Pouya, Chenran Li, Yan Chang (NVIDIA, Brown, Columbia, Harvard)
- 공개: arXiv v1 2026-08-18, 기술 보고서. 라이선스는 **arXiv 비독점 배포 라이선스**(CC BY 아님)이고, 본문에 "© 2026 NVIDIA. All rights reserved."라고 적혀 있습니다.
- 코드: **공개되지 않았습니다**("Code — coming soon"). 프로젝트 페이지를 호스팅하는 `nvidia-isaac/video_to_data` @ `7eb9721`은 같은 그룹의 다른 파이프라인(Video to Data)이고, Hydra-0 모델 코드는 들어 있지 않습니다.
- 프로젝트: https://nvidia-isaac.github.io/video_to_data/hydra-0/ (논문에 없는 RoboLab 에피소드 단위 수치가 실려 있음)

---

1. Abstract (한 줄 요약과 주장)

한 줄 요약: 로봇의 행동을 관절각이나 엔드이펙터 명령이 아니라 **이미지 평면 위 점들의 궤적(action flow)** 으로 표현하고, 이를 조건으로 하는 비디오 world model을 여러 embodiment(사람 손, UMI 그리퍼, 단팔·양팔 로봇)의 영상으로 함께 학습합니다.

주장은 네 가지입니다.

1. **action flow는 공통 인터페이스다.** 영상에서 추적으로 얻을 수 있고(학습), 배포할 때는 Isaac Lab에서 명령을 실행해 로봇 표면 점을 카메라로 투영해서 얻습니다.
2. **백본에 관계없이 이식된다.** Cosmos 2.5와 Wan2.2에 모두 적용됩니다. 최고 설정은 기준선(Cosmos 2.5 + 6D EE 행동) 대비 그리퍼 움직임 오차를 90.4%, 물체 움직임 오차를 60.2% 줄입니다.
3. **open-loop 정책 평가에 쓸 수 있다.** RoboLab의 5개 정책 × 6개 과제(300 에피소드)에서 재생 성공률과 기준 성공률의 Pearson r이 0.96입니다.
4. **역방향 모드(world action model)가 있다.** 사람 시연에서 뽑은 원하는 물체 flow를 주면, 모델이 그에 맞는 로봇 동작을 생성하고, 학습된 action head가 이를 실행 가능한 명령으로 바꿉니다.

---

2. Method

2.1 action flow의 정의와 구성 (§ 2.1, Eq. 1)

- **정의:** N개 점의 H스텝 궤적이고, 각 점은 $x_{n,t} = (u, v)$와 가시성 $m_{n,t} \in \{0,1\}$를 가집니다.
- **기하 기반 구성 (배포, 메타데이터가 있는 로봇 데이터):**
  - 첫 관측에서 보이는 로봇 표면 점 X_n을 링크 $\ell(n)$에 붙입니다.
  - 그 점을 $x_{n,t} = \pi(K\,[I\ 0]\,T_{CW}\,T_{\ell(n)}(q_t)\,X_n)$로 투영합니다.
  - 가시성은 깊이 > 0, 화면 안, 렌더 깊이 버퍼와 3×3 이웃에서 1.2 cm 이내일 때 1입니다(자기 가림 처리).
- **영상 기반 구성 (학습, 메타데이터가 없는 데이터):**
  - AllTracker로 128×128 격자의 dense track을 얻습니다.
  - SAM 3 마스크로 embodiment, object, 미할당으로 나눕니다.

- **학습 시 샘플링:** 조건을 4가지 모드 None / Embodiment / Object / All 중 하나로 고르고, 확률은 0.05 / 0.40 / 0.40 / 0.15입니다. Embodiment와 Object 모드는 1–128개 track을, All 모드는 256–1024개를 씁니다. Object 모드가 나중에 역방향 모드의 근거가 됩니다.

2.2 조건 주입 (§2.2, Eq. 3–4, 부록 8.4)

- **특징 전파:** 첫 프레임 latent s_0에서 track 출발점의 특징 h_n을 bilinear로 뽑고, 각 latent 시간 k의 목적지 셀 $p_{\square}$ 주변으로 Gaussian 가중치 $w = m_0 \cdot m_k \cdot \exp(-220 \| p_{\square} - x_{\square,\{n,k\}} \|^2)$를 줘서 퍼뜨립니다(셀마다 가중치 상위 K=2개만 사용, 정규화 없음).
- **존재 게이트:** $g = \text{clip}(\Sigma w, 0, 1)$이고, 조건은 $C_{motion} = (M, g)$입니다. 설계는 ATI와 Wan-Move를 따릅니다.
- **백본별 주입 방식:**
  - Cosmos 2.5: 17채널 부가 입력을 zero-init patch projection으로 더합니다.
  - Wan2.2 I2V-A14B: 기존 visual condition 경로(16+4채널)에 넣고, MoE의 고잡음 expert에만 적용합니다.
  - Wan2.2 TI2V-5B: 49채널을 concat합니다.
- **학습 대상:** DiT patch embedding과 q·k·v·o, FFN의 rank-64 LoRA만 학습합니다. 손실은 표준 flow matching(Eq. 5)입니다.

2.3 빠른 롤아웃 (§2.3)

LongLive-2.0 방식으로 블록 causal 자기회귀 변환을 하고(KV cache, 청크 7 latent), DMD2로 4-step 학생 모델을 증류합니다. action flow는 전체 창 좌표로 한 번 계산한 뒤 청크 오프셋에서 잘라 써서 재기준(re-anchoring)을 막습니다.

2.4 정방향과 역방향 (§2.4)

- **정방향(정책 평가):** 기록된 엔드이펙터 궤적에서 만든 그리퍼 flow로 미래 영상을 생성합니다. **정책이 생성 영상을 보고 다시 행동하지 않는** open-loop 재생입니다.
- **역방향(WAM):**
  - 원하는 물체 flow만 조건으로 주면 모델이 로봇 동작이 담긴 영상 latent를 만듭니다.
  - 그 DiT 토큰에서 action/state head(mean pool + attention pool → 2층 MLP)가 명령을 읽어 냅니다.
  - 학습 손실은 $L_{WAM} = L_{flow} + 0.1(L_{act} + L_{state} + 0.1 \cdot L_{vel})$이고, 실제 로봇의 성공·실패 궤적 쌍으로 rank-32 LoRA와 head를 학습합니다.

2.5 데이터 (Table 1)

7개 소스, 1,565,634개 창(81프레임, 약 5 s), 2,201.7 h입니다. 주로 변형 물체(천, 케이블, 로프, 봉투, 종이) 상호작용이고, **ABC-130k가 67.0%** 를 차지합니다. 정적 창과 그리퍼가 멈춘 창은 50 px 기준으로 걸렀습니다. EgoDex는 CC-BY-NC-ND입니다.

---

3. Experiments

3.1 다중 embodiment 예측 (Table 2, 데이터셋당 검증 클립 100개 × 5개)

모델 (Average 행)	PSNR	물체 EPE	그리퍼 EPE	FVD
ATI (zero-shot)	17.01	23.19	4.62	444
Wan-Move (zero-shot)	16.35	21.53	4.67	408
Cosmos 2.5 (6D EE 행동, 미세조정)	15.62	13.23	**34.28**	406
Ours (Cosmos 2.5 2B)	18.41	6.27	13.80	277
Ours (Wan2.2 A14B)	20.76	6.00	3.83	194
Ours (Wan2.2 A14B 4-step)	**21.84**	**5.27**	**3.29**	**156**

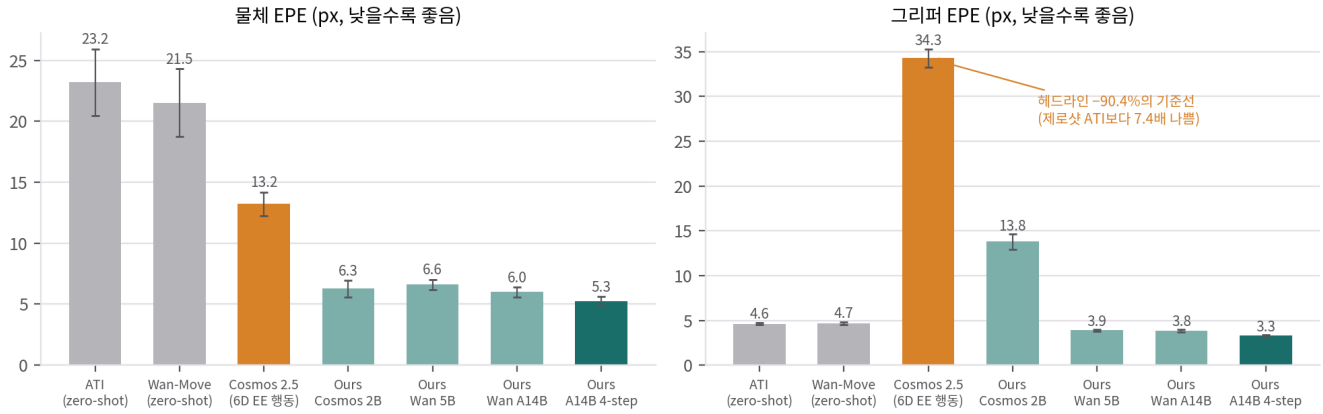


Table 2 Average 행(5개 검증셋 무가중 평균, 물체 EPE는 DROID 제외 4개). 오차막대: 논문 보고 SE.

3.2 데이터 효율 (Fig. 7, IWS 6개 과제)

0% 데이터(제로샷)에서 mid-training(MT)이 사전학습만 한 모델(PT)보다 6개 과제 모두에서 LPIPS, 물체 EPE, FVD가 낮습니다. 100%에서도 LPIPS와 FVD는 6개 과제 모두, 물체 EPE는 4개 과제에서 가장 낮습니다. 대부분의 이득은 데이터 20%에서 이미 나옵니다. 다만 수치 표가 없고 그래프로만 제시됩니다.

3.3 속도 (Table 3, H100 1장, 81프레임 480×832, VAE 디코드 제외)

양방향 교사 20.9 s, 자기회귀 교사 12.5 s, 4-step 학생 1.31 s(약 62 FPS, 16배)입니다.

3.4 RoboLab open-loop 정책 평가 (Fig. 8, 300 에피소드)

- **논문 수치:** Pearson r = 0.96, Spearman ρ = 0.93, MAE 5.7%p이고, 다섯 정책의 순위를 그대로 재현합니다.
- **프로젝트 페이지에만 있는 수치:**
  - 에피소드 단위 일치율 93.0%, Cohen's κ = 0.82
  - 오탐(FP) 10건, 미탐(FN) 11건
  - 전체 성공률 26.3%(시뮬레이션) vs 26.7%(RoboLab)

3.5 역방향 모드 (Fig. 10)

유연한 파이프 구부리기 과제 **1개**를 정성적으로만 보입니다. 성공률은 없습니다.

3.6 해석: 수치를 어떻게 읽을 것인가 (`03`, `04`에서 재계산)

1. **헤드라인 −90.4%는 기준선이 약한 데서 나옵니다.** 기준선(Cosmos 2.5 + 6D EE)의 그리퍼 EPE는 제로샷 ATI보다 **7.4배** 나쁩니다.
   - 같은 Cosmos 백본에서 조건 방식만 바꾼 통제 비교는 그리퍼 −59.7%, 물체 −52.6%입니다.

    - 최고 설정을 제로샷 ATI와 비교하면 그리퍼는 −28.8%뿐이고, 물체는 −77.3%입니다. 즉 **진짜 이득은 물체 움직임 예측에 있습니다.**
2. **그리퍼 EPE는 조건과 같은 공간에서 잰 지표입니다.** flow 조건 모델은 그리퍼가 어디로 가야 하는지를 픽셀로 직접 받으므로, 그리퍼 EPE에서 구조적으로 유리합니다. 물체 EPE가 더 공정한 지표입니다.
3. **"Hydra-0"은 하나의 모델이 아닙니다.** 결과마다 다른 설정이 쓰였습니다(`04` §2).
    - Table 2 최고는 LightX2V가 공개한 4-step I2V-A14B 체크포인트 기반입니다.
    - Table 3의 16배는 자체 자기회귀+DMD 학생입니다.
    - WAM은 50-step 자기회귀 교사입니다.
    - RoboLab에 쓴 모델은 명시되지 않았습니다(페이지 메타데이터에는 "LoRA step 6000").
4. **RoboLab의 "기준"은 실제 세계가 아니라 고충실도 시뮬레이터입니다.** RoboLab [52]는 시뮬레이션 벤치마크입니다. 실제 세계 평가는 천 접기의 정성적 예시(Fig. 9)뿐입니다.
5. **open-loop 재생은 결과 정보를 누설할 수 있습니다.** 실제로 실행된 궤적(예: 빈손으로 그리퍼를 닫고 물러나는 동작)에 성공·실패 정보가 이미 담겨 있을 수 있습니다. 그런데 "궤적만으로 성공을 맞히는" 기준선이 보고되지 않았습니다.

---

4. Limitations

4.1 저자가 밝힌 한계

WAM의 파지 위치가 센티미터 단위로 부정확합니다(깊이 인식 부족을 원인으로 추정). 생성 영상에서 파지·접촉 상태가 모호합니다. 손목 카메라 결과는 DROID 정성 예시 하나뿐입니다. 평가는 모두 open-loop이고 closed-loop은 향후 과제입니다.

4.2 분석하면서 추가로 발견한 한계

1. **배포할 때는 결국 로봇 기하와 카메라 보정이 필요합니다.** "embodiment에 무관하다"는 장점은 학습 쪽에만 해당합니다. 배포할 때는 URDF, 보정된 카메라, Isaac Lab 실행이 있어야 action flow를 만들 수 있습니다.
2. **2D 표현의 한계가 있습니다.** 깊이 방향(카메라 광축) 움직임은 flow에서 거의 보이지 않습니다. 저자들이 밝힌 "센티미터 단위 파지 오차"가 이 표현에서 구조적으로 나오는 결과일 가능성이 있습니다.
3. **Gaussian 전파의 등방성이 확실하지 않습니다.** $\beta = 220$은 "정규화된 latent 격자 좌표"에서 정의됩니다. 축별로 [0,1]로 정규화했다면 가로 52셀과 세로 30셀에서 퍼지는 폭이 픽셀로 다릅니다(`03` §3). 논문에서는 판단할 수 없습니다.
4. **재현할 수 없습니다.** 코드와 가중치가 없습니다. A14B mid-training에는 H100 32장으로 5일이 들었습니다.
5. **역방향 모드의 근거가 약합니다.** 과제 1개, 정성적 결과입니다. "과제별 전문가 시연이 필요 없다"고 하지만, 대상 로봇의 실제 궤적 쌍(성공과 실패)은 여전히 필요합니다.

03. 재계산과 해석

GPU 없이 공개된 수치만으로 검증했습니다.

- `analysis/table_check.py` → `table_check_results.json`
- `analysis/plot_headline.py` → `report/figures/headline_epe.png`

---

1. 헤드라인 수치를 분해하면

비교	그리퍼 EPE 감소	물체 EPE 감소	무엇이 다른가
최고 설정 vs Cosmos 2.5 (헤드라인)	**90.4%**	**60.2%**	조건 방식 + 백본(2B → 14B) + 4-step 체크포인트
Ours (Cosmos 2B) vs Cosmos 2.5 (통제 비교)	59.7%	52.6%	조건 방식만
최고 설정 vs ATI (제로샷 궤적 조건 모델)	28.8%	77.3%	다중 embodiment mid-training + 백본
최고 설정 vs Wan-Move (제로샷)	29.5%	75.5%	같음

해석:

- **기준선이 이례적으로 약합니다.** 6D EE 행동으로 미세조정한 Cosmos 2.5의 그리퍼 EPE(34.3 px)는 학습 없이 궤적만 받은 ATI(4.6 px)보다 7.4배 나쁩니다. 따라서 "90.4%"는 action flow 자체의 효과라기보다, **"행동을 픽셀로 주면 그리퍼가 그 픽셀을 따라간다"** 는 당연한 결과에 백본 크기 차이가 더해진 값입니다.
- **의미 있는 결과는 물체 EPE입니다.** 같은 백본에서 52.6%, 제로샷 궤적 모델 대비 75% 이상 줄었습니다. 물체가 어떻게 반응하는지는 조건에 직접 들어 있지 않으므로, 이 개선은 **다중 embodiment 학습이 상호작용 동역학을 배웠다**는 증거로 읽을 수 있습니다.

2. "4-step이 교사보다 좋다"는 이상한 결과

- 4-step 모델은 34칸 중 33칸에서 최고입니다.
- Average 행에서 50-step A14B 대비 차이를 z 점수로 보면 PSNR +6.6, SSIM +6.9, 그리퍼 EPE −3.3입니다. 즉 **4-step이 통계적으로 분명하게 더 좋습니다.**
- 증류한 학생이 교사보다 좋은 경우는 드뭅니다. 본문을 보면 이 4-step은 **LightX2V가 공개한 다른 체크포인트** (§4.2)에 같은 방법을 적용한 것이고, 자체 DMD 증류 결과(Table 3의 학생)가 아닙니다. 그래서 "증류가 품질을 올렸다"고 읽으면 안 되고, **다른 출발 가중치 비교**로 봐야 합니다.
- 한편 웹페이지는 "가장 좋고 가장 빠른 설정"이라고 쓰지만, 속도 측정(Table 3)은 다른 모델(자체 자기회귀 학생)에서 했습니다.

3. Gaussian 전파 폭 (Eq. 8)

- $w = \exp(-220 \cdot d^2)$가 0.5가 되는 거리는 $d = \sqrt{(\ln 2 / 220)} \approx$ **0.056**(정규화 좌표)입니다.
- latent 격자는 30 × 52(480×832 / 16)입니다. 축별로 [0,1]로 정규화했다고 가정하면, 반값 반경은 다음과 같습니다.

    - 가로: 0.056 × 52 ≈ 2.9셀 ≈ 47 px
    - 세로: 0.056 × 30 ≈ 1.7셀 ≈ 27 px
    - 즉 **세로로 납작한 타원**이 됩니다.
- [−1,1] 정규화라면 각각 절반입니다. 논문만으로는 어느 쪽인지 알 수 없습니다.
- 셀마다 상위 K=2개 track만 쓰므로, track이 촘촘한 곳(All 모드, 256–1024개)에서도 한 셀의 특징은 최대 2개 track의 합입니다.

4. RoboLab 정책 평가 숫자의 정합성과 의미

4.1 숫자는 서로 맞는다

항목	값	재계산
기준 성공 수	26.7% × 300	80
시뮬레이션 성공 수	80 − FN 11 + FP 10	79 → 26.3% ✅
일치율	(300 − 21) / 300	93.0% ✅
Cohen's κ	(0.930 − 0.610) / (1 − 0.610)	0.820 ✅
민감도 / 정밀도	69/80, 69/79	86.3% / 87.3%
MAE 5.7%p가 요구하는 불일치 수 하한	쌍별 차이 합 T = 17	실제 21 ≥ 17 ✅

4.2 무엇을 측정하는가

- **r = 0.96은 30개 점(정책-과제 쌍)의 상관입니다.** n=30일 때 95% 신뢰구간은 [0.917, 0.981]이고, 만약 정책 5개 단위였다면 [0.51, 0.997]입니다.
- **상관은 정책 간 차이가 주도합니다.** Fig. 8을 보면 많은 점이 (0, 0) 근처에 몰려 있고, π0.5와 Cosmos-3 Nano가 상관을 끌어올립니다. 정책 간 성공률 차이가 크면 시뮬레이터가 덜 정확해도 상관은 높게 나옵니다.
- **에피소드 단위 κ = 0.82가 더 엄밀한 지표입니다.** 이 값은 논문 본문에는 없고 웹페이지에만 있습니다. 참고로 "항상 실패"라고 답하는 무의미한 판정기도 정확도 73.3%를 얻습니다(κ = 0).
- **결과 누설 문제가 있습니다.** 실행된 궤적을 그대로 재생하므로, 성공과 실패의 차이가 이미 궤적에 들어 있을 수 있습니다. 예를 들어 실패한 시도는 물체 없이 그리퍼가 닫힌 채 끝나거나 재시도 동작이 들어 있습니다. world model이 기여한 부분을 분리하려면 **궤적만 보고 성공을 맞히는 분류기**와 비교해야 하는데, 이 기준선이 없습니다.
- **"기준"이 시뮬레이터입니다.** RoboLab [52]은 제목 그대로 "고충실도 시뮬레이션 벤치마크"입니다. 따라서 "neural simulator가 physics simulator의 판정을 재현한다"는 결과이고, 실제 세계 정책 평가의 정확도는 아직 측정되지 않았습니다.

5. 하이브리드 시뮬레이터라는 관점

배포 구조는 다음과 같습니다.

- **로봇(강체, 모델이 알려져 있음):** 물리 엔진(Isaac Lab)이 담당합니다.
- **환경(변형 물체, 접촉, 조명):** 학습된 비디오 모델이 담당합니다.
- **경계면:** 이미지 평면의 점 궤적입니다.

이것은 **grey-box 모델링**(알려진 물리 + 학습된 잔차)과 같은 철학입니다. PINN 연구 관점에서 보면, 경계면을 2D flow 대신 3D 점 궤적이나 접촉력으로 바꿀 때 얻는 것과 잃는 것을 따져 볼 만합니다.

04. 수치·주장 검증 (코드 미공개)

Hydra-0의 모델 코드는 공개되지 않았습니다("Code — coming soon"). 그래서 이번에는 코드 대조 대신 **논문 표, 프로젝트 페이지, 본문 주장**이 서로 맞는지를 검증했습니다. 스크립트는 `analysis/table_check.py` 입니다.

1. 수치 정합성

검증 항목	결과
Table 2(논문 텍스트)와 프로젝트 페이지 "Full numerical results" 42행 × 7지표	✅ 완전히 일치
Average 행 = 5개 데이터셋 무가중 평균	✅ 반올림 범위 안(SSIM 두 칸에서 0.001 차이)
Average 행 SE = $\sqrt{(\Sigma se^2)}/k$	✅ 전부 일치
헤드라인 90.40% / 60.16%	✅ 34.28 → 3.29, 13.23 → 5.27 (재계산 60.17%는 반올림 차이)
"같은 Cosmos 백본에서 PSNR·SSIM·그리퍼 EPE·FID·FVD 5개 데이터셋 모두, 물체 EPE 4개 모두 개선"	✅ 위반 0건
"4-step이 대부분 칸에서 최고"	✅ 34칸 중 33칸
Table 1 창 수 × 81/16 s = 시간	✅ 7개 소스 모두 일치, 합계 2,201.7 h
RoboLab 혼동행렬(FP 10, FN 11)과 일치율 93.0%, κ 0.82, 성공률 26.3/26.7%	✅ 전부 일치 (`03` §4.1)
MAE 5.7%p와 에피소드 불일치 21건	✅ 양립 가능 (하한 17)

결론: 숫자들은 서로 정확히 맞습니다. 문제는 숫자 자체가 아니라 **비교 기준과 해석**에 있습니다.

2. 주장과 근거 사이의 간극

#	주장	실제 근거	판정
C1	"최고 설정이 행동 조건 기준선 대비 그리퍼 오차 90.4%, 물체 오차 60.2% 감소"	백본 크기(2B vs 14B)와 시작 체크포인트(LightX2V 4-step)가 섞인 비교. 통제 비교는 59.7% / 52.6%	⚠️ 과장된 표현
C2	"action flow가 native 6D 행동보다 행동 정보를 더 잘 전달한다"	같은 백본 통제 비교로 뒷받침됨. 단 그리퍼 EPE는 조건과 같은 공간에서 잰 지표라 구조적으로 유리	✅ (물체 EPE 기준으로 읽을 것)
C3	"Hydra-0"이라는 하나의 모델	Table 2 최고(LightX2V 4-step I2V-A14B + action flow), Table 3(자체 자기회귀+DMD 학생), WAM(50-step 자기회귀 교사), RoboLab(설정 미명시, 페이지 메타데이터에 "LoRA step 6000")	⚠️ 결과마다 다른 모델
C4	"16배 빠르고 가장 좋은 설정"(웹페이지)	품질 최고 모델과 속도 측정 모델이 다름. 16배는 VAE 디코드와 guidance를 뺀 생성 전용 수치	⚠️
C5	"RoboLab에서 r = 0.96으로 정책 평가"	30쌍 집계 상관. 에피소드 $\kappa = 0.82$(웹페이지만). 기준이 시뮬레이터. 궤적 누설 통제 없음	⚠️ 의미 범위가 좁음
C6	"역방향 모드가 창발한다", "과제별 전문가 시연 없이"	과제 1개 정성 예시. 대상 로봇의 실제 궤적 쌍으로 head를 학습해야 함	⚠️ 개념 증명 수준
C7	"데이터 효율: 대부분의 이득이 20%에서"	그래프만 있고 수치 표가 없음. FVD는 점당 40 클립이라 분산이 큼(저자도 인정)	△ 정성적
C8	"embodiment에 무관한 인터페이스"	학습 쪽은 맞음. 배포할 때는 로봇 기하, 카메라 보정, 물리 시뮬레이션이 필요	△ 범위 한정 필요

3. 재현 가능성

- **공개된 것:** 논문, 프로젝트 페이지(영상, 수치표, 미디어 출처 manifest)
- **공개되지 않은 것:** 모델 코드, 가중치, 학습 데이터 전처리 결과, RoboLab 쌍별 성공률
- **재현 비용:** A14B mid-training에 H100 32장으로 5일(40,000 step)이 들었습니다. 개인 단위로는 Wan2.2 TI2V-5B 또는 Cosmos 2B 설정이 현실적인 하한입니다.
- **라이선스:** 논문은 CC BY가 아닙니다(arXiv 비독점 배포, © NVIDIA). 학습 데이터 중 EgoDex는 CC-BY-NC-ND이므로, 공개될 가중치의 라이선스에 영향이 있을 수 있습니다.

02. 선행연구와 계보

번호 [n]은 논문의 참고문헌 번호입니다. 각 논문을 별도로 열어 검증하지는 않았습니다.

1. 계보

```
[행동 조건 world model]  Dreamer [20], DINO-WM [58]  →  비디오 생성형: Cosmos 2.5/3 [36, 35], IWS [48], [19]
        │  문제: 행동이 관절·EE 좌표라 embodiment마다 매핑을 새로 배워야 함
        ▼
[궤적·움직임 조건 비디오 생성]  Motion Prompting [17] → ATI [45](Gaussian 전파) → Wan-Move [13](첫 프레임 특징을 궤적 따라 복제)
        │  문제: 사용자가 그린 궤적일 뿐, 실행 가능한 로봇 명령과 연결되지 않음
        ▼
★ Hydra-0  로봇 기하와 보정으로 명령 → 픽셀 궤적(kinematically grounded) + 다중 embodiment mid-training + 역방향 모드
```

2. 가까운 대안 (논문 Related Work 기준)

방법	2D 조건	Hydra-0과의 차이
MIMIC [8]	참조 기반 의미 마스크	점 궤적이 아님
Mask2IV [28]	행위자·물체 마스크 궤적	마스크 단위
BridgeV2W [10]	명령으로 렌더링한 embodiment 마스크	로봇 렌더 마스크
OSCAR [49]	2D 운동학 스켈레톤 렌더	스켈레톤
ContactFlow [4] arXiv:2607.26579	접촉 flow 조건	접촉 중심
기타	kinematic pointmap 조건, optical-flow WAM, 로봇 렌더링, flow 중심 생성 계획, 궤적 조건 교차 embodiment 기술 전이 [51, 9, 27, 16, 38]	—

차별점(저자 주장): 가시성을 고려한 로봇 표면 점 궤적, 다중 embodiment 학습, 정방향과 역방향의 공유 인터페이스, 그리고 메타데이터 없는 영상에서도 학습할 수 있는 track 복원입니다.

3. 구성 요소별 출처

역할	출처
비디오 백본	Cosmos 2.5 [36], Wan2.2 [44], LightX2V 4-step 체크포인트 [1]
조건 주입	ATI [45], Wan-Move [13]
자기회귀 변환	LongLive-2.0 [11], CausVid [55] 등 [55, 59]
증류	DMD [54], DMD2 [53]
추적과 분할	AllTracker [21], SAM 3 [7]
미세조정	LoRA [24]
평가	RoboLab [52] arXiv:2604.09860 (시뮬레이션 벤치마크), Gemma 4 31B VLM 판정 [40]
데이터	DROID [26], ABC-130k [3] arXiv:2606.27375, MolmoAct2 [14], EgoDex [23], Deform360 [30], X-VLA Soft-Fold [57]

4. 이 저장소에서 분석한 다른 논문과의 관계

- **Do as I Do** (`../do_as_i_do`): 사람 영상을 3D로 복원한 뒤 물리 리타겟팅으로 로봇 궤적을 만듭니다. Hydra-0은 같은 사람 영상을 **2D flow 그대로** 학습 신호로 씁니다. 두 논문은 "사람 영상 → 로봇" 문제에 대한 3D 명시적 경로와 2D 암묵적 경로라는 정반대의 선택입니다.
- **DexScrew** (`../dexscrew`): 접촉과 촉각은 시뮬레이션이 어렵다는 같은 문제의식에서 출발합니다. DexScrew는 실제 데이터로 우회하고, Hydra-0은 학습된 비디오 모델로 우회합니다. Hydra-0의 한계 절이 "촉각·힘 조건이 다음 단계"라고 적은 것도 이 지점입니다.