Generalizable Robotic Insertion with World Models: 분석 리포트

게시용 버전: 논문 그림과 표는 제외했습니다. 원문 https://arxiv.org/abs/2609.28258 · arXiv:2609.28258v1 (2026-09-23) · 학회: IROS 2026 표기는 arXiv 메타데이터뿐이고 논문에는 채택 문구가 없음(상태 불명) · 저자 Hansen 외 10인 · 분석일 2026-11-10 · 논문 그림과 표는 라이선스(arXiv 비독점 배포, CC BY 아님) 때문에 제외했습니다

핵심 요약

1. **무엇을 하는가:** 잠재 세계 모델(TD-MPC2)을 손목 깊이 영상과 고유감각으로 학습하고, MPPI로 삽입 행동을 계획합니다. 한 모델을 조립 객체 90개에 학습하고, 학습하지 않은 10개에서 제로샷 56%를 보고합니다. 디코더는 없고, 세계 모델은 잠재 상태·보상·가치만 예측합니다.
2. **"56% 대 7%"는 같은 조건의 비교가 아닙니다:** 7%는 AutoMate 논문의 수치이고, 학습 객체가 약 15-25개일 때의 한 점입니다. 같은 x에서 우리 값은 약 40%입니다. AutoMate 생성 정책은 CAD 점군을 입력으로 씁니다. 분할은 저자들도 모른다고 씁니다.
3. **미지 객체 10개의 불확실성은 큽니다:** 시도 단위 95% 구간은 [52.9, 59.1]%지만, 객체 간 분산을 넣으면 ±15-19pp입니다. "unseen"은 같은 데이터 분포의 자산이고, 기하가 다른 객체라는 뜻은 아닙니다.
4. **특수 모델 79.78% 대 70.31%는 방향이 유의합니다:** 객체별 차이 SD를 10-30pp로 가정해도 $p < 0.002$입니다. 절제 실험은 시드 수가 없어 커리큘럼 효과(+2.4pp)를 판단할 수 없습니다. 시각 입력 효과(+14.9pp 생성, +24.6pp 특수)는 큽니다.
5. **미세조정은 일부 객체에서만 뚜렷합니다:** 1053, 1129, 1079, 1102에서 차이가 크고, 1132는 두 방법 모두 실패합니다. 비교 스텝도 다릅니다(30k 대 2M 기준선).
6. **toy 결과(CPU):** 모델 오차가 간극의 절반(c/2) 이상이면, 모델이 간극을 좁게 본 에피소드가 모두 실패합니다. 샘플 수 16-256은 성공률을 바꾸지 않았습니다. 이 toy에서는 **모델 없는 kNN 정책이 더 좋았습니다.** 이 결과는 논문의 대비를 재현하지 않으며, 기준선의 강도에 달려 있습니다.
7. **빠진 정보가 많습니다:** 샘플 수, 호라이즌, 제어 주기, 시드 수, 객체별 값, 보상 계수, 코드, 체크포인트. 실물 실험은 없습니다.

구현 가능성 (판정)

- **공식 재현: 불가능합니다.** 논문 링크와 코드가 없고, AutoMate 학습 코드도 찾지 못했습니다(`gh` 검색과 웹 검색, 2026-11-10 확인). 실험은 Isaac Gym(CUDA GPU 필요)입니다.
- **이 맥(Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치): 논문 설정 재현은 불가능합니다.** 논문 학습은 RTX 3090에서 특수 40시간, 생성 3일입니다.
- **아이디어 재구현: 중간에서 높음.** TD-MPC2 공식 코드(MIT)는 재사용할 수 있습니다. 병목은 조립 자산 100쌍과 환경, 그리고 CAD 기반 역분해 시연 보상(식 5)을 다시 만드는 일입니다.
- **하드웨어:** NVIDIA GPU 1장(RTX 3090급 이상 권장), Linux. 실물은 Franka와 손목 카메라가 필요합니다.
- **이 맥에서 한 것:** 수치 재계산, 계획 계산량 추정, 2D 삽입 toy(CPU, 약 73초).

01. 논문 분석: Generalizable Robotic Insertion with World Models

- 논문: Hansen 외 10인, *Generalizable Robotic Insertion with World Models*, arXiv:2609.28258v1 (2026-09-23 제출, cs.RO)
- 원문: `paper/paper.pdf` (v1, 8쪽, 3.4 MB). 본문 인용은 절·식·그림 번호로 합니다. 페이지 번호는 쓰지 않습니다.
- 학회: arXiv Comments에 "IROS 2026"만 있습니다. 논문 본문에는 채택 여부가 없습니다(상세는 `04_claim_verification.md` §0).
- 이 문서는 논문이 말하는 것을 정리하고, 빠진 정보와 해석이 갈리는 곳을 표시합니다. 수치 재계산은 `03_analysis.md`, 주장별 판정은 `04_claim_verification.md`에 있습니다.

0. 한 문단 요약

저자들은 TD-MPC2(잠재 공간 세계 모델 + MPPI 계획)를 **삽입(insertion) 과제 하나**에 적용하고, 그 모델 하나로 **90개 조립품**(AutoMate 데이터셋 100쌍 중 90쌍)을 학습합니다. 입력은 손목 카메라의 96×96 깊이 영상과 로봇 고유감각(24차원)입니다. 학습에는 CAD 기반 역분해 시연을 쓴 보상이 들어갑니다. 학습하지 않은 10쌍(ID가 가장 큰 10개)에서 **제로샷 성공률 56%**(100회 × 10쌍)를 보고하고, 비교 대상으로 AutoMate의 **7%**를 씁니다. 이 7%는 저자들이 AutoMate 논문에서 가져온 수치이며, 같은 분할과 같은 학습 규모에서 재측정한 값이 아닙니다. 실험은 전부 Isaac Gym 시뮬레이션이고, 실물 실험은 없습니다.

1. Abstract과 Introduction

주장 (Abstract, I절).

1. 고정된 조립 쌍마다 정책을 따로 학습하는 방식(specialist)은 확장이 어렵다.
2. 세계 모델 하나를 90개 조립품에 학습하면 학습하지 않은 조립품에서 56% 제로샷 성공을 보인다. 모델 없는 기준선은 7%다.
3. 학습 객체가 늘수록 성능이 오른다(확장성).
4. 생성 모델을 미지 객체에 미세조정하면 처음부터 학습보다 데이터 효율이 좋고, 일부는 점근 성능도 높다.
5. "기하를 모르는 미지 객체를 완전히 데이터로만 조립한 첫 시스템"이라고 주장한다.

기여 (I절 마지막 문단). 새 알고리즘보다 "시각 모델 기반 RL이 산업 조립에서 쓸모 있다"는 것을 보이는 데 무게를 둡니다. 저자들은 스스로 기여를 "설계 선택의 실용 지침"이라고 씁니다(I절, "Notably, the key contribution ... is not to propose a new algorithm").

문제 설정 (I절, III절). 실물 조립은 손으로 짠 제어기나 부품별 전문 정책에 의존합니다. 제안은 정책 학습을 **다수 객체의 한 모델**로 옮기는 것입니다.

2. Preliminaries와 TD-MPC2 (III절)

논문은 II절 "Related Work" 제목 아래 본문이 없고, 관련 연구 문단이 III절 "Preliminaries" 제목 아래 들어 있습니다(편집 오류로 보입니다). 여기서는 실제 내용 위치를 따라 씁니다.

MDP 정의 (III절, "Robotic insertion with RL"). 상태는 깊이 영상 $x \in R^{96\times96}$과 고유감각 $q \in R^{24}$로 근사하고, 부분관측 MDP로 봅니다. 행동은 6자유도 end-effector 증분 자세(정규화 [-1, 1])입니다. 저자들은 "full state s는 실제 응용에서 알

수 없어 [x, q]로 근사한다"고 씁니다.

TD-MPC2 구조 (식 1). 잠재 세계 모델은 다섯 부분으로 구성됩니다.

- 인코더 z = h(s), 잠재 전이 z′ = d(z, a), 보상 r̂ = R(z), 가치 q̂ = Q(z, a), 정책 사전분포 â ∼ p(z).

학습 목적 (식 2-4). 잠재 예측 손실을 시간 지수 가중 λ로 합산합니다. 단계 손실은 보상 교차엔트로피, 가치 교차엔트로피, 그리고 잠재 공간 예측 손실 ‖ z′_t − sg(h(s′_t)) ‖ ²입니다(식 4, stop-gradient). **픽셀을 복원하는 디코더는 없습니다.** 저자는 "without decoding raw observations"라고 씁니다(III절 첫 단락). 따라서 이 세계 모델이 **예측하는 것은 잠재 상태, 보상, 가치**이고, 영상이나 물체 자세, 접촉력을 직접 예측하지 않습니다.

계획. 추론 때는 MPPI(Williams 외 2015)로 행동 시퀀스를 샘플링하고, 정책 사전분포를 샘플에 섞습니다. 샘플 수, 호라이즌, 반복 수, 온도는 **이 논문에 없습니다**. TD-MPC2 참조(III절 "Refer to [30], [31]")에만 있습니다. 저장소 기본값은 `03_analysis.md` §7에 있습니다.

3. 방법 (V절)

관측과 행동. 깊이 영상 96×96(손목 카메라 한 대, 시뮬레이션용 RealSense D435 모사), 고유감각 24차원입니다. 고유감각은 다음과 같습니다(IV절 "Observations").

- 관절각 R^7
- 끝점 자세의 잡음 섞인 추정 R^7 (위치 3 + 쿼터니언 4)
- **소켓 자세의 잡음 섞인 추정 R^7** (위치 3 + 쿼터니언 4)
- 목표 위치 R^3 (플러그가 완전히 삽입된 점)

중요한 점: 소켓 자세는 시뮬레이터의 참값에 백색 잡음을 더한 것으로 보입니다. 실제 장비에서는 이것을 추정하는 단계가 필요하고, 그 단계는 논문에서 다루지 않습니다. 저자들이 말하는 "CAD와 객체 ID가 필요 없다"는 것은 **객체 기하 정보에 한정된 주장**입니다. 자세 추정은 포함하지 않습니다(§4 C12).

인코더 (식 6). h(x, q) = h_fuse(h_depth(x) + h_prop(q)). h_depth는 얕은 CNN, h_prop과 h_fuse는 2층 MLP이고, 모두 SimNorm 출력입니다. 저자들은 "객체 ID의 one-hot은 미지 객체에 옮길 수 없으므로 시각 정보만으로 구별한다"고 씁니다(V절 "Zero-shot generalization").

행동 출력. 학습된 정책 사전분포와 MPPI 계획으로 행동을 냅니다(III절과 V절).

보상 (식 5). R = r_penetration·(r_dist + r_imitation + r_success). r_dist는 플러그와 목표의 음의 거리, r_imitation은 **역분해 절차로 만든 시연**을 따라가는 항, r_success는 성공 이진항입니다. 계수는 생략했고, 저자들은 이 보상을 [6]과 [1]에서 "수정 없이" 가져왔다고 씁니다. 이 보상은 학습 객체마다 역분해 시연이 필요하므로, **학습 단계에서는 객체 기하(CAD에서 만든 시연)를 쓴다**는 뜻입니다. 저자들은 이 점을 "privileged"라고 따로 쓰지 않습니다.

학습 설정 (VI-A "Implementation details", IV절).

- 세계 모델 약 5M 파라미터(모든 변형 동일)
- 특수 모델(specialist, 객체 100개 각각) 2M 스텝, AutoMate는 50M 스텝
- 생성 모델(generalist, 90개) 7M 스텝
- 계산: 특수 모델 40시간, 생성 모델 3일, 둘 다 RTX 3090 1장(VI-A)
- 병렬 환경: 생성 모델은 객체마다 환경 하나(90개 병렬), 무작위화된 장면 설정(IV절 "Zero-shot generalization")
- 커리큘럼: 학습 성공률에 따라 초기 상태 분포를 쉬운 쪽에서 어려운 쪽으로 옮김(V절·VI-B)

학습 구현 세부가 빠진 것. 샘플 수와 호라이즌은 없습니다. 환경 스텝의 정의(병렬 수 포함)는 없어, AutoMate의 "50M 스텝"과 직접 비교는 단위가 맞지 않을 수 있습니다. 두 방법의 단계 수를 같다고 가정하면 안 됩니다.

4. 데이터와 환경 (IV절)

- **데이터:** AutoMate[1]의 조립 자산 100쌍(플러그를 소켓에 넣는 두 부품). [4][5]에서 가져왔고, 자산마다 번호(ID)가 있습니다.
- **환경:** AutoMate의 Isaac Gym 환경을 "closely follow"로 재현(Franka Panda, 평행 그리퍼, 테이블 위 소켓은 상향 자세로 무작위 배치, 플러그는 모션 플래닝으로 잡은 뒤 시작).
- **실물 장비 주장:** 저자들은 장비 구성이 [1][6][7][10]의 실물 실험과 같다고 씁니다. 그러나 **이 논문에는 실물 결과가 없습니다**(VII절 "deployment of visual policies on real hardware is still challenging").

5. 실험 (VI절)

5.1 평가 프로토콜 (VI-A "Evaluation")

- **미지 객체 분할:** 100개 가운데 ID가 가장 큰 10개를 고정된 테스트 세트로 둡니다. 나머지 90개로 학습합니다. ID는 1036, 1041, 1053, 1079, 1092, 1102, 1125, 1129, 1132, 1136입니다(Fig. 6 제목에서 확인).
- **Fig. 2 설명:** "Training and test assemblies are drawn from the same data distribution." 즉, 미지 객체는 **같은 데이터 분포의 다른 자산**입니다. "unknown geometry"는 정책이 기하를 입력으로 받지 않는다는 뜻이고, 기하가 본질적으로 다른 객체라는 뜻은 아닙니다.
- **분할 근거:** "선택 편향을 줄이려고 ID 순서로 자른다"고 씁니다. 그러나 ID가 자산 출처나 기하 계열과 관련이 있으면 이 분할은 계열 단위의 분할일 수 있습니다. 논문은 이를 확인하지 않았습니다.
- **학습 규모 실험:** 생성 모델은 학습 객체 수를 5, 15, 45, 75, 90으로 바꿔 학습합니다(Fig. 1 오른쪽). 학습 객체의 부분집합은 ID 오름차순으로 고릅니다.
- **시도 수:** 생성 모델은 객체당 100회, 특수 모델은 객체당 5 seed × 100회입니다. 미세조정은 5 seed(95% 신뢰 구간 음영, Fig. 6).

5.2 기준선 (VI-A "Baselines")

- **AutoMate[1] (주 기준선):** PPO로 특수 모델을 학습합니다. 생성 모델은 특수 모델을 BC, DAgger, 온라인 RL로 증류하고, **CAD 모델의 점군 임베딩을 조건으로 씁니다**(VI-A). 배포 때도 객체별 CAD와 자세 추정 파이프라인이 필요하다고 씁니다.
- **수치 출처:** "AutoMate 생성 모델 수치는 [1]에서 가져왔다". 분할은 저자들도 **알 수 없다**고 씁니다("exact training and test splits for AutoMate are not known"). 그래서 Fig. 1의 AutoMate 수치는 AutoMate 논문의 값입니다. 재측정이 아닙니다.
- **내부 변형:** 시각 없는 모델(blind), 카메라 위치 변경, 커리큘럼 유무와 종류, 전문가 롤아웃 100개를 받는 생성 모델.

5.3 주요 결과 (VI-B, Fig. 1, Fig. 5, Fig. 6)

결과	값	출처
특수 모델 100개 평균	79.78% (AutoMate 70.31%)	VI-B "Single-assembly", Fig. 5
생성 모델, 학습 객체 90개(seen)	55.0% (본문), 54.5% (Fig. 7)	VI-B, Fig. 7
생성 모델, 미지 10개	56% (제로샷)	Abstract, VI-B, Fig. 1
AutoMate, 학습 80개(seen)	15.6%	VI-B
AutoMate, 미지	7% (Fig. 1의 점 하나)	Fig. 1, Abstract

결과	값	출처
미지 곡선 (우리)	5개 27%, 15개 40%, 45개 50%, 75개 53%, 90개 56%	Fig. 1 오른쪽

특수 모델. 79.78%대 70.31%입니다. 저자들은 AutoMate가 "큰 소켓"에서 이기고 우리 방법은 "작고 얇은 소켓"에서 이긴다고 씁니다. 296과 726에서 떨어짐(VI-B)을 인정합니다. 가림(occlusion)이 원인일 것이라고 추측합니다.

생성 모델 확장. 학습 객체가 늘면 seen 성능은 약간 떨어지고(59 → 55), unseen 성능은 오릅니다(27 → 56). 저자들은 "in-domain과 out-of-domain이 이 수준에서 saturation할 것"이라고 가정합니다(VI-B). 이것은 가설로 표시되어 있습니다.

미세조정 (Fig. 6, VI-B). 90개 생성 모델을 10개 미지 객체에 미세조정하고 처음부터 학습과 비교합니다. x축은 0-30k 환경 스텝이고, 처음부터 학습 기준선은 2M 스텝 값을 점선으로 씁니다. 두 곡선의 스텝 범위가 다릅니다. 또 **1053**에서는 미세조정(약 0.4-0.6)이 처음부터(약 0)보다 낫지만 2M 기준선(0.8)에 못 미치고, **1132**에서는 두 방법 모두 낮습니다(처음부터 2M 기준선 0.25, 미세조정 약 0.05). 저자들이 말한 "in some cases exceeds"는 1036과 1041 두 개를 가리킵니다.

절제 (Fig. 7, VI-B).

- 센서: 고유감각만(39.6) 대 깊이 + 고유감각(54.5) 대 대체 카메라 위치(46.4), 생성 모델 기준. 특수 모델은 55.2 / 79.8 / 72.7.
- 커리큘럼: 없음 52.1 / 기본 54.5 / 시연 56.5(생성 모델). 특수 모델은 76.2 / 79.8 / 79.5(역커리큘럼).
- 저자들의 결론: 시각이 "critical"이고, 커리큘럼은 "consistently improves"하지만 종류는 덜 중요하다.

5.4 한계 (VII절, VI-B)

저자들이 인정하는 한계는 네 가지입니다. (i) 가림이 큰 조립품에서 실패, (ii) 학습 객체가 늘수록 seen 성능이 약간 떨어짐, (iii) 생성 학습용 조립 데이터셋이 부족함, (iv) 실물 배포는 아직 어렵고 깊이 잡음과 얇은 부품, 실시간 처리가 문제. 논문은 **실물 결과가 없음**을 명시하지 않고 "still challenging"이라고 씁니다.

6. 해석이 갈리는 곳 (읽을 때 조심할 것)

1. **"unseen"의 뜻.** 같은 데이터 분포의 객체이며, 기하 계열이 떨어진 객체가 아닙니다. 분할은 ID 기준입니다.
2. **"model-free baseline 7%"의 뜻.** AutoMate는 PPO 기반의 모델 없는 방법이지만, 이 수치는 AutoMate가 **CAD를 입력으로 쓴 생성 모델의 점**이고, 학습 객체 수도 다릅니다(Fig. 1에서 7%는 학습 객체 약 15-25개 부근). 헤드라인의 "56 대 7"은 같은 조건의 비교가 아닙니다.
3. **"vision-only, no privileged information"의 뜻.** 배포 때는 CAD를 안 쓰지만, 관측에 **시뮬레이터 소켓 자세(잡음 있음)**가 들어 있고, 학습 보상에는 CAD 기반 역분해 시연이 들어 있습니다.
4. **"world model"의 뜻.** 픽셀 예측 모델이 아니라 잠재 공간 보상·가치 모델입니다. 접촉이나 자세를 명시적으로 예측하지 않습니다.
5. **시도 수와 신뢰 구간.** 미지 10개 × 100회라는 시도 수는 객체 간 분산을 무시합니다(`03_analysis.md` §2).
6. **Fig. 7 수치 불일치.** 본문 55.0%와 Fig. 7의 54.5%가 다릅니다. 같은 평가의 반올림 차이인지 확인되지 않았습니다.
7. **"zero-shot reaches in-domain at this scale"(VI-B).** 56 대 55는 차이가 우연일 가능성이 큽니다. 미지 10개의 객체 간 분산을 고려하면 구간이 매우 넓습니다.

7. 저자가 말하지 않은 것 (빠진 정보)

- 샘플 수, 호라이즌, 반복 수, 온도(MPPI) 및 계획 시간(제어 주기당 ms)
- 제어 주기, 환경 스텝의 정의, 병렬 환경 수

- 생성 모델의 seed 수(절제와 학습 곡선에 대해), 미지 객체별 제로샷 값(Fig. 6 0스텝 값은 눈으로만 읽힘)
- 생성 모델 시도 수의 근거: 100회 × 10 = 1000회는 명시되어 있지만 특수 모델 평균 분산은 없음
- 소켓 깊이 잡음 모델, 시각 렌더링 설정, 조명
- 역분해 시연 생성 절차와 시연 수
- 학습·평가 코드, 체크포인트, 프로젝트 페이지, 데이터(§ `02_prior_work.md` §4)
- 실물 실험(없음)
- 학회 채택 여부

8. 라이선스와 권리 표기 (요약)

- arXiv 라이선스: **nonexclusive-distrib 1.0**(abs 페이지 확인, 2026-11-10). CC BY가 아닙니다.
- PDF 1쪽: arXiv 찍힘(arXiv:2609.28258v1 [cs.RO] 23 Sep 2026)만 있습니다. IEEE 저작권 문구는 **없습니다**(텍스트와 1쪽 이미지 확인).
- 따라서 논문 그림과 표는 개인용 리포트와 PPT에만 넣고, 게시본에는 넣지 않습니다. 게시본 그림은 논문 수치를 다시 그린 것입니다.

9. 용어

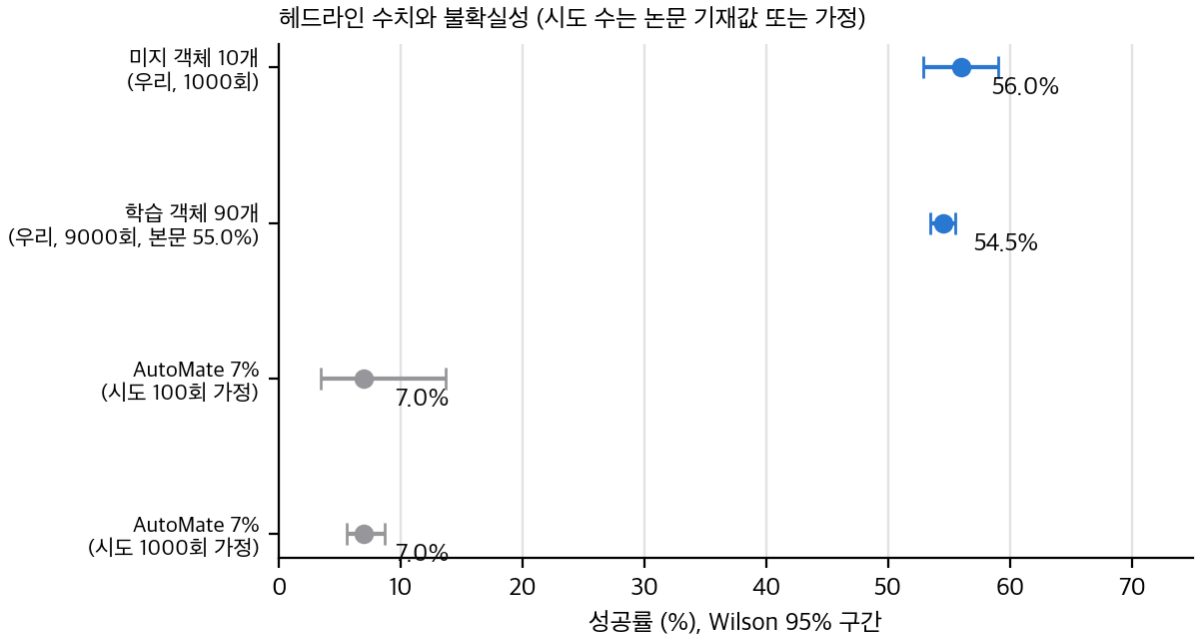
- **specialist:** 객체 쌍 하나에 학습한 정책. **generalist:** 여러 쌍을 한 모델로 학습한 정책.
- **seen / in-domain:** 학습 객체. **unseen / zero-shot / out-of-domain:** 학습하지 않은 10개 테스트 객체.
- **SimNorm:** TD-MPC2의 잠재 정규화(그룹 softmax). 논문 식 6 설명.

03. 수치 재계산, 유도, toy 검증

재현 코드는 `analysis/table_check.py` (→ `table_check_results.json`), `analysis/insertion_toy.py` (→ `insertion_toy_results.json`)에 있습니다. 둘 다 CPU, numpy·scipy, 단일 스레드입니다. toy는 약 73초 걸립니다. 논문에 없는 값은 가정으로 표시했습니다.

0. 요약

- 헤드라인 "56% 대 7%"는 **통계적으로는 확실**합니다. 56%(1000회)의 Wilson 95% 구간은 [52.9, 59.1]%입니다. 그러나 **객체 단위**로 보면 10개 객체의 평균이므로 구간은 약 ±15-19pp로 넓어집니다(§2). 비교 대상 7%는 학습 규모가 다른 점에서 나왔고, 시도 수도 밝혀지지 않았습니다(§1).
- 특수 모델 79.78 대 70.31%는 객체 쌍별 차이의 SD를 모르면 검정할 수 없습니다. 가정 SD 10-30pp에서 p는 10^{-3}보다 작습니다(§3).
- 절제 실험의 차이(커리큘럼 +2.4pp, 시연 +2.0pp)는 시드 수가 밝혀지지 않아 판단할 수 없습니다. 시도 단위 검정은 과신입니다(§4).
- 미세조정은 1053, 1129, 1079, 1102에서 30k 스텝 시점 차이가 큽니다. 1036과 1041은 시작점부터 높아서 차이가 작고, 1132는 두 방법 모두 실패합니다(§5).
- 계획 비용은 모델 호출 약 9,300회/스텝, 약 15-93 GFLOP/스텝으로 추정됩니다. 기본 설정을 가정한 값입니다(§6).
- toy: 모델 오차가 **간극의 절반(c/2) 이상**이면, 모델이 간극을 좁게 본 에피소드가 모두 실패합니다. 샘플 수(16-256)는 성공률을 바꾸지 않았습니다. 이 toy에서는 **모델 없는 kNN 정책이 모든 미지 기하에서 더 좋았습니다**(§8). 이것은 toy 설계(오라클 시연, 접촉 규칙, 관측)에 따른 결과입니다.



직접 계산: 헤드라인 수치와 Wilson 95% 구간. AutoMate 7%는 시도 수를 100회와 1000회로 가정.

1. 헤드라인 비교 (T1, `table_check.py`)

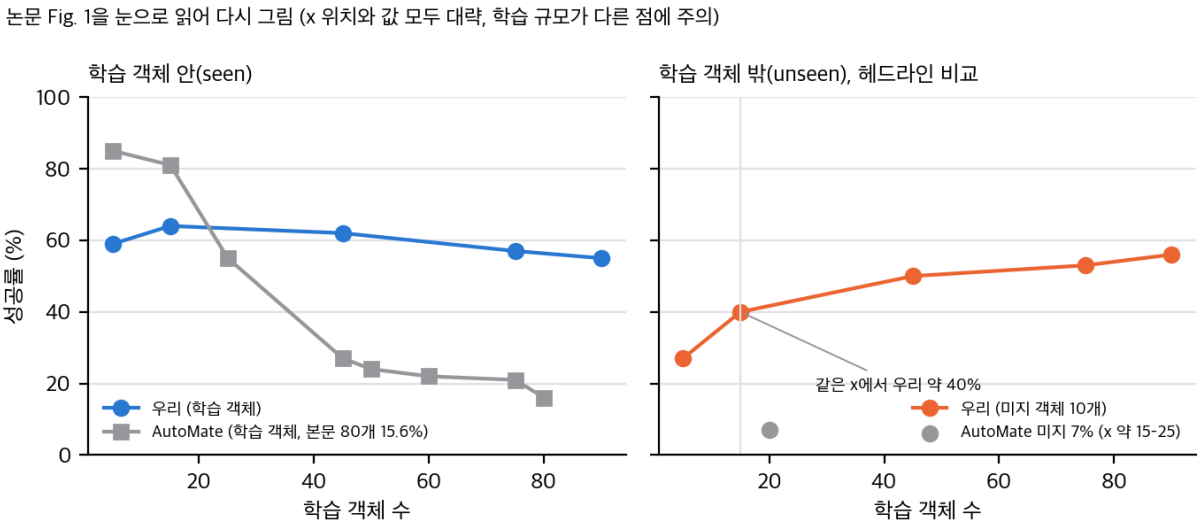
항목	값	근거
우리, 미지 10개 × 100회	560/1000 = 56.0%, Wilson 95% [52.9, 59.1]	본문 VI-A(시도 수), Fig. 1

항목	값	근거
AutoMate 미지 7%	시도 수 불명. 100회 가정 → [3.4, 13.8]%, 1000회 가정 → [5.6, 8.8]%	Fig. 1
Fisher 검정 (우리 대 AutoMate)	$p = 1.9\times10^{-23}$ (n=100 가정), $p = 1.1\times10^{-134}$ (n=1000 가정)	이항 근사

해석. 시도 단위 검정은 의미가 있습니다. 그러나 이 검정은 "같은 조건"의 차이를 보지 않습니다. 세 가지가 달라서 비교가 불균형합니다.

1. **학습 규모.** Fig. 1 오른쪽 패널에서 AutoMate 7%는 학습 객체 약 15-25개 부근의 점 하나입니다. 우리 모델은 같은 부근(15개)에서 약 40%입니다(Fig. 1). 90개 대 15-25개에서 나온 값을 나란히 놓은 것입니다.
2. **입력.** AutoMate 생성 정책은 CAD 점군 임베딩을 입력으로 받습니다(VI-A). 우리 정책은 깊이와 고유감각을 받고, 고유감각에는 잡음 섞인 소켓 자세가 들어갑니다.
3. **분할.** AutoMate 측의 분할은 알 수 없다고 저자들이 씁니다(VI-B). 같은 10개로 평가했는지 모릅니다.

Fig. 1을 눈으로 읽어 같은 x 위치에서 비교하면 40% 대 7%입니다. 그래도 차이는 크지만, 헤드라인의 56% 대 7%보다는 작습니다. 이 값은 읽은 값이므로 ±2pp 정도 오차가 있습니다.



직접 다시 그림: 논문 Fig. 1을 눈으로 읽은 규모 곡선. x 위치와 값은 대략이며, 학습 규모가 다른 점에 주의.

재계산 확인. 특수 모델 평균(79.78%)과 그 생성 모델 값(55.0%, 54.5%)은 Fig. 5와 Fig. 7에서 맞습니다. 55.0%(본문)와 54.5%(Fig. 7)가 다른 것은 반올림이나 평가 시점 차이로 보이지만 확인되지 않았습니다.

2. 객체 단위 불확실성 (T7)

미지 객체 10개의 평균 56%에서 객체 간 SD를 가정하면 다음과 같습니다.

객체 간 SD(가정)	평균의 SE	95% 구간
20pp	6.3pp	[43.6, 68.4]%
25pp	7.9pp	[40.5, 71.5]%
30pp	9.5pp	[37.4, 74.6]%

가정 근거: Fig. 6의 0스텝(미세조정 시작점)을 눈으로 읽은 값(1036 ≈ 0.95, 1053 ≈ 0.02, 1132 ≈ 0.0, 나머지 0.55-0.85)의 SD는 0.33입니다. 이 값도 눈으로 읽은 것이라 대략적입니다. 그래서 구간의 하한이 40% 근처라는 것, 즉 7%보다 훨씬 위라는 결론은 유지됩니다. 그러나 **"56%는 ±3pp 정확도로 알려졌다"는 해석은 틀립니다.**

Fig. 6의 0스텝 값 평균은 0.597입니다(§5). 본문 56%와 대략 같은 수준입니다.

3. 특수 모델 79.78% 대 AutoMate 70.31% (T3)

- 차이: 9.47pp (100개 객체, 객체당 5 seed × 100회).
- 쌍 설계(같은 객체에서 두 방법을 비교)이므로 검정에는 객체별 차이의 SD가 필요합니다. 논문에는 없습니다. Fig. 5 막대 높이로는 추정할 수 없습니다.

객체별 차이 SD(가정)	SE	z	p (정규 근사)
10pp	1.0	9.5	$< 10^{-10}$
15pp	1.5	6.3	2.7×10^{-10}
20pp	2.0	4.7	2.2×10^{-6}
30pp	3.0	3.2	1.6×10^{-3}

시도 단위로 계산하면 구간이 ±0.6pp로 나오지만, 객체를 단위로 두지 않은 과신입니다. 결론: 평균 차이 9.5pp는 가정 SD 30pp까지 유의합니다. 그러나 AutoMate의 특수 모델 수치가 **재측정이 아니라면**(VI-B 각주는 "재현 수치를 저자가 확인했다"고 씁니다) 같은 조건인지는 확인되지 않았습니다.

4. 절제 실험 (T4, Fig. 7)

막대 값만 쓸 수 있습니다. 시드 수와 시드별 분산은 없습니다.

비교	차이	근사 p(시도 단위, 시드 무시)	해석
생성: 고유감각만 39.6 → 깊이(기본) 54.5	+14.9pp	2×10^{-89}	시각 효과는 크고 안정적으로 보임. 시드 분산이 14pp보다 작다고 보기 어려운 이유는 없음
생성: 깊이(기본) 54.5 → 대체 카메라 46.4	−8.1pp	3×10^{-20}	카메라 위치 효과. 시드 1개면 확인 필요
생성: 커리큘럼 없음 52.1 → 기본 54.5	+2.4pp	0.0013	시드 분산보다 작을 수 있음. "consistently"는 과장
생성: 커리큘럼 없음 52.1 → 시연 100개 56.5	+4.4pp	3×10^{-9}	저자는 "marginal"이라고 씀
특수: 고유감각만 55.2 → 깊이 79.8	+24.6pp	0	특수 모델에서 시각 효과 매우 큼
특수: 커리큘럼 없음 76.2 → 기본 79.8	+3.6pp	6×10^{-43}	5 seed 평균이면 SE를 알아야 함

Holm 보정(8개 비교, 시도 단위 근사)은 모든 p를 그대로 두거나 키울 뿐입니다. 시드 분산을 넣으면 결론이 달라질 수 있습니다. 따라서 **시각 효과(특수와 생성 모두)는 방향이 안정적이고, 커리큘럼 효과(2-4pp)는 확인되지 않았습니다.**

5. 미세조정 (Fig. 6, T5)

- x축은 0-30k 환경 스텝입니다. 처음부터 학습의 2M 스텝 값은 점선으로만 있습니다. 즉 **데이터 효율**은 30k 스텝 시점의 곡선을 비교해야 확인됩니다.

- 객체별 시작점(0스텝, 눈으로 읽음 ±0.1): 1036 0.95, 1041 0.80, 1053 0.02, 1079 0.65, 1092 0.75, 1102 0.55, 1125 0.60, 1129 0.85, 1132 0.00, 1136 0.80. 평균 0.597.
- 30k 시점 차이가 큰 객체(눈으로 읽음, 처음부터 대 미세조정): 1053(≈0.05 대 ≈0.5), 1129(≈0.6 대 ≈0.95), 1079(≈0.7 대 ≈0.9), 1102(≈0.6 대 ≈0.75). 1092와 1136은 차이가 작습니다.
- 1132: 처음부터 2M 기준선 0.25, 미세조정 30k에서 약 0.05. **두 방법 모두 실패**에 가깝습니다. 얇은 판 형태라 깊이 영상이 잘 안 보이는 것으로 보이지만 논문은 이 원인을 확인하지 않았습니다.
- 본문의 "exceeds the asymptotic performance(1036, 1041)"는 2M 기준선과 비교한 것입니다. 1036은 미세조정 ≈0.9-0.95, 기준선 ≈0.85이고, 1041은 두 곡선이 겹칩니다. 차이가 작아 우연일 수 있습니다.

6. 계획 계산량 추정 (T6)

논문에는 샘플 수와 호라이즌이 없습니다. TD-MPC2 저장소의 기본 설정(`332f19e` : 호라이즌 3, 샘플 512, 반복 6, 정책 궤적 24)을 가정합니다.

- 제어 주기당 모델 호출 수 = 반복 × 샘플 × 호라이즌 + 정책 궤적 × 호라이즌 = 6 × 512 × 3 + 24 × 3 = **9,288회**.
- FLOPs ≈ 2 × (호출당 MLP 파라미터) × 호출 수. 호출당 파라미터가 0.8M(잠재 전이 d로 가정)이면 약 **15 GFLOP/스텝**, 전체 5M을 매번 쓴다고 보면 상한 **93 GFLOP/스텝**입니다. CNN 인코더와 가치 앙상블(5개)은 제외했으므로 실제는 더 큽니다.
- 시간 추정: 이 맥의 GPU 유효 처리량을 1-5 TFLOPS로 가정하면 3-90 ms/스텝입니다. 공개 사양 근사이고 MPS 실측은 하지 않았습니다. 제어 주기(논문에 없음)가 정해지면 판정할 수 있습니다.
- 학습 비용: 생성 모델 7M 스텝, RTX 3090 3일(VI-A). 스텝을 전체 합으로 세는지 환경당으로 세는지 논문에 없어 스텝당 시간은 계산하지 않습니다.

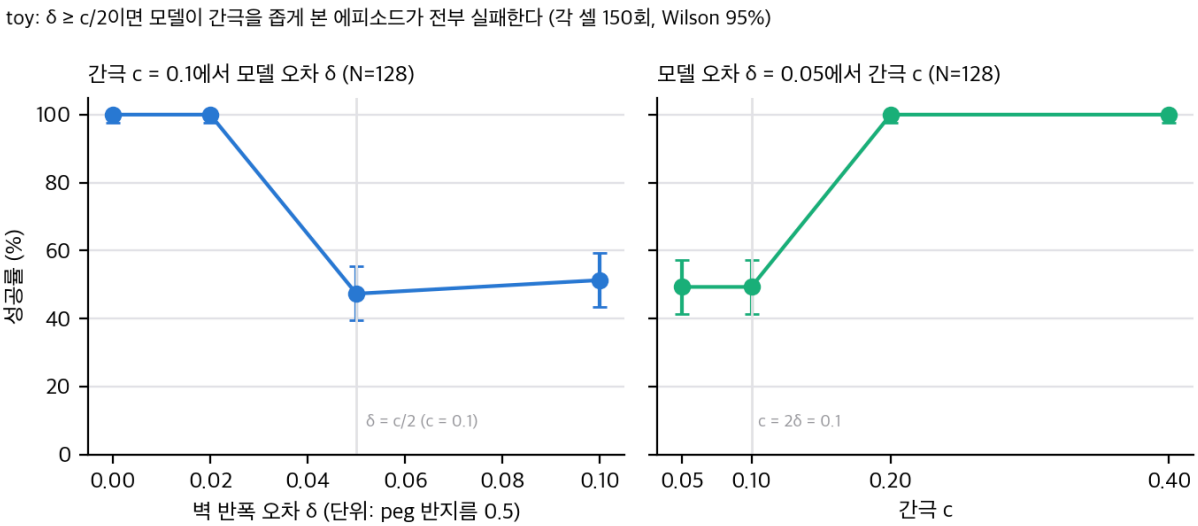
7. 세계 모델 목적 함수 (식 2-4) 해석

식 2는 λ 가중 합입니다. 단계 손실(식 3)은 보상의 two-hot 교차엔트로피, 가치의 교차엔트로피, 그리고 잠재 예측 손실(식 4)입니다. 식 4의 stop-gradient 대상은 목표 인코더 출력 h(s′)입니다. 따라서 **학습 신호는 잠재 공간의 일치와 보상·가치에서만 옵니다.** 픽셀 재구성 손실이 없으므로, 이 세계 모델은 "깊이 영상에서 무엇이 보이는지"를 직접 학습하지 않습니다. 소켓 위치와 간극은 보상과 가치를 통해서만 간접적으로 들어갑니다. 이 점이 "깊이 영상으로 기하를 추론한다"는 저자 설명과 어떻게 맞는지는 논문이 보여주지 않았습니다.

8. toy 실험 (`insertion_toy.py`)

설계 (요약, 자세한 내용은 스크립트 설명).

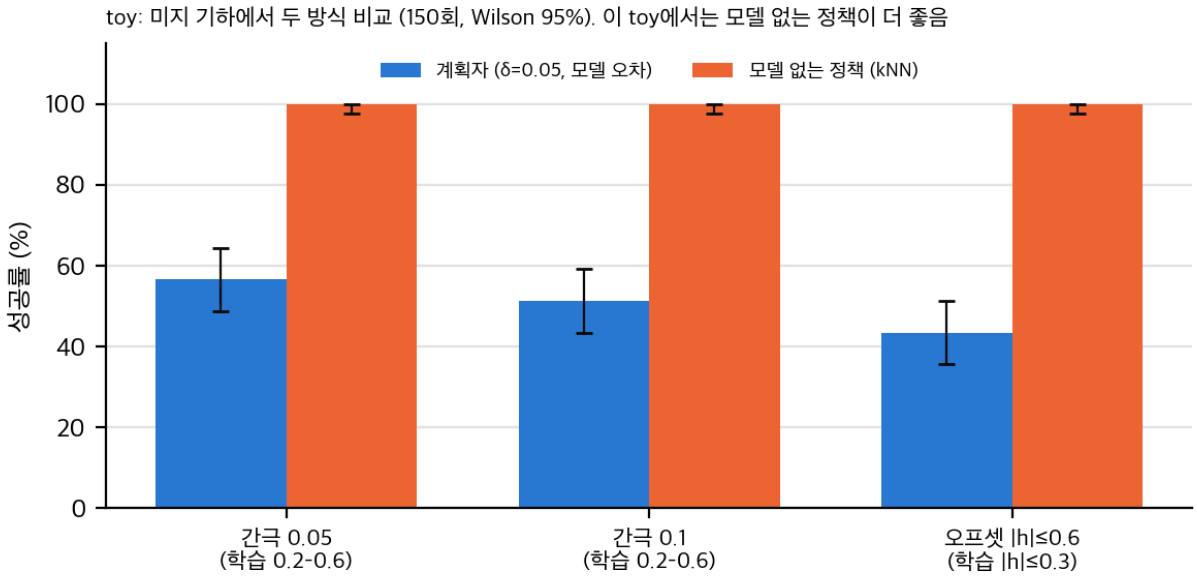
- 2D 점 peg(반지름 0.5), 깊이 2, 간극 c(슬롯 폭 = 2r + c). 벽에 막히면 그 스텝은 움직이지 않습니다(마찰 없음).
- 관측: 슬롯 중심 $\hat{n}$(잡음 0.01). 간극은 관측하지 않습니다.
- 계획자: MPPI, 호라이즌 8, 반복 2, 샘플 N. 모델은 벽 반폭에 δ 오차를 가지며, 부호는 에피소드마다 무작위입니다.
- 모델 없는 정책: 학습 간극 {0.2, 0.4, 0.6}에서 참 모델 MPPI 시연 약 6,500개로 학습한 kNN(k=10, 특징 ($\hat{n}$−x, −D−y)).
- 셀당 150 에피소드, 셀마다 고정 시드. 여러 번 다시 돌린 결과 셀 값은 ±10회 정도 흔들렸지만, 아래 결론의 방향은 바뀌지 않았습니다.



직접 계산(toy): 모델 오차 δ와 간극 c에 따른 성공률(각 150회, Wilson 95%).

결과 (마지막 실행).

실험	조건	성공
모델 오차 δ	c = 0.1, N = 128	δ=0: 150/150, δ=0.02: 150/150, δ=0.05: 71/150, δ=0.1: 77/150
부호별 (δ=0.05)	모델이 간극을 넓게 봄 / 좁게 봄	72/72 대 0/78
부호별 (δ=0.1)	같음	78/78 대 0/72
간극 c	δ = 0.05, N = 128	c=0.05: 74/150, c=0.1: 74/150, c=0.2: 150/150, c=0.4: 150/150
샘플 수 N	δ = 0.05, c = 0.05	N=16: 73/150, N=64: 72/150, N=256: 76/150
모델 없는 정책	학습 간극 0.2, 0.4	150/150, 150/150
모델 없는 정책	미지 간극 0.05, 0.1, 0.15	150/150 each
모델 없는 정책	미지 오프셋	h
같은 미지 조건 비교	계획자(δ=0.05) 대 kNN	간극 0.05: 85 대 150 ($p = 7\times10^{-24}$), 간극 0.1: 77 대 150 ($p = 2\times10^{-27}$), 오프셋: 65 대 150 ($p = 2\times10^{-33}$)



직접 계산(toy): 미지 기하에서 계획자와 모델 없는 kNN 정책의 성공률(150회, Wilson 95%).

해석.

1. **실패는 "모델이 간극을 좁게 본" 절반에서 나옵니다.** 이 경우 모델의 자유 횡방향 범위 c/2 − δ가 0 이하가 되어 모델은 중앙 정렬조차 불가능하다고 판단합니다. 그래서 계획자는 전진하지 않습니다. 반대로 간극을 넓게 본 절반은 모두 성공합니다. 그 이유는 toy 규칙 때문일 수 있습니다(벽에 막히면 멈추고 관측 잡음이 섞이므로 무작위로 빠져나옴). 실제 접촉에서는 다르게 나올 수 있습니다.
2. **임계는 δ ≈ c/2입니다.** c = 0.1에서 δ = 0.02는 통과, δ = 0.05부터 실패합니다. c = 0.2에서 δ = 0.05는 통과합니다. 이는 "모델 정확도는 간극의 절반보다 작아야 한다"는 설계 규칙으로 읽을 수 있습니다.
3. **샘플 수는 모델 편향을 고치지 못합니다.** N을 16에서 256으로 늘려도 성공률은 약 50%로 같습니다. 샘플을 늘리면 모델 오차를 더 정확히 따라가는 것이지 오차를 줄이는 것은 아닙니다. 이 결과는 정책 최적화에서 흔한 "과대 최적화" 효과와 맞지만, toy에서만 확인됐습니다.
4. **모델 없는 kNN이 이겼습니다.** 이 toy의 기준선은 오라클 시연을 그대로 모방하는데, 시연은 간극에 관계없이 "정렬 후 하강"이라는 같은 행동 규칙을 씁니다. 그래서 간극이 줄어도 정책이 맞습니다. 이 결과는 **논문의 대비(7%)를 재현하지 않습니다.** 논문의 기준선은 AutoMate PPO로, 그리고 CAD 조건이 있는 증류 정책이라 이 toy 기준선과 다릅니다. 이 toy는 "모델 기반이 모델 없는 것보다 낫다"는 주장이 **기준선의 강도와 관측 설계**에 달려 있다는 점을 보여 줍니다.

한계. 점 peg, 운동학적 이동, 벽 접촉 규칙이 단순합니다. 학습된 모델을 쓰지 않고 δ를 주입했습니다. 깊이 영상과 소켓 잡음을 모델링하지 않았습니다. 따라서 "학습된 세계 모델의 오차가 얼마인가"에 대한 답은 주지 않습니다.

9. 유도: MPPI 업데이트 (TD-MPC2 참조)

샘플 행동 시퀀스 $U_k \sim N(\mu, \sigma^2)$에 대해 비용 J_k를 구하고, 가중치 $w_k \propto \exp(-(J_k - \min J)/\lambda)$로 μ를 갱신합니다. toy와 TD-MPC2 모두 이 형태입니다. 여기서 온도 λ가 작으면 최적 샘플에 집중하므로, 모델 오차를 더 강하게 따릅니다. 이 논문은 λ를 보고하지 않아 민감도를 확인할 수 없습니다.

10. 확인되지 않은 것과 필요한 자료

- 시드 수(생성 모델과 절제), 객체별 분산, 특수 모델의 쌍별 값
- 샘플, 호라이즌, 제어 주기, 환경 스텝 정의
- AutoMate 측 분할과 평가 프로토콜
- 1132 실패의 원인, 소켓 가림의 정량 값

04. 주장 검증과 구현 가능성

공식 코드를 찾지 못했으므로 코드 대조(`04_code_verification.md`)는 만들지 않았습니다. 대신 논문의 주장을 수치와 그림으로 검증했습니다(C-번호). 재계산 근거는 `03_analysis.md`, 원자료는 `table_check_results.json`과 `insertion_toy_results.json`에 있습니다.

0. 기본 정보와 판정 요약

항목	판정
버전	arXiv:2609.28258v1 (2026-09-23, cs.RO). 이 저장소에는 v1만 있습니다(abs 페이지에 v1만 있음).
학회	**IROS 2026 표기는 arXiv Comments에만 있고, 논문 본문에는 채택 문구가 없습니다.** 채택 여부는 불명입니다. README에 "상태 불명"으로 적습니다.
라이선스	arXiv **nonexclusive-distrib 1.0**(abs 페이지 확인). **CC BY 아님.**
PDF 권리 문구	1쪽에 arXiv 찍힘만 있고, IEEE 저작권 문구는 없습니다(텍스트 추출과 1쪽 이미지로 확인).
게시 규칙	논문 그림과 표는 개인용 리포트·PPT에만 넣습니다. 게시본은 우리가 다시 그린 그래프와 수치만 씁니다.
코드	공식 코드 없음(논문 본문 링크 없음, `gh search repos`·코드 검색·웹 검색 결과 없음). AutoMate 측 코드도 찾지 못함(`02_prior_work.md` §4).
실험 환경	전부 시뮬레이션(Isaac Gym). 실물 결과 없음.

1. 주장별 판정

판정 기준: **확인**(재계산이나 그림과 일치), **부분**(일치하지만 해석이 넓음), **확인 불가**(자료 없음), **과장 가능**(같은 근거로 더 좁게만 말할 수 있음).

번호	주장 (논문 위치)	근거	판정	메모
C1	미지 10개에서 제로샷 56% (Abstract, VI-B, Fig. 1)	100회 × 10쌍 = 1000회. Wilson [52.9, 59.1]% (`03` §1)	부분	수치는 맞음. 객체 단위 구간은 약 ±15-19pp (`03` §2). 10개 평균이라 "56%"의 정밀도는 과대.
C2	모델 없는 기준선 7%와 비교 (Abstract)	AutoMate 논문 수치 인용(VI-A). Fig. 1의 7%는 학습 객체 약 15-25 부근의 한 점	확인 불가 (비교 조건 불일치)	학습 규모, 분할, 입력(CAD 조건)이 다름. 같은 x에서 우리 값은 약 40%. "model-free"는 PPO 기반이라는 뜻에서만 맞음.
C3	학습 객체가 늘수록 미지 성능이 오른다 (Abstract, VI-B)	Fig. 1 오른쪽: 5, 15, 45, 75, 90개에서 27, 40, 50, 53, 56%	확인	점 5개, seed 수 불명, 단조 증가. 시드 분산 없이 기울기를 말하기는 어려움.
C4	seen 성능은 학습 객체가 늘면 약간 떨어진다 (VII절)	Fig. 1 왼쪽: 약 59 → 55%	확인	저자 인정.
C5	학습하지 않은 객체에서 in-domain 수준에 도달 (VI-B)	56 대 55.0(또는 54.5)	부분	차이는 우연일 수 있음. 미지 10개의 객체 간 분산이 큼.
C6	시각 입력이 결정적이다 (VI-B, Fig. 7)	생성: 39.6 → 54.5, 특수: 55.2 → 79.8	확인	효과 크기가 커서 시드 분산과 무관하게 방향은 안정적으로 보임. 단, 생성 모델의 시드 수는 불명.

번호	주장 (논문 위치)	근거	판정	메모
C7	커리큘럼은 일관되게 성능을 올린다 (VI-B)	생성: 52.1 → 54.5(+2.4), 특수: 76.2 → 79.8(+3.6)	과장 가능	차이가 작고 시드 분산이 없음. "일관되게"는 근거가 약함.
C8	특수 모델이 AutoMate보다 우수, 79.78 대 70.31% (VI-B, Fig. 5)	9.47pp, 쌍 SD를 가정(10-30pp) 하면 p < 0.002 (`03` §3)	부분	방향은 유의. AutoMate 수치의 재측정 여부는 각주가 "검증했다"고만 씀. 실패 객체(296, 726)도 있음.
C9	미세조정이 처음부터 학습보다 데이터 효율이 좋다 (VI-B, Fig. 6)	10개 중 대부분에서 30k 스텝 시점 우세	부분	비교 스텝 범위가 다름(처음부터 2M 기준선). 1053과 1132는 효과 약함 또는 없음.
C10	일부 객체에서 미세조정이 처음부터 점근 성능을 넘는다 (1036, 1041)	Fig. 6: 1036 미세조정 ≈0.9-0.95 대 기준선 0.85, 1041 두 곡선 겹침	부분	1036만 차이가 뚜렷. 1041은 우연 범위.
C11	미지 객체를 데이터만으로 조립한 최초 시스템 (Abstract)	선행 시스템 비교 없음	확인 불가	선행 조사를 하지 않았음. 최초라는 주장은 검증하지 않음.
C12	배포 때 CAD와 객체 ID가 필요 없다 (V절)	관측에 소켓 자세 잡음 추정(IV절 proprio) 포함	부분	기하 정보는 입력되지 않지만, 소켓 자세는 입력됨. 실물에서는 자세 추정이 별도로 필요.
C13	기하 정보 없이 "unseen geometry"에서 작동 (Abstract, I절)	Fig. 2 설명: 학습과 테스트는 같은 데이터 분포	과장 가능	"같은 분포의 다른 자산"이 정확. "unknown geometry"는 입력에 기하가 없다는 뜻.
C14	"세계 모델" (I절, III절)	디코더 없음, 잠재 전이, 보상, 가치 (식 1-4)	확인 (용어 주의)	영상이나 자세를 예측하지 않는 잠재 모델. "world model"이 영상 예측을 뜻한다고 읽으면 틀림.
C15	학습 규모에 따라 확장된다 (Abstract)	C3과 같음	부분	학습 객체 5-90개, 90 이상은 없음. 저자도 saturation을 가설로 씀.
C16	특수 모델 2M 스텝이 AutoMate 50M 스텝보다 효율적 (VI-A)	스텝 정의(병렬 수) 불명	확인 불가	두 값의 단위가 같다는 근거가 없음. 효율 주장은 실제 벽시계 시간이나 샘플 수로 다시 말해야 함.
C17	가림이 큰 조립품에서 실패하는 원인 (VI-B)	저자 추측 ("We conjecture")	확인 불가	저자도 추측이라고 씀. 이 저장소에서 검증하지 않음.
C18	특수 정책 40시간, 생성 3일, RTX 3090 (VI-A)	본문 명시	확인 (자기 보고)	재확인 불가. 이 맥에서 재현할 수 없음.
C19	미지 분할은 ID 기준의 선택 편향을 줄인다 (VI-A)	마지막 10개 ID: 1036, 1041, 1053, 1079, 1092, 1102, 1125, 1129, 1132, 1136	확인 불가	ID가 자산 계열과 관련 있는지 확인하지 못함. 분할이 계열 단위일 수 있음.
C20	AutoMate 결과는 공식 코드로 재현했다 (VI-A)	공식 코드 미발견	확인 불가	웹사이트 저장소만 발견. 각주의 "released codebase"는 공개 위치를 밝히지 않음.
C21	실물 배포는 가능할 것 (V절 "making deployment on real hardware feasible in the future")	실물 실험 없음	확인 불가	저자도 VII절에서 어렵다고 씀.
C22	생성 정책을 AutoMate와 같은 조건으로 학습 (VI-A "Baselines")	분할과 규모가 다름	과장 가능	같은 환경 계열이지만 같은 조건은 아님. 저자도 "exact splits 불명"이라고 인정.

2. 빠진 정보 목록 (재현과 비교에 필요한 것)

1. 계획: MPPI 샘플 수, 호라이즌, 반복 수, 온도, 정책 사전분포 샘플 수, 제어 주기당 계산 시간

2. 학습: 학습률, 배치 크기, 재생 버퍼 크기, 병렬 환경 수, 스텝의 정의
3. 시드: 생성 모델과 절제의 시드 수, 특수 모델의 시드별 값
4. 미지 객체별 제로샷 값(표로 없음)과 객체별 시도 수
5. 평가: 초기 상태 분포(소켓 무작위 범위), 시도 종료 조건(성공 판정 기준 값), 실패 원인 분류
6. 시각: 깊이 잡음 모델, 카메라 내부 파라미터, 시뮬레이터 설정
7. 보상: 계수(생략됨), 역분해 시연 생성 절차와 개수
8. 자산: 100쌍 목록과 ID-계열 대응, 학습·평가 분할 파일
9. 코드, 체크포인트, 데이터, 프로젝트 페이지
10. 학회 채택 여부와 최종판(v2 여부)

3. 수치 불일치와 텍스트 문제

- 학습 객체 90개 seen 성능: 본문 55.0%, Fig. 7 54.5%.
- AutoMate 학습 80개 seen 15.6%(본문)와 Fig. 1의 마지막 점(약 16%) 위치: 일치하는 것으로 보이지만 Fig. 1의 x 위치는 읽은 값입니다.
- II절 "Related Work" 제목 아래 본문이 없고, 관련 연구 문단이 III절 "Preliminaries" 아래 있습니다(편집 오류).
- Fig. 7 생성 모델 커리큘럼 패널의 세 번째 막대는 "Demonstrations"이고, 본문에서 말한 "역커리큘럼"은 특수 모델 패널에 있습니다. 설명이 두 곳에 나뉘어 있습니다.
- Fig. 6의 x축 단위가 "environment steps"이지만 스텝 수가 명확하지 않습니다(0-30k).

4. 구현 가능성 판정 (필수)

결론 (한 줄). 논문 그대로의 재현은 **불가능**합니다. 이 맥에서도 **불가능**합니다. 아이디어를 옮기는 것은 **중간에서 높은 노력**이 들고, 병목은 모델이 아니라 **조립 환경과 자산, 역분해 시연 보상**을 다시 만드는 일입니다.

항목	판정	근거
공식 재현	**불가능**	공식 코드 없음. AutoMate 학습 코드도 찾지 못함. Isaac Gym 기반 환경이 필요함. 데이터와 체크포인트 없음.
이 맥(Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치)에서 재현	**불가능**	Isaac Gym은 NVIDIA CUDA GPU가 필요합니다. 논문 학습은 RTX 3090에서 특수 40시간, 생성 3일입니다. 맥에서 같은 시뮬레이터를 돌릴 방법이 없습니다.
맥에서 부분 재현(TD-MPC2 공식 코드를 다른 시뮬레이터, 예: MuJoCo 조립 환경에서 학습)	**조건부**	TD-MPC2 공식 코드는 MIT입니다(`tdmpc2` 999 별, 2026-10-20 push). torch 설치(승인 필요) 후 MPS에서 소형 학습은 가능해 보이나 **미확인**입니다. 조립 자산과 보상을 새로 만들어야 합니다.
아이디어 재구현 노력	**중간에서 높음**	식 6 인코더(CNN + 2층 MLP + SimNorm, 수십 줄), 식 1-4 모델(TD-MPC2 재사용). 병목은 (a) 100쌍 자산 확보 또는 대체 자산, (b) 역분해 시연 기반 보상(식 5)을 만드는 파이프라인, (c) 소켓 잡음 자세 입력 설계입니다. 추정: 환경과 보상 구축에 수 주, 학습에 GPU 수일.
필요한 하드웨어	**NVIDIA GPU 1장 (RTX 3090급 이상 권장)**, Linux, Isaac Gym 설치	논문 VI-A의 학습 시간에서 추정. 실물 실험은 Franka, 손목 RealSense D435급 카메라, 실물 소켓 세트 필요.

항목	판정	근거
실물 재현	**불가능** (현재 자료로)	실물 실험 없음, 저자도 어렵다고 씀.
수치 검증(재계산)	**가능, 완료**	`table_check.py`, Fig. 1, 5, 6, 7 읽기
toy 검증	**가능, 완료**	`insertion_toy.py` (CPU, 73초). 결과와 한계는 `03` §8.

판정 근거 요약.

1. 논문의 핵심 수치(56%, 7%, 79.78%)는 공개 자료로 확인할 방법이 없습니다. 재현하려면 시뮬레이터 환경과 AutoMate 자산 100쌍을 다시 만들어야 하는데, 그 자산이 공개되었는지 확인하지 못했습니다.
2. TD-MPC2 자체는 재사용할 수 있습니다. 그러나 논문의 큰 기여는 TD-MPC2가 아니라 시각 인코더와 다과제 설정입니다.
3. toy에서는 세계 모델 오차가 간극 절반을 넘으면 계획이 실패한다는 설계 규칙이 보였습니다. 이것은 실제 모델에도 적용할 만한 검사입니다.

5. 이 맥에서 한 검증 (CPU, 설치 없음)

- 표·그림 수치 재계산: 헤드라인, 특수 모델, 절제, 미세조정 읽기, 객체 단위 구간(`table_check.py`).
- 계획 계산량 추정(TD-MPC2 기본 설정 가정, `table_check.py` T6).
- 2D 삽입 toy: 모델 오차, 간극, 샘플 수, 부호별 실패, 모델 없는 kNN과의 비교(`insertion_toy.py`).
- 설치한 패키지: 없음(numpy, scipy, matplotlib, markdown-it-py, python-pptx, Pillow는 이미 있던 것을 사용).

6. 다음 단계 (재현은 보류)

재현이나 설치는 사용자 승인 전에는 하지 않습니다. 승인 전까지 재현 항목은 후보로만 둡니다.

02. 선행연구와 관련 저장소

확인일: 2026-11-10. 논문 본문의 참고문헌 번호는 [번호]로 씁니다.

1. 계보

축	대표 연구	이 논문과의 관계
조립 시뮬레이션과 데이터	Joinable [4], Assemble-them-all [5] (CAD 조립 자산과 역분해 시연)	자산 100쌍과 역분해 시연의 출처
특수 정책 (RL, 저차원 상태)	IndustReal [6] (PPO, 접촉 보상), Force-guided exploration [7]	보상 형태(식 5)를 가져온 출처
생성 정책 (CAD 점군 조건)	**AutoMate [1]** (RSS 2024, arXiv:2407.08028)	주 기준선. 특수 PPO 학습, 생성 정책은 BC·DAgger·RL 증류
잠재 세계 모델 + 계획	TD-MPC [30], **TD-MPC2 [31]**, 다과제 TD-MPC2 [32]	이 논문의 기반 알고리즘
시각 세계 모델 (조작)	MoDem-V2 [18], Finetuning offline WM [19]	같은 저자 계열의 선행
능동 지각 조립	Fabrica [42] (arXiv:2506.05168)	저자들이 향후 방향으로 언급

이 논문의 위치. 방법 자체는 TD-MPC2를 그대로 쓰고, 새로운 점은 (1) 깊이 + 고유감각 인코더(식 6), (2) 90개 조립품 다과제 학습, (3) 미세조정 실험입니다. 알고리즘 기여가 아니라는 점은 저자들도 씁니다(I절).

2. 가까운 대안 (읽은 것과 제목만 확인한 것)

- **AutoMate [1]:** 논문 본문과 웹 검색으로 확인. 프로젝트 페이지는 bingjietang718.github.io/automate. 공식 코드는 찾지 못했습니다(§4).
- **EasyInsert (arXiv:2505.16187):** 데이터 효율적이고 일반화되는 삽입 정책이라는 검색 결과의 제목만 확인했습니다. **읽지 않았습니다.** 이 논문의 "unseen 삽입" 주장과 비교하려면 따로 읽어야 합니다.
- **Fabrica [42]:** 본문에서 능동 지각 방향으로 언급만 합니다. 읽지 않았습니다.

3. 이 저장소의 다른 분석과의 관계

폴더	관계	이 논문에서 가져올 것
`openwam/` (arXiv:2609.07398)	세계 행동 모델(WAM). 영상 생성 prior 기반이라 잠재 모델과 목적이 다름	"세계 모델이 무엇을 예측하는가"의 대비 (영상 대 잠재)
`agentic_wam/` (arXiv:2610.30136)	영상·행동을 한 모델에서 함께 denoise하는 WAM	같은 질문: 예측 대상이 영상이어야 하나
`contact_disassembly/` (CONTACT, arXiv:2603.08560)	접촉이 많은 분해 과제, 시각 + 촉각 비교	실물 접촉 삽입에서 시각만으로 충분한지
`dexforce/` (arXiv:2501.10356)	손끝 힘을 목표에 더하는 시연 정책	힘 정보 대 시각 정보
`reactive_grasp/` (arXiv:2609.30082)	접촉력 분배 QP, 힘 제어	접촉 모델 기반 제어의 난이도
`stiffness_copilot/` (arXiv:2603.14068)	손목 영상 정책이 임피던스 행렬을 고르는 공유 제어	삽입의 임피던스 설계 대 학습 정책
`chronospolicy/` (arXiv:2610.13929)	시간 정보 주입, 센서 지연 무작위화	실물 전환에서 지연 처리

4. GitHub와 허깅페이스 (논문 본문에서 찾은 것과 검색으로 찾은 것)

논문 본문에는 URL, 프로젝트 페이지, 코드 링크가 **없습니다**(`paper/paper.txt` 전체 검색). arXiv 초록 페이지에도 코드 링크가 없습니다. 아래는 `gh search repos` 와 `gh api` 로 확인한 결과입니다.

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋
(InsertionWM 코드)	`gh search repos`, 코드 검색 ("2609.28258", "InsertionWM"), 웹 검색 모두 결과 없음	—	—	—	—
nicklashansen/tdmpc2	TD-MPC2 공식 구현(방법의 기반)	방법 원저자 공식	MIT	999	`332f19e` (2026-10-20)
bingjietang718/automate	AutoMate **프로젝트 웹사이트 소스** (README에 CC BY-SA 4.0 웹사이트 표기). 정책 학습 코드가 아닙니다	저자 계정, 코드 아님	명시 없음(웹사이트 CC BY-SA 4.0)	0	`ce95071` (2024-10-26 push)
isaac-sim/IsaacGymEnvs	Isaac Gym 강화학습 환경 모음. AutoMate 환경이 이 계열에 기반했는지는 확인하지 못함	NVIDIA 공식	NOASSERTION (LICENSE 파일 확인 필요)	2,950	`aeed298` (2024-10-26 push)
ShaneFlandermeyer/tdmpc2-jax	TD-MPC2의 JAX 구현(커뮤니티)	비공식	MIT	82	push 2026-07-28

- **AutoMate 코드:** 논문 VI-A는 "All AutoMate results are reproduced using the official codebase"라고 쓰고, VI-B 각주는 "released codebase"를 말합니다. 그러나 `bingjietang718/automate` 는 웹사이트 소스뿐입니다. **논문이 말하는 공식 학습 코드는 이 검색으로는 찾지 못했습니다.** 따라서 AutoMate 수치를 우리 조건에서 재현할 방법이 없습니다.
- **TD-MPC2 기본 설정(`tdmpc2/config.yaml`, commit `332f19e`):** 호라이즌 3, 샘플 512, 엘리트 64, 반복 6, 정책 궤적 24, 온도 0.5, 잠재 차원 512, 가치 bins 101. 이 논문의 설정이라고 확정할 수 없습니다. 논문에 명시가 없기 때문입니다 (`03_analysis.md` §7).
- **Isaac Gym:** 논문 시뮬레이션의 기반입니다(III절 "we leverage Isaac"). CUDA GPU가 있어야 하므로 이 맥에서는 실행할 수 없습니다.
- **체크포인트와 데이터:** 확인된 것이 없습니다. 자산 100쌍의 원본은 AutoMate 측이 공개했는지 확인하지 못했습니다.
- **HF:** 이 논문 전용 모델이나 데이터셋은 검색되지 않았습니다.

결론. 공식 코드가 없습니다. 재현 가능한 자산은 TD-MPC2 공식 구현(MIT)과 Isaac Gym 환경 모음뿐입니다. 이 맥에서 TD-MPC2 코드를 그대로 쓰는 것은 가능하지만(torch 설치 필요), 조립 환경과 자산은 직접 만들어야 합니다.

5. 이 논문을 읽을 때 같이 볼 것

1. AutoMate [1]의 실험 설정과 생성 정책 수치(7%의 출처).
2. TD-MPC2 [31]의 계획 설정과 MPPI 세부(샘플, 호라이즌).
3. TD-MPC2 다과제 [32]: 다과제 확장에서 학습 규모 효과가 어떻게 보고되는지.
4. Fabrica [42]: 능동 지각 방향과 이 논문의 한계(VII절)의 연결.