KineFuse: 분석 리포트

게시용 버전 · 원문 https://arxiv.org/abs/2607.14842 · arXiv:2607.14842v1 · IROS 2026 (채택) · 저자 Ahn, Lee, Park, Hwang · 공식 코드 없음(저장소는 프로젝트 페이지뿐) · 분석일 2026-11-09 · 라이선스 CC BY-NC-ND 4.0

핵심 요약

1. **무엇을 하는가:** 손가락이 가리는 물체의 6D 자세를, 사전 학습된 시각 추정기(FoundationPose 정제 네트워크)에 관절 위치·속도, 근위 F/T, 손끝 접촉을 붙여 추적합니다. 손가락 단위 4토큰 인코더를 네 가지 대안과 비교합니다.
2. **평가 단계에 따라 차이가 다르게 보입니다:** 프레임 단위에서는 차이가 1.12배(표 없음), 개방 루프 추적에서 2배(Table I: 8.11 대 4.04 cm), 하위 과제 성공에서 15.8배(Table II: 평균 4.53 대 0.29, KineFuse 대 16-token)입니다.
3. **Abstract의 "추적에서 15배"는 본문과 맞지 않습니다:** 15배는 하위 과제 성공이고, 추적은 2배입니다.
4. **본문 주장 중 여러 개가 표와 맞지 않습니다:** "KineFuse만 각도 오차가 일정", "격차가 높은 가림에서 벌어짐", "0-20%에서 비슷함", "두 정책 모두", "성공 9%"는 모두 표와 어긋납니다.
5. **통계는 약합니다:** 3 seeds입니다. 조작 성공 24개 칸 중 Holm 보정 후 유의한 칸은 3개입니다. 위치 오차 칸은 24개 중 12개가 유의합니다.
6. **norm dominance는 측정되지 않았습니다:** 노름과 attention 질량을 보고하지 않았습니다. 가정 모델(toy)로는 노름 비 약 2-4배에서 촉각 토큰이 attention을 지배하고, 표준화하면 사라지며, ridge 벌점이 있을 때 스케일이 몫을 바꿉니다.
7. **프레임 격차가 chain에서 커지는 조건:** 교정 이득이 약할수록 chain 증폭이 커지고, 이득이 0.1 이하이면 발산합니다. 논문의 메커니즘인지는 확인되지 않습니다.
8. **구현 가능성:** 공식 재현은 불가능합니다(코드·데이터·CUDA·실물 손). 아이디어 재구현은 구조 자체는 쉽지만 촉각과 자세 GT가 함께 있는 데이터 확보가 어렵습니다. 이 맥에서는 계산 검증까지 가능합니다.

01. 논문 분석: KineFuse (arXiv:2607.14842)

KineFuse는 다지 손의 **고유감각(관절 위치·속도), 근위 F/T(3축, 손가락 4개), 손끝 이진 접촉**을 사전 학습된 시각 6D 추적기(FoundationPose 정제 네트워크)에 붙여, 손가락이 가리는 물체의 자세를 추적하는 연구입니다. 저자는 손 구조(URDF)를 쓴 손가락 단위 인코더를 제안하고, 다섯 인코더 설계를 세 단계(프레임 단위, 개방 루프 추적, 하위 과제 조작)에서 비교합니다. 게재는 IROS 2026 (채택, arXiv 주석 확인)입니다. 본문 인용은 논문의 절(Sec.), 표(Table), 그림(Fig.) 번호를 씁니다. 수치 재계산은 `03_analysis.md`, 주장별 판정은 `04_claim_verification.md`에 있습니다.

1. Abstract: 무엇을 주장하나

Abstract는 세 가지 발견을 내세웁니다.

- **(i) 평가 단계에 따라 차이가 다르게 보인다.** 프레임 단위 평가에서는 인코더 차이가 안 보이고(최고/최저 비 1.12), 순차 추적에서는 차이가 커진다고 씁니다.
- **(ii) 구조화된 인코더는 교차 모달 게이팅을 스스로 배운다.** 병진은 시각만, 회전은 주의(attention) 헤드 하나로 촉각을 본다고 합니다.
- **(iii) 손가락 단위 4토큰이 가장 좋다.** flat 융합과 관절 단위 표현은 "norm dominance"로 시각을 억누른다고 합니다.

Abstract에는 한 가지 불일치가 있습니다. (i)은 "sequential tracking amplifies architectural differences by up to 15 times"라고 쓰지만, 본문 Sec. I(기여 2)과 Sec. V(결론)는 **2배는 추적, 15배는 하위 과제 조작**이라고 나눕니다. Table I의 추적 차이는 약 2배이고, 15배는 Table II(성공 횟수)에서 나옵니다. 따라서 "15배는 순차 추적에서"라는 문장은 본문과 맞지 않습니다. 프로젝트 페이지의 요약 문장도 2배(추적)와 15배(조작)를 나눠 씁니다.

2. Method

2.1 문제 설정 (Sec. III-A)

- 입력: RGB-D 관측 I_t, 촉각 관측 $h_t \in R^{J\times\tau\times C}$. $J = 16$ 관절(손가락 4×4), $\tau = 4$ 스텝(시간 이력).
- 출력: 카메라 좌표계의 물체 자세 $\hat{T}_t \in SE(3)$.
- 센서 배치: 모든 관절이 위치·속도(q, $\dot{q}$)를 줍니다. 손끝 4개는 이진 접촉을 추가로 줍니다. 3축 근위 F/T는 관절 4개에만 있고(S_{FT}, $|S_{FT}| = 4$), 가용성 플래그가 붙습니다.
- 가정: 물체 CAD 모델과 hand-eye 보정을 알고 있습니다(Sec. III-A).

2.2 시각 백본 (Sec. III-B)

FoundationPose 정제 네트워크를 **고정(frozen) 백본**으로 씁니다(Sec. I, 기여 설명). 렌더링된 자세 가설과 관측 크롭을 같은 CNN으로 인코딩해 $L = 400$ 토큰(20×20), $D = 512$를 만듭니다.

2.3 다섯 인코더 설계 (Sec. III-C, Fig. 3)

설계	구조	토큰 수
(a) Naive	모든 관절 특징을 한 벡터로 이어 선형 투영	1
(b) FingerMLP	손가락별 MLP, 이후 손가락 간 self-attention, 구조 편향 없음	4
(c) 16-token	손가락 내·간 attention을 관절 단위로, 풀링 없음	16
(d) KineFuse	손가락 내 마스크 attention → 학습된 cross-attention 풀링(16→4) → URDF 편향 Graphormer 2층	4

설계	구조	토큰 수
(V-only)	촉각 없음(FoundationPose 기준선)	0

Sec. III-C 첫 문장은 "five encoder designs"라고 쓰지만, 나열된 촉각 인코더는 네 개이고 V-only가 나머지 하나로 보입니다. 이 점은 본문에 명시되지 않아 확인이 필요합니다.

KineFuse의 세부 식:

- 관절 토큰화: x^(j) ∈ R^28(= τ·C, C = 7로 추정)을 두 층 MLP와 LayerNorm으로 투영하고 손가락 정체성·위치 임베딩을 더합니다(식 없이 본문 서술). $\hat{\mathbf{z}} = W_2\,\varphi(\mathrm{LN}(W_1 x))$, $z^{(0)} = \hat{\mathbf{z}} + e_{finger} + e_{pos}$.
- 손가락 내 attention: 마스크 M_finger로 같은 손가락 관절끼리만 두 층 attention을 합니다. 원위 F/T가 근위 관절로 전달되게 하려는 장치입니다.
- 손가락 풀링: 손가락마다 학습 질의 하나가 관절 4개를 보고 요약 토큰 하나를 만듭니다(16 → 4).
- 손가락 간 그래프 attention: Graphormer 2층. 편향 B ∈ R^{4×4×H}는 URDF에서 나온 홉 거리, 대향 관계, 인접 여부를 MLP로 바꾼 값입니다. 손 구조 정보는 손(hand) 기하에서만 오고, 물체 기하에서는 오지 않습니다(Sec. VI, 한계 (ii)).

2.4 융합과 출력 (Sec. III-D, 식 1-5)

- 식 (1): $z_t = [v_t\ ;\ h_t] \in R^{(L+4)\times 512}$. **시각과 촉각 토큰을 시퀀스 차원으로 이어 붙입니다**(flat 토큰 concat). 이 단계에서 특징 노름을 정규화하지 않습니다.
- 식 (2)-(3): 병진 헤드와 회전 헤드가 각각 한 층 transformer encoder로 z를 처리합니다.
- 식 (4)-(5): 시퀀스 평균 후 투영합니다. 병진은 tanh를 거쳐 축별 정규화기 n_t(0.01 m)로 곱해 최대 1 cm 스텝으로 제한합니다. 회전은 6D 표현[33]을 씁니다.
- 추론: 정제를 두 번 합니다(두 번째 입력은 첫 출력). 추적에서는 초기 가설이 이전 프레임 추정입니다($\tilde{T}_t = \hat{T}_{t-1}$).
- Sec. III-D 끝: 코드베이스에 게이트 변형(촉각 전용 예측 분기와 신뢰도 게이트)이 있지만 게이트가 촉각 쪽으로 포화되어 **결과는 게이트 없이 직접 융합 출력**으로 냅니다.

2.5 학습 (Sec. III-E, 식 6)

- 2단계 학습. 1단계: 촉각 인코더를 촉각만으로 자세 예측(사전 학습). 2단계: 1단계 가중치와 FoundationPose 시각 가중치를 합쳐 전체를 미세조정합니다. 2단계 처음 3 epoch는 시각 백본을 고정하고, 그 뒤 모든 파라미터를 함께 학습합니다. 촉각 분기 학습률은 시각의 2.5배입니다.
- 학습 쌍: GT 자세에 [1°, 10°] 회전과 [2, 10] mm 병진의 무작위 교란을 더한 가설에서, 정답으로 가는 잔차 자세 변화를 예측합니다.
- 데이터: IsaacLab에서 강화학습 정책으로 수집한 in-hand 재배향 궤적. 깨끗한 시퀀스 약 2,000 프레임, 물리적 가림물(occluder)이 있는 시퀀스 약 1,000 프레임(Sec. IV-A). 학습은 합친 데이터셋으로 합니다.
- 증강: 사각형 가림 마스크(관측 RGB-D), 힘 채널에 곱셈 스케일, 덧셈 오프셋, 가우스 잡음, 확률적 탈락(dropout).
- 손실 식 (6): $L = L_{pose} + \lambda_{ADD} L_{ADD} + \lambda_{attr} L_{attr} + \lambda_{pen} L_{pen}$. L_{pose}는 자세 증분 MSE, L_{ADD}는 ADD 손실, L_{attr}은 손-물체 근접(접촉 영역 주변), L_{pen}은 메시 관통 벌점입니다. λ 값은 본문에 없습니다.

3. Experiments

3.1 설정 (Sec. IV-A)

- 하드웨어: 16 자유도 4손가락 손 [35](저자 그룹의 손), 손끝에 3축 F/T와 이진 접촉. 실환경은 RealSense D435i를 손목에 달았습니다.

- 과제: 펜슬 모양 공구를 잡고 끝을 목표 영역에 맞추는 재배향(Fig. 5). 물체는 펜슬 하나입니다.
- 평가 지표: 위치 오차(cm), 각도 오차(도), ADD(cm). 하위 과제 성공은 300 스텝 에피소드에서 2 cm·15도 이내로 맞춘 횟수의 평균입니다.
- 가림 프로토콜: 평가 때 RGB-D 관측 중앙에 사각형 마스크를 0, 10, 30, 50, 70, 90%로 씌웁니다(Fig. 9b).
- 기준선: 같은 FoundationPose 백본, 같은 데이터, 같은 증강. 인코더만 다릅니다(Sec. IV-A).

3.2 프레임 단위 (Sec. IV-B, 본문 텍스트)

"all models achieve comparable per-frame accuracy (ADD < 0.011 cm), with a best-to-worst ratio of only 1.12 times". **이 수치를 담은 표나 그림은 논문에 없습니다.** Sec. IV-B 첫 문장은 Table II와 Fig. 8을 가리키지만, Table II는 조작 성공이고 Fig. 8은 정성 비교입니다. 단위(cm)도 의심스럽습니다. 0.011 cm는 0.11 mm라서 Table I의 추적 오차(3-8 cm)와 비교하면 지나치게 작습니다. 미터 단위일 가능성을 열어 둬야 합니다.

3.3 개방 루프 순차 추적 (Sec. IV-B, Table I, Fig. 6, Fig. 8)

Table I(3 seeds): KineFuse의 평균 위치 오차는 4.04 cm, V-only는 8.11 cm입니다(2배). 각도 오차는 KineFuse가 47.6도, V-only가 54.9-79.4도 범위입니다. 본문은 "KineFuse만 각도 오차가 일정하다"고 씁니다. Fig. 6은 30% 가림에서 149 스텝 drift를 보여 줍니다. V-only는 계속 벌어지고, KineFuse는 20 스텝 뒤 안정된다고 합니다. Fig. 8은 같은 조건의 정성 비교이고, 주의(attention) 비율이 병진 100% 시각, 회전 75/25(시각/촉각)라고 적혀 있습니다.

3.4 하위 과제 조작 (Sec. IV-C, Table II, Fig. 7)

Table II(성공/에피소드, 3 seeds). GT 상한은 21.25입니다. 평균은 KineFuse 4.53, FingerMLP 2.00, Naive 1.68, V-only 1.17, 16-token 0.29입니다. 본문은 "KineFuse가 V-only보다 두 RL 정책 모두에서 높다"고 쓰지만, 표는 정책 하나만 보여 줍니다.

Fig. 7은 펜슬 조작에서 각 모델의 평균 위치 오차를 RL 정책의 잡음 허용 곡선 위에 얹습니다. 저자는 "오차가 허용 범위를 넘으면 성공이 떨어진다"고 해석합니다. 그러나 16-token(위치 오차 5.8 cm)은 Naive(위치 오차 8 cm)보다 성공이 낮습니다. 위치 오차만으로는 순서가 설명되지 않습니다(`03_analysis.md` §2).

누적 drift가 주요 병목이고, 성공은 GT 상한의 "9%"로 떨어진다는 문장이 있습니다(Sec. IV-C). 표 값으로는 KineFuse가 평균 21%입니다. 9%와 맞는 값은 V-only 70% 칸(1.97/21.25 = 9.3%) 정도뿐입니다.

3.5 실환경 (Sec. IV-E, Table III, Fig. 10)

고유감각 jitter와 실패 횟수를 proxy로 쓰고, AprilTag 기준으로 Table III를 냅니다. Table III는 한 궤적의 다섯 시점(0, 67, 135, 202, 269)입니다. 시드도 궤적 수도 없습니다. Fig. 10 주석은 AprilTag를 **초기 GT 자세로만** 쓴다고 해서, 이후 시점의 기준이 무엇인지 불분명합니다.

3.6 절제 (Sec. IV-D)

- 구조 대 정보: 추론 때 촉각 채널을 모두 0으로 두면 추적이 거의 같고, V-only보다 "2.3배 낫다"고 씁니다. 이 실험의 표나 수치는 없습니다. 저자는 이를 "구조적 기여"(inductive bias)로 해석합니다.
- 실험 설계 문제: 0 입력 실험은 같은 학습 절차(1단계 사전 학습 포함)를 거친 모델에 대해서만 의미가 있습니다. V-only에는 1단계가 없습니다. 따라서 "구조 효과"와 "사전 학습 효과"가 구분되지 않습니다(`04_claim_verification.md` C16).

4. Limitations (저자 + 분석)

4.1 저자가 밝힌 한계 (Sec. V)

- 시뮬레이션 한 물체(펜슬), 실환경은 정성 시연뿐입니다.
- drift 누적이 남은 병목이고, 시간 정규화나 재초기화는 다음 과제로 미룹니다.
- 모듈형 지각-정책 구조가 drift를 정책이 고치지 못하게 합니다. 종단간 학습이 해결책일 수 있다고 씁니다.

4.2 분석하면서 추가로 찾은 한계

1. **손 구조 편향과 "고유감각 누수"의 구분이 없습니다.** 관절 위치 q는 손 자세를 알려 주고, 잡은 물체의 자세는 손 자세에 묶여 있습니다. 따라서 q만으로도 물체 자세에 대한 사전 정보가 생깁니다. 제로화 실험은 촉각 전체를 0으로 둘 뿐이고 고유감각만 빼는 대조가 없습니다.
2. **"gating"이라는 용어의 혼선.** Abstract의 "cross-modal gating"은 주의 질량의 배분이고, 학습된 게이트(신뢰도 게이트)는 포화되어 쓰이지 않았습니다. 두 개념이 섞여 있습니다.
3. **norm dominance는 측정되지 않았습니다.** 특징 노름, 토큰별 노름, 주의 질량 어느 것도 보고되지 않습니다 (`03_analysis.md` §5, §6의 toy가 그 조건을 봅니다).
4. **작은 데이터.** 깨끗한 2,000 프레임과 가림 1,000 프레임으로, 펜슬 하나에 대한 학습입니다. 학습 가능 파라미터 대비 데이터가 작아서, 인코더 차이가 과적합 차이일 수 있습니다.
5. **3 seeds, 많은 칸.** 표 I과 II는 3 seeds입니다. Holm 보정 후 Table II에서 유의한 칸은 24개 중 3개입니다 (`03_analysis.md` §3).
6. **ADD 대칭.** 펜슬은 긴 축 둘레가 거의 대칭입니다. ADD(비대칭 가정)를 쓰면 축 회전 오차가 과대평가되고, 회전 오차 130-177도(Table III)가 이 때문인지 확인할 수 없습니다.
7. **시각 백본 고정 여부가 모순됩니다.** Sec. I와 Fig. 2 설명은 "frozen"이지만, Sec. III-E는 2단계 이후 모든 파라미터를 학습한다고 씁니다.

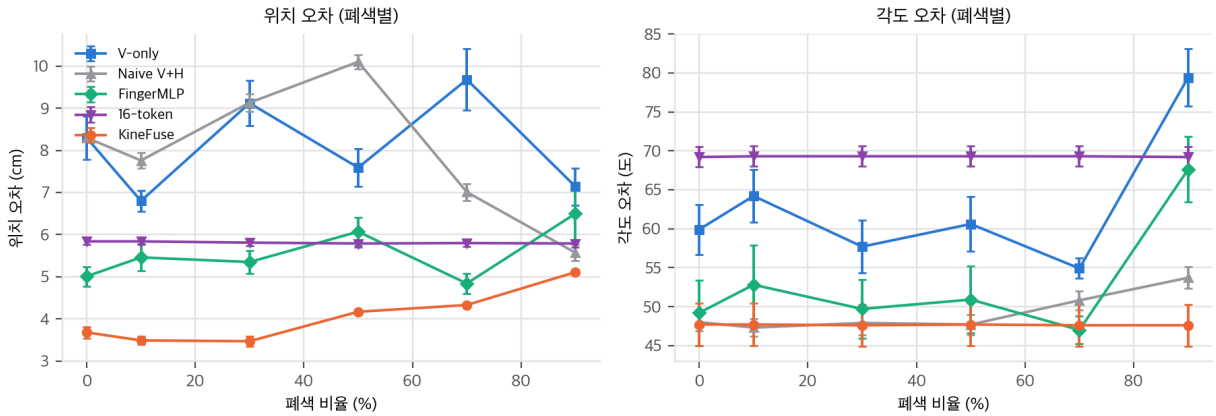
5. 한 줄 평가

구조화된 손가락 토큰이라는 설계 아이디어는 명확하고 구현이 어렵지 않습니다. 그러나 **평가 설계와 수치 보고에 해결되지 않은 불일치가 많습니다**(15배의 위치, 격차 확대 주장, 9%, "두 정책", 고정 백본). 공개 코드가 없어서 검증할 수 없는 항목도 많습니다. 결과를 인용할 때는 Table I의 2배(추적)와 Table II의 15배(조작)를 따로 적는 편이 안전합니다.

03. 재계산과 유도

모든 수치는 `analysis/table_check.py`(표 값 재계산, 결과 `table_check_results.json`), `analysis/norm_dominance_toy.py`(`norm_dominance_toy_results.json`), `analysis/drift_toy.py`(`drift_toy_results.json`)로 CPU, 단일 스레드에서 다시 만들었습니다. 논문 표 값은 `paper/paper.txt`와 PDF 렌더링을 눈으로 대조했습니다. 표준편차는 표본 표준편차(ddof=1)로 보았고, ddof=0일 때도 결론이 같은지 확인했습니다.

1. Table I: 개방 루프 추적 다시 읽기



논문 Table I (3 seeds 평균 ± 표준편차). 개방 루프 추적: 이전 프레임 추정이 다음 초기값.

논문 Table I 값으로 그린 그래프. 점은 3 seeds 평균, 막대는 표준편차.

1.1 평균과 본문 수치

설계	위치 평균 (cm)	각도 평균 (도)
V-only	8.11	62.8 (54.9-79.4)
Naive V+H	7.98	49.2 (47.3-53.7)
FingerMLP	5.54	52.9 (47.0-67.6)
16-token	5.81	69.3 (69.2-69.3)
KineFuse	**4.04**	47.7 (47.6-47.7)

- 본문 "4.04 cm"와 "8.11 cm": 재계산과 일치합니다(4.042, 8.105).
- 본문 "2배 낮다": V-only/KineFuse = 2.01. 맞습니다. Naive/KineFuse도 1.97입니다.
- "47.6도 ± 0.1": 여섯 가림 수준 평균은 47.65입니다. "± 0.1"은 가림 수준 사이의 흔들림이고, 표의 seed 표준편차는 2.7입니다. 두 값을 섞으면 안 됩니다.

1.2 본문 주장과 맞지 않는 부분

1. **"KineFuse만 각도 오차가 일정하다"는 맞지 않습니다.** 16-token은 69.2-69.3도로 더 일정합니다(변동계수 0.0007, KineFuse는 0.0011). Naive도 47.3-53.7도로 거의 일정합니다. 차이는 "일정함"이 아니라 **KineFuse의 각도 수준이 가장 낮다**는 쪽입니다.
2. **"격차가 높은 가림에서 벌어진다"는 맞지 않습니다.** 0%와 90%의 위치 격차(기준 KineFuse)를 보면 모든 기준선에서 격차가 **줄어듭니다**.

기준선	0% 격차 (cm)	90% 격차 (cm)
V-only	4.62	2.03
Naive V+H	4.62	0.46
16-token	2.16	0.68
FingerMLP	1.33	1.39 (사실상 같음)

3. **"낮은 가림(0-20%)에서는 모든 모델이 비슷하다"는 맞지 않습니다.** 0%에서 V-only는 8.30 cm, KineFuse는 3.68 cm입니다. 차이가 4.6 cm로, 가장 큰 격차 중 하나입니다. 본문은 "haptic 기여는 가림이 40%를 넘을 때 드러난다"고 쓰지만, 표는 0%에서 이미 2배 차이를 보여 줍니다.
4. **"모든 가림 수준에서 KineFuse가 가장 낮다"는 맞습니다**(6/6). 70%에서는 FingerMLP(4.84)보다 KineFuse(4.33)가 낮고, 90%에서는 Naive(5.57)보다 KineFuse(5.11)가 낮습니다.

1.3 Fig. 7의 점 위치

Fig. 7은 평균 위치 오차를 눈으로 읽으면 V-only ≈ 8.3, Naive ≈ 8.3, FingerMLP ≈ 5.0, 16-token ≈ 5.8, KineFuse ≈ 3.6입니다. 여섯 수준의 평균(4.04 등)과는 KineFuse가 0.4 cm 어긋납니다. 0-30% 평균은 V-only 8.07, Naive 8.40, FingerMLP 5.27, 16-token 5.83, KineFuse 3.55로 눈 판독에 더 가깝습니다. 어떤 부분집합을 그렸는지는 본문에 없습니다.

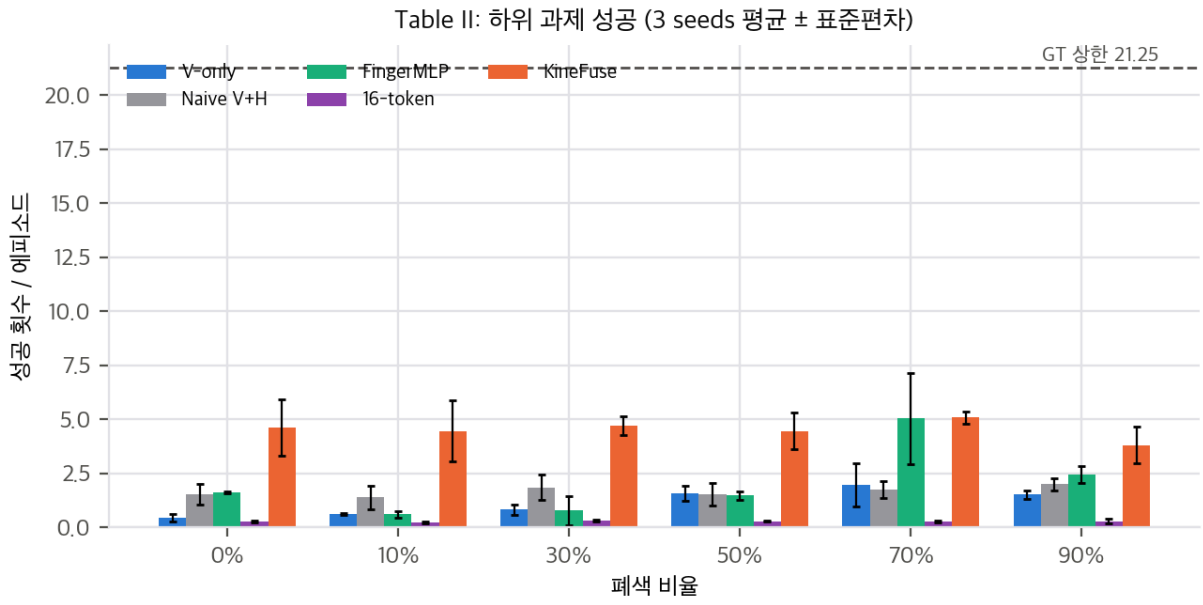
1.4 유의성 (Welch t, 3 seeds)

KineFuse와 기준선 네 개의 쌍별 비교를 가림 수준(6) 칸마다 하고, 24 검정을 Holm으로 보정했습니다.

- 표 I 위치: 24 중 **12개 유의**(보정 $p < 0.05$). 두 표준편차 정의에서 같은 결과입니다.
- 16-token과의 90% 칸은 보정 후 $p = 0.016$으로 유의합니다.
- V-only 0% 칸은 보정 후 $p = 0.07$로 유의하지 않습니다.

위치 차이는 seed를 넘어 비교적 안정적입니다. 각도 오차에는 유의성 검정을 하지 않았습니다. seed 표준편차가 2.7-5.1도로 커서 3 seeds로는 검정력이 낮을 것입니다.

2. Table II: 하위 과제 성공 다시 읽기



논문 Table II 값으로 그린 그래프. 점선은 GT 상한 21.25.

2.1 평균과 "15배"

설계	평균 성공	GT 대비 (%)
GT	21.25	100
KineFuse	**4.53**	21.3
FingerMLP	2.00	9.4
Naive V+H	1.68	7.9
V-only	1.17	5.5
16-token	0.29	1.3

- **"15배"의 정의:** KineFuse/16-token의 평균 비는 15.8입니다. 칸별 비는 17.1, 19.4, 14.3, 14.9, 17.6, 12.7이고, 칸별 로그비 95% 구간은 대략 8-29배로 넓습니다(delta method, 3 seeds).
- 본문은 이 15배를 "순차 추적"이 아니라 **하위 과제**에 붙입니다. Abstract의 "sequential tracking … up to 15 times"는 정의와 맞지 않습니다(`01` §1).
- KineFuse/V-only의 평균 비는 3.89입니다. 15배는 기준선 중 가장 낮은 16-token에 대한 비라서 "최고/최저" 비로 부르는 편이 정확합니다.

2.2 "GT 대비 9%"

본문은 누적 drift가 성공을 GT 상한의 9%로 떨어뜨린다고 씁니다. KineFuse 평균은 21%, 칸별로는 18-24%입니다. 9%에 가까운 값은 FingerMLP 0%(7.7%), Naive 90%(9.4%), V-only 70%(9.3%)뿐이어서, 어떤 칸을 말하는지 특정되지 않습니다.

2.3 유의성

24 검정 중 Holm 보정 후 유의한 칸은 **3개**뿐입니다(V-only 30%: p = 0.021, Naive 70%: p = 0.020, 16-token 70%: p = 0.029). KineFuse의 0%와 10% 칸은 SD가 1.3-1.4라서 평균이 크게 달라도 3 seeds로는 판별이 약합니다.

2.4 V-only 성공이 폐색과 함께 오른다

V-only 성공은 0%의 0.46에서 70%의 1.97로 오릅니다(Spearman ρ = 0.83, n = 6, p = 0.042). 폐색이 실패를 늘린다는 가정과 반대입니다. 이 칸들의 seed 편차(1.0)도 커서 노이즈일 가능성이 큽니다. 어쨌든 **조작 성공 지표가 폐색 강도를 잘 반영하지 않는다**는 신호이므로, 15배 주장은 이 지표의 신뢰도에 기댑니다.

2.5 무엇이 성공 순서를 설명하나

설계 5개의 평균에서 각도 오차 순위와 성공 순위의 Spearman 상관은 **ρ = −0.9(p = 0.037)**, 위치 오차와는 **ρ = −0.7(p = 0.19)**입니다. 위치 평균 순위는 KineFuse(4.04) < FingerMLP(5.54) < 16-token(5.81) < Naive(7.98) < V-only(8.11)입니다. 16-token은 위치 오차가 세 번째로 낮지만 성공은 가장 낮습니다. 따라서 Fig. 7의 "위치 오차 → 성공" 해석은 이 데이터로 지지되지 않고, 회전 오차가 더 나은 설명 변수로 보입니다. 다만 설계가 5개뿐이라 이 상관은 가설 수준입니다.

2.6 16-token의 "움직이지 않는" 오차

16-token의 위치 오차는 5.79-5.84 cm(변동계수 0.004), 각도는 69.2-69.3도, 성공은 0.23-0.33입니다. 가림이 0%에서 90%로 변해도 출력이 거의 변하지 않습니다. 시각 입력을 거의 쓰지 않거나, 학습이 수렴하지 않은 상수 출력에 가깝다는 뜻입니다. 이 경우 "관절 단위 토큰이 시각을 누른다"는 해석보다 **학습 실패** 해석이 먼저 검토되어야 합니다(`04_claim_verification.md` C14). 논문은 이 설계의 학습 곡선이나 검증 손실을 보고하지 않습니다.

3. Table III: 실환경 한 궤적

시점 (프레임)	0	67	135	202	269
위치 V-only (mm)	11.9	78.2	108.2	95.3	96.6
위치 KineFuse (mm)	1.4	17.4	35.9	58.1	85.4
회전 V-only (도)	6.7	57.7	130.3	177.4	94.3
회전 KineFuse (도)	2.5	30.8	63.5	86.6	131.5

- 위치: KineFuse가 다섯 시점 모두 낮습니다. 차이는 시점 269에서 11 mm로 줄어듭니다.
- 회전: KineFuse가 네 시점에서 낮지만, **시점 269에서 131.5도로 V-only(94.3도)보다 높습니다.** 본문은 이 역전을 언급하지 않습니다.
- 회전 오차가 130-177도라는 것은 자세가 뒤집혔다는 뜻입니다. 펜슬의 축 대칭과 ADD 지표 사용이 원인일 수 있습니다(`01` §4.2 (6)).
- 한 궤적, 시드 없음, 기준(AprilTag) 시점 불명확입니다. 통계적 주장은 할 수 없습니다.

4. 2.3배 주장 (영 입력 실험)

"촉각을 0으로 두면 V-only보다 2.3배 낫다"는 수치는 논문에 표가 없습니다. 참고로 0-30% 평균의 V-only/KineFuse 비는 8.07/3.55 = 2.27입니다. 영 입력 실험 결과가 KineFuse 전체 모델과 같다고 했으므로, 이 값이 그 실험을 가리킬 가능성이 있습니다. 확인할 방법은 없습니다.

5. 유도

5.1 프레임 격차와 chain 증폭

프레임 t의 정제를 선형 근사하면 교란 $d_t = e_{t-1} - u_t$(u_t는 물체 회전 드리프트)에 대해

$$e_t = (1 - \kappa)\, d_t + \varepsilon_t, \quad \rho \equiv 1 - \kappa$$

입니다. 정상 상태 분산은

$$\mathrm{Var}(e) = (\rho^2 \sigma_u^2 + \sigma_\varepsilon^2) / (1 - \rho^2)$$

입니다. 두 설계 A, B의 **프레임 단위** 이득 비를 $(1-\kappa_B)/(1-\kappa_A) = 1.12$로 고정하면, chain 표준편차 비는 κ_A가 작을수록 커지고 $\rho_B \geq 1$에서 발산합니다.

κ_A	ρ_A	ρ_B	chain std 비 (B/A)
0.9	0.10	0.112	1.00
0.55	0.45	0.504	1.03
0.3	0.70	0.784	1.15
0.2	0.80	0.896	1.35
≤ 0.1	≥ 0.90	≥ 1.008	발산

해석: 프레임 단위에서 12%인 격차는, 교정이 약한 시스템에서는 chain에서 35%로 커지고, 교정 이득이 1에 가까워지면 발산합니다. 즉 **프레임 평가는 chain의 안정성 여유($1-\rho$)를 보지 못합니다.** 이 식은 논문의 것이 아니라 가정 모델입니다. 논문의

1.12→2배→15배가 이 메커니즘인지는 확인되지 않습니다.

5.2 노름과 attention

flat 토큰 concat 뒤 한 층 attention에서 질의 q, 키 k = W_k x의 로짓은 (W_k x)·(W_q q)/√d입니다. 질의를 고정하면 로짓은 $\|x\|$에 선형으로 커지고, 질의도 같은 특징에서 나오면 $\|x\|^2$로 커집니다. 따라서 **노름 비가 attention 질량을 결정합니다.** 시퀀스 평균(식 4)만 본다면 촉각 토큰 K개의 질량은 K/(N+K)입니다.

K	개수 기준 질량 (N=400)
1	0.25%
4	0.99%
16	3.85%

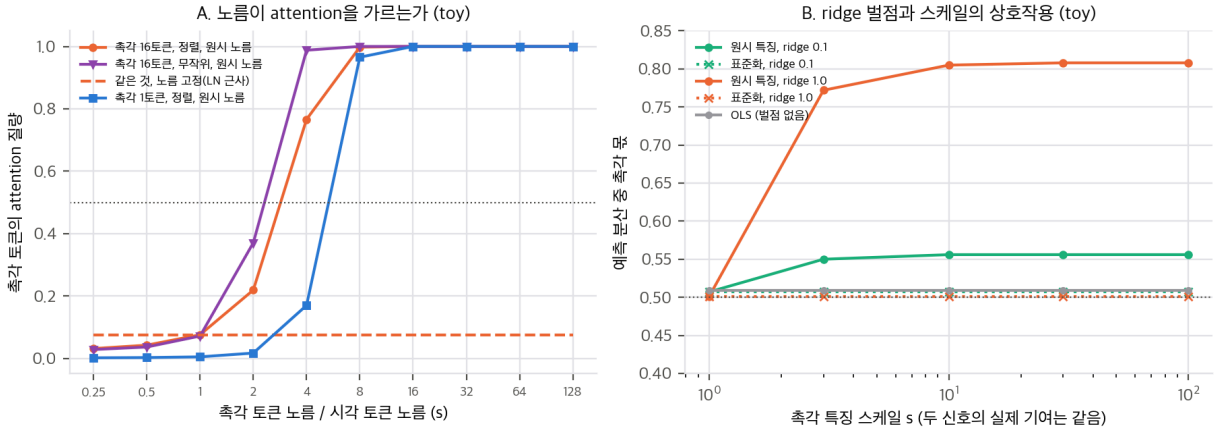
개수만 보면 16토큰이 4토큰보다 촉각 몫이 커야 합니다. "관절 토큰이 시각을 누른다"는 설명은 **개수가 아니라 노름**에 기대야 합니다. 논문은 노름을 보고하지 않으므로, 이 주장은 검증할 수 없습니다(`04_claim_verification.md` C18).

5.3 ridge 벌점과 스케일

촉각 특징이 x_h = s·z_h(z_h는 표준화)일 때, 학습 가중치는 w_h = $\tilde{w}$_h/s로 바뀝니다. 벌점 $\lambda\|w\|^2$는 $\lambda\|\tilde{w}_h\|^2/s^2$가 됩니다. 즉 **표준화 좌표에서 촉각 가중치의 유효 벌점은 λ/s^2**입니다. 스케일이 크면 벌점이 약해져 촉각 몫이 커집니다. 벌점이 없는 OLS에서는 가중치가 스케일을 보상해서 몫이 변하지 않습니다. 이 두 결론은 아래 toy B에서 확인됩니다.

6. toy 결과 요약

6.1 norm_dominance_toy.py (d = 64, 시각 토큰 400개, 시각 노름 1)

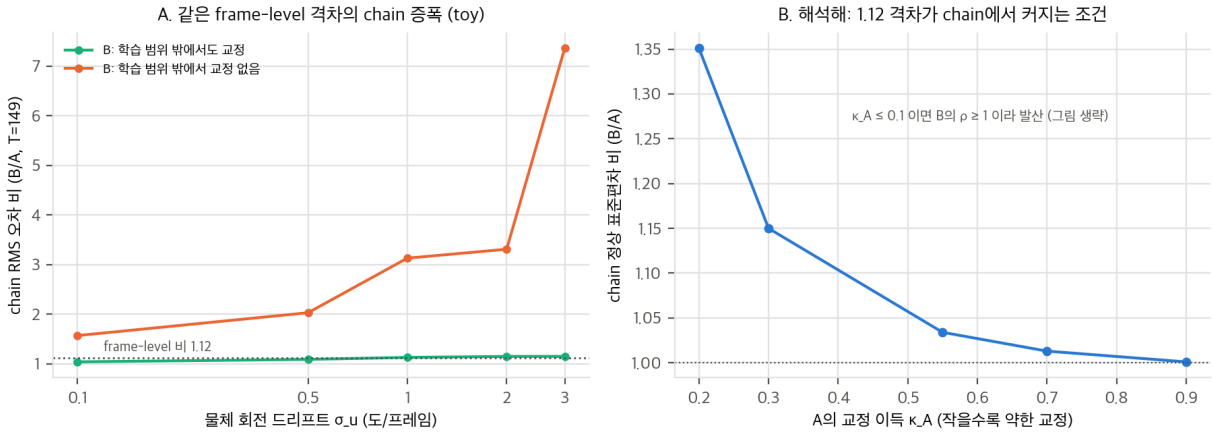


norm_dominance_toy 결과. A: 촉각 토큰 노름 대 attention 질량, B: ridge 벌점에서 촉각 몫. 가정 모델이며 논문 실험이 아닙니다.

- **A (attention 질량).** 로짓 표준편차가 무작위 초기화 수준(0.016)이면 K = 16이라도 s = 16까지 질량은 개수 기준(3.85%)과 같습니다. 로짓을 날카롭게(표준편차 1) 맞추면 임계값이 생깁니다. 정렬된 16토큰은 s = 1에서 7.6%, s = 2에서 21.9%, s = 4에서 76.6%입니다. 노름을 고정하면(LN 근사) 질량은 s와 무관하게 7.6%입니다. **임계 노름 비(약 2-4배)는 학습된 가중치에 달렸고, 논문은 이를 보고하지 않습니다.**
- **B (ridge).** 두 신호의 실제 기여는 같게 만들었습니다. OLS는 s에 무관하게 촉각 몫 0.497입니다. ridge λ = 1, s = 10에서 원시 특징의 촉각 몫은 0.79, 표준화는 0.49입니다. λ = 0.1에서는 0.54 대 0.50입니다. 이 설정에서 촉각 몫 증가는 R^2를 0.75에서 0.87로 **높였습니다**. 즉 "지배"가 항상 나쁘지는 않으며, 벌점 강도와 정보량에 따라 달라집니다.

- **C (GD, 고정 학습률).** 학습률은 가장 큰 스케일 특징에 맞춰 0.0086으로 골랐습니다(표준화는 0.75, 약 88배 차이). s = 10 원시 특징에서 T = 10 스텝에 촉각 몫은 0.995이고 시각만의 R^2는 0.08입니다. T = 2000에서는 0.50으로 수렴합니다. **단일 학습률에서 나타나는 일시적 지배**이고, 학습이 끝난 모델에 남는지는 이 toy로 말할 수 없습니다.

6.2 drift_toy.py (1차원 회전 오차, 도, T = 149)



drift_toy 결과. A: 같은 프레임 격차(1.12)의 chain 증폭, B: 해석해. 가정 모델이며 논문 실험이 아닙니다.

- **A (frame-level).** 교란 U[1, 10]도, 두 설계의 RMS 비는 1.119입니다(설계로 맞춤).
- **B (open-loop chain).** 물체 드리프트 σ_u = 0.1-3도/프레임.
  - κ_out = 0.55(범위 밖에서도 교정): chain 비 1.04-1.15. 격차가 크게 늘지 않습니다.
  - κ_out = 0(범위 밖에서 교정 없음): chain 비 1.57 → 2.03 → 3.13 → 3.31 → 7.36. 범위를 넘는 상태 비율이 σ_u = 3에서 8%입니다.
  - 교정이 없을 때(κ = 0) 누적 RMS는 $\sigma_u\sqrt{T}$, σ_u = 0.5면 6.1도입니다.
- **C (해석해).** §5.1 표와 같습니다.

toy가 보여 주는 것은 **"프레임에서 같아 보이는 두 설계가 chain에서 갈라지는 조건"** 입니다. (i) 학습 교란 범위 밖의 상태에서 교정 능력이 다르거나, (ii) 교정 이득이 1에 가까워 chain 여유가 작을 때입니다. 논문이 어느 쪽인지는 구분할 자료가 없습니다.

7. 빠진 수치 (계산에 필요했지만 논문에 없는 것)

- 프레임 단위 ADD 표(1.12의 근거)와 단위(cm/m).
- 특징과 토큰의 노름, attention 질량, 헤드 수.
- 시드 정의(3 seeds가 같은 데이터인지, 학습만 다른지).
- Table III의 시점 선택과 기준.
- λ_ADD, λ_attr, λ_pen, 학습률, epoch, batch, 데이터 분할.
- 영 입력(제로화) 실험 결과와 그 학습 절차.

추가 검증 (2026-11-11)

추가 검증 1. 고유감각 제로화와 촉각 제로화를 나눠 본 1자유도 추적 toy

목적. 논문의 "촉각을 0으로 두면 V-only보다 2.3배 낫다"(§4)는 촉각의 정보 효과인지, 관절 위치가 물체 자세를 이미 알려 주는 효과인지 구분되지 않습니다(`04` C16). 가정 모델에서 두 채널을 따로 제로화해, 제로화 대조가 어떤 정보를 빼는지 봅니다. 논문 수치를 재현하지는 않습니다.

설정 (가정).

- 관절 각 $q \sim U(-45°, 45°)$, 물체 각 $\theta = q + \delta$, $\delta \sim N(0, \sigma_\delta^2)$(파지 오프셋). $\sigma_\delta \in \{0, 2, 8, 20\}°$.
- 시각 $v = \theta + N(0, (2 + 20 \cdot occ)^2)$, 가림 $occ \in \{0, 0.3, 0.6, 0.9\}$(파지마다 무작위).
- 접촉 $c \sim Bernoulli(0.7)$. 접촉 시 촉각 $h = \delta + N(0, 3^2)$, 비접촉 시 $h = 0$.
- 파지 400개 × 프레임 50개, 절반 학습과 절반 평가. 시드 5개.
- 추정기: 표준화 후 선형 ridge($\lambda = 10^{-3}$). 손가락 토큰 구조가 없어서 정보량만 봅니다.
- 제로화: 추론 시 해당 채널의 원시 입력을 0으로 둔 뒤 표준화합니다.
- 실행 시간 약 0.2초(`analysis/extra_proprio_zero.py`, 결과 `analysis/extra_proprio_zero_results.json`).

결과. 각도 RMSE(도, 평균 ± 표준편차, 시드 5개, 가림 수준 평균).

σ_δ (도)	V	V+H	V+P	V+H+P	V+H+P, 촉각 0	V+H+P, 고유감각 0
0	11.44 ± 0.25	11.44 ± 0.25	0.06 ± 0.01	0.06 ± 0.01	0.06 ± 0.01	26.01 ± 0.06
2	11.44 ± 0.25	11.44 ± 0.25	1.91 ± 0.11	1.71 ± 0.08	1.90 ± 0.11	25.58 ± 0.10
8	11.52 ± 0.26	11.47 ± 0.26	6.60 ± 0.33	4.53 ± 0.21	6.90 ± 0.40	23.11 ± 0.34
20	11.84 ± 0.30	11.60 ± 0.28	10.63 ± 0.38	8.29 ± 0.38	12.31 ± 0.78	17.08 ± 0.71

$\sigma_\delta = 8°$에서 가림 수준별 RMSE(시드 0 한 번): V는 5.4°(가림 0)에서 16.9°(가림 0.9)로 오르지만, 촉각을 0으로 둔 모델은 7.2-7.5°로 가림과 무관합니다.

결론.

- **촉각만 있는 V+H는 V와 같습니다.** 접촉 신호는 δ만 알려 주므로, 관절 각 q 없이는 θ를 줄일 수 없습니다. 이 toy에서 촉각의 가치는 고유감각과 결합할 때만 나옵니다.
- **촉각 제로화는 이 가정 모델에서 정보를 정확히 뺍니다.** $\sigma_\delta = 8°$에서 촉각을 0으로 둔 V+H+P(6.90°)는 촉각 없이 학습한 V+P(6.60°)와 0.3° 차이입니다. 제로화 대조가 학습 제외 대조와 거의 같은 결과를 줍니다.
- **그러나 V에서 V+P로 가는 이득의 대부분은 고유감각에서 옵니다.** 고유감각을 0으로 두면 오차가 23°로 V(11.5°)보다 훨씬 나쁩니다. 즉 V-only와 비교한 배수에는 고유감각 채널의 몫이 들어갑니다. 이 toy의 촉각 정보 몫은 V+P에서 V+H+P로 갈 때 6.6°에서 4.5°로 줄어드는 만큼(약 31%)입니다.
- **2.3배는 재현되지 않았습니다.** 이 toy에서 V 대 촉각 제로화 모델의 비는 $\sigma_\delta = 8°$에서 11.5 / 6.9 = 1.7입니다. $\sigma_\delta = 20°$에서는 0.96으로, 촉각 제로화 모델이 V보다 오히려 나쁩니다(추론 때 입력 분포가 학습과 달라지는 효과). 값은 가정(σ_δ, 노이즈, 선형 추정기)에 크게 기댑니다.
- **한계.** 1자유도, 선형 추정기, 구조 없음, 사전 학습 없음. 논문의 손가락 토큰 구조와 1단계 사전 학습 효과는 이 toy로 분리할 수 없습니다. 제로화 대조로 "구조 효과"를 말하려면 학습 절차를 맞춘 비교가 필요하다는 `04` C16의 판단과 같은 결론입니다.

추가 검증 2. 학습 중 토큰 노름과 attention 질량: flat 토큰 대 손가락 4토큰

목적. §5.2와 §6.1의 toy가 가정한 "노름이 attention 질량을 정한다"는 경로를, 소형 융합 모델을 실제로 학습하면서 토큰 노름과 attention 질량을 기록해 확인합니다.

설정. `analysis/extra_token_norm.py` (torch, CPU 4스레드, 시드 3, 약 14.5분. 목표 10분을 넘었으나 상한 20분 안에서 끝났습니다).

- 합성 in-hand 데이터(자체 생성기): 물체 자세 $y \in R^3$(균일 −1-1)에서 시각 토큰 64개(16차원, 약한 잡음 포함)와 관절 토큰 16개(손가락 4개 × 관절 4개, 관절당 각도·sin·cos·토크 4값)를 만듭니다. 관절 각도는 tanh(Wy)라서 관절 정보가 강하고 시각 정보는 약합니다. 학습 6000개, 시험 1000개.
- 구조: flat은 시각 64 + 관절 16 = 80토큰, finger는 시각 64 + 손가락 4토큰입니다. 손가락 토큰은 관절 4개를 학습 질의 하나로 풀링합니다. 주의 층 2개, 4헤드, 폭 32, 잔차 FFN을 씁니다.
- 정규화: 없음 또는 pre-LayerNorm. 관절 특징 스케일 $s \in \{1, 10\}$(단위 차이를 모사)을 둡니다.
- 학습: Adam 1e-3, 배치 128, 1500 스텝. 100 스텝마다 기록합니다.
- 기록: 입력 임베딩 뒤 시각 토큰과 관절 계열 토큰(flat은 관절 토큰, finger는 손가락 토큰)의 평균 L2 노름, 그리고 관절 계열 키가 받는 attention 질량(질의, 헤드, 배치 평균, 두 층 평균). 개수 몫은 flat 20%, finger 5.9%입니다.
- 장치 CPU, torch 2.15.0, numpy 1.26.4, 약 869초.

결과. 시드 3개 평균, 시작 스텝 → 1500 스텝.

구조	스케일	정규화	관절 계열 attention 질량	개수 몫	노름 비(관절/시각)	시험 MSE(끝)
flat	1	없음	0.198 → 0.321	0.200	0.77 → 0.82	0.0022
flat	1	LN	0.196 → 0.408	0.200	0.77 → 0.81	0.0009
flat	10	없음	0.269 → 0.303	0.200	5.29 → 5.01	0.0013
flat	10	LN	0.197 → 0.280	0.200	5.29 → 5.51	0.0056
finger	1	없음	0.058 → 0.181	0.059	0.72 → 0.89	0.0033
finger	1	LN	0.057 → 0.344	0.059	0.72 → 0.74	0.0019
finger	10	없음	0.073 → 0.171	0.059	4.63 → 4.43	0.0019
finger	10	LN	0.057 → 0.209	0.059	4.63 → 4.93	0.0046

결론.

- 노름 비는 입력 스케일이 정했습니다. 스케일 1에서는 약 0.7-0.9, 스케일 10에서는 약 4.4-5.5입니다. 학습 중에는 거의 변하지 않아서, 이 설정에서 노름이 학습으로 커지는 현상은 보이지 않았습니다.
- attention 질량은 학습하면서 개수 몫보다 커졌습니다. 손가락 토큰은 5.9%에서 17-34%로, flat 관절 토큰은 20%에서 28-41%로 올랐습니다. 그러나 스케일을 10배로 올려도 질량은 늘지 않았습니다(flat, 정규화 없음: 스케일 1의 0.321 대 스케일 10의 0.303, LN에서는 0.408 대 0.280). 이 합성 설정에서 질량 쏠림을 만든 것은 노름이 아니라 관절 토큰의 정보량으로 보입니다.
- 따라서 "노름이 시각 토큰을 누른다"는 설명은 이 설정에서 재현되지 않았습니다. 노름 비가 약 5배가 되어도 질량은 개수 몫의 약 1.5배에 머물렀습니다.
- 구조 차이로 성능이 크게 갈리지 않았습니다. LN, 스케일 1에서 flat(0.0009)과 finger(0.0019)는 같은 범위입니다. 논문의 16토큰 대 4토큰 비교(성공률)와 직접 대응하지 않습니다.

한계. 합성 데이터(관절이 자세에 강하게 정보를 주고 시각은 약함)이며 실제 KineFuse가 아닙니다. 주의 층은 2개, 학습은 1500 스텝, 시드 3개, 정규화 2종과 스케일 2종만 봤습니다. 노름 지배가 임계 노름 비(약 2-4배, §6.1)를 넘을 때 생기는지는 이 설정에서 확인하지 못했습니다. 실제 모델의 노름과 질량은 기록하지 않은 상태입니다.

04. 주장 검증: 표 재계산, toy, 구현 가능성

공식 코드가 없어서 **코드 대조(04_code_verification) 대신 주장 검증**을 합니다. 공개 저장소 `cold-young/kine-fuse`는 프로젝트 페이지와 README뿐입니다(`02_prior_work.md` §5). 판정은 논문 본문, 표, 그림 캡션, 이 폴더의 재계산(`03_analysis.md`)을 근거로 합니다.

판정 기호: **재현** = 표 값으로 다시 계산해 맞음, **부분** = 일부만 맞음, **불일치** = 논문 안의 다른 값과 모순, **확인 불가** = 필요한 자료가 논문에 없음.

1. 권리 표기 (라이선스)

- arXiv abs 페이지의 라이선스 링크: **CC BY-NC-ND 4.0** (`licenses/by-nc-nd/4.0/`).
- PDF 메타데이터: `/License`와 `dc:rights` 모두 `http://creativecommons.org/licenses/by-nc-nd/4.0/` 입니다.
- PDF 본문에는 저작권 문구나 다른 권리 표기가 없습니다(텍스트 추출 확인: "©", "Copyright", "permission" 없음).
- 프로젝트 페이지 HTML에는 CC BY-SA 4.0 링크가 있지만, 이는 웹 템플릿(nerfies 계열) 라이선스로 보이며 논문 PDF의 조건이 아닙니다.
- **판정: CC BY가 아니라 NoDerivatives·NonCommercial 조건입니다.** 따라서 논문 그림은 개인용 리포트와 PPT에만 넣고, 게시본(`publish/`)과 `report_public.pdf`에는 넣지 않습니다. 게시본의 그래프는 논문 수치와 toy로 직접 그린 것만 씁니다.
- 원문 PDF는 4.8 MB라서 25 MB 기준 미만입니다. `.gitignore`에 넣지 않고 저장소에 둡니다.

2. 주장별 판정

ID	논문 주장 (위치)	판정	근거
C1	프레임 단위 ADD < 0.011 cm, 최고/최저 비 1.12 (Sec. IV-B)	**확인 불가**	이 수치를 담은 표나 그림이 없습니다. Sec. IV-B가 가리키는 Table II·Fig. 8은 다른 내용입니다. 단위도 의심됩니다(0.11 mm는 Table I의 3-8 cm와 비교해 지나치게 작음, 미터일 가능성).
C2	순차 추적에서 차이가 2배로 커진다 (Sec. I 기여 2, Sec. IV-B)	**재현**	Table I: V-only/KineFuse = 8.11/4.04 = 2.01. Naive/KineFuse = 1.97.
C3	순차 추적에서 차이가 **최대 15배** (Abstract (i))	**불일치**	15배는 Table II 조작 성공(Sec. I 기여 2, Sec. V, 프로젝트 페이지)에만 나옵니다. 추적은 2배입니다.
C4	하위 과제에서 15배 (Sec. I, Sec. V)	**재현(조건부)**	KineFuse/16-token 평균 비 15.8, 칸별 12.7-19.4. 기준선은 가장 낮은 16-token이어서 "최고/최저"입니다. 칸별 95% 구간은 8-29배로 넓습니다.
C5	KineFuse 평균 위치 오차 4.04 cm, V-only 8.11 cm (Sec. IV-B)	**재현**	Table I 평균 4.042, 8.105.
C6	모든 가림 수준에서 KineFuse가 위치 오차 최저 (암묵)	**재현**	6/6 수준 모두 최저.
C7	0-20% 가림에서 모든 모델이 비슷하다 (Sec. IV-B)	**불일치**	0%에서 V-only 8.30, KineFuse 3.68 (2.3배 차이). 10%도 6.80 대 3.49입니다.
C8	각도 오차가 KineFuse만 일정하다 (Table I 캡션, Sec. IV-B)	**불일치**	16-token(69.2-69.3도), Naive(47.3-53.7도)도 거의 일정합니다.

ID	논문 주장 (위치)	판정	근거
C9	KineFuse 각도 오차 47.6도 ± 0.1 (Sec. IV-B)	**부분**	평균 47.65는 맞습니다. "± 0.1"은 가림 수준 간 흔들림이고, seed 표준편차는 2.7입니다.
C10	V-only 각도 오차 54.9-79.4도 (Sec. IV-B)	**재현**	Table I.
C11	고 가림에서 haptic 기여가 커져 격차가 벌어진다 (Sec. IV-B)	**불일치**	네 기준선 모두 0%→90%에서 격차가 줄어듭니다(V-only 4.62→2.03, Naive 4.62→0.46, 16-token 2.16→0.68).
C12	조작 성공에서 KineFuse가 V-only보다 "두 RL 정책 모두"에서 높다 (Sec. IV-C)	**불일치(내부)**	Table II와 본문은 정책 하나("a separately trained RL policy")만 보고합니다.
C13	누적 drift가 성공을 GT의 9%로 떨어뜨린다 (Sec. IV-C)	**불일치**	KineFuse 평균 21.3%, 칸별 18-24%. 9%에 맞는 칸이 특정되지 않습니다.
C14	16-token이 전 수준에서 같은 낮은 성능 (Table I·II)	**확인 불가 (의심)**	위치 오차 변동계수 0.004, 성공 0.23-0.33. 출력이 시각 입력에 거의 반응하지 않습니다. 학습 실패인지 구조 효과인지 구분할 자료가 없습니다.
C15	위치 오차가 허용 범위를 넘으면 성공이 떨어진다 (Fig. 7, Sec. IV-C)	**부분**	16-token(5.8 cm)이 Naive(8 cm)보다 성공이 낮아 위치 오차 순서와 맞지 않습니다. 각도 오차 순위와 성공 순위는 $\rho = -0.9$입니다($n = 5$).
C16	영 입력(촉각 0) 추론에서도 V-only보다 2.3배 좋다 (Sec. IV-D)	**확인 불가**	표나 수치가 없습니다. 0-30% 부분집합 비 2.27과 맞아 떨어지지만 실험과의 연결은 추정입니다. 또한 V-only에는 1단계 사전 학습이 없어서 "구조 효과"와 "학습 절차 효과"가 분리되지 않습니다.
C17	학습된 교차 모달 게이팅: 병진은 시각만, 회전은 헤드 하나가 촉각 (Abstract (ii), Fig. 8)	**확인 불가**	근거는 Fig. 8 캡션의 백분율(100%, 75/25)뿐입니다. 헤드 수와 측정 방법이 없습니다. 본문 Sec. III-D는 "게이트"를 쓰지 않았다고 해서 "게이팅"의 뜻이 흐려집니다.
C18	flat과 관절 단위 표현이 norm dominance로 시각을 억누른다 (Abstract (iii))	**확인 불가**	노름, attention 질량, 헤드별 기여를 보고하지 않습니다. toy로는 임계 노름 비가 2-4배 정도임을 보였지만(`03` §6.1), 실제 모델의 값은 알 수 없습니다.
C19	4토큰이 flat과 관절 단위보다 낫다 (Abstract (iii), Table II)	**재현(표 기준) / 확인 불가(원인)**	성공 평균: 4토큰 KineFuse 4.53 > FingerMLP(4토큰) 2.00 > Naive(1토큰) 1.68 > 16토큰 0.29. 원인 설명은 C14와 같은 이유로 확인되지 않습니다.
C20	개선된 추적이 재배향 성공을 높인다 (Sec. IV-C)	**재현(조건부)**	성공 순서가 추적 오차 순서와 대체로 맞습니다. 다만 한 정책, 3 seeds이고, Holm 보정 후 유의한 칸은 24개 중 3개입니다.
C21	실환경에서 KineFuse가 AprilTag 기준 오차가 낮다 (Sec. IV-E, Table III)	**부분**	위치는 다섯 시점 모두 낮습니다. 회전은 네 시점에서 낮고, 시점 269에서 역전(131.5 대 94.3도)합니다. 한 궤적, 시드 없음입니다.
C22	고정(frozen) 시각 백본 (Sec. I)	**불일치**	Sec. III-E는 2단계 이후 모든 파라미터를 학습한다고 씁니다.
C23	다섯 인코더 설계 비교 (Sec. III-C 첫 문장)	**불일치(세기)**	나열된 촉각 설계는 네 개이고 V-only를 더해도 다섯입니다. 설명이 없어 설계 수를 본문으로 확인할 수 없습니다.
C24	Fig. 6: KineFuse는 20 스텝 뒤 안정	**부분**	눈 판독으로 KineFuse 위치 오차가 약 4 cm에서 140 스텝 무렵 약 6 cm까지 서서히 오릅니다. 완전히 평평하지 않습니다.
C25	촉각 0 입력에서 추적이 "거의 같다" (Sec. IV-D)	**확인 불가**	C16과 같습니다.

3. 재현에 필요한데 논문에 없는 정보

- **고정·학습 구분:** 2단계에서 시각 백본을 어떤 학습률로 얼마 동안 학습했는지, 고정 3 epoch 뒤 전체 학습의 학습률.

- **손실 가중치** λ_ADD, λ_attr, λ_pen 값, 그리고 n_t(축별 정규화기 0.01 m)를 쓰는 식의 세부.
- **구조 크기:** 관절 토큰 입력 C(추정 7: q, q̇, F/T 3축, 접촉, 가용 플래그), 헤드 수 H, Graphormer 층 수, 손가락 풀링 질의 수, transformer 헤드 수, 두 transformer 층의 차원.
- **학습 설정:** 최적화기, 배치, epoch, 학습 데이터 분할(깨끗 2,000 / 가림 1,000 프레임이 학습과 평가를 어떻게 나누는지), 시드 정의.
- **가림 증강의 분포:** 사각형 마스크의 위치와 크기 분포, 힘 채널 증강의 크기.
- **정책:** 재배향 RL 정책의 구조, 학습 스텝, 관측(ground-truth 자세 외 입력), 성공 판정 기준의 구현.
- **지표:** ADD인지 ADD-S인지(대칭 물체 처리), 프레임 단위 ADD의 단위와 교란 분포.
- **Table III:** 기준 시점, 궤적 수, 프레임 레이트, 힘 센서 보정.
- **영 입력 실험:** 학습 절차, 결과 표.
- **하드웨어:** F/T 센서의 좌표계와 보정, 접촉 임계값, 제어 주기.
- **계산 자원:** GPU 종류, 학습 시간, 파라미터 수.

4. 구현할 수 있는지

4.1 공식 코드로 재현: 불가능

- 공개 코드, 가중치, 데이터, 학습 스크립트가 없습니다. 저장소는 프로젝트 페이지입니다(`02` §5).
- 시뮬레이션 데이터는 IsaacLab으로 만드는데, IsaacLab은 NVIDIA GPU(CUDA)가 필요합니다. FoundationPose 시각 백본도 CUDA 확장을 씁니다.
- 실환경 검증에는 저자 그룹이 만든 16자유도 F/T 손(Park & Hwang [35])이 필요합니다.
- 따라서 논문 결과 재현은 공개 자료로 불가능합니다.

4.2 이 맥(Apple M4 Pro, 약 24 GiB 통합 메모리, MPS 사용 가능, CUDA 없음, torch 미설치)에서

작업	가능 여부	근거
표 재계산과 유의성	**가능, 완료**	`table_check.py`, CPU 0.3초
노름, 드리프트 toy	**가능, 완료**	numpy, 각 수 초
FoundationPose 추론	**불가**	CUDA 확장 필요
IsaacLab 데이터 생성	**불가**	Isaac Sim은 NVIDIA RTX GPU 필요
소형 융합 모델 학습(합성 데이터)	**조건부**	torch(MPS) 설치 승인 필요. 설치 전 목록을 보여 줘야 함
실물 손 재현	**불가**	하드웨어 없음

4.3 아이디어만 다시 구현

- **난이도: 중간.** 손가락 토큰화, 손가락 내 마스크 attention, 16→4 풀링, URDF 편향 Graphormer 층은 PyTorch로 수백 줄입니다. 구현 자체는 어렵지 않습니다.
- **가장 큰 장벽은 데이터입니다.** 고유감각, 근위 F/T, 접촉이 함께 기록된 in-hand 시퀀스에 물체 자세 GT가 있어야 합니다. 공개 자료에서 이 조합을 찾지 못했습니다. ALOHA류 데이터에는 F/T가 없고, 다지 손 데이터에는 촉각 신호가 없는 경우가 많습니다.
- **평가 설계의 장벽:** 프레임 평가와 chain 평가를 같이 보고, 학습 절차를 맞춘 영 입력 대조, 고유감각 대조가 필요합니다. 논문이 빠뜨린 대조들입니다.

- **하드웨어:** 재현용 최소 구성은 촉각이 있는 손(또는 손가락별 토크·전류 신호) 하나와 RGB-D 카메라입니다. 근위 F/T가 없는 손이라면 `beyond_implicit_force`의 전류 대리값으로 대신할 수 있지만, 검증은 별도로 필요합니다.

4.4 판정 요약

- **공식 재현:** 불가능(코드·데이터·GPU·하드웨어).
- **이 맥에서 할 수 있는 것:** 수치 재계산과 toy는 끝났습니다. 소형 모델 학습은 torch 설치 승인 뒤에 가능하지만 데이터 생성이 막힙니다.
- **아이디어 재구현:** 중간 난이도. 데이터(촉각 + 자세 GT)가 가장 큰 제약입니다.

한 줄 판정: 공식 재현은 불가능하고, 이 맥에서는 계산 검증까지만 가능합니다. 아이디어 재구현은 구조 자체는 쉽지만 촉각·자세 데이터 확보가 어려워 조건부입니다.

5. 검증 방식 요약

- 표 I, II, III 값은 PDF 텍스트와 렌더링을 대조해 옮겼습니다(`table_check.py` 상수).
- 평균, 비, 유의성, 상관은 `table_check.py`로 재계산했습니다.
- 노름과 드리프트의 메커니즘은 `norm_dominance_toy.py`, `drift_toy.py`의 가정 모델로만 시험했습니다. 논문 실험을 재현한 것이 아닙니다.

02. 선행연구와 관계

1. 계보

갈래	대표 연구	KineFuse가 가져온 것
시각 6D 자세 추적·추정	FoundationPose [4], BundleSDF [5], SAM-6D [19]	고정 시각 백본(FoundationPose 정제 네트워크), 렌더-비교 입력 구성
시각·촉각 in-hand 자세	Rezazadeh et al. [7] (HGNN, ICRA 2023), Mack et al. [6] (factor graph, ICRA 2025), V-HOP [22] (RSS 2025), NeuralFeels [15], VINT-6D [14]	촉각을 노드·토큰으로 넣는 방식, 접촉의 손-물체 보조 손실 [22]
촉각을 평면 벡터로 넣기	Lin et al. [18] (visuotactile, two hands)	Naive·FingerMLP 기준선의 출처. 논문은 구조가 없는 flat 융합으로 봅니다
손 구조의 그래프 표현	GET-Zero [31] (embodiment bias), Graphormer [30], Rampášek et al. [29]	URDF 홉 거리·대향·인접 편향, 그래프 transformer 층
가림·접촉 기반 손 조작	Chen et al. [9], Qi et al. [11], Wang et al. [10]	가림 문제의 동기. 이 계열은 손 자세 전환(finger gaiting)으로 가림을 피함
힘·토크 센서가 있는 손	Park & Hwang [35] (저자 그룹의 3축 F/T 손)	실험 하드웨어

2. 가까운 대안

2.1 논문이 직접 비교한 것

- **Naive V+H**: 관절을 한 토큰으로 묶은 flat 융합. Lin 계열 [18]의 단순 형태입니다.
- **FingerMLP**: 손가락 단위 MLP와 손가락 간 attention, 구조 편향 없음. 구조의 "어느 부분"이 효과를 내는지 가르는 기준선입니다.
- **16-token**: 관절 단위 attention, 풀링 없음. 토큰 수를 늘리는 쪽입니다.

2.2 논문이 인용했지만 비교하지 않은 것

- **Rezazadeh et al. [7]**: 저자가 "가장 가까운 선행"이라고 적은 HGNN입니다. 그러나 밀도 높은 시각 촉각 센서(GelSight류)를 가정합니다. KineFuse는 저차원 신호(관절, 이진 접촉, F/T)만 씁니다.
- **Mack et al. [6]**: 저해상도 접촉을 이진 기하 제약으로 씁니다. 최적화 기반이라 학습형 융합과 직접 비교되지 않습니다. 이진 접촉이 추정을 돕는다는 근거로만 인용합니다.
- **V-HOP [22]**: 손-물체 보조 손실(L_attr, L_pen)의 출처입니다. 추적 방법 비교는 없습니다.

2.3 구성 요소별 출처

구성 요소	출처	이 논문에서 새로운 점
관절 토큰화(MLP + LN)	일반 관행	관절 4 스텝 이력을 28차원으로 펴서 토큰화(C는 명시되지 않음)
손가락 내 마스크 attention	블록 대각 마스크 (일반 관행)	F/T가 있는 원위 관절에서 근위 관절로 정보 전달이라는 목적
손가락 풀링 16→4	학습 질의 cross-attention (일반 관행)	손가락마다 하나의 요약 토큰, 토큰 수를 4로 고정

구성 요소	출처	이 논문에서 새로운 점
URDF 편향 Graphormer	Graphormer [30], GET-Zero [31]	손가락 쌍의 홉 거리·대향·인접을 편향으로 씀
6D 회전 표현	Zhou et al. [33]	없음
ADD 손실, 접촉·관통 보조	ADD 일반 관행, V-HOP [22]	λ 값은 비공개
2단계 학습(촉각 사전 학습 → 결합 미세조정)	본문에 출처 없음	2단계 중 시각 백본을 3 epoch 고정하는 일정

3. 이 저장소의 다른 논문과의 관계

폴더	관계	KineFuse에 주는 것
`restacvla/` (ResTacVLA, arXiv:2607.03387)	시각·촉각 융합에서 한 모달리티가 다른 쪽을 누르는 문제(modality collapse)와 불확실성 게이트	게이트를 학습하려다 포화되는 현상은 두 논문이 공통으로 겪습니다. "gating"의 정의를 주의 질량인지 학습 게이트인지 구분하는 기준을 빌려 옵니다
`reactive_grasp/` (arXiv:2609.30082)	손 전체 링크의 접점을 물체 메쉬·자세·관절각만으로 계산하고 접촉력 분배 QP를 푸는 제어기	촉각 없이 손 구조로 접촉을 추정할 수 있다는 점. KineFuse의 URDF 편향과 같은 재료(손 기하)를 쓰지만 목적이 다릅니다
`beyond_implicit_force/` (arXiv:2607.14578)	관절 위치 오차 δ와 서보 전류가 힘을 대신하는지 시험	고유감각에서 힘을 읽으면 생기는 "구동과 감지의 혼동"을 같은 방식으로 의심할 수 있습니다. KineFuse의 고유감각 누수 문제(`01` §4.2 (1))와 같은 뿌리입니다
`chord/` (arXiv:2607.00033)	다지 손의 접촉 wrench 행렬과 지지 함수 보상	접촉 정보를 손가락 단위로 모아 쓰는 방식의 대안
`flashdexretarget/` (arXiv:2610.01849)	사람 손-물체 시연을 로봇손 궤적으로 바꾸는 정책	손 기하가 다른 로봇손으로 옮길 때 URDF 편향이 얼마나 쓸모 있는지의 질문
CONTACT (arXiv:2603.08560)	단순 촉각 융합이 오히려 나쁘다는 결과를 다루는 것으로 알려진 연구	flat 융합 열세와 같은 방향의 주장입니다. 본 분석에서 원문은 확인하지 않아 인용은 주장의 요지로만 둡니다

4. 논문이 다루지 않았지만 관련 있는 연구 (내 판단)

- **고유감각 기반 접촉 추정**: 관절 위치·속도와 URDF만으로 접촉 힘을 추정하는 계열. 촉각이 없는 손에서 KineFuse의 "손 구조" 아이디어를 쓸 수 있는 지점입니다. 논문은 이 대안과 비교하지 않았습니다.
- **가림에서의 시간적 필터링**: 칼만 필터나 관측 게이팅은 chain 오차 누적(drift)을 직접 다룹니다. 논문이 drift를 "다음 과제"로 미룬 부분입니다(`01` §4.1).

5. GitHub와 공개 자료 (2026-11-09 확인)

저장소	무엇	공식?	라이선스	별	마지막 커밋	비고
`cold-young/kine-fuse`	논문 저장소. 실제로는 프로젝트 페이지 소스(index.html)와 README뿐	공식(저자 계정)	없음(GitHub license null)	1	2026-10-15, `072f40d`	코드, 가중치, 데이터, 학습 스크립트 없음. 저장소 생성 2026-03-08

저장소	무엇	공식?	라이선스	별	마지막 커밋	비고
`NVlabs/FoundationPose`	시각 백본(정제 네트워크)의 원저	원저자 공식	NOASSERTION. LICENSE 파일은 "Copyright NVIDIA, All rights reserved" 형식이라 상업 이용 조건을 원문으로 확인해야 합니다	3,689	2026-04-29, `a1b694b`	논문의 시각 백본. CUDA 필요
`isaac-sim/IsaacLab`	시뮬레이션과 데이터 수집	공식	NOASSERTION(SPDX 미인식, 원문 확인 필요)	8,602	2026-11-09, `4cfdfcf`	논문의 데이터 생성 환경. GPU 필요
`microsoft/Graphormer`	Graphormer 층 원구현	공식	MIT	2,486	2026-11-04, `c55f569`	편향 계산 방식의 원출처
`real-stanford/get_zero`	GET-Zero, embodiment bias 설계	공식	없음	63	2026-03-05, `279652d`	URDF 편향의 설계 원출처

검색했지만 공식 코드를 찾지 못한 것: V-HOP [22], Rezazadeh et al. [7]의 HGNN. `gh search repos "KineFuse"` 는 `cold-young/kine-fuse` 하나만 돌려줬습니다. 하드웨어 논문 [35](저자의 F/T 손)의 저장소는 검색하지 않았습니다.

결론: **공개된 실행 가능한 코드는 없습니다.** 저장소는 프로젝트 페이지이므로 `repo/` clone은 남기지 않았고, 코드 대조는 `04_claim_verification.md` 에서 주장 수준으로만 합니다.