Motion-Focused Latent Action: 분석 리포트

게시용 버전: 논문 그림은 라이선스(arXiv 비독점 배포) 때문에 제외했습니다. 원문 https://arxiv.org/abs/2606.18955 · arXiv:2606.18955v2 · IROS 2026 채택 · Xu, Zhang, Wang, Wang, Yu · 공식 코드 있음(shuiyigong/Motion-Focused-Latent-Action @ fd614f7, Apache-2.0) · 분석일 2026-11-10

핵심 요약

1. **무엇을 하는가:** 사람 1인칭 영상에서 움직임을 담는 이산 잠재 행동을 만들고(손 마스크로 행동 경로와 배경 경로를 나눈 이중 코드북 VQ-VAE), 그 토큰으로 VLM을 사전학습한 뒤, 소량의 시연으로 VLM과 flow-matching 헤드를 함께 미세조정합니다(01 §2).
2. **표의 평균은 맞지만 헤드라인 차이는 작습니다:** LIBERO 평균 91.8은 villa-x 90.1보다 1.6점 높은데, 합산 Fisher p = 0.30로 유의하지 않습니다. RoboTwin 67.7은 π0 65.2(p = 0.26), UniVLA 63.6(보정 p = 0.12)과 구별되지 않습니다(03 §2).
3. **"사람 영상만으로 사전학습"은 헤드라인 LIBERO 실험과 맞지 않습니다.** IV-A의 LIBERO는 BridgeV2 **로봇** 영상으로 잠재 행동과 VLM을 사전학습했습니다. 사람 영상은 RoboTwin과 실물에서만 씁니다(01 §4.1, 04 C1).
4. **기준선 한 개는 원 보고치보다 약합니다:** UniVLA(Bridge)를 저자가 재현한 값은 88.1이고, UniVLA 원 논문의 Bridge 행은 92.5입니다. LIBERO 기준선 17칸은 200회 가정에서 정수가 되지 않아 시행 프로토콜이 다릅니다(03 §1.3, 04 C5).
5. **"움직임에 집중"은 직접 검증되지 않았습니다:** 마스크 제거, 배경 경로 제거 ablation이 없습니다. 코드에서 전체 재구성 경로는 마스크 없이 전역 MSE로 학습됩니다. 토이에서 전경 마스크 안에도 카메라 이동 정보가 남았습니다(판독 0.58 대 기준선 0.22)(04 D4, 03 §4).
6. **공개 코드와 논문의 차이:** LIBERO 설정이 손목 DINO를 항상 쓰고, 쌍 간격이 1초가 아니라 9프레임이며(기본 창 10), 이미지만 자르고 마스크는 자르지 않습니다. 기본 설정은 VLM 동결입니다(04 D8, D9, D14, D17).
7. **구현:** 이 맥에서 공식 재현은 불가능합니다(CUDA 전제, 마스크와 체크포인트 미공개). 아이디어 재구현은 중간 난이도입니다(04 §4). 가장 값싼 검증은 마스크 누수 토이와 누수 probe입니다.

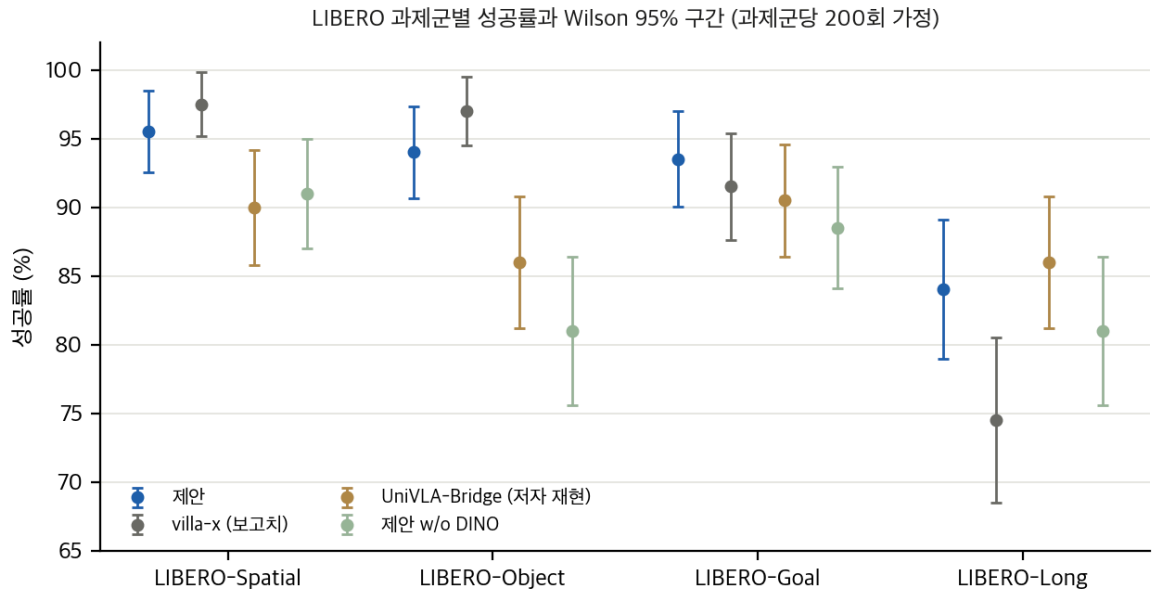


그림 1(직접 그림): LIBERO 과제군별 성공률과 Wilson 95% 구간. 과제군당 200회 가정이고, 기준선 행은 논문 보고치 또는 저자 재현치입니다.

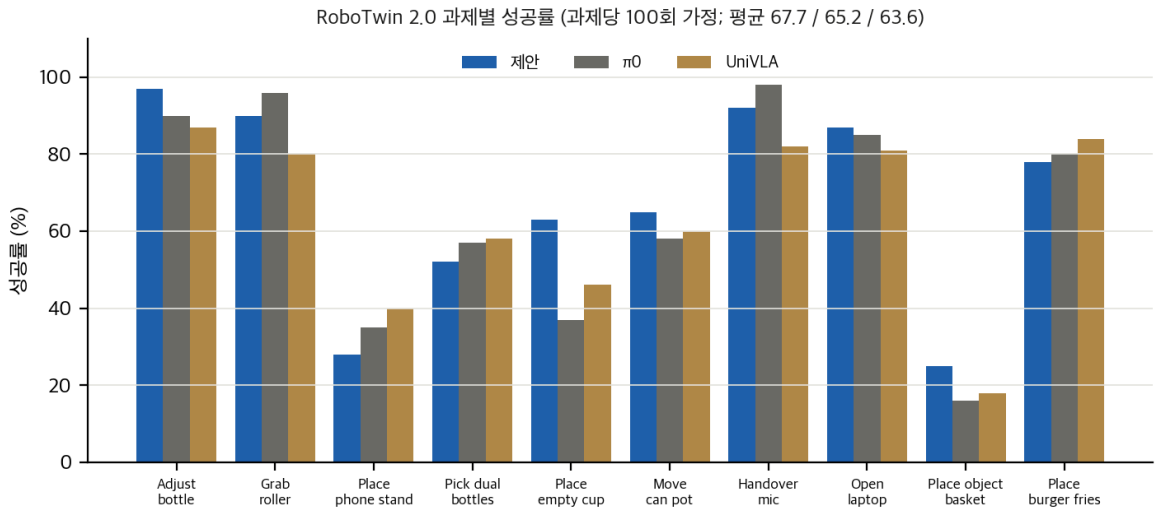


그림 2(직접 그림): RoboTwin 2.0 과제별 성공률. 과제당 100회 가정입니다.

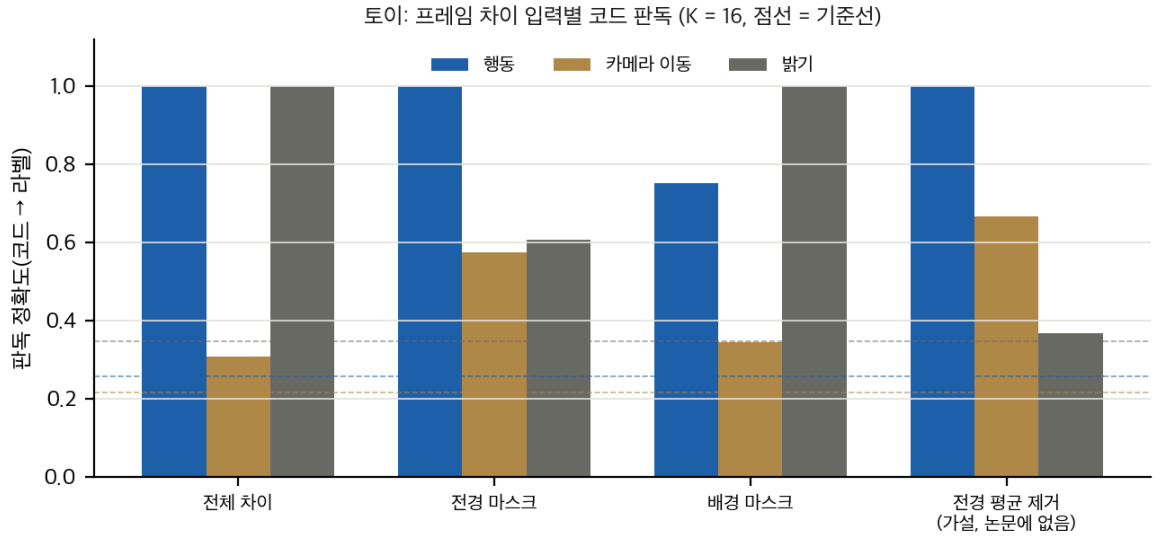


그림 3(직접 그림, 토이): 프레임 차이 입력별 코드 판독. 전경 마스크가 밝기를 줄여도 카메라 이동 정보가 마스크 안에 남습니다. "전경 평균 제거"는 논문에 없는 가설적 보정입니다.

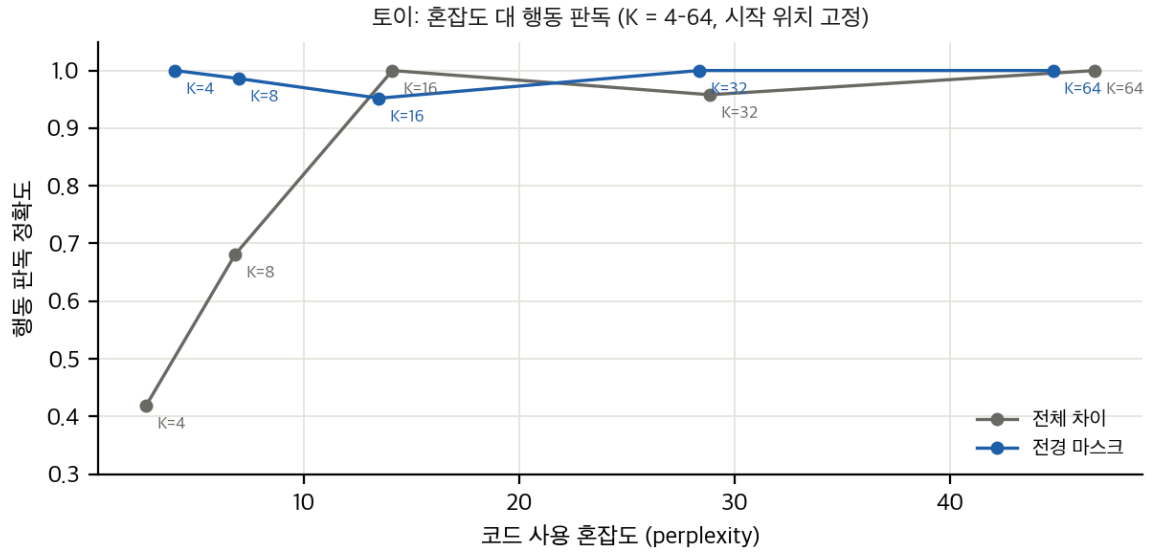


그림 4(직접 그림, 토이): 코드 혼잡도 대 행동 판독. 전체 차이는 K가 낮을 때 행동을 잘 담지 못하고, 전경 마스크는 K = 4에서도 행동을 판독합니다.

01. 논문 분석: Motion-Focused Latent Action

Motion-Focused Latent Action Enables Cross-Embodiment VLA Training from Human EgoVideos (Xu, Zhang, Wang, Wang, Yu; IROS 2026 채택, arXiv:2606.18955 v2, 2026-07-02). 원문은 arXiv:2606.18955v2 PDF(https://arxiv.org/pdf/2606.18955v2, 8쪽, IEEE 2단)이고, 분석에는 PDF 텍스트 추출본을 썼습니다. 절·식·표·그림 번호는 원문 기준입니다.

0. 읽는 순서와 한 줄 결론

논문은 사람 1인칭 영상에서 **움직임만 담는 이산 잠재 행동**(hybrid disentangled VQ-VAE)을 만들고, 그 코드를 VLM의 다음 토큰 목표로 사전학습한 뒤, 소량의 로봇 시연으로 VLM과 flow-matching action expert를 함께 미세조정합니다. 주장의 핵심은 "마스크로 배경과 움직임을 분리하면 잠재 행동이 로봇과 사람에서 같은 의미를 가진다"는 것입니다. 그런데 근거는 시뮬레이션 두 종(LIBERO, RoboTwin)과 실물 3과제, 그리고 CKA 한 쌍에 그칩니다. 분리 효과를 직접 떼어 보는 ablation(마스크 제거, 배경 경로 제거)은 없습니다.

1. Abstract와 서론

- **문제 설정:** VLA 학습에는 행동 라벨이 붙은 로봇 데이터가 많이 필요합니다. 사람 영상은 많지만 행동 라벨이 없습니다. 기존 사람-데이터 방식(EgoMimic, MotionTrans, H-RDT)은 AR/VR 손 자세 라벨을 씁니다(II-C).
- **문제 진단:** VQ-VAE형 잠재 행동(LAPA, IGOR)은 배경 변화와 카메라 이동 같은 **작업과 무관한 변화**를 잡습니다(I, 2문단). UniVLA는 언어로 작업 중심 움직임을 유도하지만, 사람 영상의 다양성 때문에 언어 신호만으로는 분리가 어렵다고 주장합니다.
- **제안:** (1) 전경(손·팔) 마스크로 행동 경로를, 배경 마스크로 배경 경로를 감독하는 이중 코드북 VQ-VAE. (2) 사람 영상으로 VLM을 사전학습. (3) 미세조정 때 VLM은 행동 의도를, 고정된 DINOv2는 현재 상태를 맡는 **의도-인지 분리**(intention-perception decoupling).
- **초록의 주장:** "사람 영상만으로 사전학습"하고 "약 50 궤적"으로 미세조정하며, 대규모 주석 데이터로 학습한 VLA와 "경쟁력 있다"고 합니다.

2. 방법 (Sec. III)

2.1 Hybrid Disentangled VQ-VAE (III-B, Fig. 2)

- **입력:** 1초 간격으로 고른 인접 프레임 쌍 V. 프레임은 224×224로 맞추고, 동결한 DINOv2 ViT-B/14-reg의 패치 특징 $F \in R^{T\times N\times D}$를 씁니다(III-B.1, IV 서두).
- **인코더:** 공간-시간 transformer. 학습 가능한 질의 두 세트 Q_act(4개)와 Q_bg(4개)를 패치와 이어 붙입니다.
- **이중 양자화:** 행동 코드북과 배경 코드북, 각각 크기 16(III-B.2). 쌍마다 행동 토큰 4개를 씁니다. 즉 행동 어휘는 16개이고 한 쌍의 행동은 16^4 조합 중 하나입니다.
- **디코더 세 경로**(III-B.3):
  - 전체 경로: z_act, z_bg, 첫 프레임 특징으로 목표 특징 맵 전체를 재구성합니다.
  - 행동 경로: z_act와 첫 프레임만 씁니다. 손 마스크 안에서만 오차를 계산합니다.
  - 배경 경로: z_bg만 씁니다. 배경 영역에서만 오차를 계산합니다.
- **마스크:** 사람 데이터는 SAM2로 손 마스크를 만듭니다. 로봇 데이터(Bridge, LIBERO 실험)는 RoboEngine으로 로봇 마스크를 만듭니다(III-B.3, IV-A). 마스크는 학습 때만 씁니다.

- **손실** (Eq. 1): L_total = λ_recon L_recon + λ_vq L_vq + λ_commit L_commit. L_recon은 전경 오차, 배경 오차, 전체 오차의 합입니다. λ 값은 본문에 없습니다.

2.2 VLM 사전학습 (III-C, Eq. 2)

- 잠재 행동 코드를 UniVLA 방식으로 VLM 어휘에 넣습니다. 쌍의 목표 토큰 K = 4를 자기회귀로 예측하는 음의 로그우도입니다.
- 백본은 Prismatic-7B입니다(III-C 마지막 문장). 사전학습 데이터 규모, 스텝 수, 배치 크기는 본문에 없습니다.

2.3 하위 과제 적응 (III-D, Eq. 3-5)

- 입력 맥락 F_full = Concat(f_act, f_obs, f_proprio)(Eq. 3). f_act는 VLM 마지막 층 은닉 상태의 평균, f_obs는 동결 DINOv2 특징, f_proprio는 로봇 상태입니다.
- action expert는 처음부터 학습하는 flow-matching 디코더입니다. 손실은 Eq. 4의 속도장 회귀입니다.
- 의도 예측을 살리려고 교차 엔트로피 L_intent를 더합니다(Eq. 5, λ_intent 값 없음). VLM은 LoRA로 미세조정합니다(III-D).
- **설계 의도:** VLM 시각 임베딩 대신 DINOv2 특징을 쓰면 "환각"이 줄어든다고 주장합니다(III-D 마지막 문단, 예: 용기가 닫혀 있는데 넣으려 함).

3. 실험 (Sec. IV)

실험	사전학습 데이터	평가	미세조정 데이터	기준선
IV-A LIBERO	BridgeV2 **3인칭 로봇 영상만**(라벨 없음)	LIBERO 4개 과제군, 과제당 20회(Table I)	LIBERO 과제당 사람 시연 50개, 3인칭만	LAPA, DP, OpenVLA, SpatialVLA, π0, π0-FAST, villa-x, UniVLA(Table I)
IV-B RoboTwin 2.0	EgoDex 영상(사람, 라벨 없음)	10과제(Table II), 시행 수 명시 없음	과제당 50 궤적, 손목 카메라 추가	RDT, π0, ACT, DP, UniVLA; 절제: w/o DINO, Freeze
IV-B 실물 ARX R5	EgoDex	3과제, 시행 수 명시 없음(Fig. 3c)	과제당 50 궤적, 20k 스텝	UniVLA
IV-C CKA	BridgeV2 + FurnitureBench 표현	토큰 중심 CKA, 2만 쌍	—	UniVLA 잠재 행동
IV-D 시각화	BridgeV2 + EgoDex	같은 토큰을 받는 쌍 예시(Fig. 5)	—	—

결과 요약

- **LIBERO (Table I):** 평균 91.8. villa-x 90.1, UniVLA(Bridge) 88.1이고, w/o DINO 85.4입니다. 과제군별로는 Spatial 95.5, Object 94.0, Goal 93.5, Long 84.0입니다. Goal은 villa-x보다 2.0, Long은 9.5 높습니다(IV-A).
- **RoboTwin (Table II):** 평균 67.7. π0 65.2, UniVLA 63.6, w/o DINO 62.8, Freeze 52.4, RDT 52.5입니다.
- **실물 (Fig. 3c):** 정확한 수치는 그림에만 있습니다. 읽은 값은 UniVLA 0.30/0.35/0.50, 제안 0.75/0.80/0.75입니다(병에 올리기/코드 뽑기/수건 접기).
- **CKA (Fig. 4b):** UniVLA 0.8659±0.0064, 제안 0.9139±0.0099. 본문은 "유의하게 높다"고 씁니다.
- **Fig. 5:** 사람 손과 로봇 팔이 같은 토큰을 받은 예 3개(Move Forward, Move Right, Lift Object)입니다. 정성적 예시입니다.

논문이 스스로 밝힌 한계 (V): 이산 행동 코드는 큰 의도는 잡지만 정밀 제어에는 표현력이 부족하고, 다중 스케일 잠재를 향후 과제로 둡니다.

4. 비판적 해석

1. **"사람 영상만으로"는 두 실험에만 해당합니다.** 초록과 서론은 사람 영상 사전학습을 강조하지만, IV-A(LIBERO, 과제군 평균 91.8이라는 헤드라인 수치)는 BridgeV2 **로봇** 영상으로 잠재 행동과 VLM을 사전학습했습니다(IV-A 1문단: "we train the hybrid disentangled VQ-VAE and the VLM backbone using only the third-view video data from the BridgeV2 dataset[24], which features a WindowX manipulator"). 사람 영상은 IV-B(RoboTwin)와 실물에서만 씁니다. 그래서 "로봇 데이터 없이"라는 주장은 헤드라인 표에 대해서는 맞지 않습니다.
2. **"50 궤적"은 과제당 수치입니다.** LIBERO는 과제 10개마다 50개씩(군당 500개)이고, RoboTwin과 실물도 과제당 50개입니다. 과제별로 따로 미세조정하는지(IV-B "30k training steps for each task")도 본문에서 분명하지 않습니다.
3. **운동 집중(motion focus)을 직접 검증하지 않았습니다.** 마스크 없는 학습, 전체 경로 제거, 배경 경로 제거의 ablation이 없습니다. 잠재 행동에 카메라 이동이나 배경이 얼마나 남는지도 재지 않았습니다. "분리되었다"는 근거는 Fig. 5의 정성적 예 3개와, 도메인 부분공간을 지운 뒤의 CKA 하나입니다. 코드 대조(04 §2)에서 전체 경로가 마스크 없이 전역 MSE를 쓰는 점을 확인했습니다. 이 경로는 카메라 이동 정보가 행동 코드에 들어갈 통로가 됩니다.
4. **기준선 재구현 문제.** UniVLA(Bridge) 행은 "엄격히 재현했다"고 적혀 있고 값은 88.1입니다. 그런데 UniVLA 원 논문의 Bridge 행은 평균 92.5입니다(arXiv:2505.06111 Table I). 따라서 저자 재현이 원 보고치보다 4.4점 낮습니다. π0, π0-FAST, villa-x, SpatialVLA, OpenVLA, DP, LAPA 행은 villa-x 논문의 값과 일치합니다. 그중 π0-FAST의 Long 60.2%는 200회 기준으로 정수가 아니어서 다른 시행 수에서 나온 값입니다(03 §1).
5. **이득의 크기와 통계.** 평균 차이는 villa-x 대비 1.6점입니다. 시드 변동이 보고되지 않았고, 이항 검정으로도 유의하지 않습니다(03 §2). UniVLA(Bridge) 대비는 방향이 맞고 $p \approx 0.02$이지만, 그 기준선은 저자 재현값입니다.
6. **절제(IV-B Freeze)의 해석.** 동결 VLM이 RDT와 비슷하니(52.4 대 52.5) "VLM 사전학습이 매우 효과적"이라고 씁니다. 같은 구조에서 사전학습을 뺀 대조가 없어서, RDT와의 비슷함은 사전학습 효과의 증거가 되지 못합니다.
7. **의도-인지 분리 효과.** w/o DINO는 RoboTwin에서 −4.9점, LIBERO에서 −6.4점입니다. 단일 시드로 보이며, 이 결과는 분리 주장을 가장 직접 지지하는 증거입니다. 다만 코드의 LIBERO 경로는 주 시점 VLM 은닉 상태와 손목 DINO를 함께 씁니다(04 §2, D17). 논문 설명과 맞지 않아 실제 분리 방식은 확인이 필요합니다.
8. **시간 간격.** "1초 간격"이라고 했지만 코드는 창 크기 10을 기본값으로 써서 쌍 간격이 9프레임입니다(04 D8). 영상 fps가 9가 아니면 1초가 아닙니다.
9. **재현 세부.** λ 값, 마스크 임계값, K-means 같은 코드북 초기화, 사용률, 학습 스텝과 배치(LAM), LIBERO 정책 헤드 종류(논문은 UniVLA의 자기회귀 헤드라고 씀, 코드는 MLP+tanh L1) 등이 본문에 없거나 코드와 다릅니다.

5. 버전과 권리 (v1 → v2)

- **텍스트 차이:** 단어 단위 비교(v1, v2 PDF 텍스트 추출본)에서 두 가지뿐입니다. (1) v2 초록에 "Code is available at https://github.com/shuiyigong/Motion-Focused-Latent-Action." 문장이 추가되었습니다. (2) 하이픈 줄바꿈 "latent-action-based"가 "latent-actionbased"로 바뀌었습니다(조판 차이). 본문, 표, 참고문헌은 같습니다.
- **그림·표:** 텍스트로는 비교할 수 없었습니다. 두 판의 그림 개수와 페이지 수(8쪽)는 같습니다.
- **arXiv 기록:** v1 2026-06-17, v2 2026-07-02. 댓글란은 "Accepted by IROS 2026"입니다.
- **권리:** arXiv 초록 페이지의 라이선스 링크는 `arxiv.org/licenses/nonexclusive-distrib/1.0/` 입니다(비독점 배포, CC BY 아님). PDF에는 © 표시나 IEEE 저작권 문구가 없습니다(`grep`으로 확인). 따라서 **논문 그림은 개인용 리포트와 PPT에만 넣고, 공개 산출물에는 넣지 않습니다.**

6. 이 논문의 위치

사람 영상에서 잠재 행동을 뽑아 VLA를 사전학습한다는 점에서 DreamX(사람 1인칭 영상 → 잠재 행동 4토큰, 확산 백본)와 가장 가깝습니다. 학습 방식은 VQ 재구성이고, 마스크로 움직임을 분리한다는 점이 새롭습니다. 자세한 관계는 02 §3에 있습니다.

03. 수치 재계산, 유의성, 유도와 toy 검증

재계산 스크립트는 `analysis/table_check.py` (→ `table_check_results.json`), `analysis/motion_toy.py` (→ `motion_toy_results.json`)입니다. 둘 다 numpy 단일 스레드로 수 초 안에 돕니다. 시행 수는 논문에 전부 적혀 있지 않아서, **보고된 %가 정수 성공 수로 떨어지는지**로 추정했고 가정을 표에 같이 적었습니다.

1. 표 재계산

1.1 시행 수 추정

표	보고된 형식	추정 시행 수	근거
Table I (LIBERO)	과제군 평균, 0.5% 단위	과제군당 200회(과제 10 × 20회)	본문 IV-A "Each task is evaluated 20 times", 과제 10개. 우리 행 8개 값 모두 200회에서 정수
Table II (RoboTwin)	과제별 정수 %	과제당 100회	모든 칸이 정수 %이고 홀수 값이 있어 50의 배수면 안 됨. 시행 수는 명시되지 않음
Fig. 3c (실물)	0.05 단위	과제당 20회	값이 모두 5%의 배수. 시행 수는 명시되지 않음

1.2 평균 재계산

- **LIBERO:** 제안 방법 (95.5+94.0+93.5+84.0)/4 = 91.75 → 보고 91.8. villa-x 90.125 → 90.1. UniVLA(Bridge) 88.125 → 88.1. 나머지 기준선도 반올림 안에서 일치합니다.
- **RoboTwin:** 과제별 값으로 계산한 평균이 보고된 8개 평균과 모두 일치합니다(제안 67.7, π0 65.2, UniVLA 63.6, w/o DINO 62.8, Freeze 52.4, RDT 52.5, ACT 51.2, DP 49.7).
- **결론:** 표 안의 평균은 모두 맞습니다.

1.3 기준선 행의 정수성 점검 (중요)

LIBERO 200회 가정에서 보고된 값이 정수 성공 수로 떨어지지 않는 칸이 **17개** 있습니다. 대부분 π0-FAST, SpatialVLA, OpenVLA, LAPA, DP 행입니다. 예를 들어 π0-FAST Long 60.2%는 200회에서 120.4회입니다. 500회로 바꾸면 이 칸은 정수가 되지만, 전체 40칸 중 **16칸은 500회에서도 정수가 되지 않고** 그중 5칸(OpenVLA Spatial·Long, DP Spatial·Goal, SpatialVLA Object)은 200회와 500회 모두에서 정수가 아닙니다. 따라서 이 기준선 값들은 한 가지 시행 수가 아니라 **다른 평가 프로토콜**(villa-x 논문 등)에서 가져온 것으로 보입니다. 이 기준선과의 비교는 시행 수가 같다는 가정이 깨진 상태입니다.

기준선	출처 표시	확인
villa-x, π0, π0-FAST, SpatialVLA, OpenVLA, LAPA, DP	본문: π0는 villa-x 보고치 사용	villa-x 논문 Table(arXiv:2507.23682) 행과 값이 같음(villa-x, π0 reimpl., π0-FAST, SpatialVLA, OpenVLA 행 확인)
UniVLA-Bridge	본문: "strictly reproduced on BridgeV2"	UniVLA 원 논문(arXiv:2505.06111, Table I)의 Bridge 행은 95.2/95.4/91.9/87.5/**92.5** 이고, 논문 값은 90.0/86.0/90.5/86.0/**88.1**. 저자 재현은 원 보고치보다 4.4점 낮음

2. 유의성 검정

방법은 다음과 같습니다. 과제군(또는 과제)별 Fisher 정확 검정, 층화 Mantel-Haenszel(CMH, 연속성 보정), 합산 Fisher를 계산했고, 비교 대상이 여러 개인 경우 Holm 보정을 적용했습니다. 모든 검정은 과제군 내 시드 변동을 포함하지 않습니다. 시드가 하나라면 여기서 나오는 p 값은 **시행 샘플링 변동만** 반영합니다.

2.1 LIBERO (과제군당 200회 가정, 합계 800회)

비교	평균 차이(점)	합산 Fisher p	CMH p (과제군 층화)	Holm p (기준선 8개)
제안 대 villa-x	+1.6	0.30	0.28	0.30
제안 대 UniVLA(저자 재현)	+3.6	0.020	0.020	0.039
제안 대 π0-FAST*	+6.3	1×10^{-4}	5×10^{-5}	3×10^{-4}
제안 대 π0*	+10.6	~0	~0	~0
제안 대 w/o DINO (절제)	+6.4	8×10^{-5}	8×10^{-5}	—

*시행 수 가정이 깨지는 행(§1.3). 과제군별로 보면 villa-x 대비 Long만 p = 0.026(Fisher)이고, Goal은 p = 0.57입니다. 나머지 과제군은 유의하지 않습니다.

Wilson 95% 구간(합산): 제안 91.8 [89.6, 93.5], villa-x 90.1 [87.9, 92.0]. 두 구간이 겹칩니다. 과제군별 구간은 Spatial [91.7, 97.6], Object [89.8, 96.5], Goal [89.2, 96.2], Long [78.3, 88.4]입니다.

2.2 RoboTwin (과제당 100회 가정, 합계 1000회)

비교	차이(점)	합산 Fisher p	CMH p (과제 층화)	Holm p (7개)	과제별 부호 검정
제안 대 π0	+2.5	0.26	0.18	0.26	—
제안 대 UniVLA	+4.1	0.060	0.032	0.12	7승 3패, p = 0.34
제안 대 w/o DINO	+4.9	0.024	0.009	0.073	—
제안 대 Freeze	+15.3	~0	~0	~0	—

RDT, ACT, DP와의 차이는 모두 $p < 10^{-14}$입니다(표 생략).

해석: 제안은 RoboTwin에서 π0, UniVLA와 **통계적으로 구별되지 않습니다.** "comparable" 표현은 맞지만 "앞선다"고 쓰기는 어렵습니다. 의도-인지 분리(w/o DINO 대비)는 층화 검정에서 nominal p = 0.009이고 보정 후에는 0.073입니다.

2.3 실물 (과제당 20회 가정, 합계 60회)

과제	제안	UniVLA	Fisher p
병을 접시에 올리기	15/20	6/20	0.010
전선 뽑기	16/20	7/20	0.0095
수건 접기	15/20	10/20	0.19
합계	46/60	23/60	3.9×10^{-5} (CMH OR 5.3, p 5.7×10^{-5})

과제별 Holm 보정 p는 0.029, 0.029, 0.19입니다. 과제당 20회와 1회 시드라는 가정 아래에서 방향은 분명하지만, 표본이 작아서 크기 추정은 불안정합니다.

2.4 CKA (Fig. 4b)

평균 차이는 0.048입니다. 부트스트랩 표준편차를 표본 표준편차로 본다면 Welch t ≈ 29입니다. 그러나 이 표준편차는 **토큰 중심의 재표본 변동**입니다. 학습 시드 변동이 아니므로 "유의하게 높다"는 주장을 뒷받침하지 못합니다. 또한 이 분석은 BridgeV2와 FurnitureBench 두 로봇 데이터셋만 사용합니다. 사람 영상은 들어 있지 않습니다.

2.5 검출력

- 91.8 대 90.1(약 1.7점 차이)을 80% 검정력, 양측 α = 0.05로 가리려면 **팔당 약 4,470회**가 필요합니다. 논문 전체 LIBERO 시행은 800회입니다.
- 3.7점 차이는 팔당 약 1,040회, 10점 차이는 약 285회가 필요합니다.
- 즉 이 실험 규모로 확인할 수 있는 것은 큰 차이(약 10점 이상)뿐입니다. 이 논문의 LIBERO 평균 개선은 그보다 훨씬 작습니다.

3. 유도 (검증한 식)

3.1 Wilson 구간

$\hat{p} = k/n$, $z = 1.96$일 때 중심 $(\hat{p} + z^2/2n)/(1 + z^2/n)$, 반폭 $z\sqrt{(\hat{p}(1-\hat{p})/n + z^2/4n^2)}/(1 + z^2/n)$. 구현은 `wilson()`에 있습니다. 극단 성공률($\hat{p} \approx 0.9$)에서도 Wald보다 안정적입니다.

3.2 층화 Mantel-Haenszel

과제군 g마다 2×2 표 (a_g, b_g, c_g, d_g), $n_g = a+b+c+d$일 때

- 공통 오즈비 $OR_{MH} = \Sigma\, a_g d_g/n_g \div \Sigma\, b_g c_g/n_g$
- $\chi^2 = (|\Sigma a_g - \Sigma E_g| - 0.5)^2 / \Sigma V_g$, $E_g = r_g c_g/n_g$, $V_g = r_g(n_g-r_g)c_g(n_g-c_g)/(n_g^2(n_g-1))$

LIBERO 결과에서 제안 대 UniVLA의 $OR_{MH} = 1.50$, 제안 대 villa-x는 1.23입니다.

3.3 Holm

m개 p 값을 정렬해 $p_{(i)} \times (m - i + 1)$의 누적 최댓값을 취합니다.

3.4 전경 마스크 기준(임계값 0.5)의 실제 의미

코드(`lam.py`)는 16×16 패치 격자에서 마스크 면적 비율 a를 `attention = (5·a + 0.3)/5.3`으로 계산합니다. 이 식은 가중치처럼 보이지만 `shared_step`에서 임계값 0.5로 이진화합니다. 따라서 패치가 전경이 되는 조건은 $(5a + 0.3)/5.3 > 0.5 \Leftrightarrow$ **$a > 0.47$**입니다. 즉 패치 면적의 47% 이상이 마스크여야 전경 손실에 들어갑니다. 논문은 "foreground"라고만 씁니다. 이 임계값은 논문에 없습니다(04 D3).

3.5 자르기로 인한 이미지-마스크 어긋남

코드의 `random_resized_crop` 설정은 `scale=[0.9, 0.9], ratio=[1, 1]` 입니다. 면적 0.9 자르기를 가정하면 자른 한 변은 $\sqrt{0.9} = 0.949$ W이고, 다시 키우면 배율은 $1/0.949 = 1.054$입니다. 자르기 시작점을 $u(0 \le u \le 0.051$ W)라고 하면 원래 좌표 x에 있는 내용은 $x' = (x - u)/0.949$로 옮겨갑니다. 마스크는 자르지 않으므로 어긋남은

$$d(x) = x' - x = 0.054\, x - 1.054\, u$$

입니다(W = 224 기준). 중앙($x = 112$)에서는 $|d| \le 6$ px, 가장자리에서는 최대 약 12 px입니다. 패치 한 칸은 14 px이므로, 가장자리 패치는 한 칸 가까이 밀립니다. 이것은 가정(면적 비율 해석)에 따른 계산이고, 실제 dlimp 구현에서 자르기 변수를 확인하지는 못했습니다(04 D9).

3.6 행동 경로 손실의 정규화

전경 손실은 Σ(pred − target)² · m / (Σm · D)입니다. 분모는 전경 패치 수 × 768입니다. 배경 손실도 같은 방식입니다. 전체 경로는 마스크 없이 평균 제곱 오차입니다. 세 항의 가중치는 모두 1입니다(코드 `w_recon_*`).

4. Toy 검증 (`analysis/motion_toy.py`)

4.1 설계

- 32×32 프레임. 4×4 에이전트 블록이 행동 {오른쪽, 왼쪽, 위, 아래}에 따라 2 px 움직입니다. 행동 라벨 4종.
- 분포 이동 두 가지를 넣었습니다. 카메라 이동 5종(장면 전체가 1 px 움직임)과 밝기 변화 3종(전체 −0.2, 0, +0.2).
- 프레임 차이를 2×2 평균풀링해 256차원으로 줄이고, k-means(16개 코드)로 이산화합니다. VQ-VAE 학습은 하지 않습니다. 목적은 **무엇이 코드를 차지하는가**를 보는 것입니다.
- 지표: 혼잡도(perplexity = 2^H(코드 사용률)), 판독력(코드별 최빈 라벨의 정확도, 확률 기준선 포함).
- 마스크: 에이전트가 t와 t+1 어디에든 있는 영역을 1 px 팽창한 영역입니다.
- 기본 배경 질감 진폭은 0.05(거의 정적인 배경)이고, 0.25로도 돌렸습니다.
- 시작 위치는 두 가지입니다. 무작위(교란 있음)와 고정(교란 제거)입니다.
- "fg_norm"은 **논문에 없는 가설적 보정**입니다. 전경 평균을 빼서 밝기 성분을 지웁니다.

4.2 결과

(A) 입력 비교, K = 16, 시작 위치 고정, 배경 0.05

입력	행동 판독	카메라 판독(기준선 0.22)	밝기 판독(기준선 0.35)	혼잡도
전체 차이	1.00	0.31	**1.00**	14.7
전경 마스크	1.00	**0.58**	0.61	14.4
배경 마스크	0.75	0.34	1.00	13.2
전경 평균 제거(가설)	1.00	0.67	0.37	11.9

(B) 시작 위치를 무작위로 두면(배경 0.05): 행동 판독이 기준선 근처(0.28 대 0.26)로 떨어집니다. 위치 교란이 k-means 군집을 지배하기 때문입니다. 밝기 판독은 전체 차이에서 1.00, 전경 마스크에서 0.40입니다. 배경 0.25에서도 같은 방향입니다(표 생략, `motion_toy_results.json`).

(C) K 스윕(시작 위치 고정): 전체 차이는 K = 4에서 행동 판독 0.42로 낮고, K ≥ 16에서 1.0 근처입니다. 전경 마스크는 K = 4에서도 1.00입니다. 혼잡도는 K에 따라 2.6-47로 늘어납니다. 낮은 K에서는 마스크가 행동 판독에 도움이 되고, 높은 K에서는 차이가 줄어듭니다.

(D) 자르기 불일치(시작 위치 고정, K = 16, 전경 마스크):

조건	행동 판독	카메라 판독	밝기 판독	가짜 움직임 라벨(25종) 판독
올바른 마스크	0.98	0.61	0.59	—
공통 자르기, 마스크는 그대로	0.79	0.26	0.47	—
프레임 t+1만 자르기	0.62	0.31	0.50	0.145(기준선 0.047)

프레임 t+1만 자르면 코드가 **자르기 이동 자체를** 판독할 수 있을 만큼 담습니다(0.145 대 0.047).

4.3 toy의 한계

- k-means는 VQ-VAE와 다릅니다. 그래디언트가 없고 전이 구조도 없습니다.
- 32×32 장면과 4×4 블록은 실제 손·팔 영상과 비교하면 매우 단순합니다.
- 가짜 움직임 실험은 자르기 정도를 ±2 px로 골랐습니다. 실제 크기는 §3.5의 계산을 따릅니다.
- 무작위 시작 위치에서 행동 판독이 무너지는 것은 토이의 군집 방식 때문입니다. 실제 VQ는 다른 결과를 낼 수 있습니다.

5. 이 분석이 말하는 것

1. **숫자는 맞지만 헤드라인 차이는 작습니다.** 표의 평균은 모두 맞습니다. 그러나 villa-x 대비 1.6점은 유의하지 않고(p 0.30), RoboTwin에서 π0·UniVLA 대비도 유의하지 않습니다(p 0.26, 0.12 보정 후). 유의한 차이는 저자 재현 UniVLA, 실물 소표본, 그리고 절제(w/o DINO)에서만 나타납니다.
2. **기준선 행이 같은 프로토콜이 아닙니다.** 17개 칸이 200회에서 정수가 되지 않습니다. UniVLA 재현은 원 보고치보다 4.4점 낮습니다.
3. **toy는 "밝기를 마스크가 못 막는다"와 "카메라 이동이 마스크 안에 남는다"를 보여 줍니다.** 전체 차이는 밝기 성분을 완전히 담고, 전경 마스크는 이를 0.61까지 줄이지만 0에는 이르지 못합니다. 전경 마스크 안의 카메라 판독은 0.58입니다. 논문의 전체 재구성 경로는 마스크 없이 학습되므로 이 누수의 통로가 됩니다.
4. **자르기 불일치는 가짜 움직임을 만들 수 있습니다.** 코드 설정(이미지만 자르고 마스크는 안 자름)을 그대로 두면, 프레임마다 다른 자르기가 들어갈 때 코드가 자르기 이동을 기억합니다. 이 실험은 설정이 실제로 프레임 단위로 독립인지 확인이 필요함을 보여 줍니다(04 D9).

추가 검증 (2026-11-11)

추가 검증 1. 전경 마스크 팽창 크기와 카메라 이동 크기에 따른 판독 (`extra_mask_dilation.py`)

- **목적:** §4.2 (A)에서 전경 마스크 안 카메라 판독이 0.58로 남는다는 결과가 마스크 크기에 얼마나 민감한지 봅니다. 마스크를 얼마나 키워야 카메라 누수가 사라지는지, 아니면 늘어나는지 확인합니다.
- **설정:** `motion_toy.py`와 같은 장면 생성(32×32, 4×4 블록, 행동 4종·카메라 5종·밝기 3종, 2×2 풀링, k-means K=16). 바꾼 것은 세 가지입니다.
  - 마스크 팽창: 블록 합집합을 4방향으로 0-4 px 팽창(기존 toy는 1 px).
  - 카메라 이동 크기: 1 px(기존)와 2 px.
  - 시작 위치: 고정(14, 14)(§4.2 (A)와 같음)과 무작위(§4.2 (B)와 같음). 배경 질감 진폭 0.05와 0.25.
  - 판독 지표는 순도입니다. 유한 표본에서 순도는 기회 수준보다 높게 나오므로, 라벨을 무작위로 섞은 순도(귀무)를 함께 냈습니다. 시드 5개, 표본 2000개.
- **결과 (시작 위치 고정, 배경 0.05, 시드 5개 평균; 귀무 순도는 0.24 안팎):**

팽창	카메라 1 px: 카메라 순도 / 밝기 순도	카메라 2 px: 카메라 순도 / 밝기 순도	행동 순도 (1 px / 2 px)
0 px	0.69 / 0.46	0.55 / 0.52	0.99 / 0.68
1 px	0.62 / 0.55	0.57 / 0.51	0.97 / 0.68
2 px	0.51 / 0.67	0.59 / 0.52	0.95 / 0.68
3 px	0.46 / 0.72	0.58 / 0.55	0.94 / 0.66
4 px	0.43 / 0.76	0.54 / 0.62	0.95 / 0.66

- 배경 질감 0.25에서도 같은 방향입니다(카메라 1 px: 0.74 → 0.42, 밝기: 0.42 → 0.79).

- 시작 위치를 무작위로 두면 카메라·행동 순도가 모두 귀무 수준(0.24–0.32)에 가까워집니다. 위치 교란이 k-means 군집을 지배합니다(§4.2 (B)와 일치). 이 경우 밝기 순도는 팽창에 따라 0.38에서 0.88로 커집니다.
- **결론:** 마스크를 0–4 px 범위에서 키워도 카메라 누수는 사라지지 않았습니다(순도가 귀무 0.24보다 0.2 이상 높음). 팽창이 커지면 코드가 카메라에서 밝기로 옮겨 갑니다. 카메라 1 px에서 팽창 0 → 4 px일 때 카메라 판독은 0.69에서 0.43으로 줄고 밝기 판독은 0.46에서 0.76으로 늘어납니다. 2 px 카메라 이동은 2–3 px 팽창에서 카메라 판독이 가장 높습니다. 이 결과는 "마스크가 커지면 누수가 줄어든다"는 직관과 맞지 않습니다. 마스크 크기로 카메라 누수를 막을 수 없고, 마스크 밖 배경을 포함하면 밝기 누수가 커집니다.
- **한계:** 2차원 격자, 블록 하나, 고정 시작 위치. 순도 지표는 k-means의 코드 수(16)에 민감합니다. 행동 순도는 카메라 2 px에서 0.68로 떨어지는데, 이는 이동 크기가 블록의 행동 신호와 섞이기 때문입니다. 실제 영상의 손 마스크(SAM2)와 다릅니다.

04. 코드 대조와 주장 검증

공식 코드는 얕게 clone해 분석 폴더 안에 두었습니다(`repo/` , 저장소 `.gitignore` 로 제외). 대조 기준 커밋은 ** `fd614f7` (2026-06-18, "update readme")**입니다. 저장소는 Apache-2.0(`LICENSE`), 별점 0, 마지막 push 2026-06-18입니다. v2 초록의 코드 링크는 2026-07-02에 추가되었으므로, 이 커밋은 v1 시점의 스냅샷에 가깝습니다. 태그나 릴리스는 없습니다. 대조 범위는 잠재 행동 모델(`latent_action_model/`), VLM 사전학습과 미세조정(`vla-scripts/`), 데이터 로더(`prismatic/vla/datasets/`)입니다. 실행은 하지 않았습니다(CUDA 전제, §4).

1. 저장소 구성

경로	내용	논문과의 관계
`latent_action_model/genie/modules/lam.py` (229줄)	이중 코드북 VQ-VAE, 세 디코딩 경로	III-B 전부
`latent_action_model/genie/model.py` (481줄)	Lightning 학습 루프, 손실, 코드 사용률	III-B.4, Eq. 1
`latent_action_model/genie/dataset.py` , `prismatic/vla/datasets/`	RLDS 로더, 쌍 샘플링, 마스크 전달, 증강	III-B 입력, 실험 설정
`latent_action_model/config/*.yaml`	EgoDex / Bridge 설정	IV-A, IV-B
`vla-scripts/train.py`	VLM 사전학습(잠재 토큰 NLL)	III-C, Eq. 2
`vla-scripts/finetune_libero.py`	LIBERO 미세조정(L1 헤드)	IV-A
`vla-scripts/finetune_robotwin_flow.py` (1166줄)	RoboTwin 미세조정(flow-matching 헤드)	III-D, IV-B
`vla-scripts/deployment_real.py`	실물 배포	IV-B 실물
없음	데이터 전처리, SAM2·RoboEngine 마스크 생성, 학습된 체크포인트	README: "data preprocessing script will be released upon finalization"

2. 논문 ↔ 코드 대조 (D 항목)

판정: **일치**(논문과 코드가 같음), **차이**(코드가 논문과 다름), **누락**(논문은 있으나 코드가 없음), **버그**(동작 오류), **미확인**(코드만으로 알 수 없음).

ID	논문 주장(위치)	코드(파일:줄)	판정
D1	SAM2로 사람 손 마스크 생성(III-B.3)	로더는 `egodex_with_sam2_mask_all` 데이터의 `mask` 키를 읽음(`lam-stage-2-egodex.yaml` , `configs.py:79–80`). 생성 코드 없음	누락(생성 파이프라인)
D2	로봇 마스크는 RoboEngine(IV-A)	Bridge 설정은 `bridge_oxeall` 의 `mask` 키를 읽음(`lam-stage-2-bridgeall.yaml`). 생성 코드 없음	누락
D3	행동 경로는 "전경 영역"만 감독(III-B.3)	`model.py:291–299` : 주의 맵 임계값 0.5로 이진화. 실제 전경 조건은 마스크 면적 > 47% (03 §3.4). 맵의 연속 가중치(`lam.py:137–139`)는 쓰이지 않음	차이(임계값은 논문에 없음)
D4	전체 재구성 경로(III-B.3)	`lam.py:204–213` , `model.py:320` : 마스크 없는 전역 MSE, 가중치 1. 행동 코드가 배경·밝기를 설명하는 통로	일치(논문도 전역 항 포함) — 누수 통로(03 §4)

ID	논문 주장(위치)	코드(파일:줄)	판정
D5	Eq. 1의 λ_recon, λ_vq, λ_commit	재구성 항 가중치 1, 1, 1(`model.py:320–325`), VQ 가중치 1, 커밋 β = 0.25(`model.py:357`, `vq_beta`). 논문은 값을 주지 않음	미확인(논문 누락)
D6	코드북 크기 16 두 개, 쌍당 토큰 4(III-B.2)	`lam.py:68–79`(`num_latents=16`), `lam.py:46`(`num_codes=4`)	일치
D7	VQ 재시작(논문 언급 없음)	`model.py:440–441`: 에포크마다 **배경 코드북만** `random_restart()`. 행동 코드북은 재시작하지 않음. 재시작은 `randperm`으로 기존 코드를 복사(`blocks.py:435–445`)	차이(행동 코드북 사용률 관리 없음; 재시작 방식이 죽은 코드에 기존 코드를 복사)
D8	"1초 간격 쌍"(III-B 서두)	`dataset.py:357–363`: 설정 목록에 없는 데이터셋은 창 크기가 기본값. `datasets.py:337`의 기본 `window_size=10`이 그대로 전달되어 쌍 간격은 **9프레임**. 목록에 없는 EgoDex와 Bridge 모두 해당. 영상 fps 확인 필요	차이(1초는 fps 9에서만 성립)
D9	(논문 언급 없음) 증강	`datasets.py:383–410`: 영상에 `random_resized_crop(scale 0.9)` 적용. 마스크 증강은 주석 처리(`#"mask": mask_augment_kwargs`). EgoDex 설정은 `image_aug: true`. `obs_transforms.augment`는 `image_*` 키 중 지정된 것만 자름. 두 프레임이 같은 자르기 변수를 쓰는지는 dlimp 내부 구현에 달려 있어 미확인	**버그 가능성**: 이미지와 마스크 정렬 불일치(03 §3.5). 프레임 단위 독립 자르기라면 가짜 움직임
D10	코드북 크기 16, 행동 토큰 4(III-C)	`vla-scripts/train.py:42`(`codebook_size=16`), 특수 토큰 `<ACT_i>` 16개	일치
D11	Prismatic-7B 백본(III-C)	`train.py:38`(`prism-dinosiglip-224px+7b`), README의 HF 링크	일치
D12	디코더와 VLM 어휘 연결(III-C, Eq. 2)	`train.py:186–218`: 학습된 LAM으로 쌍의 토큰을 만들어 VLM 목표로 사용	일치(사전학습 데이터 규모 미기재)
D13	의도 예측 CE, λ_intent(Eq. 5)	`finetune_robotwin_flow.py:1076`: VLA 미동결 시 **L = 10·L_flow + L_CE**(상대 가중 0.1). 동결 시 L = L_flow로 CE 없음	차이(λ 값은 논문에 없음; 기본 설정은 동결)
D14	VLM은 LoRA로 미세조정(III-D)	`finetune_robotwin_flow.py:855`(`freeze_vla=True`), `:857`(`use_lora=False`). `finetune_libero.py:175–176` 동일. 기본값은 **동결 + LoRA 없음**. LoRA 설정은 실행 경로 이름(`lora-r32`)에서만 드러남	차이(기본값이 논문 주 설정과 다름)
D15	미세조정 흐름: VLM 은닉 + DINOv2 + 고유 감각(Eq. 3), flow-matching(Eq. 4)	RoboTwin: DINOv2 특징(`x_norm_patchtokens`)을 주 시점과 손목 시점에 모두 씀(`:796`). 흐름 손실은 `:725`, `:811`	일치
D16	LIBERO 행동 헤드: "UniVLA의 자기회귀 헤드"(IV-A)	`finetune_libero.py:40–60`: MAP 풀링과 MLP(tanh) 출력, L1 회귀(`:133`). 자기회귀 디코딩이 아님. 흐름 손실도 아님	차이(설명과 구현 불일치)

ID	논문 주장(위치)	코드(파일:줄)	판정
D17	LIBERO는 3인칭 영상만 씀(IV-A)	`finetune_libero.py:100` : `wrist_dino = True` 로 **손목 DINOv2 특징을 항상 사용**. 주 시점 임베딩은 VLM 은닉 상태(`:105`), DINO가 아님. 주 시점 DINO 분기(`:113–120`)는 `else` 에만 있음	**차이(중요)**: 논문의 "DINO로 상태 인지"와 LIBERO 설정 설명이 코드와 맞지 않음. 손목 입력을 쓴다면 IV-A 설명과 다름
D18	잠재 토큰 위치 선택	`finetune_libero.py` 의 `action_gt > 32000` 마스크: 어휘 ID가 32000보다 큰 토큰을 잠재 행동으로 씀	미확인(32000 오프셋의 근거 없음)
D19	자기회귀 대 flow 헤드(RoboTwin)	`finetune_robotwin_flow.py:654–725` : HRDT 계열 FlowBlock 기반 헤드	일치
D20	실험 설정 값: LIBERO 30k/40k 스텝, 배치 128(IV-A)	`train.sh` 와 finetune 설정: 배치 8, 최대 40000 스텝 (`finetune_libero.py:154–155`). 배치 128과 불일치하는 설정 확인 필요	차이(미확인)
D21	코드북 크기 "32"(설정)	`finetune_robotwin_flow.py:844` 에 `lam_num_latents=32` 가 있으나 `lam.py:70, 75` 는 16을 고정. 인자는 무시됨	버그(인자 무시, 실행은 됨)
D22	학습 명령	`latent_action_model/train.sh` 는 `lam-stage-2-mix.yaml` 을 부르지만 저장소에 없음(설정은 egodex와 bridgeall 두 개). 경로는 `MFVLA/…` 고정	버그
D23	테스트 시 코드 사용률 그림	`model.py:448–455` : `self.lam.vq` 를 참조하지만 모듈 이름은 `vq_action` , `vq_bg` . 테스트 종료 때 AttributeError	버그
D24	(실행 장치)	`model.py:363, 368` : `.cuda()` 하드코딩. `flash-attn==2.5.5` (README). `torch.hub` 로 DINOv2 다운로드	제약(CUDA·네트워크)
D25	입력 마스크 채널	주석은 마스크가 2채널(`lam.py:131`)이라 하지만 로더는 1채널(`datasets.py:310–313`). 실제 형상은 (B,T,1,H,W)이고 동작에는 문제 없음	주석 오류
D26	공개 상태	README 제목 "Motion-Focused Vision-Language-Action Model via Hybrid Disentangled Action Tokenization"은 arXiv 제목과 다름. README는 데이터 전처리를 "released upon finalization"이라 함	누락·제목 불일치
D27	평가 시행 수(IV-A, 과제당 20회)	`README` : `--num_trials_per_task 20 --seed 7` (`run_libero_eval.py`)	일치

죽은 코드 참고: `model.py:325–349` 의 행동 손실 분기는 `pred_action` 이 없어서 실행되지 않습니다. `lam.py` 의 `shallow` 분기(`dim_half`)도 입력이 768차원뿐이라 빈 텐서입니다. 두 경우 모두 결과에 영향은 없습니다.

3. 주장 검증 (C 항목)

논문 주장을 원문 기준으로 대조했습니다. 판정: **지지**, **부분 지지**, **미지지**, **검증 불가**.

ID	주장(위치)	검증 결과	판정
C1	초록: "pre-trained exclusively on unlabeled human videos"	IV-A(LIBERO, 헤드라인 평균 91.8)는 BridgeV2 **로봇** 영상으로 사전학습. 사람 영상은 IV-B(RoboTwin)와 실물에서만 씀	부분 지지(헤드라인과 불일치)
C2	초록: "requiring only ~50 trajectories"	과제당 50개. LIBERO는 10과제(군당 500개), RoboTwin 10과제(500개)	부분 지지(과제당 수치)

ID	주장(위치)	검증 결과	판정
C3	Table I: 평균이 모든 기준선보다 높다	91.8 > 90.1(villa-x): 합산 Fisher p = 0.30. UniVLA(저자 재현)보다는 p = 0.020, 보정 0.039	부분 지지(villa-x 대비 유의하지 않음)
C4	IV-A: Goal +2.0, Long +9.5(villa-x 대비)	차이 값은 정확(93.5–91.5, 84.0–74.5). Long만 p = 0.026(과제군 내), Goal p = 0.57	지지(값), Long만 유의
C5	Table I 기준선 UniVLA "strictly reproduced"	원 논문 Bridge 평균 92.5 대 재현 88.1	지지되지 않음(재현값이 4.4점 낮음)
C6	Table II: "comparable to state-of-the-art"	67.7 대 π0 65.2(p = 0.26), UniVLA 63.6(p = 0.06, 보정 0.12)	지지(comparable), "앞선다"는 미지지
C7	의도-인지 분리가 성능을 올린다(IV-A, IV-B)	w/o DINO 대비 LIBERO +6.4($p \approx 8\times10^{-5}$), RoboTwin +4.9(p = 0.024, 보정 0.073). 단일 시드로 보임	부분 지지(LIBERO 강함, RoboTwin 약함)
C8	동결 VLM도 RDT와 비슷하니 VLM 사전학습이 효과적(IV-B)	대조(사전학습 없는 같은 구조)가 없음. RDT는 다른 아키텍처	미지지(근거 부족)
C9	실물에서 UniVLA를 앞선다(Fig. 3c)	46/60 대 23/60, $p = 4\times10^{-5}$(시행 수 20회 가정). 과제 3개 중 2개만 p < 0.05(보정 0.029)	지지(소표본, 시드 미보고)
C10	CKA 0.9139 대 0.8659에서 "significantly higher"	부트스트랩 표준편차는 시드 변동이 아님. 데이터 쌍 1개(BridgeV2 대 FurnitureBench), 사람 영상 없음	미지지(유의성 주장)
C11	Fig. 5: 사람과 로봇이 같은 토큰을 받는다	세 예시의 정성적 나열. 정량 지표 없음	검증 불가(예시 3개)
C12	행동 코드는 배경과 카메라 이동을 분리한다(I, III-B)	전체 재구성 경로가 마스크 없이 학습됨(D4). 분리 여부를 재는 probe가 없음. toy에서 전경 마스크 안에도 카메라 정보가 남음(03 §4.2 A)	미검증(누수 가능성)
C13	코드북 사용이 건강하다(암묵)	사용률·혼잡도를 보고하지 않음. 행동 코드북은 재시작하지 않음(D7)	검증 불가
C14	시드 반복, 신뢰구간	어떤 표에도 없음	미지지(보고 부재)

4. 구현 가능성 (판정)

결론: 공식 재현은 이 맥에서 불가능하고, 아이디어 재구현은 중간 난이도입니다.

(a) 공식 재현

- 코드는 공개되어 있지만 실행 경로가 CUDA를 전제합니다(`.cuda()` 하드코딩, flash-attn 2.5.5, `torch.hub` 다운로드). 이 맥(M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, **torch 미설치**)에서는 실행 자체가 막힙니다.
- 자원: LAM 학습은 GPU 2장(설정 `devices: 2`, 배치 64/장치, 2 epoch, 16-mixed). VLM 사전학습과 LIBERO 미세조정은 GPU 4장(`train.sh`), RoboTwin은 2장. GPU 모델은 기재되지 않았습니다.
- 데이터: EgoDex 영상 + SAM2 마스크(**마스크 미공개**), BridgeV2 OXE + RoboEngine 마스크(**미공개**), LIBERO RLDS(HF), RoboTwin 2.0 생성 데이터, 실물 데이터(미공개). 체크포인트: Prismatic-7B(HF)만 공개, 잠재 행동 체크포인트와 미세조정 체크포인트는 공개되지 않음.
- 판정: **이 맥 불가**, 공식 재현은 CUDA 서버에서 4 GPU 수준 + 마스크 생성 파이프라인이 필요합니다.

(b) 아이디어 재구현

- 핵심(이중 코드북 VQ-VAE + 마스크 손실 + 토큰을 VLM에 넣기 + 의도-인지 분리)은 코드에서 수백 줄로 다시 쓸 수 있습니다. 재구현 장벽은 (1) 사람 손 마스크 생성 파이프라인(SAM2 실행), (2) 두 단계 사전학습 자원, (3) 자르기-마스크 정렬 같은 데이터 세부입니다.

- 이 맥에서는 DINOv2-B 특징 추출도 느리고, 7B VLM의 LoRA 학습은 24 GiB에 맞지 않습니다. 작은 실험은 가능합니다(toy 수준, 소형 인코더 대체).
- 판정: **중간 난이도**. 설계 요소를 떼어 검증하는 소형 실험(후속 검증 후보)은 맥에서 가능하고, 대규모 학습은 GPU가 필요합니다.

5. 빠진 정보 목록 (재현에 필요한데 논문·코드에 없는 것)

1. 사전학습 데이터 규모(EgoDex 쌍 수), 스텝, 배치, 학습률(LAM, VLM).
2. 손·로봇 마스크 생성 절차와 임계값(D1, D2, D3).
3. λ_recon, λ_vq, λ_commit, λ_intent 값(D5, D13).
4. 쌍 간격과 영상 fps(D8).
5. 증강이 프레임과 마스크에 어떻게 적용되는지(D9).
6. 사용률, 혼잡도, 코드 재시작 방식(D7, C13).
7. 시드 수, 표준편차, 평가 시행 수(RoboTwin, 실물).
8. LIBERO 헤드 구조와 시점 구성(D16, D17).
9. 기준선 재현 설정(UniVLA-Bridge, 기준선 값의 출처별 프로토콜).

02. 선행연구와 관계

1. 계보

갈래	대표 연구	이 논문이 가져온 것
잠재 행동 사전학습(VQ 재구성)	LAPA [9], IGOR [10]	프레임 쌍을 이산 코드로 압축하고 재구성하는 틀. 배경과 카메라 이동이 섞인다는 진단(I)
작업 중심 잠재 행동	UniVLA [12]	두 단계 학습과 언어 유도로 움직임 집중. 이 논문은 언어 대신 전경 마스크를 쓴다고 주장
로봇 상태 결합 잠재	villa-x [17], GO-1 [5], GR00T N1 [14]	잠재 행동에 로봇 상태·행동 감독을 붙이는 방식. 이 논문은 행동 라벨 없이 사람 영상만 씀
사람 데이터 VLA	EgoMimic [6], MotionTrans [7], H-RDT [8], UMI [18]	손 자세 라벨(AR/VR, 손잡이) 기반. 이 논문은 라벨이 없다고 비교
VLA 바탕	OpenVLA [13], π0 [2], RDT [3], Prismatic-7B [20]	VLM 백본(Prismatic)과 flow-matching action expert(RDT 계열 헤드)
표현 정렬 측정	CKA [30]	도메인 부분공간을 지운 뒤 로봇 두 데이터셋의 토큰 표현 정렬
분할	SAM2 [19], RoboEngine [26]	손·로봇 마스크 생성

2. 가까운 대안

2.1 사람 영상을 쓰는 잠재 행동

- **DreamX** (저장소 `dreamx/`): 사전학습된 영상 확산 모델(Cosmos-Predict2.5 2B)에 질의를 붙여 잠재 프레임당 행동 토큰 4개를 뽑습니다. 이 토큰만으로 미래 영상을 재구성합니다. 이 논문과 **토큰 개수(4)와 "사람·로봇 공통 인터페이스"라는 목표가 같습니다.** 차이는 재구성 백본(확산 대 VQ-transformer)과 마스크 유무입니다. DreamX에는 마스크로 움직임을 분리하는 장치가 없습니다.
- **LAPA [9], IGOR [10]:** 사람 영상으로 잠재 행동을 학습하지만 마스크가 없습니다. 이 논문의 기준선(LAPA)입니다.
- **UniVLA [12]:** 사람 영상과 로봇 영상을 함께 쓰며, 언어 신호로 작업 중심 움직임을 고릅니다. 이 논문의 주된 비교 대상입니다(Table I, Table II, 실물).

2.2 논문이 인용하지 않은 가까운 연구

- **ThinkWorld** (저장소 `thinkworld/`): 사람·로봇 공유 손목 움직임 토큰을 쓰고, 1초 뒤 DINO 특징을 예측합니다. 이 논문과 "1초 간격 쌍"과 DINO 특징 예측이 비슷합니다. 인용되지 않았습니다.
- **FlashDexRetarget** (저장소 `flashdexretarget/`): 사람 손-물체 시연을 레퍼런스 조건부 RL 정책으로 로봇 손 궤적에 옮기는 연구입니다. 사람과 로봇을 궤적 수준에서 맞추는 방법이라서, 잠재 토큰을 공유하는 이 논문의 방식과 대비됩니다.

2.3 구성 요소별 출처

구성 요소	출처	이 논문의 새 점
이중 코드북 VQ, 쌍당 토큰 4	LAPA [9]와 VQ 재구성 계열	행동 코드북과 배경 코드북을 분리
마스크 손실(전경·배경 경로)	SAM2 [19], RoboEngine [26]	디코더 경로를 세 개로 나누고 영역별로 감독
DINOv2 특징	DINOv2 (코드 `dinov2_vitb14_reg`)	미세조정에서 상태 인지를 DINO에 맡김

구성 요소	출처	이 논문의 새 점
VLM에 잠재 토큰 넣기	UniVLA [12]의 어휘 확장	사람 영상으로 사전학습
의도-인지 분리	논문의 주장	DINO와 VLM 임베딩을 바꿔 가며 절제

3. 이 저장소의 다른 논문과의 관계

폴더	공통점	차이와 시사점
`dreamx/`	사람 영상에서 잠재 행동 토큰 4개를 뽑고 사람·로봇 공통 인터페이스로 씀	DreamX는 영상 확산 백본을 디코더로 쓰고, 이 논문은 VQ 재구성과 마스크를 씀. DreamX는 공개 코드가 없고, 이 논문은 있음. 두 논문 모두 **움직임과 배경을 어떻게 분리했는지** 직접 측정한 실험이 부족함
`openwam/`	행동 생성 설계 선택을 부품으로 쪼갬	OpenWAM은 영상 생성 prior를 쓰고, 이 논문은 VLM에 잠재 토큰을 넣음. 둘 다 사전학습 데이터 규모가 재현의 장벽
`agentic_wam/`	행동과 미래 영상을 함께 다룸	AW-0는 코드·미래 영상·행동을 Mixture-of-Transformers 하나에서 함께 denoise합니다. 이 논문은 잠재 행동 토큰만 VLM에 넣고 영상 생성은 하지 않습니다
`pacevla/`	VLA의 action expert만 바꿈	PaceVLA는 여러 decoder와 라우터. 이 논문은 action expert 입력에 DINO 특징과 VLM 의도를 함께 넣음
`thinkworld/`	1초 뒤 DINO 특징 예측	ThinkWorld는 예측을 RL 보상으로 쓰고, 이 논문은 잠재 행동 학습에 씀. 이 논문의 "1초 간격 쌍"과 설계 근거를 비교할 수 있음
`flashdexretarget/`	사람 시연을 로봇 손으로 옮김	사람-로봇 연결 방식이 다름(이 논문은 잠재 토큰으로 연결)

4. GitHub (2026-11-10 확인)

저장소	무엇인가	공식 여부	커밋	라이선스	별
`shuiyigong/Motion-Focused-Latent-Action`	논문 코드(잠재 행동, VLM 사전학습, LIBERO·RoboTwin 미세조정, 실물 배포)	공식(v2 초록 링크)	`fd614f7` (2026-06-18, "update readme")	Apache-2.0	0
`OpenDriveLab/UniVLA`	UniVLA [12] 코드	원 저자 조직 추정(논문 본문에는 링크 없음, 미확인)	`0ab9e9d` (2025-11-19)	Apache-2.0	1,145
`RoboTwin-Platform/RoboTwin`	RoboTwin 2.0 시뮬레이터와 벤치마크 [27]	원 저자 조직 추정	`ea8b211` (2026-09-24)	MIT	3,049
`apple-aiml-research/ml-egodex`	EgoDex 데이터 [28] (논문 README 링크는 `apple/ml-egodex`로 이동됨)	원 저자	`718d9eb` (2026-09-11)	NOASSERTION(라이선스 파일 확인 필요)	410
`TRI-ML/prismatic-vlms`	Prismatic VLM 백본 [20]	백본 공식	`874c5bb` (2024-05-16)	MIT	1,026

`villa-x`와 LAPA의 공식 저장소는 `gh search repos`에서 찾지 못했습니다. 이 논문의 `shuiyigong` 저장소는 clone했습니다(`repo/`). 나머지는 메타데이터만 확인했습니다.