Nemotron 3.5 Super VL·Lightning 기술 보고서: 분석 리포트

게시용 버전: 보고서 그림은 라이선스("All rights reserved") 때문에 제외했습니다. 원문 https://research.nvidia.com/labs/nemotron/files/NVIDIA-Nemotron-3.5-Super-and-Lightning-Technical-Report.pdf · NVIDIA 기술 보고서(2026-10-27, arXiv 없음, 79쪽) · 모델 HF 공개 2026-10-12, 블로그 2026-10-15 · 모델 OpenMDW-1.1, 코드 Apache-2.0 · 분석일 2026-10-30 · 보고서 그림은 개인 학습용으로만 사용(보고서가 "© 2026 NVIDIA. All rights reserved.")

핵심 요약

1. **무엇인가:** Nemotron 3 Super(텍스트, 120B-A12B)를 Ultra 3에서 1T 토큰 증류하고, Indic 계속 사전학습, 1M 문맥, 256K SWE 중간학습을 거친 뒤 사후학습에서 시각을 붙인 멀티모달 에이전트 모델이다. 교사 여러 개를 MOPD로 합치고, NVFP4 양자화와 vLLM 서빙 최적화까지 다룬 레시피·시스템 보고서다. "Lightning"은 같은 세대의 30B-A3B 텍스트 전용 소형 모델이다.
2. **구조는 공개 config로만 확인된다:** 88층(Mamba-2 40, LatentMoE 40, attention 8), expert 512개 중 top-22, KV 헤드 2개. 전체 124.45B, 토큰당 활성 12.23B로 이름과 맞다. 활성 가중치에서는 Mamba projection(35.8%)이 routed expert(39.6%)만큼 크고, attention은 2.3%뿐이다.
3. **"Ultra를 넘는다"는 부분적이다:** T10 공통 27개 중 17승 10패이고, 1위는 GraphWalks 하나다. SWE-bench Pro 51.78%는 같은 OpenCode 하네스의 F8 값(41.04%)보다 10.7%p 높고, 보고서는 이 차이를 설명하지 않는다.
4. **양자화는 중앙값보다 꼬리를 봐야 한다:** 복원율 중앙값은 99.62%(36개 기준, 표 37행 전체는 99.70%, 결론에는 99.52%)지만 SciCode problem 93.6%, Tau3 Banking 94.2%가 있다. 공개 config의 SSM 상태 기본값은 float32이고, 카드의 SGLang 명령은 BF16을 쓴다. 보고서가 검증한 FP16+SR과 다르다.
5. **메커니즘 확인:** Mamba 캐시 한 페이지 = KV 4,096토큰(보고서 "약 4K"와 일치). ReplaySSM은 MTP 5에서 상태 트래픽을 약 5배 줄이지만 측정 처리량 이득은 5-6%다. 재구성 식의 곱 범위는 본문 표기(j > i+1)가 아니라 j > i다. MOPD 2단계의 proximal teacher 하한 −0.223을 toy로 확인했다.
6. **구현 가능성:** 이 맥(M4 Pro 24 GiB, CUDA 없음)에서는 Super VL을 어떤 공개 형식으로도 돌릴 수 없다(가장 작은 MLX 3비트가 39.8 GiB). 같은 세대 Lightning 30B-A3B 4비트(17.6 GiB)만 빠듯하게 가능하다. 미세조정은 LoRA도 8× H100 노드가 필요하고, 레시피는 잘 공개되어 있다.

01. 보고서 분석: Nemotron 3.5 Super (VL)와 Lightning 기술 보고서

- 제목: *Nemotron 3.5 Super and Lightning: Open, Efficient Mixture-of-Experts Hybrid Mamba-Transformer Models for Agentic AI*
- 저자: NVIDIA (기여자 목록은 보고서 Contributors 절)
- 공개: 보고서 PDF 첫 쪽 날짜 **2026-10-27**, research.nvidia.com에 PDF로만 공개(arXiv 없음, 79쪽). 모델은 Hugging Face에 2026-10-12에 올라왔고, 발표 블로그 두 편은 2026-10-15에 나왔습니다. 보고서가 모델과 블로그보다 약 2주 늦습니다.
- 라이선스: 보고서는 **"© 2026 NVIDIA. All rights reserved."**(1쪽 하단)이고 CC 라이선스 표시가 없습니다. 그래서 보고서 그림은 개인용 리포트와 PPT에만 씁니다. 모델 가중치는 **OpenMDW-1.1**(MIT식 허용 라이선스, 조문은 `02` §4), 학습·평가 코드(NeMo 계열)는 Apache-2.0입니다.
- 분석 범위: 보고서 본문 1-53쪽, 부록 A-C. 발표 블로그(blogs.nvidia.com)와 기술 블로그(developer.nvidia.com), Hugging Face 모델 카드 2개(BF16, NVFP4), 공개 `config.json`·safetensors 색인·헤더(가중치는 받지 않음), NVIDIA-NeMo cookbook과 NeMo Gym 평가 레시피도 함께 봤습니다.

> **"Lightning"이 가리키는 것.** 같은 3.5 세대의 작은 텍스트 전용 모델 **Nemotron 3.5 Lightning 30B-A3B**입니다(Nano 3 Base에서 초기화, Hugging Face 공개 2026-08-01). 이 보고서는 두 모델을 함께 다루지만 분량은 대부분 Super VL에 씁니다. Lightning은 증류, MTP, 양자화(§4.9), 병렬 drafter(DFlash, DSpark) 부분에만 나옵니다. 이 저장소의 `lightning_grasp/` (로봇 grasp 논문)와는 관계가 없습니다.

---

1. Abstract (한 줄 요약과 주장)

한 줄 요약: Nemotron 3 Super(120B-A12B, 텍스트)를 출발점으로, **Ultra 3 Base에서 1T 토큰 증류 → Indic 계속 사전학습 → 1M 문맥 → 256K 문맥 SWE 중간학습**을 거친 뒤, 사후학습 단계에서 **시각 입력을 붙이고 전문 교사 여러 개를 MOPD로 합쳐** 멀티모달 에이전트 모델로 만들었습니다. 그다음 **NVFP4 양자화와 vLLM 서빙 최적화(ReplaySSM, Mamba 체크포인트 prefix caching)**까지 한 보고서에 담았습니다.

보고서가 내세우는 수치(초록, §1)는 다음과 같습니다.

1. SWE-bench Pro **51.78%**로 Nemotron 3 Ultra(49.66%)를 넘음. 활성 파라미터는 약 4.6배 적음.
2. Indic 계속 사전학습으로 인도 언어 벤치마크 최대 **+9.82%p**(T2).
3. 사후학습 MTP boosting으로 acceptance length가 greedy에서 +10.1%, 확률적 draft sampling에서 **+21.8%**(T8).
4. NVFP4 양자화 정확도 복원율 중앙값 **99.62%**(36개 벤치마크, §4.1). 단, 결론(§6)에는 99.52%로 적혀 있습니다(`04` C8).
5. GB200 한 장에서 사용자당 50 tok/s 이상을 유지하며 최대 **4,856 tok/s/GPU**(T24). 같은 조건에서 NVFP4가 BF16의 2.43배, Qwen3.5 122B-A10B의 2.34배, Qwen3.8 Flash-Next의 1.90배(F10, F11).
6. 공개물: base·BF16·NVFP4 체크포인트, 병렬 drafter(Super용 LiLiCorr, Lightning용 DFlash·DSpark), 데이터셋, cookbook, 학습 레시피.

---

2. Method

2.1 구조 (보고서에는 구조 표가 없어 공개 config로 보완)

보고서 본문은 "120B total, 12B active, hybrid Mamba/attention, 512 routed experts, MTP"(§4.2)라고만 적고 층 구성을 표로 주지 않습니다. 아래 값은 공개 `config.json`과 safetensors 헤더에서 읽었습니다(`analysis/param_check.py`, `04` D5).

항목	값
층	88층 = Mamba-2 40 + LatentMoE 40 + attention 8. 패턴 `MEMEMEM*EMEMEMEM*…` (attention은 대략 11층마다 1개)
LatentMoE	hidden 4096 → latent 1024로 줄인 뒤 routed expert 512개 중 top-22, expert 중간 차원 2688, shared expert 1개. 라우터 계산은 FP32
Attention	query 32헤드, **KV 2헤드**, head_dim 128 (GQA 16:1)
Mamba-2	128헤드 × 64, 상태 128, 그룹 8
문맥	최대 1,048,576 토큰
어휘	131,072
시각	C-RADIO v4-H (ViT-H/16, 32층, 폭 1280, 최대 패치 13,312, 2×2 다운샘플) + projector(중간 20,480)
MTP	재귀적으로 공유하는 MTP 층 1개(attention + MoE). lm_head는 본체와 공유
파라미터	전체 **124.45B**(보고서 BPE 계산의 N과 일치) = LLM 120.67B + MTP 2.94B + 시각 0.65B + projector 0.19B. routed expert가 전체의 90.6%
활성	토큰당 **12.2B**(임베딩 제외) / 12.8B(포함). 이름의 "A12B"와 맞음

2.2 사전학습 파이프라인 (§2)

```
Nemotron 3 Super Base (25T 사전학습, arXiv:2604.12374)
  │ MTP 초기화: 원래 MTP 헤드 2개 중 첫째만 남겨 재귀 공유 헤드 1개로 (§2.1)
  │ MTP warm-up 100B 토큰 (본체 동결) + hidden-state mixing
  ▼
증류 1T 토큰 ← 교사 Ultra 3 Base (550B-A55B)                                §2.2
  │ Skew Reverse KL (α = 0.1), top-128 logit + sink 토큰, KL 0.9 + CE 0.1
  │ LR 4.5e-6 → 4.5e-5 (200B 토큰 동안 증가) → 4.5e-6 (800B 동안 선형 감소)
  ▼
Indic 계속 사전학습 100B (Indic 10% + 직전 혼합 90%)                        §2.3
  ▼
장문맥 1M, 35B 토큰 (CP16 × TP8 × EP64, GB300)                              §2.4
  ▼
SWE 중간학습 65.4B 토큰 @256K (T4 혼합)                                     §2.5
  ▼
장문맥 회복 9B 토큰 (RULER-1M 79.9 → 33.5 → 81.0)                           §2.4
  = Nemotron 3.5 Super Base
```

Lightning은 Nano 3 Base에서 시작해 Super 3 Base를 교사로 1T 증류(forward KL)하고, 장문맥 21B만 거칩니다. Indic CPT와 중간학습은 없습니다(§2.2, §2.4).

MTP의 train-inference 불일치(§2.1). 재귀 MTP를 표준 방식으로 학습하면 k번째 단계는 정답 은닉 상태로만 학습하지만, 추론에서는 앞선 MTP 단계가 만든 합성 상태를 입력으로 받습니다. Super는 학습 중 k번째 단계의 입력을 1…k−1 단계 출력에서

섞어 뽑는 **hidden-state mixing**으로 이 차이를 줄였습니다. 여러 단계를 실제로 펼쳐 학습하는 TTT보다 계산이 적다는 것이 근거입니다.

2.3 Indic 계속 사전학습 (§2.3, T1-T3, F2-F3)

- **데이터:** Nemotron-CC 영어 문서(4,096 토큰 미만, 분할 없이 통째로)를 Gemma-4-31B-it로 번역합니다. 번역 → 품질 점수(q ≥ 75면 채택) → 오류 수정 → 재채점의 4단계이고, 로마자 표기본도 같은 모델로 만듭니다(F2). 저자원 10개 언어는 Bodhan-MT로 번역합니다. 총 **약 2.83T 토큰, 22개 언어, 34개 언어·문자 조합**입니다(T1, 합계 2,825.6B 재계산 일치).
- **비용:** 번역 비용을 영어 입력 100만 토큰당 0.835 → 0.335 GPU-h로 줄였습니다(–59.9%, 2.49배).
- **결과(T2):** 5개 Indic 벤치마크가 모두 올랐습니다(+4.98 ~ +9.82%p). 다만 합성 데이터와 자연 데이터의 기여는 나누지 않았습니다(본문 명시).
- **혼합 비율(T3):** Lightning으로 200B 토큰 예산에서 Indic 10/20/30%를 비교하면 평균 63.1 / 64.6 / 65.6으로 단조 증가합니다. 공개된 Lightning에는 Indic 단계가 없습니다.

2.4 SWE 중간학습 (§2.5, T4-T5)

사전학습은 짧은 문맥이라 저장소 전체, 이슈-PR, 커밋 이력, 빌드 로그를 담기 어렵습니다. SFT는 대부분 합성 데이터이고, 너무 길면 이후 RL 이득을 줄입니다. 중간학습은 그 사이에서 **자연 SWE 데이터를 256K 문맥으로** 학습합니다.

혼합(T4)	비율
이슈-PR(저장소 맥락 + 병합 패치)	41%
저장소 전체(서로 import하는 파일을 붙여서)	20%
사전학습 재생	20%
에이전트 궤적(도구 응답은 loss mask)	10%
장문맥 데이터	5%
커밋 diff	3%
빌드·CI 로그	1%

효과는 같은 실험용 SFT(33B 토큰, 2K step)를 base와 중간학습 체크포인트에 각각 돌려 비교했습니다(T5). OpenHands 하네스에서는 차이가 ±1점(실행 간 변동 수준)입니다. 다른 5개 하네스에서는 SWE-bench Verified가 평균 **+8.6점**, Terminal-Bench 2.1이 평균 **+6.8점** 올랐습니다(재계산 8.56, 6.82). 가장 큰 개선은 Codex 하네스입니다(48.4 → 61.8). DeepSWE는 6.4 → 10.4입니다. 다시 말해 **중간학습의 주효과는 점수보다 하네스 간 강건성**입니다.

2.5 사후학습 파이프라인 (§3, F4)

```
Super 3.5 Base (텍스트 전용)
  │ vision projector warm-up
  ▼ SFT 2단계 (§3.1): 1단계 = 시각·추론·대화·장문맥·안전·에이전트 혼합, 2단계 = 부족한 능력 보강
  │   packing 524,288 토큰, GBS 32, LR 1e-5 고정, MTP 보조 loss 0.3
  ▼ RL (§3.2): RLVR + RLHF 동시, GBS 8,192 × rollout 16, 최대 생성 80K → 128K
  │   router replay, FP32 LM head (학습·추론 엔진 간 KL 오차를 10배 이상 줄임)
  ▼ step-120 체크포인트에서 교사들을 가지치기
  ├─ 에이전트 교사 (§3.3.1): Terminal·SWE·Search 샌드박스, GRPO 64 × 16, rollout당 최대 2시간
  ├─ 추론 교사 (§3.3.2): 25,600문항(과학 90%), 생성 131,072, 80 update
  ├─ 비디오 추론·추적 교사 (§3.4.1): Video-QA + SA-V 추적, 라우터·시각 모듈 동결, step 60
  ├─ 시각 도구 사용 교사 (§3.4.2), 시각 추론 RLVR (§3.4.3)
  └─ 정렬 교사 (§3.5): 길이 벌칙을 넣은 GenRM, 고정 참조 응답(Gemma 4 31B-it)과 비교
  ▼ MOPD 2단계 (§3.6)
  ▼ MTP boosting (§3.7, 본체 동결)
  = Nemotron 3.5 Super (BF16) → NVFP4 PTQ + QAD (§4)
```

- **SFT 데이터 출처(§3.1):** 시각 데이터는 Nemotron 3 Nano Omni 코퍼스에 Qwen3.5로 만든 데이터를 더했습니다. 시각 에이전트 데이터는 Kimi K2.6·K3로 만들었고(이미지 crop·회전·확대 도구, SpatialClaw 비디오 궤적 14,169개, 행동 81,366개), 추론 데이터는 Kimi K3(수학·STEM), DeepSeek V4 Pro(증명), GLM-5.2(경쟁 프로그래밍)가 교사입니다. **5,000 토큰보다 짧은 추론 응답은 버렸습니다.** Kimi K3 궤적은 여러 epoch에 걸쳐 계속 좋아졌다고 보고합니다(DeepSeek V4 Pro 궤적은 1 epoch에서 정체).
- **시각 에이전트 학습 효과(T7):** SpatialClaw 하네스 기준 공간·비디오 벤치마크 평균 50.5 → 54.8(+4.3)입니다.
- **추론 모드(§3.9):** off, regular, medium-effort 세 가지입니다. medium은 regular보다 토큰을 약 2.2배 적게 쓰고 정확도는 약 9% 낮습니다.

2.6 MOPD: 다중 교사 on-policy 증류 (§3.6, Eq. 1-2)

학생이 직접 생성한 응답의 각 토큰에서, 그 도메인을 맡은 교사의 확률과 학생 확률의 로그 차이를 advantage로 씁니다.

```
Δθ ∝ E_{y ~ π̃_S(·|q)} [ Σ_t Â_t ∇θ log π_S(y_t | c_t) ]                    (Eq. 1)
Â_t = sg[ log π_T(y_t | c_t) − log π̃_S(y_t | c_t) ]                          (Eq. 2)
```

- 이것은 학생 분포에서 본 **reverse KL D(π_S ‖ π_T)를 토큰 단위로 최소화**하는 것과 같습니다. verifier도 교사 샘플링도 필요 없고, 교사 forward 한 번이면 모든 토큰에 dense 신호가 생깁니다. 학생과 교사가 같은 곳에서는 신호가 0입니다.
- 비동기 학습이라 한 step 늦은 응답은 $\tilde{\pi}_S/\tilde{\pi}_{S-1}$로 중요도 가중하고 [0.2, 5] 밖은 마스크합니다.
- **도메인 라우팅:** 각 프롬프트는 해당 교사로 가고, 교사가 없는 환경은 **self-anchor**(학생 시작점의 동결 복사본)로 보냅니다. self-anchor는 학생이 시작점에서 멀어질 때만 신호를 줍니다.
- **1단계**(30 step): 에이전트 35%, 추론 25%, 정렬 20%, 시각 도구 15%, self-anchor 5%. 512 프롬프트 × rollout 1, LR 2e-6.
- **2단계**(40 step): 에이전트·추론 교사는 은퇴시키고 그 환경을 self-anchor로 돌립니다. 정렬 30%, 시각 도구 20%, 시각 추론 20%, 비디오 20%, self-anchor 10%. 1,024 프롬프트, LR 3e-6. 빨리 오르고 나중에 떨어지는 도메인을 1단계에, 느리게 오르는 도메인을 2단계에 둔 배치입니다.
- **proximal teacher(2단계만):** 교사를 $\alpha\,\pi_T + (1-\alpha)\,\tilde{\pi}_S(\alpha = 0.2)$로 바꿉니다. 그러면 advantage가 아래에서 $\log(1-\alpha) \approx -0.223$으로 막혀, 교사가 매우 낮게 보는 토큰도 무한히 큰 음의 신호를 받지 않습니다(`03` §4에서 확인).
- **부수 효과(부록 B.1):** MOPD 전 체크포인트는 tau3-banking에서 rollout 776개 중 153개(19.7%)가 끝없이 반복하며 멈추지 못했습니다(runaway loop). MOPD 뒤에는 1개입니다. 이 차이가 NVFP4 양자화 강건성에도 이어집니다(§2.8).

2.7 MTP boosting (§3.7, T8-T9, F6)

본체를 동결하고 MTP 헤드만 두 번 학습합니다. SFT 체크포인트에서 4k step을 먼저 학습하고, 최종 체크포인트에서 25k step을 더 학습합니다. hidden-state mixing을 유지하고, loss를 CE 대신 **동결 본체를 교사로 한 증류(LK loss)**로 바꿨습니다. 데이터는 본체가 temp 1로 생성한 on-policy rollout(8K 토큰 상한)입니다.

draft 길이 7, SPEED-Bench	greedy AL	sampling AL
최종 체크포인트, 원래 MTP	4.287	3.787
+ SFT 단계 MTP 헤드 이식	4.528	4.436
+ 25k boosting	**4.718** (+10.1%)	**4.612** (+21.8%)

깊은 draft 위치일수록 개선이 큽니다(F6). 다만 T9에서 boosting 후 Super의 greedy AL 평균 4.718은 Gemma-4 31B(4.837)와 Qwen3.5 122B(4.799)보다 낮습니다. sampling AL 4.612는 가장 높습니다.

2.8 양자화 (§4, T12-T23, 부록 B)

목표: 중앙값 정확도 복원율 99% 이상, 출력 길이 증가 5% 이하. Super VL NVFP4는 Blackwell에서 W4A4, 그 밖에서는 W4A16으로 배포하고, Lightning은 어디서나 W4A16입니다.

모듈 (T12)	공개 레시피(Aggressive)
C-RADIO, VL connector, 임베딩, Mamba conv	BF16
routed + shared expert GEMM	**NVFP4**
latent down/up projection	BF16
attention QKV·out, Mamba linear, lm_head	FP8
KV cache, BMM	FP8
Mamba SSM cache	**FP16 + stochastic rounding**
전체 BPE	**4.82** (S = 74.987 GB, N = 124.453B)

- **PTQ(§4.2):** ModelOpt로 이미지-텍스트 SFT 데이터 1,024개를 보정에 썼습니다. 블록 scale은 MSE 탐색이 Max보다 낫습니다(T13 복원율 100.06% vs 98.58%).
- **AutoQuant(§4.3, Eq. 3):** 민감도(양자화 오차 × task-loss 기울기^2) 합을 평균 비트 제약 아래 최소화합니다. lm_head가 NVFP4 민감도의 거의 절반이고, attention·Mamba projection이 다음이며, expert는 상대적으로 강건합니다.
- **QAD(§4.4):** PTQ 학생에서 시작해 양자화된 GEMM 가중치만 KL로 학습합니다. 100% SFT 데이터로 200 iteration이 가장 좋았고, RL rollout을 섞은 효과는 작았습니다. 100 iteration에 GB200 512장으로 약 2시간(1,024 GPU-h)입니다.
- **KV cache(§4.5, T18):** NVFP4 KV(블록 16개당 FP8 scale, 원소당 4.5비트)는 FP8 대비 저장량이 43.75% 적습니다. 복원율은 NVFP4 KV 99.36%, FP8 KV 99.52%로 비슷했습니다. 그래도 공개 체크포인트는 소프트웨어 성숙도 때문에 FP8 KV를 기본으로 씁니다.
- **어디가 민감한가(§4.6, 부록 B):** 정확도 손실은 주로 **expert 가중치**에서 나옵니다. FP4로 양자화하면 멈출지 계속할지의 경계(stop-vs-continue margin)가 흔들리고, 원래 불안정하던 모델에서 runaway loop가 늘어납니다. MOPD 전 모델에서 expert를 FP8로 올리면 runaway가 28.2% → 17.9%로 줄었습니다. Mamba out_proj를 FP4로 만들면 출력이 길어지고, lm_head는 FP4에서도 정확도는 같지만 종료 판단이 흔들려 FP8 이상을 권합니다. 장문맥 구분 과제(MRCR-128k)는 attention score 해상도에 민감합니다.
- **MTP 양자화(§4.7):** MTP expert를 NVFP4로 바꾸면 AL이 4.612 → 4.592입니다. MTP는 따로 양자화한 뒤 본체 체크포인트에 이어 붙였습니다(splice).

2.9 서빙 (§5)

- **작업 부하:** 20턴 에이전트 대리 부하(공유 prefix 51,200, 턴당 입력 2,048, 출력 1,024)에서 **사용자당 50 tok/s 이상**인 점 가운데 GPU당 처리량이 가장 높은 점을 고릅니다.
- **Mamba prefix caching(§5.3):** vLLM은 attention과 Mamba의 캐시 페이지 크기를 바이트로 맞춥니다. Mamba 상태 한 페이지가 attention KV 약 4K 토큰과 같으므로(`03` §2에서 정확히 4,096으로 재계산), Mamba 상태는 4K 토큰 간격으로만 저장됩니다. 투기적 디코딩과 함께 쓰면 최대 4K 토큰을 다시 계산해야 해서, 공유 prefix 경계 근처에 Mamba 체크포인트를 하나 더 두도록 바꿨습니다.
- **ReplaySSM(§5.4):** 투기적 디코딩은 몇 토큰이 채택될지 모르므로 후보 위치마다 Mamba 상태를 써야 합니다. 대신 체크포인트 상태와 이후 입력(k, v, α)만 작은 버퍼에 저장하고, 필요할 때 상태를 재구성합니다. 상태 쓰기를 버퍼 길이 L에 걸쳐 분할상환하므로 상태 트래픽이 T+1에서 약 1+1/L로 줄고, 양자화 횟수도 줄어듭니다. 측정 이득은 출력 처리량 +4.7-6.4%, 사용자당 +6.4-12.5%입니다(T24). Dao lab의 동시 발견과 같은 기법입니다.
- **분리 서빙(§5.6, T25):** Vera Rubin(VR200) 11장에서 prefill 7 + decode 4로 나누면 GPU당 처리량 +10.3%, 사용자당 속도 +61%입니다. TTFT는 0.49 → 1.12 s로 늘지만 5 s 목표 안입니다.
- **병렬 drafter(§5.7):** LiLiCorr는 블록 8칸(7개 draft)을 한 번에 제안하고, 칸마다 상위 K 후보 사이의 호환성을 작은 Transformer로 점수 매겨 왼쪽부터 고릅니다(Eq. 4-5). drafter는 1.13B(헤드 37M)이고, 동시 처리량이 낮은 DGX Spark 같은 환경이 목표입니다. AL은 greedy 4.77, sampling 4.37입니다(T28).

---

3. Experiments

3.1 사후학습 모델 평가 (T10, 27개 공통 텍스트 벤치마크 + 시각 11개)

영역	Super 3.5	Ultra 3	관찰
SWE-bench Pro	**51.78**	49.66	표의 7개 모델 중 5위. Qwen3.8 60.37, GLM-5.3 59.70
SWE-bench Verified	71.10	73.93	7개 중 **7위**
Terminal-Bench 2.1	60.67	54.78	Qwen3.8 85.80
Tau2 Telecom	73.19	83.00	7개 중 **7위**
BrowseComp	78.91	67.85	두 하네스 모두 Ultra보다 +11점
GraphWalks (≤1M)	**89.71**	63.28	7개 중 **1위** (유일한 1위)
AA-LCR	68.63	75.19	7개 중 7위
IFBench	70.86	82.94	−12.1
MMLU-ProX	76.91	83.10	7개 중 7위
NV Chat Benchmark	52.67	34.27	+18.4 (내부 벤치마크)
시각 11개		—	대부분 Qwen3.8·Qwen3.5보다 낮음(MathVision은 5개 중 5위). OCR-Reasoning, OCRBench-v2(EN), Video-MME-v2에서만 2위

- **Super vs Ultra:** 27개 공통 벤치마크에서 Super가 17개 우세, 10개 열세입니다. 평균 순위는 4.24/7입니다(`04` C6). "Ultra를 넘는다"는 초록의 표현은 SWE-bench Pro 한 줄에 대해서는 맞지만, Ultra가 확실히 나은 영역(장문맥 AA-LCR, 지시 따르기 IFBench, 다국어 MMLU-ProX, Tau2)도 분명합니다.

- **기준선 설정:** 기준 모델의 온도·top_p·최대 토큰은 각 모델 카드 권장값을 그대로 썼다고 밝힙니다(§3.8.1). 자체 측정이므로 공식 리더보드 값과 다를 수 있습니다.

3.2 Text Arena (T11)

Super NVFP4는 투표 2,328개(Ultra의 1/5)로 1420 ± 12입니다. 신뢰구간이 GLM-5.3(1474 ± 5)을 제외한 모든 모델과 겹칩니다. 보고서도 "preliminary"라고 적었습니다.

3.3 하네스 강건성과 테스트 시간 확장 (§3.10-3.11, F8-F9)

- **F8:** 하네스 6개의 기본 설정에서 SWE-bench Pro는 Claude Code 49.45%가 최고, OpenCode가 **41.04%로 최저**입니다. T10의 51.78%도 OpenCode 하네스 값인데 10.7%p 높습니다. F8은 Git 기록 제거와 부정행위 금지 지시를 명시하고, T10은 NeMo Gym 레시피를 씁니다. 이 차이를 보고서는 설명하지 않습니다(`04` C11).
- **F9 (병렬 에이전트 + 자기 검증):** 같은 체크포인트가 후보 3-5개를 만들고 LLM-as-a-Verifier(20단계 등급 토큰의 확률 가중 점수, 쌍 비교, pivot 토너먼트)로 하나를 고릅니다. Terminal-Bench 62.7 → 71.9, DeepSWE 24.6 → 34.5, BrowseComp(400문항 부분집합) 71.5 → 79.8입니다. SWE 3종은 +1.1-2.4%p로 작습니다.

3.4 양자화 결과 (T22, T23)

- Super NVFP4(T23, 37행): 표 전체 중앙값 99.70%이고, 보고값 99.62%는 36개 부분집합에서 나옵니다. 최저는 SciCode problem 93.58%, Tau3 Banking 94.17%, MMLU-ProX 95.90%입니다. 출력 길이는 +0.43%(보고 +0.44%)입니다.
- Lightning W4A16(T22): 중앙값 99.25%(보고 99.24%), 출력 길이 −3.63%, 최저 90.22%입니다.

3.5 서빙 성능 (F10-F11, T24-T25)

비교 (사용자당 ≥ 50 tok/s)	GB200	H100
NVFP4 / BF16 (F10)	4,324 / 1,778 = **2.43배**	970 / 522 = 1.86배
Super / Qwen3.5 122B (F11)	4,331.88 / 1,854.35 = **2.34배**	988.87 / 424.94 = 2.33배
Super / Qwen3.8 Flash-Next (F11)	4,331.88 / 2,282.73 = **1.90배**	988.87 / 752.95 = **1.31배**

- 초록의 4,856 tok/s/GPU는 T24의 최고점(동시 64, MTP 5, ReplaySSM 켬, 사용자당 89.9 tok/s)입니다. F10(4,324), F11(4,331.88)과는 설정이 달라 값이 다릅니다.
- 성능 모델 설명(§5.2): attention 층이 적고 KV 헤드가 2개뿐이라 요청당 메모리가 문맥과 함께 느리게 늘어납니다. 그만큼 한 번의 가중치 읽기를 더 많은 요청이 나눠 씁니다. LatentMoE는 expert 병렬 통신량도 줄입니다.
- **SWE-bench Pro 정확도-계산(F7):** B200 4장에서 2,193과제를 끝내는 데 Super NVFP4는 8.3 GPU-h, Qwen3.8 37.1, DeepSeek V4 Flash 40.4, Inkling Small 98.9 GPU-h입니다. 다만 정확도는 Super가 51.3%로 셋보다 5.2-9.1%p 낮습니다.

3.6 Base 모델 (T6)

Super 3.5 Base와 Lightning 3.5 Base만 비교하고, **출발점인 Nemotron 3 Super Base와의 비교는 없습니다.** 그래서 증류·Indic·중간학습이 base 능력을 얼마나 바꿨는지는 T2(Indic), T5(중간학습)로만 부분적으로 볼 수 있습니다. 두 모델의 GSM8K(91.74)와 PIQA(85.09)가 소수 둘째 자리까지 같습니다. Lightning의 GPQA Diamond 33.33%는 198문항 중 66문항으로, 4지선다 우연 수준(25%)에 가깝습니다.

---

4. Limitations

4.1 저자가 밝힌 한계

- Indic 단계의 이득에서 합성 데이터와 자연 데이터의 기여를 나누지 않았습니다(§2.3). Lightning 혼합 비율 실험은 Super의 최적 비율을 정하지 않습니다.
- 오염 제거 파이프라인은 저렴한 유사도 신호로 후보를 고른 뒤에만 judge가 판정하므로 재현율에 상한이 있습니다. 문제 문장만 보고, 합성 오염 실험은 대리 평가입니다(부록 C.6). 합성 변형 탐지율은 Terminal-Bench 87.5%, GPQA 79.1%입니다.
- 양자화 원인 분석(부록 B)은 추론에 기반한 귀속이고, MRCR-128k가 유일한 구분 과제이며, 모든 구성이 FP8 KV를 쓴다는 단서를 붙였습니다.
- 하네스에 따라 순위가 바뀌므로 하네스와 설정을 함께 보고해야 한다고 스스로 강조합니다(§3.10).

4.2 분석하며 본 한계

1. **구조 표가 없습니다.** 층 구성, expert 수, KV 헤드 같은 값은 config를 봐야 알 수 있습니다(`04` D5).
2. **같은 수치가 두 값으로 나옵니다.** NVFP4 복원율이 초록·§4.1에서는 99.62%, §4.5·결론에서는 99.52%입니다. 처리량도 4,856 / 4,324 / 4,331.88로 세 값입니다(`04` C1, C8).
3. **헤드라인 SWE-bench Pro 수치는 프로토콜에 민감합니다.** 같은 OpenCode 하네스인데 T10 51.78%, F8 41.04%입니다. F8의 최고값 49.45%는 T10의 Ultra 49.66%보다 낮습니다(`04` C11).
4. **불확실성 표시가 거의 없습니다.** T10은 3-8회 평균이지만 표준편차나 신뢰구간이 없습니다. 벤치마크마다 1-2점 차이는 실행 간 변동(§2.5에서 "약 1점")과 구분하기 어렵습니다.
5. **MOPD와 교사 각각의 기여를 분리한 ablation이 없습니다.** 비디오 교사 같은 개별 교사 점수(§3.4.1)만 있고, 최종 모델 점수가 어느 단계에서 왔는지 보여 주는 단계별 표가 없습니다.
6. **블로그에만 있는 주장이 많습니다.** "5배 처리량", "Dynamo로 8배 사용자·TTFT 85% 감소", "LiLiCorr 2.3배", "Baseten 600 TPS", "사후학습 약 3.8M 샘플"은 보고서에서 확인되지 않습니다. 3.8M은 보고서의 오염 제거 수치(20,671개 = 약 0.09%)에서 역산한 약 23M과 맞지 않습니다(`04` C5, C10).
7. **로봇·embodied 평가가 없습니다.** 시각 평가는 문서·차트·OCR·비디오 QA·GUI(OSWorld) 중심입니다. 공간 추론(ERQA 등)은 SpatialClaw 하네스 효과(T7)로만 나옵니다. 로봇 VLA 백본으로 쓸 수 있는지는 이 보고서로 판단할 수 없습니다.

03. 수치 해부와 메커니즘 확인

모든 계산은 CPU, 단일 스레드 numpy로 했습니다. 구조 수치는 `analysis/param_check.py`(공개 config와 safetensors 헤더), 표 수치는 `analysis/table_check.py`, 메커니즘 toy는 `analysis/mechanism_toy.py`에서 나옵니다. 가중치는 받지 않았습니다.

1. "120B-A12B"의 해부

1.1 전체와 활성

구분	파라미터	비고
전체	**124.45B**	보고서 BPE 식의 N = 124.453B와 일치 (§4.1)
LLM (MTP·시각 제외)	120.67B	이름의 "120B"
MTP / 시각 / projector	2.94B / 0.65B / 0.19B	
routed expert	112.74B (전체의 90.6%)	40층 × 512개 × (1024 × 2688 × 2)
토큰당 활성 (임베딩 제외)	**12.23B**	이름의 "A12B". 임베딩 포함 12.77B

활성 12.23B를 모듈별로 나누면 다음과 같습니다.

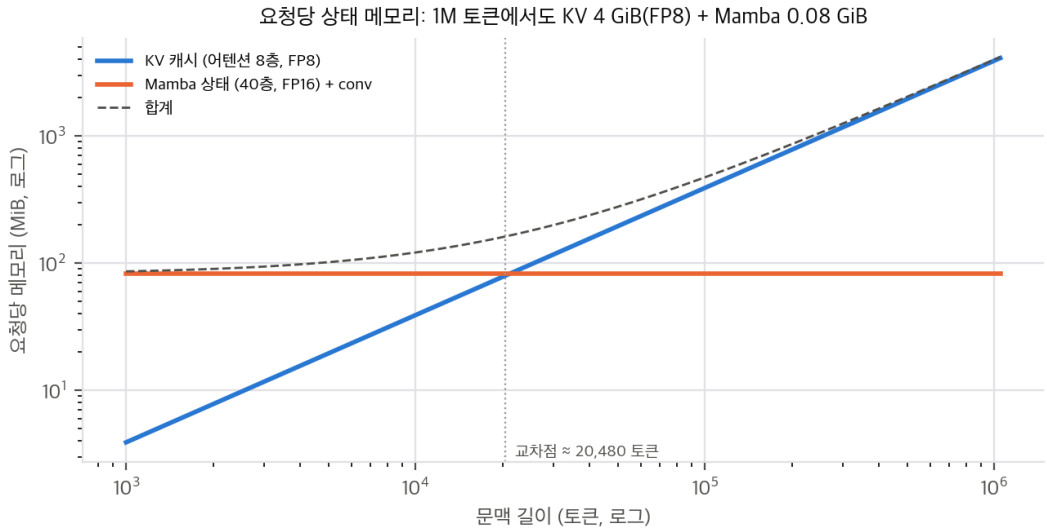
모듈	활성 (B)	비율	공개 NVFP4 레시피의 정밀도
routed expert (top-22)	4.84	39.6%	NVFP4
Mamba in/out projection	**4.38**	**35.8%**	FP8
shared expert	1.76	14.4%	NVFP4
lm_head	0.54	4.4%	FP8
latent projection + 라우터	0.42	3.4%	BF16
attention QKVO	0.29	2.3%	FP8

해석. 전체 파라미터의 90%가 routed expert지만, 토큰 하나가 실제로 지나가는 가중치에서는 **Mamba projection이 routed expert만큼 큽니다.** attention은 2%에 불과합니다. NVFP4가 적용되는 부분(expert)은 활성 가중치의 54%뿐이고, 나머지 43%는 FP8입니다. 그래서 FP8 Mamba projection의 정밀도와 커널 성능이 decode 속도에 크게 작용합니다. 보고서가 Mamba out_proj의 FP4 민감도를 따로 분석한 이유(§4.6, 부록 B.4)와도 맞습니다.

1.2 배치 1 decode의 대역폭 상한

배치 1에서는 토큰마다 활성 가중치를 한 번씩 읽어야 합니다. 공개 레시피(expert 4.5비트, FP8 3종, BF16 latent)로 계산하면 **토큰당 9.76 GB**입니다. 메모리 대역폭이 273 GB/s인 DGX Spark(이 맥의 M4 Pro도 같은 273 GB/s)에서는 투기적 디코딩 없이 **최대 약 28 tok/s**입니다. 사용자당 50 tok/s 목표에 못 미칩니다. NVFP4 모델 카드가 DGX Spark에 LiLiCorr drafter(7토큰)를 "모든 경우에" 권하는 이유가 이 계산으로 설명됩니다. KV·상태 읽기를 빼고 계산했으므로 실제 값은 더 낮습니다.

2. 요청당 상태 메모리: KV는 늘고 Mamba 상태는 고정



공개 config.json으로 계산(analysis/param_check.py). MTP의 어텐션 1층과 시각 토큰은 제외.

우리 분석: 공개 config로 계산한 요청당 메모리. KV(attention 8층, FP8)는 문맥에 비례하고, Mamba 상태(40층, FP16)는 고정이다.

항목	값	계산
KV / 토큰	BF16 8,192 B, **FP8 4,096 B**, NVFP4 2,304 B	8층 × (K, V) × KV 헤드 2 × 128
1M 토큰 KV	FP8 **4.0 GiB**, NVFP4 2.25 GiB	
Mamba SSM 상태 / 요청	FP32 160 MiB, **FP16 80 MiB**	40층 × 128헤드 × 64 × 128
conv 상태 / 요청	2.34 MiB	
교차점	**20,480 토큰**	FP16 상태 = FP8 KV가 되는 문맥 길이
Mamba 캐시 한 페이지	**4,096 토큰분 KV**	한 층 상태 2 MiB ÷ 한 층 KV 512 B/토큰. 보고서 "약 4K"(§5.3)와 일치

해석.

- KV 헤드가 2개뿐이고 attention이 8층뿐이라, 1M 토큰에서도 KV가 4 GiB입니다. 51K prefix + 20턴(약 112K 토큰) 부하에서 KV는 요청당 약 0.44 GiB이고, Mamba 상태 80 MiB와 같은 자릿수입니다. 보고서가 Qwen3.5·Qwen3.8보다 처리량이 높은 이유로 든 "요청당 메모리가 느리게 증가"(§5.2)의 구체적 크기가 이 정도입니다.
- 반대로 문맥이 2만 토큰보다 짧으면 **Mamba 상태가 KV보다 큽니다.** 짧은 요청이 많은 서빙에서는 상태 메모리가 동시 처리 수를 제한합니다. FP16 + stochastic rounding으로 상태를 반으로 줄인 것(T12)이 이 영역에서 의미가 있습니다.
- prefix caching이 Mamba 상태를 4,096 토큰 간격으로만 저장하는 이유도 바이트 맞춤에서 바로 나옵니다. 투기적 디코딩과 함께 쓰면 최악의 경우 4K 토큰을 다시 계산하므로, 보고서가 경계 근처에 체크포인트를 하나 더 두는 수정을 했습니다(§5.3).

3. ReplaySSM: 닫힌 식, 트래픽, 양자화 오차 (§5.4)

3.1 닫힌 식의 지수

보고서는 decode 갱신을 S_new = α S_old + $k^{\top}v$로 적고, 체크포인트에서 재구성하는 식을 `S = (∏ α_i) S_ckpt + Σ_i (∏_{j>i+1} α_j) k_i^⊤ v_i`로 적었습니다(47쪽). 같은 문단의 갱신식을 펼치면 i번째 입력은 그 뒤의 감쇠 α_{i+1}, ⋯, α_n을 모두 받으므로 곱의 범위는 **j > i**여야 합니다. numpy로 16토큰을 펼쳐 보면 다음과 같습니다.

곱의 범위	순차 갱신 대비 상대 오차
Π_{j>i}	3.3×10^{-16} (정확)
Π_{j>i+1} (본문 표기)	4.7×10^{-3}

감쇠가 1에 가까워 오차는 작지만, 본문 표기는 지수가 하나 어긋난 것으로 보입니다. 다른 색인 규약(α_i를 i번째 입력 전에 적용)을 썼을 가능성도 있지만 본문에 그런 정의는 없습니다(`04` D10).

3.2 상태 트래픽

공개 config 크기로 decode 한 단계, 요청 하나, Mamba 층 하나의 상태 관련 트래픽을 셌습니다. 상태는 1,048,576원소이고, 버퍼에 넣는 입력(x, B, dt)은 토큰당 9,344원소(상태의 0.89%)입니다. 버퍼 길이 L = 16(T24 설정)을 썼습니다.

draft 길이 T	기존 (상태 단위)	ReplaySSM	감소
1	2.00	1.14	1.75배
3	4.00	1.16	3.45배
5 (T24)	6.00	1.18	**5.09배**
7	8.00	1.20	6.69배

상태 트래픽은 MTP 5에서 약 5배 줄지만, 측정된 처리량 이득은 4.7-6.4%입니다(T24). 이 차이는 해당 운영점에서 decode 시간의 대부분이 가중치·KV 읽기와 expert 통신이고, Mamba 상태 쓰기는 작은 몫이라는 뜻으로 읽힙니다. 사용자당 속도 이득(최대 12.5%)이 더 큰 것은 메모리가 남아 배치와 draft 길이를 더 키울 수 있었기 때문일 가능성이 있습니다(보고서의 "enables larger batch sizes"). 둘 다 추정이며, 보고서는 단계 시간을 분해해 보여 주지 않습니다.

3.3 FP16 상태의 반올림 오차

상태를 FP16으로 저장할 때 매 토큰 반올림하는 경우와, ReplaySSM처럼 L = 16 토큰마다 한 번만 반올림하는 경우를 비교했습니다. 헤드 4개, 4,096토큰, iid 가우시안 입력, FP64 기준입니다.

상태 저장	출력 상대 오차, 빠른 헤드 (−log α ∈ [0.01, 0.05])	느린 헤드 (−log α ∈ [2e-5, 2e-4])
FP16 RN, 매 토큰	8.4×10^{-4}	6.1×10^{-3}
FP16 SR, 매 토큰	1.19×10^{-3}	8.5×10^{-3}
ReplaySSM L = 16 + RN	**2.1×10^{-4}**	**1.5×10^{-3}**
ReplaySSM L = 16 + SR	2.9×10^{-4}	2.1×10^{-3}

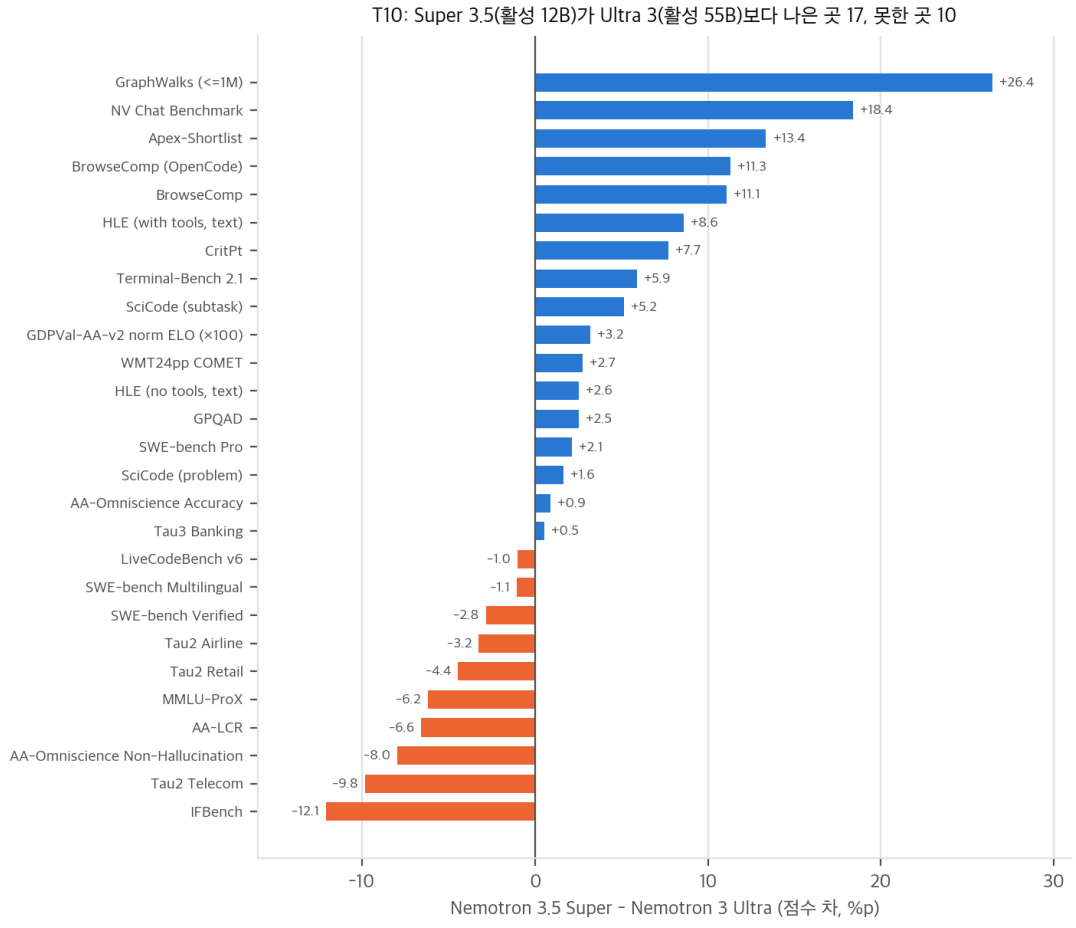
- **"덜 자주 양자화해서 오차를 줄인다"는 주장은 toy에서 성립합니다.** 오차가 3.5-4배 줄었고, 반올림 횟수가 1/16이 되면 랜덤 워크 오차가 √16 = 4배 줄어드는 것과 맞습니다.

- **stochastic rounding(SR)의 이점은 이 toy에서 보이지 않습니다.** iid 입력에서는 SR이 RN보다 오차가 약 1.4배 큽니다. SR의 장점(작은 갱신이 반올림에 묻히는 stagnation 방지, 기댓값 비편향)은 갱신이 반 ulp보다 작은 경우에만 드러납니다. 보고서는 FP16+SR을 채택했지만, RN과 직접 비교한 결과는 이 보고서에 없습니다. 근거는 선행 보고서(Super 3, Ultra 3)에 있을 수 있으나 확인하지 않았습니다.

4. MOPD advantage의 성질 (§3.6, Eq. 1-2)

1. **reverse KL의 토큰 분해.** 학생 샘플 $y \sim \pi_S$에서 $\hat{A} = \log \pi_T(y) - \log \pi_S(y)$의 기댓값은 $-D_{KL}(\pi_S \| \pi_T)$입니다. 학생이 교사보다 확률을 과하게 준 토큰은 음의 신호, 덜 준 토큰은 양의 신호를 받습니다. 교사가 낮게 보는 영역을 학생이 피하게 만드는 mode-seeking 성질이라, 여러 교사의 서로 다른 모드를 평균해 흐리게 만드는 위험이 forward KL보다 작습니다.
2. **proximal teacher의 하한.** 교사를 $\alpha\,\pi_T + (1-\alpha)\,\tilde{\pi}_S$로 바꾸면 $\hat{A} = \log(\alpha\,\pi_T/\tilde{\pi}_S + 1 - \alpha) \geq \log(1-\alpha)$입니다. $\alpha = 0.2$에서 $\log 0.8 = -0.2231$입니다. 어휘 4,096, Dirichlet 분포 200쌍으로 확인한 최솟값은 −0.22314로 하한과 같았습니다. 같은 toy에서 $KL(\pi_S \| \pi_T)$의 중앙값 8.8이 $KL(\pi_S \| \text{mix})$에서는 0.17로 줄었습니다. 2단계는 **신호를 크게 줄인 trust-region 식 갱신**이고, 1단계에서 이미 교사를 흡수한 학생이 다시 크게 흔들리지 않게 하려는 장치로 읽힙니다.
3. **self-anchor는 KL 정규화입니다.** 교사가 없는 환경의 프롬프트를 학생 시작점 복사본으로 보내면, 그 도메인에서는 $D(\pi_S \| \pi_{start})$를 줄이는 신호만 생깁니다. 2단계에서 에이전트·추론 교사를 은퇴시키고 그 환경을 self-anchor로 돌린 것(§3.6)은 "이미 배운 능력을 잊지 않게 묶어 두기"입니다.

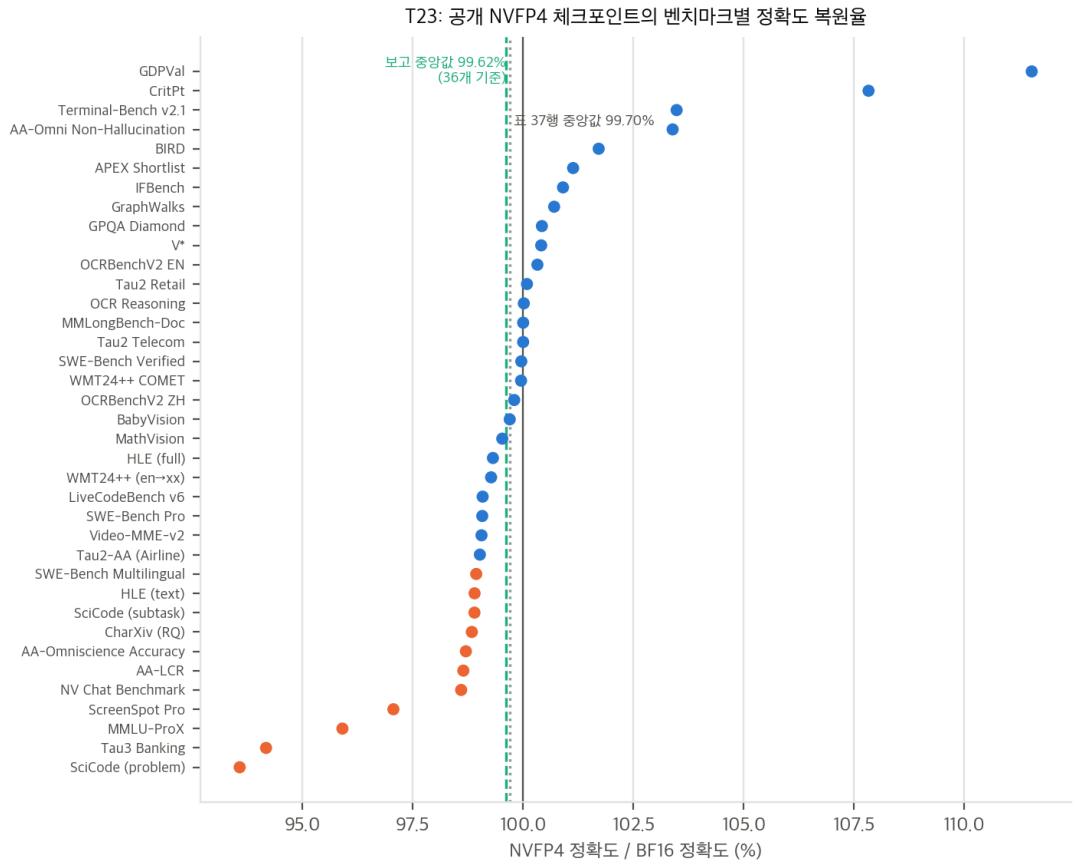
5. 벤치마크 주장 다시 읽기



출처: 보고서 Table 10. 파랑 = Super가 높음, 주황 = Ultra가 높음. 시각 벤치마크는 Ultra 값이 없어 제외.

우리 분석: T10의 27개 공통 벤치마크에서 Super 3.5 − Ultra 3 점수 차.

- **"Ultra를 넘는다"의 범위.** 활성 12B 모델이 활성 55B 모델을 27개 중 17개에서 앞서는 것은 분명한 성과입니다. 그러나 Ultra가 크게 앞서는 곳(IFBench –12.1, Tau2 Telecom –9.8, AA-Omniscience 비환각 –8.0, AA-LCR –6.6, MMLU-ProX –6.2)은 지시 따르기, 대화형 도구 사용, 장문맥 이해, 다국어처럼 모델 용량이 필요한 영역입니다. 반대로 크게 앞서는 곳(GraphWalks +26.4, NV Chat +18.4, Apex +13.4, BrowseComp +11)은 3.5에서 새로 넣은 데이터(그래프 구조 장문맥, 정렬 교사, 추론 교사, 검색 에이전트)와 바로 연결됩니다. **용량보다 데이터·교사 설계가 이긴 영역**과 그렇지 않은 영역이 갈립니다.
- **SWE-bench Pro 헤드라인.** 같은 OpenCode 하네스인데 T10은 51.78%, F8은 41.04%입니다. F8의 6개 하네스 평균은 46.54%이고 최고값은 49.45%입니다. NeMo Gym 레시피(고정 커밋 `1e66890`)도 HEAD 조상 밖의 Git 기록을 지우고 부정행위 금지 문구를 넣으므로, "미래 커밋 유출" 같은 단순한 설명은 맞지 않습니다. 차이의 원인은 하네스 프롬프트(Gym 자체 vs 하네스 기본), OpenCode 버전(v1.17.11 vs v1.17.8), 조상 기록 제거 여부, 반복 횟수 중 하나 이상입니다. 보고서는 이 차이를 설명하지 않습니다(`04` C11).

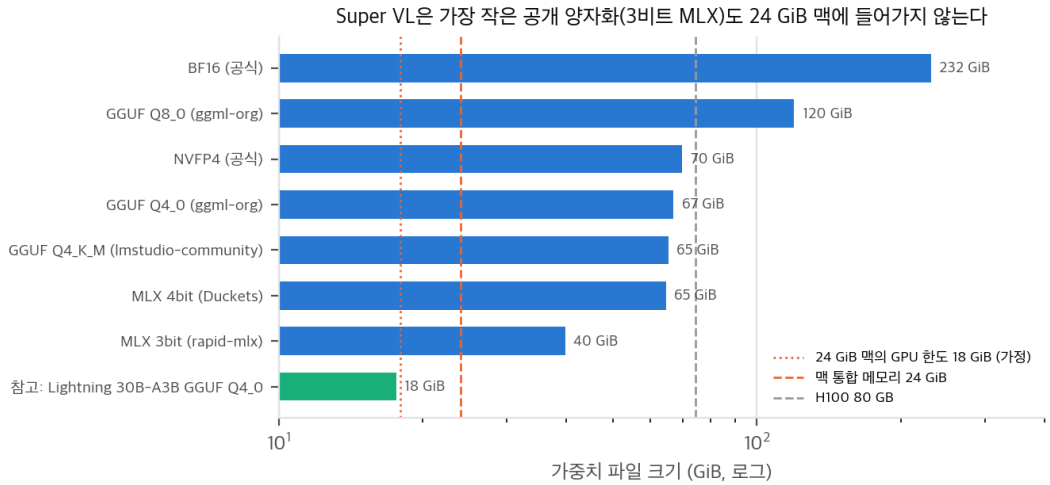


출처: 보고서 Table 23(FP8 KV 캐시). 주황 = 99% 미만. 중앙값은 높지만 최저 93.6%(SciCode problem), 94.2%(Tau3 Banking).

우리 분석: T23의 벤치마크별 NVFP4/BF16 정확도 비율. 보고 중앙값 99.62%는 36개 기준이고, 표의 37행 전체 중앙값은 99.70%다.

- **양자화 복원율은 중앙값보다 꼬리를 봐야 합니다.** 중앙값은 99.6-99.7%이지만 SciCode problem(93.6%), Tau3 Banking(94.2%), MMLU-ProX(95.9%)는 4-6% 떨어집니다. 셋 다 긴 다단계 추론이나 다국어 지식이 필요한 과제이고, 부록 B의 "FP4 expert가 종료 판단을 흔든다"는 분석과 방향이 같습니다. 같은 공개 구성의 복원율이 99.62%(36개, 초록)와 99.52%(35개, §4.5·결론) 두 값으로 나오는 것도 기준 집합 차이입니다.
- **테스트 시간 선택의 이득은 과제마다 다릅니다.** 후보 5개인 Terminal-Bench·DeepSWE는 +9-10%p, 후보 3개인 SWE 3종은 +1-2%p입니다. 후보 수와 과제 분산 중 어느 쪽 효과인지는 분리되지 않았습니다.

6. 이 맥에서 돌릴 수 있는가 (요약, 자세한 판단은 `04` §4)



크기: Hugging Face API(2026-10-30). 시각 모듈(mmproj)·MTP 별도 파일 제외. 초록 = 같은 계열 Lightning 30B-A3B(텍스트 전용).

우리 분석: 공개 체크포인트·양자화 파일 크기와 이 맥의 메모리. 가장 작은 공개 양자화(MLX 3비트, 39.8 GiB)도 들어가지 않는다.

- 가중치만 18 GiB(Metal 기본 한도로 가정)에 넣으려면 **파라미터당 1.24비트** 이하가 필요합니다. 공개된 가장 작은 양자화는 MLX 3비트 39.8 GiB입니다. Super VL은 이 맥에서 어떤 공개 형식으로도 돌릴 수 없습니다.
- 같은 세대의 Lightning 30B-A3B(텍스트 전용)는 GGUF Q4_0 17.6 GiB라 한도에 겨우 들어갑니다. 문맥과 KV를 넣을 여유는 거의 없습니다.

추가 검증 (2026-11-12)

목적

논문 §4.2(PTQ)는 블록 scale을 MSE로 고르면 Max보다 정확도가 높다고 보고합니다(보고서 Table 13, 복원율 100.06% 대 98.58%). 이 검증은 그 방향이 **가중치 오차**에서도 보이는지, 그리고 MSE 선택이 큰 원소에 어떤 대가를 치르는지 봅니다. 정확도 자체는 측정하지 않았습니다.

데이터와 받은 양

- 대상: `nvidia/NVIDIA-Nemotron-3.5-Super-VL-120B-A12B-BF16` 의 `model-00009-of-00063.safetensors` (3,980,237,344 B, 공개·게이트 없음, 리비전 `fb0ee0b`). 라이선스는 OpenMDW-1.1입니다(모델 카드의 "Governing Download Terms").
- 받은 양: **132.2 MB**(헤더 105 KB와 expert 텐서 24개). 파일의 3.3%이고, 전체 파일은 받지 않았습니다.
- 디스크 쓰기: 0 B. 바이트는 메모리에서 텐서 하나씩 디코딩하고 버렸습니다.
- 무결성: 서버가 준 파일 sha256(X-Linked-ETag)은 `24c0c91e…08b7bc` 입니다. 전체 파일을 받지 않아서 로컬에서 대조하지는 못했고, 받은 각 range의 sha256은 결과 JSON에 기록했습니다.
- 선택한 텐서: layer 12 routed expert 12개(expert 번호 121-331, 간격 약 19)의 `up_proj` (2688×1024)와 `down_proj` (1024×2688), 총 24개입니다. 이 shard에는 layer 12의 expert 일부(up 391개, down 332개)만 들어 있어서 층 간 비교는 할 수 없습니다.

설정

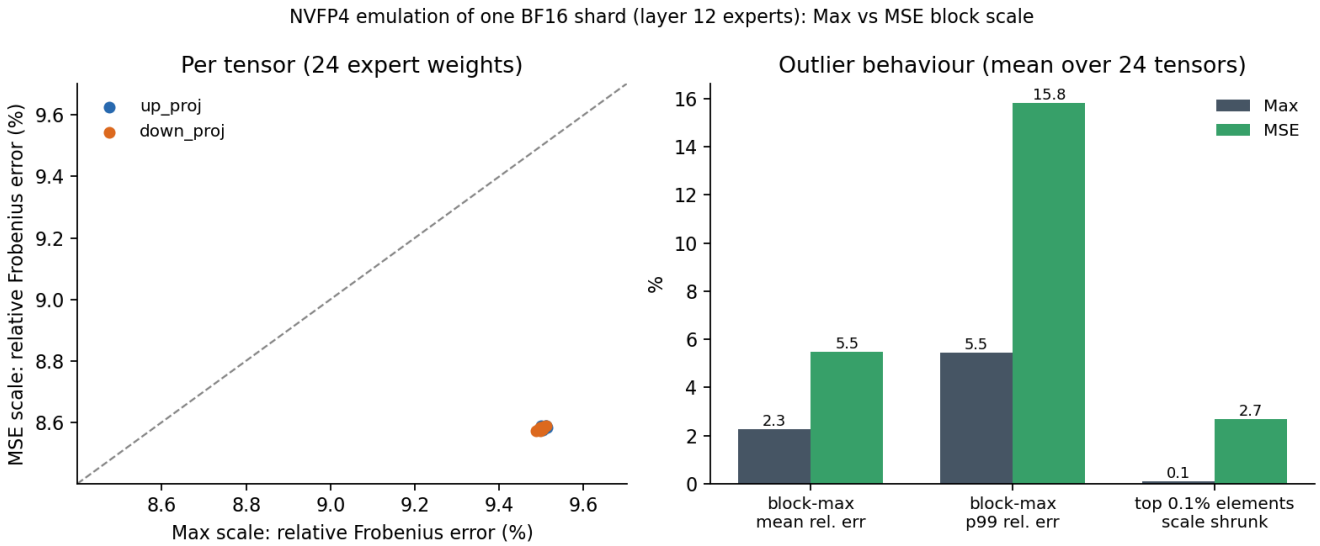
- 형식: NVFP4 에뮬레이션입니다. 값은 E2M1(±0, 0.5, 1, 1.5, 2, 3, 4, 6), 블록은 16원소(입력 축 방향), 블록 scale은 FP8 E4M3, 텐서 scale은 FP32이며 `absmax / (6·448)` 입니다.

- Max: 블록 scale을 `absmax_block / (6·g)`를 E4M3로 반올림한 값으로 정합니다.
- MSE: Max scale 근처 E4M3 값 31개(Max scale의 0.5-1.25배)를 훑어 블록 오차 제곱합이 가장 작은 값을 고릅니다. Max 후보를 포함하므로 블록 오차는 Max보다 클 수 없고, 스크립트가 이를 확인합니다.
- 지표: 상대 Frobenius 오차, SQNR, 블록 최댓값 원소의 상대 오차(평균, p99), 상위 0.1% 원소의 상대 오차와 scale이 0.9배 이하로 줄어든 비율입니다.
- 스크립트: `analysis/extra_nvfp4_scale.py`, 결과: `analysis/extra_nvfp4_scale_results.json` (실행 시간 128 s). 그림: `report/figures/extra_nvfp4_scale.png`.

결과

지표(24개 텐서 평균)	Max	MSE
상대 Frobenius 오차	9.50%	**8.58%** (평균 9.7% 감소)
SQNR	20.44 dB	21.33 dB
블록 최댓값 원소의 평균 상대 오차	2.3%	5.5%
블록 최댓값 원소의 상대 오차 p99	5.5%	15.8%
상위 0.1% 원소의 평균 상대 오차	2.7%	3.8%
상위 0.1% 원소 중 scale이 0.9배 이하로 줄어든 비율	0.09%	2.7%

- MSE가 오차를 줄인 텐서는 24/24입니다(Wilcoxon 단측 정확 검정 $p = 6\times10^{-8}$).
- MSE가 Max보다 작은 scale을 고른 블록은 31.6%입니다. 블록 오차가 실제로 줄어든 블록은 52.5%입니다.
- up_proj와 down_proj의 차이는 0.1%p 이하입니다. expert 사이 표준편차는 0.006%p 이하입니다. 이 12개 expert에서는 편차가 작았습니다.
- 블록 안 최댓값/RMS 중앙값은 2.07입니다. 블록 안에 극단적인 원소가 드문 분포입니다.



우리 에뮬레이션: 한 shard의 expert 24개. 왼쪽은 텐서별 상대 오차, 오른쪽은 블록 최댓값과 상위 0.1% 원소의 오차입니다.

결론

- 가중치 오차에서도 MSE scale이 Max보다 전체 오차를 줄입니다(24/24). 보고서 Table 13의 방향과 같습니다. 다만 이것은 가중치 공간의 근거일 뿐이고, 정확도 회복을 확인한 것은 아닙니다.
- 이득의 대가는 큰 원소입니다. MSE는 큰 원소의 scale을 줄여 나머지 원소의 반올림 오차를 줄입니다. 그 결과 블록 최댓값의 오차는 약 2.4배, 상위 0.1%의 오차는 약 1.4배가 되었습니다. 이 shard에서는 블록 안 극단값이 드물어서 이 손해가 전체 오

차 감소를 뒤집지 않았습니다. 큰 활성과 짝을 이루는 모듈에서는 결과가 다를 수 있습니다.
- 01·03의 결론은 바뀌지 않습니다.

한계

- shard 하나, layer 12의 expert 12개(512개 중), 가중치 전용입니다. 층별·모듈별 차이는 보지 못했습니다.
- NumPy 에뮬레이션이며 GPU 커널이나 ModelOpt의 실제 보정 절차가 아닙니다. MSE 탐색은 E4M3 값을 31단계로 훑은 근사입니다.
- 가중치 오차를 최소화한 것이 최종 출력 오차(정확도)를 최소화하는지는 이 검증으로 알 수 없습니다.

추가 검증 (2026-11-13): Mamba 감쇠 실제 분포와 FP16 반올림 비교

목적

앞의 toy(§3.3)는 감쇠 α를 가정한 구간(빠른 헤드 −log α ∈ [0.01, 0.05], 느린 헤드 [2e-5, 2e-4])에서 돌렸습니다. 이 검증은 공개 가중치의 `A_log`와 `dt_bias`에서 얻은 실제 헤드별 감쇠로 같은 비교를 다시 해서, §3.3의 "SR의 이점은 이 toy에서 보이지 않는다"가 실제 분포에서도 맞는지 봅니다.

데이터와 받은 양

- 대상: `nvidia/NVIDIA-Nemotron-3.5-Super-VL-120B-A12B-BF16`, 리비전 `fb0ee0bc6b3f70342afd8d84cb80dbadbaa8a1fe`(짧게 `fb0ee0b`). 공개, 게이트 없음.
- 텐서: `language_model.backbone.layers.{L}.mixer.A_log`와 `…mixer.dt_bias`, 두 개씩 Mamba 층 40개 (L = 0, 2, 4, …, 86, `layers_block_type`의 mamba 항목). dtype BF16, shape [128] (층당 헤드 128개). 텐서는 80개이고, 층 하나당 샤드 하나에 두 텐서가 들어 있습니다 (샤드 40개, `paper/hf/bf16_index.json`으로 대응 확인).
- 받은 양: **3,922,128 B** = 샤드 40개의 헤더 3,901,648 B + 텐서 80개 20,480 B (각 256 B). 가중치 전체는 받지 않았습니다. 원자료 80개는 `data/mamba_decay_raw/` (gitignore)에 저장했고, 파싱은 저장된 바이트를 `python3 -I`로 읽었습니다. 각 텐서의 sha256과 샤드 헤더 sha256은 `analysis/extra_mamba_decay_results.json`에 있습니다. 서버 LFS 해시와는 대조하지 않았습니다.
- 감쇠 식: `−log α = exp(A_log) · softplus(dt_raw + dt_bias)`, α = exp(−(−log α)). 표준 Mamba-2 형태입니다. **모델 코드 파일은 로컬에 없어서 이 식을 저장소 코드와 대조하지 않았습니다.** `dt_raw`(입력 의존)는 가중치에 없어서 0(편향만)을 본선으로 하고, −2와 +2를 민감도로 봤습니다.
- 스크립트: `analysis/extra_mamba_decay.py` (받기 → 파싱 → 분포 → toy, 약 8분). 결과: `analysis/extra_mamba_decay_results.json`.

실제 감쇠 분포 (헤드 5,120개, 층 40 × 헤드 128)

설정	분위 10%	중앙값	90%	−log α < 2.4e-4	−log α > 0.1
dt_raw = 0 (본선)	0.0016	0.028	0.31	1.8% (90개)	27%
dt_raw = −2	0.0002	0.0041	0.062	10.7%	5.6%
dt_raw = +2	0.011	0.14	1.39	0.3%	56%

- `A_log`: 평균 −0.71, 표준편차 2.03, 범위 [−6.81, 8.81]. `dt_bias`: 평균 −2.82, 표준편차 2.45, 범위 [−11.69, 8.50].
- 본선에서 헤드 중 상당수(27%)는 한 토큰 만에 기억을 거의 잃습니다 (−log α > 0.1). 가장 큰 값은 1,500 이상이라 α가 0입니다. 느린 헤드(−log α < 2.4e-4)는 2%도 안 됩니다. dt_raw에 따라 분포가 크게 바뀌므로 실제 분포는 이 세 설정 사이 어딘가에 있습니다.

toy 결과 (헤드 64개, 4,096 토큰, 체크포인트 L = 16, iid 가우시안 입력, FP64 기준)

출력 상대 오차의 평균입니다. "SR 나쁨"은 SR이 RN보다 오차가 큰 헤드의 수입니다.

헤드 집합	FP16 RN 매 토큰	FP16 SR 매 토큰	Replay + RN	Replay + SR	SR이 RN보다 나쁜 헤드 (매 토큰 / Replay)
실제, 분위 샘플, dt_raw = 0	1.51e-3	2.13e-3	3.62e-4	5.13e-4	64/64 · 64/64
실제, 분위 샘플, dt_raw = −2	2.84e-3	3.99e-3	6.95e-4	9.83e-4	64/64 · 64/64
가정 구간, 빠른 헤드 (§3.3과 같은 범위)	1.04e-3	1.48e-3	2.59e-4	3.66e-4	64/64 · 64/64
가정 구간, 느린 헤드	6.13e-3	8.57e-3	1.52e-3	2.14e-3	64/64 · 64/64

실제 분포를 −log α 구간으로 나눈 결과 (구간당 헤드 32개):

−log α 구간	헤드 수 (전체)	FP16 RN	FP16 SR	Replay + RN	Replay + SR	SR / RN
< 2.4e-4 (느린)	90	6.10e-3	8.47e-3	1.50e-3	2.12e-3	1.39
2.4e-4 - 1e-2	1,673	2.78e-3	3.91e-3	6.92e-4	9.78e-4	1.41
≥ 1e-2 (빠른)	3,357	7.15e-4	1.01e-3	1.59e-4	2.26e-4	1.41

느린 구간의 최종 상태 상대 오차도 RN 8.9e-3, SR 1.21e-2로 같은 방향이었습니다.

질문에 대한 답

아니오. 실제 감쇠 분포에서도 SR의 이점은 보이지 않았습니다. 어떤 부분집합, 어떤 dt_raw에서도 SR의 출력 오차가 RN보다 작지 않았습니다. 가장 느린 헤드에서도 SR은 RN보다 약 1.4배 큽니다. 이는 §3.3의 iid 결과(약 1.4배)와 같습니다. 보고서가 FP16+SR을 택한 근거는 이 toy로 설명되지 않습니다.

- 반면 ReplaySSM의 체크포인트 효과(L = 16)는 실제 분포에서도 나타납니다. 세 구간 모두 매 토큰 RN 대비 오차가 약 4배 줄었습니다 (§3.3과 같은 방향).
- 다만 config의 `mamba_ssm_cache_dtype`은 `float32`입니다. 보고서의 FP16 상태는 이 설정과 다른 설계 가정입니다. 저장소 설정 기준의 상태 정밀도는 FP32이고, FP16 상태 비교는 그 가정 아래의 질문입니다.

한계

- `dt_raw`를 가정했습니다. 실제 입력 의존 `dt`의 분포는 모릅니다. 세 설정 모두에서 결론이 같았지만, 실제 분포가 다른 곳에 있을 가능성은 남습니다.
- 감쇠 식은 표준 Mamba-2 형태입니다. 모델 코드와 대조하지 않았습니다.
- 입력은 iid 가우시안입니다 (§3.3과 같음). 실제 k, v, q의 크기와 상관은 측정하지 않았습니다.
- 지표는 상대 출력 오차(FP64 대비)이고 작업 정확도가 아닙니다. 평균 오차에는 편향과 분산이 섞여 있습니다. SR의 장점은 편향 제거인데, 이 지표로는 편향을 따로 분리하지 못했습니다. 편향만 보려면 같은 헤드를 여러 번 돌려 부호 있는 평균 오차를 봐야 합니다. 이 검증에서는 하지 않았습니다.
- 헤드 64개는 분위 간격으로 골랐습니다 (구간당 32개). 전체 5,120개의 전수 계산은 하지 않았습니다.

04. 공개물 검증: 보고서 ↔ 공개 체크포인트·레시피 대조, 수치 재계산, 구현 가능성

- **대상:**
  - Hugging Face `nvidia/NVIDIA-Nemotron-3.5-Super-VL-120B-A12B-BF16` @ `fb0ee0b` (2026-10-22)와 `-NVFP4` @ `da5b265` (2026-10-23)의 `config.json`, `hf_quant_config.json`, safetensors 색인, 색인이 가리키는 64개 파일의 헤더(HTTP range 요청으로 헤더만 읽음, `analysis/fetch_hf_meta.py`), 모델 카드
  - cookbook `NVIDIA-NeMo/Nemotron` @ `99a7e45`, AutoModel 문서 `NVIDIA-NeMo/Automodel` @ `571df6d`
  - 평가 레시피 `NVIDIA-NeMo/Gym` `nemotron_recipes/super-3.5/` (레시피가 고정한 평가 커밋 `1e66890`)
- **범위:** 학습 코드 전체는 보지 않았습니다. 보고서가 학습 프레임워크(NeMo-RL, ModelOpt, Megatron)만 가리키고 이 모델의 학습 스크립트는 공개하지 않았기 때문입니다. 가중치는 받지 않았고, 모델 실행·API 호출도 하지 않았습니다.

1. 보고서 ↔ 공개물 매핑

보고서	공개물	일치 여부
120B total, 12B active	LLM 120.67B, 활성 12.23B(임베딩 제외)	✅ (`03` §1)
BPE 계산의 N = 124.453B	shard 헤더 합 124.453B	✅ 정확히 일치
512 routed expert, LatentMoE	`n_routed_experts 512`, top-22, latent 1024, expert 2688, shared 1	✅ top-k와 차원은 보고서에 없음(D5)
C-RADIO 시각 인코더	`vision_model` ViT-H/16, 32층, 폭 1280. cookbook은 C-RADIO v4-H로 명시	✅
MTP: 재귀 공유 헤드 1개, attention + MoE, lm_head 공유 (§4.7)	`language_model.mtp.layers.0`에 attention·MoE, 2.94B, 별도 lm_head 없음	✅
1M 문맥	`max_position_embeddings 1,048,576`	✅
T12 Aggressive 레시피	`hf_quant_config.json`: routed expert up/down 각 20,480개와 shared expert가 NVFP4. Mamba in/out, attention QKVO, lm_head가 FP8. 임베딩, conv1d, latent proj, 라우터, MTP attention, 시각·projector는 제외	✅ 모듈 단위로 정확히 일치
MTP expert NVFP4, MTP attention BF16 (§4.7)	MTP experts·shared expert NVFP4, MTP q/k/v/o 제외	✅
KV cache FP8	`kv_cache_quant_algo: FP8`	✅
Mamba SSM cache FP16 + SR	config `mamba_ssm_cache_dtype: float32`	⚠️ D1
권장 샘플링: 텍스트 temp 1.0, top_p 0.95	`generation_config.json` temp 1.0, top_p 0.95	✅ (시각용 0.6은 카드에만 있음)
평가 재현 레시피 (§3.8.1 각주 14)	Gym `super-3.5/`에 벤치마크 설정 22개, `reproducibility.md`	✅ 시각 8개와 NV Chat은 없음. 보고서도 "아직 공개 도구에 없음"이라고 밝힘

2. 불일치와 보고서에 적히지 않은 요소

#	내용	영향
D1	**SSM 상태 정밀도가 세 가지입니다.** 보고서 평가와 서빙은 FP16 + stochastic rounding입니다(T12, §4.5, §5.6). 공개 NVFP4 `config.json`의 기본값은 `float32`입니다. 모델 카드의 vLLM 명령은 `--mamba-ssm-cache-dtype float16 --enable-mamba-cache-stochastic-rounding`으로 덮어쓰고, SGLang 명령은 `--mamba-ssm-dtype bfloat16`(+SR)을 씁니다.	플래그 없이 띄우면 요청당 상태가 160 MiB로 두 배가 되어 동시 처리 수가 줄어듭니다. SGLang의 BF16 상태(가수 8비트)는 보고서가 검증한 FP16(가수 10비트)과 다르므로, SGLang 경로의 정확도는 보고서 수치로 보증되지 않습니다
D2	모델 카드는 SWE 중간학습을 **67B 토큰**, 보고서는 **65.4B 토큰**이라고 적었습니다(§1, §2.5). 혼합 비율(T4)은 같습니다. 카드 벤치마크 표의 CritPt는 Qwen3.8·GLM-5.3이 "—"인데 T10에는 15.70, 9.70이 있습니다.	사소하지만 카드와 보고서 중 어느 쪽이 최종인지 알 수 없습니다
D3	AutoModel 문서는 "120.7B 학습 가능(시각 동결, 99.31%), bf16 약 227 GB, 63 shard"라고 적었습니다. 실제 저장소는 전체 124.45B, 248.9 GB이고 색인이 가리키는 파일은 64개입니다.	문서 수치는 **MTP(2.94B)를 뺀 모델 기준**으로 계산하면 맞습니다(120.67 / 121.51 = 99.31%, 226.3 GiB). 64번째 파일은 RADIO의 `vision_model.summary_idxs`(int64 2개) 하나만 담은 `model-summary-idxs.safetensors`라, 가중치 shard는 문서대로 63개입니다. 디스크 계획에는 248.9 GB를 써야 합니다
D4	NVFP4 색인의 `total_size`는 75.010 GB, 보고서의 S는 74.987 GB입니다.	0.03% 차이라 BPE는 둘 다 4.82입니다. 색인 메타데이터나 scale 텐서 집계 방식 차이로 보입니다
D5	**보고서에 구조 표가 없습니다.** 층 패턴, top-22, KV 헤드 2, Mamba 차원, 어휘 131,072는 config에서만 확인됩니다.	재구현·메모리 계획에는 config가 필수입니다. Super 3 보고서(2604.12374)에 있을 가능성이 있지만 확인하지 않았습니다
D6	**복원율 수치가 기준 집합마다 다릅니다.** T23은 37행이고 전체 중앙값이 99.70%입니다. 초록·§4.1의 99.62%는 "36개 벤치마크" 기준입니다. §4.5(T18)와 결론(§6)은 같은 공개 구성(FP8 KV)을 99.52%(35개)로 적었습니다.	숫자 자체보다 꼬리(93.6%, 94.2%, 95.9%)가 중요합니다(`03` §5)
D7	**공개 체크포인트의 KV 구성은 QAD가 겨냥한 구성이 아닙니다.** QAD 학생은 NVFP4 KV용 고정 scale(1/6)로 학습했고, 공개본은 KV scale 없이 FP8 KV를 씁니다(vLLM은 scale 1.0을 기본으로 씀).	보고서가 직접 밝힌 사실입니다(§4.5). NVFP4 KV를 쓰려면 원래 QAD 체크포인트가 필요한데, 공개되지 않았습니다
D8	MTP는 따로 양자화한 뒤 본체에 이어 붙였습니다(splice). 텐서 이름·모양·dtype이 정확히 같아야 합니다.	보고서가 밝힌 사실입니다(§4.7). 사용자가 본체만 다시 양자화하면 MTP를 같은 방식으로 다시 붙여야 합니다
D9	**블로그에만 있는 주장이 있습니다**(C10): 5배 처리량, Dynamo 8배 사용자·TTFT 85% 감소, LiLiCorr 2.3배, Baseten 600 TPS, Hermes Bench·LangChain Evals 점수, CharXiv Nano Omni 63%와 Python 도구 84%, 사후학습 약 3.8M 샘플.	보고서 수치(C1, C9)는 블로그보다 보수적입니다. 3.8M 샘플은 보고서의 오염 제거 비율로 역산한 약 23M과 맞지 않습니다
D10	ReplaySSM 재구성 식의 곱 범위가 본문에서는 $\Pi_{j>i+1}$이지만, 같은 문단의 갱신식에서 유도하면 $\Pi_{j>i}$입니다.	표기 오류로 보입니다. 구현은 TensorRT-LLM PR #14203에 있어 식 자체의 영향은 없습니다(`03` §3.1)
D11	**SWE-bench Pro 평가 프로토콜이 둘입니다.** T10(51.78%)은 Gym 레시피로 측정했습니다(OpenCode v1.17.11, 3회, `apply_anti_cheating=True`로 HEAD 조상 밖의 refs·reflog 삭제, 프롬프트에 부정행위 금지 규칙). F8은 하네스 기본 프롬프트, Git 기록 제거, OpenCode v1.17.8, 2회이고 41.04%입니다.	같은 하네스 이름으로 10.7%p 차이가 나는데 보고서는 설명하지 않습니다. 하네스 기본 설정에서는 6개 하네스 모두 Ultra의 T10 값(49.66%)보다 낮거나 같습니다

#	내용	영향
D12	T6에서 Super Base와 Lightning Base의 GSM8K(91.74)와 PIQA(85.09)가 소수 둘째 자리까지 같습니다.	복사 오류일 가능성이 있지만 검증할 방법이 없습니다

3. 수치 재계산 (`analysis/table_check.py`, `param_check.py`, `mechanism_toy.py`)

#	주장 (출처)	재계산	판정
C1	SWE-bench Pro 51.78 > Ultra 49.66, 활성 약 4.6배 적음 (초록)	+2.12%p, 55/12 = 4.58배	✅ (단 D11)
C1′	MTP boosting AL +21.8% (초록, T8)	greedy +10.05%, sampling +21.79%	✅
C1″	NVFP4 2.43배, Qwen3.5 2.34배, Qwen3.8 1.90배 (초록, F10-F11)	GB200 2.432 / 2.336 / 1.898. H100에서는 1.858 / 2.327 / **1.313**	✅ GB200 기준. H100에서 Qwen3.8 대비는 1.31배뿐
C1‴	4,856 tok/s/GPU (초록)	T24 최고점(동시 64, MTP 5, ReplaySSM 켬). F10은 4,324, F11은 4,331.88	✅ 설정이 다른 세 값
C2	Indic 최대 +9.82%p (T2), 2.83T 토큰 (T1)	T2 변화량 5개 모두 일치, T1 소계(2,273.8 / 224.6 / 327.2 = 2,825.6B) 일치, 번역 비용 −59.9%(2.49배)	✅
C3	중간학습: 다른 하네스 평균 SWE-V +8.6, TB +6.8 (§2.5)	8.56, 6.82. RULER-1M 79.9 → 33.5 → 81.0	✅
C4	테스트 시간 선택 +9.2 / +9.9 / +8.3%p (§3.11)	일치	✅
C5	오염 제거: 20,671개(약 0.09%), 30개 중 22개 벤치마크의 1,808문항(6.0%)	SFT 14,793 + RL 5,878 = 20,671. 0.085-0.095%로 역산하면 사후학습 표본 21.8-24.3M. 1,808 / 6.0% ≈ 30,133문항	✅ 내부 일관. 블로그 3.8M과 불일치(D9)
C6	Super가 Ultra를 넘음 (초록·결론)	T10 공통 27개 중 17승 10패, 평균 순위 4.24/7. 1위는 GraphWalks 하나. SWE-V·Tau2 Telecom·AA-LCR·MMLU-ProX는 7개 중 7위	⚠️ 부분적
C7	Text Arena (T11)	Super NVFP4 1420 ± 12의 구간이 GLM-5.3을 제외한 모든 모델과 겹침	구분 불가
C8	NVFP4 중앙값 복원율 99.62%, 길이 +0.44% (§4.1)	37행 전체 99.70%, 길이 +0.43%. 36개 부분집합이면 99.62%. 같은 구성의 다른 값 99.52%(§4.5, §6). Lightning 99.25%(보고 99.24%), 길이 −3.63%	✅ (D6)
C8′	BPE 4.82 = 8S/N (§4.1), NVFP4 KV 저장량 −43.75% (§4.5)	8 × 74.987 / 124.453 = 4.820, 색인 기준 4.822. 1 − 4.5/8 = 43.75%	✅
C9	ReplaySSM 이득 4.7-6.4% / 6.4-12.5% (T24), 분리 서빙 +10.3% / +61% (T25)	T24 다섯 행 재계산 범위 일치. T25 +10.3%, +61.4%, TTFT 2.29배 증가	✅
C10	블로그 주장	26T 토큰 = Super 3의 25T + 3.5 단계 1.209T(재구성 26.21T) ✅. F7 기준 GPU-h 4.5-4.9배 적음 ✅ 이지만 정확도 5-9%p 낮음. 5배·8배·2.3배·600 TPS·3.8M은 보고서에 없음	부분
C11	SWE-bench Pro 하네스 (F8 vs T10)	OpenCode 41.04 vs 51.78 (10.74%p). F8 평균 46.54, 최고 49.45 < Ultra 49.66	⚠️ D11

#	주장 (출처)	재계산	판정
V1	Mamba 페이지 ≈ 4K 토큰 KV (§5.3)	2 MiB / 512 B = **4,096**	✅
V2	ReplaySSM: 트래픽 T+1 → 약 1+1/L, 양자화 오차 감소 (§5.4)	T = 5, L = 16에서 6.00 → 1.18 (5.1배). FP16 반올림 오차 3.5-4배 감소	✅ (SR 이점은 toy에서 안 보임)
V3	proximal teacher 하한 log(1−α) ≈ −0.22 (§3.6)	toy 최솟값 −0.22314 = log 0.8	✅

4. 구현 가능성 판단 ("이 맥에서 돌릴 수 있는가, 고칠 수 있는가")

이 맥: Apple M4 Pro, 통합 메모리 24 GiB(GPU가 쓸 수 있는 양은 Metal 기본 한도인 약 18 GiB로 가정), 메모리 대역폭 273 GB/s, MPS 있음, **CUDA 없음**.

4.1 공개 모델로 추론하기

경로	요구 사항	이 맥
BF16 (공식, vLLM·SGLang)	4× H100 또는 2× GB200 (카드). 가중치 231.8 GiB	❌
NVFP4 (공식)	W4A4는 Blackwell, 그 밖에는 W4A16. 1× GB200, 1× H200, 2× H100, 1× RTX PRO 6000(96 GB), 1× DGX Spark(128 GB, LiLiCorr 권장). 가중치 69.9 GiB. vLLM·SGLang·TRT-LLM은 모두 CUDA 필요	❌ (CUDA 없음, 메모리 부족)
커뮤니티 GGUF (llama.cpp, Metal 지원)	Q4_0 67.0 GiB, Q4_K_M 65.3 GiB, Q8_0 119.7 GiB. 시각은 mmproj 별도	❌ 메모리 부족
커뮤니티 MLX	4비트 64.6 GiB, 3비트 39.8 GiB	❌ 메모리 부족
이론적 최소	18 GiB에 가중치만 넣으려면 파라미터당 1.24비트	❌ 품질을 기대할 수 없는 수준
같은 세대 Lightning 30B-A3B (텍스트 전용)	GGUF Q4_0 17.6 GiB	△ 한도에 겨우 들어감. 긴 문맥 불가. llama.cpp 또는 mlx-lm 설치 필요(하지 않음)

판단: Super VL은 **이 맥에서 어떤 공개 형식으로도 실행할 수 없습니다.** 메모리가 부족한 것이 결정적이고, 공식 서빙 스택(vLLM, SGLang, TRT-LLM)과 NVFP4 커널은 CUDA 전용입니다. 메모리가 충분한 Apple Silicon(64 GB 이상, 3-4비트 양자화)이라도 대역폭 계산상 배치 1 decode는 수십 tok/s가 상한입니다(`03` §1.2). 이 맥에서 Nemotron 3.5를 직접 만져 보려면 Lightning 30B-A3B 4비트가 현실적인 유일한 선택지입니다. 로컬 실행을 목표로 만든 Bolt 24GB 계열은 별도 분석 대상입니다. NVIDIA 호스팅 API(build.nvidia.com)는 이번에 호출하지 않았습니다.

4.2 미세조정

방법	공개 레시피의 요구 사항	이 맥
전체 SFT (AutoModel)	4노드 × 8 H100 80 GB, GPU당 약 65 GiB, 400 step 약 21분(문서 기준)	❌
LoRA (AutoModel)	1노드 × 8 H100, GPU당 약 39 GiB (rank 64, 시각 동결)	❌
LoRA (Megatron-Bridge, finance cookbook)	8× H200 또는 8× H100, 디스크 약 800 GB	❌
멀티모달 GRPO (NeMo RL + Gym cookbook)	다중 노드	❌

판단: 미세조정은 **최소 8× H100급 노드 하나(LoRA)**가 필요합니다. 공개 레시피가 잘 갖춰져 있어 GPU 노드만 있으면 진입 장벽은 낮습니다. 이 맥에서는 불가능합니다.

4.3 보고서 학습 과정 재현

1T 토큰 증류, GB200 128노드의 MOPD, GB200 512장의 QAD가 들어갑니다. 교사 체크포인트(에이전트, 추론, 비디오, 정렬)와 MOPD 전 체크포인트도 공개되지 않았습니다. **학습 재현은 사실상 불가능합니다.** 사후학습 데이터 일부(CC BY 4.0)와 RL 환경(Gym)은 공개되어 있어, 레시피를 작은 모델로 옮겨 보는 것은 가능합니다.

4.4 평가 재현

Gym 레시피로 T10의 텍스트·에이전트 벤치마크 22종을 재현할 수 있습니다. 조건은 다음과 같습니다. 모델을 서빙하는 GPU 4장(GB200 4장에서 검증, 80 GB GPU는 메모리 설정 변경 필요), SWE 과제마다 CPU 4개·RAM 30 GB인 Docker 샌드박스(동시 16개), judge 모델 API(GPT-5.6 Luna 등), Exa 검색 API(BrowseComp)입니다. 시각 벤치마크 8종과 NV Chat Benchmark는 레시피가 없습니다.

4.5 CPU로 한 것과 더 할 수 있는 것

단계	상태	근거
구조·파라미터·메모리 계산 (헤더만 읽음)	✅ 완료	`param_check.py`
표·본문·블로그 수치 재계산	✅ 완료	`table_check.py`
ReplaySSM, MOPD 하한 toy	✅ 완료	`mechanism_toy.py`
shard 하나(약 4 GB)를 받아 expert 가중치의 NVFP4 양자화 오차 분포 측정	가능 (다운로드 필요, 하지 않음)	블록 scale MSE vs Max(T13)를 가중치 수준에서 확인할 수 있음
ReplaySSM을 PyTorch(MPS/CPU)로 구현해 Mamba-2 실제 decode와 대조	가능	공개 config 차원, 무작위 가중치로 충분
작은 모델(0.5-1B)로 MOPD 2단계 레시피 축소 실험	MPS로 가능할 수 있음 (설치 필요)	교사 2-3개를 같은 작은 모델의 과제별 미세조정으로 대체

02. 선행연구, 공개 자료, 이 저장소의 다른 논문과의 관계

arXiv 번호와 제목은 arXiv API로 확인했습니다(2026-10-30). 보고서가 인용하지 않은 계열 문서는 "인용 없음"으로 표시했습니다. 선행 보고서들은 따로 열어 검증하지 않았고, 아래 설명은 이 보고서가 그 문서를 어떻게 쓰는지에 한정합니다.

1. 계보도

```
Nemotron-H (arXiv:2504.03624, 2025-04)  Mamba-2 + attention 하이브리드 계열의 출발점        ← 인용 없음
   ▼
Nemotron 3 (백서 arXiv:2512.20856)
← 인용 없음
  ├─ Nano 3 (arXiv:2512.20848)        → Lightning 3.5의 초기화 (§2.2)
  ├─ Super 3 (arXiv:2604.12374)       → Super 3.5의 초기화, 25T 사전학습, 재귀 공유 MTP 정식화 (§2.1)
  ├─ Ultra 3 (arXiv:2606.15007)       → 증류 교사(550B-A55B), RL 알고리즘, MOPD 원형, 오염 제거·추론 모드 레시피
  └─ Nano 3 Omni (arXiv:2604.24954)   → 시각 데이터 코퍼스, vision projector warm-up (§3.1)
                                          ▼
            ★ Nemotron 3.5 Super VL (120B-A12B) · Lightning (30B-A3B)  ← 이 보고서 (2026-10-27)
                                          │
            같은 3.5 세대: Bolt 74B-A9B 24GB (arXiv:2610.33039, 로컬용 하이브리드 VLM) → 별도 분석 `nemotron35_bolt/`

[사후학습 계열]  Nemotron-Cascade (arXiv:2512.13607, 인용 없음) → Cascade 2 (arXiv:2603.19220, MOPD의 토큰 단위 갱신 근거로 인용)
                 On-policy distillation (Lu & Thinking Machines, 2025) · trust-region policy distillation (Xie et al., 2026)
[투기적 디코딩]  speculative sampling (Leviathan 2023) · MTP (Gloeckle 2024) · LK loss (Samarin 2026)
                 DFlash · DSpark · LiLiCorr (Rusanovsky 2026) · ReplaySSM (Liou, …, Dao 2026)
[기타]           Skew Reverse KL (Ko 2024) · LLM-as-a-Verifier (Kwok 2026) · Nemotron Elastic (arXiv:2511.16664, 인용 없음)
```

차별점 요약: 구조 자체는 Super 3와 같습니다(LatentMoE, Mamba-2, MTP). 3.5에서 새로 생긴 것은 (1) 더 큰 교사(Ultra 3)에서 받는 1T 토큰 증류, (2) Indic과 SWE 중간학습이라는 데이터 단계, (3) 텍스트 전용 base를 **사후학습에서** VLM으로 바꾼 점, (4) 시각·비디오 교사를 포함한 2단계 MOPD, (5) 양자화·서빙 공학(QAD, MTP splice, ReplaySSM, Mamba 체크포인트 prefix caching)입니다. 새로운 모델 구조를 제안하는 논문이라기보다 **레시피와 시스템 보고서**에 가깝습니다.

2. 구성 요소별 출처

구성 요소	출처	이 보고서에서 바뀐 점
Mamba-2/attention 하이브리드 + LatentMoE	Super 3 (2604.12374)	바뀐 점 없음. 구조 표도 없음(`04` D5)
재귀 공유 MTP	Super 3	헤드 2개 중 첫째만 남김, hidden-state mixing (§2.1)
대형 교사 증류	Ultra 3 Base	Skew Reverse KL(α = 0.1)과 top-128 logit (§2.2)
Indic 합성 데이터	NeMo Data Designer, Gemma-4-31B-it, Bodhan-MT	2.83T 토큰 코퍼스, 4단계 번역·검증 (§2.3)

구성 요소	출처	이 보고서에서 바뀐 점
SWE 중간학습	Singhal et al. 2026 (별도 보고서)	65.4B 토큰 @256K, T4 혼합
시각 인코더	C-RADIO v4-H	projector warm-up 뒤 SFT에서 언어·시각을 함께 학습(§3.1). 비디오 교사 RL에서는 동결(§3.4.1). AutoModel 미세조정 레시피도 시각 모듈을 동결
RL (GRPO, 비동기)	Ultra 3, NeMo-RL, NeMo Gym	router replay, FP32 LM head 추가 (§3.2)
MOPD	Ultra 3, on-policy distillation 계열	2단계, 도메인별 교사 + self-anchor, proximal teacher (§3.6)
MTP boosting	Ultra 3 (temperature forward-KL)	LK loss로 교체 (§3.7)
NVFP4 PTQ/QAD	ModelOpt	시각 포함 보정, MTP 별도 양자화 후 splice (§4)
ReplaySSM	TensorRT-LLM PR #14203, Liou et al. (Dao lab) 동시 발견	vLLM 통합 (§5.4)
병렬 drafter	DFlash, DSpark, LiLiCorr	Super용 LiLiCorr 학습을 증류로 변경 (§5.7.1)
테스트 시간 선택	LLM-as-a-Verifier (Kwok 2026)	같은 체크포인트가 검증자 (§3.11)

3. 이 저장소의 다른 논문과의 관계

솔직히 말하면 **직접적인 방법론 연결은 약합니다.** 이 저장소의 로봇 논문들은 2-3B 규모 VLM이나 비디오 생성 모델을 백본으로 쓰고, 실시간 제어 지연이 핵심 제약입니다. Super VL은 활성 12B, 체크포인트 75-249 GB라 로봇 위에서 돌리는 백본 후보가 아닙니다. 연결 지점은 "오프라인 도구"와 "학습 레시피" 쪽입니다.

폴더	그 논문의 핵심	Super VL과의 관계
`thinkworld/`	Qwen3-VL-2B VLA가 손목 움직임 토큰(CoD)을 생성하고, 예측-관찰 일치 보상으로 GRPO	둘 다 **VLM 자체를 RL로 고칩니다.** ThinkWorld의 결과 기반 보상과 Super의 MOPD는 상보적입니다. 과제별로 RL한 교사 여러 개를 한 학생으로 합치는 MOPD 레시피(§3.6)는, 과제별 VLA 정책을 하나로 합칠 때 그대로 참고할 수 있습니다. 다만 2B 학생에 MOPD를 쓴 증거는 이 보고서에 없습니다
`pacevla/`	GR00T N1.5 action expert에 속도 모드 decoder 4개, LVLM(Gemini 3.8 Flash) 라벨로 학습한 judge·라우터	PaceVLA는 데이터셋 전체의 chunk 라벨링을 상용 API로 했습니다. Super VL(OpenMDW, 비디오 입력, 1M 문맥)은 이 **오프라인 라벨러를 자체 호스팅 모델로 바꾸는 후보**입니다. 다만 로봇 국면 판정 정확도는 이 보고서의 평가에 없습니다
`agentic_wam/`	코드·미래 영상·행동을 MoT 하나에서 함께 denoise (SDAR-1.7B 코드 LM, Cosmos-Predict2.5-2B, Qwen3-VL-2B ViT). 하이브리드 모드에서 Molmo·SAM 3·GraspNet 사용	AW-0의 "코드로 계획" 부분은 작은 LM을 씁니다. Super VL의 시각 도구 사용(SpatialClaw, crop·zoom·SAM3 호출)과 에이전트 학습은 **도구를 호출하는 상위 계획기** 쪽과 맞닿습니다. 지연 0.23 s 수준의 joint denoising과는 시간 규모가 다릅니다
`hydra0/`	범용 비디오 world model(Cosmos 2.5, Wan2.2)로 행동을 이미지 평면 점 궤적(action flow)으로 생성	직접 관계는 거의 없습니다. 같은 NVIDIA 연구 생태계이고, 보고서가 "© NVIDIA All rights reserved"라 그림을 게시하지 못한다는 라이선스 처리만 같습니다

하이브리드 SSM 관점의 연결. 로봇 정책의 긴 이력(수천 프레임 관측)을 다룰 때, KV는 문맥에 비례해 늘고 Mamba 상태는 고정입니다. Super의 서빙 분석(§5.2-5.4)과 `03` §2의 요청당 메모리 계산은 하이브리드 백본 VLA를 설계할 때 메모리 예산을 잡는 근거가 됩니다.

4. 공개 자료 (GitHub, Hugging Face)

조회일 2026-10-30. 별 수와 마지막 push는 GitHub API, Hugging Face 값은 Hub API 기준입니다. 코드 저장소는 clone하지 않고, 필요한 파일만 받아 `paper/cookbook/`, `paper/gym_recipe/`에 두었습니다.

자료	내용	라이선스	별 / 좋아요	마지막 push·수정	확인한 커밋·리비전
NVIDIA-NeMo/Nemotron	cookbook(vLLM·SGLang·TRT-LLM 배포, LoRA, RL, 에이전트 예제)	Apache-2.0	★2,248	2026-10-28	`99a7e45`
NVIDIA-NeMo/Automodel	Super VL 전체 SFT·LoRA 레시피	Apache-2.0	★1,064	2026-10-30	`571df6d`
NVIDIA-NeMo/RL	GRPO, MOPD 학습 프레임워크	Apache-2.0	★2,095	2026-10-30	`2bb62a8`
NVIDIA-NeMo/Gym	평가·RL 환경, `nemotron_recipes/super-3.5/` 재현 레시피	Apache-2.0	★1,305	2026-10-30	`abdc0b5` (레시피가 고정한 평가 커밋 `1e66890`)
NVIDIA/Model-Optimizer	NVFP4 PTQ·QAD·AutoQuant	Apache-2.0	★5,471	2026-10-30	`cb9ab4d`
NVIDIA-NeMo/DataDesigner	Indic·시각 합성 데이터 파이프라인	Apache-2.0	★2,382	2026-10-30	`f61f71d`
NVIDIA-NeMo/Evaluator	base 모델 평가(T6)	Apache-2.0	★357	2026-10-19	`ea35ba3`
HF `nvidia/NVIDIA-Nemotron-3.5-Super-VL-120B-A12B-BF16`	사후학습 BF16, 가중치 shard 63개, 248.9 GB	OpenMDW-1.1	♥107	2026-10-22	`fb0ee0b`
HF `…-Super-VL-120B-A12B-NVFP4`	공개 양자화본, 75.0 GB	OpenMDW-1.1	♥246	2026-10-23	`da5b265`
HF `…-Super-VL-120B-A12B-Base-BF16`	base	OpenMDW-1.1	♥57	2026-10-22	`5d80455`
HF `…-Super-VL-120B-A12B-NVFP4-LiLiCorr`	병렬 drafter, 4.9 GB	OpenMDW-1.1	♥11	2026-10-16	`292bf1e`
HF `…-Lightning-30B-A3B-BF16` / `-NVFP4` / `-Base-BF16`	Lightning 본체 (65.8 / 25.2 / 65.8 GB)	OpenMDW-1.1	♥257 / 482 / 28	2026-08-24 / 09-10 / 08-11	`a9904d2` / `bee7596` / `434456c`
HF `…-Lightning-30B-A3B-NVFP4-DFlash` / `-DSpark`	Lightning drafter	OpenMDW-1.1	♥23 / 42	2026-09-01 / 10-12	`8abcc4d` / `6d127b5`
HF `nvidia/Nemotron-Post-Training-Dataset-v2`	MTP boosting 시드 프롬프트	CC BY 4.0 (gated: auto)	—	2025-08-21	`5c89e01`
HF `nvidia/Nemotron-RL-Super-Training-Blends`	RL·MTP boosting 프롬프트	CC BY 4.0	—	2026-09-29	`79c4deb`

자료	내용	라이선스	별 / 좋아요	마지막 push·수정	확인한 커밋·리비전
HF `nvidia/Nemotron-Pretraining-Indic-CC-v1`, `-Indic-Specialized-v1`	Indic 코퍼스 일부	확인 안 함	—	2026-09-04, 10-26	—

모델 라이선스 OpenMDW-1.1 (Linux Foundation, `paper/openmdw_1.1.html` 에서 원문 확인): 모델과 관련 산출물을 저작권·특허·DB·영업비밀 범위에서 무료로 "제한 없이" 다룰 수 있게 허락합니다. 재배포할 때는 라이선스 사본과 고지를 유지해야 하고, 모델이 특허·저작권을 침해한다고 먼저 소송을 걸면 권리가 종료됩니다. 모델 출력에는 제한이 없습니다. 모델 카드는 "commercial or non-commercial use"가 가능하다고 적었습니다. 이 라이선스는 **모델에만** 적용됩니다. 보고서 PDF는 별도로 "All rights reserved"입니다.

선행 보고서 (arXiv)

arXiv	제목	이 보고서에서의 역할
2504.03624	Nemotron-H: A Family of Accurate and Efficient Hybrid Mamba-Transformer Models	하이브리드 계열의 시작 (인용 없음)
2512.20856	NVIDIA Nemotron 3: Efficient and Open Intelligence	3세대 개요 (인용 없음)
2512.20848	Nemotron 3 Nano	Lightning 초기화
2604.12374	Nemotron 3 Super	Super 3.5 초기화, MTP 정식화
2606.15007	Nemotron 3 Ultra	증류 교사, RL·MOPD·오염 제거 레시피
2604.24954	Nemotron 3 Nano Omni	시각 데이터, projector warm-up
2512.13607	Nemotron-Cascade	cascade RL (인용 없음)
2603.19220	Nemotron-Cascade 2	MOPD의 토큰 단위 on-policy 증류 근거
2511.16664	Nemotron Elastic	many-in-one 모델 (인용 없음). Lightning MTP를 Super 3 MTP에서 차원을 줄여 만든 방식(§2.1)과 발상이 비슷하지만 관계는 확인하지 않음
2610.33039	Nemotron 3.5 Bolt 74B-A9B 24GB	같은 세대의 로컬용 모델. 이 폴더에서는 다루지 않음