ResTacVLA: 분석 리포트

게시용 버전: 논문 그림은 라이선스(arXiv 비독점 배포) 때문에 제외했습니다. 원문 https://arxiv.org/abs/2607.03387 · arXiv:2607.03387v3 · IROS 2026 · 중국과학원대학·중국과학원 자동화연구소, Zhongguancun Academy, Dexmal (Zhang, Xie, Meng, Guo, Hao, Deng, Cheng, Wang) · 코드 미공개(웹페이지 저장소 Awilekong/ResTacVLA @ 09cdbcb) · 분석일 2026-11-09

핵심 요약

1. **무엇을 하는가:** π0.5에 촉각을 넣되, 원시 촉각 대신 "손목 영상으로 예측한 촉각 잠재와 실제 촉각 잠재의 차이"(잔차)를 VQ로 이산화해 action expert에 토큰 하나로 붙인다. 시각 예측의 불확실성 σ로 그 토큰의 세기를 조절한다(Eq. 1-4).
2. **표는 정수로 맞지만 헤드라인은 부풀려져 있다:** "최대 86.7% task success"는 Peg-in-Hole의 정렬 칸이다(완료 기준 최고 80.0). "+34.6%"는 π0.5 대비 pp다. Peg Transfer에서는 T-UniT가 더 높아(66.7 대 60.0) "모든 과제에서 앞선다"가 논문 표와 어긋난다.
3. **최강 기준선과는 합산해야 구분된다:** π0.5 대비 5과제 합산 $p = 4.7\times10^{-7}$로 확실하다. 같은 UniT 인코더를 쓴 T-UniT 대비로는 과제별로 유의한 차이가 없고($p = 0.088$-1.0), 합산 $p = 0.004$다.
4. **이득은 주로 정렬 단계에서 나온다:** T-UniT 대비 완료 성공 이득의 74%(log)가 정렬 성공률 차이다. 정렬 뒤 완료율 P(I|A) 차이는 $p = 0.28$이다.
5. **게이트는 surprise가 아니라 영상 기반 접촉 국면 검출기다:** Eq. 1의 최적 σ는 손목 영상만의 함수다. Fig. 5에서 g가 접촉 전부터 오르는 것도 이와 맞다. toy에서 σ 게이트는 시각에 보이지 않는 충돌을 0% 열었고, 예측 오차를 넣으면 100%가 됐다.
6. **잔차의 효과는 분리되지 않았다:** 잔차 대 원시 ablation이 없고, 연속 잔차(w/o VQ 33.3)가 같은 두 과제의 T-UniT(32.7)와 같다. toy에서 잔차는 "시각 차원 ≫ 데이터, 정확한 CMP, 높은 ρ^2"일 때만 이기고(25-38%), CMP를 정책 데이터로 학습하면 진다.
7. **강건성 표는 교란 전 차이를 보여 준다:** 교란에 따른 하락폭이 세 방법에서 같다(Dynamic 모두 −13.3pp, Height− 모두 −20.0pp).
8. **구현 가능성:** 코드·데이터 미공개라 공식 재현은 불가능하다. 아이디어는 수백 줄로 옮길 수 있다. 장벽은 GelSight 하드웨어와 촉각 시연, π0.5 미세조정용 24 GB급 CUDA GPU다. 이 맥에서는 재계산·toy를 끝냈고, CMP 단독 학습은 torch 설치와 데이터가 있으면 MPS로 가능해 보인다.

01. 논문 분석: ResTacVLA

- **논문:** Pengwei Zhang, Bin Xie, Xinpan Meng, Xinyu Guo, Ce Hao, Fang Deng, Long Cheng(교신), Tiancai Wang. *Feeling the Unexpected: ResTacVLA for Contact-Rich Manipulation via Residual Tactile Representation.* arXiv:2607.03387v3 (2026-07-19). 8쪽, 그림 6개, 표 3개.
- **소속:** 중국과학원대학 인공지능학원·중국과학원 자동화연구소, Zhongguancun Academy, Dexmal(1쪽 각주).
- **학회:** IROS 2026 채택(arXiv Comments: "Accepted by IROS 2026"). PDF 본문에는 IEEE 저작권 문구가 없습니다. "IEEE"는 참고문헌에만 나옵니다.
- **공개 자료:** 프로젝트 페이지 https://awilekong.github.io/ResTacVLA/ ("Code coming soon", "Data coming soon"). 웹페이지 저장소 `Awilekong/ResTacVLA` @ `09cdbcb` (2026-08-06)에는 `docs/`의 HTML·JS·CSS만 있습니다.
- **라이선스:** arXiv 비독점 배포(nonexclusive-distrib 1.0)입니다. CC BY가 아니어서 논문 그림은 개인용 리포트·PPT에만 넣었습니다.
- **판본:** v1(07-03), v2(07-07), v3(07-19). 단어 단위로 비교하면 v1 → v2는 arXiv 날짜 표기만, v2 → v3는 저자 순서만 바뀌었습니다. Ce Hao가 3번째에서 5번째로 옮겼고, 본문·표·그림(내장 이미지 101개)은 같습니다. 프로젝트 페이지는 아직 v1 순서입니다.

1. Abstract: 무엇을 주장하나

VLA에 촉각을 그냥 넣으면 고대역 시각 특징이 희소한 촉각 신호를 덮는 "modality collapse"가 생긴다고 봅니다(Sec. I, [9]). 저자들은 뇌가 예측 가능한 입력을 약화하고 예측에서 벗어난 자극(surprise)에 집중한다는 predictive coding [12-15]에서 착안했습니다.

1. 촉각을 원시 입력 대신 **잔차 촉각 표현** r_t = z_t − ẑ_t로 바꿉니다. 손목 영상으로 예측한 촉각 잠재와 실제 촉각 잠재의 차이입니다.
2. 잔차를 VQ 병목으로 이산화해 **Latent Contact Primitive**를 만듭니다.
3. 시각 예측의 불확실성 σ_t로 촉각 주입을 조절하는 **Surprise-Aware Gate(SAG)**를 둡니다.

주장은 세 가지입니다. 다섯 실물 과제에서 모든 기준선을 일관되게 앞서고, 예상 밖의 동적 교란에 강건하며, "최대 86.7% task success, 평균 34.6% 향상"입니다(Abstract, Sec. I 기여 3).

2. Method

2.1 문제 설정 (Sec. III 첫 문단)

관측은 O_t = {V_base, V_side, V_wrist, I_tac, s_t}이고 s_t ∈ R^7는 고유 감각입니다. 정책 π(A_t | O_t, L)은 길이 H의 행동 chunk를 냅니다. 바탕 모델은 π0.5 [2]입니다. PaliGemma VLM [27]이 영상·지시·상태를 인코딩하고, action expert가 조건부 flow matching [26]으로 행동을 생성합니다(Sec. III-A).

2.2 Cross-Modal Predictor (Sec. III-B-1, Eq. 1)

- 손목 영상 V_wrist → 학습 가능한 ResNet-18 + MLP → 평균 μ_t ∈ R^{3×H′×W′}와 **스칼라** 표준편차 σ_t ∈ R를 냅니다. 둘은 예측 촉각 잠재 ẑ_t의 가우시안을 정의합니다.
- 실제 촉각 영상 I_tac는 UniT [21] 기반 촉각 인코더가 같은 공간의 z_t로 보냅니다. UniT는 VQVAE 기반 촉각 표현입니다.
- 잔차는 r_t = z_t − ẑ_t입니다. ẑ_t가 μ_t인지 표본인지는 적혀 있지 않습니다.

- 손실은 가중 NLL [28]입니다: $L_{pred} = \lambda_\sigma \log \sigma_t^2 + \| z_t - \mu_t \|^2 / \sigma_t^2$ (Eq. 1). λ_σ는 "불확실성 붕괴"를 막는 가중치입니다.
- 논문은 "σ_t가 cross-modal surprise의 원리적 척도"라고 씁니다. 하지만 Eq. 1이 학습하는 σ_t는 Kendall & Gal [28]의 aleatoric 불확실성이고, **손목 영상만의 함수**입니다. 실제 촉각이 예측에서 얼마나 벗어났는지(예측 오차)는 σ_t에 들어가지 않습니다(`03` §2).

2.3 Latent Contact Primitive (Sec. III-B-2, Eq. 2)

- event encoder f_φ(conv residual block + global max pooling)가 r_t를 전역 사건 벡터 $h_t \in R^D$로 줄입니다.
- VQ [29] 코드북 $C = \{c_k\}$로 h_t를 q_t로 이산화합니다. 코드북 붕괴를 막으려고 네 가지를 씁니다: 저차원 코드 [30], 코사인 유사도 [30], EMA 갱신 [31], 비활성 코드 재초기화 [32].
- 복원 경로: q_t가 FiLM [33]으로 예측 사전 $\hat{z}_t$를 변조해 $\tilde{z}_t$를 만들고, decoder가 촉각 영상 $\hat{I}_t$로 되돌립니다.
- CMP 전체 손실은 $L_{CMP} = L_{rec} + \lambda_p L_{pred} + L_{vq}$입니다(Eq. 2). L_{rec}는 촉각 영상 MSE입니다.
- 정보 관점: q_t는 코드북 index 하나라서 프레임당 많아야 $\log_2 K$ 비트입니다. 정책이 받는 촉각 정보는 모두 이 index를 거칩니다. K와 D는 논문에 없습니다.

2.4 Surprise-Aware Gate와 정책 주입 (Sec. III-C, Eq. 3-4)

- $g_t = \text{Sigmoid}(\text{MLP}(\sigma_t))$ (Eq. 3). 입력은 스칼라 σ_t 하나입니다.
- q_t를 선형층으로 $p_t \in R^d$에 투영하고, 학습되는 "접촉 없음" 토큰 e_0와 섞습니다: $e_t = g_t\, p_t + (1 - g_t)\, e_0$ (Eq. 4).
- e_t는 VLM 쪽이 아니라 **action expert의 noise 토큰 옆에 이어 붙입니다.** VLM의 사전학습 표현을 해치지 않으려는 선택입니다.
- **정책이 촉각을 받는 경로는 이 토큰 하나뿐입니다.** $g_t \to 0$이면 $e_t \to e_0$가 되어 정책은 촉각을 보지 못합니다.

2.5 학습 순서 (Sec. III-A, III-C)

1. CMP를 여러 과제의 상호작용 데이터로 따로 사전학습합니다.
2. CMP를 고정하고 촉각 확장 정책 전체를 flow matching으로 end-to-end 미세조정합니다. 게이트 MLP와 투영층도 이때 학습되므로, 게이트는 surprise를 직접 감독받지 않고 행동 손실만으로 배웁니다.

CMP 학습 데이터가 정책 데이터와 같은지는 적혀 있지 않습니다. 같다면 학습 중 잔차가 시험 때보다 작아지는 분포 차이가 생길 수 있습니다(`03` §3).

구성 요소	논문에 있는 것	없는 것
CMP	ResNet-18 + MLP, 스칼라 σ, Eq. 1	λ_σ, $H' \cdot W'$, $\hat{z}_t$ 정의(μ 또는 표본), 입력 해상도
촉각 인코더	UniT 기반	사전학습 여부(공개 가중치 / 재학습), 고정 여부
event encoder + VQ	구조 서술, 붕괴 방지 4가지	K, D, 코드 사용률, 재초기화 주기
게이트	Eq. 3-4	MLP 크기, 초기화, g 분포 통계
정책	π0.5 + flow matching, e_t 주입	H, 학습 step·batch, LoRA 여부, 추론 지연

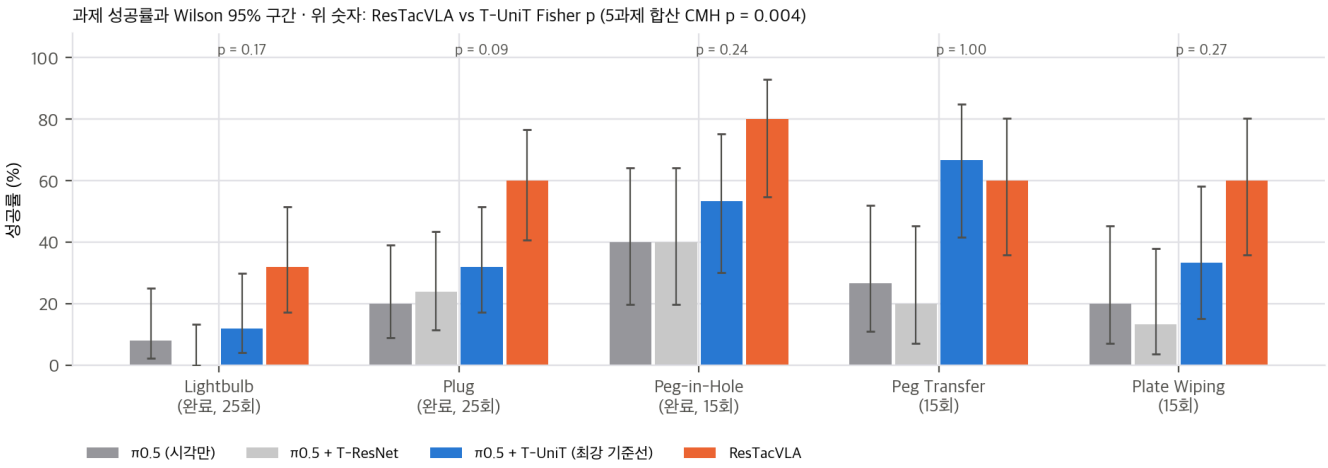
3. Experiments

3.1 설정 (Sec. IV-A)

- **플랫폼:** Franka Research 3 + Robotiq 2F-85. **GelSight Mini 하나를 한쪽 손가락에만** 달았습니다. RealSense D435 세 대(정면, 측면, 손목)와 RTX 4090 워크스테이션 하나로 수집과 평가를 했습니다.
- **과제 다섯 개:** Lightbulb Screwing, Plug Insertion, Peg-in-Hole, Peg Transfer, Plate Wiping(Fig. 3). 과제마다 시연은 약 100개이고, 작업자는 실시간 촉각 영상을 보면서 시연했습니다.
- **평가 시행:** Lightbulb·Plug는 25회, 나머지 셋은 15회("롤아웃이 길어서")입니다. Lightbulb·Plug·Peg-in-Hole은 정렬(A)과 완료(I) 두 단계로 나눠 씁니다.
- **기준선 다섯 개:** DP w/o T, DP w/ T-ResTac, π0.5 w/o T, π0.5 w/ T-ResNet(ResNet-18 촉각 인코더), π0.5 w/ T-UniT(사전학습 UniT 특징).
  - 기준선의 촉각 주입 위치(VLM 입력 / action expert)와 게이트 유무는 적혀 있지 않습니다.
  - T-UniT는 ResTacVLA와 같은 촉각 인코더를 쓰므로, 둘의 차이가 CMP 잔차 + VQ + 게이트 + 주입 방식 전체입니다.

3.2 Q1: 주요 결과 (Table I)

- 평균 62.8%로 π0.5 28.2%보다 34.6, DP w/o T 18.8%보다 44.0 높다고 씁니다. 단위는 퍼센트포인트입니다.
- 이 평균은 **8칸 평균**입니다. A와 I를 같은 무게로 섞고, 두 단계 과제를 두 번 셉니다. 과제 성공(최종 단계) 기준 5과제 평균은 ResTacVLA 58.4%, T-UniT 39.5%, π0.5 22.9%입니다(`04` C3).
- "최대 86.7% task success"는 Peg-in-Hole의 **정렬(A)** 칸입니다. 과제 완료 기준 최고값은 Peg-in-Hole I의 80.0%입니다(`04` C1).
- Peg Transfer에서는 T-UniT 66.7%(굵게)가 ResTacVLA 60.0%(밑줄)보다 높습니다. 논문 표 자신의 강조 표시로도 "모든 과제에서 앞선다"(Abstract, Sec. IV-B)는 성립하지 않습니다(`04` C2).
- T-ResNet이 Lightbulb에서 "성능을 떨어뜨린다"(28.0 → 16.0)는 A칸 7/25 대 4/25이고 Fisher p = 0.50입니다.
- DP에 잔차 촉각을 넣으면 +19.2(38.0 대 18.8)입니다. DP w/ T-UniT 같은 "원시 촉각 DP" 칸이 없어서, 이 이득이 잔차 때문인지 촉각 자체 때문인지 가를 수 없습니다.



우리 분석: Table I의 과제 성공(최종 단계) 칸과 Wilson 95% 구간. 위 숫자는 ResTacVLA 대 T-UniT 과제별 Fisher p.

3.3 Q2: Ablation (Table II)

- Plug Insertion과 Plate Wiping 두 과제의 평균만 보고합니다: Full 60.0, w/o VQ(연속 잔차) 33.3, w/o Gating(g = 1 고정) 46.7, π0.5 20.0.

- 정성 설명: VQ가 없으면 "잦은 떨림과 파지 자세 민감도"가 생기고, 게이트가 없으면 "촉각 잡음과 초기 파지 오차로 궤적이 표류"합니다.
- **잔차 대 원시 촉각을 직접 비교한 ablation은 없습니다.** w/o VQ 33.3은 같은 두 과제의 T-UniT 평균 32.7과 거의 같습니다. VQ를 뺀 잔차 경로가 원시 UniT 특징보다 나은지 이 표로는 보이지 않습니다(`04` C5).
- 두 과제 평균(25회 + 15회)은 정수 조합이 여러 개라 과제별 값을 복원할 수 없습니다. 예를 들어 33.3은 (Plug, Wiping) = (0/25, 10/15), (5, 7), (10, 4), (15, 1) 중 하나입니다.

3.4 Q3: 해석 (Fig. 4, Fig. 5)

- **t-SNE(Fig. 4):** 자유 공간 프레임은 다섯 과제가 한 군집으로 모이고, 접촉 프레임은 과제·사건(충돌, 정렬 성공)별 작은 군집으로 갈라진다고 씁니다.
  - 정량 지표(군집 순도, 코드 사용률)는 없습니다.
  - 점들이 연속적으로 흩어져 있습니다. 양자화된 코드 q_t를 그렸다면 많아야 K개 위치에 겹쳐야 하므로, 실제로는 양자화 전 h_t를 그렸을 가능성이 있습니다. 논문은 이를 밝히지 않습니다.

게이트 곡선(Fig. 5): 성공한 Lightbulb 시행 **하나**의 g_t입니다. 그림에서 읽은 값은 다음과 같습니다.

단계 (진행도)	g_t
Approach (0-0.3)	약 0.11-0.14
Pre-contact (0.3-0.45)	약 0.35로 뛰어오름
Alignment	약 0.55-0.60
Screwing	최고 약 0.78
Success (0.81 이후)	0 근처로 떨어짐

- 본문은 "접근 중 0 근처, 접촉하면 빠르게 포화"라고 쓰고, 캡션은 "점진적으로 오른다"고 씁니다. 그림은 캡션 쪽이고 포화(1)에 이르지 않습니다.
- g가 **접촉 전(pre-contact)부터** 오른다는 점이 중요합니다. 게이트가 실제 촉각의 놀람이 아니라 영상에서 "접촉이 가까움"을 읽는다는 뜻이며, σ_t의 정의(영상만의 함수)와 맞습니다(`03` §2).

3.5 Q4: 강건성 (Table III, Fig. 6)

교란 세 가지를 썼습니다: 초기 파지 교란(Plug, ±5 mm, ±10°), 동적 표적 이동(Peg-in-Hole, 3-5 cm), 표면 높이 ±2 cm(Plate Wiping). 비교 대상은 π0.5와 T-UniT 둘입니다.

조건	π0.5	T-UniT	ResTacVLA	교란 없는 칸(Table I) 대비 하락
Dynamic (Peg-in-Hole, 15회)	26.7	40.0	66.7	**세 방법 모두 −13.3** (−2/15)
Height + (Wiping, 15회)	33.3	46.7	53.3	π0.5·T-UniT +13.3, ResTacVLA −6.7
Height − (Wiping, 15회)	0.0	13.3	40.0	**세 방법 모두 −20.0** (−3/15)
Grasp (Plug, 25회)	8.0	20.0	52.0	−12, −12, −8

교란에 따른 하락폭이 방법 사이에 같거나 비슷합니다. 그래서 표 III의 우위는 교란 없는 성능 차이가 그대로 옮겨 온 것으로 읽는 편이 맞습니다. "교란에 더 강건하다"는 근거는 되지 않습니다(`04` C7). 교란 조건의 시행 수(15·25회)는 따로 적혀 있지 않아, Table I과 같다고 가정했습니다. 모든 값이 그 분모와 정수로 맞습니다.

4. Limitations

논문에는 한계 절이 없습니다. 읽으면서 확인한 한계는 다음과 같습니다.

1. **게이트가 예상 밖 사건을 볼 수 없는 구조입니다.** g는 손목 영상만의 함수인 σ_t로 정해집니다. 그래서 영상으로 보이지 않는 자유 공간 충돌에서는 게이트가 닫힌 채로 남습니다. 제목의 "Feeling the Unexpected"와 Fig. 4의 "unexpected collision" 군집은 CMP 안의 표현이고, 정책까지 전달된다는 보장은 없습니다(`03` §2, toy).
2. **잔차의 기여가 분리되지 않았습니다.** 잔차 대 원시 ablation이 없고, Table II는 두 과제 평균입니다.
3. **통계 근거가 약합니다.** 과제당 15-25회이고 시드, 반복, 신뢰구간이 없습니다. 최강 기준선 T-UniT와는 과제별로 유의한 차이가 하나도 없습니다(최소 Fisher $p = 0.088$). 다섯 과제를 합치면 CMH $p = 0.004$입니다.
4. **이득이 대부분 정렬 단계에서 나옵니다.** T-UniT 대비 완료 성공 이득의 74%(로그 배율)가 정렬 성공률 차이입니다. "촉각이 상호작용 단계에서 시각의 빈틈을 메운다"는 서술(Sec. IV-B)과 결이 다릅니다(`03` §1).
5. **하드웨어 범위가 좁습니다.** GelSight Mini 하나, 한 손가락, 평행 그리퍼, 한 연구실 환경입니다.
6. **재현 정보가 부족합니다.** λ_σ, λ_p, K, D, H, 게이트 MLP, 학습 step, 기준선 조율 방법, 추론 지연이 없습니다.
7. **해석 그림이 정성적입니다.** Fig. 5는 시행 하나, Fig. 4는 정량 지표가 없습니다.

5. 한 줄 평가

"촉각을 시각 예측과의 차이로 표현하고, 접촉 국면에서만 주입한다"는 설계는 간단하고 옮기기 쉽습니다. 다만 논문의 증거는 **ResTacVLA 전체가 π0.5보다 낫다**까지만 보여 줍니다(5과제 합산 $p < 10^{-6}$). 잔차·surprise라는 명명이 성능의 원인이라는 주장은 실험으로 분리되지 않았습니다. 게이트는 surprise 검출기라기보다 **영상 기반 접촉 국면 검출기**로 읽는 편이 정확합니다.

03. 재계산과 유도

스크립트는 `analysis/table_check.py`(표 재계산, 1초 미만)와 `analysis/gate_toy.py`(numpy toy, 1스레드 약 30초)입니다. 결과는 같은 이름의 `*_results.json`에 있습니다.

1. Table I 다시 읽기

1.1 성공 횟수와 평균

모든 칸이 25회(Lightbulb, Plug)·15회(나머지)와 정수로 맞습니다. 예를 들어 ResTacVLA는 14/25, 8/25, 17/25, 15/25, 13/15, 12/15, 9/15, 9/15입니다. 보고된 평균 여섯 개도 8칸 단순 평균과 모두 일치합니다.

방법	8칸 평균 (보고)	과제 성공 5과제 평균	과제 성공 합산 (95회)
π0.5 (시각만)	28.2	22.9	20/95
DP w/o T	18.8	12.5	12/95
π0.5 + T-ResNet	23.2	19.5	17/95
π0.5 + T-UniT	42.3	39.5	34/95
DP + T-ResTac	38.0	34.7	30/95
ResTacVLA	**62.8**	**58.4**	**53/95**

"+34.6%"는 π0.5 대비 퍼센트포인트 차이입니다. 상대 향상으로는 +123%입니다. 가장 센 기준선 T-UniT와 비교하면 8칸 평균으로 +20.5pp, 과제 성공으로 +18.9pp입니다.

1.2 유의성

과제 성공(최종 단계) 칸에 Fisher 정확검정과 Holm 보정을 적용하고, 다섯 과제를 Cochran-Mantel-Haenszel(CMH)로 합쳤습니다.

과제	ResTacVLA	π0.5	p (π0.5 대비)	T-UniT	p (T-UniT 대비)
Lightbulb (I)	8/25	2/25	0.074	3/25	0.17
Plug (I)	15/25	5/25	**0.0086** (Holm 0.043)	8/25	0.088
Peg-in-Hole (I)	12/15	6/15	0.060	8/15	0.25
Peg Transfer	9/15	4/15	0.14	10/15	1.00
Plate Wiping	9/15	3/15	0.060	5/15	0.27
5과제 CMH			**$p = 4.7\times10^{-7}$**, OR 5.5		**$p = 0.0039$**, OR 2.5

- π0.5 대비 우위는 확실합니다. 과제별로 Holm 뒤에 유의한 것은 Plug 하나지만, 다섯 과제 방향이 모두 같고 합산 p가 매우 작습니다.
- T-UniT 대비로는 **과제별로 유의한 것이 하나도 없습니다.** 합산하면 p = 0.004입니다. 이 차이에는 잔차, VQ, 게이트, 주입 방식이 모두 섞여 있습니다.
- DP + T-ResTac 대 DP w/o T: 과제별 p는 0.14-0.50이고, 합산하면 $p = 5.6\times10^{-4}$입니다.

1.3 정렬(A)과 완료(I)로 분해

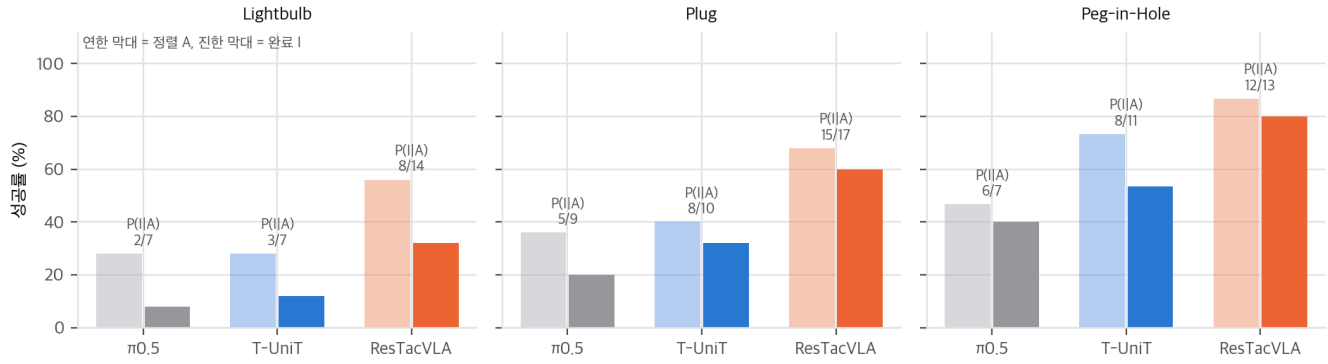
두 단계 과제에서 완료 성공은 P(I) = P(A) · P(I|A)입니다(I가 A의 부분집합이라고 가정).

과제	π0.5 A → I	T-UniT A → I	ResTacVLA A → I
Lightbulb	7 → 2 (0.29)	7 → 3 (0.43)	14 → 8 (0.57)
Plug	9 → 5 (0.56)	10 → 8 (0.80)	17 → 15 (0.88)
Peg-in-Hole	7 → 6 (0.86)	11 → 8 (0.73)	13 → 12 (0.92)

세 과제를 합산하면 ResTacVLA 대 T-UniT는 A 44 대 28, I 35 대 19입니다. 완료 성공 배율 1.84 = 정렬 배율 1.57 × 조건부 배율 1.17입니다. **로그 기준으로 이득의 74%가 정렬 단계에서 나옵니다.** 조건부 성공률 P(I|A) 차이(35/44 대 19/28)는 Fisher p = 0.28입니다. π0.5 대비로는 65%가 정렬 몫입니다.

논문은 "시각 정책은 정렬은 그럭저럭 하지만 상호작용에서 무너지고, ResTacVLA는 상호작용 내내 유지된다"고 해석합니다(Sec. IV-B). 하지만 수치상 가장 큰 차이는 **정렬을 더 자주 성공시키는 데** 있습니다. 정렬은 게이트가 0.35-0.6으로 반쯤 열린 국면입니다(Fig. 5). 그래서 촉각 접촉 사건보다 "접촉 직전의 미세 접근"에서 효과가 났을 수 있습니다. 시행별 기록이 없어서 더 가를 수는 없습니다.

T-UniT 대비 완료 성공 이득(log 배율)의 74%가 정렬 단계에서 나온다 (세 과제 합산 A 44 vs 28, I 35 vs 19)



우리 분석: Table I의 정렬(연한 막대)·완료(진한 막대) 성공률과 P(I|A).

2. 게이트가 실제로 보는 것

2.1 Eq. 1의 최적해

손목 영상 v가 주어졌을 때 n = 3H′W′차원 잠재 z에 대해 기대 손실은 $E[\lambda_\sigma \log \sigma^2 + \| z - \mu \|^2/\sigma^2 \mid v]$입니다. 이를 최소화하면 다음을 얻습니다.

- $\mu^*(v) = E[z \mid v]$
- $\sigma^*(v)^2 = E[\| z - \mu^*(v) \|^2 \mid v] / \lambda_\sigma$ (σ^2로 미분: $\lambda_\sigma/\sigma^2 - E[\| \cdot \|^2 \mid v]/\sigma^4 = 0$)

$\lambda_\sigma = n$이면 σ^2가 차원당 분산이 되어 보정된 값이 됩니다. 다른 값이면 배율만 달라지고, 그 배율은 게이트 MLP가 흡수합니다. 핵심은 **σ^*가 v만의 함수**라는 점입니다. 이 σ는 "이 영상에서 촉각이 얼마나 퍼져 있을지"(기대 불확실성, aleatoric)를 나타냅니다. 지금 들어온 촉각이 예측에서 얼마나 벗어났는지(예측 오차)와는 다른 양입니다. predictive coding의 surprise는 정밀도로 가중한 예측 오차 $(z - \mu)/\sigma$이고, 실제 z가 있어야 계산됩니다.

결과적으로 $g_t = \text{Sigmoid}(\text{MLP}(\sigma_t))$는 다음 성질을 가집니다.

1. 영상이 "접촉이 가까움"을 보이면 촉각이 실제로 어떻든 열립니다. Fig. 5에서 접촉 전(pre-contact)부터 0.35로 오르는 것과 맞습니다.
2. 영상이 자유 공간처럼 보이면 예상 밖 충돌이 있어도 닫혀 있습니다. 예상 밖 사건이 가장 중요한 순간에 촉각 경로를 낮춥니다.
3. Sigmoid는 0이 되지 않으므로 "차단"이 아니라 감쇠입니다. Fig. 5의 접근 단계 $g \approx 0.12$는 p_t를 약 8배 줄인 것입니다. 정책이 이 신호를 다시 키워 쓸 수 있는지는 학습에 달렸습니다.

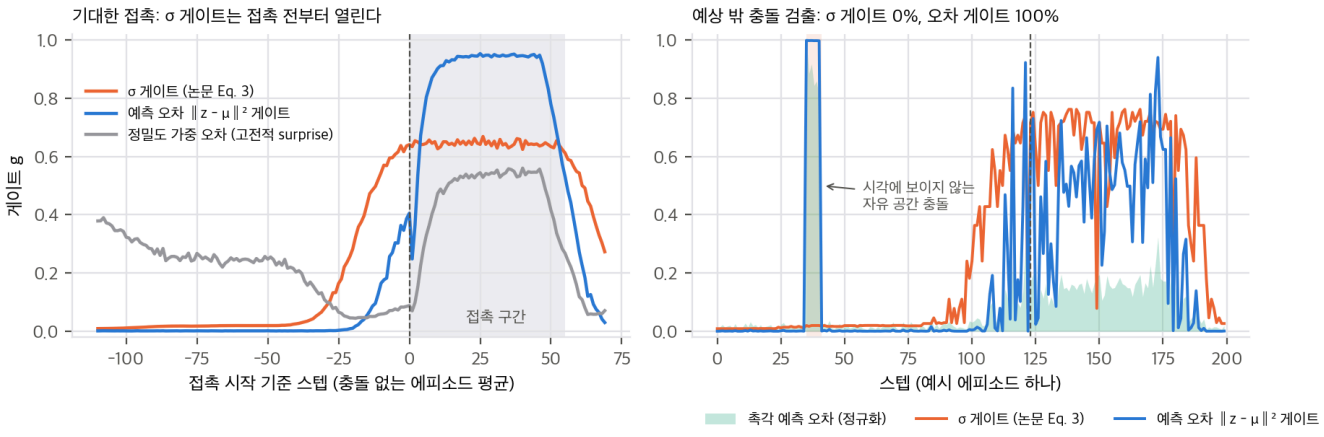
2.2 toy: σ 게이트 대 예측 오차 게이트

1차원 접근 → 접촉 → 해제 에피소드(200스텝)를 만들었습니다. 접촉 시점은 ±8스텝 흔들리고, 접촉 근처에서는 시각 오차가 커집니다(가림). 촉각 잠재는 8차원이고 접촉력은 에피소드마다 0.5–1.5입니다. 에피소드 절반에는 **시각으로 보이지 않는 자유 공간 충돌**(6스텝)을 넣었습니다.

CMP는 분위수 구간 평균으로 Eq. 1의 최적해(μ^*, σ^*)를 근사했습니다. 게이트 네 개는 모두 같은 로지스틱 회귀로 "접촉 중(기대 + 예상 밖)" 라벨에 맞췄습니다. 따라서 차이는 입력 특징에서만 납니다.

게이트 입력	기대 접촉 열림	예상 밖 충돌 열림	자유 공간 오개방	접촉 전 10스텝 평균 g	열림 지연 (중앙값)
σ (논문 Eq. 3)	0.88	**0.00**	0.039	**0.60**	0스텝
원시 예측 오차 $\|z-\mu\|^2$	0.93	1.00	0.001	0.28	1스텝
정밀도 가중 오차 (고전적 surprise)	0.50	1.00	0.082	0.07	8스텝
σ + 오차	0.93	1.00	0.001	0.27	1스텝

- **σ 게이트는 예상 밖 충돌을 하나도 열지 못합니다.** 게이트 보정 데이터에 충돌이 절반 있어도, CMP 학습 데이터의 충돌 비율을 0.5로 올려도 0%입니다. 구조적 한계라서 데이터로 해결되지 않습니다.
- 대신 σ 게이트는 접촉 **전부터** 열립니다(접촉 전 평균 0.60). 이것이 Fig. 5의 pre-contact 상승과 같은 현상입니다. 기대 접촉에는 유리합니다.
- 고전적 surprise(정밀도 가중 오차)는 기대한 접촉에서 오히려 닫힙니다. 예측대로 일어난 접촉은 놀랍지 않기 때문입니다. 접촉 과제에 필요한 신호는 "놀람"이 아니라 "촉각에 정보가 있음"이고, 이는 σ와 오차를 함께 봐야 얻어집니다. 이 게이트가 접근 초반에 0.3–0.4로 높은 것은 분위수 구간 가장자리의 σ 추정 잡음 때문입니다(toy 인공물).
- **센서 잡음 스윕:** $\sigma_n = 0.03 \rightarrow 0.3$으로 키우면 원시 오차 게이트의 충돌 검출은 1.00 → 0.68로, 기대 접촉 검출은 0.94 → 0.47로 떨어집니다. σ 게이트는 0.8 이상을 유지합니다.
- σ + 오차 게이트의 충돌 검출은 $\sigma_n = 0.2$에서 0.33, 0.3에서 0.01로 무너집니다. 로지스틱이 흔한 기대 접촉을 맞추려고 σ에 무게를 싣기 때문입니다. 게이트를 행동 손실만으로 학습하면(논문 Sec. III-C) **드문 예상 밖 사건은 손실에서 차지하는 몫이 작아** 같은 일이 생길 수 있습니다. 예상 밖 사건 검출이 목적이면 별도 감독이나 가중이 필요합니다.



우리 toy: (왼쪽) 충돌 없는 에피소드를 접촉 시점에 맞춰 평균한 게이트. (오른쪽) 충돌이 있는 예시 에피소드. 오차 게이트는 기대 접촉 중에도 예측과 맞는 순간에 닫혔다 열리기를 반복한다.

3. 잔차 대 원시 촉각

3.1 선형 재매개화라는 점

CMP가 고정된 함수 $\hat{z} = f(v)$이면 잔차 특징 $[v, r] = [v, z - f(v)]$는 원시 특징 $[v, z]$의 가역 변환입니다. 정책이 v와 z를 모두 받는다면 정보량은 같습니다(데이터 처리 부등식에서 등호). f가 선형이면 OLS 예측이 정확히 같습니다. toy에서 최대 차이는 6×10^{-13}이었습니다.

그래서 잔차화의 이득은 다음 세 경로로만 생길 수 있습니다.

1. **정규화·최적화의 귀납 편향.** 모달리티별로 표준화하면 원시 z에서는 시각으로 예측되는 성분이 분산을 차지합니다. 그러면 촉각 고유 성분의 계수가 $1/\sqrt{(1 - \rho^2)}$배로 커져야 하고, ridge나 weight decay가 이를 더 강하게 누릅니다.
2. **정책이 f를 스스로 배우기 어려울 때.** ResNet-18 CMP가 별도 데이터로 배운 f를 정책이 공짜로 받습니다.
3. **VQ 병목과의 결합.** 원시 z를 K개 코드로 자르면 대부분의 비트가 예측 가능한 성분에 쓰입니다. 잔차를 자르면 비트가 예측 불가능한 성분에 갑니다(§5).

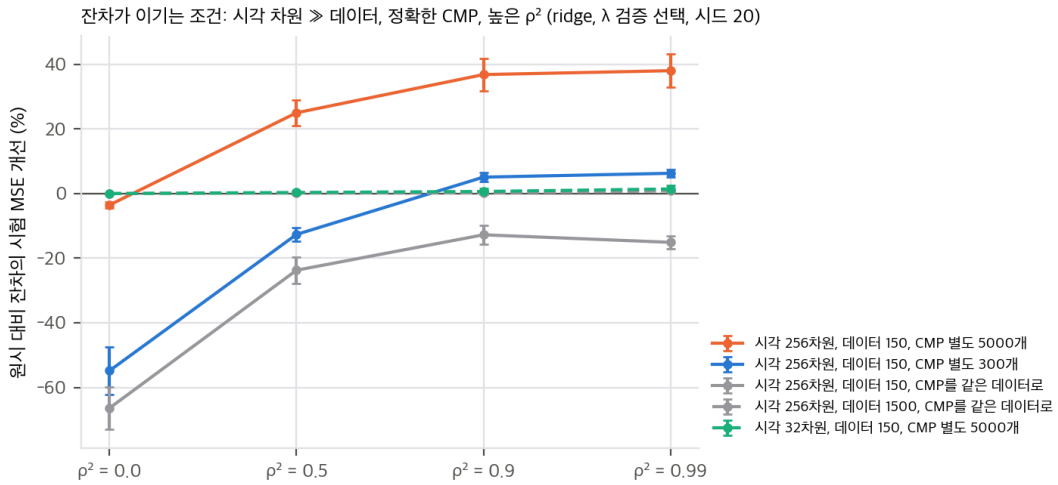
반대로 잔차가 손해인 경우도 있습니다. CMP가 정책 데이터와 같은 데이터로 학습되어 과적합하면, 학습 중 잔차는 작고 시험 중 잔차는 큽니다.

3.2 toy: ridge, 유한 데이터, CMP 품질

$y = w_v \cdot v + w_u \cdot u +$ 잡음, $z = Cv + \sqrt{(1 - \rho^2)}\, u$로 두었습니다. ρ^2는 촉각 중 시각으로 예측되는 비율입니다. 특징 열마다 표준화하고 ridge λ는 검증 세트로 골랐습니다. 시드 20개 평균이고, 값은 원시 대비 잔차의 시험 MSE 개선(%)입니다.

조건	$\rho^2 = 0$	0.5	0.9	0.99
시각 32차원, 데이터 150, CMP 별도 5000	−0.0	+0.3	+0.6	+1.4
시각 256차원, 데이터 1500, CMP 별도 5000	−0.1	+0.1	+0.1	+0.7
시각 256차원, 데이터 150, CMP 별도 5000	−3.6	**+25.0**	**+36.8**	**+38.0**
시각 256차원, 데이터 150, CMP 별도 300	−54.8	−12.7	+5.1	+6.3
시각 256차원, 데이터 150, **CMP를 같은 데이터로**	−66.4	−23.7	−12.8	−15.1

- 시각 차원이 데이터보다 작으면 잔차든 원시든 거의 같습니다(|차이| ≤ 1.4%).
- 시각 차원이 데이터보다 훨씬 크고(256 대 150), **CMP가 별도의 큰 데이터로 정확하게 학습되고, ρ^2가 높을 때만** 잔차가 크게 이깁니다(25-38%). 논문이 말하는 "고대역 시각이 희소 촉각을 덮는" 상황이 바로 이 조건입니다.
- CMP가 부정확하면(300개) 낮은 ρ^2에서 잔차가 크게 집니다. CMP 오차가 잔차에 시각 잡음을 섞기 때문입니다.
- CMP를 정책 데이터로 학습하면 모든 ρ^2에서 집니다. 학습 쪽 잔차 분산이 시험 쪽의 0.0배(시각 256차원, 데이터 150)-0.69배(데이터 1500)로 줄어드는 분포 차이 때문입니다.



우리 toy: 원시 대비 잔차의 시험 MSE 개선(%)과 95% 구간(시드 20).

논문의 CMP는 다섯 과제 시연 약 500개로 학습한 ResNet-18입니다. 정책 데이터와 같은지, 시험 데이터에서 예측 오차가 얼마인지는 보고되지 않았습니다. toy 기준으로는 이 두 값이 잔차의 득실을 가르는 변수입니다. 그래서 "잔차 표현이 필수"(Sec. IV-B)라고 결론 내리려면 같은 조건의 원시 대 잔차 ablation과 CMP 일반화 오차가 필요합니다.

4. Table II·III

- **Table II:** 두 과제 평균은 정수 조합이 여러 개입니다. Full 60.0 = (Plug, Wiping) ∈ {(5, 15), (10, 12), (15, 9), (20, 6), (25, 3)}이고, Table I의 (15, 9)와 맞습니다. w/o VQ 33.3과 w/o Gating 46.7도 각각 네·다섯 조합이 가능합니다.
  - Plug 25회 + Wiping 15회를 합치면 차이 −13.3pp(게이트)는 약 5-6회 차이입니다.
  - Full 24/40 대 w/o Gating 18-20/40을 단순 비교하면 Fisher p = 0.26-0.50입니다(조합에 따라 다름).
  - w/o VQ 33.3은 같은 두 과제의 T-UniT 평균 32.7과 거의 같습니다.
- **Table III:** 교란 없는 Table I 칸 대비 하락폭은 다음과 같습니다. 방법 사이 차이가 교란 전의 차이와 같습니다. 같은 방법 안에서도 교란 전후 차이는 Fisher p ≥ 0.22로 구분되지 않습니다.
  - Dynamic: 모두 −13.3
  - Height −: 모두 −20.0
  - Height +: π0.5와 T-UniT는 오히려 +13.3, ResTacVLA는 −6.7
  - Grasp: −12, −12, −8

5. VQ 병목의 정보량

정책이 받는 촉각은 코드 index q_t 하나를 선형 투영한 토큰입니다. 그래서 프레임당 정보는 많아야 $\log_2 K$ 비트입니다($K = 64$면 6비트, 512면 9비트). 접촉 위치, 방향, 힘 크기를 모두 이 index 하나에 담아야 합니다. Plate Wiping처럼 연속적인 힘 조절이 필요한 과제에서는 K단계 양자화가 해상도 상한이 됩니다.

Table II에서 VQ를 빼면 성능이 떨어지므로, 이 병목은 잡음 제거로서는 이득입니다. 다만 초록의 "희소 촉각을 조밀한 정보 이득으로 바꾼다"와는 방향이 반대입니다. 정책이 받는 것은 **조밀한 신호가 아니라 이산 사건 라벨**입니다. K와 코드 사용률이 없어서 이 상한을 계산할 수는 없습니다.

추가 검증 (2026-11-11)

추가 검증 1: 행동 손실만으로 학습한 게이트는 드문 예상 밖 충돌을 여는가

목적. §2.2에서 σ 게이트가 예상 밖 충돌을 못 본다는 것을 확인했다. 여기서는 게이트를 행동 손실만으로 학습할 때(논문 Sec. III-C), 학습 데이터의 충돌 비율(1-20%)에 따라 충돌 구간에서 게이트가 열리는지, 보조 감독(게이트 라벨의 BCE)과 입력(σ만, σ와 예측 오차)을 바꾸면 달라지는지 본다.

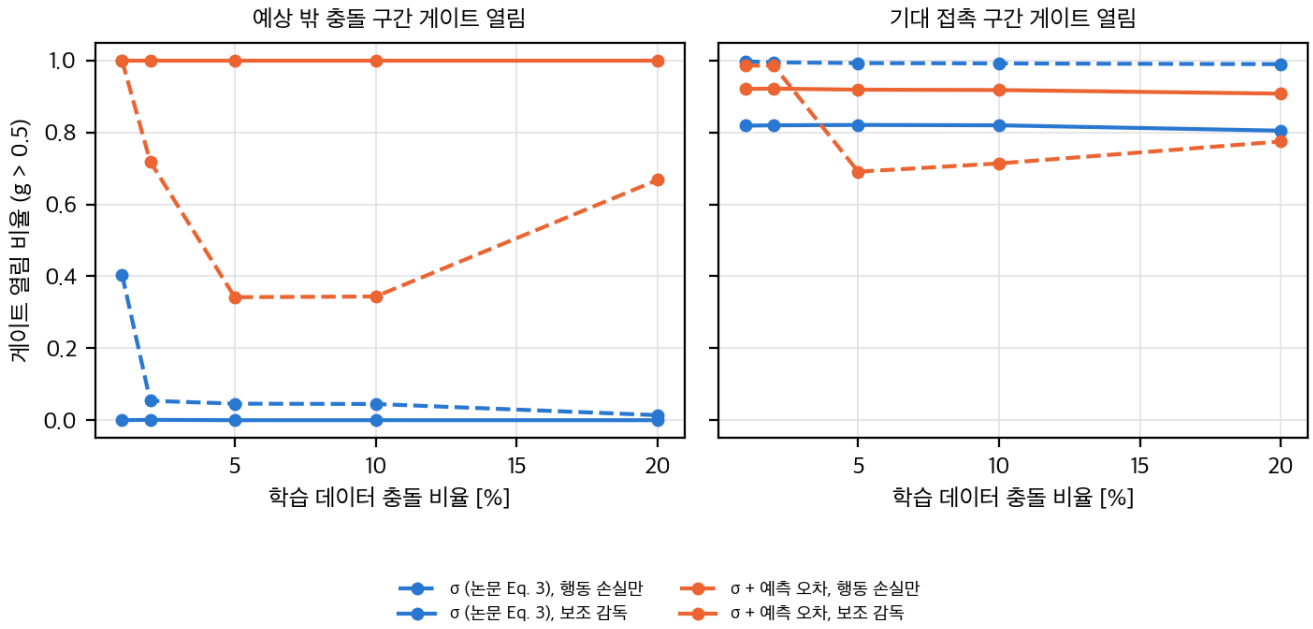
설정. `analysis/extra_gate_rare.py` (numpy, 약 3분, 단일 스레드). `gate_toy.py`의 에피소드(200스텝, 접촉 시작 ≈120, 충돌은 접촉 전 20-90 스텝 사이 6스텝)와 CMP(분위수 구간 평균)를 그대로 썼다.

- 게이트: g = Sigmoid(MLP(입력)), MLP는 2→4→1(tanh). 입력은 log σ(논문 Eq. 3) 또는 [log σ, log 예측 오차]. 입력은 학습 데이터로 표준화한다.
- 정책: $p = w_0 + w_1 \cdot v + w_2 \cdot g \cdot \| z \| + w_3 \cdot g \cdot \| z \| \cdot v$. 처음에는 w_3 항이 없었는데, 그때는 게이트를 완전히 열어도 충돌 구간 출력이 후퇴 쪽으로 내려가지 않아서 상호작용 항을 추가했다.
- 행동 목표 a*: 기대 접촉 +1(밀기), 예상 밖 충돌 −1(후퇴), 그 밖 0. 손실은 행동 MSE다. 보조 감독 변형은 여기에 "접촉 또는 충돌" 라벨의 BCE(가중 1)를 더한다.
- 학습: 에피소드 200개, Adam 800스텝, 학습률 0.03. 시험은 에피소드 200개이고 절반에 충돌을 넣었다. 시드 3개(표준편차를 표에 같이 적었다).

결과. 시험 구간에서 게이트 값 g > 0.5인 비율.

게이트 입력	학습	충돌 1%	2%	5%	10%	20%	기대 접촉 (1%→20%)
σ (논문 Eq. 3)	행동 손실만	0.41	0.05	0.05	0.04	0.01	1.00 → 0.99
σ (논문 Eq. 3)	보조 감독	0.00	0.00	0.00	0.00	0.00	0.82 → 0.81
σ + 예측 오차	행동 손실만	1.00	0.72	0.34	0.34	0.67	0.99 → 0.78
σ + 예측 오차	보조 감독	1.00	1.00	1.00	1.00	1.00	0.92 → 0.91

- 행동 손실만 쓴 σ+오차 게이트의 충돌 열림 비율은 시드 간 표준편차가 0.40-0.47로 컸다(1%만 0.00). 충돌 비율과 단조 관계가 없었다.
- 후퇴 반응(정책 출력 < −0.5)은 어떤 조건에서도 0%였다. 게이트를 강제로 열어도(g = 1) 충돌 구간 출력은 대체로 0.3-2.7의 양수(밀기) 쪽이었다. 이 정책 형태로는 후퇴를 표현하기 어렵다. 그래서 "충돌에 반응한다"는 행동 수준의 결론은 이 toy에서 내리지 못했다.



직접 그림(추가 검증 1): 학습 데이터 충돌 비율에 따른 시험 구간 게이트 열림 비율(g > 0.5). 왼쪽은 예상 밖 충돌, 오른쪽은 기대 접촉 구간이다. 시드 3개.

결론.

- σ 게이트는 행동 손실만으로도, 보조 감독을 주어도 충돌을 거의 열지 못했다. 입력에 충돌 정보가 없어서이고, 감독은 이를 바꾸지 못한다. §2.2의 "구조적 한계" 결론과 맞는다.
- 예측 오차를 입력에 더하면 보조 감독이 있을 때 충돌 열림이 시험 전 구간에서 1.00이었다. 행동 손실만으로는 충돌 비율에 따라 0.34-1.00으로 흔들렸다. 드문 사건을 행동 손실에만 맡기면 신뢰할 수 없다는 §2.2의 우려와 맞는다.
- 한계: 시드 3개, 정책은 선형 + 한 개의 상호작용 항이다. 충돌 비율 효과를 단조 곡선으로 말하기에는 분산이 너무 크다. 그리고 후퇴 반응을 제대로 재려면 정책 표현력을 먼저 키워야 한다.

추가 검증 2: 비선형 CMP와 VQ 병목에서 잔차 대 원시 촉각

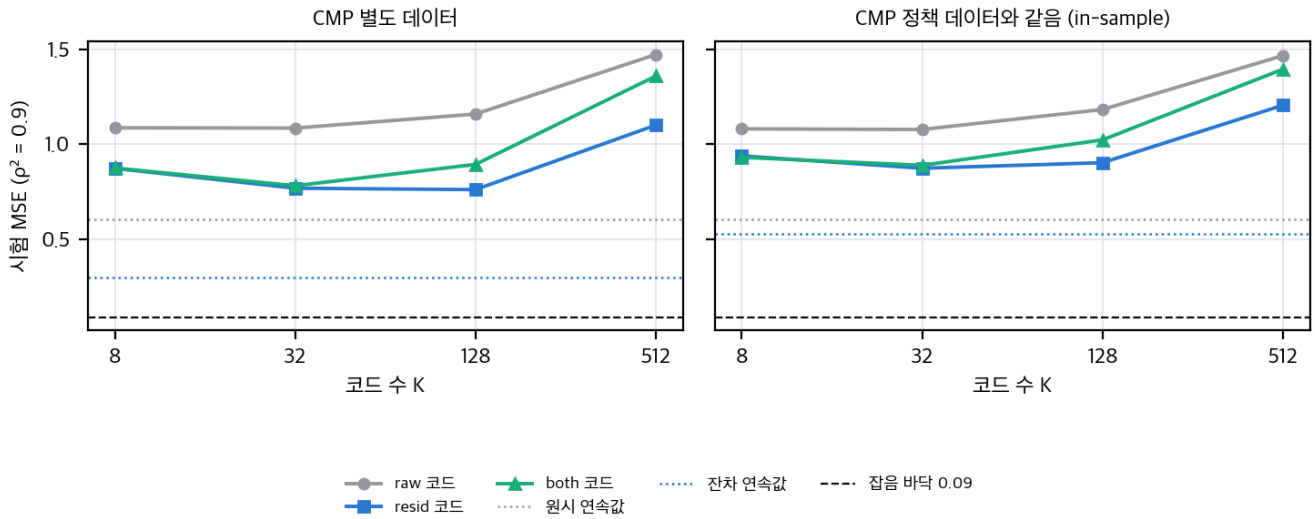
목적. §3.2의 선형 toy 결론(잔차 이득은 CMP가 별도 데이터로 정확하고 시각 차원이 클 때만 나온다)이 비선형 CMP와 VQ 병목(§5)에서도 유지되는지 본다. K에 따른 힘 해상도 손실도 함께 본다.

설정. `analysis/extra_residual_vq.py` (numpy, 약 100초, 단일 스레드).

- 세계: 시각 $v \in R^{256}$, 촉각 $z \in R^{8} = \sqrt{\rho^2}\cdot p(v) + \sqrt{(1-\rho^2)}\cdot u$. p(v)는 tanh 비선형 함수(표준화). 행동 y = w_v·v + w_u·u + 잡음(0.3).
- CMP: MLP 256→32→8(tanh), 전체 배치 Adam 800스텝, 가중치 감쇠 0.1. 감쇠 없이 학습하면 과적합해서(시험 MSE 0.91, 이상적 0.5) 감쇠를 넣었다. 감쇠를 넣은 뒤 단일 시드 점검에서 시험 MSE는 0.55였다.
- CMP 데이터: 별도 5000개, 또는 정책 데이터와 같은 600개(in-sample).
- 정책: 표준화한 ridge(λ는 검증 세트 300개로 선택). 학습 600개, 시험 3000개, 시드 5개. 원시 입력 [v, z], 잔차 입력 [v, r = z − ẑ], VQ 입력은 k-means 코드북(K = 8, 32, 128, 512)의 one-hot이다. 코드북은 정책 학습 데이터의 비지도 특징으로 적합했다.
- 잡음 바닥은 0.09다.

결과. 시험 MSE(시드 5개 평균). 괄호는 잔차 − 원시의 짝지은 차이(시드 5개 중 잔차가 이긴 수).

ρ^2	CMP	연속값: 원시 / 잔차	VQ 8: 원시 / 잔차	VQ 128: 원시 / 잔차	VQ 512: 원시 / 잔차
0.5	별도 5000	0.233 / 0.194 (−0.04, 5/5)	0.952 / 0.831 (−0.12, 5/5)	0.874 / 0.674 (−0.20, 5/5)	1.296 / 0.989 (−0.31, 5/5)
0.5	in-sample 600	0.233 / 0.693 (+0.46, 0/5)	0.958 / 0.919 (−0.04, 5/5)	0.866 / 0.845 (−0.02, 4/5)	1.284 / 1.091 (−0.19, 5/5)
0.9	별도 5000	0.606 / 0.300 (−0.31, 5/5)	1.087 / 0.873 (−0.21, 5/5)	1.159 / 0.761 (−0.40, 5/5)	1.472 / 1.100 (−0.37, 5/5)
0.9	in-sample 600	0.606 / 0.529 (−0.08, 5/5)	1.081 / 0.939 (−0.14, 5/5)	1.183 / 0.903 (−0.28, 5/5)	1.467 / 1.205 (−0.26, 5/5)



직접 그림(추가 검증 2): ρ^2 = 0.9에서 코드 수 K에 따른 시험 MSE. 가로선은 연속값 입력이다. 점선 검은 선은 잡음 바닥 0.09다.

결론.

- 별도 CMP에서는 비선형 CMP와 VQ 병목 모두에서 잔차가 원시보다 나았다(VQ 전 구간, 시드 5/5). 선형 toy의 "별도 CMP + 시각이 클 때 잔차가 이긴다"와 방향이 같다.
- in-sample CMP의 결론은 조건에 따라 다르다. ρ^2 = 0.5의 연속값에서는 잔차가 크게 졌다(+0.46). 그러나 ρ^2 = 0.9와 VQ 입력에서는 잔차가 여전히 이겼다. 선형 toy에서 "in-sample CMP면 모든 ρ^2에서 진다"던 결론은 비선형 CMP와 VQ에서는 그대로 유지되지 않았다.
- VQ는 K가 커질수록 개선되지 않았다. K = 512에서는 600개 데이터에 비해 코드가 너무 많아 오히려 나빠졌다. 잔차 VQ는 K = 32-128에서 가장 나았고(MSE 0.67-0.77), 연속값 잔차와의 차이(0.4-0.5)가 남았다. 힘 해상도 손실은 이 데이터 규모에서 K에 따라 커졌다.
- 한계: 정책 데이터가 600개로 시각 차원(256)보다 적다. 그래서 MSE는 잡음 바닥(0.09)보다 한참 위에 있고, 차이의 상당 부분은 추정 분산일 수 있다. ρ^2 = 0.9의 원시 연속값(0.61)이 ρ^2 = 0.5(0.23)보다 나쁜 이유도 이 toy로는 구분하지 못했다. 실물 데이터의 CMP 일반화 오차는 여전히 보고되지 않았다.

04. 주장 검증: 표 재계산, toy, 구현 가능성

- **대상:** arXiv:2607.03387v3, 프로젝트 페이지(https://awilekong.github.io/ResTacVLA/), 웹페이지 저장소 `Awilekong/ResTacVLA` @ `09cdbcb`.
- **코드:** 공개되지 않았습니다("Code coming soon", 2026-11-09 확인). 그래서 논문 ↔ 코드 대조(D 항목) 대신 다음 두 가지를 했습니다.
  - 표 재계산: `analysis/table_check.py`
  - 핵심 가정의 numpy toy: `analysis/gate_toy.py`

1. 주장별 판정

#	주장 (출처)	재계산·점검	판정
C1	"최대 86.7% task success" (Sec. I 기여 3)	86.7은 Peg-in-Hole의 **정렬(A)** 칸(13/15). 과제 완료 기준 최고값은 Peg-in-Hole I 80.0(12/15)	⚠️ 정렬을 과제 성공으로 표기
C2	모든 기준선을 다섯 과제 모두에서 일관되게 앞선다 (Abstract, Sec. IV-B)	Peg Transfer에서 T-UniT 10/15(66.7, 표에서 굵게)가 ResTacVLA 9/15(60.0, 밑줄)보다 높음. 나머지 7칸은 1위	❌ 논문 표와 모순
C3	평균 34.6% 향상 (Sec. I), π0.5 대비 +34.6, DP 대비 +44.0 (Sec. IV-B)	숫자는 맞음(62.8 − 28.2, 62.8 − 18.8). 단위는 pp이고, A·I를 섞은 8칸 평균. 최강 기준선 T-UniT 대비 +20.5pp, 과제 성공 5과제 평균으로는 +18.9pp	✅ 수치 / ⚠️ 비교 대상 선택
C4	표준 VLA와 naive 촉각 융합을 "유의하게" 앞선다 (Sec. I)	논문에 통계 검정 없음. π0.5 대비 5과제 CMH $p = 4.7\times10^{-7}$. T-UniT 대비 과제별 Fisher p = 0.088-1.00(유의 0개), 합산 CMH p = 0.0039	✅ π0.5 / ⚠️ T-UniT는 합산으로만
C5	잔차를 명시적으로 모델링하는 것이 필수다 (Sec. IV-B)	잔차 대 원시 ablation 없음. 연속 잔차(w/o VQ) 33.3 ≈ 같은 두 과제 T-UniT 32.7. toy에서는 잔차의 득실이 CMP 일반화와 차원/데이터 비에 달림(`03` §3)	❓ 분리되지 않음
C6	ResNet 촉각은 Lightbulb 성능을 떨어뜨린다 (28.0 → 16.0) (Sec. IV-B)	Lightbulb-A 7/25 대 4/25, Fisher p = 0.50	⚠️ 잡음 수준
C7	예상 밖 동적 교란에 강건하다 (Abstract, Sec. IV-E)	교란 없는 칸 대비 하락폭이 방법 사이에 같음(Dynamic 모두 −13.3, Height− 모두 −20.0). 방법 안 교란 전후 Fisher p ≥ 0.22	⚠️ 표는 교란 전 성능 차이를 보여 줌
C8	σ_t는 cross-modal surprise의 원리적 척도다 (Sec. III-B-1)	Eq. 1의 최적 σ는 $E[\|z-\mu\|^2 \mid v]/\lambda_\sigma$의 제곱근으로, 손목 영상만의 함수(aleatoric). 실제 촉각의 예측 오차는 들어가지 않음	❌ surprise / ✅ 불확실성
C9	접근 중 g ≈ 0, 접촉하면 "빠르게 포화" (Sec. IV-C)	Fig. 5 판독: 접근 0.11-0.14, pre-contact 약 0.35(접촉 전 상승), 최고 약 0.78. 캡션은 "점진적 상승". 시행 1개	⚠️ 본문과 그림·캡션 불일치
C10	contact primitive가 예상 밖 충돌을 잡는다 (Fig. 4)	정성 t-SNE뿐. 점이 연속적으로 흩어져 양자화 전 h_t일 가능성. 정책 쪽 게이트는 자유 공간에서 닫힘(toy에서 σ 게이트 충돌 열림 0%)	❓ 정책까지 전달 미확인
C11	잔차 표현은 구조 무관하게 효과가 있다(DP +19.2) (Sec. IV-B)	수치 맞음(38.0 − 18.8). DP + 원시 촉각 칸이 없어 촉각 자체의 효과와 구분 불가. 과제별 p = 0.14-0.50, 합산 5.6×10^{-4}	⚠️ 비교군 빠짐
C12	VQ 제거 −26.7, 게이트 제거 −13.3 (Table II)	Full 60.0과 π0.5 20.0은 Table I과 일치. 두 과제 평균이라 과제별 값은 여러 조합. 게이트 차이는 40회 중 약 5-6회, Fisher p = 0.26-0.50	✅ 정합 / ⚠️ 유의 미확인

#	주장 (출처)	재계산·점검	판정
C13	시각 정책은 정렬은 되고 상호작용에서 무너지며, ResTacVLA는 상호작용 내내 유지된다 (Sec. IV-B)	T-UniT 대비 완료 이득의 74%(log)가 정렬 성공률 차이. P(IIA) 차이는 p = 0.28	⚠️ 이득은 주로 정렬 단계
C14	저자·판본	v1 → v2: 날짜 표기만. v2 → v3: Ce Hao 3번째 → 5번째. 프로젝트 페이지는 v1 순서	ℹ️

2. 재현에 필요한데 논문에 없는 정보

항목	영향
λ_σ, λ_p, H′·W′, ẑ_t 정의(μ 또는 표본)	σ의 배율과 잔차 정의가 정해지지 않음
코드북 K, 차원 D, 코드 사용률	정책이 받는 촉각 정보의 상한($\log_2 K$ 비트)을 모름(`03` §5)
게이트 MLP 크기, g 분포 통계(시행 여럿)	Fig. 5가 대표적인지 알 수 없음
CMP 학습 데이터와 정책 데이터의 관계, CMP 시험 오차	toy에서 잔차 득실을 가르는 변수(`03` §3.2)
기준선의 촉각 주입 위치, 학습 설정, 조율 방법	T-UniT와의 차이를 무엇에 돌릴지 모름
행동 chunk H, 학습 step·batch, LoRA 여부, 추론 지연·주파수	재학습과 실시간성 판단 불가
시드, 반복, 시행 순서, 시행별 기록	유의성·분산 평가 불가
교란 조건 시행 수	Table I과 같다고 가정(모든 값이 정수로 맞음)

3. 권리 표기

- arXiv 라이선스는 nonexclusive-distrib 1.0입니다. abs 페이지에 Creative Commons 링크가 없습니다. 따라서 CC BY가 아닙니다.
- arXiv PDF(v3)에는 IEEE 저작권 문구나 "personal use permitted" 같은 권리 표기가 없습니다. "IEEE"는 참고문헌에만 나옵니다. IROS 2026 최종본(IEEE)에는 IEEE 저작권이 붙을 가능성이 높습니다.
- 그래서 논문 그림은 개인용 리포트·PPT에만 쓰고, 게시본에는 직접 그린 그래프만 넣었습니다.

4. 구현할 수 있는지

4.1 공식 코드로 재현

불가능합니다. 코드, CMP·정책 가중치, 시연 데이터가 공개되지 않았습니다("coming soon", 2026-11-09 확인). 하드웨어도 필요합니다: Franka FR3, Robotiq 2F-85, 손가락 하나의 GelSight Mini, RealSense D435 세 대, 과제 물체 다섯 세트, 과제당 시연 약 100개(촉각 영상을 보며 텔레옵).

4.2 이 맥(Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음)에서

단계	판단
표 재계산, 게이트·잔차 toy	✅ 완료(numpy 1스레드, 30초)
CMP(ResNet-18 + UniT 인코더 + event encoder + VQ + FiLM decoder) 학습	조건부. 모델이 작아(수천만 파라미터 이하로 추정) MPS로 충분해 보임. torch 설치 승인과 **(손목 영상, 촉각 영상) 쌍 데이터**가 필요. UniT 공개 데이터(Google Drive)에 정책 시연이 있으나 손목 영상 포함 여부는 확인 안 함

단계	판단
π0.5 추론	불확실. openpi는 Ubuntu 22.04만 지원한다고 명시하고, 추론에 8 GB 이상 필요. MPS 동작은 확인되지 않음
π0.5 미세조정	**불가.** LoRA는 22.5 GB 이상이고 JAX 경로에서만 지원(PyTorch 경로는 LoRA 미지원). 전체 미세조정은 70 GB 이상
작은 대체 정책(DP·flow, 수천만 파라미터) + 게이트 토큰	조건부. torch(MPS) 설치와 촉각 데이터 또는 촉각 시뮬레이터 필요. 흔한 GPU 촉각 시뮬레이터(Isaac 기반)는 CUDA가 필요해 이 맥에서 불가
실물	불가. 하드웨어 필요

4.3 아이디어만 다시 구현

쉽습니다. 핵심은 기존 정책에 세 부분을 붙이는 것입니다.

- CMP 손실(Eq. 1): 수십 줄
- 잔차 VQ(EMA, 죽은 코드 재초기화): 백여 줄
- 게이트 토큰(Eq. 3-4)을 action expert 입력에 붙이기: 수십 줄

openpi나 Diffusion Policy 위에 수백 줄이면 됩니다. 장벽은 세 가지입니다.

1. **촉각 하드웨어와 시연 데이터:** GelSight Mini와 촉각을 보며 하는 텔레옵
2. **π0.5를 쓰려면 24 GB급 CUDA GPU:** 논문은 RTX 4090 하나
3. **CMP 일반화:** toy에서 CMP를 정책 데이터로 학습하면 잔차가 오히려 손해였습니다. CMP용 데이터를 따로 두거나 시험 오차를 확인해야 합니다

재구현할 때는 논문의 빈칸 두 가지를 같이 채우는 편이 좋습니다. 하나는 **게이트 입력에 실제 예측 오차 $\|z - \mu\|^2$를 넣는 것**이고, 다른 하나는 **잔차 대 원시 ablation**입니다. 첫째는 toy에서 예상 밖 충돌 검출이 0% → 100%로 바뀌었습니다.

02. 선행연구와 관계

1. 계보

갈래	대표 연구	ResTacVLA가 가져온 것
Predictive coding, 감각 약화	Rao & Ballard 1999 [13], Friston 2010 [14], Wolpert 1998(간지럼) [15], Kilteni & Ehrsson 2022 [12]	"예측 가능한 입력은 약화하고 예측 오차에 주의를 준다"는 동기. [12]는 예측적 약화와 촉각 gating이 **서로 다른** 현상이라고 보고합니다. 논문은 둘을 한 장치(σ 게이트)로 묶습니다
이분산 불확실성	Kendall & Gal 2017 [28]	Eq. 1의 NLL, 스칼라 σ_t. 원 논문에서 이 σ는 "입력에 내재한 잡음"(aleatoric)입니다
이산 표현 학습	VQ-VAE [29], ViT-VQGAN [30], VQ-VAE-2 [31], SoundStream [32]	코드북, 저차원 코사인 코드, EMA, 죽은 코드 재초기화
조건부 변조	FiLM [33]	q_t로 예측 사전 ẑ_t를 변조해 촉각을 복원
VLA 바탕	π0 [1], π0.5 [2], PaliGemma [27], flow matching [26]	정책 본체와 action expert 주입 위치
촉각 표현	UniT [21](VQVAE 기반, RA-L 2025), Sparsh [20]	촉각 인코더. 기준선 T-UniT도 같은 인코더
시각→촉각 교차 예측	Li et al. 2019 "Connecting Touch and Vision via Cross-Modal Prediction"(arXiv:1906.06322, **인용 안 됨**)	영상에서 촉각을 예측하는 CMP의 직접적 선행

2. 가까운 대안

2.1 촉각·힘을 넣은 VLA·정책 (논문 Sec. II-C)

- **촉각을 토큰으로 넣는 VLA:** VLA-Touch [7], VTLA [8], TLA [19], Tactile-VLA [25]. 논문은 이들이 촉각을 "보조 시각 특징"으로 다뤄 modality collapse를 겪는다고 봅니다. 하지만 이 논문 표에 이들과의 직접 비교는 없습니다. 비교한 촉각 기준선은 π0.5 + ResNet·UniT 인코더 두 개입니다.
- **언어로 정렬:** Beyond Sight [6]은 이종 센서를 언어 grounding으로 미세조정합니다. VITaL·"Touch begins where vision ends" [22]은 대조 학습으로 촉각을 시각·언어 공간에 맞춥니다. 논문은 정렬이 촉각 고유의 잔차 정보를 지운다고 비판합니다(Sec. II-B).
- **힘·토크:** ForceVLA [23](힘 인지 MoE), TA-VLA [24](토크 인지 설계 공간). 손목 F/T는 접촉 기하를 잃는다는 이유로 촉각과 구분합니다.
- **모달리티 불균형:** Chaudhuri et al. [9](표현 붕괴), multi-modal policy consensus [10], ImplicitRDP [11].

2.2 논문이 인용하지 않은 가까운 연구

- **FoAR** (He et al., arXiv:2411.15753, RA-L 2025)는 미래 접촉 예측기가 힘 특징의 주입을 조절합니다. "접촉 국면에서만 비시각 신호를 쓰는 gating"이라는 점에서 SAG와 가장 가까운 선행입니다. 다만 FoAR의 게이트는 시각과 힘 신호 둘 다에서 접촉을 예측합니다.
- **Reactive Diffusion Policy** (Xue et al., arXiv:2503.02881)는 촉각·힘으로 빠른 루프를 따로 돌리는 slow-fast 구조입니다. ImplicitRDP [11]의 전작입니다.
- **Connecting Touch and Vision** (Li et al., arXiv:1906.06322)는 위 §1 표에 적었습니다. 이 연구가 영상에서 촉각을 예측한 지 7년이 지났는데, 예측 오차 자체를 정책 입력으로 쓴 것이 ResTacVLA의 새 점입니다.

2.3 구성 요소별 출처

구성 요소	출처	이 논문에서 새로운 점
영상 → 촉각 잠재 예측	[1906.06322], [28]	정책 입력을 예측 오차(잔차)로 바꿈
잔차 VQ + FiLM 복원	[29-33]	예측 사전을 조건으로 잔차 코드만 학습
σ 게이트 + 학습되는 기본 토큰	[28], FoAR와 유사	게이트 입력이 σ 하나뿐
action expert 토큰 주입	π0.5 [2]	VLM 쪽을 건드리지 않음

3. 이 저장소의 다른 논문과의 관계

폴더	공통점	차이와 시사점
`gpt6_astra_tactile/`	삽입 과제에서 촉각의 몫을 따짐	그 폴더에서 반사실 촉각(거울 반전)으로 "정책이 촉각을 실제로 쓰는가"를 시험했습니다. ResTacVLA에는 이런 시험(촉각 섞기·제거, 게이트 고정)이 없어서, 이득이 촉각 정보에서 오는지 확인할 수 없습니다
`contact_grounded_policy/`	촉각을 **예측**한다	CGP는 미래 촉각을 예측해 제어 목표로 쓰고, ResTacVLA는 현재 촉각을 영상으로 예측해 빼는 기준선으로 씁니다. CGP 분석에서 "잡음 강건성 과장"을 찾았는데, 여기 Table III도 교란 하락폭이 방법 사이에 같아 같은 패턴입니다. 두 논문 모두 CC BY가 아닙니다
`dexforce/`	접촉 과제, 소수 시연	DexForce는 측정한 힘을 행동 목표(x_f = x_o + k_f f)에 넣습니다. ResTacVLA는 촉각을 조건으로만 쓰고, Plate Wiping의 "힘 조절"을 위치 행동만으로 합니다. 높이 −2 cm에서 세 방법이 모두 −20pp 떨어진 것은, 촉각이 있어도 힘 목표가 없으면 높이 오차를 보정하지 못한다는 해석과 어긋나지 않습니다(확인은 안 됨)
`reactive_grasp/`	영상·기하로 접촉을 예상	그 논문은 메쉬와 추적 자세로 접점을 **해석적으로** 계산합니다(촉각 없음). CMP의 μ_t는 같은 "시각적 접촉 기대"를 학습으로 근사한 것이고, 잔차는 그 기대가 틀린 부분입니다
`nestdex/`	소표본 성공률 비교	같은 통계 도구(Fisher, Holm, MH)를 썼습니다. NestDex의 effort, 여기의 잔차 크기 모두 접촉 사건 신호로 쓸 수 있습니다
`pacevla/`	VLA의 action expert만 바꿈	PaceVLA는 GR00T action expert에 decoder를 여러 개 달고, 라우터가 국면에 따라 고릅니다. ResTacVLA의 국면 의존 게이트와 같은 발상입니다. 둘 다 국면 판단을 영상에서 합니다
`thinkworld/`	예측 → 비교	ThinkWorld는 1초 뒤 DINO 특징을 예측하고, 예측-관찰 일치를 RL 보상으로 씁니다. ResTacVLA는 예측-관찰 차이(잔차)를 입력 특징으로 쓰지만 게이트는 오차가 아니라 σ로 엽니다. predictive coding을 표방하는 두 방식 중 ThinkWorld가 실제로 오차를 쓰는 쪽입니다

4. GitHub (2026-11-09 확인)

저장소	무엇인가	공식 여부	커밋	라이선스
`Awilekong/ResTacVLA`	프로젝트 웹페이지(`docs/index.html`, JS, CSS)만 있음. 코드 없음("Code coming soon", "Data coming soon")	공식	`09cdbcb` (2026-08-06, 커밋 5개)	표기 없음
`ZhengtongXu/UniT`	촉각 인코더 [21]. VQVAE 표현 학습 코드와 데이터(Google Drive)	구성 요소 공식	`52a2865` (2025-04-16)	MIT

저장소	무엇인가	공식 여부	커밋	라이선스
`Physical-Intelligence/openpi`	π0.5 [2] JAX·PyTorch 구현. LoRA 미세조정은 JAX에서만	구성요소 공식	`215abfb` (2026-08-24)	Apache-2.0
`real-stanford/diffusion_policy`	DP 기준선 [34]	구성요소 공식	`5ba07ac` (2024-12-24)	MIT
`gelsightinc/gsrobotics`	GelSight Mini SDK	하드웨어 공식	`321d6a2` (2025-06-25)	GPL-3.0
`facebookresearch/sparsh`	대안 촉각 SSL [20]	관련	`fee6a05` (2025-02-27)	저장소 표기 NOASSERTION

`ResTacVLA` 이름으로 GitHub를 검색하면 웹페이지 저장소 하나만 나옵니다. 공식 코드가 없으므로 clone하지 않았고, 04는 주장 검증(`04_claim_verification.md`)으로 썼습니다.