# RPD (Refined Policy Distillation): 분석 리포트

arXiv:2503.05833v2 (2025-08-04) · IROS 2026 채택 · 공식 저장소 Refined-Policy-Distillation/RPD (Apache-2.0, 커밋 10becdf) · 분석일 2026-11-11 · 게시용 버전: 논문 그림과 원문 PDF는 라이선스(arXiv 비독점 배포) 때문에 뺐습니다.

## 핵심 요약

1. **무엇을 하는가:** PPO의 행동 평균을 VLA 교사의 행동 샘플에 제곱 오차로 당기는 항 하나를 더합니다(식 3, 5). 가중치는 1입니다(`01` §3).
2. **빠르게 수렴하는 것은 맞고, 최종 성공률은 PPO와 비슷합니다:** PickCube에서 0.5 도달은 약 6배 빠르고(약 0.15 대 0.9 ×10^7), 끝 시점 차이는 약 0.08입니다(`01` §5.1, `03` §3).
3. **유의성 검정이 불가능하고 근사도 경계선입니다:** 시드 5개, 곡선 음영뿐입니다. 근사 Welch p ≈ 0.025, 80% 검정력의 최소 차이는 약 0.10입니다(`03` §3).
4. **교사 질의는 스텝당 8회입니다:** 논문은 "한 샘플"이라고 쓰지만 코드는 에폭마다 질의합니다. 환경 스텝만 세는 샘플 효율에는 이 비용이 빠집니다(`04` D3, `03` §4.6).
5. **고정점에 교사 편향이 남습니다:** 상수 λ에서 $\mu_{fix} - \mu^* = [\lambda_e/(\kappa/2 + \lambda_e)](\bar{t} - \mu^*)$. κ는 논문에 없어서 편향 크기를 모릅니다(`03` §4.5).
6. **토이가 편향 공식을 확인합니다:** 편향 교사 0.204 대 이론 0.200, 무관 교사 -0.507 대 -0.500. 교사가 없으면 희소 보상은 학습되지 않습니다(`03` §5).
7. **무관 교사 대조가 없습니다:** "낮은 성공률 교사도 방향을 준다"는 해석을 검증하지 않았습니다. 토이에서는 무관 교사가 상수 λ에서 학습을 막습니다(`03` §5.4).
8. **코드와 논문의 차이:** 교사 질의 빈도(D3), MSE 정규화(D2), 하이퍼파라미터 설명(D9), 의존성 미고정과 현재 vlagents와의 불일치(D16)가 있습니다(`04` §2).
9. **구현 가능성:** 공식 재현은 NVIDIA GPU와 `agents` 2025 상태 고정이 있을 때만 가능합니다. 이 맥에서는 불가입니다(`04` §4).
10. **라이선스:** arXiv 비독점 배포이고 PDF 첫 쪽에 재사용 고지가 없습니다. 논문 그림은 이 개인 리포트에만 넣었습니다(`01` §0).

# 01. 논문 분석: Refined Policy Distillation (RPD)

## 0. 메타

- **제목:** Refined Policy Distillation: From VLA Generalists to RL Experts
- **저자:** Tobias Jülg, Wolfram Burgard, Florian Walter (University of Technology Nuremberg, 로봇 학습 연구실)
- **arXiv:** 2503.05833. 분석 대상은 **v2** (2025-08-04). v1 (2025-03-06)과의 차이는 §7.
- **학회 상태:** IROS 2026 채택 (arXiv 댓글 "accepted for publication at IROS 2026"). 본문 PDF에는 채택 문구가 없습니다.
- **분량:** PDF 8쪽. 본문은 1-7쪽, 8쪽은 결론과 참고문헌입니다. 메모의 "6쪽"은 IROS 열 형식의 본문 분량으로 보이며 PDF 쪽수와 다릅니다.
- **라이선스:** arXiv 비독점 배포 1.0 (`nonexclusive-distrib/1.0`, abs 페이지 확인). CC 라이선스가 아닙니다. **PDF 첫 쪽에 저작권 고지나 재사용 조건은 없고** arXiv 스탬프("arXiv:2503.05833v2 [cs.RO] 4 Aug 2025")만 있습니다. 따라서 논문 그림은 개인용 리포트와 PPT에만 넣고, 공개본에는 우리가 그린 그래프만 넣습니다.
- **공개 자료:** 공식 코드 (Apache-2.0), Octo와 OpenVLA의 ManiSkill 파인튜닝 체크포인트 (HF, MIT), RLDS 데이터셋 (HF, Apache-2.0). 프로젝트 페이지 refined-policy-distillation.github.io.

## 1. 한 문단 요약

PPO 학생 정책의 행동 평균 μ(s)를 VLA 교사의 행동 샘플 ā(s)에 제곱 오차로 당기는 항을 PPO 손실에 하나 더한 방법입니다 (Eq. 3, 5). 가중치는 1로 고정합니다. 교사는 ManiSkill3의 인간 카메라(힌트 포함) RGB로 RL 시연을 써서 파인튜닝한 Octo(93M)와 OpenVLA(7B)입니다. 8개 과제 중 6개 학습 과제에서 dense와 sparse 보상 모두 PPO보다 빨리 올라가고, 대부분 과제에서 희소 보상 PPO가 실패하는 설정에서 RPD는 성공합니다. 최종 성공률은 PickCube에서 PPO와 비슷하고(약 80% 대 약 72%, 읽음), 교사가 0%인 카메라 변경 PushCube에서도 RPD는 PPO보다 높습니다. 시뮬레이션만 다룹니다.

## 2. 문제와 동기 (§I)

- VLA는 일반화가 좋지만 성공률이 전문가 정책에 못 미치고, 설정이 바뀌면 파인튜닝이 필요합니다(§I, 두 번째 문단).
- RL은 샘플이 많이 들고, 보상과 하이퍼파라미터에 민감합니다(§I, 네 번째 문단).
- 제안은 "교사가 약해도 교사 행동의 방향이 탐색을 안내한다"입니다(§I, 세 번째 문단 끝, §IV-D).

## 3. 방법 (§III-A)

### 3.1 목적 함수

- 식 (3): L_RPD(θ) = L_RL(θ) – L_MSE(θ). L_RL은 PPO 클리핑 목적(식 4), L_MSE는 식 (5)입니다.
- 식 (5): L_MSE = E_t[ (μ(π_θ(a_t|s_t)) – E_{a_VLA}[a_VLA])² ]. 기댓값은 교사 분포에 대한 것이며, 논문은 **상태당 교사 행동 한 개**로 추정하면 충분하다고 씁니다(§III-A, "a single VLA action per step").
- 식 (6)은 θ*를 목적 최대화로 정의합니다. L_MSE 앞의 음수 부호는 PPO 목적을 최대화하고 MSE를 최소화한다는 뜻입니다.
- 논문은 MSE 항의 가중치를 명시적으로 1로 두지만, 식 (3)에는 가중치 기호가 없습니다. 코드는 `ppd_lambda = 1.0`으로 상수 가중치를 씁니다(`04` D1, D5).

### 3.2 변형

- **RPD-MSE:** 주 방법, 식 (3).

- **RPD-L1:** MSE를 L1로 바꿉니다.
- **RPD-BC:** 식 (2)의 최대우도(가우시안 음의 로그우도, 학습되는 분산 포함)를 씁니다.
- **PPD (비교용, 자체 구현):** KL 기반 Proximal Policy Distillation [23]. 교사 분포를 교사 행동 10개로 다변량 가우시안에 맞춰 KL을 계산합니다(§IV-A). 공식 구현은 없습니다.

## 4. 실험 설계 (§III-B, §III-C, §IV)

- **과제:** ManiSkill3의 8개 과제 (Table I). 학습 데이터에 든 6개(LiftPegUpright, PickCube, PullCube, PushCube, RollBall, StackCube)와 제외한 2개(PullCubeTool, PokeCube). 조건은 "교사가 풀 수 있는 과제"입니다.
- **관측:** 인간 카메라 256×256 RGB와 고정 자연어 지시. 학생 정책도 같은 RGB를 받고 상태 정보는 받지 않습니다(§III-B, `04` D7).
- **교사 파인튜닝:** RL 생성 시연으로 Octo와 OpenVLA를 파인튜닝합니다. 최대 길이를 300으로 늘렸고, 길이가 긴 에피소드는 뺐습니다(§III-B). 원 체크포인트의 성공률은 모든 과제에서 0%입니다.
- **학생:** NatureCNN과 2층 MLP 액터·크리틱, PPO(ManiSkill3 기본값 기반). 배치 크기만 VLA를 GPU에 올리려고 바꿨습니다(§IV-A). 교사 질의 방식은 HTTP 서버와 공유 메모리입니다(§III-C).
- **보상:** dense(ManiSkill 정규화 dense)와 sparse(성공 1, 실패 -1, 그 밖에 0). sparse에서는 $\gamma$를 0.8에서 0.99로 바꿨습니다(§IV-C).
- **시드:** 5개(Fig. 3-5, 7). OpenVLA는 1회(Fig. 3, §IV-A). 편차는 음영(표준편차)으로만 보고합니다.
- **평가:** 학습 중 주기적 검증 롤아웃(curve). 최종 수치 표는 없습니다.

### 4.1 Table I (텍스트에서 확인한 값)

| 과제 | Octo 원 체크포인트 | Octo 파인튜닝 SR | OpenVLA 파인튜닝 SR |
|---|---|---|---|
| LiftPegUpright | 0% | 0% | 12% |
| PickCube | 0% | 9% | 6% |
| PullCube | 0% | 90% | 92% |
| PullCubeTool (제외) | 0% | 10% | 12% |
| PushCube | 0% | 67% | 27% |
| RollBall | 0% | 10% | 4% |
| StackCube | 0% | 1% | 3% |
| PokeCube (제외) | 0% | 12% | 12% |

출처: Table I. 교사 SR은 Fig. 3-5의 점선 기준선과 맞습니다(PickCube Octo 약 0.09, OpenVLA 약 0.06). 제외한 두 과제의 "성공"은 도구를 쓰지 않고 밀거나 당긴 경우도 포함합니다(§III-B, 386-401행). 저자들은 이를 "방해물이 있는 PullCube·PushCube"로 다시 읽으라고 합니다(§IV-D a).

## 5. 결과 (§IV)와 육안 판독

모든 수치는 논문 그림에서 육안으로 읽은 값입니다. 판독 정확도는 x축 범위의 약 ±10%이고, 시드별 값은 없습니다 (`fig_reading.json`, `03` §2).

### 5.1 PickCube 변형 비교 (Fig. 3, §IV-A)

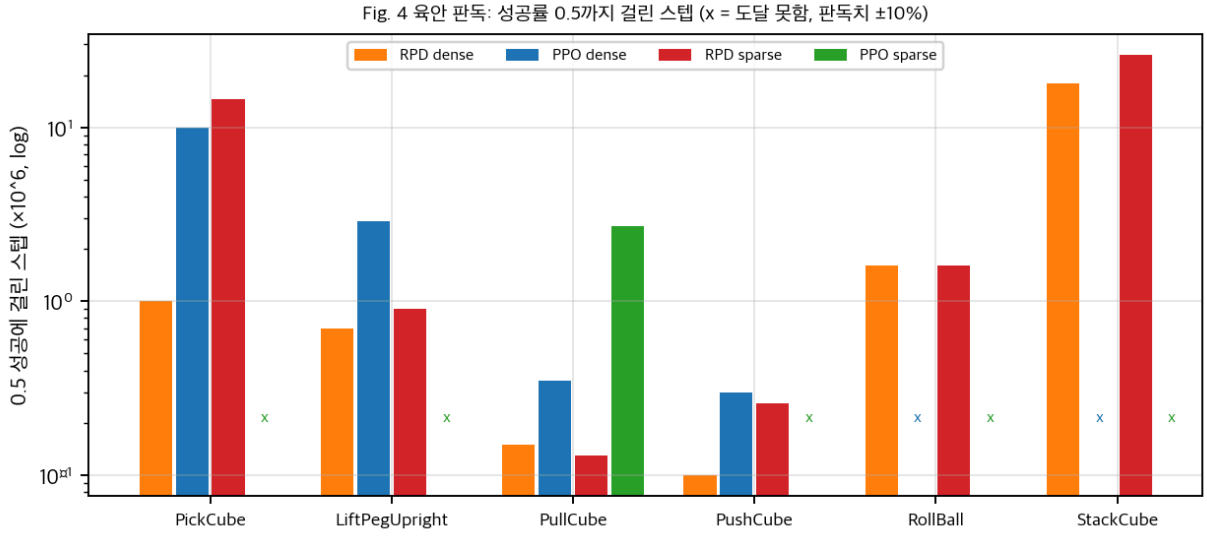
| 변형 | 0.5 성공까지 스텝 (×10^7) | 1.25×10^7 시점 성공률 (읽음) |
|---|---|---|
| RPD-MSE (Octo) | 약 0.15 | 약 0.80 |
| RPD-L1 | 약 0.15 | 약 0.76 |
| RPD-MSE (OpenVLA, 1회) | 약 0.15 | 약 0.80 (약 0.72×10^7에서 끝남) |
| PPO | 약 0.9 | 약 0.72 |
| RPD-BC | 도달 안 함 | 약 0.14 |
| PPD | 도달 안 함 | 약 0.03 |

주장과 맞는 점: RPD-MSE와 RPD-L1은 PPO보다 약 6배 빨리 0.5에 도달합니다. RPD-BC는 교사 수준(0.09)을 넘지만 정체합니다. PPD는 실패합니다.

주의:

- x축이 약 1.25×10^7에서 끝납니다. `train.py`의 `total_timesteps`는 3×10^7입니다. 논문은 곡선의 끝 시점을 밝히지 않습니다. 이 범위에서 PPO는 아직 오르는 중이므로 "약 80% 수렴"은 더 긴 학습 뒤의 값일 수 있습니다.
- OpenVLA 곡선은 약 7×10^6에서 끝납니다. 비교 기준이 다릅니다.

Fig. 4 육안 판독: 성공률 0.5까지 걸린 스텝 (x = 도달 못함, 판독치 ±10%)




그래프: Fig. 4를 육안으로 읽은 0.5 도달 스텝(×10^6, 로그 축). 판독 오차는 약 ±10%이며 시드별 값은 없습니다.

### 5.2 여섯 학습 과제, dense와 sparse (Fig. 4, §IV-B, §IV-C)

0.5 성공까지 스텝 (×10^6, 육안 판독, ±10%):

| 과제 | RPD dense | PPO dense | RPD sparse | PPO sparse |
|---|---|---|---|---|
| PickCube | 약 1.0 | 약 10 | 약 14.5 | 도달 안 함 |
| LiftPegUpright | 약 0.7 | 약 2.9 | 약 0.9 | 도달 안 함 |
| PullCube | 약 0.15 | 약 0.35 | 약 0.13 | 약 2.7 |
| PushCube | 약 0.10 | 약 0.30 | 약 0.26 | 도달 안 함 (약 0.45에서 멈춤) |
| RollBall | 약 1.6 (약 0.5 평탄) | 도달 안 함 | 약 1.6 | 도달 안 함 |

| 과제 | RPD dense | PPO dense | RPD sparse | PPO sparse |
|---|---|---|---|---|
| StackCube | 약 18 | 도달 안 함 | 약 26 | 도달 안 함 (오른쪽 잘림, 거칠음) |

- 주장과 맞는 점: 여섯 과제 모두 RPD dense가 PPO dense보다 빨리 올라갑니다. PullCube에서 차이는 작습니다(0.15 대 0.35). RollBall과 StackCube에서 PPO는 하이퍼파라미터가 같을 때 실패합니다(§IV-B). sparse에서는 RPD가 대부분 과제에서 성공합니다(§IV-C).
- 주의: PPO의 "실패"는 같은 하이퍼파라미터의 한 설정입니다. 다른 설정의 PPO는 보고하지 않았습니다.
- 주의: Fig. 4의 x축 범위는 과제마다 다릅니다(PickCube 1.9×10^7, PushCube 10^6, StackCube 3×10^7). 전체 학습 길이를 맞추지 않았습니다.

### 5.3 학습 과제가 아닌 두 과제 (Fig. 5, §IV-D a)

- **PullCubeTool (sparse):** RPD sparse 최종 약 0.85, PPO sparse 약 0.42. dense에서는 RPD와 PPO 모두 약 0이고, 교사가 도구를 쓰지 않으므로 기대와 맞습니다.
- **PokeCube:** RPD sparse 약 0.60, PPO dense 약 0.62, PPO sparse 약 0.05. "PPO보다 낫다"는 주장은 sparse 설정 사이의 비교에 해당합니다. PPO dense와는 비슷합니다. RPD dense 곡선은 판독하지 못했습니다.

### 5.4 카메라 변경 PushCube, sparse (Fig. 7, §IV-D b)

| 변형 | 0.5 성공까지 (×10^6) | 1.5×10^6 시점 성공률 (읽음) |
|---|---|---|
| RPD-MSE (Octo) | 약 0.28 | 약 0.98 |
| RPD-MSE (OpenVLA) | 약 0.23 | 약 0.96 |
| PPO | 도달 안 함 | 약 0.35 (음영 반폭 약 0.10) |

교사 자체 성공률은 카메라 변경 뒤 Octo 0%, OpenVLA 약 4.5%(Fig. 6과 본문 926행)입니다. RPD는 교사가 거의 쓸모없어도 PPO보다 빠르고 높게 학습합니다. 이 결과가 "교사의 방향 정보"인지 "교사 질의에 따른 다른 효과"인지는 본문에서 구분하지 않습니다. 무관한 교사 대조가 없습니다(`03` §5).

## 6. 한계 (§IV-E)

저자들이 직접 쓴 한계:

- 교사가 과제에서 의미 있는 행동을 못 내면 RPD가 PPO를 해칠 수 있습니다. 제외 과제의 dense 설정이 그 예입니다.
- PPO가 이미 잘 튜닝되었거나 과제가 쉬우면 이득이 작습니다.
- 온라인 RL은 복잡한 과제에서 수백만 스텝이 필요합니다. 실물 적용은 어렵습니다.
- 시뮬레이션에서만 검증했습니다.

이 조사에서 추가로 본 한계:

- **무관한 교사 대조가 없습니다.** 교사 성공률이 0~12%인 과제(PullCube 제외)에서 RPD가 빠르다는 결과를 "방향 정보" 해석으로 설명하지만, 그 해석을 검증하는 대조(무작위 교사, 교사 행동 셔플)가 없습니다.
- **벽시계와 VLA 호출 비용이 없습니다.** "샘플 효율"은 환경 스텝만 셉니다. 교사 질의 수는 `04` §3과 `03` §4.6에서 셉니다.
- **MSE 가중치 민감도가 없습니다.** λ 조정 문단(§IV-A 641-644행)은 PPD에 대한 것입니다.
- **시드 수가 적고 통계 검정이 없습니다.** 5개 시드, 곡선 음영뿐입니다.

## 7. v1 대 v2 차이 (v1 텍스트 추출본과 비교)

- **시뮬레이터:** v1은 ManiSkill2, v2는 ManiSkill3입니다. 코드도 ManiSkill3 (`mani_skill v3.0.0b15`)를 씁니다.
- **기여 목록:** v2에 "4) 교사 평가 통찰" 항목과 "sparse 보상에서 더 빠른 수렴" 문구가 추가되었습니다.
- **초록:** v2는 "sample efficiency와 stability"를 추가했습니다. v1은 "in the teacher's performance"라고 썼습니다.
- **과제 선택 근거:** v2에 "교사를 쓸 수 있는 과제에서 속도 향상을 재려고 PPO가 풀 수 있는 과제만 고른다"는 문단이 추가되었습니다(§III-B).
- **의존성 문단:** v1에 있던 "JAX와 CUDA 버전이 맞지 않아 환경을 나눈다"는 설명이 v2에서 짧아졌습니다.
- **표와 수치:** 텍스트 비교에서는 Table I과 Fig. 3 근처의 수치 변경을 찾지 못했습니다. 표는 텍스트 추출이 불완전하므로 이 점은 확실하지 않습니다.
- **공개 시점:** v2 (2025-08-04)는 코드 저장소 최근 커밋 (2025-07-18)보다 늦습니다. 코드와 논문 버전이 맞는지는 `04`에서 다룹니다.

## 8. 독자가 확인할 질문

1. 교사 질의를 상태당 몇 번 하는가. 논문은 "한 번"이라고 쓰지만 코드는 에폭마다 질의합니다(`04` D3).
2. 전체 학습 길이를 맞춘 PPO 곡선이 있는가. 있다면 최종 성공률의 차이가 0.08 이상인가(`03` §3).
3. 교사가 무관할 때 같은 MSE 항이 같은 효과를 내는가(`03` §5 토이).
4. 교사 질의에 드는 벽시계 시간은 얼마인가. 샘플 효율이 시간 효율로 이어지는가(`03` §4.6).

# 02. 선행연구와 관련 저장소

## 1. 계보

RPD는 두 흐름이 만나는 자리에 있습니다. 하나는 **정책 증류**(RL 교사를 작은 학생에 옮기기), 다른 하나는 **VLA 파인튜닝과 RL 개선**입니다.

| 흐름 | 대표 연구 (논문 참고문헌 번호) | RPD와의 관계 |
|---|---|---|
| 정책 증류 (DQN) | Rusu 외 2016 [20] | 교사가 RL 정책이고 손실은 Q값 기반 |
| 정책 증류 (PPO, KL) | Green 외 2019 [21] | DQN 교사를 PPO 학생에 KL로 증류. 교사는 RL 정책 |
| 정책 증류 (재사용) | Agarwal 외 2022 [22] | 다른 RL 알고리즘의 교사를 지도학습 방식으로 옮김 |
| 정책 증류 개요 | Czarnecki 외 2019 [19] | 정책 증류의 일반 틀 |
| 근접 정책 증류 (PPD) | Spigler 2024 [23] | 가장 가까운 대안. 학생 PPO에 KL 항과 클리핑 추가. 교사는 PPO. RPD 논문에서 비교 기준 |
| BC와 RL 결합 | Rajeswaran 외 2018 [25], Libardi 외 2021 [26] | 고정된 시연을 탐색 안내에 씀. RPD는 생성 교사를 온라인으로 씀 |
| 오프라인 RL 결합 | Levine 외 2020 [27], Ball 외 2023 [28] | 데이터셋 기반. RPD는 온-폴리시 |
| VLA 데이터 생성 | Xu 외 2024 (RLDG) [10] | RL 전문가로 VLA를 파인튜닝. 전문가가 이미 있어야 함. RPD는 전문가를 만들지 않고 증류 |
| 교사 VLA | Octo [4], OpenVLA [7] | RPD의 교사 |
| 시뮬레이션 | ManiSkill3 [31], CleanRL [32] | RPD의 환경과 PPO 기준선 |

RPD의 차별점은 논문이 주장하는 것처럼 "교사 VLA에서 온라인 on-policy RL로 바로 가는 증류"입니다(§II). 다만 PPD와 "교사 질의 비용"에서 직접 비교하지 않았습니다. 논문은 PPD를 KL 샘플 비용 때문에 피한다고 씁니다(§II, 150-154행). 우리 `03` §4.6은 RPD도 같은 교사 질의를 에폭마다 하므로 비용이 가볍다고 말할 수 없음을 보입니다.

## 2. 공식 저장소와 의존성 (GitHub 및 HF 확인)

확인 날짜: 2026-11-11. `gh api`와 HF API로 확인했습니다. 별 수는 확인 시점 기준입니다.

| 저장소 | 무엇 | 공식? | 라이선스 | 별 | 마지막 push | 확인한 커밋 |
|---|---|---|---|---|---|---|
| Refined-Policy-Distillation/RPD | RPD PPO 구현, `train.py`, 설정 | **공식** (저자) | Apache-2.0 | 24 | 2025-07-18 | `10becdf` (shallow clone, HEAD) |
| RobotControlStack/vlagents (구 juelg/agents) | 교사 VLA 서버와 `RemoteAgent`, `octodist`, `openvladist` | 저자 저장소 (이름 변경, 리다이렉트) | Apache-2.0 | 22 | 2026-10-21 | HEAD `1b98af4`. **2025 상태 확인은 `f51338c` (2025-07-18)** |
| mani-skill/ManiSkill (구 haosulab/ManiSkill) | 시뮬레이션, 과제, 인간 카메라 | 원 저장소 | Apache-2.0 | 3504 | 2026-08-04 | RPD는 `v3.0.0b15`로 고정 |
| octo-models/octo | Octo 모델 코드 | 원 저장소 | MIT | 1821 | 2024-07-31 | 확인 안 함 |

| 저장소 | 무엇 | 공식? | 라이선스 | 별 | 마지막 push | 확인한 커밋 |
|---|---|---|---|---|---|---|
| openvla/openvla | OpenVLA 코드 | 원 저장소 | MIT | 7288 | 2025-03-23 | 확인 안 함 |
| HF Juelg/octo-base-1.5-finetuned-maniskill | 파인튜닝된 Octo | 저자 공개 | MIT (태그) | 다운로드 19 | 2026-01-24 | 가중치는 받지 않음 |
| HF Juelg/openvla-7b-finetuned-maniskill | 파인튜닝된 OpenVLA | 저자 공개 | MIT (태그) | 다운로드 145 | 2026-01-24 | 가중치는 받지 않음 |
| HF Juelg/RPD-maniskill | RLDS 데이터셋 | 저자 공개 | Apache-2.0 (태그) | 다운로드 1898 | 2026-01-24 | 데이터는 받지 않음 |

주의:

- **`agents` 의존성은 고정되지 않았습니다.** `pyproject.toml`은 `agents @ git+https://github.com/juelg/agents.git`로만 씁니다. 커밋을 고정하지 않았습니다.
- **현재 vlagents HEAD에는 RPD 코드가 쓰는 경로가 없습니다.** `agents.client`, `agents.policies`, `agents.evaluator_envs`, `agents.wrappers`는 HEAD의 `vlagents` 패키지에 없습니다. `octodist`, `openvladist`, `means`, `stds`도 HEAD tarball에서 찾지 못했습니다(`04` D16). 2025-08-04 이전 커밋 `f51338c`에는 모두 있습니다.
- 저장소의 `repo/`는 gitignore되어 있습니다. 실행하지 않았습니다.

## 3. 이 저장소의 다른 분석과의 관계

| 폴더 | 한 줄 | RPD와의 관계 |
|---|---|---|
| `foresight_residual_rl/` (IROS 2026) | 고정된 π0 위에서 잔차 RL, 단계 성공 예측기로 보상을 곱해 나사 조립 성공률 54.5% → 85.6% | VLA를 고정하고 RL을 얹는다는 점에서 RPD와 같은 문제. RPD는 VLA를 학생이 떠나는 교사로 쓰고, 잔차 RL은 행동을 더한다 |
| `dexpolicy/` | ViViDex 상태 정책 RL에서 탐색 잡음 σ를 0.20 → 0.04로 줄이는 스케줄 | RL 탐색을 어떻게 안내하느냐는 같은 질문. RPD는 교사 행동으로 안내, dexpolicy는 잡음 크기로 안내 |
| `thinkworld/` | VLA의 예측-관찰 일치 보상으로 GRPO 강화 | RPD와 비교하면 교사를 손실 항으로 쓰느냐 보상으로 쓰느냐의 차이 |
| `pacevla/` | 시연의 느린 속도를 물려받는 VLA를 이웃 행동 합치기로 가속 | VLA 쪽 개선. RPD와 직접 관계는 약함 |
| `adavla/` | 흐름 매칭 VLA의 적분 가속 (학습 없음) | VLA 추론 비용 관점. RPD의 교사 질의 비용(`03` §4.6)과 관련 |
| `insertion_wm/` | 잠재 세계 모델로 조립 제로샷 | RPD와 직접 관계 없음. 시뮬 기반 증류 비교 대상 정도 |
| `ddpg/` | DDPG 재현과 numpy 토이 | 기준선 구현과 토이 설계 참고. 교사가 없는 RL 기준선 |

## 4. 가까운 대안: 이 논문이 다루지 않은 것

- **PPD 대 MSE:** 논문의 PPD는 자체 구현이고 공식 코드가 없습니다. 교사 분포를 10개 샘플로 맞추므로 질의가 10배입니다. RPD는 1개를 쓰지만 에폭마다 다시 질의합니다(`03` §4.6). 두 방법의 비용을 같은 질의 수에서 비교한 결과는 없습니다.
- **BC 정규화 대 RL 정규화:** 고정 σ 가우시안 BC와 같다는 것은 `03` §4.4의 유도에 있습니다. 논문은 이 연결을 쓰지 않습니다.

- **교사 혼합 탐색:** 교사 행동을 확률 β로 실행하는 방식(DAgger, ε-greedy형 혼합)은 논문에 없습니다. RPD와 비교할 자연스러운 대안입니다.
- **무관한 교사 대조:** 논문에 없습니다(`03` §5.4).

# 03. 재계산, 유도, 토이

이 문서는 논문 수치를 다시 읽고(§1-§3), MSE 항의 기울기와 고정점 편향을 유도하고(§4), CPU numpy 토이로 확인한 결과를 정리합니다(§5). 토이는 `analysis/toy_teacher_pull.py`, 결과는 `analysis/toy_teacher_pull_results.json`, 곡선 판독은 `analysis/fig_reading.json`, 유의성 계산은 `analysis/reading_stats.py`입니다.

## 1. 표와 텍스트 수치 재계산

- **Table I:** 과제 8개, 교사 4종. 파인튜닝 전 SR은 모든 과제 0%입니다. 파인튜닝 후 SR을 텍스트와 대조했습니다. PullCube Octo 90%와 OpenVLA 92%, PushCube Octo 67%와 OpenVLA 27%는 §IV-D 본문의 "OpenVLA 27%, Octo 67%" 문장과 맞습니다. PickCube 9%와 6%는 Fig. 3 점선(0.09, 0.06)과 맞습니다.
- **카메라 변경:** 본문 "OpenVLA 27% → 4.5%, Octo 67% → 0%"(§IV-D b)는 Table I의 PushCube 값을 기준으로 한 것입니다. Fig. 7의 점선도 Octo 0%, OpenVLA 약 0.045로 맞습니다.
- **Table I의 RW:** 과제별 보상(RW) 값은 Table I에 있지만 보상 정의가 dense인지 sparse인지 표에 쓰여 있지 않습니다. 기준선 정의에 따라 다른 값입니다. 여기서는 SR만 씁니다.

결론: 텍스트와 표의 수치는 서로 맞습니다. 다만 교사 SR은 단일 파인튜닝 체크포인트의 값이고 시드 분산이 없습니다.

## 2. 곡선 판독 요약

판독 프로토콜: 400 dpi로 확대한 벡터 그림에서 평균선을 읽고, 0.5 도달 시점과 끝 시점의 값을 적습니다. 음영 반폭을 표준편차로 간주합니다. 정확도는 x축 범위의 ±10%입니다.

| 그림 | 비교 | 읽은 값 |
|---|---|---|
| Fig. 3 (PickCube, Octo) | RPD-MSE 대 PPO, 0.5 도달 | 약 0.15×10^7 대 약 0.9×10^7 (약 6배) |
| Fig. 3 | 끝 시점 (약 1.25×10^7) | RPD-MSE 약 0.80 ±0.04, PPO 약 0.72 ±0.05 |
| Fig. 4 (6 과제, dense) | RPD dense 대 PPO dense, 0.5 도달 | 과제별 1.5배 (PullCube) ~ 약 10배 (PickCube) |
| Fig. 4 (sparse) | RPD sparse 대 PPO sparse | PPO sparse는 PullCube에서만 도달 (약 2.7×10^6) |
| Fig. 5 (학습 밖 과제) | PullCubeTool sparse 끝 | RPD 약 0.85 대 PPO 약 0.42 |
| Fig. 7 (카메라 변경, sparse) | RPD-MSE (Octo) 대 PPO, 1.5×10^6 끝 | 약 0.98 대 약 0.35 |

전체 판독표는 `analysis/fig_reading.json`에 있습니다. 시드별 값이 없으므로 아래 유의성은 근사입니다.

## 3. 유의성

- **Fig. 3 끝 시점, Welch 근사:** 차이 0.08, 표준오차 0.029, t = 2.79, df = 7.6, p ≈ 0.025 (음영 반폭을 SD로 가정, 시드 5개). 이 값은 "약 1.25×10^7에서의 한 점"에 대한 것이며 논문이 세운 주장(수렴 속도)에 대한 검정이 아닙니다.
- **검정력:** 시드 5개, SD 0.05에서 80% 검정력으로 찾을 최소 차이는 약 0.10입니다. SD 0.02이면 약 0.04입니다. 따라서 Fig. 3의 0.08 차이는 SD가 0.05 근처일 때 경계선에 있습니다.
- **Fig. 7 (1.5×10^6 끝, PPO 음영 반폭 0.10 가정):** 차이 0.63, 표준오차 0.046, t = 13.8, df = 4.3, p ≈ 0.0001. 방향과 크기는 분명하지만 교사 0%에서 RPD가 이기는 것은 "교사 없는 대조가 없다"는 점과 따로 봐야 합니다.
- **Fig. 4와 Fig. 5:** 검정 가능한 최종 수치가 없어 유의성을 계산하지 않았습니다. 0.5 도달 시점의 비율(약 6배, 약 10배)은 단일 판독이므로 구간을 줄 수 없습니다.

결론: 이 조사로는 "빠르게 수렴한다"는 주장의 통계적 강도를 판단할 수 없습니다. 필요한 것은 시드별 곡선 또는 로그입니다.

## 4. 유도

### 4.1 기호와 코드 대응

- 행동 $a \in R^d$, $d = 7$ (ΔEE 6 + 그리퍼). 정책 평균 $\mu_\theta(s)$, 로그 표준편차 $\ell$ 상태 독립, $\sigma = \exp(\ell)$.
- 교사 샘플 $\bar{a}(s) \sim \pi_{VLA}(\cdot|s)$. 논문 식 (5)의 기댓값 $m(s) = E[\bar{a}|s]$.
- 코드의 PPO 손실 `pg_loss` = −min(...)의 평균 (최소화 방향). 코드의 MSE 항 `l_ppd` = `F.mse_loss(means, p.mean)` = $(1/(Bd)) \Sigma_i \Sigma_k (\mu_{ik} - \bar{a}_{ik})^2$.
- 코드 전체 손실: `loss = pg_loss + v_coef·v_loss + λ·l_ppd` (`ent_coef = 0`). 최대화 형태로 쓰면 $J_{RPD} = J_{clip} - \lambda \cdot \ell_{MSE}$입니다.

### 4.2 결합 손실의 기울기

$J_{clip}$의 기울기는 PPO 표준입니다. MSE 항의 기울기는 다음과 같습니다.

$$\nabla_\theta \ell_{MSE} = (2/(Bd)) \Sigma_i (\mu_\theta(s_i) - \bar{a}_i)^T \nabla_\theta \mu_\theta(s_i)$$

따라서

$$\nabla_\theta J_{RPD} = \nabla_\theta J_{clip} - (2\lambda/d) \cdot E_s[(\mu_\theta(s) - \bar{a})^T \nabla_\theta \mu_\theta(s)].$$

- 로그 표준편차 $\ell$은 MSE 항에 들어가지 않습니다. 따라서 RPD는 분산을 줄이라고 요구하지 않습니다. 분산이 바뀌는 것은 PPO 항 때문입니다.
- 논문 식 (3)의 가중치 1은 코드에서 `λ = 1`인 상수입니다(`04` D1). 코드의 MSE는 원소 평균(÷d)이므로, 식 (5)를 합 형태로 쓰면 가중치가 $\lambda/d = 1/7$입니다. 논문은 이 정규화를 밝히지 않습니다(`04` D2).

### 4.3 단일 교사 샘플의 편향

교사 샘플 하나로 추정해도 기울기의 기댓값은 바뀌지 않습니다. 교사 분포에 대해

$$E_{\bar{a}}[(\mu - \bar{a})^2] = (\mu - m)^2 + Var(\bar{a})$$

이고 $Var(\bar{a})$는 $\theta$와 무관합니다. 따라서 $\nabla_\theta E_{\bar{a}}[(\mu-\bar{a})^2] = 2(\mu-m)\nabla_\theta\mu$이고, 단일 샘플 추정의 기댓값도 같습니다. 단일 샘플은 편향이 아니라 분산을 더합니다. 이 점은 논문의 "상태당 한 샘플이면 충분하다"(§III-A)와 맞습니다.

한 가지 단서: 코드는 같은 상태를 에폭마다 다시 질의하므로(`04` D3) 교사 샘플은 에폭마다 새로 뽑힙니다(Octo는 확률적 샘플링, OpenVLA는 결정적 생성). 위 기댓값 논리는 여전히 성립하고, 질의 횟수만 늘어납니다.

### 4.4 가우시안 BC와의 관계

고정 $\sigma$의 가우시안 최대우도 손실은 $(1/(2\sigma^2)) \| \mu - a \|^2$ + 상수입니다. 따라서 코드의 MSE 항은 **고정 $\sigma$ 가우시안 BC와 같고, $\sigma^2 = d/(2\lambda)$입니다.** $\lambda = 1$, $d = 7$에서 $\sigma^2 = 3.5$, $\sigma \approx 1.9$입니다. 행동 범위가 대략 [-1, 1]인 것을 생각하면 이 BC는 매우 느슨합니다. 식 (5)를 합 형태로 쓰면 $\sigma^2 = 0.5$, $\sigma \approx 0.7$이 되어 더 강합니다. 두 해석 중 무엇이 코드인지는 `04` D2가 확정합니다(코드는 원소 평균).

RPD-BC(식 2)는 $\sigma$를 학습하므로 $\sigma$가 줄어드는 방향으로 움직입니다. 논문의 "분산 항이 표준편차를 줄여 교사에 과적합한다"(§IV-A)는 설명은 이 차이와 맞습니다. 기울기 수준에서 확인하지는 않았습니다.

### 4.5 고정점 편향

RL 목적을 평균 공간에서 국소 이차 근사합니다.

$J_{clip}(\mu) \approx -(\kappa/2)(\mu - \mu^*)^2$

여기서 $\mu^*$는 RL 최적 평균이고 $\kappa > 0$는 곡률입니다. 교사 항의 유효 가중치를 $\lambda_e = \lambda/d$ (코드 기준)로 두면, 정지점은

$\kappa(\mu^* - \mu) - 2\lambda_e(\mu - \bar{t}) = 0 \boxtimes \mu_{fix} = (\kappa\mu^* + 2\lambda_e \bar{t})/(\kappa + 2\lambda_e)$

이고 편향은

$\mu_{fix} - \mu^* = [2\lambda_e/(\kappa + 2\lambda_e)] \cdot (\bar{t} - \mu^*)$

입니다. 여기서 $\bar{t} = E[\bar{a}|s]$.

- **상수 λ:** 편향 비율 $w = 2\lambda_e/(\kappa + 2\lambda_e)$는 λ가 클수록, κ가 작을수록 커집니다. 교사가 최적 ($\bar{t} = \mu^*$)이면 편향 0입니다. 교사가 틀리면 편향은 $w(\bar{t} - \mu^*)$에 비례합니다.
- **감쇠 λ(t) → 0:** 정지점 편향은 0으로 갑니다. 다만 수렴 속도는 λ(t)의 시간 척도에 달려 있습니다(§5 토이).
- **κ는 식에 없는 값입니다.** 논문의 정규화 advantage (`norm_adv = True`)를 쓰면 κ의 단위는 기울기 스케일에 따라 달라집니다. 따라서 "λ = 10이 얼마나 강한가"는 이 논문만으로 정할 수 없습니다. κ를 재려면 PPO 항과 MSE 항의 기울기 노름을 기록해야 합니다.

### 4.6 교사 질의 수와 비용

코드 설정 (`train.py`, `ppo_rgb_rpd.py`): num_envs = 128, num_steps = 50 → 배치 6400, num_minibatches = 48 → 미니배치 133, update_epochs = 8, total_timesteps = 3×10^7.

- 반복 수 = 3×10^7 // 6400 = 4687
- 반복당 교사 호출 = 8 에폭 × 49 미니배치 = 392 (마지막 미니배치는 16개)
- 반복당 교사 이미지 = 8 × 6400 = 51,200 → **환경 스텝 1개당 8개**
- 총 호출 = 1,837,304 (Octo는 배치 호출), 총 이미지 = 약 2.4×10^8 (OpenVLA는 이미지마다 순차 추론)
- 호출당 입력 전송 = 133 × 256×256×3 바이트 ≈ 26 MB

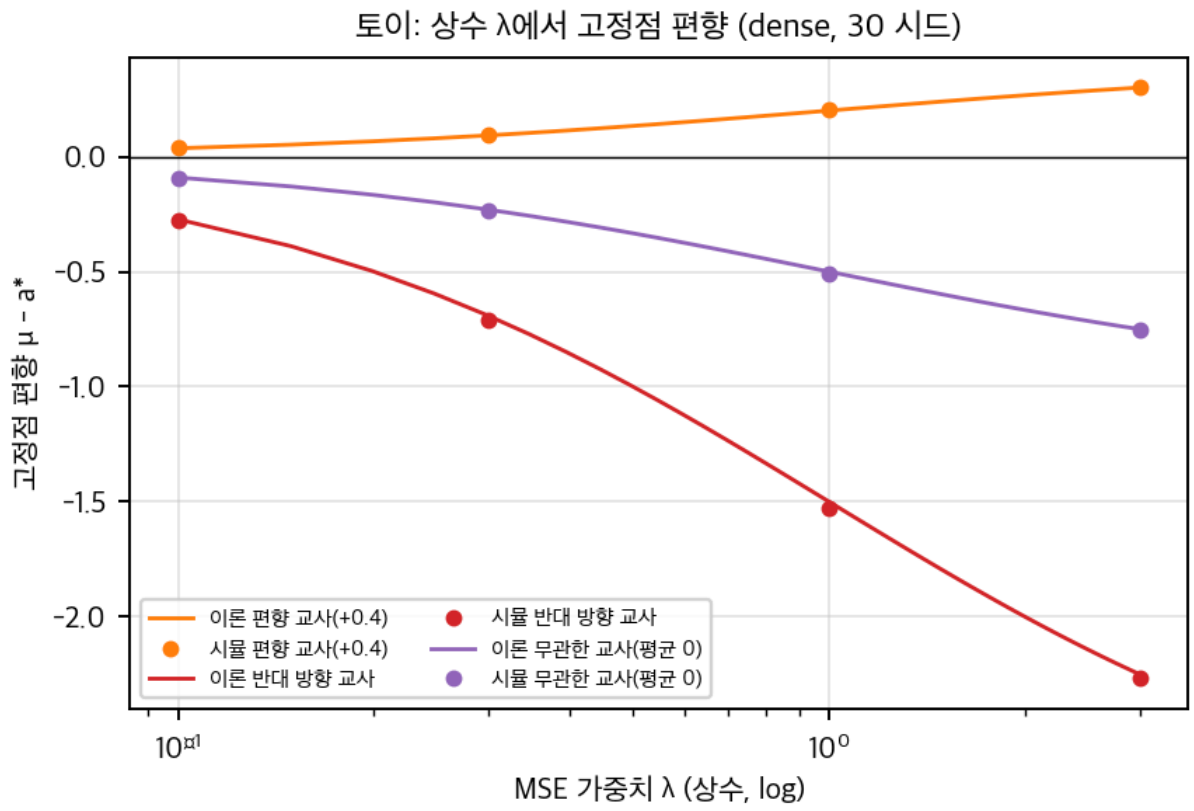
논문은 "상태당 한 샘플"이라고 쓰지만, 같은 상태를 에폭마다 다시 질의하므로 **스텝당 질의는 8배**입니다. 샘플 효율을 환경 스텝으로만 재면 이 비용이 빠집니다. 조기 종료(target KL 0.2)가 걸리면 줄어들지만 코드에 근거가 없습니다. 이 계산은 `python3 -I`로 확인했습니다.

### 4.7 탐색 관점의 해석

RPD 항은 μ를 $\bar{t}$ 쪽으로 끌어당기는 결정적 항입니다. 학습 초기에 RL 신호가 없거나 약하면(희소 보상에서 성공이 없으면) 이 항이 사실상 유일한 기울기입니다. 이것이 논문의 속도 향상과 희소 보상 결과를 설명하는 기본 메커니즘입니다. 반대로 RL 신호가 충분해지면 교사 항은 편향만 더합니다. 논문은 이 두 단계를 나누어 보고하지 않습니다.

## 5. 토이 (CPU numpy)

설정: 1차원 행동, 정책 $a \sim N(\mu, 0.3^2)$, $a^* = 1$, 배치 32, 반복 800, 시드 30, $\eta = 0.1$, $\mu_0 = -1$. 교사는 좋은 교사(t = 1), 편향 교사(t = 1.4, 같은 방향), 반대 교사(t = -2), 잡음·무편향 교사($N(1, 1^2)$), 무관한 교사($N(0, 1^2)$)입니다. 보상은 dense $-(a-a^*)^2$와 sparse $1\{|a-a^*| < 0.1\}$입니다. 스케줄은 상수, 선형(T/2에서 0), 코사인(`0.5cos(πt/T) + 0.5`)입니다.

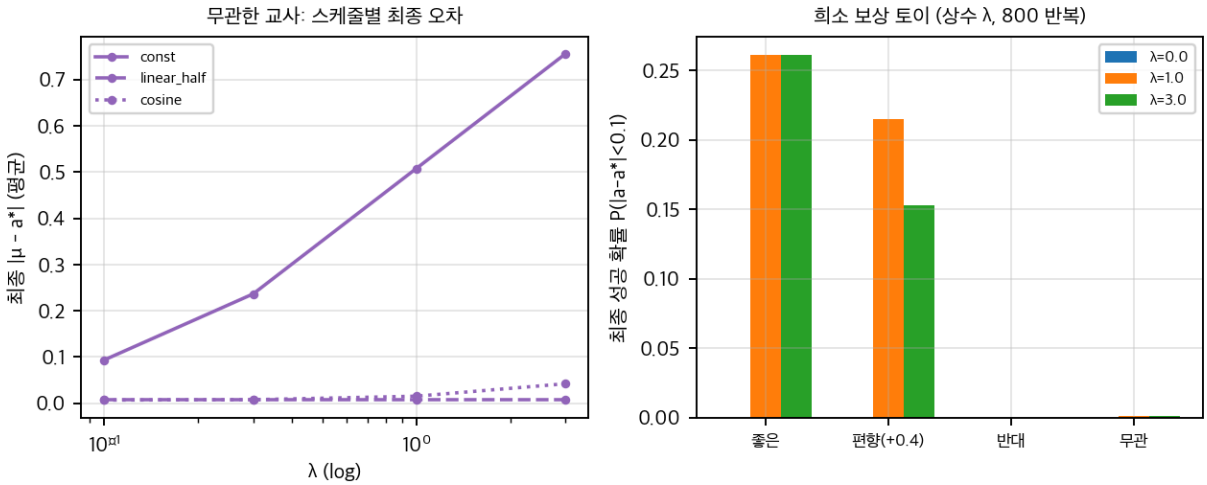



그래프: 토이의 고정점 편향. 점은 시뮬레이션(30 시드), 선은 이론 λ/(1+λ)·(ī − a*). 합성 데이터이며 논문 값이 아닙니다.

### 5.1 고정점 편향 검증 (dense, 상수 λ)

| 교사 | λ | 시뮬 편향 | 이론 λ/(1+λ)·(ī − a*) |
|---|---|---|---|
| 편향 교사 | 1 | +0.204 | +0.200 |
| 반대 교사 | 1 | -1.525 | -1.500 |
| 무관한 교사 | 1 | -0.507 | -0.500 |
| 좋은 교사 | 1 | +0.001 | 0 |
| 잡음 무편향 | 1 | +0.001 | 0 |

이론식 μ_fix = (a* + λī)/(1+λ)가 시뮬레이션과 0.01 이내로 맞습니다(κ = 2, λ_e = λ인 1차원 모델). 이 토이에서는 λ_e = λ이므로 d 정규화 문제가 없습니다.



그래프: 토이의 스케줄별 최종 오차(왼쪽)와 희소 보상 성공 확률(오른쪽). 합성 데이터입니다.

### 5.2 학습 속도와 스케줄 (dense)

0.1 근처에 도달한 반복 중앙값:

| 교사 | 스케줄 | λ = 0 | λ = 0.3 | λ = 1 | λ = 3 |
|---|---|---|---|---|---|
| 편향 | 상수 | 13 | 8 | 3 | 800 (미도달) |
| 편향 | 코사인 | 13 | 8 | 3 | 582 |
| 무관 | 상수 | 14 | 800 | 800 | 800 |
| 무관 | 선형 | 14 | 174 | 344 | 388 |
| 무관 | 코사인 | 14 | 360 | 595 | 691 |
| 반대 | 상수 | 13 | 800 | 800 | 800 |

- 교사가 좋거나 편향되어 같은 방향이면 λ가 클수록 빠릅니다. 다만 λ = 3에서 편향 교사가 800까지 도달하지 못하는 것은 편향 0.30이 0.1 창 밖에 머물기 때문입니다.
- 무관하거나 반대인 교사에서 상수 λ는 학습을 막습니다. 감쇠 스케줄은 편향을 없애고 도달을 되찾지만 느립니다.
- 이 토이의 λ 척도는 κ = 2인 dense 보상에 맞춰져 있습니다. 실제 RPD의 λ 의미는 §4.5와 같이 κ에 따라 달라지므로 값을 옮기면 안 됩니다.

### 5.3 희소 보상 (상수 λ, 최종 성공 확률 P(|a-a*| < 0.1))

| 교사 | λ = 0 | λ = 0.1 | λ = 1 | λ = 3 |
|---|---|---|---|---|
| 좋은 | 0.00 | 0.26 | 0.26 | 0.26 |
| 편향 (+0.4) | 0.00 | 0.26 | 0.21 | 0.15 |
| 반대 | 0.00 | 0.00 | 0.00 | 0.00 |
| 무관 | 0.00 | 0.25 | 0.00 | 0.00 |
| 잡음 무편향 | 0.00 | 0.26 | 0.26 | 0.26 |

- **교사가 없으면 희소 보상 학습은 전혀 되지 않습니다**(λ = 0, 800 반복 내 성공 0). 교사의 탐색 기여가 가장 분명한 부분입니다.
- 편향 교사는 λ가 클수록 최종 성공 확률이 떨어집니다. 같은 방향이어도 고정점 편향이 0.1 창을 벗어나기 때문입니다.
- 무관한 교사는 λ = 0.1에서만 성공하고, λ가 커지면 교사 편향이 학습을 막습니다.

### 5.4 무관한 교사 대조가 보여 주는 것

논문에 없는 대조입니다. 무관한 교사(평균 0, 잡음 1)는 상수 λ에서 편향(-0.5 at λ = 1)을 만들고 학습을 막습니다. 잡음만 있고 편향이 없는 교사는 편향 없이 탐색만 돕습니다. 그러므로 "교사 행동이 탐색 방향을 준다"는 해석이 맞으려면, 교사의 **평균**이 과제 목표와 맞아야 합니다. 논문의 "낮은 성공률에서도 방향을 준다"(§IV-D)는 교사 평균이 맞는 경우에 한정될 때만 성립합니다. 이 점은 이 토이로 확인되었고, 논문에서는 검증되지 않았습니다.

## 6. 이 분석이 말하지 않는 것

- 논문의 실제 PPO와 RPD 곡선 재현: 실행하지 않았습니다.
- κ와 실제 기울기 비율: 값을 모릅니다. §4.5의 w는 식으로만 주어집니다.

- 교사 분산과 시드 분산의 분리: 데이터가 없습니다.
- 토이의 λ 척도가 실제 PPO의 λ 척도와 같다는 주장: 근거가 없습니다.
- 벽시계 시간: 측정하지 않았습니다.

# 04. 코드 대조: 논문 ↔ Refined-Policy-Distillation/RPD

**정적 읽기만 했습니다.** 코드를 실행하지 않았고 아무것도 설치하지 않았습니다. 교사 쪽 의존성은 GitHub에서 소스 tarball을 받아 임시 폴더에서 읽었습니다(공개 자료에 넣지 않음).

## 1. 확인한 파일

| 파일 | 줄 수 | 내용 |
|---|---|---|
| `repo/src/rpd/ppo_rgb_rpd.py` | 756 | RPD 학습 본체. 손실은 633-672행, 교사 질의는 636-646행, 서버 기동은 752-756행 |
| `repo/src/rpd/ppo_rgb.py` | 610 | PPO 기준선. RPD와 달리는 것은 MSE 항, RPD 인자, 로그 메시지뿐 (`diff` 로 확인) |
| `repo/train.py` | 약 90 | 실험 설정. `use_rpd`, 환경, 시드, 하이퍼파라미터, 기본 인자 |
| `repo/README.md`, `pyproject.toml`, `Makefile` | — | 설치, 의존성, 데이터 |

커밋: `10becdf` (2025-07-18, HEAD, shallow clone). 저장소 이력은 3개 커밋(`2f71ca8`, `39ba6a5`, `10becdf`)입니다. 논문 v1 (2025-03-06)과 v2 (2025-08-04) 사이에 코드가 바뀌었는지는 이력만으로 알 수 없습니다. 마지막 push가 2025-07-18이므로 v2 시점의 코드와 같을 가능성이 큽니다.

교사 쪽 대조는 `RobotControlStack/vlagents`의 **2025-07-18 상태(`f51338c`)**를 기준으로 했습니다. 이 상태에 `src/agents/policies.py`의 `OctoActionDistribution`, `OpenVLADistribution`과 `octodist`, `openvladist` 등록, `client.py`의 `RemoteAgent`, `evaluator_envs.py`의 `start_server`, `wrappers.py`의 `HumanCameraWrapper`가 있습니다. 현재 HEAD (`1b98af4`)에는 이 경로가 없으므로(D16) 재현하려면 2025 상태를 고정해야 합니다.

## 2. 논문 ↔ 코드 대조 (D 항목)

판정 기호: **일치**, **차이** (논문과 코드가 다름), **미확인** (이 조사에서 확인할 수 없음), **정보 없음** (논문이나 코드 어느 쪽에도 없음).

| ID | 항목 | 논문 | 코드 (위치) | 판정 |
|---|---|---|---|---|
| D1 | 손실 형태와 가중치 | 식 (3) L_RL – L_MSE, 가중치 1 (§III-A) | `loss = pg_loss − ent_coef·H + vf_coef·v_loss + ppd_lambda·l_ppd`, `ppd_lambda = 1.0` 상수 (633-672행, `train.py`의 `--ppd-lambda=1.0`) | **일치** (부호 규약: `pg_loss`는 surrogate의 음수) |
| D2 | MSE의 정규화 | 식 (5), (μ – Ea)² (합 형태로 읽힘) | `F.mse_loss(means, p.mean)` : 배치와 7차원 모두 평균 (655-656행) | **차이** (합 형태 대비 1/7). 논문에 정규화 설명 없음 |
| D3 | 교사 질의 빈도 | "상태당 교사 행동 한 개" (§III-A) | 미니배치마다 `model.act` 호출 (636-646행). 에폭 8 × 미니배치 49 = 반복당 392회, 상태당 **8회** | **차이** (논문은 한 번, 코드는 에폭마다 한 번). 같은 상태를 8번 다시 질의 (`03` §4.6) |
| D4 | 교사 출력의 성질 | 확률적 샘플 한 개 (§III-A, §III-C) | Octo: `sample_actions`로 확률적 샘플 1개, 배치 질의 (vlagents `octodist`). OpenVLA: `do_sample=False`이고 이미지마다 순차 추론 (vlagents `OpenVLADistribution`) | **일치** (§III-C의 "OpenVLA는 배치 추론 미지원"과 맞음). Octo는 확률적이므로 같은 상태의 목표가 에폭마다 바뀜 |

| ID | 항목 | 논문 | 코드 (위치) | 판정 |
|---|---|---|---|---|
| D5 | MSE 가중치 스케줄 | 상수 (§IV-A, RPD). PPD만 λ 조정 언급 | `max_ppd_anneal_steps=None`이면 상수 `ppd_lambda`. 코사인 감쇠 코드는 있으나 `train.py`에서 주석 처리 (`# args.append("--max-ppd-anneal-steps=6_000_000")`). 주석 "starts at a value of 2"는 식 `0.5cos(0)+0.5 = 1`과 맞지 않음 | **일치** (주 실험은 상수). 주석 불일치는 코드 결함 |
| D6 | 분포 추정 분기 | PPD는 교사 샘플 10개로 다변량 가우시안을 맞춤 (§IV-A). RPD는 1개 (§III-A) | `Args.num_vla_samples` 기본 10이고 `train.py`는 1. 분기 `if num_vla_samples != 1`는 KL 경로. 그런데 서버 호출 `Obs(cameras=...)`에 `info["num_samples"]`를 넣지 않으므로 서버는 항상 1 (`obs.info.get("num_samples", 1)`). `stds`는 0 | **차이 / 주의**: 인자 `num_vla_samples`는 분기 선택에만 쓰이고 서버 샘플 수를 바꾸지 않음. KL 경로를 켜면 공분산 0이 됨. 실제로 쓰이는 경로는 MSE/L1/BC뿐 |
| D7 | 관측 공간 | 인간 카메라 256×256 RGB, 교사와 학생 같은 카메라, 상태 정보 없음 (§III-B) | 학생: `obs_mode="rgb"`, `HumanCameraWrapper`, `FlattenRGBDObservationWrapper(rgb=True, depth=False, state=args.include_state)`, 기본 `include_state=False`. 교사: `cameras["rgb_side"]`, octo 어댑터에서 `(256,256,3)` assert | **일치** |
| D8 | 지시문 | Table I 문자열 (§III-B) | `INSTRUCTIONS` 사전 (43-55행): 8개 과제 문자열이 Table I과 같음 | **일치** |
| D9 | 하이퍼파라미터 | "ManiSkill3 기준선의 상수 하이퍼파라미터, 배치 크기만 바꿈" (§IV-A) | `train.py`: num_envs 128 (Args 기본 512), num_steps 50, num_minibatches 48 (기본 32), update_epochs 8 (기본 4), total_timesteps 3×10^7 (기본 10^7), eval_freq 10, num_eval_envs 500 (기본 8), lr 3e-4, gae 0.9, clip 0.2, target_kl 0.2, ent 0, vf 0.5, max_grad_norm 0.5, norm_adv True | **차이 / 미확인**: 미니배치 수와 에폭 수도 기본값과 다름. "기준선"이 ManiSkill3의 값인지는 확인하지 않음 (ManiSkill 저장소의 기준선 파일은 조사하지 않음) |
| D10 | sparse의 γ | 0.8 → 0.99, 다른 변경 없음 (§IV-C) | `gamma = 0.99 if sparse else 0.8`. 같은 `train.py`가 `use_rpd`에 상관없이 적용되므로 PPO 기준선도 같음 | **일치**. 이전 메모의 "기준선에도 적용됐는지 불확실"은 해소 |
| D11 | 시드 | 5개 (Fig. 3-5, 7), OpenVLA 1개 | `train.py`의 `seed = 0` 기본, "mass experiments"는 사용자가 바꾸라는 주석. 시드 목록과 실행 스크립트는 없음 | **미확인** (실행 목록 없음) |
| D12 | 평가 | 주기적 검증 롤아웃 (Fig. 3-5, 7) | `eval_envs`는 500개, `eval_reconfiguration_freq=1` (매 리셋마다 물체 재배치), 결정적 평균 행동 `deterministic=True`, 50 스텝. 기록 키는 `eval_infos["episode"]`의 항목 | **일치** (성공 지표의 정확한 키는 ManiSkill이 정의. 이 조사에서 확인하지 않음) |
| D13 | 시뮬레이터 백엔드, 보상 | ManiSkill3 (§III-B), dense 정규화 보상 (§IV-C) | `sim_backend="gpu"`로 고정 (370-380행), `reward_mode = "normalized_dense" if dense else "sparse"`. 빈 `sim_backend`를 CPU로 바꾸는 옵션 없음 | **차이 (재현성)**: GPU 시뮬 강제 (`04` §4) |
| D14 | 교사 체크포인트 | Octo, OpenVLA 파인튜닝본 (§III-B) | Octo `hf://Juelg/octo-base-1.5-finetuned-maniskill`, horizon 1. OpenVLA `Juelg/openvla-7b-finetuned-maniskill`, `unnorm_key = "maniskill_human:7.0.0"`, `checkpoint_step = 40000`, `attn_implementation = "flash_attention_2"`, `device = "cuda:0"` | **일치** (HF 확인). OpenVLA는 CUDA와 flash-attn 2가 필요 |
| D15 | PPD 기준선 | 자체 구현, 공식 코드 없음 (§IV-A) | 저장소에 PPD 구현 없음. `vlad_loss_type`은 mse/l1/bc만 | **정보 없음**: PPD 결과는 이 저장소로 재현 불가 |

| ID | 항목 | 논문 | 코드 (위치) | 판정 |
|---|---|---|---|---|
| D16 | 의존성 버전 | 명시 없음 | `agents @ git+https://github.com/juelg/agents.git` : 커밋 미고정. `mani_skill @ v3.0.0b15` 는 고정. 현재 HEAD의 `vlagents` 에는 `agents.*` 경로와 `octodist` / `openvladist` 가 없음 | **차이 (재현성)**: 2025-07~08 상태의 `agents` 를 고정해야 함 |
| D17 | 서버와 메모리 | 같은 기기면 공유 메모리, 아니면 HTTP (§III-C) | `RemoteAgent("localhost", port, ..., on_same_machine=True)` , 무작위 포트 10000-40000, `start_server` 가 하위 프로세스로 교사 실행. `_to_shared_memory` 와 `_from_shared_memory` 사용 (2025 `client.py` , `policies.py` ) | **일치** |
| D18 | 로그 이름 | — | `losses/ppd_kl` 에 실제로는 MSE가 기록됨 (690행). `losses/ppd_loss = ppd_kl × ppd_lambda` | **정보 없음** (이름만 혼동). 분석에서는 MSE로 읽음 |
| D19 | PPO 세부 | 식 (4) 클리핑, CleanRL 기반 (§IV-A) | 클리핑 surrogate (614-616행), 가치 손실 비클리핑 ( `clip_vloss=False` ), 기울기 노름 0.5, 정규화 advantage (CleanRL 표준) | **일치** |
| D20 | 기준선 공정성 | "모든 변형 같은 하이퍼파라미터" | `ppo_rgb.py` 는 `ppd_lambda` , `num_vla_samples` 인자가 없고 `train.py` 의 `use_rpd=False` 경로가 이를 붙이지 않음. 나머지 인자는 같음 | **일치** (RPD와 PPO 차이가 MSE 항 하나로 한정됨) |
| D21 | RPD-BC, L1 | 식 (2) 최대우도, L1 (§IV-A) | `bc` : `-p.log_prob(means).sum(1).mean()` (학습되는 log-std 사용). `l1` : `F.l1_loss` | **일치** |
| D22 | 과제 최대 길이, 데이터 필터 | 최대 300 (§III-B, 파인튜닝용), RL 쪽은 기본 | 저장소에 없음 (데이터셋 변환은 HF 데이터셋과 외부 도구) | **미확인** |
| D23 | 교사 질의 시점의 관측 | 같은 상태 (§III-A) | `b_obs[mb_inds]["rgb"]` 는 롤아웃 때 저장한 학생 관측. 질의 시점의 현재 정책이 아님 | **일치** (저장된 상태에 대한 질의) |
| D24 | 학습 길이와 곡선 범위 | 명시 없음 | 기본 3×10^7 스텝 ( `train.py` ). Fig. 3 x축은 약 1.25×10^7에서 끝나고 OpenVLA는 약 0.7×10^7 | **정보 없음** (곡선 길이가 `train.py` 와 다름) |

### 2.1 두 가지 설명

- **D3과 D4의 결합.** 논문의 "한 샘플"은 질의 횟수를 줄이기 위한 선택으로 읽힙니다. 코드에서는 같은 상태를 에폭마다 질의합니다. Octo는 확률적이므로 에폭마다 다른 샘플이 들어옵니다. 기댓값 논리( `03` §4.3)는 유지되지만 계산 비용은 8배입니다.
- **D6의 의미.** `num_vla_samples` 를 1보다 크게 설정해도 서버는 여전히 샘플 1개를 줍니다. KL 경로(PPD형)는 기본 설정에서 공분산이 0이 되어 제대로 동작하지 않습니다. 논문의 PPD는 이 경로가 아니라 자체 구현으로 돌렸을 것입니다.

## 3. 저장소의 실행 흐름 (정적 추적)

1. `train.py` 가 `ppo_rgb_rpd.py` 를 인자와 함께 `os.system` 으로 호출 ( `shlex.join` ).
2. `__main__` 에서 `vla_type` 에 따라 `start_server("octodist" 또는 "openvladist", kwargs, port, ...)` 를 하위 프로세스로 띄움. Python 경로는 `vla_conda_path` .
3. 5초 대기 후 `main()` : `RemoteAgent` 로 연결, `model.reset(obs=Obs(), instruction=...)` .

4. 환경 2개 (학습 128, 평가 500), 래퍼 (`HumanCameraWrapper`, `FlattenRGBDObservationWrapper`, `ManiSkillVectorEnv`).
5. 반복마다: 롤아웃 50 스텝 → GAE → 에폭 8 × 미니배치 (PPO 손실 + 교사 질의와 MSE) → 기울기 클리핑 → Adam.
6. 평가는 `eval_freq` 마다 `iteration % eval_freq == 1` 일 때.

## 4. 구현할 수 있는지

### 4.1 공식 재현

- **필요한 것:** NVIDIA GPU (ManiSkill GPU 시뮬, `sim_backend="gpu"` 고정), conda 환경 두 개 (RPD와 교사 VLA), `mani_skill` v3.0.0b15, `agents` 2025 상태, HF 체크포인트 (Octo 약 93M, OpenVLA 7B), 시연 데이터 (RLDS 또는 원본 HDF5 재생).
- **노력:** 높음. 의존성 고정 (D16), 시연 재생으로 인간 카메라 영상을 만드는 단계 (README의 `replay_trajectory` 명령), `HumanCameraWrapper` 위치 (agents 저장소) 확인이 필요합니다.
- **계산:** 논문은 OpenVLA를 H100 4노드 (노드당 GPU 4장 중 2개씩 인스턴스, 병렬 8)에서 돌렸고 Octo는 A40 한 장에서 돌렸다고 씁니다(§III-C). Octo 한 번 실행 (3×10^7 스텝, D3 기준 교사 질의 2.4×10^8 이미지)의 벽시계 시간은 논문에 없습니다. 논문 그림 수준 (1.25×10^7 스텝, 5 시드)은 A40급 GPU 수 장으로 며칠 규모로 추정합니다. 추정치이며 측정하지 않았습니다.
- **판정:** 기술적으로 가능하지만 GPU가 있는 곳에서만, 버전 고정 작업을 거쳐야 합니다.

### 4.2 이 맥 (Apple M4 Pro, 약 24 GiB 통합 메모리, MPS, CUDA 없음, torch 미설치)

- **공식 재현: 불가.** `sim_backend="gpu"` 하드코딩 (D13)과 OpenVLA의 `cuda:0` 과 `flash_attention_2` (D14)가 막습니다. Octo는 JAX 기반이고 Apple 쪽 GPU 가속 경로가 표준이 아닙니다.
- **CPU 검증: 제한적으로 가능.** 학생 PPO의 MSE 항은 교사 없이도 토이로 확인할 수 있습니다(`03` §5). 이것은 손실 수학의 확인이며 논문 수치 재현이 아닙니다.
- **MPS로 OpenVLA:** 7B 모델은 이 기기에서 실용적이지 않습니다.

### 4.3 아이디어 재구현 노력

- **손실 항만 옮기기:** CleanRL 스타일 PPO에 교사 질의 함수와 MSE 한 줄을 붙이는 것은 쉽습니다. 어려운 부분은 교사 서버와 GPU 시뮬입니다.
- **교사를 바꾸기:** 교사를 임의의 정책 함수로 바꾸면 RPD 항은 교사를 모르고 동작합니다. 교사 질의 비용이 줄어듭니다(예: 교사 질의를 롤아웃 때 한 번만).

### 4.4 판정 (한 줄)

**공식 재현은 NVIDIA GPU 환경과 버전 고정이 있을 때만 가능하고, 이 맥에서는 불가입니다. 아이디어(MSE 항) 재구현은 쉽고, 그 효과를 교사 없이 확인하는 토이는 CPU에서 가능합니다.**

## 5. 라이선스와 코드 사용

- RPD: Apache-2.0 (`LICENSE` 파일과 `pyproject.toml` 일치).
- vlagents: Apache-2.0 (GitHub API). 이 조사에서 받은 소스는 공개본에 넣지 않습니다.
- 체크포인트: MIT (태그), 데이터셋: Apache-2.0 (태그). 두 가지 모두 HF 모델 카드에 명시적 라이선스 파일이 있는지는 확인하지 않았습니다.

- 공개본에는 코드를 복사하지 않고 파일명과 줄 번호로만 인용합니다.

## 6. 재현에 필요하지만 논문과 코드에 없는 정보

- 시드 목록과 실행 명령, 교사 질의 방식의 실제 로그 (D11)
- 과제별 최대 에피소드 길이와 데이터 필터 (D22)
- ManiSkill3 기준선의 하이퍼파라미터 (D9)
- PPD 구현 (D15)
- 교사 샘플 방식의 `agents` 2025 상태 확인 (이 조사에서 확인한 것은 2025-07-18 `f51338c`까지)
- 학습 길이 (D24)
- 벽시계 시간과 GPU 사용량