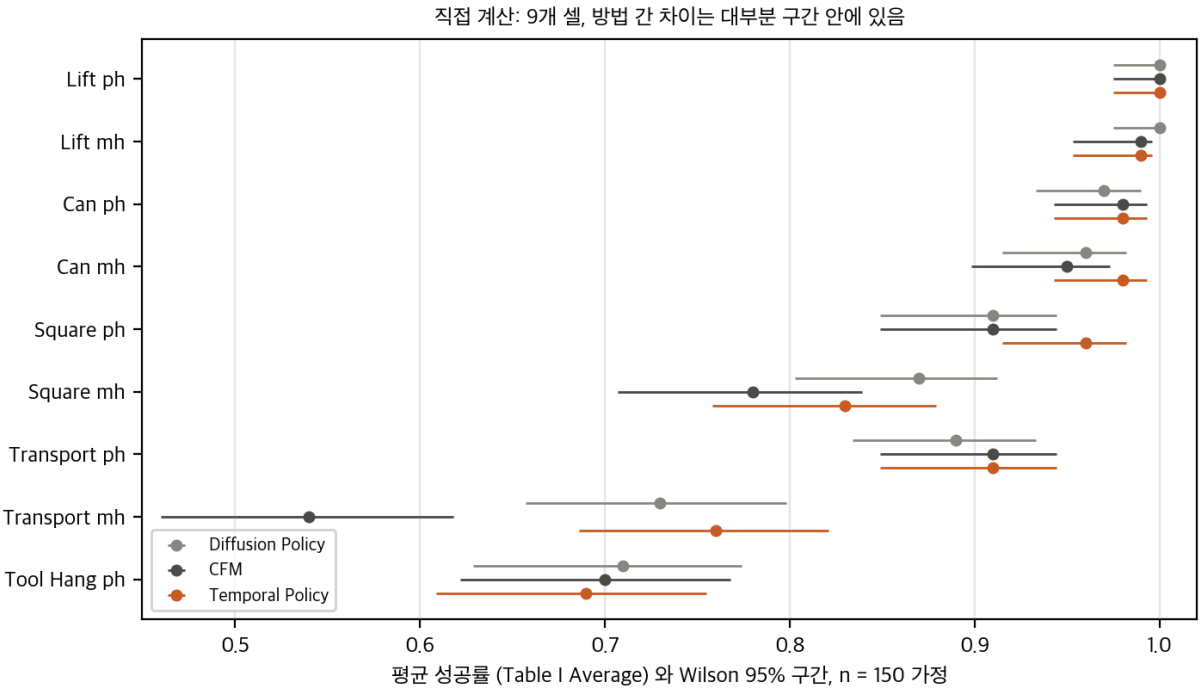
Temporal Policy: 분석 리포트

게시용 버전: 논문 그림과 표는 라이선스(arXiv 비독점 배포) 때문에 제외했습니다. 원문 https://arxiv.org/abs/2607.29482 · arXiv:2607.29482v1 · IROS 2026 (채택) · Dylan Miller, Martin Jagersand (University of Alberta) · 공식 코드 MIT (dmiller12/TemporalPolicy, e1e7ee5, 2026-08-18) · 분석일 2026-11-10

핵심 요약

1. **무엇을 하는가:** 플로우 매칭 정책의 출발점을 가우시안 잡음에서 로봇의 상태 이력으로 바꿉니다. 목표는 14 스텝 뒤의 행동 청크이고, 추론은 10 Euler 단계입니다. 학습 손실과 점수 식은 표준 확률적 보간을 따릅니다.
2. **"order of magnitude" 전달 비용 감소는 수치가 맞고, 원인이 다릅니다:** CFM 대비 8.3배는 14 스텝 떨어진 행동 쌍의 상관 ρ_{14}가 0.76-0.88이면 나옵니다(단위 분산 가정). DP 대비 157배의 대부분은 샘플러와 측정 방식에서 옵니다. 두 방법은 같은 잡음 원천인데 DP와 CFM의 차이가 19배입니다(`03` §3, §4).
3. **직진성 1.02는 식으로는 나올 수 없고, 코드 정의로만 나옵니다:** 식 7-8로 10단계 직선 경로를 재면 0.1입니다. 공개 코드는 길이 합으로 재고 직선이면 1입니다. 표 수치는 코드와 맞습니다(`04` D8).
4. **결정적 샘플러는 조건부 평균을 냅니다:** 점 원천에서 결정적 ODE는 평균 경로에 머뭅니다. 두 모드 목표에서 모든 단계 수에 끝점이 두 모드 사이에 옵니다. 모드 분리는 SDE(추론 g > 0)에서만 나옵니다. 논문 표 I의 NFE 10은 결정적 설정입니다(`03` §6.2, `04` D5).
5. **성공률은 DP와 차이 없고, CFM 대비로는 Transport mh 한 셀만 유의합니다:** 9셀 CMH 대 DP p = 0.69, 대 CFM p = 0.0014(Holm 보정 후 Transport mh 0.002). 근거는 Average 기준의 근사입니다(`03` §1.1).
6. **지연 19.1 ms의 이득은 모델 크기에서 옵니다:** NFE 10이 같은 CFM(63.5 ms) 대비 3.3배 차이는 파라미터 255M 대 17M와 함께 나옵니다. 원천 효과는 분리되지 않았습니다(`03` §5).
7. **실물 10/20, 집기 19/20은 기준선이 없습니다:** Wilson 95% [0.30, 0.70]. 코드도 공개되지 않았습니다(`04` D12).



직접 계산: Table I의 Average 성공률과 Wilson 95% 구간(n = 150 가정). 방법 간 차이 대부분은 구간 안에 있습니다.

구현 가능성 (판정)

공식 시뮬 재현은 GPU가 있으면 가능하고, 이 맥에서는 학습이 불가능합니다. 실물 재현은 불가능합니다(코드 없음). 아이디어 재구현은 중간 난이도입니다.

항목	이 맥(Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, torch 미설치)에서
공식 시뮬 재현 (Robomimic, 한 과제)	학습 불가(CUDA 필요, 학위논문 기준 과제당 2.5-53시간 A100). 평가도 MuJoCo와 데이터가 필요
공식 실물 재현	불가(코드와 하드웨어 없음)
아이디어 재구현	가능(중간 난이도). 원천을 이력으로 바꾸고 점수 보정 두 줄을 더함. 토이 수준은 이미 완료
필요한 하드웨어	학습에 GPU 1장(시뮬 17M 모델 기준). 지연 비교에는 CUDA 장치가 필요

권리 표기

- **논문:** arXiv 비독점 배포 라이선스(CC BY 아님). PDF 1쪽에 IEEE 저작권 문구는 없습니다(확인). 그래서 논문 그림과 표는 개인용 리포트와 PPT에만 넣고, 게시본에는 직접 만든 그래프만 넣습니다.
- **공식 코드:** MIT(`LICENSE`). 클론만 했고 재배포하지 않습니다.

01. 논문 분석: Temporal Policy (arXiv:2607.29482v1)

제목(원문 그대로): Temporal Policy: History-Initialized Action Generation for Robotic Learning from Demonstration **저자:** Dylan Miller, Martin Jagersand (University of Alberta, Canada) **arXiv:** 2607.29482v1, 2026-07-31 제출, cs.RO, 8쪽. 같은 저자의 학위논문(79쪽, 프로젝트 페이지에 링크)을 보조 자료로 함께 읽었습니다(`paper/thesis.pdf`, `paper/thesis.txt`). **학회:** IROS 2026 채택. 학위논문 서문에 "accepted for publication at IROS 2026"이 있습니다. arXiv PDF 자체에는 학회 표기가 없습니다. **공식 코드:** `github.com/dmiller12/TemporalPolicy` (MIT). 논문 초록과 프로젝트 페이지가 모두 이 저장소를 가리킵니다. 얕은 클론 커밋 `e1e7ee5` (2026-08-18)를 `repo/TemporalPolicy/`에 두고 대조했습니다(`04_code_verification.md`).

0. 한 줄 요약

생성 모델(플로우 매칭)의 출발점을 가우시안 잡음 대신 로봇의 최근 상태 이력으로 바꾸면, 전달 비용과 직진성이 좋아지고 추론 단계 수(NFE)를 10으로 줄여도 Robomimic 성공률이 CFM과 비슷하다는 주장입니다. 다만 이 논문이 보인 효과 중 상당 부분은 **데이터 쌍의 시간 간격(d = 14)과 행동 정규화**에서 나오고, 공개된 샘플러에서 결정적 ODE는 사실상 **조건부 평균(회귀)** 을 출력합니다(`03` §6, §7).

1. 문제 설정과 동기 (Sec. I, II)

- 표준 확산·플로우 정책은 가우시안 잡음 `x0 ~ N(0, I)`에서 행동 청크 `x1`로 가는 흐름을 학습합니다(Sec. I, Fig. 1). 논문은 이 원천이 "정보 없는 사전분포"라서 긴 곡선 경로와 많은 적분 단계를 낳는다고 봅니다(Sec. I, II-A).
- 관련 연구로 CFM(Sec. II-B)과 OT-CFM, Schrödinger bridge를 다루고, 데이터 의존 결합(Sec. II-C)으로 Streaming Flow Policy(이전 행동에서 출발), VITA(잠재 시각 표현 원천), Trajectory Flow Matching(관측 이력 조건, 이중 네트워크)을 비교합니다. 논문의 차별점은 **학습된 두 번째 네트워크 없이** 이력 그 자체를 원천으로 쓰는 것입니다.
- 이론적 틀은 Chen et al.(ICML 2024, [7])의 확률적 보간(stochastic interpolant)을 따릅니다. 원천을 점질량 `δ(x0)`로 두는 "점에서 분포로" 수송입니다.

2. 방법 (Sec. III)

2.1 원천과 목표 (Sec. III-A)

- 상태 공간과 행동 공간을 같은 표현(관절 위치 또는 말단 자세)으로 둡니다(식 없음, 강한 가정).
- 시각 `t`에서 **원천** `x0 = s[t-H+1 : t]` (상태 이력), **목표** `x1 = s[t-H+1+d : t+d]` (d시점 뒤로 밀린 "미래 행동" 청크), `1 ≤ d ≤ H`. `d < H`면 두 열이 겹칩니다(Sec. III-A).
- 실험 설정은 H = 16, d = 14, 겹침 2(학위논문 부록 A.1). 실물은 겹침 2, 관측 창 2(Sec. IV-E).

2.2 학습 (Sec. III-C, Alg. 1, 식 1-3)

- 보간(식 1): `xλ = (1-λ)x0 + λx1 + ε(1-λ)wλ`, `λ ~ U(0,1)`, `ε`는 학습 잡음 계수. 선형 보간을 골랐다고 명시합니다.
- 드리프트 목표(식 2-3): `u_λ = (x1 − x0) − ε√λ z`, 손실 `L = E‖b_θ(xλ, x0, λ, c) − u_λ‖²`. 확률 미분 방정식은 식 2입니다.
- 관측 조건 `c`는 ResNet-18 + Spatial Softmax + FiLM으로 넣습니다(Sec. III-D). 드리프트 네트워크는 1D U-Net입니다.

2.3 추론 (Sec. III-E, Alg. 2, 식 4-6)

- 점수(식 4-5): `∇x log p_λ(x|x0) = [λ u_λ − (x − x0)] / (ε² λ(1−λ))`. 조건부 가우시안 구조에서 닫힌 식입니다. **이 식은 코드의 `compute_score`와 수치로 일치합니다(`03` §7, 최대 차이 2e-9).**
- 추론 SDE(식 6): `dx = [u_λ + (g_λ² − γ_λ²)/2 · ∇log p] dλ + g_λ dw`. `g_λ = 0`이면 결정적 흐름(ODE), `g_λ > 0`이면 확률적 샘플링입니다.
- 논문은 결정적 샘플링을 주 방식으로 씁니다(Sec. IV-C). 실물은 10 Euler 단계, 청크 16개 예측·8개 실행(수신 지평, Sec. III-E 끝, Sec. IV-E).

2.4 논문이 제시한 핵심 논리

1. 원천이 목표에 가까우면 전달 거리가 짧다(Sec. III-B, 식 없이 서술).
2. 같은 가정에서 `J_temporal < J_indep`이다. `J_indep = 2HD`, `J_temporal = 2HD − 2E[x1ᵀx0]` (Sec. III-B). 이 유도는 **각 차원이 분산 1로 표준화되었다**고 가정합니다(§5 `03` 참조).
3. 짧고 직선인 흐름이면 적은 단계로 적분할 수 있다(Sec. IV-A, IV-B).

3. 실험 (Sec. IV)

3.1 시뮬레이션 (Sec. IV-A, Table I)

- 과제 5개(Lift, Can, Square, Transport, Tool Hang), 데이터 ph(숙련 사람)와 mh(여러 사람, Tool Hang 제외).
- 기준선: Diffusion Policy(DDPM, 255M, 100 NFE)와 CFM(255M, 10 NFE). 제안법은 17M 파라미터(U-Net [256, 512]).
- 평가: 체크포인트당 50회, 시드 3개, 50 epoch마다 평가. **Max는 학습 전체 최댓값, Average는 마지막 10개 체크포인트 평균**(Table I 캡션).
- 학습: 배치 128, 1500 epoch, A100 1장. 추론 지연은 RTX 4080(Table I).

Table I 요지(성공률 Max/Average):

과제	제안법 Average	DP Average	CFM Average
Lift ph / mh	1.00 / 0.99	1.00 / 1.00	1.00 / 0.99
Can ph / mh	0.98 / 0.98	0.97 / 0.96	0.98 / 0.95
Square ph / mh	0.96 / 0.83	0.91 / 0.87	0.91 / 0.78
Transport ph / mh	0.91 / 0.76	0.89 / 0.73	0.91 / 0.54
Tool Hang ph	0.69	0.71	0.70
NFE / 지연(ms)	10 / 19.1	100 / 615.6	10 / 63.5

- 논문은 "outperforming on Can mh, Square ph, Transport mh, underperforming on Square mh and Tool Hang ph"라고 씁니다(Sec. IV-A). 재계산 결과 차이는 대부분 구간 안에 있고, 통계적으로 남는 것은 Transport mh의 CFM 대비 차이뿐입니다(`03` §1).

3.2 전달 비용 (Sec. IV-B, Table II, 식 7-8)

- 식 7: `J(τ) = Σ_k (‖p_{k+1} − p_k‖² + r·θ(R_k, R_{k+1}))`, `r = 0.1 m`. 식 8: `J(τ) / (‖p_K − p_0‖² + r·θ(R_0, R_K))`.

Table II (Square ph, 50 에피소드):

방법	전달 비용	직진성 비율
Diffusion Policy	189.99	20.61
CFM	10.00	1.08
제안법	1.21	1.02

- 논문은 "nearly an order of magnitude"라고 씁니다. CFM 대비 8.3배, DP 대비 157배입니다. 두 방법 모두 `N(0, I)` 원천이라 결합 비용은 같은데도 DP와 CFM의 차이가 19배입니다. 그 차이는 샘플러(100단계 DDPM 대 10단계 ODE)와 측정 방식에서 옵니다(`03` §4, §8).
- 직진성 1.02 대 1.08(CFM)은 학위논문 표 5.4의 SD(0.03, n = 100)로 보면 통계적으로는 구별되지만(Welch p ≈ 1e-38) 차이가 7%입니다(`03` §1.4).

3.3 추론 단계 수와 잡음 (Sec. IV-A 끝, IV-C, Fig. 3)

- Fig. 3 왼쪽(Tool Hang ph): 제안법은 NFE 1에서 약 0.6, CFM도 약 0.56, DP는 32 NFE 미만에서 0입니다. 10 NFE 이상에서 세 방법이 비슷해집니다.
- Fig. 3 오른쪽: 추론 SDE 계수 ε를 올리면 성공률 곡선이 오른쪽으로 밀립니다. ε = 0은 2-4 단계에서 높은 성공률, ε = 1.0은 8-16 단계가 필요합니다. 결정적 ODE를 쓰는 근거입니다.
- 학습 잡음 `ε` 값은 본문에 없습니다(학위논문: ε = 1.0으로 고정, 부록에서 ε = 0.1일 때 NFE 1 성공률 0.34, ε = 1.0일 때 0.89, 표 5.1 본문 설명).

3.4 데이터 효율 (Sec. IV-D, Fig. 4)

- Square ph에서 데이터 수 40-200을 바꾼 곡선 하나. 제안법이 DP보다 모든 구간에서 높다고 씁니다. 시드 수, 오차 막대, 평가 횟수가 없습니다. 그림에서 읽으면 40개일 때 0.51 대 0.44, 200개일 때 0.995 대 0.98입니다(읽은 값, 그림 기준).

3.5 실물 (Sec. IV-E, F)

- 양팔 원격조작 장치, 7자유도 Barrett WAM 추종기, BarrettHand. 10 Hz 제어, 두 카메라.
- 과제: 머그를 집어 나무 못에 걸기. 시연 150개. **20회 평가, 10/20 성공(50%), 집기 19/20(95%).** 실패는 정렬 단계에서 깊이를 덜 밀어 넣는 것이었습니다.
- **비교 기준선이 없습니다.** DP나 CFM을 같은 실물 과제에 돌리지 않았습니다.

4. 결론과 한계 (Sec. V)

논문이 스스로 밝힌 한계:

- 원천이 현재 관측에 묶이므로 **초기화 품질에 민감합니다.** 원천의 잡음이 크면 생성 궤적이 치우칩니다(Sec. V).
- 미래 연구: 현재 속도로 원천을 앞으로 밀기, 힘·토크 제어, 키포인트 표현.
- "이력 초기화가 다중 모드를 분리하는지, 행동의 다양성을 보존하는지"는 **연구 과제로 남겨 둡니다**(Sec. V 첫 문단).

5. 학위논문과의 차이 (보조 자료, `paper/thesis.txt`)

항목	arXiv v1	학위논문	비고
Table II 표본	50 에피소드, SD 없음	100 에피소드, 평균 ± SD (표 5.4)	학위논문에서 Welch 검정 가능
단일 단계 성공률	본문에 수치 없음(Fig. 3 왼쪽)	표 5.3, 100 에피소드	제안법 Square mh 0.88 대 CFM 0.70 (Fisher p ≈ 0.003)

항목	arXiv v1	학위논문	비고
ε 절제	Fig. 3 오른쪽, Tool Hang ph	그림 5.1 오른쪽, 캡션은 Tool Hang, 본문은 Transport	학위논문 본문과 캡션이 다릅니다
데이터 효율	Square ph, DP만 비교	Square, TP·DP·CFM 세 방법, 50-225 데모	
다중 모드	주장 없음	부록 A.2: 시계 방향·반시계 방향 두 모드를 SDE로 보여 준 정성 그림 한 장	정량 평가 없음
실물 지연	19.1 ms(시뮬), 실물 지연 언급 없음	실물 19.62 ms(1.78 ms × 10 + 시각 1.86 ms)	
학습 epoch	1500	1500	저장소 기본 설정은 4500(`04` D6)
행동 정규화	표준화(분산 1)라고 가정 (Sec. III-B)	모든 행동 차원을 [−1, 1]로 정규화(부록 A.1)	분석 가정과 다릅니다(`03` §2)

6. 논문 안에서 찾은 불일치와 빠진 정보

1. **식 7·8의 정의와 Table II 수치가 맞지 않습니다.** 식은 스텝 거리의 제곱 합과 끝점 거리의 제곱을 씁니다. 10단계 직선 경로에서 이 식은 1/10을 줍니다. 그런데 표의 직진성은 1.02, 1.08입니다. 공개 코드는 거리의 **합(제곱 없음)** 과 회전 각을 쓰고 끝점 거리로 나눕니다(`04` D8). 표 수치는 코드 정의와 맞습니다.
2. **원천과 목표의 시간 정렬이 식과 그림에서 다르게 읽힙니다.** 식 본문은 `x1 = s[t−H+1+d : t+d]`(상태)라고 쓰고, 그림 2는 원천을 `s_{t−1}`(한 상태)라고 씁니다. 코드는 원천 `s[t−15 : t]`(16개 상태)와 목표 `a[t−1 : t+14]`(16개 행동)를 인덱스 순서대로 짝짓습니다(`04` D2).
3. **같은 인덱스의 원천과 목표는 14 스텝 떨어진 시점입니다.** 그래서 전달 거리는 "14 스텝 동안의 움직임"입니다. 중복(겹침 2)은 시간으로는 같은 값이지만, 흐름이 학습하는 쌍은 인덱스 기준이므로 실제 이동량은 d에 의해 정해집니다(`03` §2, §8).
4. **실물의 결합 표현이 상태-행동 동등 가정에 맞지 않습니다.** 결합은 "관절 위치와 그리퍼 속도"(Sec. IV-E)라고 씁니다. 그리퍼 속도는 상태가 아니라 파생량입니다. 학위논문에도 같은 문장이 있습니다.
5. **실물 제어 코드는 저장소에 없습니다.** `real_world/` 폴더에는 비디오 기록기만 있습니다. 500 Hz 보간(학위논문 5.2절)도 공개되지 않았습니다.
6. **학습 epoch 불일치.** 논문과 학위논문은 1500, 저장소 기본 설정은 4500입니다(`04` D6).
7. **평가 횟수 불일치.** 논문은 체크포인트당 50회, `eval.py`는 100회입니다. 학습 중 롤아웃은 50회입니다.
8. **추론 설정 불일치.** 논문 표의 NFE 10은 결정적 ODE입니다. 공개 `eval.py`는 추론 SDE 계수를 1.0으로, 단계 수를 100으로 덮어씁니다(`04` D5).
9. **정규화 가정.** 분석 식은 분산 1을 쓰고, 코드는 [−1, 1] 범위 정규화를 씁니다(`03` §2).
10. **ε 값이 본문 주 결과에 없습니다.** 학위논문만 1.0을 적습니다.
11. **Fig. 2의 원천 표기**가 본문과 다릅니다(위 2번).
12. **원천 밀기 제안과 실물 평가 부족.** 실물 한 과제, 20회, 기준선 없음.

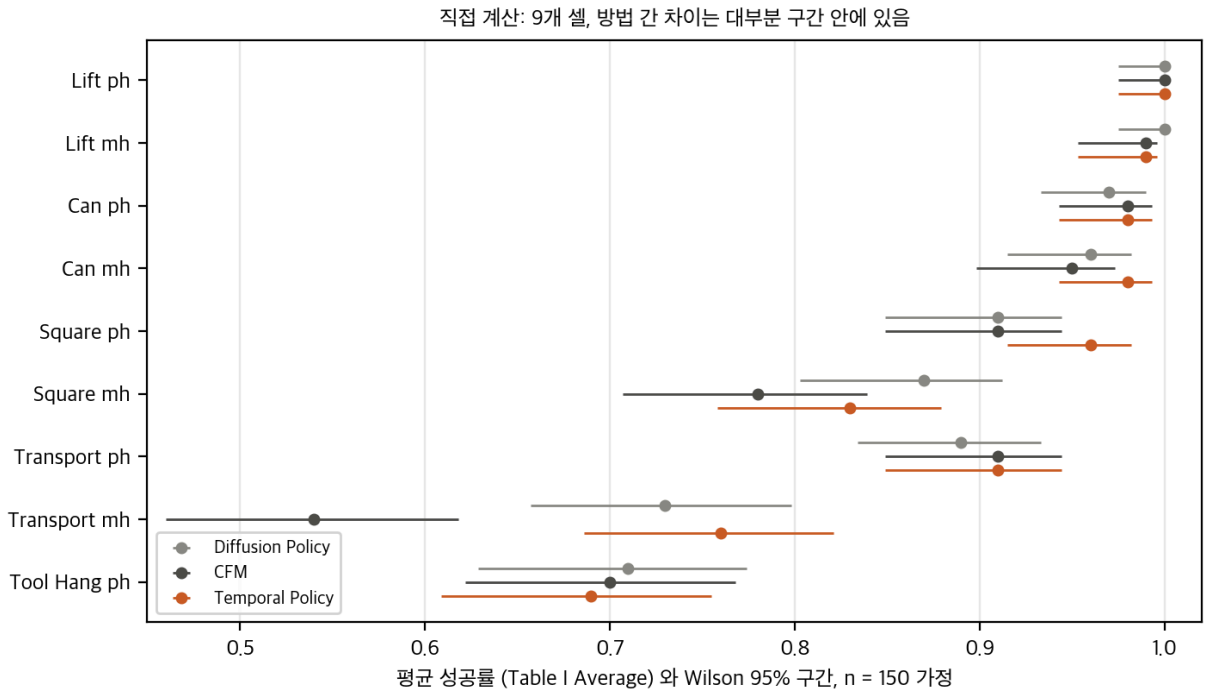
7. 용어

- 원천(source) x0: 이력, 확률 과정의 출발 분포. 여기서는 점질량.
- 목표(target) x1: 미래 행동 청크(인덱스 순서로 d만큼 밀림).
- 드리프트 b_θ: 신경망이 예측하는 `E[ẋ | xλ, x0, c]`.
- 결정적 ODE: 추론 SDE 계수 g = 0. 논문 식 6의 보정항은 g = 0에서도 남습니다(`03` §6).
- NFE: 드리프트 신경망 호출 수. 여기서는 적분 단계 수와 같습니다(Euler 1단계 = NFE 1).

03. 재계산과 유도

재계산 스크립트는 `analysis/table_check.py` (→ `table_check_results.json`), `analysis/transport_toy.py` (→ `transport_toy_results.json`), `analysis/plot_figures.py` 입니다. 모두 단일 스레드 numpy와 scipy로 이 맥에서 각각 수 초에서 15초 걸립니다. 설치는 하지 않았습니다(scipy는 기존 설치본).

1. 표 재계산과 유의성



직접 계산: Table I Average와 Wilson 95% 구간(n = 150 가정), 9셀 × 3방법.

1.1 Table I (9셀, Average 기준)

Average는 체크포인트 10개의 평균이라 이항 표본이 아닙니다. 그래서 **유효 표본 n = 150(3 시드 × 50 평가)으로 가정**하고 성공 횟수를 `round(평균 × 150)` 으로 바꿔 계산했습니다. 이 가정은 근사이고, 실제 불확실성은 이보다 클 수도 작을 수도 있습니다. Max는 학습 전체의 최댓값이라 선택 편향이 있어 검정하지 않았습니다.

과제	분할	DP	CFM	제안법	제안법 – DP (pp), Fisher p	제안법 – CFM (pp), Fisher p
Lift	ph	1.00	1.00	1.00	0.0, 1.00	0.0, 1.00
Lift	mh	1.00	0.99	0.99	–1.0, 0.50	0.0, 1.00
Can	ph	0.97	0.98	0.98	+1.0, 1.00	0.0, 1.00
Can	mh	0.96	0.95	0.98	+2.0, 0.50	+3.0, 0.22
Square	ph	0.91	0.91	0.96	+5.0, 0.10	+5.0, 0.10
Square	mh	0.87	0.78	0.83	–4.0, 0.42	+5.0, 0.38
Transport	ph	0.89	0.91	0.91	+2.0, 0.85	0.0, 1.00
Transport	mh	0.73	0.54	0.76	+3.0, 0.69	**+22.0, 0.000 (Holm 18개 보정 후 0.002)**
Tool Hang	ph	0.71	0.70	0.69	–2.0, 0.80	–1.0, 0.90

- **Cochran-Mantel-Haenszel(9셀):** 제안법 대 DP 공통 OR = 1.06, p = 0.69. 제안법 대 CFM 공통 OR = 1.52, p = 0.0014. 대 CFM 차이는 Transport mh가 대부분을 설명합니다.
- **해석:** 제안법은 DP와 차이가 없습니다. CFM 대비로는 Transport mh 한 셀만 Holm 보정 후 남습니다. 나머지 셀의 +3 ~ +5pp는 구간 안에 있습니다. 논문이 "outperforming"으로 든 셀(Can mh, Square ph, Transport mh, Sec. IV-A) 중 유의한 것은 Transport mh(대 CFM) 하나뿐입니다. `own_table1_ci.png` 가 구간을 보여 줍니다.

1.2 Table II (논문, 50 에피소드)

비교	비율	해석
CFM / 제안법 (전달 비용)	10.00 / 1.21 = **8.26**	"nearly an order of magnitude" 근거
DP / 제안법 (전달 비용)	189.99 / 1.21 = **157**	논문 본문은 "150배 이상" (학위논문)
DP / CFM (전달 비용)	189.99 / 10.00 = **19**	두 방법 모두 N(0, I) 원천이라 결합 비용은 같은데도 19배
직진성	제안법 1.02, CFM 1.08, DP 20.61	SD 없음

표 II에는 SD와 시드가 없어서 신뢰구간을 만들 수 없습니다. 학위논문 표 5.4에서 SD를 얻을 수 있습니다(§1.4).

1.3 학위논문 표 5.3: 단일 단계 성공률 (n = 100)

과제	분할	CFM	제안법	Fisher p	Holm 9개 보정
Square	mh	0.70	**0.88**	0.0029	**0.026**
Square	ph	0.84	0.90	0.29	1.00
Can	mh	0.94	0.97	0.50	1.00
Transport	mh	0.63	0.67	0.66	1.00
Transport	ph	0.91	0.92	1.00	1.00
Tool Hang	ph	0.56	0.61	0.57	1.00
Lift, Can ph	—	1.00, 0.98	1.00, 0.98	1.00	1.00

DP는 1단계에서 0%입니다(Lift mh 13% 제외). **1단계 추론에서 제안법은 CFM과 같거나 조금 낮고, 유의한 차이는 Square mh 한 셀뿐입니다.** §7에서 보듯 이 1단계 출력은 조건부 평균입니다.

1.4 학위논문 표 5.4: 전달 비용과 직진성 (평균 ± SD, n = 100)

비교	차이 또는 비율	Welch t	p
전달 비용, CFM 대 제안법	9.99 / 1.21 = 8.26배	72.1	6e-140
전달 비용, DP 대 제안법	190.02 / 1.21 = 157배	467	1e-292
직진성, CFM 1.09 ± 0.03 대 제안법 1.02 ± 0.03	0.07	16.5	2e-38

- 직진성 차이는 통계적으로 뚜렷하지만 크기는 7%입니다. 논문도 "only slight improvements over CFM"이라고 씁니다(학위논문 5.1.2).
- Welch는 에피소드를 독립으로 본 근사입니다. 전달 비용 분포는 한쪽으로 치우쳐 있을 수 있어 비모수 검정이 더 안전합니다. 원자료가 없어 확인하지 못했습니다.

1.5 실물 (Sec. IV-E, F)

지표	성공	비율	Wilson 95%
전체	10/20	0.50	[0.30, 0.70]
집기	19/20	0.95	[0.76, 0.99]

비교 기준선이 없습니다. 20회 중 10회 성공은 0.30에서 0.70 사이의 어떤 값과도 구별되지 않습니다. 실물 결과로는 "50% 수준의 시험 결과가 있다"까지만 말할 수 있습니다.

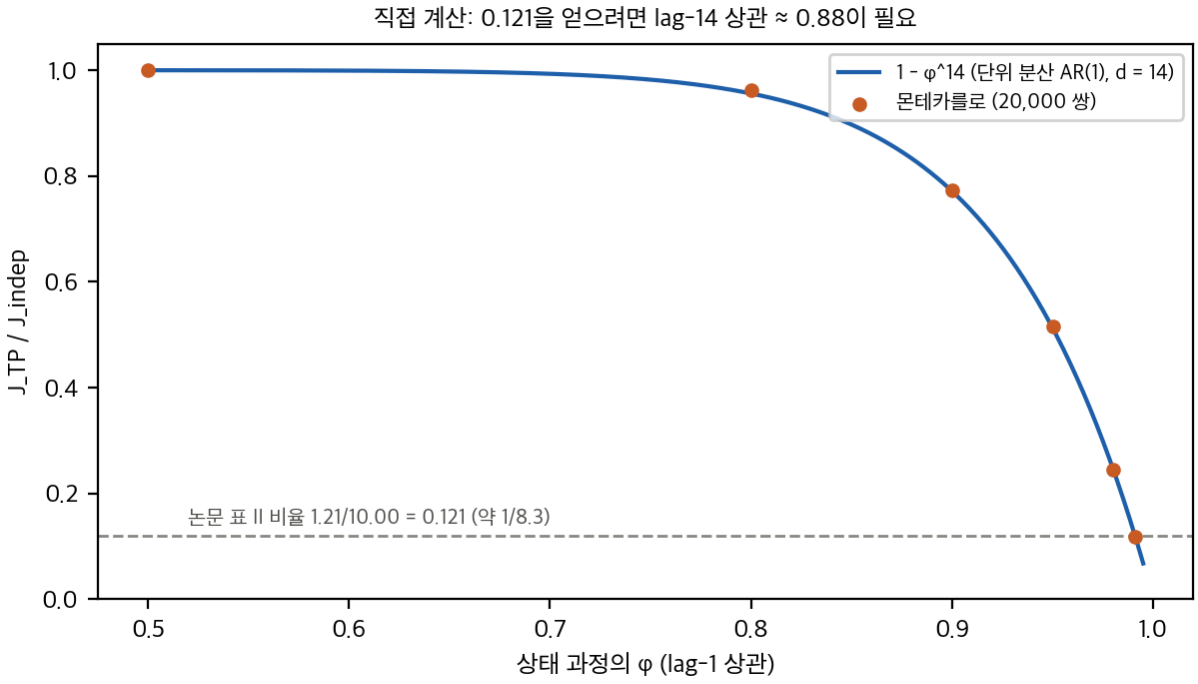
2. 행동 정규화와 분산 가정

논문 Sec. III-B는 "학습 데이터를 자유도별로 표준화했다"고 가정하고 $E\|x\|^2 = HD$를 씁니다. 코드와 학위논문 부록 A.1은 **모든 행동 차원을 [−1, 1]로 정규화**합니다(범위 정규화, `robomimic_abs_action_only_normalizer_from_stat`).

차원별 이차 모멘트를 $m = E[x_d^2]$라 하면(정규화 후, 두 원천 모두 같은 분포라 가정):

- 독립 잡음 원천 $x0 \sim N(0, I)$: $E\|x0\|^2 = HD$, $E\|x1\|^2 = mHD$. 따라서 $J_{indep} = E\|x1 - x0\|^2 = HD(1 + m)$.
- 논문 식: $J_{indep} = 2HD$는 $m = 1$일 때만 맞습니다.
- 이력 원천: $J_{TP} = E\|x1\|^2 + E\|x0\|^2 - 2E[x1^\top x0] = 2mHD(1 - \rho_d)$. 여기서 ρ_d는 d 스텝 떨어진 쌍의 상관(정상성 가정, 두 원천 분포가 같다는 가정).
- 비율: **$J_{TP} / J_{indep} = 2m(1 - \rho_d) / (1 + m)$**. m = 1이면 $(1 - \rho_d)$입니다.

m = 1/3(범위 [−1, 1]의 균등 분포)이면 J_indep = (4/3)HD입니다. 논문의 2HD보다 1.5배 작습니다. 실제 데이터는 균등 분포가 아니므로 m은 데이터마다 다릅니다. 이 차이는 비율의 수치를 바꾸지만 방향은 바꾸지 않습니다.



직접 계산: J_TP / J_indep = 1 − φ^14 (몬테카를로 점 포함). 논문 비율 0.121에는 φ ≈ 0.991이 필요.

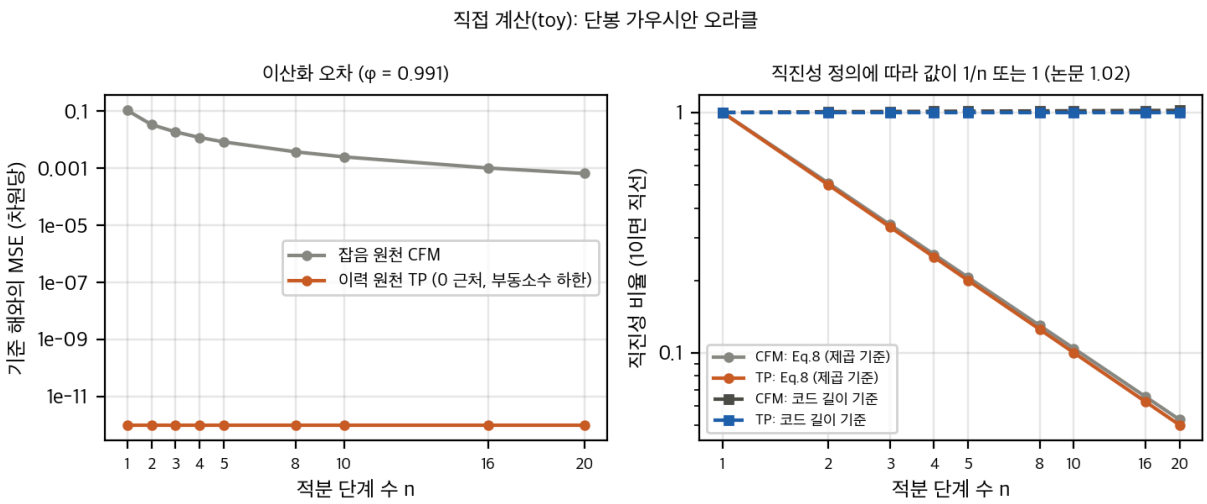
3. 결합 비용 항등식과 toy A

항등식 검증 (몬테카를로, 쌍 20,000개, 단위 분산 AR(1), d = 14):

φ	$\rho_{14} = \varphi^{14}$	MC: J_TP / J_indep	$1 - \rho_{14}$
0.5	0.00006	0.99997	0.99994
0.8	0.044	0.962	0.956
0.9	0.229	0.774	0.771
0.95	0.488	0.515	0.512
0.98	0.754	0.245	0.246
0.991	0.881	0.1187	0.1189

- 논문의 CFM/제안법 비율 8.26(표 II)을 얻으려면 **$\rho_{14} \approx 0.88$(m = 1)** 또는 **$\rho_{14} \approx 0.76$(m = 1/3)** 이 필요합니다. 14 스텝 떨어진 행동 사이의 상관이 0.76 이상이어야 "order of magnitude"가 나옵니다.
- φ = 0.9(ρ_{14} = 0.23)이면 전달 비용 비율은 약 0.77입니다. 즉 1.3배에 그칩니다.
- **d에 대한 민감도는 보고되지 않았습니다.** d = 10이면 비율은 1 – φ ≈ 0.009입니다. 거리는 거의 0이 되지만 목표가 원천의 복사본이 되어 의미가 없습니다(copycat, §9). d = 14는 저자들이 고른 값이고, 그 선택이 비율을 결정합니다.

4. 측정 정의와 단계 수 의존 (Table II, 식 7-8, 코드)



직접 계산(toy): 단봉 오라클의 이산화 오차(왼쪽)와 직진성 정의에 따른 값(오른쪽). 식 기준은 1/n, 코드 기준은 1.

4.1 식 7-8의 직진성은 10단계에서 1이 될 수 없습니다

식 7은 스텝 거리의 **제곱** 합, 식 8은 끝점 거리의 **제곱**으로 나눕니다. K 스텝 직선 경로(스텝 길이 D/K)에서 식 7 = K·$(D/K)^2$ = D^2/K이고, 식 8 = 1/K입니다. **K = 10이면 0.1이고, 논문의 1.02와 맞지 않습니다.** 토이에서 같은 정의를 쓰면 CFM과 제안법 모두 1/n을 보입니다(`own_nfe_error.png` 오른쪽, 파란 점선과 함께).

4.2 공개 코드의 정의는 길이 기준입니다

`env_runner/robomimic_runner.py::compute_transport`는 스텝 거리의 **합(제곱 없음)** 과 회전 측지 거리(×0.1)를 더하고, 직진성은 **총 길이 ÷ 끝점 거리**입니다. 직선 경로에서 1이 됩니다. 토이의 길이 기준 값은 제안법 1.00, CFM 1.00-1.02(n = 1-20)입니다. 논문 표 II의 1.02와 1.08과 맞습니다. **표 II 수치는 식이 아니라 코드 정의로 계산된 것으로 보입니다**(`04` D8).

4.3 전달 비용의 단계 수 의존

토이(단봉 가우시안, φ = 0.991, Eq. 7 제곱 합, 평균):

n	CFM (Eq. 7)	제안법 (Eq. 7)	비율
1	30.01	1.98	15.1
2	14.54	0.99	14.7
10	2.78	0.198	14.0
20	1.38	0.099	13.9

- 비율은 약 14배로, 논문의 8.3배보다 큽니다. 학습된 모델의 경로는 오라클보다 흔들려서(경로 길이가 늘어서) 실제 비율이 줄어드는 것으로 해석할 수 있습니다. 이 해석은 학습 결과로 확인하지 못했습니다.
- φ = 0.9(ρ_{14} = 0.23)에서는 같은 비율이 1.3-1.5배입니다.
- **DP(DDPM 기반 100 단계)의 190은 CFM과 원천이 같은데도 19배 큽니다.** 결합 비용으로는 설명되지 않습니다. 확률적 경로의 잡음 스텝이 단계 수에 비례해 쌓이는 효과 또는 측정 방식 차이로 보입니다. 이 가설은 공개 평가를 돌려 확인해야 하므로 미검증입니다.

5. 지연 분해 (Table I)

방법	NFE	파라미터	지연(ms)	NFE당 (ms)
DP	100	255M	615.6	6.16
CFM	10	255M	63.5	6.35
제안법	10	17M	19.1	1.91

- **NFE가 같은 10일 때 CFM과 제안법의 지연 차이는 3.3배입니다.** 같은 시기에 파라미터는 15배 적습니다. 지연 차이는 원천 선택이 아니라 **모델 크기**로 설명됩니다.
- 학위논문은 "17M 모델로 CFM을 같은 크기에서 학습한 대조군은 transport 과제에서 성능 저하가 없었다"고만 씁니다(5.1.1). 수치가 없습니다. 원천 효과를 분리하려면 **17M 크기 CFM의 지연과 성공률**이 필요합니다(추가 실험 필요).
- 학위논문의 실물 지연 분해: 시각 1.86 ms + 10 × 1.78 ms = 19.62 ms(RTX 4080). 시각 인코더가 지연의 약 10%입니다.

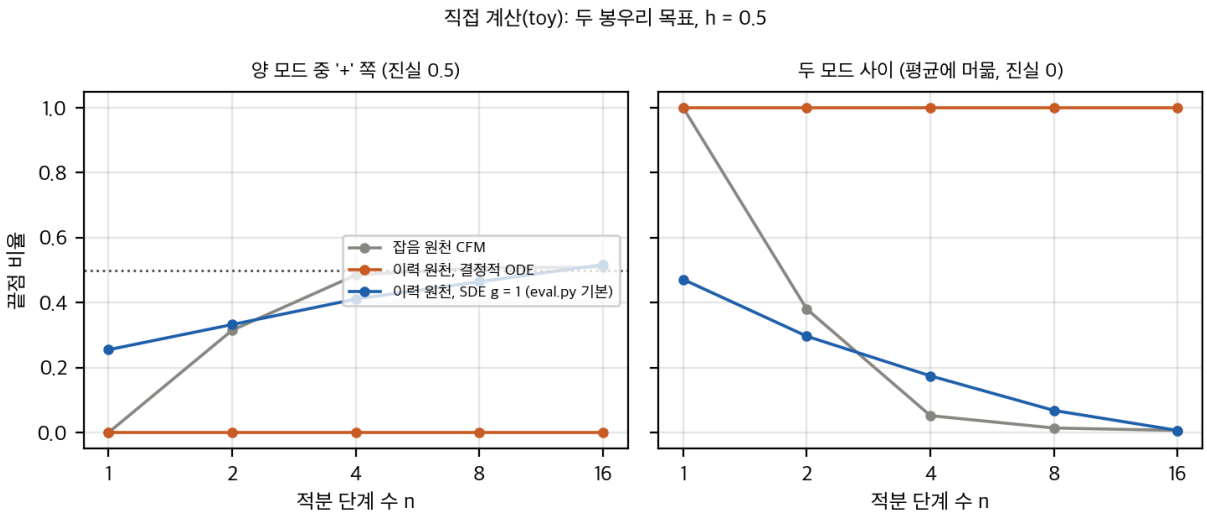
6. 샘플러: 결정적 ODE는 평균으로 붕괴한다

6.1 보정항의 닫힌 식 (코드와 식 5-6의 결합)

추론 드리프트는 $\tilde{b} = b + \frac{1}{2}(g^2 - \gamma^2)\nabla \log p$이고, $g = 0$(결정적)이면 $\tilde{b} = b - \frac{1}{2}\gamma^2 \nabla \log p$입니다. $\gamma = \varepsilon(1 - t)$입니다. 식 5의 $\nabla \log p = (t \cdot b - (x - x_0)) / (\varepsilon^2 t (1 - t))$를 넣으면 **ε가 사라집니다**:

$$\tilde{b} = ((1 + t)/2) \cdot b + ((1 - t)/(2t)) \cdot (x - x_0)$$

- 보정항 $(1-t)/(2t) \cdot (x - x_0)$는 $t \to 0$에서 발산합니다. 시작 근처에서 이력 원천과의 차이가 크게 증폭됩니다(§6.3).
- 논문의 "결정적 샘플링은 보정 없는 흐름 b_θ를 적분한다"는 가정과 다릅니다. 코드 `compute_updated_drift`는 $g = 0$에서도 보정을 넣습니다.



직접 계산(toy): 두 봉우리 목표(h = 0.5)에서 단계 수별 끝점 위치. 결정적 이력 흐름은 두 모드 사이에 머문다.

6.2 점 원천에서는 결정적 흐름이 평균 경로에 머문다 (toy B, C)

이력 원천은 점질량이라 `x0 = c`가 정확히 주어집니다. 가우시안 조건부 `x1 | c ~ N(μ(c), Σ)`에서 `x = c`에서 시작하면 해는 직선 `a(t) = (1 − t)c + tμ`에 머뭅니다. 이 선 위에서는 `x − a = 0`이라 점수가 0이고, 보정항이 사라집니다. 드리프트는 상수 `μ − c`이므로 Euler가 정확합니다.

- **토이 B(φ = 0.991):** 보정 있는 ODE와 없는 ODE의 끝점이 같습니다(차이 MSE 2e-29). 끝점의 분산은 0이고, 목표 조건부 분산은 차원당 0.109입니다. **결정적 이력 흐름은 조건부 분포가 아니라 조건부 평균을 출력합니다.**
- **토이 C(두 봉우리, h = 0.5, 단계 1-16):** 결정적 제안법의 끝점은 모든 단계에서 두 봉우리 사이(평균)에 있습니다(비율 1.0). 잡음 원천 CFM은 8단계에서 '+' 0.507, '−' 0.479, 사이 0.014로 두 모드를 나눕니다(`own_mode_split.png`).
- 평균은 제곱 오차를 최소화하므로 샘플 기준 MSE는 더 낮습니다(h = 0.5, 8단계: 제안법 결정적 0.134, CFM 0.239). **회귀 지표로는 좋아 보이지만 다중 모드를 잃습니다.** 두 모드 중간에 놓인 행동은 실제로는 충돌이나 빈 공간일 수 있습니다.

6.3 확률적 샘플러(SDE)와 단계 수 (toy C)

방법 (h = 0.5)	n = 1 사이	n = 8 사이	n = 16 사이	n = 16, '+' 비율
잡음 원천 CFM	1.00	0.014	0.006	0.509
이력 결정적 (논문 표 I 설정)	1.00	1.00	1.00	0
이력 SDE g = 1 (`eval.py` 기본)	0.47	0.068	0.006	0.517
이력 SDE g = 0.1 (설정 파일 기본)	1.00	0.066	0.020	0.47

- SDE g = 1은 8-16 단계에서 두 모드를 회복하지만, 1단계에서 진실 샘플에 대한 MSE가 1.13입니다(결정적 0.134의 8배 이상). 논문 Fig. 3 오른쪽에서 SDE가 적은 단계에서 불리한 것과 같은 방향입니다.
- **논문 Table I의 NFE 10은 결정적 ODE이므로 다중 모드를 볼 수 없습니다.** 다중 모드 표현은 SDE에 달려 있는데, 논문 표는 SDE 결과를 보고하지 않습니다.

6.4 시작 근처 오차의 증폭 (toy D)

끝점 편차 배수(주입 오차 1단위당, 차원당 RMS, 200단계):

주입 시점 t	보정 있음	보정 없음	식으로 본 √(1/t) (상한 추정)
0.05	**1.51**	0.60	4.47

주입 시점 t	보정 있음	보정 없음	식으로 본 √(1/t) (상한 추정)
0.10	1.10	0.61	3.16
0.20	0.80	0.57	2.24
0.40	0.60	0.53	1.58
0.60	0.57	0.53	1.29
0.80	0.64	0.61	1.12

- 보정 항이 있으면 시작 근처 오차가 2.5배 증폭됩니다(t = 0.05). 보정이 없으면 증폭이 없습니다.
- 단순한 √(1/t)보다 작은 이유는 오라클 드리프트 자체가 수축 성분(−(1 + t)/(2(1 − t)))을 가지기 때문입니다.
- 논문 Sec. V가 말한 "초기화 품질에 민감하다"는 한계는 이 증폭으로 설명됩니다. 학습된 드리프트의 오차는 시작 근처에서 가장 크므로 실제 효과는 더 클 수 있습니다(검증 안 됨).

7. 식 5 검산과 1단계 출력 = 조건부 평균

- **식 5 검산:** 토이의 가우시안 오라클 드리프트 b로 계산한 점수와 식 5 `(t b − (x − x0))/(ε² t(1 − t))` 의 최대 차이는 t = 0.2, 0.5, 0.8에서 각각 7.7e-11, 1.0e-10, 1.9e-9입니다. 식 5는 정확한 드리프트에 대해 맞습니다(`transport_toy.py` 의 `eq5_check`).
- **1단계 추론:** 제안법 1단계 출력 `c + b(c, 0)` 은 `E[x1 | c]` 와 2e-16 차이입니다. **1단계 제안법은 조건부 평균을 내는 회귀입니다.** Table I과 표 5.3의 1단계 성능은 "MSE 회귀 정책이 이 과제에서 잘 된다"는 것과 같은 말입니다. 이를 가리키는 기준선(같은 입력, 같은 목표, MSE 학습)이 논문에 없습니다(추가 실험 필요).

8. "order of magnitude"의 원인 분해

요인	기여	근거
14 스텝 떨어진 쌍의 상관 (1 − ρ_{14})	대략 8배	§3. $\rho_{14} \approx 0.76$-0.88 필요
측정 방식과 샘플러 단계 수	DP 대 CFM 19배의 대부분	§4.3. 두 방법 원천 동일
직진성	작음 (CFM 대비 7%)	§1.4. 결정적 점 원천에서는 직선이 자동
지연	모델 크기 (3.3배 중 전부)	§5. NFE 같을 때 원천 효과 0
성공률	1단계 회귀와 비슷	§1.3, §7. 다중 모드 능력은 SDE 쪽

종합: 논문의 "전달 비용 감소"는 **학습 쌍의 시간 간격에서 나오는 거리 감소**입니다. 저자들의 설명 "원천이 목표에 가까워서"는 맞지만, 그 "가까움"은 학습 설계(d = 14)와 정규화가 만든 것입니다. 직선 흐름과 저단계 추론은 점 원천의 성질이라 이 방법만의 장점이 아닙니다(CFM도 토이에서 직선).

9. 실패 조건과 반례

9.1 복사 (copycat)

출력이 이력과 같으면 전달 비용은 0이고, 직진성은 정의되지 않습니다(분모 0). 토이(φ = 0.991)에서 복사 출력과 조건부 평균의 차이는 차원당 MSE 0.124입니다. 조건부 평균이 이 목표에서 가장 좋은 예측이므로, 복사는 그만큼 손해입니다. **전달 비용은 복사를 잡지 못합니다.** 정확도(성공률, 궤적 오차)와 함께 봐야 합니다. 논문의 지표는 성공률뿐이고 복사 기준선이 없습니다.

9.2 모드 전환

이력이 옛 모드를 가리키고(기울기 부호), 실제 미래는 확률 h로 바뀝니다. 토이 C에서 조건부 목표는 옛 모드 1 – h, 새 모드 h입니다. **흐름은 조건부를 재현할 뿐이므로, 모드 전환에서의 오차는 조건부의 베이즈 오차입니다.** 원천 종류(이력 대 잡음)와 무관합니다. 차이는 단계 수입니다. 잡음 원천은 8단계에서 모드를 나누지만, 결정적 이력 흐름은 나누지 못합니다(§6.2).

따라서 "이력이 잘못된 모드를 가리키면 실패한다"는 질문에 대한 답은 **학습된 조건부가 새 모드에 확률 질량을 주지 않으면 실패하고, 결정적 샘플링은 그 질량을 0으로 만든다**입니다. 소수 모드를 안정적으로 내려면 SDE 또는 잡음 원천이 필요합니다.

9.3 에피소드 시작

데이터 로더는 에피소드 시작 전 이력을 **첫 상태의 복사**로 채웁니다(`common/sampler.py`, `SequenceOffsetSampler.sample_sequence`의 `data[:sample_start_idx] = data[sample_start_idx]`). 따라서 시작 구간의 원천은 **움직이지 않는 이력**이고, 목표는 실제로 움직이는 행동입니다. 학습 쌍의 앞부분은 "정지 → 움직임"을 배우고, 추론은 정지 상태에서 시작하는 흐름을 씁니다. 시작 근처 오차는 §6.4에서 2.5배 증폭됩니다. 실물 시험(10 Hz, 청크 16, 실행 8)에서 시작 구간의 성공률을 따로 보고하지 않았습니다.

9.4 기타

- 상태 추정 잡음이 크면 원천이 잘못된 위치에 놓입니다(논문 Sec. V, 학위논문 6.1). 이 효과는 §6.4와 같은 방향입니다. 정량 실험은 없습니다.
- 행동과 상태가 같은 표현이라는 가정은 그리퍼 차원에서 깨집니다(`04` D3).

10. 재현 가능한 계산 목록

스크립트	결과	시간 (이 맥, 1 스레드)
`analysis/table_check.py`	`table_check_results.json` : Table I (Fisher, CMH, Holm), thesis 표 5.3·5.4 (Fisher, Welch), 지연 분해, 실물 Wilson, 결합 항등식	1초 미만
`analysis/transport_toy.py`	`transport_toy_results.json` : A(결합 항등식 MC), B(단봉 오라클, φ = 0.991과 0.9), C(두 봉우리, h 세 값, 결정적·SDE g = 1, 0.1), D(주입 증폭), 식 5 검산	약 13초
`analysis/plot_figures.py`	`report/figures/own_*.png` 네 장	약 5초

11. 이 문서가 확정하지 못한 것

- 원자료(에피소드별 결과, 시드별 성공률)가 없어 쌍별 검정(McNemar 등)을 할 수 없습니다.
- Table I의 n = 150은 근사입니다. 체크포인트 평균의 실제 유효 표본을 알 수 없습니다.
- DP 190과 CFM 10의 차이가 샘플러인지 측정인지 확인하지 못했습니다(공개 평가 필요).
- 학습된 드리프트의 오차가 §6.4 증폭을 얼마나 키우는지는 측정하지 못했습니다(오라클 토이만 사용).
- 토이는 단봉 가우시안과 두 봉우리뿐입니다. 실제 로봇 데이터의 다중 모드 구조는 모릅니다.

추가 검증 (2026-11-11)

이 절은 §6(샘플러)의 오라클 토이를 학습된 드리프트로 바꿔 본 검사입니다. 결과는 `analysis/extra_flow_mode_results.json`에 있습니다.

추가 검증 1. 학습된 이력 조건부 흐름의 모드 붕괴와 샘플러 시드 분산

목적. §6.2에서 오라클 드리프트로 본 "결정적 흐름은 평균으로 붕괴한다"가 작은 신경망으로 학습한 드리프트에서도 나타나는지 봅니다. 확률적 샘플러(SDE, g = 0.1, 1.0)가 두 모드를 회복하는지, 결정적 샘플러의 끝점이 샘플링 시드마다 분산 0인지도 함께 봅니다.

설정. 스크립트는 `analysis/extra_flow_mode.py` 입니다.

- 데이터: `transport_toy.py` 의 상태 과정(단위분산 AR(1), φ = 0.99, 청크 H = 16, 시차 d = 14). 목표 x1 | c는 평균 A·c에 두 봉우리 ±δ(δ = 0.5·linspace(−1, 1, 16))를 더하고 잡음 0.2를 씁니다. 이력이 가리키는 모드와 같은 모드를 고를 확률이 1 − h입니다.
  - 주 설정 h = 0.5: 이력이 모드를 정하지 않습니다. 참 조건부 모드 비율은 0.5 / 0.5입니다.
  - 대조 설정 h = 0.02: 이력이 모드를 거의 정합니다. 참 비율은 0.504 / 0.496입니다.
- 학습: 보간 $x_t = (1-t)c + t\cdot x1 + \varepsilon(1-t)\sqrt{t}\cdot z$ (ε = 1), 목표 드리프트 $(x1 - x_t)/(1-t)$, 손실은 $(1-t)^2$로 가중한 MSE입니다. 드리프트 망은 입력 33 → 128 → 128 → 16 (SiLU), 매개변수 약 $2.3\cdot10^4$개. Adam $1\cdot10^{-3}$ 코사인 감쇠, 배치 512, 6000 스텝. 학습 시드 3개(0, 1, 2)를 설정마다 씁니다.
- 샘플러: 점수는 학습된 드리프트에서 식 5($\nabla \log p = (t\cdot b - (x_t - c)) / (\varepsilon^2 t(1-t))$)로 계산합니다. 결정적 샘플러는 $b - \tfrac{1}{2}\varepsilon^2(1-t)^2\nabla \log p$이고, SDE는 $b + \tfrac{1}{2}(g^2 - \varepsilon^2(1-t)^2)\nabla \log p + g\sqrt{dt}\cdot z$입니다. t = 0의 보정항은 0으로 둡니다. 단계 수 n = 10, 16, 이력 1000개.
- 장치: CPU, torch 2.15.0, numpy 1.26.4, Python 3.12.7, 스레드 4. 학습 설정당 약 5 s, 전체 33 s.

결과. 값은 학습 시드 3개의 범위입니다 (n = 10).

설정	샘플러	사이(모드 사이) 비율	+ / −	조건부 평균 대비 RMS	샘플러 시드 SD
h = 0.5	결정적 ODE (보정)	1.000	0 / 0	0.024	10^{-17}
h = 0.5	결정적 ODE (보정 없음)	1.000	0 / 0	0.025	10^{-17}
h = 0.5	SDE g = 0.1	0.992	0.003 / 0.005	0.083	0.074
h = 0.5	SDE g = 1.0 (식 5 점수)	0.36	0.31 / 0.32	0.53	0.49
h = 0.5	SDE g = 1.0 (오라클 점수, 진단)	0.02	0.47 / 0.51	0.46	0.43
h = 0.5	완전 오라클 SDE g = 1.0 (진단)	0.03	0.48 / 0.49	0.45	0.42
h = 0.02	결정적 ODE (보정)	0.05	0.48 / 0.46	0.08	10^{-17}
h = 0.02	SDE g = 1.0 (식 5 점수)	0.09	0.46 / 0.44	0.46	0.42

- 결정적 샘플러는 n = 16에서도 같습니다(h = 0.5, 사이 비율 1.000). 시드 분산은 부동소수점 잡음 수준(10^{-17})입니다.
- 학습된 ODE의 끝점은 조건부 평균에서 RMS 0.024만큼 떨어져 있습니다. 두 모드 중심까지의 거리는 0.089(per-dim 제곱)로, 참 조건부 분포에서 가까운 모드까지의 기대 제곱 거리(잡음 분산 0.04)보다 큽니다. 모든 끝점이 모드 사이에 있습니다.
- 진단: 같은 학습 드리프트에 점수만 오라클로 바꾸면 SDE g = 1은 두 모드를 회복합니다(사이 비율 0.02, n = 10). 식 5로 학습된 드리프트에서 점수를 계산한 경우에만 사이 비율이 0.36으로 남습니다. 점수 항은 (1−t)를 나눠서 드리프트 오차를 키우므로, 학습 드리프트의 작은 오차가 t → 1 근처에서 증폭되는 것으로 보입니다. 이 증폭은 g = 0.1에서는 없습니다(보정 항의 계수가 $(1-t)^2$이라 안정합니다).

결론.

- 두 봉우리 목표를 이력으로 정하지 못할 때(h = 0.5), 학습된 결정적 흐름은 모든 끝점을 두 모드 사이의 평균에 붕괴시킵니다. 샘플링 시드마다 끝점이 같습니다(분산 0). 이 결과는 오라클 토이(§6.2, 토이 B와 C)를 학습 모델에서 재현합니다.
- SDE g = 0.1도 같은 방향으로 붕괴합니다(사이 비율 0.99). 모드를 회복하려면 g = 1이 필요합니다.
- SDE g = 1이 모드를 회복하는지는 점수의 정확도에 달려 있습니다. 식 5로 얻은 학습 점수는 회복하지 못했고, 오라클 점수는 회복했습니다. §6.3의 "SDE g = 1이 8-16 단계에서 모드를 회복한다"는 주장은 정확한 점수를 가정한 것입니다. 학습된 점수를 쓰는 실제 샘플러에 그대로 옮길 수 없습니다.
- 이력이 모드를 정하는 경우(h = 0.02)에는 학습된 ODE도 대부분의 끝점을 맞는 모드에 둡니다(사이 비율 0.05). 붕괴는 이력이 모드 정보를 주지 않을 때 크게 나타납니다.

한계.

- 데이터는 가우시안 두 봉우리 합성입니다. 실제 로봇 행동이나 논문의 학습 목적 함수가 아닙니다. 보간과 손실은 §6과 같은 형태로 골랐습니다.
- 점수는 식 5의 항등식(ε = 1 가정)으로 계산합니다. 논문 코드가 같은 방식으로 점수를 얻는지는 확인하지 못했습니다.
- 모델은 작고(128 폭), 학습 6000 스텝입니다. 학습 손실을 더 줄이면 SDE g = 1의 점수 오차가 줄 수 있으나 시험하지 않았습니다.
- 샘플러 단계 수는 n ≤ 16입니다. 논문의 NFE 10 설정에 맞췄지만 더 많은 단계에서 g = 1의 점수 오차가 어떻게 바뀌는지는 n = 16의 결과(사이 비율 0.37 → 0.35, 변화 없음)로만 봤습니다.
- 학습 시드는 3개입니다. 시드 간 차이는 작았으나 분포 수준의 불확실성은 추정하지 않았습니다.

04. 코드 대조: 논문 ↔ dmiller12/TemporalPolicy (e1e7ee5)

공식 저장소를 얕게 클론했습니다(`repo/TemporalPolicy/` , git 기록은 1개 커밋, `e1e7ee5` , 2026-08-18 "add bib", MIT). 실물 제어 코드와 데이터, 체크포인트는 없습니다. 학습과 평가는 실행하지 않았습니다(GPU와 데이터가 필요하고 설치를 하지 않기로 했습니다). 대조는 **읽기만으로** 했고, 수치 검증은 같은 수식을 옮긴 토이(`analysis/transport_toy.py`)로 했습니다.

1. 확인한 파일

항목	파일 (저장소 기준)
정책과 손실	`temporal_policy/policy/temporal_policy.py` (`conditional_sample` 97-109, `predict_action` 147-177, `compute_loss` 185-240)
보간과 점수	`temporal_policy/interpolants/interpolants.py` (`compute_score` 23-45, `compute_updated_drift` 47-50, `LinearForecastInterpolant` 52-87)
짝짓기와 샘플링	`temporal_policy/couplings/coupling.py` , `temporal_policy/dataset/robomimic_replay_dataset.py` (166-173, 295-331, `_obs_to_action` 374-413), `temporal_policy/common/sampler.py` (`SequenceOffsetSampler` 173-277)
정규화	`temporal_policy/common/normalize_util.py` (`get_range_normalizer_from_stat` 6-, `robomimic_abs_action_only_normalizer_from_stat` 110-)
학습과 설정	`train.py` , `temporal_policy/workspace/train_workspace.py` (224-225 손실, 87-90 디버그 덮어쓰기), `temporal_policy/config/train_temporal_policy_unet_image_workspace.yaml` , `temporal_policy/config/policy/temporal_policy.yaml` , `temporal_policy/config/training/training.yaml` , `temporal_policy/config/task/{robomimic_default,square_image_abs}.yaml`
평가와 전달 비용	`eval.py` (24-55), `temporal_policy/env_runner/robomimic_runner.py` (`compute_transport` 81-155, 롤아웃 루프 약 560-640)
실물	`temporal_policy/real_world/` (`video_recorder.py` 만 있음)
테스트	`tests/` (8개, 대부분 유틸리티. 방법 대조에는 쓰지 않음)

2. 논문 ↔ 코드 대조 (D-항목)

판정 기호: **일치**, **부분 일치**, **불일치**, **미공개**(저장소에 없음), **미검증**(읽기로는 확인 불가, 실행 필요).

ID	항목	논문	코드	판정	영향
D1	학습 목표	식 3: `u = (x1 − x0) − ε√λ z` , 보간 `xλ = (1−λ)x0 + λx1 + ε(1−λ)√λ z` (식 1, Alg. 1)	`temporal_policy.py:210–222` : `it = (1−t)x0 + t x1` , `gamma = √t · ε(1−t)` , 목표 `it_dot + gamma_dot · z` 와 `gamma_dot = −ε√t` → `u = x1 − x0 − ε√t z`	**일치**	—

ID	항목	논문	코드	판정	영향
D2	원천과 목표의 인덱스 정렬	본문 식: 원천 `s[t−H+1 : t]`, 목표 `s[t−H+1+d : t+d]`, `d = H − 2 = 14` (학위논문 부록 A.1). 본문 목표는 "미래 행동"이라고 씀	원천 창의 시작 오프셋 `horizon − n_obs = 14` (`dataset.py:166`), 패딩 `pad_before = n_obs − 1 + 14 = 15` (`dataset.py:173`). 따라서 원천 = `s[t−15 … t]` (16개 상태), 목표 = `a[t−1 … t+14]` (16개 행동). 같은 인덱스 `j`의 쌍은 **14 스텝** 떨어진 시점	**일치**(d = 14). 표기는 모호(식은 상태 시점, 코드는 행동 시점)	전달 비용이 "14 스텝 동작량"이 됨(`03` §3, §8)
D3	상태와 행동의 같은 표현	Sec. III-A: 상태와 행동은 같은 표현(관절 또는 말단 자세)	`_obs_to_action` (`dataset.py:374–413`): 위치 3 + 회전(사원수 → 6D, 보정 상수 곱) + 그리퍼 `gripper_qpos[..., 7:8]` (손가락 위치). 행동의 그리퍼는 명령(±1). 정규화만 같은 통계로 맞춤	**부분 일치**	그리퍼 차원은 상태(위치)와 행동(명령)이 다른 양. 실물(§IV-E)은 "그리퍼 속도"를 결합에 씀(D12)
D4	행동 정규화	Sec. III-B: 자유도별 표준화, `E‖x‖² = HD`	`normalize_util.py:6–20, 110–130` : 위치, 6D 회전, 그리퍼를 **[−1, 1] 범위 정규화**(학위논문 A.1과 같음)	**불일치**(가정)	`J_indep = 2HD`가 `HD(1+m)`로 바뀜(`03` §2)
D5	추론 설정	Table I: NFE 10, 결정적 샘플링(Sec. IV-C 결론)	학습 설정(`train_..._yaml:30, 43`): `inference_sde_epsilon_coefficient: 0.0`, `num_inference_steps: 10` → **학습 중 롤아웃은 일치**. 반면 `eval.py:43–44`는 `inference_sde_epsilon_coefficient = 1.0`, `num_inference_steps = 101`로 덮어쓴다. 정책 기본값은 0.1(`temporal_policy.yaml:18`)	**부분 일치**(공개 평가 스크립트는 다름)	공개 `eval.py`를 돌리면 SDE, 100 단계. 표 I의 NFE 10·결정적과 다른 결과가 나온다
D6	학습 epoch	Sec. IV-A: 1500 epoch (학위논문도 1500)	`training.yaml:8` : `num_epochs: 4500`. 과제 설정과 README 명령에 덮어쓰기 없음	**불일치**(기본값)	설정대로 학습하면 3배 길다. 논문 수치의 학습 길이를 확인할 수 없음
D7	학습 잡음 ε	본문 주 결과에 없음(Fig. 3 오른쪽은 추론 SDE만)	`train_..._yaml:33` : `sde_epsilon_coefficient: 1.0`. 학위논문 5.1: ε = 1.0 고정	**미공개**(논문 본문) / **일치**(학위논문, 코드)	논문만 읽으면 ε를 알 수 없음
D8	전달 비용과 직진성 정의	식 7: `Σ(‖Δp‖² + r·θ)`, 식 8: 위 값 ÷ `‖p_K − p_0‖² + r·θ`	`robomimic_runner.py:81–155` : 스텝 거리 **합(제곱 없음)** + `0.1 ×` 회전 각 합, 직진성 = 총합 ÷ 직선 거리(제곱 없음). 값은 `unnormalize`한 행동 단위(m, rad), 정규화 공간 버전(`_standardized`)도 기록	**불일치**(정의)	직선 경로에서 식은 1/K, 코드는 1. 표 II의 1.02·1.08은 코드 정의와 맞음(`03` §4). 어느 정의를 썼는지 논문에 없음
D9	점수와 추론 드리프트	식 5: `∇log p = [λu − (x−x0)]/(ε²λ(1−λ))`, Alg. 2 줄 5: `b̃ = b + (g²−γ²)/2 · ∇log p`	`interpolants.py:23–50` : `As = 1/(tσ(β̇σ−βσ̇))`, `cs = β̇x + (βα̇−β̇α)x0`, `score = As(βb − cs)`, `drift = b + ½(g²−σ²)·score`, `σ = ε(1−t)`. `temporal_policy.py:103–104`에서 `g = inference_sde · (1−t)`	**일치**	토이로 식 5 수치 일치 확인(최대 차 2e-9, `03` §7). `g = 0`에서도 보정항이 남는다(`03` §6)
D10	적분 격자와 Euler 갱신	Alg. 2: `x ← x + b̃Δλ (+ g√Δλ z)`	`temporal_policy.py:97–109` : `times = linspace(1, 0, num+1)`을 뒤집어 0→1, 단계 `num − 1 = 10`(설정 10). `mu = x + b̃·dt`, `x = mu + g·z·√dt`	**일치**	—
D11	실행 수평	Sec. III-E 끝, IV-E: 16개 예측, 8개 실행	`n_action_steps: 8` (`train_..._yaml:41`), 실행 구간 `[n_obs−1 : n_obs−1+8]` = 인덱스 1-8(`temporal_policy.py:174–177`). 인덱스 0(`a_{t−1}`)은 버림	**일치**	—

ID	항목	논문	코드	판정	영향
D12	실물 제어와 결합	Sec. IV-E: 7자유도 WAM, 10 Hz, 그리퍼 속도 결합, 500 Hz 보간(학위논문)	`real_world/` 에는 `video_recorder.py` 뿐. 제어 루프·보간·결합 생성 코드 없음	**미공개**	실물 결과는 코드로 확인 불가
D13	평가 횟수와 시드	Table I: 체크포인트당 50회, 시드 3개	`robomimic_default.yaml:20, 22` : `n_test: 50` , `test_start_seed: 100000` (모든 실행 공통, 같은 초기 조건 블록). 시드 3개는 실행 스크립트에 없음. `eval.py` 는 100회, 시드 49	**일치**(50회·공통 초기 조건), **미검증**(시드 3개)	공통 초기 조건은 쌍 설계지만 에피소드별 결과가 공개되지 않아 쌍 검정 불가
D14	평가 주기와 체크포인트 집계	50 epoch마다 평가, Max·Average(마지막 10개)	`training.yaml:16` 의 `rollout_every: 50` . Max·Average 집계 코드는 없음(wandb 로그에 의존)	**일치**(주기), **미검증**(집계)	—
D15	네트워크 구조	Sec. III-D, IV-A: 1D U-Net, 17M, FiLM, Spatial Softmax	`train_temporal_policy_unet_image_workspace.yaml:26, 28` : `use_initial: True` , `down_dims: [256, 512]` . 파라미터 수는 읽기로 셀 수 없음(torch 미설치)	**부분 일치**(구조), **미검증**(17M)	—
D16	시간 표본 분포	Alg. 1: λ ~ U(0, 1)	`config/policy/sigma_distribution/rand_uniform.yaml` (`RandUniform(0, 1)` , `common/distributions.py:82–90`)	**일치**	—
D17	보조 손실	식 3(드리프트 손실만)	`compute_loss` 가 `x1_loss` , `vel_loss` , `noise_loss` , `accel/vel_penalty` 를 계산하지만 `train_workspace.py:224` 는 `loss_dict["loss"]` (드리프트)만 역전파	**일치**(로그용 보조 손실)	논문에 보조 손실이 없어도 무방
D18	에피소드 경계 패딩	논문에 없음	`sampler.py:270` : 시작 전 이력은 **첫 상태 복제**, 끝 뒤는 마지막 값 복제	**미공개**(논문)	시작 구간의 원천은 정지한 이력(`03` §9.3)
D19	전달 비용을 잰 샘플	Table II: Square ph, 50 에피소드	측정 코드는 있음(`robomimic_runner.py` , 롤아웃 중 `collector` 에 경로 저장). 측정 시 설정(ODE 10 단계 또는 SDE 100 단계)은 확인 불가	**미검증**	표 II가 어느 샘플러에서 나왔는지 알 수 없음. DP 190은 확률적 샘플러 효과일 수 있음(`03` §4.3)
D20	추론 시 `infill_overlap`	논문에 없음	`predict_action(..., infill_overlap=False)` (기본 꺼짐). 켜면 첫 두 스텝을 관측으로 고정	**미공개**(논문), 기본 꺼짐	논문 결과에는 꺼진 설정이 쓰였다고 보임(미검증)

3. 재현에 필요한데 논문에 없는 정보

1. **원천과 목표의 시간 정렬**(D2). 식 본문과 그림 2가 서로 다르게 적혀 있습니다. 코드를 봐야 d = 14와 인덱스 구조를 알 수 있습니다.
2. **학습 epoch**(D6). 1500(논문)과 4500(기본 설정) 중 무엇을 썼는지.
3. **공개 평가 설정과 논문 표 설정의 차이**(D5). SDE 1.0·100 단계(`eval.py`)와 결정적·10 단계(표 I) 중 어느 것을 썼는지.
4. **전달 비용 정의와 측정 샘플러**(D8, D19). 식과 코드 중 어느 것, 어떤 단계 수에서 쟀는지.
5. **학습 잡음 ε의 본문 값**(D7). 학위논문에는 1.0.
6. **행동 정규화 방식과 그리퍼 처리**(D3, D4). 분산 가정과 실제 정규화가 다릅니다.
7. **실물 결합 표현과 제어 루프**(D12). "그리퍼 속도"가 무엇인지, 500 Hz 보간은 어떻게 했는지.
8. **시드 수와 집계 방법**(D13, D14). Max와 Average 계산 스크립트, 에피소드별 결과.

9. **기준선 설정**. DP와 CFM의 학습 설정은 "Diffusion Policy 설정을 따른다"고만 씁니다. 두 방법의 파라미터 수(255M)를 확인하지 못했습니다.
10. **직진성 계산 대상**. 학습 중 롤아웃 경로인지, 평가 경로인지.

4. 구현할 수 있는지

4.1 공식 재현

시뮬레이션(Robomimic):

- 필요한 것: Robomimic 데이터(저장소 README 기준 전체 256 GB, 과제 하나는 이미지 데이터 수 GB 수준으로 추정. 실제 크기는 받아 보지 않아 미검증), `robomimic` 패키지와 MuJoCo 설치, 학습용 GPU.
- 학습 시간: 학위논문 부록에서 과제당 2.5-53 시간(A100 1장, 배치 128, 1500 epoch). 기본 설정(4500 epoch)이면 더 길다.
- 평가: 50회 × 체크포인트 수(50 epoch마다). 시뮬 렌더링은 CPU로 가능하지만 느리다.
- **판정: 공식 재현 가능**(GPU가 있으면), 이 맥에서는 학습이 불가능합니다(§4.2).

실물:

- 코드가 없고 하드웨어(Barrett WAM 2대, BarrettHand, FLIR 카메라)가 필요합니다. **재현 불가**.

4.2 이 맥(Apple M4 Pro, 통합 메모리 약 24 GiB, MPS, CUDA 없음, torch 미설치)에서

항목	판정	이유
저장소 코드 실행	**어려움**	코드가 `device: cuda:0`을 기본으로 하고 `torch.autocast`가 CUDA 전용입니다(`robomimic_runner.py` 롤아웃 루프). MPS로 바꾸는 패치는 가능해 보이지만 확인하지 못했습니다. 현재 torch가 없어 설치가 필요하고, 설치는 이번 작업에서 금지되었습니다
17M 모델 학습	**조건부 가능**(패치와 설치 승인 후)	파라미터가 작아 메모리는 충분합니다(24 GiB). 속도는 A100보다 느릴 것으로 예상되지만 측정하지 않았습니다
255M 기준선(DP, CFM) 학습	**불가**	메모리와 시간 모두 과합니다(추정)
Robomimic 평가	**조건부 가능**	MuJoCo와 robomimic 설치가 필요. CPU 렌더링은 느립니다
실물	**불가**	하드웨어 없음
지연 측정(RTX 4080 대비)	**비교 불가**	MPS 지연은 CUDA와 다르고, 논문 지연은 RTX 4080 기준입니다

4.3 아이디어만 다시 구현

- **난이도: 중간**. 핵심 변경은 원천을 `x0 = 이력`으로 바꾸는 것입니다. 나머지(보간, 손실, 샘플러)는 표준 플로우 매칭 코드에 점수 보정 두 줄을 더하면 됩니다. 토이(`transport_toy.py`)에 닫힌 식 드리프트와 Euler 샘플러가 이미 있어, 같은 식을 신경망 드리프트에 연결하기만 하면 됩니다.
- 필요한 설계 결정: d(쌍 간격), 정규화(분산 1 또는 범위), 점수 보정 사용 여부, 추론 SDE 계수, 원천을 어떤 상태 표현으로 만들지(그리퍼 포함).
- 논문에 없는 것: 학습 ε 값, 17M 구조 세부(깊이, 커널은 학위논문에 있음), 기준선 설정의 세부.

4.4 요약 표

경로	가능 여부	필요 자원	이 맥에서
공식 시뮬 재현(Robomimic, 한 과제, 1 시드)	가능(코드 공개)	GPU 1장(A100 급 권장), 데이터 수 GB, MuJoCo	학습 불가, 평가는 조건부
공식 실물 재현	불가(코드 없음)	로봇 하드웨어	불가
아이디어 재구현	가능(중간 난이도)	GPU 1장(시뮬 학습용)	토이 수준까지 가능, 신경망 학습은 설치 승인 후 조건부
토이·표 재계산	완료	CPU	완료(`03` §1-§7)

5. 권리 표기 (license verdict)

- **저장소 코드: MIT**(`LICENSE`, GitHub 메타데이터 확인). README가 Diffusion Policy(MIT)에서 파생되었다고 밝힙니다. 코드는 이 저장소에 클론만 했고 재배포하지 않습니다.
- **논문:** arXiv 비독점 배포(`arxiv.org/licenses/nonexclusive-distrib/1.0/`). **CC BY가 아닙니다.** PDF 1쪽에 IEEE 저작권 문구는 **없습니다**(`pdftotext -f 1 -l 1`로 확인: ©, copyright, IEEE, permission 문구 없음). 그래서 논문 그림과 표는 개인용 리포트와 PPT에만 넣고, 공개 산출물에서는 뺍니다. 공개물에는 직접 만든 그래프와 우리 문장만 씁니다.
- **학위논문:** 표지에 "© Dylan Miller, 2026"이 있습니다. 이 폴더는 학위논문의 수치와 문장을 짧게 인용하고, 그림은 쓰지 않습니다.
- **프로젝트 페이지:** 사이트 HTML에 CC BY-SA 4.0 링크가 있으나 템플릿 출처 표기와 함께 있어, 사이트 글의 재사용 조건인지 불분명합니다. 이 폴더는 페이지 글을 복사하지 않고 링크만 씁니다.

6. 주장 판정 요약

ID	주장 (논문)	판정	근거
C1	전달 비용을 거의 한 자릿수 줄였다 (Abstract, Table II)	**수치는 일관, 해석은 과장**	CFM 대비 8.3배는 $\rho_{14} \approx 0.76$-0.88이면 가능(`03` §3). DP 대비 157배의 대부분은 결합이 아니라 측정·샘플러 효과(`03` §4.3). D2, D8
C2	직진성 1.02 (Table II)	**코드 정의로만 일관**	식 8로는 10단계 직선에서 0.1(`03` §4.1). 코드 길이 기준으로는 1(D8). CFM 1.08과의 차이 7%는 통계적으로 구별되지만 작다(`03` §1.4)
C3	19.1 ms 지연 (Table I)	**원천 효과와 분리되지 않음**	NFE 10으로 같은 CFM 63.5 ms 대비 3.3배 차이는 모델 크기 255M → 17M와 함께 나왔다(`03` §5). 재현 불가(RTX 4080)
C4	성공률이 SOTA와 맞먹는다(Abstract, Table I)	**대체로 확인(근사)**	9셀 CMH 대 DP $p = 0.69$, 대 CFM $p = 0.0014$(Transport mh 한 셀이 대부분)(`03` §1.1). $n = 150$ 가정은 근사
C5	데이터 효율이 더 좋다(Sec. IV-D, Fig. 4)	**확인 불가**	그림 한 장, 시드와 오차 막대 없음. 학위논문도 같은 곡선(TP·DP·CFM)
C6	1 단계에서도 성공률이 높다(Sec. IV-A, Fig. 3, 학위논문 표 5.3)	**수치는 확인, 해석은 회귀와 구별 안 됨**	1단계 출력 = 조건부 평균(`03` §7, 차 2e-16). 회귀 기준선이 없음
C7	결정적 샘플링이 효율적이고 다중 모드를 잃지 않는다(학위논문 부록 A.2)	**토이로 반증(결정적 모드 붕괴)**	점 원천의 결정적 ODE는 평균 경로에 머묾(`03` §6.2). 다중 모드는 SDE에서만 나옴(§6.3). 부록 A.2는 한 장면의 정성 그림뿐
C8	실물 50%(10/20), 집기 95%(19/20)	**미확인(기준선 없음)**	Wilson 95%: [0.30, 0.70], [0.76, 0.99](`03` §1.5). 코드 없음(D12)
C9	이력 원천이 직선 흐름을 만든다(Sec. IV-B)	**원인 해석 과장**	점 원천에서 직선은 자동으로 나온다(`03` §6.2). CFM도 토이에서 거의 직선(코드 길이 기준 1.00-1.02)
C10	J_temporal < J_indep(Sec. III-B)	**확인(조건부)**	단위 분산이면 `J_TP/J_indep = 1 − ρ_d`, 따라서 $\rho_d > 0$이면 성립. 분산 1/3이면 `2m(1−ρ)/(1+m)`(`03` §2)

ID	주장 (논문)	판정	근거
C11	시작 근처 이력 초기화가 민감하다는 한계 (Sec. V)	**확인**	보정항에 의한 시작 근처 오차 증폭 2.5배(`03` §6.4)

7. 기록

- 저장소 커밋: `e1e7ee5ebf689d9f65c7453893dc35df5c40d158` (2026-08-18). 얕은 클론이라 이전 기록이 없습니다.
- 확인한 날짜: 2026-11-10.
- 실행하지 않은 것: 학습, 평가, 설치, 데이터·체크포인트 다운로드, 실물.

02. 선행연구와 관계

1. 계보

```
확산 정책 (Diffusion Policy, Chi et al., IJRR 2025 [3])   — 가우시안 잡음 원천, DDPM 100단계
  └ 조건부 확산 (Reuss et al., RSS 2023 [8])               — 목표 조건, classifier-free guidance
플로우 매칭 (Lipman et al., ICLR 2023 [4]) / 정류 플로우 (Liu et al., ICLR 2023 [9])
  └ 확률적 보간 (Albergo, Boffi, Vanden-Eijnden, JMLR 2025 [6])  — 원천과 목표 임의 결합, 확률 과정 일반화
      └ 확률적 보간 예측 (Chen et al., ICML 2024 [7])        — 점질량 원천, 점→분포 수송, 해석적 점수
          └ Temporal Policy (Miller & Jagersand, IROS 2026)  — 원천을 로봇 상태 이력으로 교체
```

논문의 핵심 기여는 "원천의 선택"입니다. 보간·드리프트·손실 틀은 [6], [7]에서 가져옵니다. 저자들이 새로 낸 것은 로봇 LfD에서 이력을 원천으로 쓰는 것, 그리고 그 원천에서의 전달 비용 측정입니다(Sec. II-C, III).

2. 가까운 대안

2.1 논문이 인용한 것 (Sec. II)

방법	원천	논문의 평가	차이
Diffusion Policy [3]	가우시안	기준선	100 NFE, 255M
CFM [4]	가우시안	기준선, 10 NFE	255M, 같은 학습 설정
Streaming Flow Policy [24]	이전 행동	"목표가 시점별 주변분포라서 행동 청크의 결합 분포를 못 보고 행동을 섞는다"	시점별 주변 대 청크 전체
VITA [25]	잠재 시각 표현	디코더 학습에 ODE 역전파 필요	원천이 시각 잠재
Trajectory Flow Matching [23]	관측 이력	이중 네트워크로 확산 과정을 매개변수화	논문은 같은 원천을 쓰면서 단일 네트워크
Schrödinger bridge / OT-CFM [15]-[20]	최적 결합	로봇에 적용하기 어렵다고 판단	결합을 미니배치 OT로 맞춤
Consistency models [10], ManiFlow [14]	—	"직교적(orthogonal)"이라고 씀	NFE 축소를 증류로

2.2 논문이 인용하지 않은 가까운 연구 (이 문서 작성자의 판단)

- **ACT의 시간 앙상블링**(Zhao et al., RSS 2023 [27]). 행동을 여러 시점에서 예측해 지수 가중으로 평균합니다. 이 저장소에서 `nestdex/`와 `beyond_implicit_force/`가 다룹니다. TP의 "겹침 d < H"도 인접 청크를 이어 주는 역할에서는 비슷하지만, 앙상블은 **출력 평균**이고 TP는 **생성 원천**입니다. 이 차이 때문에 TP는 샘플 다양성에 영향을 줍니다(`03` §6).
- **Real-Time Chunking**(Physical Intelligence). 이전 청크를 인페인팅으로 이어 붙입니다(`nestdex/analysis/02_prior_work.md` 기재). TP의 원천은 "상태 이력"이고 RTC의 조건은 "이전에 실행한 청크"라서 생성 시작점과 정보가 다릅니다. 원문은 이 문서에서 읽지 않았습니다.
- **가우시안 원천을 쓰는 로봇 플로우의 NFE 축소 연구**(예: `adavla/`, AdaVLA). 곡률로 적분 단계를 줄입니다. 원천은 그대로이고 샘플러만 바꿉니다. TP는 원천을 바꾸고 샘플러는 Euler입니다(`03` §8).
- **정보 없는 원천 대신 평균 예측** (BC 회귀, MSE 정책). TP의 1단계 추론은 정확히 `E[x1 | 이력]`을 내는 회귀입니다(`03` §7). 논문은 이 기준선을 실험에 넣지 않았습니다.

3. 이 저장소의 다른 논문과의 관계

폴더	논문의 방법	이 논문과 관계	대비
`chronospolicy/` (arXiv:2610.13929)	관측 캡처 시각과 행동 실행 시각을 RoPE로 넣고, 학습 때 센서 주기와 지연을 무작위화	**"시간 정보를 정책에 넣는 다른 방법"**으로 가장 가깝습니다. Chronos는 입력에 시각 좌표를 넣고, TP는 생성 원천에 이력을 넣습니다	Chronos는 시각 불일치 보정, TP는 전달 거리 단축. 둘 다 이력·시각을 활용하지만 목표가 다름
`adavla/` (arXiv:2608.29208)	곡률 기준으로 흐름 적분 단계 수를 줄임	**흐름 단계 수**. TP는 단계 수 10을 주장하고 AdaVLA는 평균 NFE를 역산했습니다	AdaVLA는 원천 고정 + 샘플러 적응, TP는 원천 변경 + 고정 Euler
`openwam/` (arXiv:2609.07398)	영상 prior + 행동 생성, 잡음 평면과 timestep shift 분석	**원천·잡음 선택**. OpenWAM 분석은 shift 5 때문에 잡음 쪽 샘플이 25배 조밀하다고 봤습니다(`openwam/analysis/03`)	OpenWAM은 잡음 원천을 유지. 원천을 바꾼 TP는 같은 축(원천의 위치가 학습 신호를 어떻게 바꾸나)에서 다른 해법
`pacevla/` (arXiv:2610.25961)	시연보다 빠른 행동을 시간 양자화(q = 2)로 생성	**시간 간격 d**. TP의 d = 14는 원천과 목표 사이 시간 간격이라서, 간격을 바꾸면 전달 비용이 바뀝니다	PaceVLA는 실행 속도, TP는 학습 쌍의 간격
`beyond_implicit_force/` (arXiv:2607.14578)	ACT 기반 힘 인지 (leader-follower δ, 전류 토크)	같은 ACT 계열의 **시간 앙상블링**을 공유	TP는 원천 변경, 이 논문은 입력 특징 변경
`nestdex/` (arXiv:2608.13362)	다지 손 텔레옵, 시간 앙상블링 Eq. 2의 가중 exp(−m i)	시간 앙상블링 toy와 비교 근거	TP는 앙상블 없음

IMLE-VLA(arXiv:2609.10915)는 같은 주간에 다른 작업으로 분석 중이라 이 문서에서 인용하지 않았습니다.

4. GitHub (2026-11-10 확인)

저장소	무엇인가	공식 여부	라이선스	별	최근 커밋
`dmiller12/TemporalPolicy`	Temporal Policy 구현(시뮬 학습·평가, 실물 제어 없음)	공식(논문과 프로젝트 페이지가 링크)	MIT	2	`e1e7ee5` (2026-08-18, "add bib")
`real-stanford/diffusion_policy`	기준선 Diffusion Policy와 기반 코드 베이스(논문 감사의 말 명시)	기준선 원저자	MIT	4,721	`5ba07ac` (2024-12-24)
`ARISE-Initiative/robomimic`	벤치마크(Lift, Can, Square, Transport, Tool Hang)	벤치마크 원저자	MIT	1,602	`d309eae` (2026-08-09)
프로젝트 페이지 `dmiller12.github.io/TemporalPolicyWebpage/`	논문, 학위논문, 슬라이드 링크	공식 (저자)	사이트 HTML에 CC BY-SA 4.0 링크가 있으나 템플릿 출처 표기와 함께 있어 사이트 글의 재사용 조건인지 불분명	—	날짜 표기 없음 (2026-11-10 조회)
학위논문 `DM_thesis_latest.pdf`	같은 저자 석사 학위논문 (79쪽)	공식 보조 자료	© Dylan Miller, 2026(표기)	—	2026-07-24 생성

- `gh search repos` 로 "temporal policy", "history-initialized", "stochastic interpolant robot"을 검색해 다른 구현은 찾지 못했습니다(2026-11-10).
- 저장소 클론은 `repo/TemporalPolicy/` (얕은 클론, git 제외)에 있고 `.gitignore` 에 넣었습니다.
- 학습 데이터는 Robomimic 전체 256 GB(README)이고 체크포인트 `data/0550-test_mean_score=0.969.ckpt` 는 README 예시로만 나오며 받지 않았습니다.

5. 참고 문헌으로만 쓴 것

- Chen et al., "Probabilistic Forecasting with Stochastic Interpolants and Föllmer Processes", ICML 2024 [7]. 식 4-6의 점수와 추론 SDE 형식이 여기서 옵니다.
- Albergo et al., JMLR 2025 [6]. 보간과 확률 과정의 일반 틀.
- Lipman et al., ICLR 2023 [4]: 조건부 플로우 매칭. 잡음 원천 CFM의 기준.