ULTRA (arXiv:2603.03279): 분석 리포트

ULTRA: Unified Multimodal Control for Autonomous Humanoid Whole-Body Loco-Manipulation · arXiv v3(2026-10-17) · IROS 2026 채택(Best Mobile Manipulation Paper Award Finalist) · 공식 코드 Sirui-Xu/ULTRA (Apache-2.0, 커밋 146ddd5) · 분석일 2026-11-11 · 게시용 버전: 논문 표와 원문 PDF는 라이선스(arXiv 비독점 배포) 때문에 뺐습니다.

핵심 요약

1. **무엇을 하는가:** 사람-물체 MoCap(OMOMO)을 물리 RL로 G1 궤적에 옮기고(약 6배 증강), 특권 교사를 거쳐 시각·희소 목표를 받는 학생으로 증류한 뒤 RL 미세조정으로 분포 밖 목표를 개선합니다(`01` §2).
2. **표 III의 RL 효과는 방향은 맞지만 약합니다.** OOD 위치 4→12는 Fisher p = 0.022이지만 Holm 보정 후 0.09입니다. OOD 점군 5→9는 p = 0.32입니다(`03` §2).
3. **표 II의 "관통 감소"는 두 칸에서 반대입니다.** Largebox 관통 지속과 Suitcase 관통 최대 깊이에서 ULTRA가 집니다. 나머지 8개 칸은 ULTRA가 최고입니다(`01` §4).
4. **보상 설정 일부가 코드에서 무효입니다.** 표 B의 kint, kct는 읽히지 않고 하드코딩됩니다. 물체 위치 보상은 리타게팅 설정에서 0입니다(`04` D4-D6).
5. **공개 교사 가중치는 논문과 데이터가 다릅니다.** AMASS와 BONES-SEED로 추가 학습되었고, 두 데이터는 비상업 조건을 따릅니다. 학생 가중치는 공개되지 않았습니다(`04` D11, §1).
6. **실물 증거는 칸당 10회 이하입니다.** 칸 간 차이를 구분하려면 집단당 24-44회가 필요합니다(`03` §6).
7. **구현 가능성:** 이 맥(CUDA 없음)에서 공식 학습과 실물 재현은 **불가능**합니다. 공개 교사 가중치의 MuJoCo 추론 한 모션은 **조건부**입니다. 미검증입니다(`04` §4).
8. **라이선스:** arXiv 비독점 배포(CC BY 아님). 논문 표와 원문 PDF는 싣지 않았습니다(`04` §5).

ULTRA: 논문 분석 (arXiv:2603.03279v3)

0. 대상과 방법

- **논문:** He, Xu, Li, Dong, Bian, Wang, Gui, *ULTRA: Unified Multimodal Control for Autonomous Humanoid Whole-Body Loco-Manipulation*, arXiv:2603.03279. 저자 소속은 University of Illinois Urbana-Champaign입니다.
- **학회:** IROS 2026. arXiv comments에 "IROS 2026 Best Mobile Manipulation Paper Award Finalist"가 있어 채택으로 봅니다. 본회의 발표 여부는 확인하지 못했습니다.
- **버전:** 최신은 v3(2026-10-17)입니다(`abs` 페이지 확인). v1(2026-03-03, 13쪽)과 v2(2026-09-18, 12쪽)는 `.scratch/`에 보관했습니다. 차이는 `02` §1에 있습니다.
- **읽은 방법:** `paper/paper.txt`(`pdftotext -layout`)로 본문을 읽었습니다. 표 I, II, III, IV는 텍스트 추출이 깨지기 쉬워 **6쪽과 7쪽을 200 dpi로 렌더해 눈으로 다시 읽었습니다.** 추출 값과 일치했습니다. 표 I의 열 구조(Succ, E_g-mpjpe, E_mpjpe, E_jitter, E_pos, E_rot)도 확인했습니다.
- **그림:** 논문 그림은 이 문서에 넣지 않습니다. 원문 표 이미지는 개인용 리포트·PPT에만 씁니다(`report/figures/paper_*.png`).
- **원문 구성:** 12쪽입니다. 본문 I-VI절, 참고문헌, 부록(Table A-M, 부록 A-D)이 있습니다. 부록 표 번호(Table A-M)와 본문 표 번호(Table I-IV)를 구분합니다.

1. 문제와 과제 정의 (Sec. III)

- 전신 loco-manipulation에서 참조 동작을 따라가는 추적기(dense reference)와 목표만 주는 제어기(sparse goal)는 보통 따로 다룹니다. 저자들은 둘을 **하나의 목표 조건부 정책** π(a_t | o_t, c_t)으로 묶으려 합니다(III-A, III-B).
- 목표 c는 두 종류입니다. 시간에 따른 참조 동작(dense), 장기 목표 변환(sparse)입니다. 관측은 두 종류입니다. MoCap 물체 자세, 또는 깊이 카메라에서 만든 물체 점군(egocentric)입니다(III-A "Perception").
- 문제를 **목표 조건부 POMDP**로 씁니다(III-B). 행동은 PD 제어기의 목표 관절각입니다.

2. 방법 (Sec. IV)

ULTRA는 네 단계입니다(Fig. 2).

단계	내용	근거
0-1 물리 기반 리타게팅	SMPL-X 사람-물체 궤적을 G1 궤적으로 바꾸는 RL 정책. 축별 스케일과 물체 크기 증강을 재학습 없이 적용	IV-A
2 교사	특권 상태와 조밀한 참조로 추적하는 정책. 물리 무작위화와 외란 포함	IV-B, App. B
3 학생	고유감각, 목표, 물체 상태 또는 점군을 받는 잠재 변수 정책. 모달리티 마스크로 입력을 빠뜨리며 학습. DAgger 방식 증류	IV-C, Eq. (1)
3' RL 미세조정	병렬 환경 일부를 목표 도달 목적으로 바꾸고, 증류 손실과 함께 PPO	IV-C "RL finetuning", Table G
4 배포	학생만 실행. 잠재 변수는 사전 분포(prior)에서 샘플. 마스크로 추적, 목표 추종, 점군 기반 조작 전환	IV-C "Deployment versatility"

2.1 리타게팅 보상 (IV-A)

논문은 보상을 곱 형태 하나로 씁니다.

r_track = r_p · r_r · r_obj · r_int · r_ct · r_eng

- r_p: F(발과 손바닥)의 위치를 희소 앵커로 추적
- r_r: 핵심 링크 방향의 정규화 벡터 일치
- r_obj: 물체 자세와 속도 추적

- r_int: 손바닥과 물체 표면 사이 거리 일치
- r_ct: 사람 링크의 접촉 사건을 G1 링크에 대응시켜 맞춤
- r_eng: 관절 노력과 발 배치 정규화

이 식은 **코드와 대조가 필요한 항목**입니다. 구현별 차이는 `04` §2 D1-D8에 있습니다.

2.2 교사와 학생 (IV-B, IV-C, Eq. 1)

교사는 4052차원 관측과 29차원 행동을 씁니다(App. B, Table D). 학생은 1496차원 관측이며, 토큰 256차원, 트랜스포머 2층, 잠재 64차원입니다(App. C, Table H).

학생 손실(Eq. 1)은 세 부분입니다.

- L = ‖ a^student − a^teacher ‖ ² + L_aux + λ_KL · KL(q_φ(z | o^student, o^teacher) ‖ p_θ(z | o^student))
- L_aux: 가려진 모달리티를 복원하는 재구성 손실
- 잠재 변수는 **사후 분포(교사 정보 포함)**와 **사전 분포(학생 관측만)**를 맞춥니다.

App. F(Table F)에는 가중치 일정이 있습니다. KL 계수는 0.001에서 0.1까지 코사인으로 올리고, 평활 계수는 0.0001에서 0.001까지 올립니다. 이 두 일정은 코드와 일치합니다(`04` D14). 본문에 적힌 "prior-only 행동 손실"은 코드에서 계수가 0이어서 꺼져 있습니다(`04` D13).

2.3 RL 미세조정 (IV-C "RL finetuning", App. C, Table G)

- 병렬 환경 일부를 목표 도달 환경으로 바꿉니다. 목표 오프셋과 초기 상태 오프셋을 무작위로 줍니다.
- PPO는 **배포용 학생(사전 분포만 쓰는 정책)**에 적용합니다.
- 보상은 목표 근접 보상(지수 감쇠), 진행 보상(거리 감소, 클리핑), 성공 보너스, 종료 페널티입니다. 목표가 가려지면 해당 보상을 0으로 씁니다(마스크 게이팅).
- 증류 손실에 PPO 손실을 더하되, PPO 항은 0.2배로 줄입니다. 액터 손실 계수는 시작 후 100-200 에포크에 걸쳐 0에서 1로 올립니다. 본문은 "100 에포크 동안 점진적으로 켠다"고 씁니다(App. C, `04` D15).

2.4 점군 잡음 (IV-C, App. D, Table K)

점군에는 가우시안 지터, 점 누락, 이상점, 가림, 카메라 자세 잡음을 넣습니다. 학습 설정 파일(`g1_student_finetune.yaml`)과 값이 일치합니다(`04` D16).

3. 실험 설정 (V-A)

- **시뮬레이터:** IsaacGym(GPU 병렬)에서 학습하고, MuJoCo에서 주요 결과를 검증합니다(sim-to-sim). 실물은 Unitree G1입니다.
- **데이터:** OMOMO 사람-물체 MoCap을 쓰고, InterMimic이 정리한 수정 부분집합을 씁니다. 상자 계열 물체 4개(largebox, plasticbox, smallbox, suitcase)를 씁니다.
- **증강:** 축별 스케일과 물체 크기 변화로 데이터를 약 6배 늘렸습니다(Fig. 4).
- **평가 지표:** 리타게팅은 관통(지속 시간, 최대 깊이), 발 미끄럼(지속, 최대 접선 속도), 접촉 뜸(손-물체 접촉 손실 지속)입니다(V-B). 추적은 성공률과 MPJPE 계열 오차입니다(V-C). 목표 추종은 최종 상태가 목표 0.3 m 이내인 비율입니다(V-D).
- **훈련 반복과 통계:** 표에 반복 수나 시드 수는 없습니다. 표 I의 ±는 표준편차로 보이지만 n이 적혀 있지 않습니다.

4. 결과: 리타게팅 (V-B, Table II)

Table II는 두 물체와 네 방법의 관통, 발 미끄럼, 접촉 뜸을 비교합니다.

- ULTRA는 10개 칸(2물체 × 5지표) 중 8개에서 가장 좋습니다.
- **ULTRA가 지는 칸:** Largebox 관통 지속(0.008 대 OmniRetarget 0.000), Suitcase 관통 최대 깊이(0.017 대 OmniRetarget 0.012). 저자는 "reducing penetration"이라고 쓰지만 이 두 칸은 반대입니다.
- 발 미끄럼은 지속과 속도 모두 ULTRA가 일관되게 낮습니다(예: Largebox 지속 0.061 대 0.205).
- 접촉 뜸은 Largebox 0.015 대 0.231입니다.

- ± 값이 평균보다 크게 나오는 칸이 많아(예: 0.015 ± 0.063) 분포가 치우쳐 있을 가능성이 큽니다. 정확한 검정은 `03` §4에 있습니다.

질적 비교(Fig. 3) 는 OmniRetarget의 정지 발 배치를 보여 주지만, 한 장면입니다.

5. 결과: 추적 (V-C, Table I)

Table I의 주요 칸(IsaacGym, ID 및 OOD, 열: Succ(humanoid), Succ(+object), 오차들).

방법	ID 성공 (humanoid)	ID 성공 (+object)	OOD 성공 (humanoid)	OOD 성공 (+object)
ULTRA (Ours, 통합 학생)	67.30 ± 0.12	57.44 ± 0.40	70.57 ± 0.54	52.00 ± 0.44
ULTRA 교사 (특권)	97.57 ± 0.05	89.79 ± 0.11	97.12 ± 0.43	81.33 ± 0.78
ULTRA (RL, 학생 관측 직접 RL)	54.47 ± 0.43	41.78 ± 0.31	53.38 ± 0.98	23.54 ± 0.24
ULTRA (증류만, 추적 전용)	85.03 ± 3.00	77.15 ± 0.57	86.63 ± 0.50	52.74 ± 0.04
HDMI	13.07 ± 0.20	9.94 ± 0.38	13.92 ± 0.78	12.95 ± 0.30
OmniRetarget† (원본 데이터)	41.27 ± 1.17	21.90 ± 0.29	33.36 ± 0.39	20.78 ± 0.13
OmniRetarget (증강 데이터로 재학습)	51.34 ± 0.67	20.91 ± 0.52	46.71 ± 0.74	25.82 ± 0.52

(표는 `paper/paper.pdf` 6쪽을 렌더해 확인한 값입니다. 오차 열은 생략했습니다.)

해석할 때 세 가지를 봐야 합니다.

1. **통합 학생은 추적 전용 증류보다 ID 추적이 17.7%p 낮습니다**(67.30 대 85.03). 저자는 교사와 학생의 격차(97.57 대 67.30)를 "과소적합이 아니라 통합 때문"이라고 씁니다(V-C). 이 주장을 확인하는 실험(학습 길이, 용량 변화)은 없습니다.
2. **OmniRetarget 기준선의 데이터가 다릅니다.** OmniRetarget†은 원본 데이터, 다른 행은 6배 증강 데이터로 학습했습니다. 증강 데이터로 재학습한 OmniRetarget의 OOD 성공은 46.71로 원본(33.36)보다 높습니다. 저자는 이를 증강 효과의 근거로 씁니다(V-B). 그래도 ULTRA(OOD 70.57)와의 차이에는 방법 차이와 데이터 차이가 섞여 있습니다.
3. **HDMI는 저자 설명대로 대규모 설정에서 수렴하지 못한 것으로 보입니다**(성공 13%). 하이퍼파라미터를 맞춘 것인지는 논문에 없습니다.

6. 결과: 목표 추종과 RL 미세조정 (V-D, Table III, Fig. 5-6)

Table III는 MuJoCo sim-to-sim에서 칸당 20개 모션을 씁니다.

설정	미세조정 전	미세조정 후	저자 보고 증가율
ID 목표 · 점군	16/20	19/20	+18.8%
ID 목표 · 위치	14/20	16/20	+14.3%
OOD 목표 · 점군	5/20	9/20	+80.0%
OOD 목표 · 위치	4/20	12/20	+200.0%

- 저자는 "미세조정이 ID는 조금, OOD는 크게 올린다"고 씁니다. 방향은 맞습니다.
- 그러나 **칸당 20회, 시드 분산 없음, 쌍 설계 여부 불명**이라 증가율은 세 건(3, 2, 4, 8회)의 차이입니다. 유의성은 `03` §2에 있습니다. OOD 위치는 Fisher p = 0.022이지만 네 검정에 Holm을 적용하면 0.09입니다. OOD 점군은 p = 0.32입니다.
- Fig. 5는 잠재 공간이 모달리티 사이에서 섞인다고 보여 줍니다. 정량 지표는 없습니다. 텍스트 군집(MiniLM + K-Means)과의 대응도 정성적입니다.
- Fig. 6은 장면 몇 장을 보여 줍니다.

7. 결과: 실물 Unitree G1 (V-E, Table IV)

설정	세로 (Vertical)	가로 (Lateral)
밀집 참조 추적	73% (19/26), 방향 구분 없음	

설정	세로 (Vertical)	가로 (Lateral)
희소 목표 · MoCap 물체 자세	80% (8/10)	90% (9/10)
희소 목표 · egocentric 점군	50% (5/10)	60% (6/10)

(열 배치는 `paper/paper.pdf` 7쪽을 렌더해 확인했습니다. 이전 텍스트 추출은 열을 확정하지 못했습니다.)

- 캡션은 "Each task is evaluated over two trials"라고 씁니다. 방향별 분모가 10이므로 "두 시도"는 두 방향을 가리키는 것으로 보입니다. 밀집 추적의 분모 26은 설명이 없습니다.
- 실물 결과는 모두 칸당 10회 이하입니다. Wilson 95% 구간은 5/10에서 [24%, 76%]입니다(`03` §3).
- 실패 원인으로 마찰 차이에 의한 미끄럼, 점군 잡음과 가림, 외란 세 가지를 듭니다. 촉각을 추가하지 않은 것이 한계입니다.
- 실물 영상은 프로젝트 페이지에 있습니다. 이 분석에서는 보지 않았습니다.

8. 한계와 열린 문제

논문과 부록이 직접 밝힌 한계(App., "Limitations"; 결론).

- 손이 있는 로봇(dexterous hands)을 쓰지 않고 상자 계열 물체에만 한정됩니다.
- 동적 이동(dynamic locomotion)을 다루지 않습니다.
- 점군 인식 모델을 처음부터 학습합니다.
- OOD 가림에 약하고, MoCap 마커 가림은 물체 자세의 지터와 드리프트를 만듭니다. 목표가 과도하거나 불연속이면 실패합니다.

본문에서 드러나지만 명시하지 않은 한계.

- **학생 가중치가 공개되지 않았습니다.** 공개된 것은 교사 가중치뿐입니다(`04` §1).
- **교사 가중치의 훈련 데이터가 논문과 다릅니다.** 공개 저장소는 OMOMO 외에 AMASS와 BONES-SEED를 추가했다고 씁니다(`04` D11).
- **실물 배포 스택이 저장소에 없습니다.** ROS 노드, G1 저수준 제어, OptiTrack, 깊이 점군 추출, 키보드 목표 인터페이스가 빠져 있습니다(`04` D18).
- **증강 효과와 방법 효과가 섞여 있습니다.** 표 I의 기준선 비교는 데이터를 함께 바꿨습니다(V-B, V-C).

9. 주장과 증거의 수준

주장	근거	수준
물리 기반 리타게팅이 접촉을 더 잘 보존한다	Table II, 질적 Fig. 3	중간. 8/10 칸 우세. 관통 두 칸은 반대. 반복 수 없음
증강은 OOD 일반화를 높인다	Table I의 OmniRetarget† 대 재학습 행	약함. 같은 방법의 데이터 차이만 본 것이 아니라 "재학습 전후"가 비교 대상
통합 학생은 추적 기준선보다 낫다	Table I, ID와 OOD	중간. 기준선 설정이 달라 엄밀한 비교 아님
통합 학생은 교사에 가깝다	Table I 교사 97.57 대 학생 67.30	약함. 격차를 "통합"으로 설명하는 근거가 없음
RL 미세조정은 OOD 목표를 개선한다	Table III	방향은 맞음. 칸당 20회, Holm 보정 후 OOD 위치 $p = 0.09$
실물에서 밀집 추적과 희소 목표 추종이 된다	Table IV	약함. 칸당 10회 이하. 실패 수 1-5

재현 가능성은 `04` §4에 있습니다.

ULTRA: 선행연구와 관계

1. 버전 차이

버전	날짜	쪽수	내용 차이
v1	2026-03-03	13	초록과 서론이 더 길고, 용어가 "skill latent"(잠재 기술 공간)입니다. 참고문헌 번호가 다릅니다(PHC는 [15], GMR은 [1]). 표 I-IV의 수치는 v3와 같습니다.
v2	2026-09-18	12	본문을 다시 씀. 저자 목록과 제목 쪽 배치가 바뀌었습니다. 수치 변화는 텍스트 추출로 확인하지 못했습니다(표 확인은 v3 기준).
v3	2026-10-17	12	v2와 텍스트 차이는 두 줄뿐입니다(arXiv 스탬프 날짜, 프로젝트 주소 `ultra-humanoid.github.io` → `ultrahumanoid.github.io`).

- v1과 v3의 **표 수치는 같습니다**(표 I, II, III, IV를 텍스트 추출과 렌더로 확인했습니다). 표 IV의 열 배치(Vertical, Lateral)도 두 버전에서 같습니다.
- v1 대 v2 텍스트 차이는 1,497줄로 대부분 재작성입니다. 결과 수치를 바꿨는지는 표로 확인했습니다.
- 원본 PDF: v1(`.scratch/v1.pdf`), v2(`.scratch/v2.pdf`)는 `ultra_humanoid/.scratch/`에 있습니다(gitignore). 최신 v3는 `paper/paper.pdf`입니다.

2. 계보

2.1 리타게팅

흐름	대표 연구 (논문 참고문헌)	ULTRA와의 관계
IK 기반 애니메이션 리타게팅	Lee & Shin, SIGGRAPH 1999 [8]	운동학만 씀. 물리 일관성 없음
신경 리타게팅	Villegas et al., CVPR 2018 [9]	상각된 매핑. 접촉 무시
운동학 휴머노이드 리타게팅	PHC 계열 [4], GMR [5], OmniRetarget [2]	기준선. 논문 Table II와 I의 대상
물리 기반 리타게팅 (샘플링·RL)	DexPlore [11], SPIDER [12]	물체 한 개씩 최적화. ULTRA는 한 정책으로 모든 동작을 처리한다고 주장

ULTRA의 위치는 "물리 기반이지만 한 정책으로 대량 처리"입니다. 이 점이 새롭다고 주장하지만, 이전 연구가 같은 목적으로 RL 리타게팅을 쓴 경우와의 직접 비교는 없습니다.

2.2 휴머노이드 추적과 기반 모델 방식

- 추적 제어: OmniH2O [13], ASAP [15], HOVER [16], TWIST [18], GMT [19], UniTracker [20], SONIC [21], BeyondMimic [22], BFM-Zero [27]
- 잠재 사전 분포: LeVERB [24], StyleLoco [25], AMP 계열 [26]. 논문은 이들이 대규모 이질 데이터로 확장된 적이 없다고 봅니다.
- 교사-학생 증류: DAgger [38], MaskedMimic [6]. ULTRA의 증류는 DAgger 방식과 잠재 변수 손실(VAE 유사)을 합칩니다.

2.3 물체 상호작용과 loco-manipulation

- 같은 저자 계열: InterMimic [3] (CVPR 2025, 사람-물체 추적 교사), InterPrior [7] (CVPR 2026, 증류 후 RL 미세조정 절차의 출처). ULTRA는 InterPrior의 두 단계 절차를 따른다고 씁니다(IV-C).
- 물체 상호작용 추적·조작: HDMI [1], ResMimic [31], DemoHLM [32], PhysHSI [34], DreamControl [33], VisualMimic [17]
- 계층형 설계: 계획기가 궤적을 만들고 추적기가 따름 [17], [33]. ULTRA는 계층 오차 누적을 피하려고 단일 목표 조건부 정책을 씁니다.

3. 이 저장소의 관련 분석과 관계

폴더	대상	ULTRA와 관계
`warp_retargeting/`	WARP(arXiv:2606.29940, CoRL 2026): 사람 상체 시연을 로봇 전신으로 바꾸는 오프라인 기하 리타게터	**가장 가깝습니다.** 같은 리타게팅 문제를 기하 해법으로 풉니다. ULTRA는 RL로 물리 일관성을 얻습니다. 두 방법의 접촉 품질 지표(관통, 미끄럼, 접촉 뜸)를 맞대어 볼 수 있습니다.
`reasoning_retargeting/`	블로그 "Retargeting Through Reasoning": 에이전트가 MuJoCo 피드백으로 HOI 리타게팅 기준을 만듦	리타게팅을 최적화 문제가 아니라 설계 과정으로 봅니다. ULTRA의 보상 항과 대조할 수 있습니다. 블로그라 심사된 근거가 없습니다.
`gnr/`	GNR(arXiv:2610.12440): 샘플링 MPC 궤적에 잔차를 더하는 생성 리타게터(손 로봇)	방법은 다르지만 "리타게팅 궤적을 물리 필터로 거른다"는 점이 같습니다. ULTRA는 손이 없는 G1을 씁니다.
`cross_embodiment_wm/`	교차 형상 세계 모델(IROS 2026)	학생의 모달리티 마스크와 교차 형상 문제(여러 입력을 한 모델로)가 관련됩니다.
`dreamx/`	DreamX(arXiv:2611.05377): 영상 확산 모델 잠재 행동	사람-로봇 공통 행동 인터페이스라는 목표는 같지만, ULTRA는 물리 정책입니다.
`motion_latent_action/`	Motion-Focused Latent Action(IROS 2026)	잠재 행동을 교차 형상 VLA에 쓴다는 점에서 ULTRA의 잠재 변수와 비교할 수 있습니다.
`contactbench/`	ContactBench(arXiv:2610.24512): 접촉 과제 벤치마크	실물 검정력과 표 재계산 방식을 같이 씁니다(`03` §6).

4. GitHub 저장소 표

확인일 2026-11-11. 별 수와 최근 활동은 `gh api`로 확인했습니다. 라이선스는 저장소의 감지 결과입니다.

저장소	무엇	공식?	라이선스	별	최근 활동 (push)	비고
Sirui-Xu/ULTRA	ULTRA 코드, 교사 추론 가중치, 증강 데이터 링크	공식 (저자 계정)	Apache-2.0 (InterMimic 파생 MIT 포함)	56	2026-10-17, 커밋 `146ddd5f6398` ("Fix project page link in README")	학생 가중치, 배포 스택, 실제 데이터 없음. `repo/ULTRA/`에 얕게 클론
Sirui-Xu/InterMimic	사람-물체 전신 추적(CVPR 2025), ULTRA 데이터 형식 원본	공식	MIT	558	2026-04-21	ULTRA가 데이터 형식과 OMOMO 수정 부분집합을 가져옴
YanjieZe/GMR	실시간 CPU 운동학 리타게팅(ICRA 2026)	논문 [5] 구현으로 보임	MIT	2,821	2026-10-22	기준선. 공식 여부는 저자 목록으로 추정
ZhengyiLuo/PHC	PHC(ICCV 2023) 공식 구현	공식	감지 안 됨 (NOASSERTION, 원문 확인 필요)	1,308	2025-08-21	기준선 [4]
LeCAR-Lab/HDMI	HDMI(인간 영상 학습)	공식	없음	680	2026-01-17	기준선 [1]. 라이선스가 없어 코드를 가져다 쓸 수 없음

저장소	무엇	공식?	라이선스	별	최근 활동 (push)	비고
project-instinct/omniretargeting	OmniRetarget(arXiv:2509.26633) 재구현	**재구현** (논문 저자 공식 구현이 아님)	MIT	85	2026-11-03	공식 저장소는 찾지 못함. 이 재구현으로 OmniRetarget 결과를 재현한 것은 아님
OmniRetarget/omniretarget.github.io	OmniRetarget 프로젝트 페이지 저장소	공식 추정	없음	2	2026-07-11	코드 저장소로 보기 어려움
facebookresearch/spider	SPIDER(arXiv:2511.09484) 물리 기반 손 리타게팅	공식 추정	NOASSERTION	598	2026-09-22	기준선 아님. 물리 기반 리타게팅의 다른 구현

공식 코드가 있는 것은 ULTRA 하나입니다. 기준선 중 PHC와 GMR은 공식 구현이 공개되어 있고, HDMI는 공개되었지만 라이선스가 없습니다. OmniRetarget의 공식 구현은 찾지 못했습니다.

5. 한 줄 정리

ULTRA는 "사람-물체 MoCap을 물리 RL로 대량 리타게팅 → 교사 → 모달리티 마스크 학생 → RL 미세조정"이라는 파이프라인을 한 논문에 묶은 시스템 논문입니다. 새 알고리즘 하나보다 **단계들의 결합**이 기여입니다. 그래서 개별 단계의 검증 수준(`03`, `04`)을 따로 봐야 합니다.

ULTRA: 표 재계산, 유의성, 토이

재현 스크립트: `analysis/table_check.py` (표 재계산과 검정, 1초 미만), `analysis/power_toy.py` (실물 검정력, 수십 초), `analysis/retarget_toy.py` (리타게팅 토이, 1초 미만). 결과는 같은 이름의 `*_results.json`에 있습니다. 그래프는 `analysis/plot_figures.py`가 만듭니다.

0. 방법과 가정

- **입력 값:** 표 I-IV의 값은 `paper/paper.pdf` 6-7쪽을 200 dpi로 렌더해 눈으로 확인했습니다. 텍스트 추출과 같았습니다.
- **반복 수:** 표 III는 칸당 n = 20, 표 IV는 칸당 n = 10(밀집은 26), 표 I과 II는 n이 없습니다(±만 있음).
- **도구:** scipy(Fisher 정확 검정, 두 집단 Welch), statsmodels(Wilson 구간, Holm).
- **공식:**
  - Wilson 구간: 비율 $\hat{p}$, 표본 n에서 중심 $(\hat{p} + z^2/2n)/(1 + z^2/n)$, 반폭 $z\sqrt{(\hat{p}(1-\hat{p})/n + z^2/4n^2)}/(1 + z^2/n)$. z = 1.96.
  - Fisher 정확 검정: 2×2 표의 초기하 분포에서 양측 합 p값.
  - Newcombe 차이 구간: 두 Wilson 구간의 끝점을 점수법으로 합침.
  - Holm: p값을 오름차순으로 정렬해 $(m - i + 1)\cdot p(i)$를 구하고 단조 증가로 고침.
  - McNemar 정확 검정(쌍 설계): 불일치 쌍 b, c에 대해 $2\cdot P(X \le \min(b, c))$, $X \sim \text{Binom}(b+c, 0.5)$. **에피소드별 쌍 정보가 없으므로** 가능한 (b, c)의 범위에서 p값의 최소와 최대를 봅니다.
  - Welch: n이 가정값일 때의 민감도 분석으로만 씁니다.
  - 검정력: 두 이항 분포의 모든 결과 쌍 (k1, k2)에 대해 Fisher p값을 계산하고 확률로 가중합합니다(몬테카를로 없음).

1. 표 재계산 일치 확인

확인 항목	결과
표 III 네 칸의 성공 수와 본문 증가율(+18.8%, +14.3%, +80%, +200%)	19/16, 16/14, 9/5, 12/4의 비율과 일치
본문 "nearly doubling"(OOD 점군)	9/5 = 1.8. 맞음
본문 "tripling"(OOD 위치)	12/4 = 3.0. 맞음
표 I 교사와 학생의 ID 격차	97.57 – 67.30 = 30.27%p. 본문의 "residual gap"과 같은 수치
표 IV 밀집 추적	19/26 = 73.1%. 표의 73%와 맞음
표 II 승패	10개 칸 중 ULTRA 최고 8개. 지는 칸 2개(아래 §4)

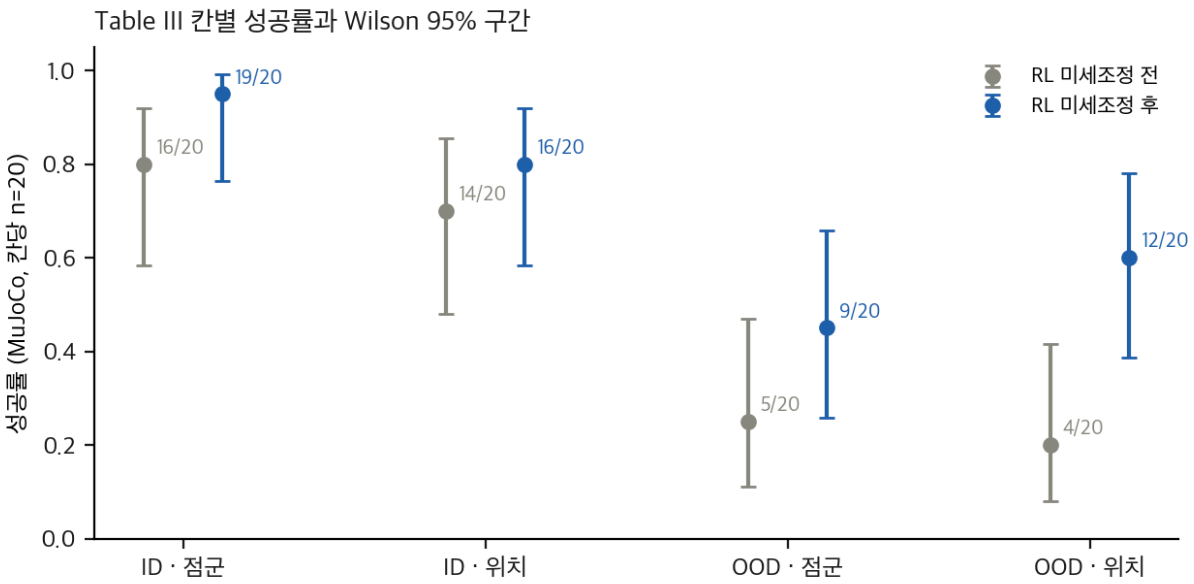
2. 표 III: RL 미세조정 전후 (칸당 n = 20)

설정	전 → 후	차이(%p)	Newcombe 95% 구간(%p)	Fisher p (원)	Holm p (4개)	쌍 설계일 때 McNemar p 범위
ID · 점군	16 → 19	+15	[–7.1, +37.0]	0.342	0.961	0.25 - 0.375
ID · 위치	14 → 16	+10	[–16.6, +34.9]	0.716	0.961	0.50 - 0.754
OOD · 점군	5 → 9	+20	[–9.1, +45.0]	0.320	0.961	0.125 - 0.424
OOD · 위치	4 → 12	+40	[+9.6, +61.7]	**0.0225**	**0.090**	**0.0078 - 0.0768**

해석.

- **OOD 위치는 원 p값으로는 유의(0.022)하지만 네 검정의 Holm 보정 후에는 0.09입니다.** 실험을 네 번 한 것으로 보면 유의하다는 결론은 약합니다. 다만 쌍 설계라면 McNemar 범위는 0.008-0.077이라 쌍 정보에 따라 결론이 달라집니다.
- **OOD 점군(+20%p)은 어떤 정렬에서도 p < 0.05를 만들지 못합니다.** 원 p 0.32, 쌍 설계에서도 최소 0.125입니다. 저자의 "OOD 점군 두 배"는 세 건(5→9)의 차이입니다.
- ID 증가(+10~15%p)는 모든 검정에서 유의하지 않습니다.

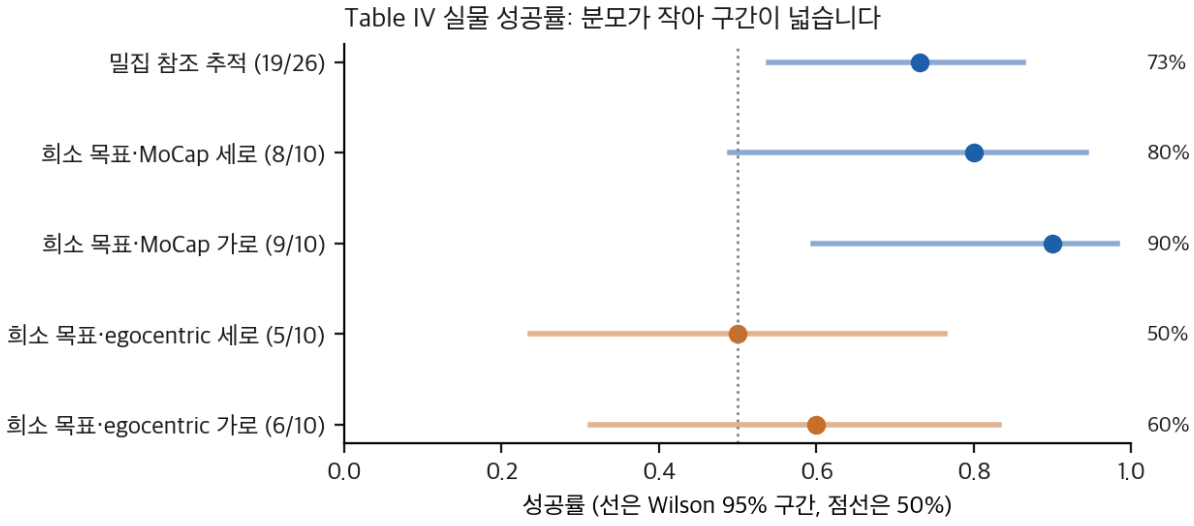
- 칸당 20회라서 Wilson 구간 폭이 약 ±20%p입니다. 증가율 +200%는 분모 4에서 나온 값이라 비율 자체가 불안정합니다. 보고할 때는 %p 차이와 구간을 함께 쓰는 것이 낫습니다.



3. 표 IV: 실물 (칸당 n = 10)

칸	성공	Wilson 95%
밀집 참조 추적	19/26	[53.9%, 86.3%]
희소 목표 · MoCap · 세로	8/10	[49.0%, 94.3%]
희소 목표 · MoCap · 가로	9/10	[59.6%, 98.2%]
희소 목표 · egocentric · 세로	5/10	[23.7%, 76.3%]
희소 목표 · egocentric · 가로	6/10	[31.3%, 83.2%]

- **MoCap 대 egocentric(합계 17/20 대 11/20):** Fisher p = 0.082. 방향별로는 세로 p = 0.35(8/10 대 5/10), 가로 p = 0.30(9/10 대 6/10)입니다. 방향별 차이는 모두 검정하지 못했습니다.
- **분모 문제.** 캡션은 "two trials"라고 씁니다. 방향별 분모가 10이므로 두 방향을 가리키는 것으로 보입니다. 그러나 밀집 추적의 분모 26은 설명이 없습니다. 실물 결과의 실제 시도 수를 확인하려면 저자에게 물어야 합니다.
- **결론의 한계.** 칸 간 차이가 10-40%p인데 이 칸들의 검정력은 낮습니다(§6). 실물 결과는 "작동한다"는 증거는 되지만 "MoCap이 egocentric보다 낫다"는 증거는 아닙니다.



4. 표 I, II: 반복 수가 없음 (n 가정 민감도)

표 I과 II는 ±만 있고 n이 없습니다. Welch의 p값은 n을 가정한 값입니다(민감도 분석).

표 I

비교	n=3	n=5	n=10	n=20
ID 추적 · 통합 학생 67.30±0.12 대 증류만 85.03±3.00	0.009	0.0002	≈0	≈0
OOD 추적 · 통합 학생 70.57±0.54 대 OmniRetarget(재학습) 46.71±0.74	4e-6	≈0	≈0	≈0

- 표 I의 큰 차이는 n이 적어도 유의합니다. 다만 **표준편차가 시드 분산인지, 에피소드 분산인지, 평가 반복인지** 논문이 말하지 않습니다. 이것이 정해지지 않으면 어떤 n도 근거가 없습니다.
- 통합 학생과 증류만 학생의 차이 17.7%p(ID, 85.03 – 67.30)는 n이 3 이상이면 유의합니다. 저자가 "통합 때문"이라고 해석하는 격차는 **통계적으로는 확실하지만 원인은 확인되지 않았습니다.**

표 II (Largebox 발 미끄럼 지속, 접촉 뜸)

비교	n=3	n=5	n=10	n=20
발 미끄럼 지속 0.061±0.031 대 0.205±0.106	0.13	0.036	0.0019	7e-6
접촉 뜸 0.015±0.063 대 0.231±0.224	0.23	0.097	0.014	0.0004
Suitcase 관통 지속 0.002±0.013 대 0.003±0.016	0.94	0.92	0.88	0.83

- 표 II의 큰 차이도 n에 따라 달라집니다. n이 5 이하면 유의하지 않습니다.
- 표준편차가 평균보다 큰 칸(0.015 ± 0.063)은 분포가 한쪽으로 치우쳐 있을 가능성이 큽니다. 평균과 표준편차 대신 중앙값과 사분위를 보고해야 합니다.
- 논문은 "lowest foot-skating ⋯ much less contact floating"이라고 씁니다. 이 결론은 n이 10 이상이면 유지되지만, 본문에서 n을 밝히지 않은 것이 문제입니다.

5. 텍스트 주장 대조

본문 문장	표와 맞는지
"ULTRA outperforms baselines across nearly all metrics" (V-B)	10개 칸 중 8개. 맞지만 "nearly all"로는 과함
"while also reducing penetration" (V-B)	**틀림.** Largebox 관통 지속(0.008 대 0.000)과 Suitcase 관통 최대 깊이(0.017 대 0.012)에서 ULTRA가 짐
"near-zero on Largebox/Suitcase" contact floating (V-B)	Largebox 0.015, Suitcase 0.008. 대략 맞음. "near-zero"는 ±가 평균보다 큼
"tracking-only student already reaches 85.03%" (V-C)	표 I 증류 행과 맞음
"Table III: finetuning yields modest ID gains but large OOD gains" (V-D)	방향 맞음. 크기 해석은 §2처럼 n에 민감
"reliably grasps/transports on hardware" (V-E)	실물 73-90%. 칸당 n이 작아 "reliably"는 과함

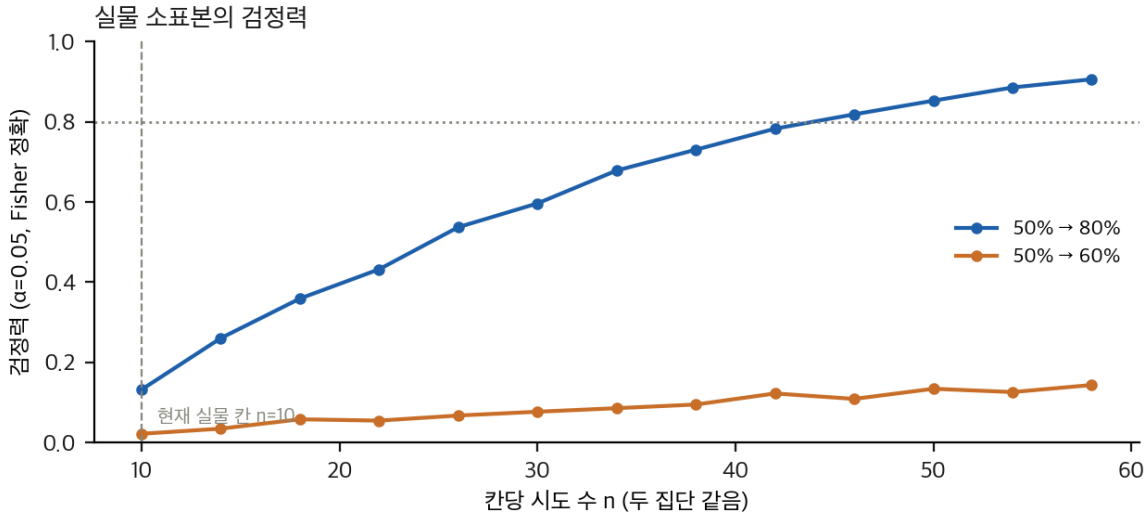
6. 실물 검정력과 설계

`analysis/power_toy.py` (Fisher 정확, 양측, α = 0.05)의 검정력 표. 칸당 n은 두 집단 같음.

차이	n = 10	n = 20	n = 30	n = 40	80% 검정력에 필요한 n (집단당)
50% → 80%	0.13	0.41	0.60	0.75	44
50% → 90%	0.30	0.74	0.91	0.98	24
20% → 60%	0.25	0.65	0.85	0.95	28

차이	n = 10	n = 20	n = 30	n = 40	80% 검정력에 필요한 n (집단당)
25% → 45%	0.06	0.18	0.27	0.38	80 초과
50% → 60%	0.02	0.05	0.08	0.11	80 초과

- **실물 칸 n = 10에서는 차이 30%p 이하를 거의 못 잡습니다.** 표 IV의 칸 간 차이(10-40%p)는 대부분 이 범위입니다.
- 80% 검정력을 얻으려면 차이 40%p(20% → 60%)에는 집단당 28회, 30%p(50% → 80%)에는 44회, 20%p(25% → 45%)에는 80회를 넘게 필요합니다.
- 이 수치는 실물 시도가 독립이라고 가정합니다. 같은 물체와 같은 날에 반복한 시도는 독립이 아닐 수 있습니다.



7. 토이 1: 운동학 리타게팅의 실행 가능성 (`retarget_toy.py`)

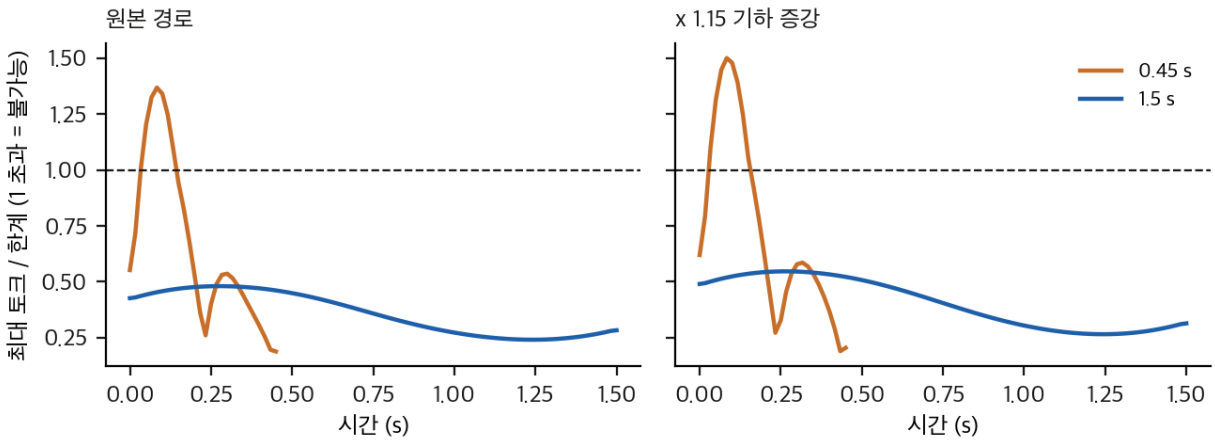
이것은 ULTRA의 재현이 아니라 토이입니다. 평면 2링크 팔(링크 0.35 m, 질량 1.5 kg, 끝 물체 1.0 kg, 토크 한계 30/15 N·m)이 같은 손 경로를 따라갑니다.

- 운동학 리타게팅: 손 경로를 damped least squares IK로 따라가 관절 궤적을 만듭니다(IK 오차 약 1e-7 m).
- 동역학 검사: 역동역학 $\tau = M\,\ddot{q} + C\,\dot{q} + G$로 토크를 계산하고, 한계와 비교합니다.
- 경로: 시작 (0.45, 0) → 끝 (0.25, 0.45), 5차 시간 법칙. 증강은 x 방향 1.15배.

조건	손 경로 시간	최대 토크 / 한계	불가능 프레임 비율
원본	0.30 s	2.56	58%
원본	0.45 s	1.37	25%
원본	1.50 s	0.48	0%
x 1.15 증강	0.30 s	2.80	68%
x 1.15 증강	0.45 s	1.50	29%
x 1.15 증강	1.50 s	0.55	0%

- **실행 가능한 최소 시간:** 원본 0.558 s, 증강 0.608 s. 기하 증강은 같은 동작을 약 9% 더 느리게 만들어야 실행 가능합니다.
- 메시지: 운동학으로 만든 리타게팅 궤적은 빠른 동작에서 토크 한계를 넘고, 기하 증강은 이 문제를 키웁니다. 그래서 ULTRA가 증강 뒤에 물리 RL을 두는 설계는 **합리적**입니다. 다만 토이는 이 설계가 실제로 맞는지 보여 주지 않습니다.
- 한계: 토이는 정적·역동역학 실행 가능성만 봅니다. 접촉, 마찰, 미끄럼, 제어 오차는 없습니다. 토크 한계 값은 임의로 골랐습니다.

토이: 같은 손 경로의 토크 실행 가능성



8. 열린 문제와 다음 검정

1. **OOD 위치 효과(p = 0.022 원, 0.09 Holm).** 같은 20개 모션에 쌍으로 적용했는지, 모션별 결과가 있는지 저자에게 묻습니다. 있다면 McNemar 검정으로 결론이 달라지는지 확인합니다.
2. **표 I, II의 n.** 시드 수, 평가 에피소드 수를 확인합니다. 이것이 없으면 §4의 결론은 모두 조건부입니다.
3. **실물 시도 수.** 밀집 추적 분모 26과 "two trials"의 의미를 확인합니다.
4. **공개 교사 가중치 대 논문 교사.** 공개 가중치는 AMASS와 BONES-SEED를 더 학습했습니다(`04` D11). 논문 표 I의 교사 성능을 공개 가중치로 재현하면 차이가 나는지 확인해야 합니다(GPU 필요).

ULTRA: 논문 ↔ 공식 코드 대조 (정적 읽기)

0. 대상과 방법

- **저장소:** github.com/Sirui-Xu/ULTRA (Apache-2.0, InterMimic 파생 MIT). 얕은 클론 `repo/ULTRA/` (gitignore). 커밋 `146ddd5f63987f9b41304b368e40f69990e63ec2` (2026-10-17, "Fix project page link in README").
- **읽은 것:** `README.md`, `docs/install.md`, `docs/deploy.md`, `docs/teacher-model-card.md`, `requirements.txt`, `scripts/train_retarget_smplx.sh`, `train_teacher.sh`, `train_student.sh`, `train_finetune.sh`, `ultra/data/cfg/g1_retarget_smplx.yaml`, `g1_teacher.yaml`, `g1_student_vae.yaml`, `g1_student_finetune.yaml` (일부), `ultra/env/tasks/ultra_g1.py`, `ultra_g1_retarget.py` (보상 함수 1053-1245행), `humanoid_g1.py` (보상 함수 516-745행), `ultra/learning/ultra_agent_distill_vae_rl.py` (손실 657-690행), `ultra/run_teacher_inference.py`, `ultra/sim2sim_teacher.py` (임포트).
- **하지 않은 것:** 코드 실행, `pip install`, 데이터·가중치 다운로드(Google Drive 링크 포함), GPU 사용, IsaacGym 설치. 모든 결과는 읽기에서 나온 것입니다.
- **표기:** 논문은 절·표·부록 번호(IV-A, Table B 등), 코드는 `파일:줄` 로 씁니다.

1. 저장소에 있는 것과 없는 것

구성	저장소에 있나	비고
리타게팅 학습 코드(UltraG1)	있음	`scripts/train_retarget_smplx.sh` → `--task UltraG1`
리타게팅 증강 내보내기	있음	`scripts/export_retarget_smplx.py` (`--xyz`, `--asset-scale`)
교사 학습 코드 (UltraG1Retarget)	있음	`scripts/train_teacher.sh`
학생 증류 코드(VAE)	있음	`scripts/train_student.sh` → `UltraDistillObjV2Point`
RL 미세조정 코드	있음	`scripts/train_finetune.sh` → `UltraDistillObjV3RL`
교사 추론 가중치	있음	`ultra/weights/teacher_ultra_inference.pth`, 45.9 MB
학생 가중치	**없음**	표 I, III, IV의 학생 결과를 저장소만으로 재현할 수 없음
리타게팅 가중치	없음	학습해야 함
데이터	없음	두 개의 Google Drive 링크(InterAct OMOMO 준비본, ULTRA 리타게팅 증강본). 받지 않음
실물 배포 스택	**없음**	`docs/deploy.md` : ROS 노드, G1 저수준 제어, OptiTrack, 깊이 점군 추출, 키보드 목표 인터페이스는 저장소 밖
시뮬 대 시뮬(MuJoCo) 검증	있음	`ultra/sim2sim_teacher.py`, `sim2sim_vae.py`, `sim2sim_vae_keyboard.py`
로봇 자산	있음	G1 29-DoF URDF·XML·메시, 물체 4종(+크기 변형)

2. 논문 ↔ 코드 D-items

판정: **일치**, **불일치**(논문과 코드가 다름), **추가**(코드에만 있음), **확인 불가**(읽기로는 근거를 못 찾음).

ID	주제	논문	코드	판정	근거
D1	리타게팅 보상 구조	곱 형태 단일식 r_track = r_p·r_r·r_obj·r_int·r_ct·r_eng (IV-A)	두 구현이 있음. 리타게팅 단계(UltraG1)는 보상 = reward_dof·contact_energy·energy·obj_energy·w1 + rb·ro·rig·w2 + rb·ro·rig·rcg·w3. w1, w2, w3는 시간에 대한 sigmoid로 "정지 → 접근 → 추적" 단계를 나눔. 교사 단계(UltraG1Retarget)는 단일 곱에 **1.6 배율**을 곱함	불일치 (추가 항목 있음)	`humanoid_g1.py:743`, `ultra_g1_retarget.py:1238, 1243`, 주석 "I: standing; II: approaching; III: tracking"
D2	r_p 대상 (발과 손바닥)	"F은 발과 손바닥"(IV-A)	리타게팅 단계: `local_key_pos = key_pos[:, [2, 5]]` (발만)으로 rp를 계산. 손은 접촉과 r_int에만 씀. 교사 단계는 **39개 전신 링크**의 위치를 씀	불일치	`humanoid_g1.py:631–632`, `ultra_g1_retarget.py:1155–1156`
D3	r_r (링크 방향 대 관절각)	핵심 링크 방향의 정규화 벡터 일치(IV-A)	리타게팅 단계: 링크 방향 벡터 `rot_id` 9쌍으로 일치(일치). 교사 단계: **관절각** `dof_pos`를 직접 일치	일치 (리타게팅), 불일치 (교사)	`humanoid_g1.py:634–635` (local_key_rot), `ultra_g1_retarget.py:1159–1161`
D4	r_obj: 물체 위치 추적	"물체 자세와 속도 추적"(IV-A)	리타게팅 설정 `op: 0.`이라 **물체 위치 보상이 꺼짐** (`rop = exp(−0·eop) = 1`). 회전과 속도만 남음(or 0.1, opv 0.01). 물체 위치는 종료 조건(물체 점군 차이 > 0.5 m)으로만 제한	불일치	`g1_retarget_smplx.yaml:67`, `ultra_g1_retarget.py:1177, 1195`
D5	r_int 가중치 (kint = 20)	Table B: kint = 20	설정 파일 `ig: 20`은 **읽히지 않음**. 리타게팅 단계는 `w_ig = 5`로, 교사 단계는 `w_ig = 1`로 **함수 안에 하드코딩**. `run.py` / `run_distill.py`가 `args.ig`를 넣어도 사용처가 없음	불일치 (구성값 무효)	`humanoid_g1.py:616`, `ultra_g1_retarget.py:1140`, `run.py:251`
D6	r_ct 가중치 (kct = 5)	Table B: kct = 5	설정의 `cg1`, `cg2 = 5`는 **읽히지 않음**. 리타게팅 단계는 손 접촉에 `w_cg_left = 0.5`, 교사 단계는 전신 접촉에 `w_cg = 1.0`으로 하드코딩	불일치 (구성값 무효)	`humanoid_g1.py:683`, `ultra_g1_retarget.py:1208`
D7	r_eng (노력·발 배치 정규화)	"관절 노력과 발 배치 정규화"(IV-A)	행동 노력 항(eg1)은 교사 설정에서 0.0이고, 리타게팅 함수는 행동 항을 아예 쓰지 않음. 접촉 에너지(eg3 = 1e−10)는 사실상 1. 발 배치 정규화 항은 없음	불일치 (사실상 없음)	`g1_teacher.yaml:86–88`, `ultra_g1_retarget.py:1231–1235`

ID	주제	논문	코드	판정	근거
D8	기준 궤적의 발 높이 보정	논문에 없음	교사 단계는 기준 발 높이에 **발 수평 속도 × 0.1**을 더함(발이 움직이면 기준 높이를 올림)	추가(미기재)	`ultra_g1_retarget.py:1126` (`vel_to_height_coef = 0.1`)
D9	교사 보상 가중치 (Table B)	kp = 10, kr = 5, kpv = 0.1, kop = 5, kor = 0.5, kopv = 0.1, kint = 20, kct = 5	교사 설정 `p 10, r 5, pv 0.1, op 5, or 0.5, opv 0.1, ig 20, cg 5` (`g1_teacher.yaml:67–78`)는 Table B와 같음. 그러나 `ig`와 `cg`는 D5·D6에서 보듯 **적용되지 않음**	부분 일치	D5, D6
D10	자세 사전 보상	논문에 없음	리타게팅 단계의 자세 사전 `exp(−20·mean((q − q_init)²))`는 **정지 단계에서만** 씀(w1)	추가(미기재)	`humanoid_g1.py:528, 743`
D11	교사 학습 데이터	OMOMO 데이터(V-A)	**공개 교사 가중치**는 README와 model card에 따르면 OMOMO 외에 **AMASS와 BONES-SEED를 추가로** 학습. 학습 코드는 OMOMO 설정을 따름	불일치(공개 가중치 한정)	`README.md` (Inference), `docs/teacher-model-card.md`
D12	관측과 행동 차원	교사 4052(Table D), 학생 1496(Table H), 행동 29, 잠재 64	교사 추론 가중치 설명: 입력 4052, 출력 29 (`teacher-model-card.md`). 배포 설명: 학생 입력 1496, 출력 29, 잠재 64 (`deploy.md`)	일치	`docs/teacher-model-card.md`, `docs/deploy.md`
D13	증류 손실의 prior-only 행동항	Table F (V): prior-only 행동 맞춤 손실 포함	계수 `prior_action_coeff = 0.0·(…)`으로 **항상 0**. 항은 계산하지만 손실에 기여하지 않음	불일치(코드에서 꺼짐)	`ultra_agent_distill_vae_rl.py:663, 683`
D14	KL, 평활, 보조 손실 일정	0.001→0.1 (KL), 0.0001→0.001 (평활), λ_E = λ_A = λ_G = 1, 에포크 500-3500 (Table F)	KL: `0.001 + 0.099·(1 − cos)/2`, 평활: `0.0001 + 0.0009·…`, 에포크 500-3500. 같음	일치	`ultra_agent_distill_vae_rl.py:657–667`
D15	RL 미세조정 손실	PPO는 배포용 학생(사전 분포만)에 적용, 크기는 "작은 상수", 액터는 "100 에포크 동안 점진 활성"(App. C)	RL 항에 **0.2** 배율. 액터 계수는 시작 후 100-200 에포크에 걸쳐 0에서 1로 올림. 학생 사전 분포만 쓰는지는 `UltraDistillObjV3RL`에서 확인 필요	일치(수치 추가)	`ultra_agent_distill_vae_rl.py:674, 688`

ID	주제	논문	코드	판정	근거
D16	점군 잡음	Table K: 가우시안 0.02 m, 점 누락 0.15, 이상점 0.05, 가림 0.1	설정: `pointNoiseStd: 0.02`, `pointDropoutProb: 0.15`, `pointOutlierProb: 0.05`, `pointOcclusionProb: 0.1`	일치	`g1_student_finetune.yaml:103–114`
D17	목표 성공 보너스	Table G: 성공 보너스	`goal_success_bonus: 10.0`	추가 (값 공개)	`g1_student_finetune.yaml:72`
D18	실물 배포	실물 G1 실험(V-E)	배포 스택이 저장소에 없음. 대신 `export_jit.py` (TorchScript, 원시 1496차원 관측 입력, 행동 ×3.0 PD 목표)와 MuJoCo 키보드 데모만 있음	불일치 (재현 불가)	`docs/deploy.md`, `ultra/export_jit.py`
D19	리타게팅 제어기	"이상적인 저수준 제어, 제어 주파수 = 시뮬 주파수"(IV-A)	설정은 `controlFrequencyInv: 17` (교사와 같음)이고 README는 "position target PD control"이라고 씀. 이상적 제어 여부는 확인 못함	불일치 (부분)	`g1_retarget_smplx.yaml:16`, `README.md` (stage 1)
D20	리타게팅 학습 길이	논문에 없음	"최대 50,000 에포크", 4096 환경	추가	`README.md` (stage 1)
D21	물체 종류	largebox, plasticbox, smallbox, suitcase (V-A)	같은 4종 + 크기 변형 `080_080_080`, `100_100_100`	일치	`ultra/data/assets/objects/`
D22	증강 (축별 스케일, 물체 크기)	재학습 없이 한 정책으로 적용 (IV-A)	`export_retarget_smplx.py --xyz X Y Z` (반복 지정)와 `--asset-scale`로 같은 정책을 실행	일치	`README.md` (stage 2)
D23	종료 조건 (접촉 불일치 20프레임)	"접촉 불일치 20프레임" (IV-A, [3])	종료 로직은 확인했으나 프레임 수는 줄 단위로 찾지 못함	확인 불가	—
D24	깊이 점군 추출 파이프라인	역투영, 전방 ROI, 바닥 제거, 최대 군집 (V-E)	학습 쪽은 점군 잡음만 있고 실물 추출 코드는 없음	불일치 (배포 스택에 있음)	`docs/deploy.md`

핵심 결론. 보상의 **구조**와 **일정**은 대부분 맞지만, **가중치 몇 개가 실제로 쓰이지 않고 몇몇 항이 논문에 없고 일부 논문 항이 0이거나 꺼져 있습니다.** 특히 D4(물체 위치 보상 0)와 D5·D6(표 B 가중치가 무효)은 논문의 "물체와 접촉 보존" 주장과 직접 관련됩니다. 저자가 실제로 쓴 설정이 논문의 표와 다르다는 뜻이므로, 재현할 때는 **코드를 기준으로** 해야 합니다.

3. 세부 확인

- **증강.** 논문은 증강을 "재학습 없이 한 정책으로"라고 씁니다(IV-A). 코드에서 `--xyz`와 `--asset-scale`로 같은 체크포인트를 재실행합니다(D22). 일치합니다.
- **교사 추론.** `run_teacher_inference.py`는 `isaacgym`을 임포트합니다. 반면 `sim2sim_teacher.py`는 `mujoco`, `rl_games`, `trimesh`를 씁니다. **MuJoCo 기반 교사 추론은 IsaacGym 없이 가능한 구조입니다**(확인은 실행하지 않음).
- **관측 빌더.** `ultra/utils/obs_vae.py`(`MujocoObs`)가 IsaacGym 밖의 학생 관측을 만듭니다. 학생 관측을 재구성하는 참조 구현으로 쓸 수 있습니다.
- **정규화.** 배포 문서는 학습 설정에서 `normalize_input: False`라고 씁니다. TorchScript 내보내기는 항등 정규화를 씁니다. 실행 중 정규화 통계는 없습니다.

4. 구현 가능성 판정

4.1 공식 재현 (학습 파이프라인 전체)

판정: 이 맥에서 불가능합니다.

- 학습은 IsaacGym Preview 4가 필요합니다(`docs/install.md`). IsaacGym은 NVIDIA GPU와 Linux를 전제로 합니다. 이 맥(Apple Silicon, CUDA 없음)에서는 실행할 수 없습니다.
- Python 3.8, CUDA 11.x, torch cu118을 쓰는 설치 절차입니다. `numpy<1.24`가 필요합니다.
- 단계별 필요 자원: 리타게팅 학습(최대 50,000 에포크, 4096 환경), 교사 학습, 증강 내보내기, 학생 증류(5500 에포크), RL 미세조정. 저장소에 소요 시간 기록은 없습니다. **단일 RTX급 GPU에서 수일에서 수주로 추정합니다**(근거 없는 추정).
- 데이터: OMOMO 준비본과 ULTRA 증강본을 Google Drive에서 받아야 합니다. OMOMO와 InterMimic 데이터 조건을 확인해야 합니다. AMASS와 BONES-SEED 조건은 공개 교사 가중치에만 해당합니다.

4.2 부분 재현 (이 맥에서 가능성 있음, 미검증)

- **교사 가중치의 MuJoCo 추론(sim2sim_teacher.py).** 구조상 IsaacGym이 필요 없어 보입니다. 이 맥에서 CPU로 한 모션을 돌려 보는 것은 **조건부로 가능할 수 있습니다.** 필요한 것: torch, rl_games==1.1.4, mujoco, trimesh 설치(사용자 승인 후), 모션 `.pt` 파일 1개(Google Drive), 교사 가중치(저장소에 있음). 실행 시간과 결과는 확인하지 않았습니다.
- 이것으로 얻는 것은 **교사의 추적 성능 일부**뿐입니다. 학생, 목표 추종, RL 미세조정, 실물은 검증하지 못합니다.
- 이 실험은 AMASS 또는 BONES-SEED로 학습된 가중치라는 점에서 논문의 교사와 다릅니다. 결과를 논문 Table I과 직접 비교하면 안 됩니다.

4.3 실물 재현

판정: 불가능합니다.

- 배포 스택(ROS 노드, G1 저수준, OptiTrack, 깊이 점군)이 저장소에 없습니다(D18).
- Unitree G1 실물, OptiTrack 시스템, 깊이 카메라, 가정용 상자 물체가 필요합니다. 현재 사용할 수 있는 환경에는 없습니다.
- 가장 가까운 대체: 시뮬 대 시뮬(MuJoCo)에서 학생 관측을 만들고 TorchScript로 내보내는 경로(`export_jit.py`)는 있습니다. 학생 가중치가 없으므로 이것도 학습이 먼저 필요합니다.

4.4 요약 표

수준	이 맥 (CPU, MPS, CUDA 없음)	필요한 것	판정
리타게팅·교사·학생 학습	불가	NVIDIA GPU, Linux, IsaacGym Preview 4, 데이터	**불가**
교사 MuJoCo 추론 (한 모션)	조건부	torch, rl_games, mujoco, trimesh, 모션 파일 1개	조건부(미검증)

수준	이 맥 (CPU, MPS, CUDA 없음)	필요한 것	판정
학생 추론과 TorchScript 내보내기	학생 가중치 없음	학생 학습 필요	불가(학습 선행)
목표 추종 (sim2sim)	학생 가중치 없음	학생 학습 필요	불가(학습 선행)
실물 G1	불가	G1, OptiTrack, 깊이 카메라, 배포 스택 직접 작성	**불가**

총평. 공식 코드는 **재현 경로가 열려 있지만**(Apache-2.0, 학습 스크립트, 교사 가중치) 학생 가중치가 빠져 있어 **표 I, III, IV의 핵심 결과를 저장소만으로 재현할 수 없습니다.** 이 맥에서는 교사 추론 일부만 조건부로 가능합니다.

5. 권리와 라이선스

- **논문.** arXiv 비독점 배포(nonexclusive-distrib 1.0)입니다. CC BY가 아닙니다. 원문 PDF에는 저작권 표시가 없고 arXiv 스탬프만 있습니다(1쪽, 확인함). 따라서 **논문 그림은 개인용 리포트와 PPT에만 씁니다.** 게시본에는 우리가 그린 그래프만 넣습니다.
- **코드.** 저장소 최상위 LICENSE는 Apache-2.0입니다. `LICENSE-InterMimic`은 InterMimic 파생 MIT이고, 일부 IsaacGym 예제 파일은 NVIDIA 헤더를 유지합니다.
- **교사 가중치.** 상위 Apache-2.0이 데이터 조건을 대체하지 않습니다. AMASS는 비상업 연구·교육으로 제한되고, BONES-SEED는 모델 배포 시 조건과 출처 표기가 필요합니다. 가중치는 비상업 연구·교육용으로 제공된다고 명시되어 있습니다(`docs/teacher-model-card.md`).
- **데이터.** OMOMO와 InterAct 준비본은 원 데이터 조건을 따릅니다. 이 분석에서 내려받지 않았습니다.
- **로봇 자산.** Unitree에서 왔습니다. 재배포 조건은 확인하지 않았습니다.

6. 열린 질문 (저자나 저장소에 물을 것)

1. 학생 가중치를 공개할 계획이 있는지.
2. 논문 Table I과 III의 학생 결과를 어떤 설정(D5, D6의 하드코딩 값, D13의 0 계수)으로 얻었는지. 공개 코드가 그 설정과 같은지.
3. 공개 교사 가중치가 AMASS와 BONES-SEED로 추가 학습된 뒤 논문 Table I의 교사 성능이 달라지는지.
4. 실물 배포 스택을 공개할 계획이 있는지.