Sparks of Weight-Space Programming: 분석 리포트

게시용 버전: 블로그 그림은 라이선스 표기가 없어 제외했습니다. 그래프는 공개 로그(CC BY 4.0)로 직접 그렸습니다. · Rikiya Takehi, Jayden Teoh, Alex Zhang, Omar Khattab (MIT CSAIL) · 블로그 글 2026-11-02, https://rikiyat.github.io/blog/weight-space-programming/ (arXiv 판 없음) · 공개 로그 RikiyaT/lm_understand-logs 커밋 4d09ba6 (로그·데이터·신경망 CC BY 4.0, 스크립트 MIT) · 분석일 2026-11-03 · 블로그 그림 © 저자, 라이선스 표기 없음(개인 학습용으로만 사용)

핵심 요약

1. **무엇을 주장하는가:** 범용 LLM(GPT-6 Astra)이 경사하강 없이 신경망 가중치를 직접 읽고(게임·모양·언어·복사 헤드 맞히기), 고치고(자동차 정책 0 → 100%, Qwen3.5-0.8B MATH-500 7.9 → 48.1%), 처음부터 쓴다(MinAtar, 148만 가중치 바둑). 저자들은 이를 Weight-Space Programming이라 부른다.
2. **수치는 모두 맞다:** 공개 로그(1,125턴, 평가 파일, 신경망)로 블로그의 모든 수치를 CPU에서 다시 계산해 일치를 확인했다. 실험 8의 50 pass 편집은 MATH-500 500문제 중 306개를 개선하고 0개를 악화시켰다(+40.2%p, 95% 구간 [36.9, 43.6]).
3. **읽기 실험 1·2는 얕은 구조다:** numpy로 첫 층을 접으면 Breakout 정책의 agent 가중치 97.4%가 맨 아래 행에, Pong은 96.5%가 왼쪽 열에 몰려 있다. DDPM 출력층은 모양의 변을 그대로 그린다. 가장 강한 읽기 결과는 실행 없이 복사 헤드 5개를 정확히 찾은 실험 3이다.
4. **"작은 편집"은 개수 기준이다:** 실험 4의 3.5%는 노름 기준 25.7배 변화이고(|w| ≤ 1인 층에 80-876을 넣은 조건부 덮어쓰기 경로), 실험 8의 0.016%는 반복(loop) 방향 하나를 지운 것이다. 실험 8 이득의 원천은 반복 제거다(상한 도달 93 → 33%).
5. **gradient는 없지만 피드백은 있다:** 실험 6·8은 최대 50번의 측정(연습 대국, 짝 비교)으로 후보를 고르는 탐색이다. 예산마다 실행이 1개이고, 공개 결과표에는 편집을 못 낸 다른 실행도 있다.
6. **빠진 기준선:** 시각화, Elhage식 composition 점수, Arditi식 방향 제거 스크립트, 디코딩 처방, 같은 측정 예산의 무작위 탐색과 비교하지 않았다. 이 글은 "기존 해석·설계 기법을 자연어 지시만으로 끝까지 수행하는 에이전트"의 증거로 읽는 것이 정확하다.

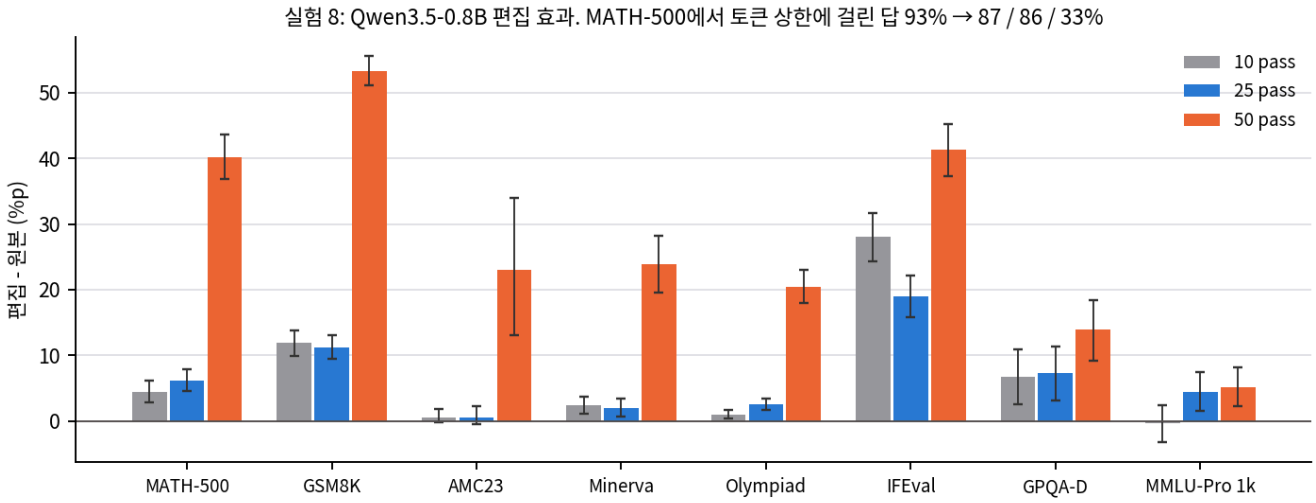


그림: 실험 8, 벤치마크별 편집 효과(문제 단위 짝 비교, 95% 부트스트랩 구간). 공개 로그로 직접 계산(`03` §6).

Sparks of Weight-Space Programming: 블로그 분석

- 원문: Rikiya Takehi*, Jayden Teoh*, Alex Zhang, Omar Khattab (MIT CSAIL), "Sparks of Weight-Space Programming: LLMs can natively read & write neural network weights", 블로그 글, 2026-11-02. https://rikiyat.github.io/blog/weight-space-programming/
- arXiv 판은 없습니다. 이 분석은 블로그 HTML(`paper/blog.html`, 2026-11-03 받음)과 그것을 Chrome으로 인쇄한 `paper/paper.pdf`(22쪽)를 원문으로 씁니다. 쪽 번호는 이 PDF 기준입니다.
- 공개 로그: https://github.com/RikiyaT/lm_understand-logs (커밋 `4d09ba6`, `logs_official/`에 clone). 모델에 보낸 프롬프트, 응답, 실행한 코드, 평가 파일, 신경망이 모두 들어 있습니다. 라이선스는 로그·데이터·신경망 CC BY 4.0, 스크립트 MIT입니다.
- 블로그 페이지 자체에는 라이선스 표기가 없습니다. 그래서 블로그 그림은 개인용 리포트·PPT에만 넣고, 게시본에는 로그로 직접 그린 그래프만 씁니다.
- "Astra"는 OpenAI의 `gpt-6-astra`이고, Codex CLI(`codex exec`)로 호출했습니다(로그 README).

1. Abstract: 무엇을 주장하는가

범용 LLM(GPT-6 Astra)이 신경망 가중치를 **직접 읽고 쓸 수 있다**고 주장합니다. 저자들은 이것을 Weight-Space Programming이라고 부릅니다. 최적화기(경사하강)를 거치지 않고, 자연어 목표에 맞춰 LLM이 추론으로 가중치를 고친다는 뜻입니다(p.3).

블로그는 실험 여덟 개를 세 묶음으로 나눕니다(p.4).

묶음	실험	한 줄 결과(블로그 주장)
읽기	1 게임 맞히기, 2 DDPM 모양 맞히기, 3 중간 블록만으로 언어·복사 헤드 맞히기, 7 아첨 모델 고르기	1-3은 모두 정답. 7은 가중치만으로는 실패, attention 패턴을 보여 주면 3쌍 모두 정답
고치기	4 Kinetix 자동차 정책 수정, 8 Qwen3.5-0.8B 수학 개선	4는 성공률 0% → 100%, 8은 MATH-500 7.9% → 48.1%
처음부터 쓰기	5 MinAtar 정책 세 개, 6 9x9 바둑 정책(148만 가중치)	5는 100M 스텝 PPO보다 높음, 6은 forward pass 50번이면 같은 크기 PPO를 이김

결론부(p.18-19)는 이를 근거로 평가 없는 감사(backdoor 탐지), 학습 비용 절감, 데이터 없는 능력 추가·삭제, 재귀적 자기 개선, 서로 다른 구조 사이의 회로 이식을 앞으로의 가능성으로 듭니다. 동료 심사를 거치지 않은 "초기 결과(very early results)"라고 스스로 밝힙니다(p.3).

2. Method: 실험을 어떻게 짰는가

2.1 공통 조건 (로그 README "How the model was run")

- 한 턴은 `codex exec` 호출 한 번입니다. Codex의 기본 도구(셸, 파일 편집, 웹 검색, 이미지 보기, 하위 에이전트)는 모두 껐습니다. 턴마다 이벤트 스트림을 검사해 `audit.tool_free`로 기록했고, 공개된 1,125개 턴이 모두 도구를 쓰지 않았다고 적혀 있습니다.
- 추론 강도는 실험 1·2·4가 `high`, 3·5·6·7이 `xhigh`, 8이 `max`입니다.
- 코드를 허용한 실험(3, 6, 7, 8)에서는 Astra가 Python 블록을 쓰면 하네스가 네트워크 없는 sandbox(bubblewrap)에서 돌리고 출력만 돌려줍니다. 무엇을 허용하는지는 각 실험 프롬프트에 적혀 있습니다.

2.2 실험별 조건

실험	대상 신경망	Astra가 받은 것	금지한 것	피드백
1	MLP 500-32-32-5 tanh(17,253개), PPO 10억 스텝, 자체 10x10 격자 게임 4종	가중치 전부(소수 3자리 텍스트), 입력 채널·행동 설명(게임 이름 없음)	도구 전부. 보기 목록도 주지 않음(열린 질문)	없음, 1회 답
2	DDPM MLP 160-64-64-144 ReLU(23,824개), 원·사각형·삼각형 각 1개	가중치 전부(텍스트), 노이즈 스케줄	도구, 머릿속 forward 계산	없음, 1회 답
3	문자 단위 Transformer 4층 x 6헤드, 폭 384(716만 개). 입력층·출력층 제거	네 블록 가중치(Python으로 읽음), 후보 텍스트 3종	네트워크나 어떤 층도 입력에 돌리기, 검색	자기 코드 실행 결과(최대 100회, 실제 6-11회)
4	Kinetix 공식 actor 679-128x6-16(171,664개), PPO 10억 스텝, 차가 경사로에서 멈춤(0/256)	가중치 전부(정수 x 스케일), 장면 설명, 실패 에피소드 1개 기록	도구, 두 번째 시도	없음, 1회 답
5	MinAtar 정책 600-32-32-6 tanh(20,486개), **모두 0에서 시작**	게임 규칙과 **MinAtar 소스 파일 원문**, 입출력 배치, 채점 방법	학습·데이터·도구, 환경 실행	없음, 1회 답
6	9x9 바둑 정책 243-512x6-82 ReLU(1,480,274개), 0에서 시작	규칙, Python sandbox(가중치 load/save), forward pass 예산 0·10·25·50	데이터 적합(경사·회귀·최소제곱), 탐색(트리·롤아웃), pass 밖에서 네트워크 실행	pass마다 연습 상대와 최대 128판 또는 256개 국면 출력
7	Gemma 3 270M 미세조정 쌍 3개(정직/아첨), 임베딩 고정	두 모델의 가중치·토크나이저, Python. 완화 조건에서는 attention 패턴 도구(직접 쓴 텍스트 16개까지)	모델 출력 보기, 직접 실행	가중치만: 없음. 완화: attention 가중치만
8	Qwen3.5-0.8B(thinking on)	가중치를 담은 Python 커널(CPU), GSM8K·MATH **학습 집합** 연습 문제, forward pass 10·25·50번	경사하강·학습, 커널 안에서 모델 실행, 임베딩·출력층·최종 norm 편집, 텐서 전체 상수배	pass마다 최대 512문제 생성(원본·편집 짝 비교 가능) 또는 1,024개 텍스트 teacher-forced 읽기

2.3 "Weight-Space Programming"의 실제 작동 방식

로그의 응답을 보면 Astra가 가중치를 다루는 방식은 실험마다 다릅니다.

- **읽기(1-3):** 층 하나를 격자나 그림으로 다시 접어서 구조를 찾습니다. 실험 1은 첫 층에서 agent 채널 가중치가 어디에 몰리는지(Breakout은 맨 아래 행, 패들)와 출력층이 어떤 행동을 구분하는지를 봅니다. 실험 2는 출력층의 은닉 단위마다 모양의 테두리 조각이 그려져 있는 것을 읽습니다(p.5-6). 실험 3은 1층의 "한 글자 앞" 헤드와, 행렬 곱으로 그 헤드와 K-composition하는 뒤 층 헤드를 찾습니다(p.8). 이것은 Elhage et al.(2021)의 composition 분석과 같은 방법이고, 블로그도 그렇게 적습니다.
- **고치기(4):** 기존 네트워크 일부 단위(층마다 몇 개)를 0으로 비운 뒤, 차체 x 위치·속도와 초록 바퀴 x 위치를 읽어 "후진 → 전속 전진 → 바퀴가 x = 0.95를 지나면 꺼짐"을 수행하는 별도 경로를 손으로 배선합니다(로그 `exp4_fix_car/README.md`).
- **쓰기(5-6):** 원하는 프로그램을 먼저 설계하고 신경망 형태로 바꿉니다. Breakout은 1층이 공의 낙하 지점을, 2층이 패들 이동을 계산합니다(p.11). 바둑은 1층이 돌과 활로(liberty), 중간층이 연결된 돌을 따라 위험한 무리, 마지막 층이 따내기·살리기·단수 피하기 점수를 계산합니다(p.13). forward pass가 있으면 연습 대국에서 지는 이유를 보고 해당 부분을 고쳐, 이기는 횟수가 늘 때만 바꾼 것을 유지합니다.

- **고치기(8):** 반복에 빠진 문맥과 정상 문맥에서 MLP 출력을 비교해 반복 방향을 찾고, 층 15와 19의 MLP `down_proj`에서 그 방향을 가장 많이 쓰는 출력 열 64개씩에서 그 방향 성분을 뺍니다(블로그 p.16, `exp8_math/runs/p50c/final_answer.md`). 방향 하나를 빼서 행동을 지우는 방법은 Arditi et al.(2024, 블로그 참고 문헌 14)의 refusal direction과 같은 계열입니다.

3. Experiments: 결과와 해석

수치는 모두 공개 로그에서 다시 계산해 맞는 것을 확인했습니다(`04_claim_verification.md`, `verify_logs.py`).

3.1 읽기

실험	결과	확인한 것
1	4/4 정답, 확신도 99/96/96/97%	정답 수, 파라미터 수 17,253 일치. Freeway는 "Frogger"로 답했고 채점기가 같은 게임으로 인정
2	3/3 정답, 확신도 84/77/88%	모두 테두리만 있는 모양으로 그렸지만, 실제 모델은 속이 찬 모양을 생성
3	6/6 대화에서 언어 정답, 복사 헤드(induct > 0.2) 정확히 맞힘	정답 확률은 0.48-0.62. 보기 3개가 주어진 문제라 균등 추측의 log loss는 1.10, Astra는 0.60
7	가중치만: 4번 모두 판단 못 함. attention 패턴 허용: 3/3	세 쌍 모두 맞힐 우연 확률 1/8

실험 3이 읽기 실험 중 가장 강한 증거입니다. 입력·출력층이 없어 어느 차원이 어느 글자인지 모르는 상태에서, 실행 없이 복사 헤드 다섯 개(세 모델 합)를 하나도 틀리지 않고 찾았습니다(`eval/heads.json`: 복사 헤드는 induct 0.22-0.55, 나머지는 모두 0.019 이하). 다만 언어 판정은 "복사 헤드가 많으면 코드"라는 간접 추론이고, 확률도 0.5 근처에 머뭅니다.

실험 1과 2는 정답이 4/4, 3/3이지만, 정보가 얕은 층에 크게 드러나 있습니다. numpy 몇 줄로 첫 층과 출력층을 접어 보면 Breakout 정책의 agent 채널 가중치 에너지 97.4%가 맨 아래 행(8행)에 몰려 있고, 출력층은 왼쪽·오른쪽 행동만 크게 구분합니다. Pong은 96.5%가 1열에 몰려 있고 위·아래 행동을 구분합니다. DDPM 출력층의 행을 12x12로 접으면 사각형은 가로·세로 변, 삼각형은 빗변, 원은 호가 그대로 보입니다(`03_analysis.md` §1, 그림 `exp1_agent_maps.png`, `exp2_output_units.png`). Astra가 한 일은 이 구조를 **텍스트 숫자 표만 보고** 찾아내 게임·모양 이름과 연결한 것입니다. 쉬운 일은 아니지만, "가중치 공간을 이해한다"는 일반적인 주장의 근거로는 약합니다.

실험 7은 블로그가 실패를 그대로 보고한 점이 좋습니다. 완화 조건의 attention 도구는 모델을 실제로 실행해 activation(attention 가중치)을 보는 것이므로, 가중치 읽기가 아니라 activation 기반 해석입니다.

3.2 고치기

실험 4 (Kinetix 자동차): 51개 편집 문장으로 1,024/1,024 성공(테스트), 256/256 성공(프롬프트에 준 에피소드 흐름)입니다. 바뀐 칸은 171,664개 중 6,073개(3.54%)입니다. 하지만 바뀐 크기는 매우 큽니다. 전체 가중치 노름 대비 변화량(Frobenius)은 25.7배이고, 원래 |w|가 1 이하이던 층에 80, 200, 876 같은 값을 넣었습니다(그림 `exp4_edit_size.png`). 원래 정책을 조금 고친 것이 아니라, 몇 개 단위를 비우고 그 자리에 크게 증폭한 손 설계 제어기를 넣고, 특정 조건에서 꺼지게 한 것입니다. 단 하나의 장면(`l/h2_car_ramp`)에서 1회 시도이고, 장면이 바뀌면(시작 위치, 경사로 길이) 어떻게 되는지는 평가하지 않았습니다.

실험 8 (Qwen3.5-0.8B 수학):

모델	MATH-500	GSM8K	IFEval	MATH-500 토큰 상한 도달
원본	7.9	13.8	21.0	93.0

모델	MATH-500	GSM8K	IFEval	MATH-500 토큰 상한 도달
10 pass	12.3	25.7	49.0	87.2
25 pass	14.1	25.1	39.9	86.4
50 pass	48.1	67.1	62.3	33.1

블로그 p.16 표와 같고, 로그의 `merged.json`과 문제별 파일로 다시 계산해도 같습니다. 50 pass 편집은 MATH-500 500문제 중 306문제를 개선하고 나빠진 문제는 0개입니다(문제별 4표본 평균 기준, 짝 부트스트랩 95% 구간 +36.9–+43.6%p).

해석에서 중요한 점이 세 가지 있습니다.

1. **이득은 반복(loop) 제거에서 나옵니다.** 원본은 thinking on, 32,768 토큰 상한에서 MATH-500 답의 93%가 상한에 걸립니다. 50 pass 편집 뒤에는 33%입니다. Astra 자신의 연습 문제 검증에서도 구조된 579개 중 576개가 원래 잘린 답이었고, 원래 끝까지 간 답의 정확도는 변하지 않았습니다(`runs/p50c/final_answer.md`). 블로그도 Gemma 3 270M 추가 실험에서 "가려진 능력을 꺼내는 것이지 없는 능력을 더하지는 않는다"고 인정합니다(p.17).
2. **"gradient 없음"은 맞지만 "피드백 없음"은 아닙니다.** 50 pass 실행은 158턴, 20.3시간 동안 연습 문제에 대한 원본·편집 짝 비교를 반복하며 후보를 고르고 버렸습니다(`requests/fwd_*.done.json`). LLM이 제안하고 측정으로 고르는 영차(zeroth-order) 탐색에 가깝습니다. 실험 6도 같습니다.
3. **실행 하나씩, 고른 결과입니다.** 예산마다 실행은 1개이고 10 → 25 → 50 pass가 단조롭지 않습니다(IFEval 49.0 → 39.9 → 62.3). 25 pass 편집은 층 15의 attention head 7 하나를 끈 것이고, 10 pass는 다른 방식(층 8–22의 30개 행렬에서 rank-1 제거)입니다. 공개된 결과표(`eval/RESULTS_excerpt.md`)에는 블로그에 없는 실행이 더 있습니다: 프롬프트 v2의 0 pass, v3의 5 pass, v4의 10 pass는 편집을 제출하지 않았고, v4의 25 pass는 14.1 / 25.1로 v3 25 pass와 같은 값이었습니다. 블로그는 이를 숨기지 않고 로그로 공개했지만, 본문 표만 보면 "pass를 늘리면 좋아진다"로 읽히기 쉽습니다.

3.3 처음부터 쓰기

실험 5 (MinAtar):

게임	PPO 100M	PPO 500M	Astra 1회
Breakout	15.8	25.3	517.4
Seaquest	5.6	88.9	53.1
Asterix	25.8	55.2	53.2

블로그 표는 각 칸에서 **최고 씨앗**입니다. 씨앗 사이 편차가 큽니다. Seaquest 500M은 씨앗 3개가 7.5 / 4.4 / 88.9이고, Breakout 100M은 씨앗 10개의 중앙값이 6.6입니다(그림 `exp5_seeds.png`). Breakout에서 Astra 네트워크는 평균 7,417 스텝을 버텨 에피소드 상한(10,000 스텝)에 가깝습니다. 공을 계속 받아 내는 규칙이 하나 있으면 점수가 거의 상한까지 오르는 게임이라, 517.4 대 25.3이라는 차이는 "PPO보다 20배 낫다"보다 "작은 PPO가 공 추적 규칙을 못 배웠다"에 가깝습니다. Astra는 게임 소스 코드를 받았으므로, 이 실험은 **알려진 규칙을 신경망 형태로 컴파일하는 능력**을 보여 줍니다. 그 자체로 인상적이지만, 학습을 대체하는 최적화 능력과는 다릅니다.

실험 6 (9x9 바둑): pass 0개로 작은 PPO 두 개에 54.1%, 54.9%(2,000판, 95% 구간 하한 52% 이상)이고, pass 50개로 84.0%, 80.8%입니다. 같은 크기 PPO(학습률을 조정한 씨앗 3개)와의 맞대결은 pass 0개에서 42.6 / 26.3 / 36.3%로 지고, pass 50개에서 74.2 / 70.0 / 78.5%로 이깁니다(그림 `exp6_budget.png`). 비교 대상 PPO는 20,000번 반복(2,050만 판)만 학습했고 탐색이 없는 정책망입니다. 바둑 규칙 코드를 작성하는 것은 허용되었으므로, 최종 네트워크는 Astra가 Python으로 쓴 바둑 휴리스틱을 층별로 옮긴 것에 pass 피드백으로 손본 결과입니다. 학습률을 조정하지 않은 같은 크기 PPO(lr 3e-4)는 Astra 네트워크에 92–98% 진다는 수치도 로그에 있는데, 블로그는 조정한 쪽(lr 3e-5)을 기준으로 보고했습니다. 이것은 공정한 선택입니다.

4. Limitations: 블로그가 인정한 것과 빠진 것

블로그가 인정한 한계(p.18):

- 컨텍스트 길이와 하네스의 비효율 때문에 능력이 아직 제한적입니다.
- 실험 7은 가중치만으로는 실패했고, Gemma 수학 실험도 개선하지 못했습니다(p.15, p.17).

분석하며 추가로 본 한계:

1. **실험마다 실행 수가 1-6개입니다.** 실험 1·2·4·5는 대상당 한 번, 실험 6·8은 예산마다 한 번입니다. 같은 프롬프트로 다시 돌렸을 때의 편차를 알 수 없습니다. 실험 8의 결과표는 다른 프롬프트 버전이 편집을 못 내기도 했음을 보여 줍니다.
2. **기준선이 "같은 정보를 가진 단순한 방법"이 아닙니다.** 실험 1·2는 numpy 통계로도 보이는 구조였고(§3.1), 실험 3의 복사 헤드는 Elhage et al.의 composition 점수로 자동으로 찾을 수 있습니다. 실험 8은 Arditi et al. 방식(반복 문맥과 정상 문맥의 activation 평균 차이로 방향을 구하고 지우기)을 스크립트로 돌린 기준선이나, 디코딩 쪽 처방(반복 패널티, 토큰 예산 조정, thinking 끄기)과 비교하지 않았습니다. LLM의 추론이 기존 해석·편집 기법을 넘어서는 무엇을 더하는지는 이 비교가 있어야 판단할 수 있습니다.
3. **비교 대상 PPO가 작고 편차가 큽니다.** 실험 5는 최고 씨앗과 비교해도 공정하지만, 32-32 MLP PPO가 이 게임들에서 약하다는 점이 큰 격차의 상당 부분을 설명합니다.
4. **편집의 "작음"은 개수 기준입니다.** 실험 4의 3.5%는 노름 기준으로 25.7배 변화이고, 실험 8의 0.016%(131,072개)는 두 텐서에서 각각 상대 변화 10.6%, 8.1%입니다. "catastrophic forgetting을 피한다"(p.19)는 주장은 MMLU-Pro·GPQA가 떨어지지 않은 실험 8에 대해서만 근거가 있습니다.
5. **사용한 모델이 공개 모델이 아닙니다.** `gpt-6-astra`의 다른 판이나 다른 회사 모델로 같은 결과가 나오는지는 확인할 수 없습니다. 로그는 완전하지만 같은 모델이 없으면 다시 실행할 수 없습니다.
6. **"범용 LLM이 그대로" 했다는 표현과 하네스 설계의 비중.** 실험 6·8은 상세한 하네스(pass 종류, 짝 비교 요약, 실험자 공지, "EXPLAIN EVERY STEP" 지시)를 거쳤고, 실험 8 프롬프트는 v3까지 바뀌었습니다. 결과는 모델 능력과 하네스 설계의 합입니다.

5. 한 문단 평가

로그가 매우 투명하다는 점이 이 글의 가장 큰 장점입니다. 블로그의 수치는 모두 공개 파일로 정확히 다시 계산됩니다. 가장 설득력 있는 결과는 실험 3(실행 없이 복사 헤드를 정확히 찾음)과 실험 8(작은 방향 편집으로 반복을 크게 줄임)입니다. 반면 "LLM이 가중치 공간을 이해한다"는 일반 주장은 아직 근거가 부족합니다. 읽기 실험 1·2는 얕은 층에 드러난 구조였고, 쓰기 실험 5·6은 알려진 규칙을 신경망으로 옮긴 것이며, 실험 4·8은 손 설계 경로 추가와 방향 제거라는 기존 기법의 범주입니다. 이 블로그는 "기존 해석·편집 기법을 자연어 지시만으로 끝까지 수행하는 에이전트"의 증거로 읽는 것이 정확합니다. 그 수준만으로도 연구 도구로서 쓸모가 큽니다.

수치 재계산과 해석

모든 수치는 공개 로그(`logs_official/` , CC BY 4.0)에서 CPU로 다시 계산했습니다. 스크립트는 `verify_logs.py` (→ `verify_logs_results.json`), `weight_reading_toy.py` (→ `weight_reading_toy_results.json`), `plot_figures.py` 입니다.

1. 읽기 실험이 얼마나 어려운가 (실험 1·2)

블로그와 같은 조건(forward pass 없음)으로, LLM 없이 numpy 몇 줄로 첫 층과 출력층을 접어 보았습니다.

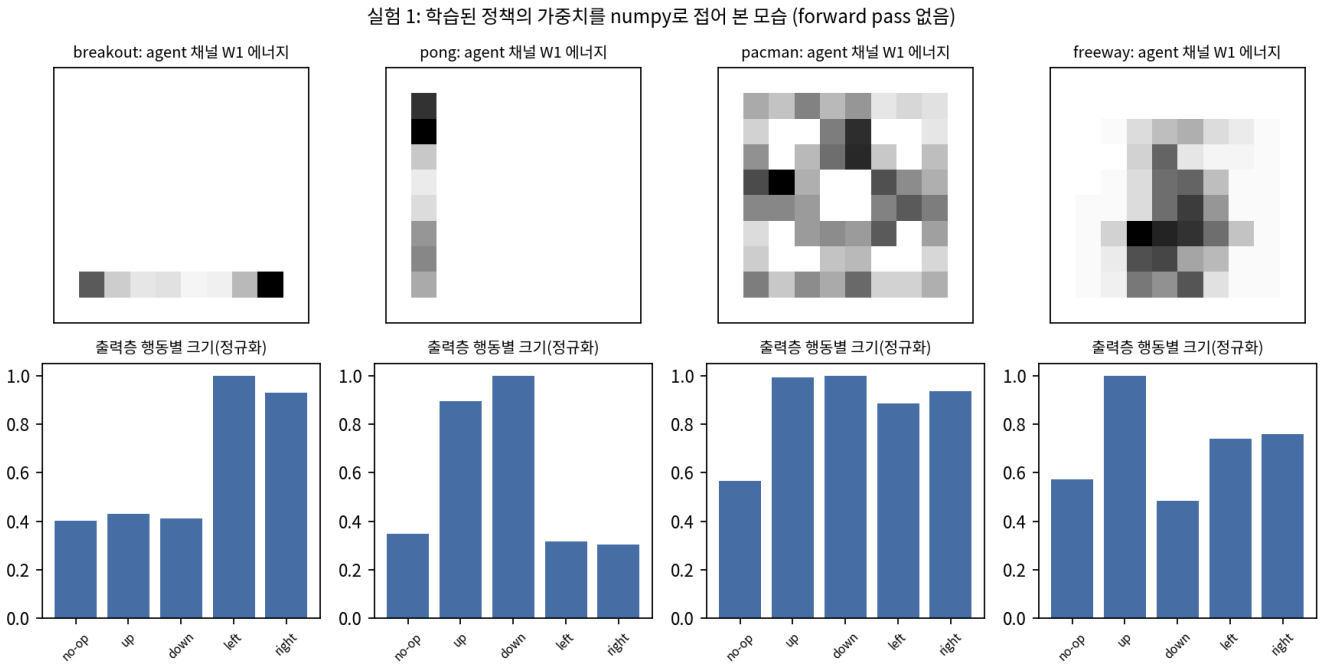


그림: 실험 1의 네 정책. 위는 첫 층 W1에서 agent 채널 가중치 제곱합을 10x10 칸으로 접은 것, 아래는 출력층 W3에서 행동별 평균을 뺀 열의 크기(최댓값으로 정규화). 직접 계산.

게임	agent 에너지가 가장 몰린 행·열(안쪽 8x8 기준 비율)	크게 구분하는 행동	Astra 답
Breakout	8행(맨 아래) 97.4%	left 1.00, right 0.93 (나머지 0.40-0.43)	Breakout 99%
Pong	1열(맨 왼쪽) 96.5%	down 1.00, up 0.90 (나머지 0.30-0.35)	Pong 96%
Pac-Man	고르게 퍼짐(최대 행 17.1%, 최대 열 16.4%)	네 방향 모두 0.89-1.00	Pac-Man 96%
Freeway	가운데 영역(최대 행 25.6%)	up 1.00, down 0.48	Frogger 97%

"패들이 맨 아래 행에서 좌우로 움직인다 → Breakout", "왼쪽 열에서 위아래로 움직인다 → Pong", "위로만 간다 → 길 건너기" 같은 추론은 이 표만으로 사람도 할 수 있습니다. Astra가 이 판단을 17,253개 숫자 텍스트만 보고, 도구 없이 해냈다는 점은 인상적입니다. 하지만 정보는 첫 층과 마지막 층에 거의 그대로 드러나 있습니다. 블로그도 실험 3 서두에서 "앞의 두 실험은 첫 층이나 마지막 층만 읽어도 풀 수 있었다"고 인정합니다(p.6).

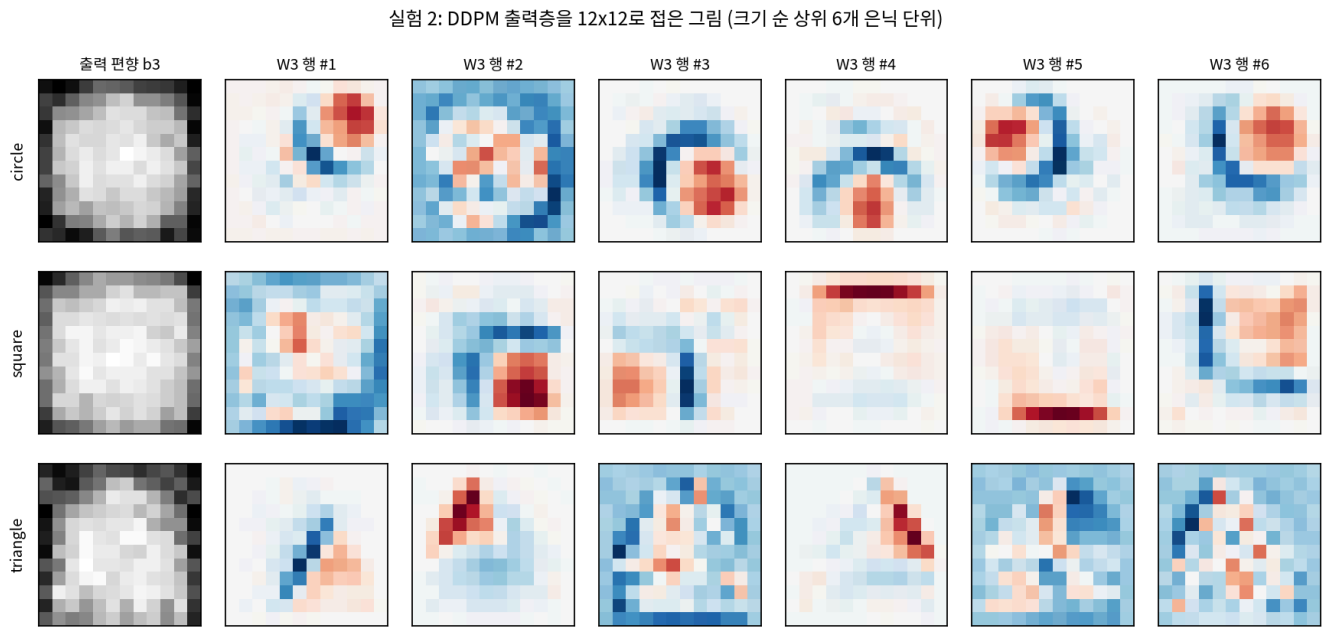


그림: 실험 2의 세 DDPM. 출력 편향 b3와, 노름이 큰 은닉 단위 6개의 출력 가중치를 12x12로 접은 것. 사각형은 가로·세로 변, 삼각형은 빗변, 원은 호가 보인다. 직접 계산.

출력 편향만 봐도 삼각형은 위쪽 폭이 좁습니다(편향이 평균보다 큰 칸 수: 위 세 행 평균 2.67, 아래 세 행 평균 7.0). 원과 사각형은 편향만으로는 덜 구분되지만(위 4.0 대 아래 3.67, 위 5.0 대 아래 3.33), 출력 단위의 그림에서는 직선 변과 호가 뚜렷합니다. Astra가 테두리만 그린 이유도 이 그림으로 설명됩니다. 각 출력 단위가 테두리 조각을 그리고 속을 채우는 것은 편향(넓은 덩어리)이 맡는데, Astra는 단위들만 읽었습니다.

결론: 실험 1·2는 "가중치를 텍스트로만 받아도 얕은 구조를 찾는다"는 증거입니다. 깊은 계산을 이해한다는 증거는 실험 3에서 나와야 합니다.

2. 실험 3: 확률의 크기와 복사 헤드 기준

항목	값
정답 언어에 준 확률(대화 6개)	0.56, 0.52, 0.55, 0.62, 0.58, 0.48 (평균 0.55)
log loss	0.60 (균등 추측 ln 3 = 1.10)
복사 헤드, induct > 0.2	Python 2.1, 3.1, 3.5 / romaji 3.3 / English 3.1 (다른 헤드는 모두 0.019 이하)
복사 헤드, induct > 0.3(채점 스크립트 기본값)	Python 3.5 / romaji 없음 / English 3.1

언어 판정은 맞았지만 확신이 크지 않습니다. 보기 3개 중 정답에 평균 0.55를 줬습니다. 복사 헤드 쪽이 더 강한 결과입니다. 0.2 기준에서 다섯 헤드를 모두 맞혔고 다른 헤드는 하나도 복사 헤드로 부르지 않았습니다. 0.2와 0.3 사이에 헤드가 없고, 복사 헤드가 아닌 헤드는 모두 0.02 이하라서 기준을 어디에 두든 Astra의 지목은 "실제로 induction 점수가 높은 헤드"와 일치합니다. 로그 README가 0.3 기준 필드(`true_copy_heads`)와 블로그의 0.2 기준이 다르다는 점을 스스로 밝혀 둔 것도 확인했습니다.

3. 실험 4: "3.5%"의 크기

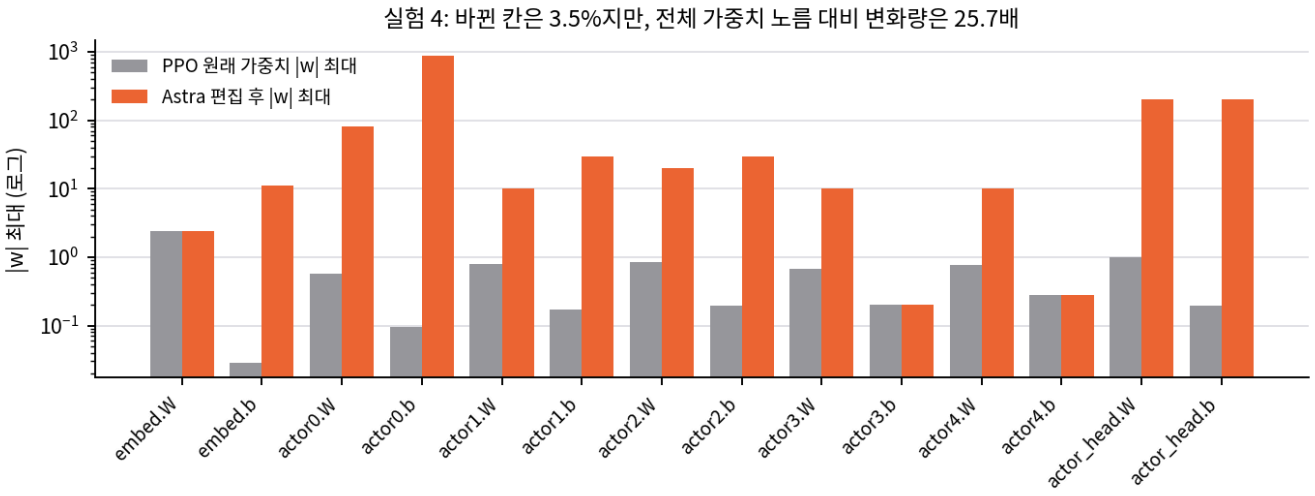


그림: 텐서별 |w| 최댓값, 원래 PPO(회색)와 Astra 편집 후(주황). 로그 축. 직접 계산.

- 바뀐 칸: 6,073 / 171,664 = 3.54% (`eval/oneshot_result.json`과 일치).
- 변화량 노름 / 원래 노름(Frobenius, 14개 텐서 전체): **25.7배**. 로그의 `rel_change` 25.66과 일치합니다.
- 텐서별로 actor0.b는 원래 노름의 3,737배, actor_head.b는 938배, actor_head.W는 55배입니다. 원래 |w| ≤ 1인 층에 80(actor0.W), 200(actor_head.W), 876(actor0.b)을 넣었습니다.

편집은 tanh 단위를 포화시켜 if-then 스위치로 쓰는 손 설계 제어기입니다. 출력층에 ±200을 넣으면 특정 조건에서 해당 행동의 확률이 1에 가까워집니다. 원래 정책은 그 조건이 꺼진 뒤에만 영향이 있습니다. 이 방식은 해석 가능하고 정확하지만, "기존 정책을 조금 고쳤다"보다 "조건부로 덮어쓰는 모듈을 붙였다"가 정확한 설명입니다.

4. 실험 5: 씨앗 편차와 에피소드 상한

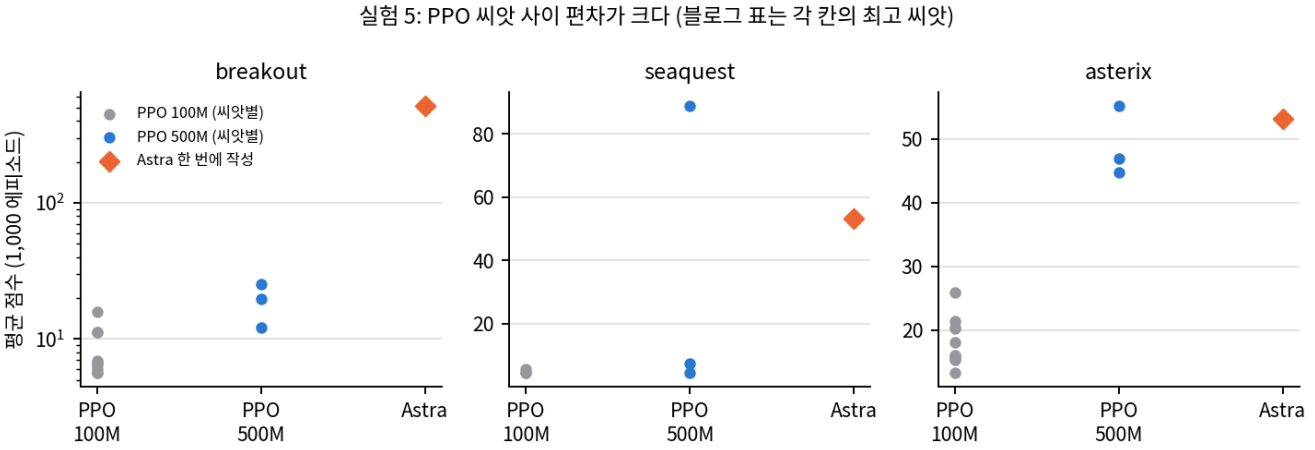


그림: 게임별 PPO 씨앗 점수(회색 100M, 파랑 500M)와 Astra가 한 번에 쓴 네트워크(주황). Breakout은 로그 축. 직접 계산.

게임	PPO 100M 최고 / 중앙값(씨앗 수)	PPO 500M 최고 / 중앙값(씨앗 3)	Astra	Astra 평균 에피소드 길이
Breakout	15.8 / 6.6 (10)	25.3 / 19.8	517.4 ± 7.4	7,417 스텝(상한 10,000의 74%)
Seaquest	5.6 / 4.4 (3)	88.9 / 7.5	53.1 ± 1.4	1,412
Asterix	25.8 / 17.1 (10)	55.2 / 46.9	53.2 ± 1.0	858

- Breakout의 큰 차이는 에피소드 상한의 영향이 큽니다. 공을 계속 받아 내면 점수는 시간에 비례해 오르고, Astra 네트워크는 대부분의 에피소드를 상한 근처까지 끌고 갑니다. 최고 PPO는 평균 282 스텝에서 끝납니다.
- Seaquest는 PPO 500M 씨앗 하나(88.9)만 높고 나머지 둘은 7.5, 4.4입니다. 중앙값과 비교하면 Astra(53.1)가 7배 높고, 최고 씨앗과 비교하면 60%입니다. 블로그는 최고 씨앗과 비교해 "60%"라고 보수적으로 보고했습니다.
- Astra 네트워크의 0이 아닌 가중치는 815 / 803 / 637개(20,486개 중 3-4%)입니다. 희소한 손 설계 회로라는 뜻입니다.

5. 실험 6: 피드백의 효과

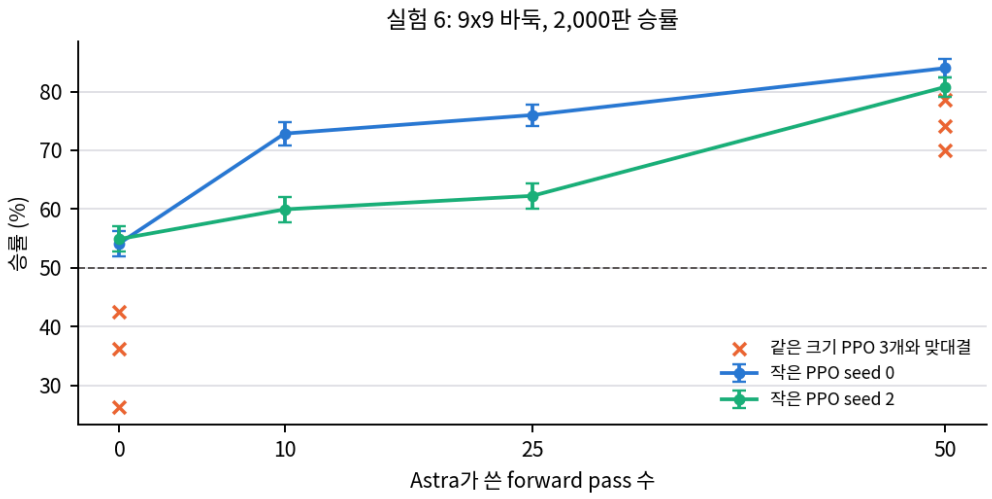


그림: forward pass 예산별 승률(2,000판, Wilson 95% 구간)과 같은 크기 PPO 세 씨앗과의 맞대결(x 표시). 직접 계산.

예산	작은 PPO seed 0	작은 PPO seed 2	같은 크기 PPO 3개 맞대결
0	54.1% [52.0, 56.3]	54.9% [52.7, 57.1]	42.6 / 26.3 / 36.3%
10	72.9% [70.9, 74.8]	60.0% [57.8, 62.1]	-
25	76.0% [74.1, 77.8]	62.3% [60.1, 64.4]	-
50	84.0% [82.3, 85.5]	80.8% [79.0, 82.5]	74.2 / 70.0 / 78.5%

- pass 0개 네트워크도 무작위 상대와 REINFORCE 상대에게는 98.8-99.7%를 이깁니다. 바둑 규칙을 아는 휴리스틱으로서는 이미 동작합니다.
- 같은 크기 PPO를 이기려면 pass 50번(연습 대국 47번 + 국면 분석 3번, 대국당 최대 128판)이 필요했습니다. 연습 상대 "strong"은 PPO 씨앗 1이고, 채점 상대는 씨앗 0·2라서 상대 자체는 분리되어 있습니다. 하지만 같은 학습 절차의 씨앗이므로 약점이 겹칠 수 있습니다. 블로그의 "same-size PPO를 이긴다"는 이 범위에서의 결과입니다.
- 예산마다 실행이 1개라 10 → 25 구간의 작은 증가가 의미 있는지는 판단할 수 없습니다.

6. 실험 8: 무엇이 좋아졌는가

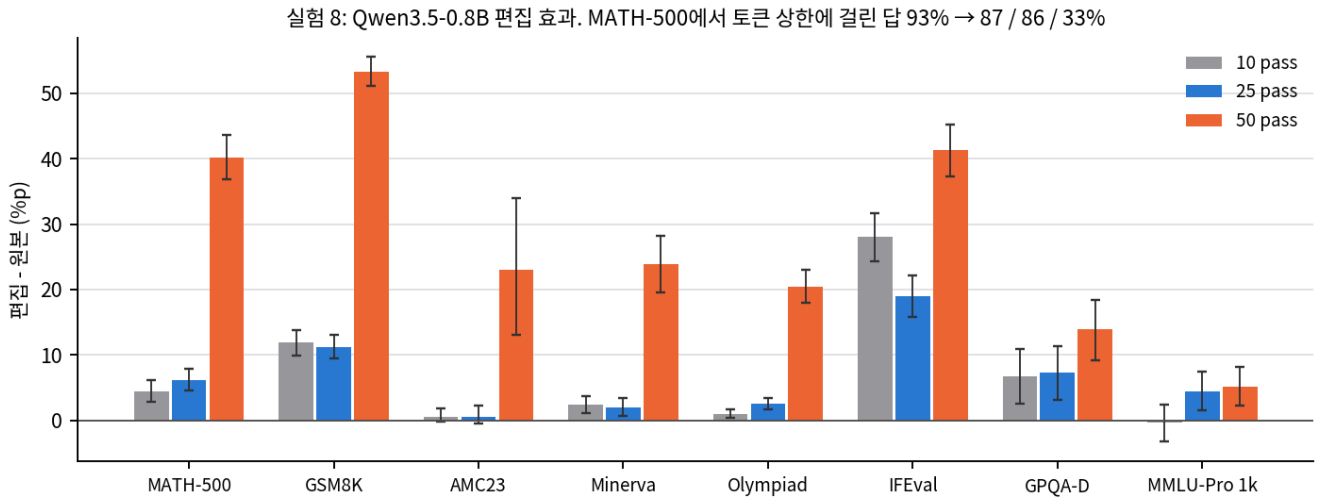


그림: 벤치마크별 (편집 - 원본) 정확도 차이와 문제 단위 짝 부트스트랩 95% 구간. 직접 계산.

6.1 문제 단위 짝 비교

벤치마크	10 pass	25 pass	50 pass
MATH-500	+4.5 [2.8, 6.2]	+6.2 [4.6, 7.9]	**+40.2 [36.9, 43.6]**, 개선 306 / 악화 0
GSM8K	+11.9 [9.9, 13.8]	+11.2 [9.5, 13.0]	**+53.3 [51.0, 55.5]**, 개선 916 / 악화 4
AMC23	+0.6 [-0.2, 1.9]	+0.6 [-0.5, 2.3]	+23.0 [13.1, 33.9]
Minerva	+2.4 [1.1, 3.8]	+2.0 [0.6, 3.5]	+23.9 [19.6, 28.2]
OlympiadBench	+1.0 [0.4, 1.7]	+2.6 [1.7, 3.5]	+20.5 [18.0, 23.0]
IFEval	+28.0 [24.3, 31.7]	+19.0 [15.8, 22.2]	+41.3 [37.3, 45.2]
GPQA Diamond	+6.7 [2.5, 11.0]	+7.3 [3.2, 11.4]	+13.9 [9.2, 18.4]
MMLU-Pro 1k	-0.3 [-3.2, 2.5]	+4.4 [1.5, 7.4]	+5.2 [2.3, 8.2]

(%p, 괄호는 95% 구간. MMLU-Pro는 1표본이라 구간이 넓습니다.)

50 pass 편집의 효과는 통계적으로 매우 분명합니다. MATH-500에서 나빠진 문제가 하나도 없다는 점이 특히 눈에 띕니다. 반복을 줄이는 편집이 "끝까지 가지 못하던 풀이를 끝까지 가게 할 뿐, 원래 맞히던 풀이를 망가뜨리지 않는다"는 해석과 맞습니다.

6.2 이득이 어디서 오는가

- MATH-500에서 토큰 상한(32,768)에 걸린 답의 비율: 원본 93.0% → 10 pass 87.2% → 25 pass 86.4% → 50 pass 33.1%.
- 정확도가 크게 오른 것은 상한 비율이 크게 줄어든 50 pass뿐입니다. 10·25 pass는 상한 비율이 6-7%p 줄고 정확도도 4-6%p 올랐습니다.
- Astra의 연습 문제 검증(1,152문제)에서 구조된 579개 중 576개가 원래 잘린 답이었습니다 (`runs/p50c/final_answer.md`).
- 반복이 거의 없는 Gemma 3 270M(상한 도달 8.5%)에서는 편집 네 개가 엄격 채점 기준 -0.15 - +1.0%p였고, 25 pass 하나만 구간이 0을 살짝 넘었습니다([+0.2, +1.85]). 블로그의 결론("가려진 능력을 꺼낼 뿐 없는 능력은 못 더한다", p.17)과 맞습니다.

6.3 기준선에 대한 질문

원본의 7.9%는 thinking on, 32,768 토큰, presence penalty 1.5라는 특정 설정에서의 값이고, 이 설정에서 모델이 반복에 빠진다는 것은 Qwen 모델 카드도 경고합니다(블로그 p.16). 따라서 이 결과는 "수학 능력 향상"보다 "알려진 실패 모드의 정밀한 제거"로 읽어야 합니다. 같은 문제를 푸는 더 단순한 방법들(반복 패널티 조정, thinking 끄기, 토큰 예산과 강제 종료, Arditi식 평균 차이 방향 제거를 스크립트로 수행)이 어디까지 따라오는지가 다음 비교 대상입니다. 로그에는 이 기준선이 없습니다.

6.4 실행 선택

공개된 결과표(`eval/RESULTS_excerpt.md`)에 있는 Qwen 편집 실행:

실행	MATH-500	블로그
v2, 0 pass	7.9 (편집 없음)	없음
v3, 5 pass	7.9 (편집 미제출)	없음
v3, 10 / 25 / 50 pass	12.3 / 14.1 / 48.1	보고
v4, 10 pass	7.9 (편집 미제출)	없음
v4, 25 pass	14.1	없음
v5, 5-50 pass	미완(…)	없음

값이 있는 실행 중 큰 이득(48.1)은 하나뿐이고, 같은 예산의 다른 실행이 없어 재현성을 판단할 수 없습니다. 저자들은 이 표를 그대로 공개해서 판단할 근거를 남겼습니다.

7. 실험별로 LLM이 더한 것

실험	정보가 있는 곳	기존 기법으로 되는가	LLM이 더한 것
1	첫 층·출력층	시각화로 보임(§1)	텍스트에서 구조를 찾고 세계 지식(게임 이름)과 연결
2	출력층	시각화로 보임(§1)	같음
3	층 사이 composition	Elhage식 점수	해당 분석을 스스로 고르고 수행, 언어 판정까지 추론
4	장면 설명 + 정책	손 설계 제어기 + 전환	실패 진단과 배선을 한 번에, 도구 없이
5	게임 소스	휴리스틱을 Tracr식으로 컴파일	휴리스틱 설계와 컴파일을 한 번에, 도구 없이
6	규칙 + 대국 피드백	휴리스틱 + 측정 기반 탐색	같은 일을 148만 가중치 규모에서 수행
7	attention 패턴	activation 비교	탐침 텍스트 설계
8	activation + 측정	방향 제거, 디코딩 처방	실패 모드 발견, 위치 특정, 대조군 설계, 측정 기반 선택

공통점은 **기존 해석·설계 기법의 선택과 실행을 자연어 지시만으로 끝까지 수행한다**는 것입니다. 새 종류의 능력이라기보다 연구자가 하던 일련의 작업을 자동화한 것에 가깝고, 그 자체로 실용적 가치가 큽니다.

추가 검증 (2026-11-11)

추가 검증 1: 블록 가중치만으로 K-composition 점수를 계산해 복사 헤드를 찾을 수 있는가

목적. 실험 3에서 Astra는 실행 없이 가중치만 읽어 복사 헤드 5개를 맞혔습니다(§2). 같은 일을 표준 기법인 K-composition 점수(Elhage et al., 2021)로 자동화할 수 있는지 봅니다. 점수가 높은 헤드가 실행으로 측정한 복사(induction) 헤드와 맞으면 "가

중치 읽기"가 기존 기법으로도 된다는 뜻이고, 안 맞으면 그 읽기는 기존 기법으로 대체되지 않는다는 뜻입니다.

데이터. 블록 가중치 `networks/{python,romaji,english}/blocks.npz` 세 개와 정답 `eval/heads.json`, `eval/scores.json`, `eval/key.json`, 설명 `README.md`를 공개 로그 커밋 `4d09ba6`에서 받았습니다 (`raw.githubusercontent.com`, 로그 전체 367 MB 대신 필요한 파일만). 크기는 blocks.npz 세 개가 각 28.3 MB(합 84.9 MB), 나머지 JSON과 README는 합 25 KB입니다. 라이선스는 CC BY 4.0입니다(02_prior_work.md §5). Git blob SHA1로 받은 파일이 커밋과 일치함을 확인했습니다. 원본 파일은 `data/` (git 제외)에 있습니다.

설정.

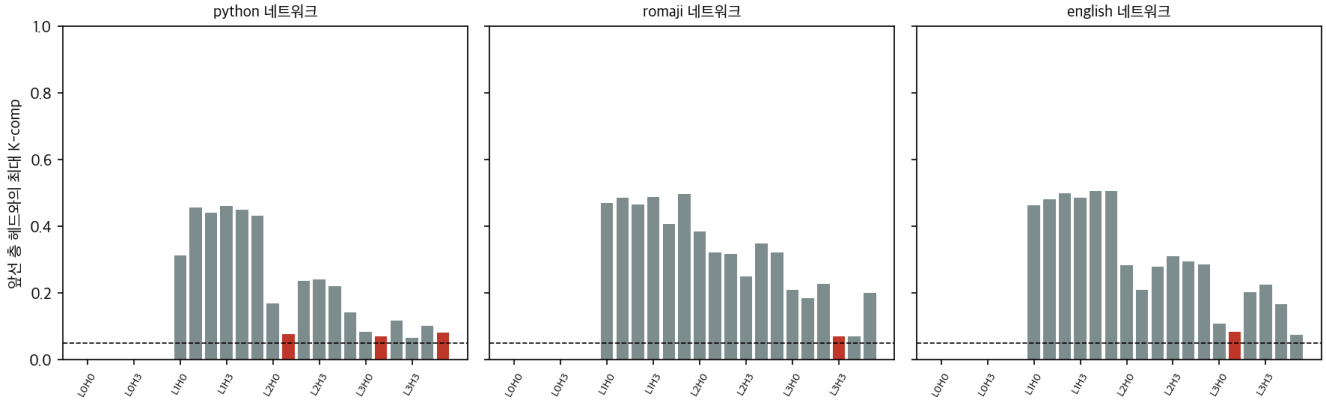
- 가중치 규약은 README에 따라 (출력, 입력) 순서이며, 헤드 h는 각 행렬의 64행 또는 64열 블록입니다.
- 헤드 h2의 K 입력 행렬 W_K^{h2}와 헤드 h1의 OV 행렬 W_V^{h1}W_O^{h1}(384×384)로 점수 ‖ W_OV^{h1} W_K^{h2} ‖_F / (‖ W_OV^{h1} ‖_F ‖ W_K^{h2} ‖_F)를 계산합니다. 층 l1 < l2인 모든 쌍을 봅니다.
- LayerNorm 이득(gamma)은 W_K 앞에 곱하고, 평균 제거는 투영 행렬로 넣었습니다. 편향(beta)은 무시했습니다.
- forward pass는 하지 않습니다. 입력층(임베딩)이 blocks.npz에 없어서 토큰 수준의 해석은 하지 않았습니다.
- 무작위 기준선은 같은 형태의 가우시안 행렬 200쌍으로 잡았습니다(seed 0).
- 평가 대상은 층 1-3의 헤드 54개입니다(층 0 헤드는 앞선 층이 없어 점수를 정의할 수 없음). 정답은 `induct > 0.2`인 복사 헤드 5개이고, 평가 지표는 AUC와 상위 5개 정밀도입니다.
- 스크립트 `analysis/extra_kcomp.py` → `analysis/extra_kcomp_results.json`, 그림 `report/figures/extra_kcomp_heads.png`. numpy 4스레드, 실행 0.7 s(다운로드 제외).
- 합성 검사: 시뮬레이션 두 헤드에서 K 입력을 OV의 쓰기 부분공간에 맞추면 점수가 무작위보다 뚜렷이 높고(0.125 대 0.051), 직교 부분공간에서는 0.002로 떨어져 방향이 맞게 계산됨을 확인했습니다.

결과.

- 무작위 기준선은 평균 0.051(표준편차 0.0006, 95% 분위 0.052)입니다.
- 정답 복사 헤드의 앞선 층과의 최대 점수는 모두 기준선 근처입니다. python L2H1 0.078, python L3H1 0.070, python L3H5 0.080, romaji L3H3 0.069, english L3H1 0.084.
- 층 1 헤드는 0.31-0.51로 높고, 이 점수들은 주로 층 0 헤드 L0H4·L0H5와 맺어집니다.
- 상위 5개(english L1H5 0.507, english L1H4 0.506, english L1H2 0.500, romaji L1H5 0.498, romaji L1H3 0.488)는 모두 정답이 아닙니다.
- 평가: AUC 0.049(정답 복사 헤드가 나머지보다 낮은 점수를 받음), 상위 5개 정밀도 0.0, 재현율 0.0.
- 실행으로 측정한 python L0H5(`prev` 0.649)와 python 복사 헤드의 K-comp는 0.078-0.080으로 기준선 수준입니다. 이전 토큰 헤드의 출력이 복사 헤드의 K 입력으로 직접 흐른다는 가중치 증거는 나오지 않았습니다.

결론. 표준 K-composition 점수만으로는 실험 3의 복사 헤드가 찾아지지 않습니다. 따라서 Astra의 가중치 읽기는 이 점수로 대체되지 않으며, 단순한 자동화로 같은 답을 얻은 것은 아닙니다. 이 결과는 §2의 "실행 없이 복사 헤드 5개를 정확히 찾은 것이 가장 강한 읽기 결과"라는 판단과 맞습니다. 다만 Astra가 무엇을 근거로 맞혔는지는 이 검사로 밝혀지지 않습니다.

그림. 네트워크별 헤드의 앞선 층과의 최대 K-comp(빨간 막대는 정답 복사 헤드, 점선은 무작위 기준선).



한계.

- 임베딩과 출력층이 없어서 OV의 토큰 수준 해석과 이전 토큰 헤드의 확인(가중치만으로는 판별 불가)은 하지 않았습니다. 정답 라벨만 사용했습니다.
- 복사 헤드가 Q 쪽으로 이전 토큰 정보를 읽는 경로라면 K-comp로는 잡히지 않을 수 있습니다. Q-comp나 V-comp는 계산하지 않았습니다.
- 편향(beta)과 잔차 흐름의 다른 기여는 무시했습니다.
- 헤드 5개, 네트워크 3개의 작은 표본이라 AUC는 불확실성이 큽니다. 같은 구조의 다른 씨앗 없이 일반화할 수 없습니다.

주장 검증

공식 "코드"는 하네스가 비공개라 코드 대조 대신 **공개 로그의 평가 파일로 블로그 수치를 다시 계산**했습니다 (`verify_logs.py` → `verify_logs_results.json`). 판정은 "맞음"(파일과 정확히 일치), "맞음, 단서"(수치는 맞지만 해석에 조건이 필요), "근거 부족"으로 나눕니다.

1. 주장별 판정

#	블로그 주장 (쪽)	다시 계산한 값	판정
C1	네트워크 크기 17,253 / 23,824 / 171,664 / 1,480,274 (p.5-13)	층 구조로 계산해 모두 일치(실험 5는 20,486)	맞음
C2	실험 1 네 게임 모두 정답, 실험 2 세 모양 모두 정답 (p.5-6)	`scores.json` 4/4, 3/3	맞음, 단서: 정보가 첫 층·출력층에 그대로 드러남(`03` §1). Freeway는 "Frogger"로 답한 것을 정답 처리
C3	실험 3 세 언어 모두 두 번씩 정답, 복사 헤드를 모두 찾고 다른 헤드는 지목하지 않음 (p.7)	6/6, 복사 헤드 5/5(induct > 0.2), 오지목 0	맞음, 단서: 보기 3개 중 고르는 문제이고 정답 확률 평균 0.55
C4	실험 4 한 번의 편집으로 1,024 에피소드 모두 성공, 가중치 3.5% 변경 (p.9)	1,024/1,024, 6,073/171,664 = 3.54%	맞음, 단서: 노름 기준 변화 25.7배, 한 장면에서만 평가(`03` §3)
C5	실험 5 세 게임 모두 PPO 100M을 이김, 500M 대비 Breakout 20배·Asterix 근접·Seaquest 60% (p.10)	517.4/25.3 = 20.4배, 53.2/55.2 = 96%, 53.1/88.9 = 60%	맞음, 단서: 최고 씨앗과 비교. Breakout은 에피소드 상한 영향(`03` §4)
C6	실험 6 pass 0개로 작은 PPO 둘에게 과반 승리, pass 50개로 같은 크기 PPO를 이김 (p.12)	54.1%, 54.9% (95% 구간 하한 52.0%, 52.7%); 74.2 / 70.0 / 78.5%	맞음
C7	실험 7 가중치만으로는 4번 모두 실패, attention 도구로 3쌍 모두 정답 (p.14)	3/3, 우연 확률 1/8	맞음, 단서: attention 도구는 모델 실행이라 가중치 읽기가 아님
C8	실험 8 MATH-500 7.9 → 48.1, GSM8K 13.8 → 67.1, IFEval 21.0 → 62.3, 상한 도달 93 → 33% (p.16)	문제별 파일로 다시 계산해 모두 일치. 짝 차이 +40.2%p [36.9, 43.6]	맞음
C9	실험 8 편집은 0.8B 가중치 중 131,072개(0.016%) (p.16)	2 텐서 x 64 열 x 1,024 = 131,072, 0.0164%. bf16 반올림 뒤 실제로 달라진 값은 130,188개	맞음
C10	실험 8 "without gradients" (p.1, p.15)	경사·학습은 없음. 50 pass 실행은 원본·편집 짝 비교 측정을 반복하며 후보를 선택	맞음, 단서: 측정 피드백 기반 탐색. 블로그 p.1의 "without any environment feedback"은 실험 5에만 해당
C11	실험 8 이득이 수학 밖(IFEval)으로 일반화 (p.16)	IFEval +41.3%p, GPQA +13.9%p, MMLU-Pro +5.2%p	맞음, 단서: 반복 제거라 일반화가 자연스러움(IFEval은 `</think>` 뒤 답을 채점하므로 생각이 끝나야 점수가 남)
C12	편집이 소수 가중치만 건드려 catastrophic forgetting을 피할 수 있다 (p.19)	실험 8에서 MMLU-Pro·GPQA가 떨어지지 않음. 실험 4는 노름 기준 큰 편집	근거 부족: 일반 주장으로는 실험 하나뿐

#	블로그 주장 (쪽)	다시 계산한 값	판정
C13	LLM이 사람이나 기존 알고리즘의 기대를 훨씬 넘어선다 (p.1 TL;DR)	단순 기준선(시각화, composition 점수, 방향 제거 스크립트, 디코딩 처방)과의 비교 없음(`02` §2)	근거 부족
C14	각 결과의 재현성	예산·대상마다 실행 1개(실험 3은 2개). 실험 8에서 블로그에 없는 실행 4개(v2 0 pass, v3 5 pass, v4 10·25 pass) 중 편집을 낸 것은 1개(v4 25 pass, 14.1)	판단 불가

2. 재현 정보 체크리스트

항목	공개 여부
모델에 보낸 프롬프트와 응답 전체	공개(1,125턴, 도구 사용 감사 포함)
실행한 코드와 출력	공개(`tool_calls.jsonl`)
평가 파일(문제별 결과)	공개. GPQA 문제 원문만 제외
읽거나 쓴 신경망	공개. 실험 7의 미세조정 모델(17 GB)은 학습 스크립트와 해시만
실험 8 편집	공개. 공개 Qwen 가중치에 대한 정확한 diff와 적용 스크립트(`code/apply_edit.py`)
하네스 코드(프롬프트 서버, forward pass 서버)	비공개. 규칙은 프롬프트에 적혀 있음
PPO 기준선 체크포인트(실험 5)	비공개. 결과만
사용한 LLM(`gpt-6-astra`)	상용 API. 같은 판을 계속 쓸 수 있는지 알 수 없음

3. 구현 가능성

- **블로그 수치 재현:** 평가 쪽은 가능합니다. 실험 8의 편집 diff를 공개 Qwen3.5-0.8B에 적용하면 평가 모델을 비트 단위로 다시 만들 수 있다고 로그 README가 적고 있습니다. 다만 MATH-500을 thinking on, 32,768 토큰, 4표본으로 다시 평가하려면 GPU와 vLLM이 필요합니다. 실험 4·5의 편집된 네트워크는 공개되어 있어 Kinetix(JAX)·MinAtar(numpy)로 CPU 재평가가 가능합니다.
- **LLM 쪽 재현:** 같은 모델이 없으면 불가능합니다. 다른 모델(Claude, 공개 모델)로 같은 프롬프트를 돌리는 것은 가능하고, 이것이 "범용 LLM의 능력"인지 "특정 모델의 능력"인지를 가르는 실험이 됩니다. 실험 1·2·4·5는 도구가 없고 프롬프트가 공개되어 있어 API 호출만으로 다시 해 볼 수 있습니다.
- **이 노트북(CPU)에서 한 것:** 로그 수치 재계산 전부, 실험 1·2 가중치 시각화. 실행하지 않은 것: MinAtar·Kinetix 재평가(패키지 설치 필요), LLM 재실행(API 비용·외부 전송 확인 필요), 실험 8 재평가(GPU 필요).

선행연구와 위치

블로그 참고문헌 번호는 [n]으로 씁니다(`paper/paper.pdf` p.21-22). 블로그가 인용하지 않았지만 가까운 연구는 arXiv 번호를 함께 적습니다.

1. 계보: 이 글이 이어 붙이는 세 흐름

흐름	대표 연구	이 글과의 관계
LLM으로 텍스트 산출물 최적화	OPRO [1], DSPy [2], MIPRO [3], GEPA [4], Meta-Harness [5], autoresearch [6]	저자 중 Khattab이 DSPy·GEPA 계열의 저자입니다. "프롬프트·프로그램을 LLM이 고치듯 가중치도 LLM이 고친다"는 확장이 글의 동기입니다(p.3)
가중치를 사람이 정한 프로그램에서 만들기	RASP(Weiss et al., 2021), Tracr(Lindner et al., 2023, arXiv:2301.05062, 블로그 p.3 링크), AdderBoard [28]	실험 5·6은 "원하는 프로그램을 먼저 설계하고 층별로 옮기는" 방식이라 이 흐름에 가장 가깝습니다. 차이는 컴파일러 대신 LLM이 설계와 변환을 둘 다 한다는 점입니다
다른 네트워크가 가중치를 쓰기	fast weight programmer(Schlag et al., 2021, arXiv:2102.11174, 블로그 p.3 링크), hypernetwork(Ha et al., 2016, arXiv:1609.09106), p-diff [22], HyperTuning [23], NeuroGen [24]	이들은 가중치를 쓰는 모델을 **그 일에 맞게 학습**합니다. 이 글은 학습하지 않은 범용 LLM을 그대로 씁니다

2. 가까운 대안: 같은 결과를 다른 방법으로 낼 수 있는가

이 글의 각 실험에는 LLM 없이도 같은 일을 하는 기존 기법이 있습니다. 블로그는 이들과 직접 비교하지 않았습니다. 이 비교가 "LLM이 무엇을 더하는가"를 가르는 기준입니다.

실험	기존 기법	어떻게 대응되는가
1·2 (얕은 층 읽기)	첫 층·마지막 층 가중치 시각화(feature visualization 이전의 고전적 방법)	numpy로 접으면 같은 구조가 보입니다(`03` §1). LLM은 텍스트 숫자만 보고 이 구조를 찾아 이름과 연결합니다
3 (복사 헤드)	Elhage et al. [10]의 QK·OV composition 점수, Olsson et al.(2022, arXiv:2209.11895)의 induction head	블로그도 Astra가 이 방법을 스스로 다시 찾아냈다고 씁니다(p.8). 같은 계산을 스크립트로 돌리면 사람이 해석할 필요 없이 같은 헤드가 나옵니다
7 (아첨 탐지)	두 모델의 activation·attention 비교, 자동 해석 에이전트 MAIA(Shaham et al., 2024, arXiv:2404.14394)	가중치만으로 실패하고 attention 도구로 성공했으므로, 결과는 activation 기반 해석에 속합니다
4 (정책 수정)	손 설계 제어기와 학습 정책의 결합(잔차·전환 제어), 보상 shaping 후 재학습	편집은 별도 경로를 배선해 특정 구간만 덮어쓰는 방식입니다(`01` §2.3)
8 (반복 제거)	방향 하나를 지우는 Arditi et al. [14], activation steering(ITI, Li et al., 2023, arXiv:2306.03341), Representation Engineering(Zou et al., 2023, arXiv:2310.01405), 반복 원인 분석 [13]	Astra가 쓴 방법(반복·정상 문맥 비교로 방향 → `down_proj` 일부 열에서 제거)이 이 계열 그대로입니다. 디코딩 쪽 처방(반복 패널티, 토큰 예산)과의 비교도 없습니다
5·6 (처음부터 쓰기)	사람이 쓴 휴리스틱을 Tracr식으로 컴파일, 행동 복제(휴리스틱 → 데이터 → 지도학습)	실험 6은 데이터 적합을 금지했으므로, 휴리스틱을 손으로 층에 옮기는 것만 허용됩니다

경사 없는 최적화 쪽 기준선도 있습니다: SPSA [25], ES [26], MeZO [27]. 실험 6·8의 pass 예산(최대 50번 측정)은 이들이 보통 쓰는 평가 횟수보다 훨씬 적습니다. 그래서 "같은 측정 예산에서 무작위 섭동 탐색보다 LLM 제안이 낫다"는 비교가 있으면 설득력이 커집니다. 실험 8에서 Astra는 자기 검증에 노름을 맞춘 무작위 방향 대조군을 넣었다고 적었습니다 (`runs/p50c/final_answer.md`). 이 대조군은 연습 문제 기준이고 블로그 본문에는 나오지 않습니다.

3. 해석 연구 쪽의 위치

연구	무엇을 하는가	이 글과의 차이
Circuits [15], Elhage et al. [10]	사람이 도구로 회로를 추적	이 글은 같은 분석을 LLM이 자연어 지시로 수행
ROME [16], MEMIT(Meng et al., 2023, arXiv:2210.07229)	사실 연관을 특정 MLP에서 찾아 rank-1로 편집	실험 8의 10 pass 편집(30개 행렬에서 rank-1 제거)과 형태가 비슷
Bills et al. [19]	LLM이 뉴런 하나의 activation 예시를 보고 설명	activation을 본다는 점이 다름. 이 글의 실험 1-3은 가중치만 봄
Natural Language Autoencoders [17], Weight Oracles [18]	activation이나 가중치를 읽도록 **학습된** 모델	이 글은 학습 없이 범용 모델을 그대로 씀. Weight Oracles(arXiv:2610.07334)가 가장 가까운 비교 대상인데, 같은 과제로 비교하지 않았음
WorkspaceBench [21]	해석 방법을 비교하는 벤치마크	저자들이 만들겠다는 "Weight-Space Programming 벤치마크"(p.19)와 목적이 겹침

4. 이 저장소의 다른 논문과의 관계

- **`gpt6_astra_tactile`**: 같은 GPT-6 Astra를 고정된 촉각 정책으로 쓴 논문입니다. 거기서는 LLM이 **행동을 직접 출력**하고, 여기서는 LLM이 **행동을 내는 신경망의 가중치를 씁니다**. 그 분석에서 지적한 결정당 지연(약 30초) 문제를, 가중치를 한 번 써 두고 작은 네트워크로 실시간 실행하는 방식이 피해 갈 수 있습니다. 실험 4·5가 바로 그 형태입니다.
- **`dust`**: 역전파 없이 forward만으로 Transformer를 사전학습하는 영차 방법입니다. 실험 8의 "gradient 없음, 측정은 있음" 구조와 같은 축에 있습니다. Dust는 무작위 섭동을 수많이 평가하고, 여기서는 LLM이 소수의 구조적 후보를 제안해 50번 안에 고릅니다. 두 글을 겹쳐 보면, 측정 예산 대비 효율을 비교하는 실험을 설계할 수 있습니다.
- **로봇 정책 논문들(`dexscrew`, `flashdexretarget` 등):** 실험 4처럼 PPO 정책이 국소 최적(경사로 앞에서 멈춤)에 빠지는 문제는 이 저장소의 RL 기반 손 조작 논문에서도 반복됩니다. 재학습 대신 정책 가중치를 진단·편집하는 접근은 이들에 바로 옮겨 볼 수 있습니다.

5. GitHub 요약 (2026-11-03 확인)

저장소	무엇인가	라이선스	확인
RikiyaT/lm_understand-logs	실험 1-8의 전체 로그, 평가, 신경망(실험 7 미세조정 모델 17 GB는 제외)	로그·데이터·신경망 CC BY 4.0, 스크립트 MIT, 실험 5 프롬프트 속 MinAtar 소스 GPL-3.0	커밋 `4d09ba6`, `logs_official/` 에 clone(367 MB)
kenjyoung/MinAtar	실험 5의 게임	GPL-3.0	메타데이터만
FLAIROx/Kinetix	실험 4의 환경과 공식 PPO	MIT	메타데이터만
google-deepmind/tracr	프로그램 → Transformer 가중치 컴파일러(비교용)	Apache-2.0	메타데이터만

저장소	무엇인가	라이선스	확인
andyrdt/refusal_direction	Arditi et al.의 방향 제거 구현(실험 8 기준선 후보)	Apache-2.0	메타데이터만

공식 하네스 코드(프롬프트 서버, forward pass 서버)는 공개되지 않았습니다. 로그 README의 "Not included"에 적혀 있습니다. 공개된 스크립트는 평가·채점·편집 적용(`exp8_math/code/`), 실험 7 학습·평가(`exp7_sycophancy/code/`), sandbox(`harness/sandbox.py`)입니다.