ZeroDex: 분석 리포트

게시용 버전 · 원문 https://arxiv.org/abs/2606.19340 · arXiv:2606.19340v3 · 서울대, 고려대 (Kim, Baik, Kim, Kim, Lee, Choi, Park, Choi, Joo) · 코드 미공개("Coming Soon") · 분석일 2026-10-28 · v1(2026-06-17)과 대조 · 논문 그림 © 저자, CC BY 4.0

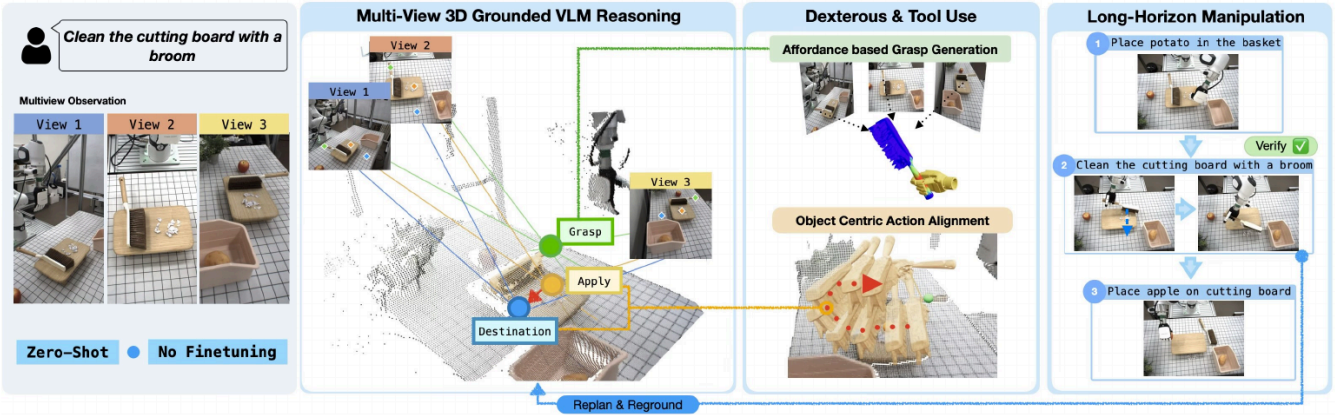


Fig. 1. **ZeroDex.** Given a language instruction and calibrated multi-view observations, our framework uses multi-view VLM grounding with robust triangulation to infer task-relevant 3D groundings, generates affordance-aware dexterous grasps, and executes pick-and-place or tool-use plans through reusable action primitives.

논문 Fig. 1: 보정된 다시점 RGB에서 VLM 그라운딩을 합의 삼각측량으로 3D에 올리고, 어포던스 파지와 원자 동작 정렬로 실행한다.

핵심 요약

1. **무엇을 하는가:** 학습된 정책 없이 Gemini Robotics-ER이 지시를 원자 과제로 나누고 2D 키포인트를 찍으면, 카메라 4대의 시점 쌍 삼각측량과 재투영 합의로 3D로 올린다. 도구 사용은 저장된 물체 중심 6D 궤적을 두 앵커로 정렬하고, 파지는 다시점 어포던스 박스의 메쉬 투표 영역에서 생성한다.
2. **표는 일관되지만 표본이 작다:** All = 조건 평균, Table II 실패 합 = Table I 실패 수, Table V 단계 연쇄가 모두 맞는다. 다만 zero-shot 기준선 대비 우위는 MOKA에만 유의하고($p = 0.008$), ReKep 대비는 $n = 20$에서 $p = 0.08$이다.
3. **VLA 비교의 차이는 파지에서 나온다:** 100개 시연 GR00T는 접근 0.95, 잡기 0.35, 성공 0.30이다. 한 과제이고, ZeroDex는 카메라 4대·자세 추정·메쉬·파지 시뮬레이션을 쓴다.
4. **"3배 반복성"은 평균이 만든다:** MOKA의 σ 평균 8.1 mm는 최악 장면(64.9 mm) 하나가 크게 끌어올렸을 가능성이 높다. 해석에 따라 나머지 9개 장면은 1.8 mm일 수도 있다. 침투 지표도 9 cm 안팎의 깊은 침투 장면 하나가 평균을 지배한다.
5. **v1 → v3에서 방법과 실험이 크게 바뀌었다:** 핵심 기여였던 ray voting이 빠졌고, 기준선, 시행 수, VLA 시연 수(30 → 100), 로봇이 바뀌었다. 하이퍼파라미터와 프롬프트 원문은 v1 부록에만 있다.
6. **숨은 가정:** 어포던스, 자세 추정, 침투 검사, 파지 생성이 모두 **물체 메쉬**를 쓰지만 메쉬 출처가 적혀 있지 않다. Eq. 6을 글자 그대로 구현하면 좁은 기선 스테레오 쌍 때문에 꼬리가 폭발한다(toy). inlier 재적합으로 해결된다.
7. **구현 가능성:** 공식 코드가 없어서 그대로 재현할 수는 없다. 그라운딩 계층(VLM + 다시점 합의)은 이 맥에서 Gemini API로 시작할 수 있다. 실행 계층은 NVIDIA GPU, 로봇, 물체 메쉬가 필요하다.

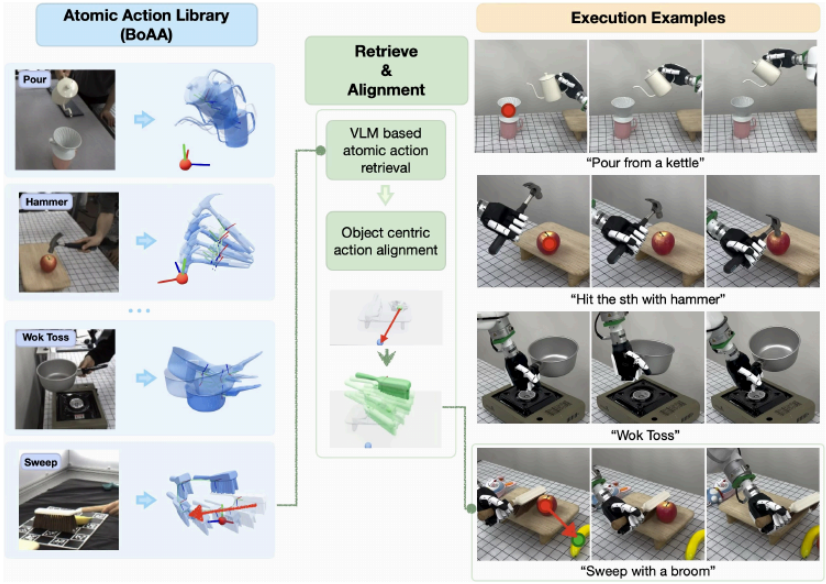


Fig. 2. **Bag of Atomic Actions.** Examples of object-centric atomic actions executed on the real robot.

논문 Fig. 2: Bag of Atomic Actions. 물체 중심 6D 도구 궤적을 기술 범주로 꺼내 장면에 정렬한다.

01. 논문 분석: ZeroDex (arXiv:2606.19340)

- 제목: *ZeroDex: Zero-Shot Long-Horizon Dexterous Manipulation via Multi-View 3D-Grounded VLM Reasoning*
- 저자: Jisoo Kim, Sangwon Baik, Taeksoo Kim, Sungjoo Kim, Junyoung Lee, Mingi Choi, Kisang Park, Sungjoon Choi, Hanbyul Joo (서울대, 고려대)
- 공개: arXiv v1 2026-06-17, v2 2026-06-19, **v3 2026-10-20** · 프로젝트 https://jlogkim.github.io/zerodex/ · 코드 **미공개**(페이지에 "Code (Coming Soon)". `github.com/jlogkim/zerodex` 는 프로젝트 페이지 저장소뿐, 2026-10-28 확인)
- 라이선스: 논문 **CC BY 4.0** (arXiv abs 페이지에서 확인)
- 분석 범위: v3 본문 8쪽과 참고문헌(총 9쪽). v1(21쪽, 부록 포함)과 대조했습니다. v1 부록에는 v3에 없는 하이퍼파라미터와 VLM 프롬프트 원문이 있습니다.

---

1. Abstract (한 줄 요약과 주장)

한 줄 요약: 학습된 정책 없이, VLM(Gemini Robotics-ER 1.6)이 지시를 원자 과제로 나누고 각 시점 이미지에 2D 키포인트를 찍으면, 보정된 4개 RGB 카메라의 시점 쌍 삼각측량과 재투영 합의로 3D로 올린 뒤, 파지 생성기와 팔-손 모션 생성기로 dexterous hand(Inspire)가 실행하는 zero-shot 시스템입니다.

논문이 내세우는 기여는 세 가지입니다(Sec. I).

1. VLM 과제 계획 + 다시점 3D 그라운딩 + 재사용 가능한 원자 동작 라이브러리를 묶은 zero-shot long-horizon dexterous 조작 프레임워크
2. 시점별 2D 예측을 교차 시점 합의 삼각측량으로 3D에 올리는 다시점 VLM 그라운딩. 가림과 부분 가시성에 강건하다고 주장합니다
3. 같은 그라운딩이 실행의 두 부분을 모두 맡는다는 점. 키포인트는 저장된 6D 도구 궤적을 장면에 맞추는 대응점이 되고, 파지 키포인트는 기능적 3D 어포던스 영역으로 확장됩니다

헤드라인 수치는 세 개입니다. 반복성이 MOKA의 단일 RGB-D 역투영보다 3배 이상 좋고(σ 2.5 vs 8.1 mm), zero-shot 기준선(MOKA 0.40, ReKep 0.55)보다 성공률이 높으며(0.85), 100개 시연으로 미세조정한 VLA(GR00T 0.30, Being-H0 0.00)를 시연 없이 이깁니다(0.95).

---

2. Method

2.1 전체 구조 (Fig. 1, Eq. 1)

```
보정된 다시점 RGB I = {I_v} (4대, 스테레오 쌍 포함) + 지시 l
  │
  ├─ (A) 기준 시점 의미 그라운딩: VLM이 기준 시점 r, 모드 z ∈ {pick, tool}, 대상·도구·기술 범주 c를 고름
(Eq. 3)
  │       → 기준 시점에서 원시 동작열 Q_r = {(m_t, 2D 키포인트 + 텍스트 설명)} (Eq. 2, 4)
  │         m_t ∈ {grasp, apply_action, waypoint, release, hold}
  ├─ (B) 다시점 3D 올리기: 키포인트마다 각 시점에 다시 질의 → 시점 쌍 삼각측량 → 재투영 합의 최대 후보 (Eq. 5–6)
  ├─ (C) 물체 궤적 T_obj: pick-and-place는 현재 자세 → 경유점 → 놓을 곳(자세 유지),
  │       도구 사용은 Bag of Atomic Actions에서 기술 범주 c로 궤적을 꺼내 두 앵커로 정렬 (Eq. 7),
  │       끝점은 충돌 없는 가장 가까운 격자점으로 보정 (Eq. 8)
  ├─ (D) 파지·모션: 시점별 어포던스 박스 → 메쉬 꼭짓점 투표로 3D 어포던스 영역 (Eq. 9)
  │       → 원통 템플릿 또는 BODex 최적화로 파지 후보 → 물리 시뮬레이션으로 안정성 검사
  │       → 팔-손 모션 생성기(cuRobo v2 + Natural functional gradients)로 T_obj를 따라가는 궤적, 실행
가능성 η (Eq. 10)
  └─ (E) long-horizon: 실행 후 새 관측으로 VLM이 continue / retry / replan / done 결정, 텍스트 메모리
갱신 (Eq. 11)
```

2.2 다시점 3D 올리기 (Sec. III-B, Eq. 5-6)

키포인트마다 각 시점에서 VLM 예측 $\tilde{p}_v$를 받고, 시점 쌍 (a, b)마다 삼각측량한 후보 X_{a,b}의 지지 수를 셉니다.

$$S_{tri}(X) = \Sigma_v \, 1\left(\|\pi_v(X) - \tilde{p}_v\| \le \varepsilon_{tri} \right) \qquad \text{(Eq. 5)}$$

$$(a^*, b^*) = \operatorname{argmax}_{a<b} S_{tri}(X_{a,b}), \quad X^* = X_{a^*,b^*} \qquad \text{(Eq. 6)}$$

평균을 내지 않고 가장 넓게 합의된 후보를 고르므로, 한 시점이 가려져서 엉뚱한 곳을 가리켜도 버틸 수 있다는 설계입니다. v3 본문에는 ε_tri 값과 동률 처리 규칙이 없습니다. v1 부록 D.1은 ε_tri = 20 px(640×480)이고, 지지 수가 τ_tri = 0.5·M을 넘지 못하면 **reference-view ray voting**으로 대체한다고 적었습니다. v3에서는 ray voting이 방법에서 빠졌고, 합의가 실패했을 때 무엇을 하는지는 적혀 있지 않습니다(`04` C7).

2.3 물체 궤적 구성 (Sec. III-C, Eq. 7-8)

- **Bag of Atomic Actions:** 각 항목 A = (c, T, X^s, X^e)는 기술 범주, 도구 자세열 T ⊂ SE(3), 시작·끝 앵커를 저장합니다. 기록된 시연이나 VLMPose[45](같은 그룹)로 만든 궤적에서 오프라인으로 구축합니다. 붓기, 쓸기, 망치질, 웍 토스 네 가지가 예로 나옵니다(Fig. 2, v1 부록 A.2).
- **정렬 (Eq. 7):** 저장 앵커 (X^s, X^e)를 장면의 (X^app, X^term)에 맞추는 변환을 구하되, 회전을 미리 정한 축으로 제한합니다. 대응점이 두 개뿐이라 일반 회전은 두 앵커를 잇는 축 둘레로 1자유도가 남기 때문입니다(`03` §3). 축척은 바꾸지 않으므로, 두 앵커 간 거리가 장면과 다르면 앵커에 잔차가 남습니다.
- **충돌 고려 끝점 보정 (Eq. 8):** 놓을 위치 주변 격자에서 침투 깊이 φ = 0인 가장 가까운 점을 고릅니다. v1 부록은 ±4 cm, 2 cm 간격, 연직 방향 우선입니다. 이 보정으로 모션 계획 성공이 7/10에서 10/10이 됐다고 보고합니다(Sec. IV-D).

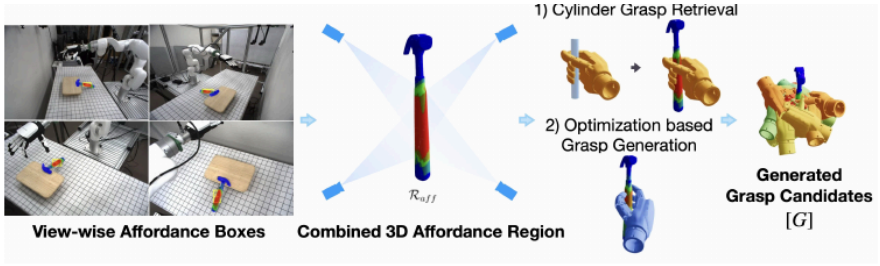


Fig. 3. Affordance grounding and grasp generation. Multi-view affordance bounding boxes are combined to identify a 3D affordance region.

논문 Fig. 3: 시점별 어포던스 박스를 합쳐 3D 어포던스 영역을 만들고 파지 후보를 생성한다.

2.4 파지와 모션 (Sec. III-D, Eq. 9-10)

- **어포던스 영역 (Eq. 9):** 시점마다 VLM이 잡을 수 있는 2D 박스 B_v를 그리고, 물체 **메쉬** 꼭짓점 q_i가 몇 개 시점의 박스 안에 투영되는지 비율 s(q_i)를 셉니다. s ≥ τ_aff인 꼭짓점이 영역입니다. v1 부록의 τ = 0.65는 4개 시점이면 3개 이상의 박스에 들어가야 한다는 뜻입니다. 가시성 검사가 없으므로 이는 박스 시야뿔들의 투표형 교집합(visual hull)입니다(`03` §4).
- **파지 생성:** 손잡이형 영역은 원통 템플릿(손바닥을 표면 법선 방향 0-3 cm 떨어뜨려 놓고 Dexonomy식 손가락 닫기), 일반 형상은 BODex[48]에 어포던스 거리·방향 항을 더한 최적화를 씁니다(v1 부록 B). 후보마다 시뮬레이션에서 여섯 축 방향 외력·토크로 안정성을 검사합니다.
- **모션:** 팔-손 모션 생성기[52, 53]가 파지 γ로 T_obj를 운반하는 궤적을 찾고, 기구학·충돌 제약을 만족하면 η = 1입니다. 가능한 쌍이 없으면 실패를 보고합니다.

2.5 long-horizon 확장 (Sec. III-E, Eq. 11)

VLM이 하위 과제 큐와 텍스트 메모리를 관리하고, 시도마다 새 관측을 보고 continue / retry / replan / done을 고릅니다. v3 실험은 하위 과제당 재시도 1회 예산이고, v1은 4회였습니다.

---

3. Experiments

3.1 설정 (Sec. IV-A, IV-B)

- **로봇:** Franka + Inspire 손(zero-shot 기준선 비교), xArm + Inspire 손(VLA 비교, 텔레옵 장비가 xArm에 있어서). 정성 결과는 둘 다 씁니다.
- **센서·인식:** 보정된 RGB 카메라 4대(스테레오 쌍 포함), FoundationStereo[43]로 깊이, FoundationPose[44]로 다중 물체 6D 자세입니다.
- **VLM:** 모든 질의에 Gemini Robotics-ER 1.6(medium thinking)을 씁니다. v1 부록에는 `gemini-robotics-er-1.6-preview`로 적혀 있습니다. v3는 "프롬프트는 보충 영상에 있다"고 적었고, 텍스트 원문은 v1 부록 D.2에 있습니다.
- **기준선:** MOKA[6](단일 RGB-D 시점에서 키포인트 역투영, 경유점 높이 선택지를 저자들이 늘려 줌), ReKep[32](공개 구현의 키포인트 제안과 제약 생성, 같은 실행 스택). 두 방법은 같은 파지·모션 스택을 써서 **그라운딩만 다르게** 했습니다. VLA는 GR00T[20], Being-H0[22]이고, 100개 텔레옵 pick-and-place 시연(약 1시간)으로 각자 공식 설정에 따라 사후학습했습니다(H = 16, 배치 64, LR 1e-4, 30k step, A6000 4장).

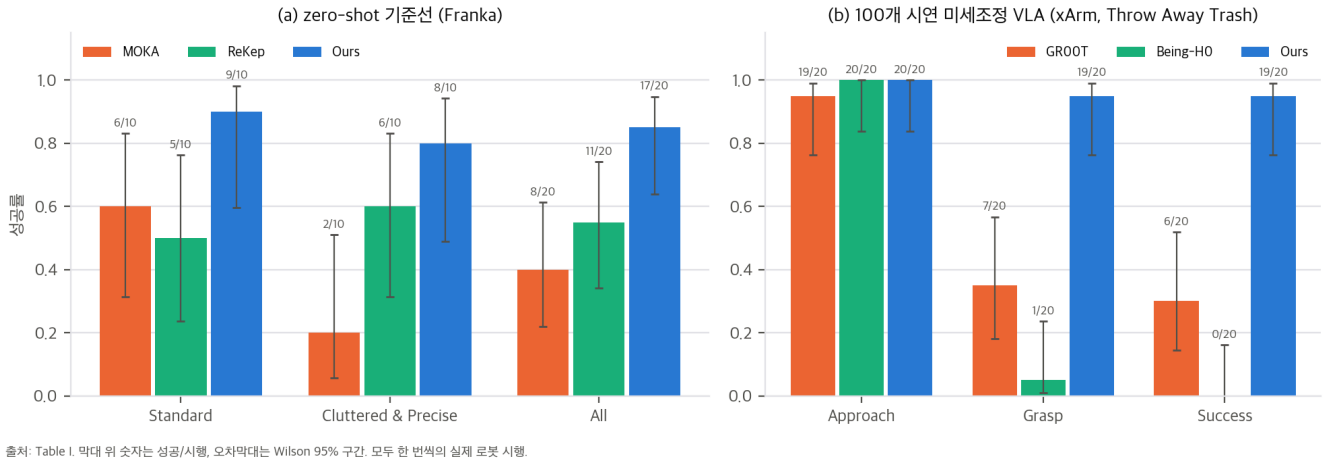
3.2 실제 로봇 성공률 (Table I, Table II)

방법	N(시연)	Standard (n=10)	Cluttered & Precise (n=10)	All (n=20)
MOKA	0	0.60	0.20	0.40

방법	N(시연)	Standard (n=10)	Cluttered & Precise (n=10)	All (n=20)
ReKep	0	0.50	0.60	0.55
Ours	0	**0.90**	**0.80**	**0.85**

VLA 비교 (xArm, Throw Away Trash, n=20)	N	Approach	Grasp	Success
GR00T	100	0.95	0.35	0.30
Being-H0	100	1.00	0.05	0.00
Ours	0	1.00	0.95	**0.95**

실패 단계(Table II, n=20): MOKA는 그라운딩 6, 파지 3, 실행 3이고, ReKep은 그라운딩 7, solver 2입니다. Ours는 파지 3뿐입니다.



출처: Table I. 막대 위 숫자는 성공/시행, 오차막대는 Wilson 95% 구간. 모두 한 번씩의 실제 로봇 시행.

우리 분석: Table I 성공률과 Wilson 95% 구간. (a) zero-shot 기준선, (b) 100개 시연 미세조정 VLA의 단계별 성공.

해석 (재계산은 `04_claim_verification.md`, `analysis/table_check.py`):

- **표는 내부적으로 일관됩니다.** All은 두 조건의 평균이고, Table II의 실패 합(12, 9, 3)은 Table I의 실패 수와 정확히 맞습니다.
- **zero-shot 기준선과의 차이는 시행 수에 비해 확실하지 않습니다.** 전체 17/20 vs MOKA 8/20은 Fisher p = 0.008이지만, ReKep 11/20과는 p = 0.08입니다. 조건별(n = 10)로는 Cluttered에서 MOKA 대비(p = 0.02)만 5% 수준을 넘습니다. 모든 결과가 장면당 한 번의 시행이고, 시행별 짝 정보(같은 장면에서 둘 다 성공했는지)가 없어 대응 검정은 할 수 없습니다.
- **VLA와의 차이는 큽니다**(19/20 vs 6/20, p = 4×10^{-5}). 다만 성격을 봐야 합니다. 두 VLA 모두 목표에는 거의 항상 다가가고(0.95, 1.00), **잡기에서 실패합니다**(0.35, 0.05). GR00T는 잡은 7번 중 6번을 성공했습니다. 즉 이 비교는 "VLA가 1시간 시연으로 새 dexterous 손의 파지를 배우지 못한다"는 결과에 가깝습니다. 과제도 하나(Throw Away Trash)뿐입니다.
- **정보량이 다릅니다.** ZeroDex는 보정된 카메라 4대, FoundationStereo·FoundationPose, 물체 메쉬, 파지 시뮬레이션, 충돌 고려 모션 계획을 씁니다. VLA는 이미지 1-2개만 봅니다. 저자들은 "같은 xArm, 같은 장면 목록, 같은 성공 기준이라 matched"라고 썼지만, 입력과 사전 정보는 같지 않습니다.

TABLE I

REAL-ROBOT SUCCESS RATES. N IS THE NUMBER OF TASK-SPECIFIC TELEOPERATION DEMONSTRATIONS FOR FINE-TUNING; FOR THE FINE-TUNED VLA BASELINES WE ADDITIONALLY REPORT STAGE-WISE SUCCESS.

Method	N	**Standard** (n=10)	**Cluttered & Precise** (n=10)	**All** (n=20)
Zero-shot grounding				
MOKA [6]	0	0.60	0.20	0.40
ReKep [32]	0	0.50	0.60	0.55
Ours	**0**	**0.90**	**0.80**	**0.85**
Fine-tuned VLA		**Throw Away Trash** (n=20)		
		Approach	*Grasp*	*Success*
GR00T [20]	100	0.95	0.35	0.30
Being-H0 [22]	100	1.00	0.05	0.00
Ours	0	1.00	0.95	0.95

TABLE II

WHERE ZERO-SHOT METHODS FAIL. FAILURE COUNTS BY STAGE; SUCCESS REPEATS TABLE I. SOLVER IS REKEP'S CONSTRAINT-SOLVING STAGE, WHICH THE OTHERS LACK.

Method	**Success** (n=20)	**Ground**	**Solver**	**Grasp**	**Exec.**
MOKA [6]	0.40	6	–	3	3
ReKep [32]	0.55	7	2	0	0
Ours	**0.85**	**0**	–	3	**0**

TABLE III

EFFECT OF AFFORDANCE CONDITIONING. SUCC. IS REAL-ROBOT SUCCESS OVER 10 TRIALS. #G: MEAN GRASP CANDIDATES PER SCENE; CLEAR% AND IK% (SEC. IV-C) ARE POOLED OVER ALL CANDIDATES IN OFFLINE.

	Tool-use(5 scenes)				**Pick-and-place**(10 scenes)			
Affordance	#G	Clear%	IK%	**Succ.**	#G	Clear%	IK%	**Succ.**
off	22	16.7	16.7	2/10	69	23.4	5.6	9/10
on	16	96.2	35.0	**7/10**	27	96.0	37.2	9/10

논문 Table I-III.

3.3 3D 그라운딩 품질 (Table IV)

	σ (mm)	δ_max (mm)		P_max	P_avg	Coll%	IK%
MOKA	8.1	64.9	Tool (5 장면)	20.4	20.4	20	30.3
Ours	**2.5**	**3.9**		20.3	**4.7**	**5**	**35.0**
(10 장면 × 8회)			P&P (10 장면) MOKA	37.2	36.3	100	24.2
			Ours	**32.6**	**16.3**	**17**	**37.2**

- **"3배 반복성"은 맞지만 한 장면에 크게 좌우될 수 있습니다.** 8.1 / 2.5 = 3.24입니다. 그런데 δ_max가 "장면별 σ의 최댓값"이라면, MOKA의 나머지 9개 장면 σ 평균은 1.79 mm로 Ours(2.5)보다 오히려 작습니다. δ_max가 "한 실행의 최대 이탈"이라면, 그 장면의 σ는 24.5 mm 이상이고 나머지 9개 평균은 6.3 mm 이하입니다(`04` C4b). 어느 해석이든 MOKA의 평균은 이상치 장면이 끌어올렸습니다. 장면별 중앙값을 함께 보고했어야 합니다.
- **침투 지표도 소수 장면이 지배합니다.** 비충돌 waypoint를 1 mm 이하로 보면 P_avg, Coll%, P_max가 동시에 성립하기 위한 최악 장면의 P_max 하한을 계산할 수 있습니다. MOKA 도구 행은 5개 장면 중 한 장면이 약 9.5 cm 이상 침투해야 하고 (P_max 질량의 94%), Ours 도구 행도 6.7 cm 이상인 장면이 하나 있어야 합니다. Ours P&P도 8.8 cm 이상인 장면이 있어야 합니다(`04` C4). Tool 행의 차이는 사실상 "같은 실패 장면에서 몇 개의 waypoint가 충돌하는가"의 차이입니다.
- **IK%는 여전히 낮습니다.** Ours도 도구 35%, P&P 37%입니다. 파지 후보 셋 중 둘은 기구학적으로 실행할 수 없습니다.
- ReKep은 목표가 범위(예: 키포인트 위 5-10 cm)로 주어져서 이 지표에서 제외했다고 설명합니다.

3.4 어포던스 조건 ablation (Table III)

	Tool #G	Clear%	IK%	성공	P&P #G	Clear%	IK%	성공
off	22	16.7	16.7	2/10	69	23.4	5.6	9/10
on	16	96.2	35.0	**7/10**	27	96.0	37.2	9/10

- 어포던스 영역으로 파지를 조건화하면 충돌 없는 후보 비율이 16-23%에서 96%로 오르고, 도구 사용 성공이 2/10에서 7/10이 됩니다(Fisher p ≈ 0.07, n = 10). pick-and-place는 이미 9/10으로 포화입니다.
- 반올림을 역산하면 합산 후보 수가 정수로 맞아떨어집니다(도구 off 108개 중 18개, on 80개 중 77·28개, `04` C3). 장면당 IK 가능 후보는 도구 3.6 → 5.6개, P&P 3.9 → 10.2개로 늘어납니다.
- 같은 데이터의 IK%(35.0, 37.2)가 Table IV의 Ours IK%와 같습니다. 두 표가 같은 후보 풀에서 나왔다는 뜻입니다.

TABLE IV

3D GROUNDING QUALITY VS. MOKA [6] ON THE SAME 15 SCENES. ALL LENGTHS IN MM; METRICS ARE DEFINED IN SEC. IV-C.

Grasp repeatability (10 scenes × 8 runs)

Method	$\sigma\downarrow$	$\delta_{\max}\downarrow$
MOKA [6]	8.1	64.9
Ours	**2.5**	**3.9**

Method	$\mathcal{P}^o_{\max}\downarrow$	$\mathcal{P}^o_{\text{avg}}\downarrow$	Coll%↓	IK%↑
Tool (5 scenes)				
MOKA [6]	20.4	20.4	20	30.3
Ours	20.3	**4.7**	**5**	**35.0**
P&P (10 scenes)				
MOKA [6]	37.2	36.3	100	24.2
Ours	**32.6**	**16.3**	**17**	**37.2**

TABLE V

LONG-HORIZON SUCCESS PER SUB-STEP AND END-TO-END. MAIN NUMBERS ALLOW ONE RETRY PER SUBTASK; NUMBERS IN PARENTHESES ARE WITHOUT RETRY.

Task	Step 1	Step 2	Step 3	End-to-End
Organize Objects	10/10	10/10(7/10)	8/10(6/7)	8/10 (6/10)
Cooking (with tool-usage)	9/10(8/10)	9/9(7/8)	9/9(6/7)	9/10 (6/10)

논문 Table IV-V.

3.5 long-horizon (Table V)

과제	Step 1	Step 2	Step 3	End-to-End
Organize Objects	10/10	10/10 (7/10)	8/10 (6/7)	**8/10** (6/10)
Cooking (도구 포함)	9/10 (8/10)	9/9 (7/8)	9/9 (6/7)	**9/10** (6/10)

괄호는 재시도 없음입니다. 단계별 분모가 이전 단계의 성공 수와 정확히 이어집니다(`04` C5). 재시도 1회로 End-to-End가 6/10 → 8/10, 9/10이 됩니다. 남은 실패는 팔 관절 한계와 환경 충돌이라고 보고합니다. n = 10이라 Wilson 구간은 8/10이 [0.49, 0.94], 6/10이 [0.31, 0.83]으로 겹칩니다.

3.6 실행 시간

다시점 그라운딩 한 번에 19.4 s(기준 시점 6.7 + 시점별 질의 4개 9.6 + 삼각측량 3.1, 합이 맞음)이고, 팔-손 모션 생성에 4.8 s(장면 구성) + 9.4 s(계획)가 듭니다. 파지 시뮬레이션 검증 시간은 후보 수에 비례해서 보고하지 않았습니다. 하위 과제 하나에 파지 검증을 빼고도 약 34 s입니다. 키포인트가 3-4개면 VLM 질의는 하위 과제당 약 19-23회로 추정됩니다(`04` C6).

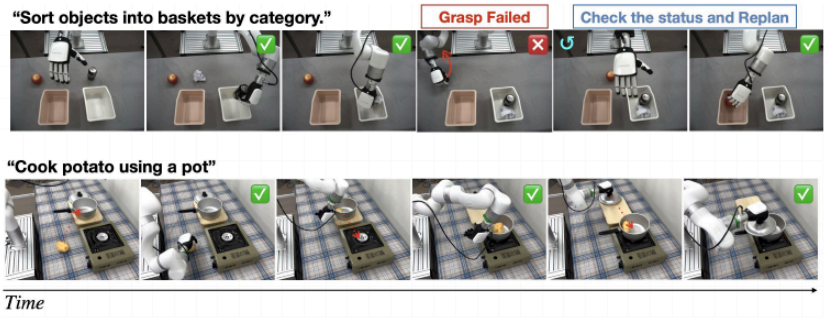


Fig. 5. **Qualitative Results.** Long-horizon manipulation examples. The shown scenarios consist of multiple subtasks. In the example above, the grasp fails, and the VLM detects the failure state and replans the next action.

논문 Fig. 5: long-horizon 예시. 파지 실패를 VLM이 감지하고 재계획한다.

4. Limitations

4.1 저자가 밝힌 한계 (Sec. V)

2D VLM의 추론 신뢰도가 상한을 정합니다. 외부 팔-손 모션 생성기의 특이점, 충돌 검사 시간 초과, 불안정한 파지로 실패할 수 있습니다. Bag of Atomic Actions에 없는 도구 동작은 바로 실행할 수 없습니다(다만 라이브러리는 확장 가능한 캐시라고 설명합니다). 변형 물체와 손 안 조작(물체 돌리기, 가위)은 다루지 않습니다.

4.2 분석하면서 추가로 발견한 한계와 의문점

1. **물체 메쉬가 필요하다는 가정이 본문에 드러나 있지 않습니다.** Eq. 9의 어포던스 영역은 "물체 메쉬의 꼭짓점"으로 정의되고, FoundationPose 자세 추정, 침투 깊이 φ, BODex 파지 최적화, 파지 안정성 시뮬레이션도 모두 메쉬가 있어야 합니다. 그런데 메쉬를 어디서 얻는지(스캔, CAD, 복원)는 v1, v3 모두 적혀 있지 않습니다. "처음 보는 물체로 zero-shot"은 학습 없이라는 뜻이지, 메쉬 없이라는 뜻이 아닙니다.
2. **v1 → v3 사이에 실험이 거의 다시 만들어졌습니다**(`04` C7). 핵심 기여였던 ray voting이 빠졌고, 기준선이 바뀌었으며(단일 RGB-D → MOKA, ReKep), VLA 시연이 과제당 30개 → 100개로 늘었습니다. 시행 수도 과제당 5 → 조건당 10으로 늘었고, long-horizon 성공률은 4/6, 1/3에서 8/10, 9/10으로 올랐습니다. 프로젝트 페이지 초록은 아직 ray voting을 설명합니다. 개선 자체는 좋지만, 어떤 변경이 수치를 바꿨는지는 추적할 수 없습니다.
3. **v1에서는 다시점 그라운딩의 침투 개선이 없었습니다.** v1 Table 3은 침투 오차가 RGB-D 9.91, Ours 9.81로 거의 같았습니다. v3 Table IV의 Coll% 100 vs 17은 지표 정의와 기준선이 바뀐 뒤의 결과입니다. 같은 현상을 다른 지표로 재본 것인지 판단할 근거가 본문에 없습니다.
4. **합의 규칙이 덜 명시되어 있습니다.** ε_tri 값, 동률 처리, 합의 실패 시 동작이 v3에 없습니다. toy에서 Eq. 6을 그대로(동률이면 첫 쌍, 재적합 없음) 구현하면 기선이 짧은 스테레오 쌍을 골라 꼬리가 매우 길어집니다. inlier 전체로 다시 삼각측량하면 이 꼬리가 사라집니다(`03` §2). 구현에 따라 결과가 크게 달라질 수 있는 부분입니다.
5. **4개 시점에서 버틸 수 있는 이상치 시점은 하나입니다.** toy에서 VLM이 엉뚱한 곳을 가리킨 시점이 1개면 합의가 강건하지만(중앙값 7 mm), 2개면 꼬리가 커지고(p90 약 10 cm), 3개면 실패합니다. "가림에 강건"은 4개 중 3개 시점이 같은 곳을 가리킨다는 조건에서만 성립합니다.
6. **폐쇄형 VLM 의존성:** Gemini Robotics-ER 1.6 preview 버전에 묶여 있습니다. 모델이 바뀌거나 내려가면 같은 결과를 재현할 수 없고, v3는 프롬프트를 영상으로만 제공합니다.
7. **통계 정보가 부족합니다.** 모든 성공률이 n = 10-20의 단일 시행이고, 신뢰구간이 없습니다. ReKep 대비 전체 우위도 p = 0.08입니다.

8. **느립니다.** 하위 과제마다 30초 이상 걸리고(파지 검증 제외) VLM 호출이 약 20회입니다. 닫힌 루프 반응 제어는 아니며, 저자들도 반응형 저수준 정책 결합을 향후 과제로 남겼습니다.

03. 핵심 식 해석과 toy 검증

공식 코드가 없어서, 본문 식(v3)과 v1 부록의 하이퍼파라미터로 toy를 직접 구현했습니다. 스크립트는 `analysis/grounding_toy.py`(Eq. 5-6, 결과 `grounding_toy_results.json`), `analysis/alignment_toy.py`(Eq. 7, 결과 `alignment_toy_results.json`), `analysis/table_check.py`(표 재계산, 결과 `table_check_results.json`)이고, 모두 CPU에서 몇 초 안에 끝납니다.

1. 다시점 합의 삼각측량 (Eq. 5-6)의 성질

1.1 후보와 지지 수

시점이 M개면 후보는 시점 쌍 수 C(M, 2)개입니다. 4대면 6개입니다. 후보 X_{a,b}의 지지 수 S_tri는 재투영 오차가 ε_tri 이하인 시점 수로, 0부터 M까지의 정수입니다. 따라서 다음이 성립합니다.

- 네 시점 중 세 시점(inlier)이 같은 곳을 가리키면, inlier 쌍에서 나온 후보는 지지 수가 3 이상입니다. 이상치 시점이 하나면 그 시점이 포함된 쌍의 후보는 지지 수가 2 이하입니다. 그래서 **이상치 시점 하나는 항상 걸러집니다.**
- 이상치가 둘이면 inlier 쌍도 지지 수 2가 되어 이상치 쌍과 동률이 될 수 있고, 결과는 동률 처리 규칙에 달립니다. v3 본문에는 그 규칙이 없습니다. v1 부록은 지지 수가 τ_tri = 0.5·M을 "넘어야" 채택하고(4대면 3 이상), 아니면 ray voting으로 대체했습니다. v3에서는 그 대체 경로가 사라졌습니다.

1.2 어느 쌍을 고르는지가 정밀도를 정합니다

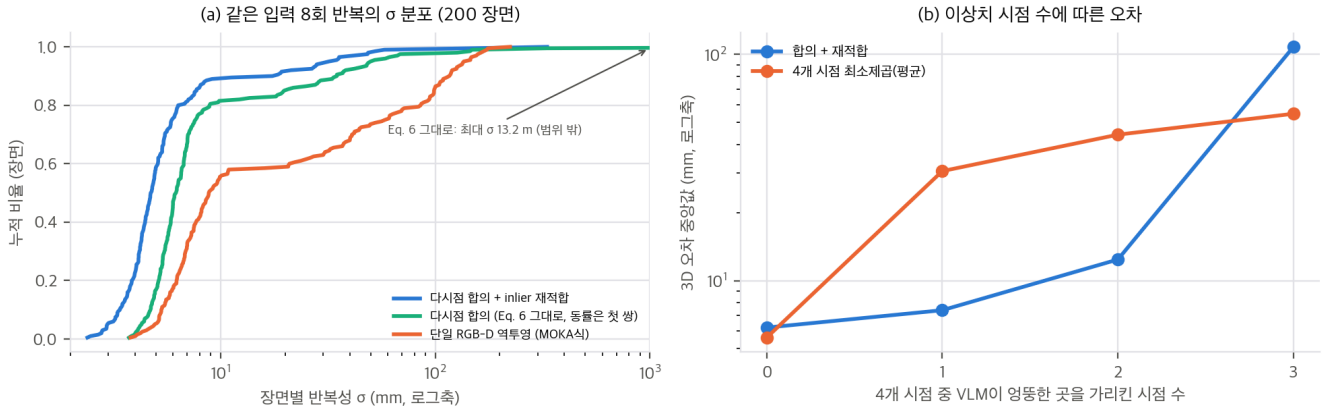
두 광선의 사잇각을 θ라고 하면, 2D 오차 σ_px에 대한 3D 오차는 대략 z·σ_px / (f·sin θ)입니다. 카메라 4대에 스테레오 쌍이 포함되어 있으므로, 기선 12 cm 스테레오 쌍(1 m 거리에서 θ ≈ 7°)으로 삼각측량하면 오차가 넓은 기선 쌍(θ ≈ 60-90°)보다 약 7-8배 커집니다. Eq. 6은 지지 수만 보고 쌍을 고르므로, 동률일 때 좁은 기선 쌍이 선택되면 정밀도가 크게 떨어집니다. 표준 RANSAC처럼 **최다 지지 후보의 inlier 시점 전체로 다시 삼각측량**하면(refit) 이 문제가 사라집니다.

2. toy: 다시점 합의 vs 단일 RGB-D 역투영 (G1-G3)

모델 (가정): VLM 2D 출력 = 장면별로 고정된 의미 편향 N(0, 4 px) + 실행별 흔들림 N(0, 3 px) + 질의당 5% 확률의 이상치(40-100 px)입니다. 카메라는 f = 900 px, 1280×720이고, 4대 중 2대가 기선 12 cm 스테레오 쌍입니다. 목표는 높이 8-15 cm 용기의 윗면이며, 절반은 안쪽, 절반은 테두리 6 mm 이내입니다. 단일 RGB-D는 기준 시점 픽셀의 광선이 처음 맞는 표면의 깊이(+3 mm 잡음)로 역투영합니다. 카메라 배치와 잡음 크기는 논문에 없어서 가정한 값입니다.

2.1 반복성 (G1, Table IV와 같은 10 장면 × 8회 설계를 20번 반복)

방법	σ 평균 (mm)	σ 중앙값	최악 장면 σ (평균)	σ > 10 mm 장면	정확도 오차 중앙값
다시점 합의, Eq. 6 그대로 (동률이면 첫 쌍)	80.4	6.2	720.5	18.5%	5.5
다시점 합의 + inlier 재적합	**9.8**	**4.8**	46.3	11%	5.2
4개 시점 최소제곱 (평균)	12.4	11.7	23.1	62.5%	6.4
단일 RGB-D 역투영 (MOKA식)	38.3	8.8	126.8	44.5%	12.3



toy 가정: VLM 2D 오차 = 고정 편향 4 px + 실행별 3 px + 질의당 5% 이상치(40–100 px), ε_tri = 10 px, 카메라 배치 가정. analysis/grounding_toy.py

해석:

- **메커니즘은 논문 설명과 맞습니다.** 단일 RGB-D는 픽셀이 용기 테두리를 넘어가면 깊이가 탁자로 튀어서 긴 꼬리가 생깁니다. 다시점 합의는 깊이 맵을 쓰지 않으므로 이 꼬리가 없습니다.
- **평균 비율은 꼬리가 만듭니다.** 재적합 합의 대 RGB-D의 σ 비율은 평균 기준 3.9배지만 중앙값 기준 1.9배입니다. 논문 Table IV의 "3배"도 평균이고, MOKA의 δ_max 64.9 mm가 평균을 크게 끌어올렸을 가능성이 높습니다(`04` C4b).
- **Eq. 6을 글자 그대로 구현하면 위험합니다.** 동률일 때 스테레오 쌍을 고르면 미터 단위로 튀는 장면이 나옵니다(최악 13 m). 저자 구현은 이를 처리했겠지만, 본문만으로는 재현할 수 없는 부분입니다.
- **평균(최소제곱)은 이상치에 약합니다.** 한 번의 실행(4개 질의)에 이상치가 하나라도 섞일 확률이 18.5%($1 - 0.95^4$)라서, 8번 반복하면 대부분의 장면에서 한 번 이상 끌려가고 σ 중앙값이 11.7 mm가 됩니다. "평균 대신 합의"라는 논문의 선택이 옳다는 것을 보여 줍니다.

2.2 이상치 시점 수 (G2)

이상치 시점	합의 + 재적합: 중앙값 / p90 (mm)	Eq. 6 그대로	최소제곱
0	6.2 / 11.4	7.4 / 12.7	5.6 / 9.1
1	**7.4 / 13.1**	8.8 / 49.7	30.5 / 45.7
2	12.4 / 99.5	16.5 / 402	44.2 / 64.3
3	108 / 844	113 / 1,271	54.7 / 79.2

4대 구성에서는 이상치 하나까지만 확실히 버팁니다(§1.1). 둘이면 꼬리가 10 cm 수준이 되고, 셋이면 합의가 틀린 쌍을 고릅니다. 가림이 심해 두 시점 이상이 대상을 못 보는 장면에서는 시점을 늘리거나 합의 실패를 감지해 재질의해야 합니다.

2.3 ε_tri 민감도 (G3, 이상치 시점 1개)

ε_tri (toy px)	3	5	10	20	40
재적합: 중앙값 / p90 (mm)	11.0 / 288	10.1 / 390	7.5 / 14.2	**6.4 / 11.7**	7.1 / 25.2
Eq. 6 그대로	19.9 / 492	36.4 / 1,785	8.8 / 99.8	9.1 / 19.9	15.9 / 63.1

ε_tri가 VLM의 시점별 오차(여기서는 편향 + 흔들림 약 5 px)보다 작으면 inlier가 거의 없어 동률이 생기고, 꼬리가 폭발합니다. 너무 크면 이상치 시점도 inlier로 들어옵니다. v1 부록의 ε_tri = 20 px(640×480)는 같은 화각이면 이 toy 해상도에서 약 40 px입니다. 실제 VLM 오차가 이 toy보다 꽤 크다는 것을 시사합니다. **ε_tri는 VLM의 픽셀 오차 분포에 맞춰 정해야 하는 핵심 하이퍼파라미터**인데, v3 본문에는 값이 없습니다.

3. 두 앵커 정렬 (Eq. 7)

3.1 왜 회전 축을 제한하는가 (A1)

대응점이 X^s ↔ X^app, X^e ↔ X^term 두 쌍뿐이면, 두 앵커를 잇는 직선 둘레의 회전은 두 점을 움직이지 않습니다(toy에서 잔차 0 확인). 즉 일반 3-DoF 회전을 쓰면 도구가 그 축 둘레로 얼마나 돌아가 있는지(예: 주전자 주둥이가 어느 쪽을 향하는지)를 정할 수 없습니다. v1은 "앵커를 맞추는 강체 변환"이라고만 썼고, v3는 "회전을 미리 정한 축으로 제한"이라고 고쳤습니다. 이 수정은 필요한 것입니다.

3.2 연직축 제한의 닫힌 해와 잔차 (A2, A3)

회전을 연직축(z)으로 제한하고 병진을 더하면 자유도는 4입니다. 두 앵커의 제곱오차를 최소화하는 해는 다음과 같습니다.

```
u = (X^e − X^s)/2,  w = (X^term − X^app)/2
θ = atan2( (u × w)_z , u_xy · w_xy )
t = (X^app + X^term)/2 − R_z(θ) (X^s + X^e)/2
앵커 잔차 = |w − R_z(θ) u|  (두 앵커에서 같음) = 두 앵커 간 벡터 불일치의 절반
```

장면 앵커 간격 − 저장 간격	높이차 불일치 0 cm	3 cm
0 cm	0.0 cm	1.5 cm
2 cm	1.0 cm	1.8 cm
5 cm	2.5 cm	2.9 cm
10 cm	**5.0 cm**	5.2 cm

축척을 바꾸지 않으므로 저장 궤적과 장면의 기하가 다르면 오차를 양 끝에 반씩 나눠 가집니다. 예를 들어 주둥이-드리퍼 거리가 저장 궤적보다 10 cm 멀면, 붓기 시작점과 끝점이 각각 5 cm 어긋납니다. 라이브러리 항목이 장면과 비슷한 크기여야 하고, 그렇지 않으면 구간별 정렬이나 축척 허용 같은 확장이 필요합니다. 본문은 이 잔차를 보고하지 않습니다.

4. 어포던스 영역 (Eq. 9)은 투표형 visual hull입니다

s(q) = (1/M) Σ_v 1(π_v(q) ∈ B_v)이고, v1 부록의 τ = 0.65이면 4대 기준 3개 이상의 박스에 투영되어야 합니다. 2D 박스 하나의 역투영은 시야뿔이므로, 이 영역은 시야뿔들의 "4개 중 3개" 교집합입니다.

- **가시성 검사가 없습니다.** 박스 안에 투영되기만 하면 가려진 뒷면 꼭짓점도 들어갑니다. 손잡이처럼 둘러 잡는 부위에는 오히려 맞는 성질이지만, 머그 손잡이를 고른 박스가 몸통 일부와 겹치면 몸통 꼭짓점도 들어올 수 있습니다. 시점 수가 많을수록 이런 과포함이 줄어듭니다.
- **박스가 크면 영역도 넓어집니다.** 박스는 축정렬 직사각형이라 기울어진 손잡이에서는 주변 부위까지 포함됩니다. Table III에서 어포던스를 켜면 장면당 후보 수가 줄고(도구 22 → 16, P&P 69 → 27) 충돌 없는 비율이 96%로 오르는 것과 일관됩니다.

5. Table IV에서 추론할 수 있는 것 (C4, C4b)

침투 지표. 장면 s의 waypoint 가운데 비율 c_s가 1 mm를 넘고 나머지는 1 mm 이하라고 하면, P_avg,s ≤ c_s·P_max,s + (1 − c_s)·1 mm입니다. 장면 평균을 취하면 다음 하한을 얻습니다.

```
max_s P_max,s ≥ ( P_avg − (1 − Coll) · 1 mm ) / Coll
```

행	평균 P_max	최악 장면 P_max 하한	총 P_max 중 그 장면 비중
Tool / MOKA	20.4 mm	**95.4 mm**	94%
Tool / Ours	20.3 mm	67.4 mm	66%
P&P / MOKA	37.2 mm	36.2 mm	(모든 waypoint가 충돌, 제약 없음)
P&P / Ours	32.6 mm	88.1 mm	27%

(Coll% 반올림 ±0.5와 P_avg 반올림을 반영한 보수적 값.) 도구 사용 5개 장면에서 MOKA와 Ours의 차이는 "모든 장면이 조금씩 나쁘다"가 아니라, **한 장면에서 10 cm 가까이 박히는 실패**가 두 방법 모두에 있고, 그 장면에서 충돌하는 waypoint 비율이 다르다는 쪽에 가깝습니다. Ours P&P도 9 cm 가까이 박히는 장면이 적어도 하나 있습니다. 논문이 이 지표에 충돌 고려 보정(Eq. 8) **이전** 값을 쓴 것은 그라운딩 자체를 평가하려는 의도라 타당합니다. 다만 꼬리 정보(장면별 분포)가 함께 있어야 해석할 수 있습니다.

반복성 지표. σ는 장면 평균이고 δ_max는 "최악값"입니다. δ_max가 장면별 σ의 최댓값이라면 MOKA의 나머지 9개 장면 σ 평균은 (10 × 8.1 − 64.9)/9 = 1.79 mm로 Ours(2.5 mm)보다 작습니다. δ_max가 한 실행의 최대 이탈이라면, 편차 합이 0이라는 제약에서 그 장면의 σ ≥ 64.9/√7 = 24.5 mm이고, 나머지 9개 평균은 6.3 mm 이하입니다. 어느 해석이든 "3배"의 상당 부분은 이 상치 한 장면에서 나옵니다. toy(§2.1)도 평균 비율 3.9배, 중앙값 비율 1.9배로 같은 양상을 보입니다.

04. 주장 검증: 표 재계산, v1 ↔ v3 대조, 구현 가능성

- **대상:** arXiv:2606.19340 v3(2026-10-20) 본문 표 I-V와 수치 주장, v1(2026-06-17) 본문과 부록, 프로젝트 페이지
- **범위:** 공식 코드가 공개되지 않아(페이지에 "Coming Soon", 2026-10-28 확인) 논문 ↔ 코드 대조는 할 수 없습니다. 대신 표 수치를 재계산하고, 핵심 식을 toy로 구현해 성질을 확인했습니다(`03`). 실제 로봇 결과 파일은 공개되어 있지 않습니다.

1. 수치 재계산 (`analysis/table_check.py`)

#	주장 (출처)	재계산	판정
C1	표 내부 일관성 (Table I, II)	All = 두 조건 평균(MOKA 0.40, ReKep 0.55, Ours 0.85). Table II 실패 합 12 / 9 / 3 = Table I의 실패 수. Table III·IV 모두 IK% ≤ Clear%. Table IV Ours IK% (35.0, 37.2) = Table III affordance on	✅
C2a	zero-shot 기준선보다 높은 성공률 (Abstract, Sec. IV-D)	전체 17/20 vs MOKA 8/20 **p = 0.008**, vs ReKep 11/20 **p = 0.08**. 조건별(n = 10): Standard vs MOKA p = 0.30, vs ReKep p = 0.14. Cluttered vs MOKA p = 0.02, vs ReKep p = 0.63	방향은 일치하나 ReKep 대비는 n = 20에서 유의하지 않음
C2b	100개 시연 미세조정 VLA를 앞섬 (Abstract)	19/20 vs GR00T 6/20, p = 4×10^{-5}. 단계별로 접근은 차이 없음(20/20 vs 19/20), 차이는 잡기(19/20 vs 7/20, p = 1.4×10^{-4}). GR00T는 잡은 7번 중 6번 성공	✅ 단, 과제 1개이고 차이는 파지 단계에 있음
C2c	어포던스 조건화로 도구 성공 2/10 → 7/10 (Table III)	Fisher p = 0.07	큰 효과지만 n = 10
C3	Table III 합산 비율	반올림을 역산하면 정수 조합이 존재: 도구 off 108개 중 18(Clear)·18(IK), on 80개 중 77·28, P&P off 691-693개 중 162·39, on 274개 중 263·102. 장면당 IK 가능 후보 3.6 → 5.6(도구), 3.9 → 10.2(P&P)	✅
C4	"3배 이상 반복성" (Sec. I, Table IV)	σ 8.1 / 2.5 = **3.24배**, δ_max 64.9 / 3.9 = 16.6배	✅ (평균 기준)
C4b	그 평균이 무엇에 좌우되는가	δ_max가 장면별 σ의 최댓값이면 MOKA 나머지 9개 장면 σ 평균 = **1.79 mm**(Ours 2.5보다 작음). 한 실행의 최대 이탈이면 그 장면 σ ≥ 24.5 mm, 나머지 평균 ≤ 6.3 mm	⚠️ 이상치 한 장면이 크게 작용. 중앙값이 보고되지 않음
C4c	침투·충돌률 (Table IV)	최악 장면 P_max 하한: Tool/MOKA 95 mm(전체 P_max의 94%), Tool/Ours 67 mm, P&P/Ours 88 mm (`03` §5)	⚠️ 소수 장면의 깊은 침투가 평균을 지배
C5	long-horizon (Table V)	단계별 분모가 이전 단계 성공 수와 이어지고, E2E = 마지막 단계 성공 수. 재시도 8/10 vs 없음 6/10은 p = 0.63, Wilson [0.49, 0.94] vs [0.31, 0.83]	✅ 일관됨, 표본은 작음
C6	실행 시간 (Sec. IV-D)	6.7 + 9.6 + 3.1 = 19.4 s (합 일치). 모션 4.8 + 9.4 = 14.2 s. 하위 과제당 파지 검증 제외 약 34 s. VLM 호출 추정 19(pick-and-place) / 23(도구)회	✅ ("9.6 s가 키포인트 하나 기준인지"는 불명)
C7	방법과 실험이 버전 간 같은가	§2 표	⚠️ 크게 바뀜
C8	비교의 공정성: "그라운딩만 다르다" (Sec. IV-B)	MOKA·ReKep과는 파지·모션 스택을 공유. VLA와는 입력 정보량이 다름 (ZeroDex: 보정 카메라 4대, FoundationStereo·Pose, 물체 메쉬, 파지 시뮬레이션)	zero-shot 비교는 대체로 공정, VLA 비교는 같은 조건이 아님
C9	ε_tri, 동률 규칙 (Eq. 5-6)	v3 본문에 값과 규칙이 없음. toy에서 Eq. 6을 글자 그대로 구현하면 꼬리가 폭발하고, inlier 재적합으로 해결됨 (`03` §2)	⚠️ 재현에 필요한 정보 누락

2. v1 ↔ v3 대조

항목	v1 (2026-06-17, 21쪽, 부록 포함)	v3 (2026-10-20, 9쪽)
다시점 올리기	삼각측량 합의 + **reference-view ray voting**(합의가 τ_tri = 0.5M 미만이면 대체)	삼각측량 합의만. ray voting 언급 없음. 합의 실패 시 동작 미기재
로봇	xArm + Inspire	Franka(zero-shot 비교) + xArm(VLA 비교)
zero-shot 기준선	단일 시점 RGB-D 역투영 1개	MOKA, ReKep
성공률 시행 수	과제별 n = 5 (Ours 5/5, 4/5, 4/5 vs RGB-D 4/5, 4/5, 2/5)	조건별 n = 10, 합 n = 20
VLA 미세조정	과제당 30개 시연. GR00T·Being-H0 모두 0/5 (두 과제)	100개 시연. GR00T 6/20, Being-H0 0/20 (한 과제)
그라운딩 지표	정확도: L_grasp RGB-D 16.43 cm vs Ours 4.58 cm. 침투 오차 9.91 vs 9.81 (거의 같음)	반복성 σ, δ_max. 침투 P_max, P_avg, Coll% (Coll% 100 vs 17)
시점 수	4-6대, 2·3·5 시점 ablation (차이 작음)	"모든 실험 4시점", ablation 없음
long-horizon	retry 예산 4. Organize 4/6, Cooking 1/3	retry 1회. 8/10, 9/10 (없으면 6/10, 6/10)
모션 생성기	기성 팔-손 모션 생성기 [54]	cuRobo v2 [52] + Natural functional gradients [53] (고려대 공저자 추가)
하이퍼파라미터·프롬프트	부록 D: ε_tri = 20 px(640×480), τ = 0.65, 보정 격자 ±4 cm / 2 cm, 파지 가중치, VLM 프롬프트 원문	본문에 없음. "프롬프트는 보충 영상에"
프로젝트 페이지	초록이 ray voting 설명 (현재까지 유지)	—

해석: 실험이 더 강한 기준선과 더 많은 시행으로 다시 만들어졌다는 점은 긍정적입니다. 다만 (1) 핵심 기여였던 ray voting이 빠졌는데 그 이유와 영향이 설명되지 않았고, (2) v1에서는 침투 오차 개선이 없었는데 v3에서는 크게 개선된 것으로 나와 지표 변경의 영향을 분리할 수 없으며, (3) VLA 비교의 시연 수가 30 → 100개로 바뀌었습니다. v3만 읽은 독자는 이 이력을 알 수 없습니다.

3. 재현에 필요한 정보 체크리스트

정보	공개 여부
방법 식 (Eq. 1-11)	✅ v3 본문
ε_tri, τ_tri, τ_aff, 보정 격자, 파지 가중치	⚠️ v1 부록에만 있음 (v3 설정과 같은지 불명)
VLM 프롬프트	⚠️ v1 부록 D.2에 텍스트, v3는 영상
VLM 버전	✅ Gemini Robotics-ER 1.6 (preview) — 폐쇄형 API
카메라 배치, 보정 방법	❌ (4대, 스테레오 쌍 포함이라는 것만)
물체 메쉬 출처	❌ (메쉬가 필요하다는 사실 자체가 본문에 드러나지 않음)
Bag of Atomic Actions 궤적 데이터	❌ (네 가지 예시 그림만)
장면 목록, 성공 판정 세부	❌ (Standard / Cluttered 조건 설명 수준)

정보	공개 여부
의존 코드	✅ 대부분 공개: cuRobo(Apache-2.0), BODex, Dexonomy, FoundationPose·FoundationStereo(NVIDIA 라이선스), VLMPose(`snuvclab/vlmpose`), MOKA(MIT), ReKep. Natural functional gradients [53]의 코드는 확인하지 못함
ZeroDex 코드	❌ "Coming Soon"

4. 구현 가능성 판단

4.1 공식 코드를 그대로 돌리는 경우

현재 불가능합니다. 코드가 공개되지 않았습니다. 공개되더라도 다음이 필요합니다.

항목	요구 사항
로봇	Franka 또는 xArm 팔 + Inspire dexterous hand
센서	보정된 RGB 카메라 4대(스테레오 쌍 포함)
GPU	NVIDIA CUDA GPU (FoundationStereo, FoundationPose, BODex, cuRobo, 파지 물리 시뮬레이션)
VLM	Gemini Robotics-ER 1.6 API 키, 하위 과제당 약 20회 호출
물체	조작 대상마다 메쉬(스캔 또는 CAD)
라이브러리	기술 범주별 물체 중심 6D 궤적(시연 기록 또는 VLMPose)

4.2 이 맥(Apple M4 Pro, CUDA 없음)에서 할 수 있는 것

구성 요소	가능 여부	근거
다시점 합의, 정렬, 어포던스 투표, 끝점 보정의 수학	✅ 완료	numpy toy (`grounding_toy.py` , `alignment_toy.py`)
VLM 2D 그라운딩 (Gemini API)	✅ 가능	API 호출이라 기기와 무관합니다. 다만 이미지를 외부 서비스(Google)로 보내야 하고 API 키·비용이 필요합니다. v1 부록 프롬프트로 시작할 수 있습니다
실제 다시점 3D 그라운딩	⚠️ 장비가 있으면 가능	카메라 2-4대(스마트폰 가능)와 체커보드 보정만 있으면 삼각측량까지는 이 맥에서 돌릴 수 있습니다
FoundationStereo / FoundationPose	❌ (미확인)	CUDA 전용 연산을 쓰는 것으로 알고 있어 MPS로 돌리기 어렵다고 판단합니다. 확인하지는 않았습니다
BODex 파지 생성, cuRobo 모션 계획	❌	CUDA 커널 기반입니다
실제 로봇 실행	❌	하드웨어가 필요합니다

4.3 아이디어를 재구현하는 경우

계층	난이도	메모
그라운딩 (VLM 질의 + 다시점 합의)	낮음-중간	핵심은 수십 줄이지만 ε_tri를 VLM 픽셀 오차에 맞춰야 하고, 동률·합의 실패 처리를 정해야 합니다(`03` §2). inlier 재적합을 권장합니다
도구 궤적 정렬 (Eq. 7)	낮음	닫힌 해가 있습니다(`03` §3). 앵커 간격 불일치가 그대로 끝점 오차가 된다는 점을 점검해야 합니다
어포던스 영역 (Eq. 9)	낮음	메쉬 꼭짓점 투영 투표. 메쉬와 자세 추정이 있어야 합니다

계층	난이도	메모
파지 생성 + 안정성 시뮬레이션	중간-높음	BODex·Dexonomy를 손 모델에 맞춰 설정해야 하고 NVIDIA GPU가 필요합니다
팔-손 모션 계획	중간	cuRobo로 대체할 수 있습니다. [53]은 코드 공개 여부를 확인하지 못했습니다
long-horizon 검증 루프	낮음	VLM 프롬프트 설계 문제입니다. v1 부록의 planner 프롬프트가 출발점입니다

요약: 지금은 공식 코드가 없어서 "그대로 재현"은 할 수 없습니다. 아이디어의 핵심인 그라운딩 계층(VLM + 다시점 합의)은 이 맥에서 Gemini API로 바로 시작할 수 있습니다. 반면 실행 계층(깊이·자세 추정, 파지, 모션)은 NVIDIA GPU와 로봇 하드웨어가 있어야 하고, 물체 메쉬도 준비해야 합니다. 논문 성능을 비교하려면 장면 목록과 성공 기준이 공개되어야 하는데, 지금은 없습니다.

02. 선행연구와 계보

번호 [n]은 v3 참고문헌 번호이고, arXiv ID는 참고문헌 목록에 적힌 값을 그대로 옮겼습니다. 이 문서의 각 논문을 별도로 열어 내용을 검증하지는 않았습니다. 하이퍼파라미터와 프롬프트는 v1 부록(arXiv:2606.19340v1)에서 직접 확인했습니다.

1. 계보도

```
[end-to-end VLA: 로봇 데이터로 학습]
  RT-1 [1] → RT-2 [2] → OpenVLA [3], Octo [4] → π0 [5]
  dexterous·휴머노이드: GR00T N1 [20], DexVLA [15], DexGraspVLA [21], Being-H0 [22] ← 비교 대상
(100개 시연 미세조정)

[foundation model로 zero-shot 조작: 중간 표현이 무엇인가]
  코드 생성          Code as Policies [29], ProgPrompt [30], VoxPoser [31] (3D value map)
  visual prompting PIVOT [33], RoboPoint [34], Manipulate-Anything [35]
                   MOKA [6] arXiv:2403.03174   키포인트 + 운동 원시 동작, 단일 RGB-D 역투영    ← 비교
대상
  제약 기반          ReKep [32] arXiv:2409.01652  키포인트 관계 제약을 풀어 엔드이펙터 자세  ← 비교 대상
                   OmniManip [42] (물체 중심 상호작용 원시 동작을 공간 제약으로)
  오케스트레이터    MAESTRO [36], [37] (VLM이 기술을 순서화·검증, 실행은 학습된 정책)

[3D 그라운딩] 다시점 스테레오 [38], SpatialVLM [39], RoboSpatial [40], VLM-Grounder [41](다시점 → 3D
그라운딩)
[실행] 물체 중심 기술 이전: VLMPose [45](같은 그룹), MimicFunc [46]
       dexterous 파지: DexGraspNet [47], BODex [48], Dexonomy [49], RT-Affordance [50]
       모션: cuRobo v2 [52] arXiv:2603.05493, Natural functional gradients [53]
arXiv:2605.28202(공저자)
       검증·재계획: Inner Monologue [51]

          ▼
  ★ ZeroDex: VLM 키포인트를 다시점 합의로 metric 3D에 올리고, 물체 중심 6D 궤적 정렬 + 어포던스 파지 + 충돌
·IK 검증
```

차별점 요약: MOKA와 ReKep은 VLM 출력을 **단일 RGB-D 시점**에서 깊이로 역투영하고, 남는 깊이 모호성을 VLM 추론이나 제약 범위에 맡깁니다. ZeroDex는 같은 VLM 질의를 여러 보정 시점에 반복해서 **기하 합의**로 깊이를 정합니다. 그리고 그 3D 키포인트를 도구 궤적 정렬과 파지 영역 결정에 함께 씁니다. 학습된 정책이 없다는 점은 MOKA, ReKep과 같고, 실행 스택(파지 생성, 모션 계획)은 비교 실험에서 공유합니다.

2. 구성 요소별 출처

역할	출처	이 논문에서의 쓰임
VLM	Gemini Robotics-ER 1.6 (v1: `gemini-robotics-er-1.6-preview`), Gemini Robotics 1.5 [19]	계획, 기준 시점 선택, 시점별 키포인트, 어포던스 박스, 실행 검증
키포인트 + 원시 동작 표현	MOKA [6]	grasp / waypoint / release 구조가 가장 비슷한 선행연구
강건 합의	RANSAC [54]	시점 쌍 삼각측량 후보를 재투영 inlier 수로 고름 (Eq. 5-6)
다시점 기하	Multi-view stereo tutorial [38]	삼각측량의 근거

역할	출처	이 논문에서의 쓰임
깊이·자세	FoundationStereo [43], FoundationPose [44]	스테레오 쌍 깊이(장면 충돌), 다중 물체 6D 자세
물체 중심 궤적 생성	VLMPose [45] arXiv:2604.09781 (Baik, Kim, Choi, Joo)	Bag of Atomic Actions 항목 생성
파지 생성	BODex [48] + 어포던스 거리·방향 항 (v1 부록 B.2), Dexonomy [49]식 손가락 닫기 (B.1)	일반 형상 / 손잡이형 영역
팔-손 모션	cuRobo v2 [52], Natural functional gradients [53]	운반 궤적, 기구학·충돌 제약, η
실행 검증·재계획	Inner Monologue [51]	텍스트 메모리 + continue / retry / replan
VLA 기준선	GR00T N1 [20] arXiv:2503.14734, Being-H0 [22] arXiv:2507.15597	100개 시연으로 사후학습

3. 이 저장소의 다른 논문과의 관계

논문	관계
FlashDexRetarget (`flashdexretarget/`)	둘 다 "작업마다 로봇 시연을 모으지 않고" dexterous 손 동작을 만들지만 방향이 반대입니다. FlashDexRetarget은 사람 시연을 RL로 로봇 궤적으로 **변환**하고, ZeroDex는 서론에서 그 경로(리타겟팅의 embodiment 간극)를 피해야 할 문제로 듭니다. 그런데 ZeroDex의 Bag of Atomic Actions는 바로 **물체 중심 6D 도구 궤적**을 저장합니다. FlashDexRetarget이나 아래 Do as I Do가 사람 시연에서 얻는 물체 궤적은 embodiment와 무관하므로 이 라이브러리를 채우는 데 그대로 쓸 수 있습니다. 실행 측면에서는 FlashDexRetarget이 물리적으로 검증된 접촉을, ZeroDex는 파지 시뮬레이션 + 운반 궤적 계획을 씁니다.
Do as I Do (`do_as_i_do/`)	같은 "영상·VLM → 3D 기하" 문제를 다른 방식으로 풉니다. Do as I Do는 단안 영상에서 SAM 3D로 메쉬와 4D 궤적을 복원하고, ZeroDex는 보정된 다시점 + FoundationPose로 자세를 얻습니다. ZeroDex가 본문에 드러내지 않은 "물체 메쉬 필요" 가정(01 §4.2)을 Do as I Do식 SAM 3D 복원으로 대체할 수 있는지가 둘을 잇는 질문입니다. Do as I Do가 출력하는 물체 궤적도 Bag of Atomic Actions 항목이 될 수 있습니다.

4. 논문이 다루지 않았지만 관련 있는 연구 (내 판단)

주제	관련성	근거 수준
Visual hull / space carving (Laurentini 1994; Kutulakos & Seitz 2000)	Eq. 9의 어포던스 영역은 시점별 2D 박스 시야뿔의 투표형 교집합입니다. 가시성 검사가 없어서 가려진 뒷면 꼭짓점도 포함됩니다(`03` §4).	내 사전 지식. 서지 확인 필요
두 점 정렬과 absolute orientation (Horn 1987; Umeyama 1991)	Eq. 7은 대응점 2개짜리 정합입니다. 일반 회전은 앵커 축 둘레로 결정되지 않으므로 회전 축 제한이 필수이고, 축척이 다르면 잔차가 남습니다(`03` §3).	내 사전 지식. 서지 확인 필요
Self-consistency (LLM의 다중 샘플 투표)	시점별 VLM 질의를 합의로 묶는 것은 시점 다양성을 이용한 self-consistency와 같은 구조입니다. 같은 시점에서 여러 번 샘플링해 투표하는 확장도 생각할 수 있습니다.	내 해석
과제 지향 파지 (예: GraspGPT, LERF-TOGO)	언어 조건 어포던스 → 파지라는 같은 문제를 학습 기반으로 다룹니다.	내 사전 지식. 서지 확인 필요

한계: 4절의 서지 정보는 내 사전 지식에 근거합니다. 블로그나 git에 올리기 전에 원문을 직접 확인해야 합니다.